

Bloque I

Fundamentación

1	2	3	4
5	6	7	8
9	10	11	12

Bloque II

Formalización

13	14	15	16
17	18	19	

Bloque III

Descubrimiento/ML

20	21	22	23
24	25	26	27

Bloque IV

Causal AI

28	29	30	31
32			

previos · actual · próximos

CAPÍTULO 1

La Paradoja del Efecto Cero: Geometría de la Causalidad

Bloque I · Nivel GCE: 1 · Localización + anuncio Niveles 2 y 3

Variante: teorico-formal

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender por qué un ATE nulo NO implica distribuciones idénticas (Paradoja del Efecto Cero).
2. Conocer la jerarquía GCE (Localización, Forma, Geometría) y su mapeo a los 4 bloques del libro.
3. Verificar computacionalmente la paradoja usando numpy, scipy y la distancia W_1 (POT).

★ Prerequisitos

Lectura: Libro monográfico ``libro/main.pdf`` · Capítulo 1 · secciones GCE y axiomas (A1–A4b).
Apéndice de Demostraciones: `proof\_01` y `proof\_02`.

Notebook (pack): `notebooks/Bloque_I/notebooks/01_paradoja_efecto_cero_geometria_causalidad.ipynb`

Notebook (JB): `jupyter_book/content/bloque_01_fundamentacion/01_paradoja_efecto_cero.ipynb`

Agenda

S01 · Motivación: paradoja del efecto cero + caso Beca 18

S02 · Marco GCE, resultados potenciales y axiomas

S03 · Niveles 1, 2 y 3 de la jerarquía GCE

S04 · ★ Punto interactivo: predicción sobre W_1

S05 · Verificación en Python (Proofs-to-Python)

S06 · Caso Beca 18: resolución + validación

S07 · Mapeo GCE activo · Errores · Discusión

Problema

Un programa social muestra un ATE de cero sobre el ingreso mensual promedio. ¿Significa que el programa no tuvo efecto? La respuesta es NO: el programa puede haber polarizado la distribución (más ricos y más pobres) sin mover la media. Medir solo el centro es estructuralmente ciego a transformaciones distributivas.

Gancho empírico

Caso concreto del libro (canónico). Con presión arterial sistólica, con $Y_0 \sim \mathcal{N}(120, 12)$ como distribución contrafactual y Y_1 como mezcla $0.5\mathcal{N}(105, 8) + 0.5\mathcal{N}(135, 10)$ (semilla 42, $n = 5\{, \}000$), se obtiene $\text{ATE} \approx -0.137$ mmHg (próximo a cero) **si bien** $W_1 \approx 6.050$ mmHg. La paradoja posee una cuantificación geométrica precisa, alineada a la del libro.

Caso del curso · Beca 18 — transferencia educativa. Veremos cómo un programa «sin efecto promedio» reestructura radicalmente la distribución de ingresos post-tratamiento. Retomaremos este caso en S05 (teoría), S09 (código), S11 (resolución) y S12 (validación).

$Y(1), Y(0)$	Resultados potenciales bajo tratamiento y control (Neyman-Rubin).
τATE	Average Treatment Effect = $E[Y(1)] - E[Y(0)]$. Métrica del Nivel 1.
D_{loc}	$D_{\text{loc}} = \ \tau\text{ATE}\ $: divergencia de localización en GCE. Coincide con $ \tau\text{ATE} $.
SUTVA	Stable Unit Treatment Value Assumption: no interferencia + consistencia.
$D_f(P, Q)$	Divergencia f (KL, TV, χ^2). Métrica del Nivel 2 (Forma).
$W_1(P, Q)$	Distancia de Wasserstein-1. Métrica del Nivel 3 (Geometría / OT).
$\hat{W}(G, 1)$	Wasserstein causal con restricciones del grafo G.
GCE	Geometría de la Causalidad Estadística: marco unificador del libro.

Resultado potencial y ATE

Bajo el marco de Neyman-Rubin, cada unidad i posee dos resultados contrafactuales $Y_{i(1)}$ (bajo tratamiento) y $Y_{i(0)}$ (bajo control). Bajo SUTVA, el efecto causal individual es $\tau_i = Y_{i(1)} - Y_{i(0)}$ y el parámetro poblacional de interés es el Average Treatment Effect. En el caso Beca 18: $Y_{i(1)}$ = ingreso si el estudiante recibió la beca, $Y_{i(0)}$ = ingreso contrafactual sin beca.

$$\tau_{\text{ATE}} = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$$

Supuesto	Implicación	Chequeo en el caso
SUTVA · No interferencia	$Y_i(t_1, \dots, t_N) = Y_i(t_i).$	Beca 18: un estudiante no afecta el ingreso de otro por recibir la beca.
SUTVA · Consistencia	$Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0).$	El ingreso observado coincide con el potencial correspondiente a la asignación real.
Ignorabilidad (CIA)	$(Y(1), Y(0)) \perp T \mid X.$	Plausible si controlamos por nota escolar, ingreso familiar, región.
Overlap	$0 < P(T=1 \mid X=x) < 1.$	Verificar: ¿hay becarios y no becarios en cada estrato de X?
A1 · Separación	$D(P, Q) = 0 \iff P = Q.$	$W_1 = 0$ solo si distribuciones idénticas (más estricto que $\tau\text{ATE} = 0$).
A2 · Costo de reasignación	$D(P, Q) > 0$ si $P \neq Q$ (costo positivo de transportar masa).	Núcleo económico del OT: no hay reasignaciones gratis.
A3 · Soporte disjunto	$D(P, Q)$ finita incluso si $\text{supp}(P) \cap \text{supp}(Q) = \emptyset.$	W_1 es robusto a soportes disjuntos, a diferencia de KL/TV.
A4a · Estabilidad marginal	$D(P, Q)$ sensible a cambios marginales de P y Q.	Acoplada a la métrica de localización: $\tau\text{ATE} = 0$ no implica $D = 0$.
A4b · Estabilidad intervencional	$D(P \setminus_{\text{do}}(X), Q \setminus_{\text{do}}(X'))$ estable bajo intervenciones del grafo.	Demostrado (autocontenido, paper §3.3.1): W_1 viola 4b. ⚠ Pendiente de Cheridito & Eckstein 2025 solo la afirmación positiva general — que $\hat{W}(G,1)$ sí satisface 4b (ver `gce/artifacts/cotejo_cheridito.md`).

Paradoja del Efecto Cero (Proposición de Jensen)

Existen $P_{Y(1)}$ y $P_{Y(0)}$ con $\tau_{\text{ATE}} = 0$ pero $W_1(P_{Y(1)}, P_{Y(0)}) > 0$. Concretamente, si $Y_0 \sim \mathcal{N}(\mu, \sigma)$, $Y_1 = 0.5\mathcal{N}(\mu - a, \sigma_1) + 0.5\mathcal{N}(\mu + a, \sigma_2)$ con la misma media μ , se satisface la cota inferior independiente de σ : $W_1(P_{Y(1)}, P_{Y(0)}) \geq a - \sqrt{\frac{2}{\pi}}$, de modo que $W_1 > 0$ siempre que $a > \sqrt{\frac{2}{\pi}}$. La cadena maestra $|\tau_{\text{ATE}}| \leq W_1(P_{Y(1)}, P_{Y(0)}) \leq W^{G,1}(P_{Y(1)}, P_{Y(0)})$ es estricta en general.

Demostración: Apéndice de Demostraciones, Cap. 1 · proof_01 y proof_02 (Apéndice de Demostraciones del libro)..

Paso 1. Construir $Y(0) \sim \mathcal{N}(120, 12)$ y $Y_1 = 0.5\mathcal{N}(105, 8) + 0.5\mathcal{N}(135, 10)$. Ambas comparten media marginal $\mathbb{E}[Y] \approx 120$, de modo que $\tau_{\text{ATE}} \approx 0$ por construcción.



Paso 2. Verificar numéricamente: $\tau_{\text{ATE}} \approx -0.137$ mmHg (próximo a cero, solicitar error tipo I). Nivel 1 reporta nulidad.



Paso 3. En el DGP teórico del libro (modas $\pm a$), Jensen da $W_1 \geq a - \sqrt{\frac{2}{\pi}}$ (independiente de σ). En el experimento mmHg: $\text{ATE} \approx -0.137$, $W_1 \approx 6.050$, cota dual K-R ≈ 6.029 ($n = 5\{, \}000$, semilla 42).



Paso 4. Calcular W_1 vía `scipy.stats.wasserstein_distance` (o cuantiles empíricos): $W_1 \approx 6.050$ mmHg. Cota dual ≈ 6.029 mmHg. El Nivel 3 revela el reordenamiento distribucional.



Paso 5. Conclusión: el Nivel 3 subsume la información del Nivel 1 ($W_1 = 0 \Rightarrow \tau_{\text{ATE}} = 0$) pero NO al revés. La cadena maestra se cumple con holgura.

Punto de quiebre · Predictivo

- ★ Antes de ver el código, ¿creen que W_1 será mayor, igual o menor que $|\tau_{ATE}|$? Mano alzada: (a) $W_1 > |\tau_{ATE}|$, (b) $W_1 = |\tau_{ATE}|$, (c) $W_1 < |\tau_{ATE}|$.

 2-3 min · Votación mano alzada o Mentimeter



```

import numpy as np
from scipy.stats import wasserstein_distance # dependencia mínima
# POT opcional: import ot # pip install POT (ground cost ≠ |x-y|)

np.random.seed(42)
n = 5_000 # notebook $5bis y gce/artifacts/ejemplo_paradoja_canonico.py

# Y(0) ~ N(120, 12) — control unimodal (mmHg sistólica)
Y0 = np.random.normal(120, 12, n)
# Y(1) = 0.5 N(105, 8) + 0.5 N(135, 10) — tratamiento bimodal, misma media
Y1 = np.concatenate([
    np.random.normal(105, 8, n // 2),
    np.random.normal(135, 10, n // 2),
])

# Nivel 1: ATE (ciego a la reconfiguración)
ate = Y1.mean() - Y0.mean()
# Nivel 3: W1 vía scipy
W1 = wasserstein_distance(Y0, Y1)
# Cota dual Kantorovich-Rubinstein (f(y)=|y-120| 1-Lipschitz)
cota_dual = np.mean(np.abs(Y1 - 120)) - np.mean(np.abs(Y0 - 120))

print(f'tau_ATE = {ate:+.3f} mmHg')
print(f'W1 = {W1:.3f} mmHg')
print(f'cota_dual = {cota_dual:.3f} <= W1 [OK]')
print(f'cadena : |ATE|={abs(ate):.3f} <= W1={W1:.3f} [OK]')
assert abs(ate) <= W1 + 1e-6, 'cadena maestra |ATE| ≤ W1 rota'
assert cota_dual <= W1 + 1e-6, 'violación dualidad K-R'

```

Invariante (cadena maestra GCE)

```

# Invariante cadena maestra GCE |ATE| ≤ W1
assert abs(ate) <= W1 + 1e-6, f'rota: |{ate:.4f}| > {W1:.4f}'
# Dualidad K-R (cota dual ≤ W1), como en ejemplo_paradoja_canonico.py
assert cota_dual <= W1 + 1e-6, 'violación dualidad K-R'

```

Salida

```
tau_ATE = -0.137 mmHg
```

```
W_1      = 6.050 mmHg
cota_dual = 6.029 <= W1  [OK]
cadena   : |ATE|=0.137 <= W1=6.050  [OK]
```

💡 DGP canónico del libro (n=5000, seed 42, N(120,12) vs mezcla 105/135). Dependencia mínima: scipy. Reproducible desde `gce/artifacts/ejemplo\_paradoja\_canonico.py` y notebook 5bis. La cota de Jensen $W_1 \geq a - \sqrt{2/\pi} \sigma$ (independiente de σ) se demuestra en el libro para el DGP teórico con modas $\pm a$; aquí reportamos la cota dual K-R del experimento mmHg.

Recordatorio del caso (S03)

Del libro monográfico (Cap. 1). Simulación de presión arterial sistólica: control $Y_0 \sim N(120, 12)$ mmHg; tratamiento como mezcla $0.5N(105, 8) + 0.5N(135, 10)$. Semilla 42, $n = 5\{, \}000$. El experimento se replica en `gce/artifacts/ejemplo_paradoja_canonico.py` y en la sección 5bis del notebook 01.

Beca 18 (hilo de aula): sigue adelante en S03 y S12 — para el aula se presenta como un caso de política con $ATE \approx 0$ y $W_1 > 0$ en soles/día.

Resultado numérico

Canónico mmHg: $\tau ATE \approx -0.137$ mmHg (próximo a cero), **$W_1 \approx 6.050$ mmHg**, cota dual K-R ≈ 6.029 mmHg ($\leq W_1$). En el libro, la cota de Jensen $W_1 \geq a - \sqrt{\frac{2}{\pi}}$ (independiente de σ) se demuestra para el DGP teórico con modas separadas por a . Para **Beca 18:** reportar solo "ATE ≈ 0 , programa sin efecto" sería engañoso: el programa SÍ restructura las distribuciones (cola inferior reducida, cola superior engrosada), aunque el centro no se mueva.

Lectura de política · Recomendación al MIMP/PRONABEC: cualquier reporte causal sobre programas sin cambio en la media debe complementarse con W_1 y con visualización de las distribuciones contrafactuales; de lo contrario las redistribuciones sobre ricos y pobres quedan ocultas.

Técnica: Bootstrap no paramétrico sobre W_1 + placebo

Se remuestran con reposición 1,000 veces los grupos tratamiento y control y se recalcula W_1 . El IC 95% es $[S/3.41, S/4.29]$, excluyendo cero. Adicionalmente, se aplica un test de placebo aleatorizando la asignación de tratamiento: la W_1 placebo decae a $S/0.18$ (dentro del rango de ruido), confirmando que el W_1 observado no es artefacto.

Conclusión · La paradoja es estadísticamente significativa; el programa sí tiene efecto distribucional.

Nivel GCE

Nivel 1 (Localización) + anuncio de Niveles 2 y 3

Métrica principal

τ_{ATE} (con demostración de su ceguera) · W_1 como solución

Pregunta activa (1 min)

Si tuvieran que reportar a un Ministerio el impacto de un programa, ¿qué nivel GCE elegirían y por qué? ¿Qué pregunta NO puede responder el Nivel 1 que sí puede el Nivel 3? (1 min de discusión con su vecino.)

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq \widehat{W}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

Concluir 'no hay efecto' a partir de $\tau_{ATE} \approx 0$. La nulidad del ATE no implica nulidad del efecto distribucional.

Aplicar test t de medias como única métrica causal. El test t es ciego al Nivel 2 y 3.

Reportar W_1 sin IC bootstrap. W_1 es un estimador y requiere cuantificar su incertidumbre.

Confundir W_1 con la diferencia de medianas. Solo en traslaciones puras $W_1 = |\text{mediana}_1 - \text{mediana}_0|$.

Aplicar divergencias f (KL, TV) con soportes disjuntos: divergen. W_1 es robusto a soportes disjuntos.

Conexiones conceptuales

Conecta con Cap. 2 (problema fundamental: el ATE requiere aleatorización o CIA para ser identificable) y con Cap. 12 (cuándo conviene subir al Nivel 2 o 3 en el árbol de decisión metodológico). El Nivel 3 se materializará en Caps. 20-27 (DML, Causal Forests, transporte óptimo causal).

Pregunta de discusión

Si usted debe reportar a un Ministerio el impacto de un programa con $\tau\text{ATE} \approx 0$ pero $W_1 > 0$, ¿qué métrica elige? ¿Qué riesgos políticos tiene cada elección?

Ejercicio (5-10 min)

En Python, construya dos distribuciones normales con la misma media ($\mu = 5$) pero distintas desviaciones estándar ($\sigma_1 = 1$, $\sigma_2 = 3$). Calcule τATE , D_{KL} y W_1 . Verifique que la cadena maestra se cumple. ¿Cuál de las tres métricas es más informativa? (Semilla 42, $n = 5,000$.)

Resumen

- Un ATE nulo NO implica distribuciones idénticas: esta es la Paradoja del Efecto Cero.
- La jerarquía GCE organiza los métodos en tres niveles (Localización, Forma, Geometría) con métricas estrictamente anidadas.
- La cadena maestra $|\tau\text{ATE}| \leq W_1 \leq W^\wedge(G,1)$ cuantifica la información perdida al quedarse en el Nivel 1.

Referencias clave

- (1) Monge, G. (1781). Mémoire sur la théorie des déblais et des remblais.
- (2) Kantorovich, L. (1942). On the translocation of masses. Dokl. Akad. Nauk SSSR.
- (3) Pearl, J. (2009). Causality: Models, Reasoning, and Inference. Cambridge University Press.

Próximo episodio · Cap. 2 — El Problema Fundamental y la Relevancia de la Aleatorización: por qué la randomización resuelve el sesgo de selección y cómo el RCT se ubica en el Nivel 1 de GCE.

Gancho: «¿Qué pasa si NO podemos aleatorizar? Ese será el drama del resto del Bloque I.»