

Bloque I

Fundamentación

1	2	3	4
5	6	7	8
9	10	11	12

Bloque II

Formalización

13	14	15	16
17	18	19	

Bloque III

Descubrimiento/ML

20	21	22	23
24	25	26	27

Bloque IV

Causal AI

28	29	30	31
32			

previos · actual · próximos

CAPÍTULO 2

El Problema Fundamental y la Aleatorización

Bloque I · Nivel GCE: 1 · Localización (RCT)

Variante: teorico-formal

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender el problema fundamental de la inferencia causal: nunca observamos ambos resultados potenciales en la misma unidad.
2. Diagnosticar el sesgo de selección y cuantificarlo en el caso Beca 18 (asignación no aleatoria).
3. Verificar computacionalmente que la aleatorización elimina el sesgo y recupera el ATE verdadero.

★ Prerequisitos

Lectura: Libro monográfico ``libro/main.pdf`` · Capítulo 2. Leer Cap. 2 del libro completo (secciones: El Problema Fundamental, Anatomía del Sesgo, RCT como Nivel 1 en GCE).

Notebook (pack): `notebooks/Bloque_I/notebooks/02_problema_fundamental_relevancia_aleatorizacion.ipynb`

Notebook (JB): `jupyter_book/content/bloque_01_fundamentacion/02_problema_fundamental.ipynb`

Agenda

S01 · Motivación: Beca 18 sin aleatorización + RCT médico (libro)

S02 · Problema fundamental y sesgo de selección

S03 · Identificabilidad e independencia causal

S04 · ★ Punto interactivo: predicción del signo del sesgo

S05 · Verificación en Python (Proofs-to-Python)

S06 · Caso Beca 18: slide de puente con RCT médico

S07 · Mapeo GCE · Errores · Discusión

Problema

Beca 18 asignó becas según criterios de pobreza y mérito académico, NO por aleatorización. Los becarios son sistemáticamente distintos de los no becarios ANTES del tratamiento: mejores notas, mayor ingreso familiar, mejor apoyo escolar. Comparar sus ingresos post-beca sin ajuste produce un sesgo de selección positivo.

Gancho empírico

En un dataset de 10,000 estudiantes peruanos, el ATE verdadero es 300 soles/mes, pero la comparación ingenua (becarios vs. no becarios) reporta 418 soles/mes — un sesgo de +118 soles. La aleatorización elimina este sesgo por diseño.

Caso del curso · Beca 18 — sesgo al comparar becarios vs. no becarios sin aleatorización. El notebook del capítulo usa además el dataset **NSW mixtape** (LaLonde, 1986) — el RCT laboral paradigmático — como referencia aleatorizada real. Este caso atraviesa la sesión: S03 (motivación), S05-S06 (teoría), S09-S10 (código), S11 (slide de puente con RCT médico del libro), S12 (validación).

$Y_i(1), Y_i(0)$	Resultados potenciales de la unidad i bajo tratamiento y control (Neyman-Rubin).
τ_{ATE}	Average Treatment Effect = $E[Y(1)] - E[Y(0)]$. Métrica del Nivel 1 GCE.
Sesgo de selección	$E[Y(0) T=1] - E[Y(0) T=0]$: diferencia en el contrafactual entre grupos.
CIA	Conditional Independence Assumption: $(Y(1), Y(0)) \perp T \mid X$.
SUTVA	Stable Unit Treatment Value Assumption: no interferencia + consistencia.
RCT	Randomized Controlled Trial: $T \perp (Y(1), Y(0))$ por diseño.
Independencia fuerte	$T \perp (Y(1), Y(0))$: garantizada por RCT, NO por observación.

El problema fundamental de la inferencia causal

Para cada unidad i existen dos resultados potenciales $Y_{i(1)}$ (bajo tratamiento) y $Y_{i(0)}$ (bajo control), pero solo observamos uno: $Y_i^{\text{obs}} = T_i \cdot Y_{i(1)} + (1 - T_i) \cdot Y_{i(0)}$. El efecto causal individual $\tau_i = Y_{i(1)} - Y_{i(0)}$ es **fundamentalmente no observable** en una misma unidad. Solo podemos estimarlo poblacionalmente vía supuestos. En Beca 18: $Y_{i(1)}$ = ingreso si recibió la beca; $Y_{i(0)}$ = ingreso contrafactual sin beca.

$$\tau_{\text{ATE}} = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$$

Supuesto	Implicación	Chequeo en el caso
SUTVA · No interferencia	$Y_i(T_1, \dots, T_N) = Y_i(T_i)$.	Beca 18: un becario no afecta el ingreso de otro.
SUTVA · Consistencia	$Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$.	El ingreso observado coincide con el potencial correspondiente.
Independencia fuerte (RCT)	$T \perp (Y(1), Y(0))$.	Beca 18 NO la satisface: T depende de nota e ingreso familiar.
Overlap	$0 < P(T=1 X) < 1$.	Verificar: ¿hay becarios y no becarios en cada estrato de X?
CIA (observacional)	$(Y(1), Y(0)) \perp T \mid X$.	Plausible si controlamos por nota, ingreso, región.

Descomposición del sesgo de selección

Bajo consistencia (SUTVA), la diferencia de medias observacional se descompone: $\underbrace{\mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]}_{\text{diferencia observada}} = \underbrace{\mathbb{E}[Y(1)|T = 1] - \mathbb{E}[Y(0)|T = 1]}_{\tau_{\text{ATE}}} + \underbrace{\mathbb{E}[Y(0)|T = 1] - \mathbb{E}[Y(0)|T = 0]}_{\text{sesgo de selección}}$ Bajo $T \perp (Y(1), Y(0))$ (RCT), el sesgo de selección es cero y la diferencia observada iguala el ATE. Bajo observación sin CIA, el sesgo es distinto de cero.

Demostración: Apéndice de Demostraciones, Cap. 2 · proof_01..03 (Apéndice de Demostraciones del libro). Cubren: descomposición del sesgo, anulación bajo RCT y consistencia del estimador de diferencia de medias..

Paso 1. Partir de la diferencia observada: $\mathbb{E}[Y|T = 1] - \mathbb{E}[Y|T = 0]$.



Paso 2. Sustituir $Y = TY(1) + (1 - T)Y(0)$ y simplificar: $\mathbb{E}[Y(1)|T = 1] - \mathbb{E}[Y(0)|T = 0]$.



Paso 3. Sumar y restar $\mathbb{E}[Y(0)|T = 1]$: aparece el ATT y el sesgo de selección.



Paso 4. Bajo RCT ($T \perp Y(0)$): $\mathbb{E}[Y(0)|T = 1] = \mathbb{E}[Y(0)|T = 0] \rightarrow \text{sesgo} = 0$.




Paso 5. Bajo observación sin CIA: $\mathbb{E}[Y(0)|T = 1] \neq \mathbb{E}[Y(0)|T = 0] \rightarrow \text{sesgo} \neq 0$. En Beca 18: becarios tendrían mayor ingreso sin beca (sesgo +).

Punto de quiebre · Predictivo

★ Si aleatorizamos la asignación de Beca 18, ¿cuál será el signo del sesgo de selección en la comparación ingenua? (a) +, (b) −, (c) ≈ 0 . Mano alzada.

🕒 2-3 min · Votación mano alzada o Mentimeter



T depende de X $\rightarrow$ sesgo de selección

```

import numpy as np
rng = np.random.default_rng(42)
n = 10_000

# DGP: Beca 18 (T) depende de nota escolar e ingreso familiar
nota = rng.normal(14, 2, n)
ingreso_fam = rng.normal(2500, 800, n)
logit = 2*(nota - 14) - 0.001*(ingreso_fam - 2500)
prop = 1 / (1 + np.exp(-logit))
T_obs = (rng.uniform(size=n) < prop).astype(int)

# Potential outcomes
Y0 = 1500 + 50*nota + 0.1*ingreso_fam + rng.normal(0, 200, n)
Y1 = Y0 + 300 # efecto verdadero = 300 soles
Y_obs = T_obs * Y1 + (1 - T_obs) * Y0

# Estimador ingenuo (sesgado)
naive_ate = Y_obs[T_obs==1].mean() - Y_obs[T_obs==0].mean()

# RCT (contrafactual: aleatorizar T)
T_rct = rng.integers(0, 2, n)
Y_rct = T_rct * Y1 + (1 - T_rct) * Y0
rct_ate = Y_rct[T_rct==1].mean() - Y_rct[T_rct==0].mean()

print(f'true_ATE = {(Y1-Y0).mean():.2f}')
print(f'naive_ATE = {naive_ate:.2f} (sesgo: +{naive_ate-300:.2f})')
print(f'rct_ATE = {rct_ate:.2f} (RCT recupera el verdadero)')

```

Salida

```

true_ATE = 300.00
naive_ATE = 418.37 (sesgo: +118.37)
rct_ATE = 299.34 (RCT recupera el verdadero)

```

💡 El sesgo +118.37 soles refleja que los becarios ya eran de hogares con más apoyo escolar. La aleatorización lo elimina por diseño.

Slide de puente V5 — Beca 18 (curso) | RCT médico (libro)

Caso peruano (Beca 18)	Caso original del libro (RCT médico)
Descripción: Becarios vs. no becarios sin aleatorización. T depende de nota e ingreso familiar.	Descripción: Ensayo clínico de hipotensión con T asignado aleatoriamente. Independencia fuerte por diseño.
Resultado: naive_ATE = 418 soles (sesgo +118); rct_ATE = 299 soles (verdad).	Resultado: diferencia de medias = ATE (sesgo = 0 por diseño).
Lección transferible: sin aleatorización, T depende de X → sesgo. Se necesita ajuste (Caps. 3-9).	Lección transferible: la aleatorización es el gold standard; establece el ideal a recuperar.

Conexión V5 · El RCT médico muestra el ideal (independencia fuerte por diseño). Beca 18 muestra la realidad (asignación no aleatoria). Los métodos del Bloque I (Caps. 3-9: matching, IPW, IV, RDD, DiD, synth) intentan recuperar lo que la aleatorización habría dado gratis.

Técnica: Simulación Monte Carlo (1000 réplicas)

Repetir el experimento 1000 veces con semillas distintas. Calcular la distribución del sesgo ($\text{naive_ATE} - \text{true_ATE}$) bajo asignación observacional vs. RCT. Bajo RCT: media del sesgo ≈ 0 (IC 95% incluye cero). Bajo observación: media del sesgo $\approx +118$ (IC 95% no incluye cero). Esto confirma que la aleatorización elimina el sesgo en valor esperado, no solo en una muestra.

Conclusión · La aleatorización es la única herramienta que garantiza ausencia de sesgo de selección por diseño. Sin ella, se necesita ajuste (Bloque I).

Nivel GCE

1 · Localización (RCT)

Métrica principal

$\tau_{ATE} = E[Y(1)] - E[Y(0)]$, estimado bajo RCT. Bajo aleatorización: identificable sin supuestos adicionales (más allá de SUTVA y overlap).

Pregunta activa (1 min)

Si tuvieran que diseñar una evaluación de impacto desde cero, ¿qué preferirían: un RCT pequeño pero bien diseñado, o un estudio observacional grande con muchos controles? Pista: el RCT **NSW mixtape** del notebook muestra la diferencia. Discutan 1 min.

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq W^*(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

- Pensar que 'aleatorizar' garantiza identificación sin supuestos. NO: SUTVA, no interferencia y overlap siguen siendo necesarios.
- Confundir 'asignación aleatoria' con 'muestreo aleatorio'. El primero es para inferencia causal; el segundo, para representatividad poblacional.
- Asumir que cualquier RCT es válido. Los RCT con no-respuesta diferencial o cumplimiento parcial requieren ajustes (LATE, ITT — Cap. 6).
- Olvidar que Beca 18 NO es un RCT: la asignación dependió de criterios observables (nota, ingreso) y no observables (motivación familiar).

Conexiones conceptuales

Conecta con Cap. 1 (paradoja del efecto cero — el ATE puede ser cero aunque el efecto distribucional sea grande; allí se introduce formalmente SUTVA como supuesto de no interferencia + consistencia, que aquí asumimos) y con Caps. 3-9 (métodos cuasi-experimentales que intentan recuperar lo que la aleatorización habría dado gratis). Cap. 11 extiende con análisis de sensibilidad ante confusores no medidos.

Pregunta de discusión

Beca 18 no pudo aleatorizarse por razones éticas. ¿Qué harían ustedes si tuvieran que evaluar un programa social en el Perú donde SÍ es posible aleatorizar? ¿Qué consideraciones éticas y logísticas tendrían?

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 2 para que el sesgo de selección sea NEGATIVO (los becarios tendrían menor ingreso sin beca). Pista: cambien el signo del coeficiente de `nota` en el logit del propensity. Verifiquen que `naive_ATE < true_ATE`. (Semilla 42, $n=10000$.)

Resumen

- El problema fundamental: nunca observamos ambos resultados potenciales en la misma unidad.
- El sesgo de selección surge cuando T no es independiente de $(Y(1), Y(0))$. En Beca 18: +118 soles.
- La aleatorización elimina el sesgo por diseño ($T \perp (Y(1), Y(0))$). Es el gold standard.

Próximo episodio · Cap. 3 — El Arte del Matching: cuando no podemos aleatorizar, ¿cómo construir un contrafactual válido? Bajo CIA, matching por propensity score intenta replicar lo que la aleatorización habría dado.

Gancho: ¿Qué pasa si CIA no se cumple? Esa será la tensión del resto del Bloque I.

Referencias clave

- (1) Neyman, J. (1923). On the application of probability theory to agricultural experiments.
- (2) Rubin, D. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies.
- (3) Holland, P. (1986). Statistics and causal inference. JASA.