

Bloque I

Fundamentación

1	2	3	4
5	6	7	8
9	10	11	12

Bloque II

Formalización

13	14	15	16
17	18	19	

Bloque III

Descubrimiento/ML

20	21	22	23
24	25	26	27

Bloque IV

Causal AI

28	29	30	31
32			

previos · actual · próximos

CAPÍTULO 3

El Arte del Matching: Dimensiones y Distancias

Bloque I · Nivel GCE: 1 · Localización (ATT vía matching)

Variante: metodologico-practico

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender el estimador de matching como una generalización del 'control gemelo': emparejar cada tratado con un control idéntico en covariables observables.
2. Diagnosticar cómo la elección de distancia (Euclidiana cruda, Mahalanobis, propensity score) y la estandarización de covariables afectan el sesgo.
3. Verificar computacionalmente que matching 1:1 sobre covariables crudas apenas reduce el sesgo cuando las escalas difieren (Beca 18: +25.46 → +23.42).

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 3. Leer Cap. 3 del libro (Distancias, Propensity Score, NN Matching, Calipers, Common Support).

Notebook (pack): notebooks/Bloque_I/
notebooks/03_arte_matching_dimensiones_distancias.ipynb

Notebook (JB): jupyter_book/content/bloque_01_fundamentacion/03_arte_matching.ipynb

Agenda

S01 · Motivación: Beca 18 con confusores observables + LaLonde (1986)

S02 · Distancias, propensity score y estimador NN 1:1

S03 · Supuestos CIA + overlap y teorema de consistencia

S04 · ★ Punto interactivo: ¿qué covariable domina la distancia?

S05 · Verificación en Python (matching NN sobre covariables crudas)

S06 · Caso Beca 18: slide de puente con LaLonde (1986)

S07 · Mapeo GCE · Errores · Discusión

Problema

Beca 18 asigna becas según nota escolar e ingreso familiar: ambos son **confusores observables** que afectan también al ingreso futuro. La comparación ingenua (becarios vs. no becarios) arroja un sesgo de +25.46 soles. La idea del matching es tentadora: para cada becario, encontrar un no becario **gemelo** en covariables y comparar sus ingresos. Pero, ¿qué significa “gemelo” cuando una covariable se mide en kilómetros y otra en miles de soles?

Gancho empírico

Con semilla 42 y $n = 10\,000$, el ATE verdadero es 300 soles/mes. El estimador ingenuo da 325.46 (sesgo +25.46). El matching 1:1 sobre covariables **crudas** da 323.42 (sesgo +23.42): apenas recorta 2 soles de sesgo. La culpa es de la **escala**: la distancia Euclidiana queda dominada por ingreso_fam (escala miles) y casi ignora la nota (escala unidades). Estandarizar cambia todo.

Caso del curso · Beca 18 — matching por propensity score y covariables. El notebook del capítulo usa además el dataset **NSW mixtape** (LaLonde, 1986) como benchmark RCT real para auditar el matching observacional. Caso LaLonde (1986) capacitación laboral en paralelo (slide de puente S11).

Matching

Distancia $d(X_i, X_j)$

Propensity score (PS)

NN 1:1 con remplazo

Caliper

ATT

Overlap / common support

Emparejar cada unidad tratada con una o más controles 'similares' en covariables X y comparar Y .

Métrica de similitud: Euclidiana, Mahalanobis, o $|PS_i - PS_j|$ (Rosenbaum-Rubin).

$e(X) = P(T=1|X)$. Scalar que resume toda la información de X relevante para T .

Para cada tratado, el control más cercano; el mismo control puede servir a varios tratados.

Distancia máxima permitida; si ningún control cae dentro, el tratado queda sin match.

Average Treatment Effect on the Treated: $E[Y(1) - Y(0) | T=1]$. Lo que identifica matching NN.

$0 < e(X) < 1$ en ambos grupos. Sin overlap, matching extrapola y sesga.

Estimador de matching 1:1 con remplazo

Sea $X_i \in \mathbb{R}^p$ el vector de covariables de la unidad i , $T_i \in \{0, 1\}$ su tratamiento, y $d(X_i, X_j)$ una distancia en $\mathbb{R}^p$. Para cada unidad tratada $i \in \{T = 1\}$, sea $m(i) = \operatorname{argmin}_{j \in \{T=0\}} d(X_i, X_j)$ el índice del control más cercano. El estimador del ATT por matching 1:1 con remplazo es el promedio de las diferencias intra-pareja. Bajo CIA + overlap, $\hat{\tau}_{\text{ATT}}$ es consistente para τ_{ATT} . La elección de d es crucial: Euclidiana cruda privilegia covariables de gran escala; Mahalanobis y PS (Rosenbaum-Rubin, 1983) corrigen este sesgo de escala.

$$\hat{\tau}_{\text{ATT}} = \frac{1}{N_T} \sum_{i \in \{T=1\}} [Y_i - Y_{m(i)}]$$

Supuesto	Implicación	Chequeo en el caso
CIA	$(Y(1), Y(0)) \perp T \mid X$. Condicional a X, la asignación es como si fuera aleatoria.	Beca 18: plausible si ajustamos por nota e ingreso_fam. Falla si hay motivación familiar (no observable).
Overlap	$0 < P(T=1 X) < 1$ para todo X con soporte positivo. Sin extrapolación.	Beca 18: verificar histograma de PS por grupo. Algunas regiones rurales tienen PS cercano a 1.
SUTVA	No interferencia + consistencia: $Y = T \cdot Y(1) + (1-T) \cdot Y(0)$.	Beca 18: un becario no afecta el ingreso de otro por el hecho de recibir la beca.
Escala de covariables	Si las covariables tienen escalas distintas, estandarizar o usar Mahalanobis/PS.	Beca 18: nota (0-20) vs. ingreso_fam (cientos de soles) → Euclidiana cruda queda dominada por ingreso.
Common support	Los PS de tratados y controles deben solaparse sustancialmente.	Beca 18: $n_treated=2856$, $n_control=7144$. Solapamiento PS > 0.85 — matching viable.

Consistencia del estimador de matching (Abadie-Imbens, 2006)

Si se satisface el CIA, el supuesto de overlap, y SUTVA, y el número de vecinos k es fijo (o crece lentamente), entonces el estimador de matching k -NN con remplazo es **consistente** para el ATT: $\hat{\tau}_{\text{ATT}} \Rightarrow \tau_{\text{ATT}} = \mathbb{E}[Y(1) - Y(0) \mid T = 1]$ La clave del CIA: para cada X , los controles **cercanos** en X son comparables a los tratados en su contrafactual $Y(0)$. Sin CIA (p.ej. con confusores no observables), matching sesga igual que OLS — el sesgo de Cap. 5.

Demostración: Apéndice de Demostraciones, Cap. 3 · proof_01..09 (Apéndice de Demostraciones del libro). Cubren consistencia del estimador NN, sesgo por escala, propiedades del PS de Rosenbaum-Rubin y variantes con caliper..

Paso 1. Para cada tratado i , calcular la distancia $d(X_i, X_j)$ a todos los controles j .



Paso 2. Tomar $m(i) = \operatorname{argmin}_j d(X_i, X_j)$: el control más cercano en X .



Paso 3. Construir el contrafactual $\hat{Y}_{i(0)} = Y_{m(i)}$: el ingreso del «gemelo» no becario.



Paso 4. Estimar $\hat{\tau}_i = Y_i - \hat{Y}_{i(0)}$ y promediar sobre los tratados.




Paso 5. Bajo CIA, $\mathbb{E}[Y_{m(i)} \mid T_i = 1, X_i] \rightarrow \mathbb{E}[Y(0) \mid T_i = 1, X_i]$, así $\hat{\tau}_{\text{ATT}}$ es insesgado.

Punto de quiebre · Predictivo

★ En el matching 1:1 sobre covariables crudas (nota en escala 0-20, ingreso_fam en escala 0-5000), ¿qué covariable domina la distancia Euclidiana? (a) nota, (b) ingreso_fam, (c) ambas por igual. Mano alzada. Pista: $d^2 = (\Delta \text{ nota})^2 + (\Delta \text{ ingreso})^2$.

🕒 2-3 min · Votación mano alzada o Mentimeter



```

import numpy as np
rng = np.random.default_rng(42)
n = 10_000

# Covariables (confusores observables)
nota = rng.normal(14, 2, n)
ingreso_fam = rng.normal(2500, 800, n)

# Propensity score verdadero (modelo logit)
logit_ps = -1 + 0.282*(nota - 14) - 0.000455*(ingreso_fam - 2500)
ps = 1 / (1 + np.exp(-logit_ps))
T = (rng.uniform(size=n) < ps).astype(int)

# Resultados potenciales (true ATE = 300 soles/mes)
Y0 = 1500 + 50*nota + 0.1*ingreso_fam + rng.normal(0, 194.25, n)
Y1 = Y0 + 300
Y = T*Y1 + (1 - T)*Y0

# Estimador ingenuo (sesgado por confounding)
true_ate = (Y1 - Y0).mean()
naive_ate = Y[T==1].mean() - Y[T==0].mean()

# Matching 1:1 NN sobre covariables crudas (sin estandarizar)
treated_idx = np.where(T==1)[0]
control_idx = np.where(T==0)[0]
X = np.column_stack([nota, ingreso_fam])
Xt = X[treated_idx]
Xc = X[control_idx]
Yc = Y[control_idx]
match_y = np.zeros(len(treated_idx))
for i in range(len(treated_idx)):
    d2 = ((Xc - Xt[i])*2).sum(axis=1)
    j = int(np.argmin(d2))
    match_y[i] = Yc[j]
match_ate = (Y[treated_idx] - match_y).mean()

print(f'true_ATE = {true_ate:.2f}')
print(f'naive_ATE = {naive_ate:.2f} (sesgo: +{naive_ate - true_ate:.2f})')
print(f'match_ATE = {match_ate:.2f} (sesgo: +{match_ate - true_ate:.2f})')

```

Salida

```
true_ATE = 300.00  
naive_ATE = 325.46 (sesgo: +25.46)  
match_ATE = 323.42 (sesgo: +23.42)
```

💡 Matching apenas recorta 2 soles de sesgo: la distancia Euclidiana cruda queda dominada por ingreso_fam (escala miles) e ignora la nota (escala unidades). Estandarizar Mahalanobis o usar PS elimina el sesgo por escala.

Slide de puente V5 — Beca 18 (curso) | LaLonde 1986 (libro)

Caso peruano (Beca 18)	Caso original del libro (LaLonde 1986)
Descripción: Becarios y no becarios con covariables observables (nota, ingreso familiar). Matching 1:1 sobre covariables crudas en Python (semilla 42, n=10 000).	Descripción: Programa NSW de capacitación laboral en EE.UU. (1976). RCT original; LaLonde comparó estimadores observacionales contra el benchmark experimental.
Resultado: naive_ATE = 325.46 soles (sesgo +25.46); match_ATE = 323.42 (sesgo +23.42). Matching crudo apenas recorta 2 soles.	Resultado: los estimadores observacionales (matching, regresión) daban entre −800 y +1600 dólares vs. el RCT (+1700). LaLonde concluyó: poco confiables sin covariables correctas.
Lección transferible: la elección de distancia y la estandarización importan tanto como el método. Matching no es varita mágica: depende de covariables bien medidas y escaladas.	Lección transferible: los métodos observacionales pueden fallar estrepitosamente cuando hay confusores no observables o medidos con error. LaLonde motivó décadas de causal ML.

Conexión V5 · Ambos casos muestran que matching NO es garantía de identificación. Beca 18 ilustra el problema de escala (corregible estandarizando o usando PS). LaLonde ilustra el problema de confusores no observables (irresoluble sin IV/RCT). La transferencia metodológica: matching exige CIA + overlap + buena elección de distancia; sin ello, el sesgo persiste.

Técnica: Balance check + sensibilidad a distancia y caliper

1. **Balance check post-matching:** comparar medias de nota e ingreso_fam entre tratados y controles matched. Si la diferencia estandarizada (SMD) es < 0.1 , el matching balancea.
2. **Sensibilidad a distancia:** repetir el matching con covariables estandarizadas (Mahalanobis) y con propensity score (1D). Verificar que match_ATE cae a sesgo < 5 soles.
3. **Sensibilidad a caliper:** imponer caliper $c = 0.2\sigma(d)$. Los tratados sin match dentro del caliper se excluyen; reportar la fracción descartada.
4. **Common support plot:** histograma de PS por grupo. Si el solapamiento es > 0.85 , matching es viable; si < 0.5 , hay extrapolación peligrosa.

Conclusión · En Beca 18: el matching crudo apenas reduce el sesgo ($+25.46 \rightarrow +23.42$) por la escala desigual de covariables. Estandarizar o usar PS elimina el sesgo de escala; el remanente refleja confounders no observables.

Nivel GCE

1 · Localización (ATT vía matching)

Métrica principal

ATT (Average Treatment Effect on the Treated), NO ATE. Matching NN identifica el efecto **SOBRE** los tratados — solo es extrapolable a unidades como los tratados actuales.

Pregunta activa (1 min)

Si matching identifica ATT y no ATE, ¿cuándo es suficiente para decisión de política pública? Pista: en el benchmark **NSW mixtape** del notebook, el objetivo es replicar el ATT experimental. ¿Qué pasa si el programa se expande a nuevos beneficiarios que no se parecen a los tratados actuales? Discutan 1 min.

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq \hat{W}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

Matching sobre covariables crudas sin estandarizar. La covariable de mayor escala domina la distancia y el sesgo persiste (Beca 18: +23.42 vs. naive +25.46).

Pensar que matching elimina el sesgo por confusores no observables. NO: si el CIA falla, matching sesga igual que OLS. Necesita IV (Cap. 5).

Reportar ATT sin verificar common support. Si los PS no se solapan, matching extrapola y sesga.

Usar matching sin caliper. Sin caliper, los 'matches' pueden ser pésimos (controles muy lejanos).

Confundir matching con IPW. Matching empareja; IPW pondera. Ambos requieren CIA pero usan el PS distinto. Cap. 4 los compara.

Conexiones conceptuales

Conecta con Cap. 2 (problema fundamental: matching es la primera respuesta observacional al sesgo de selección), Cap. 4 (IPW usa el mismo PS pero pondera en lugar de emparejar; más eficiente bajo especificación correcta), Cap. 5 (IV rescata cuando el CIA falla por confusores no observables), Cap. 11 (Rosenbaum cuantifica qué tan fuerte debe ser un confusor no medido para revertir la conclusión del matching).

Pregunta de discusión

LaLonde (1986) encontró que los estimadores observacionales (matching, regresión) fallaban contra el benchmark RCT de NSW. ¿Significa esto que matching es inútil en práctica? ¿Qué condiciones harían que matching sea confiable en Beca 18?

Ejercicio (5-10 min)

En Python, modifiquen el snippet del Cap. 3 para hacer matching sobre covariables **estandarizadas** (z-score de nota e ingreso_fam). Verifiquen que el sesgo cae de +23.42 a menos de +5 soles. Repitan con matching sobre propensity score (1D) y comparen. (Semilla 42, n=10 000.)

Resumen

- Matching empareja cada tratado con el control más cercano en covariables; bajo CIA + overlap, es consistente para el ATT.
- La elección de distancia es crítica: Euclidiana cruda sesga por escala; Mahalanobis y PS corrigen.
- En Beca 18, matching crudo apenas reduce el sesgo ($+25.46 \rightarrow +23.42$) — la estandarización es obligatoria.

Referencias clave

- (1) Rosenbaum, P. & Rubin, D. (1983). The Central Role of the Propensity Score in Observational Studies for Causal Effects. *Biometrika*.
- (2) LaLonde, R. (1986). Evaluating the Econometric Evaluations of Training Programs with Experimental Data. *AER*.
- (3) Abadie, A. & Imbens, G. (2006). Large Sample Properties of Matching Estimators for Average Treatment Effects. *Econometrica*.

Próximo episodio · Cap. 4 — Inverse Probability Weighting (IPW): en lugar de emparejar, usa el propensity score para cada observación. Más eficiente bajo especificación correcta del PS, pero más sensible a PS extremos. Veremos cómo IPW y matching se complementan, y por qué AIPW (Cap. 9) los combina.

Gancho: Si matching y IPW usan el mismo PS, ¿por qué a veces dan resultados distintos?