

Bloque I

Fundamentación

1	2	3	4
5	6	7	8
9	10	11	12

Bloque II

Formalización

13	14	15	16
17	18	19	

Bloque III

Descubrimiento/ML

20	21	22	23
24	25	26	27

Bloque IV

Causal AI

28	29	30	31
32			

previos · actual · próximos

CAPÍTULO 4

IPW y el Santo Grial de la Doble Robustez

Bloque I · Nivel GCE: 1 · Localización (estimador DR dentro del nivel)

Variante: metodologico-practico

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender IPW como estimador que usa el propensity score para *ponderar* (no emparejar) y reconstruir el ATE bajo CIA + positivity.
2. Diagnosticar por qué un propensity *mal especificado* (lineal en vez de logit) hace que IPW puro sea inestable y por qué AIPW amortigua pero no elimina el sesgo cuando el outcome model también falla.
3. Verificar computacionalmente que AIPW bajo doble mal especificación arroja un sesgo residual de +20.80 soles (vs. $\text{true_ATE} = 300$) en Beca 18.

★ Prerequisitos

Lectura: Libro monográfico ``libro/main.pdf`` · Capítulo 4. Leer Cap. 4 del libro (IPW, Horvitz-Thompson, AIPW, doble robustez, estabilización de pesos).

Notebook (pack): `notebooks/Bloque_I/notebooks/04_ipw_santo_grial_doble_robustez.ipynb`

Notebook (JB): `jupyter_book/content/bloque_01_fundamentacion/04_ipw_doble_robustez.ipynb`

Agenda

S01 · Motivación: Beca 18 con propensity lineal ingenuo + Angrist (1998)

S02 · IPW y la identidad de Horvitz-Thompson · pesos $1/e(X)$

S03 · AIPW (doubly robust): combines PS + outcome model

S04 · ★ Punto interactivo: ¿qué pasa si ambos modelos están mal?

S05 · Verificación en Python (AIPW bajo propensity lineal)

S06 · Caso Beca 18: slide de puente con Angrist (1998)

S07 · Mapeo GCE · Errores · Discusión

Problema

En el Cap. 3 vimos que matching empareja cada tratado con un control similar. IPW toma otra ruta: en lugar de emparejar, **pondera** cada observación por $1/e(X)$ (tratados) o $1/(1 - e(X))$ (controles), creando una pseudo-población balanceada donde la asignación es como si fuera aleatoria. Pero IPW es **extremadamente sensible** a la especificación del propensity score. En Beca 18, usar un propensity **lineal** (LPM) en vez de logit produce pesos negativos y varianza explosiva. Necesitamos un estimador más robusto: AIPW.

Gancho empírico

Con semilla 42 y $n = 10\,000$, el ATE verdadero es 300 soles/mes. Si el analista estima el propensity con un modelo lineal (LPM) en lugar de logit, el IPW puro colapsa (estimaciones > 500 soles, varianza enorme). El estimador AIPW **doubly robust** combina propensity + outcome model y, si **al menos uno** de los dos está bien especificado, recupera el ATE. Pero en Beca 18 **ambos** modelos están mal especificados: el propensity omite la no-linearidad del logit y el outcome model omite ingreso_fam. El sesgo residual es +20.80 soles.

Caso del curso · Beca 18 — AIPW bajo propensity lineal mal especificado. Caso Angrist (1998) servicio militar voluntario en paralelo (slide de puente S11).

IPW	Inverse Probability Weighting: pondera tratados por $1/e(X)$ y controles por $1/(1-e(X))$ para crear una pseudo-población balanceada.
Horvitz-Thompson	Estimador HT: $\tau_{HT} = 1/N \sum_i [T_i Y_i / e(X_i) - (1-T_i) Y_i / (1-e(X_i))]$. Base teórica de IPW.
Positivity	$0 < P(T=1 X) < 1$ para todo X con soporte. Sin positivity, los pesos $1/e(X)$ explotan.
AIPW	Augmented IPW: combina propensity $e(X)$ y outcome model $\mu_t(X)$. 'Santo Grial' por su doble robustez.
Doble robustez	Si $e(X)$ o $\mu_t(X)$ está bien especificado (al menos uno), AIPW es consistente. Si ambos fallan, sesgo residual.
PS mal especificado	El propensity estimado difiere del verdadero (p.ej. LPM en vez de logit, omisión de interacciones).
Estabilización	Recortar $e(X)$ a $[\epsilon, 1-\epsilon]$ o usar pesos estabilizados $p/e(X)$ para controlar la varianza.

Estimadores IPW y AIPW (doubly robust)

Sea $e(X) = P(T = 1|X)$ el propensity score y $\mu_{t(X)} = \mathbb{E}[Y(t)|X]$ el outcome model para $t \in \{0, 1\}$. El estimador **IPW** (Horvitz-Thompson) repondera cada observación por la inversa de su probabilidad de recibir el tratamiento observado. El estimador **AIPW** añade un término de corrección $\mu_1(X) - \mu_0(X)$ y los residuos $(Y - \mu_{t(X)})$ ponderados por $1/e(X)$. Bajo CIA + positivity, ambos son consistentes. La **doble robustez** de AIPW establece que basta con que **uno** de los dos modelos (propensity u outcome) esté bien especificado. Si **ambos** están mal especificados, AIPW conserva un sesgo residual.

$$\hat{\tau}_{\text{AIPW}} = \frac{1}{N} \sum_i \left[\mu_1(X_i) - \mu_0(X_i) + \frac{T_i(Y_i - \mu_1(X_i))}{e(X_i)} - \frac{(1 - T_i)(Y_i - \mu_0(X_i))}{1 - e(X_i)} \right]$$

Supuesto	Implicación	Chequeo en el caso
CIA	$(Y(1), Y(0)) \perp T \mid X$. Sin confusores no observables.	Beca 18: plausible ajustando por nota e ingreso_fam. Falla si hay motivación familiar (Cap. 5).
Positivity	$0 < e(X) < 1$ para todo X. Pesos finitos.	Beca 18: ps_true $\in [0.10, 0.78]$. Pero LPM estimado da valores negativos (150 unidades con ps < 0).
SUTVA	No interferencia + consistencia.	Beca 18: un becario no afecta el ingreso de otro por recibir la beca.
$e(X)$ bien especificado	El modelo de propensity coincide con el verdadero (p.ej. logit si DGP es logit).	Beca 18: el analista usa LPM lineal — MAL especificado. IPW puro colapsa; AIPW reduce sesgo pero no lo elimina.
$\mu_t(X)$ bien especificado	El outcome model captura la forma funcional correcta de $E[Y X, T=t]$.	Beca 18: el analista omite ingreso_fam del outcome model — MAL especificado. Sin doble robustez efectiva.

Doble robustez de AIPW (Robins, Rotnitzky, Zhao 1994)

Si se satisface el CIA y la positivity, entonces el estimador AIPW es **consistente** para el ATE si **al menos uno** de los dos modelos está bien especificado: $\hat{\tau}_{\text{AIPW}} \Rightarrow \tau_{\text{ATE}} = \mathbb{E}[Y(1) - Y(0)]$ Caso 1: $e(X)$ correcta, $\mu_{t(X)}$ incorrecta $\rightarrow$ la corrección de residuos compensa el error de μ_t . Caso 2: $e(X)$ incorrecta, $\mu_{t(X)}$ correcta $\rightarrow$ el término $\mu_1 - \mu_0$ domina y la reponderación residual ajusta. Caso 3 (patológico): **ambos** mal especificados $\rightarrow$ AIPW conserva sesgo residual proporcional al producto de los errores. En Beca 18: +20.80 soles.

Demostración: Apéndice de Demostraciones, Cap. 4 · proof_01 (consistencia IPW) y proof_02 (doble robustez AIPW).

Paso 1. Partir del ATE: $\tau = \mathbb{E}[\mu_1(X) - \mu_0(X)]$ por ley de esperanzas totales.



Paso 2. Añadir el residuo $T(Y - \mu_1(X))/e(X)$ que tiene esperanza cero si μ_1 es correcto o si $e(X)$ es correcto (doble robustez).



Paso 3. Simétricamente, restar $(1 - T)(Y - \mu_0(X))/(1 - e(X))$ con esperanza cero bajo las mismas condiciones.



Paso 4. Si μ_t es correcto: los residuos son ruido centrado, $\hat{\tau}_{\text{AIPW}} \Rightarrow \tau$ sin importar $e(X)$.



Paso 5. Si $e(X)$ es correcto: la reponderación HT reconstruye $\mathbb{E}[Y(t)]$ sin importar μ_t . Doble robustez: basta UNO.


Punto de quiebre · Predictivo

Si en Beca 18 el propensity se estima con un modelo **lineal** (LPM) en vez de logit, Y el outcome model también omite


- ★ ingreso_fam, ¿qué esperan que pase con AIPW? (a) sesgo ≈ 0 (doble robustez siempre), (b) sesgo moderado (residual, entre naive y matching), (c) sesgo = naive (+25.46). Mano alzada. Pista: doble robustez exige que **al menos uno** esté bien.

🕒 2-3 min · Votación mano alzada o Mentimeter

Panel A · e(X) logit correcto



Panel B · e(X) LPM mal especificado



```

import numpy as np
rng = np.random.default_rng(42)
n = 10_000

# Mismo DGP que Caps. 2-3 (true ATE = 300 soles/mes)
nota = rng.normal(14, 2, n)
ingreso_fam = rng.normal(2500, 800, n)

# Propensity verdadero (logit) – no observable para el analista
logit_ps = -1 + 0.282*(nota - 14) - 0.000455*(ingreso_fam - 2500)
ps_true = 1 / (1 + np.exp(-logit_ps))
T = (rng.uniform(size=n) < ps_true).astype(int)

# Resultados potenciales (true ATE = 300 soles/mes)
Y0 = 1500 + 50*nota + 0.1*ingreso_fam + rng.normal(0, 194.25, n)
Y1 = Y0 + 300
Y = T*Y1 + (1 - T)*Y0

true_ate = (Y1 - Y0).mean()

# --- Propensity MAL ESPECIFICADO: LPM lineal en vez de logit ---
X_ps = np.column_stack([np.ones(n), nota, ingreso_fam])
beta_lpm = np.linalg.lstsq(X_ps, T, rcond=None)[0]
ps_hat = X_ps @ beta_lpm # LPM: puede dar ps < 0 o > 1
ps_clip = np.clip(ps_hat, 0.01069, 1 - 0.01069)

# --- Outcome model MAL ESPECIFICADO: omite ingreso_fam ---
X_om = np.column_stack([np.ones(n), nota])
coef_y0 = np.linalg.lstsq(X_om[T==0], Y[T==0], rcond=None)[0]
coef_y1 = np.linalg.lstsq(X_om[T==1], Y[T==1], rcond=None)[0]
mu0_hat = X_om @ coef_y0
mu1_hat = X_om @ coef_y1

# AIPW (doubly robust): combina PS + OM
aipw_i = (mu1_hat - mu0_hat
          + T*(Y - mu1_hat)/ps_clip
          - (1 - T)*(Y - mu0_hat)/(1 - ps_clip))
aipw_ate = aipw_i.mean()

print(f'true_ATE = {true_ate:.2f}')
print(f'AIPW_ATE = {aipw_ate:.2f} (sesgo: +{aipw_ate - true_ate:.2f})')

```

Invariante (cadena maestra GCE)

```
assert np.isfinite(aipw_ate) and abs(true_ate - 300) < 1.0
# Bajo doble mala especificación el sesgo no es cero; la invariante es finitud + ATE verdadero conocido
print('✓ DGP y AIPW numéricamente bien formados')
```

Salida

```
true_ATE = 300.00
AIPW_ATE = 320.80 (sesgo: +20.80)
```

💡 IPW puro NO se reporta: con LPM da estimaciones >500 soles y varianza explosiva (std > 11000). IPW requiere logit bien especificado. AIPW amortigua el sesgo (+20.80 vs. naive +25.46) pero no lo elimina porque AMBOS modelos (propensity y outcome) están mal especificados — la doble robustez exige que al menos uno sea correcto. (cifras ilustrativas de clase; las del notebook pueden diferir ligeramente)

Slide de puente V5 — Beca 18 (curso) | Angrist 1998 (libro)

Caso peruano (Beca 18)	Caso original del libro (Angrist 1998)
Descripción: Becarios y no becarios con covariables observables (nota, ingreso_fam). Propensity estimado con LPM lineal (mal especificado); outcome model omite ingreso_fam.	Descripción: Solicitantes al servicio militar voluntario en EE.UU. (1979-1982). Angrist usó IPW con logit cuidadosamente especificado + controles ricos para estimar el efecto del servicio en ingresos posteriores.
Resultado: AIPW_ATE = 320.80 soles (true=300, sesgo +20.80). IPW puro inestable (no reportable). Doble robustez parcial: ambos modelos mal especificados.	Resultado: IPW recuperó el efecto causal del servicio militar (5% menos ingresos a largo plazo) consistente con el benchmark experimental. La especificación logit rica fue clave.
Lección transferible: la doble robustez exige que al menos uno de los dos modelos (propensity u outcome) esté bien especificado. Si ambos fallan, AIPW reduce pero no elimina el sesgo.	Lección transferible: IPW requiere logit (o modelo de probabilidades correcto), NO LPM. La estabilización de pesos (clipping, pesos estabilizados) es necesaria pero no suficiente.

Conexión V5 · Ambos casos ilustran que IPW/AIPW dependen críticamente de la especificación del propensity. Angrist (1998) usó logit bien especificado y obtuvo resultados consistentes con el RCT. Beca 18 con LPM mal especificado muestra el colapso. La transferencia metodológica: SIEMPRE usar logit (o calibración), verificar positivity, y reportar la distribución de pesos. AIPW no es varita mágica: su doble robustez es condicional.

Técnica: Diagnóstico de pesos + sensibilidad a especificación del propensity

1. **Distribución de pesos:** histograma de $1/\hat{e}(X)$ y $1/(1 - \hat{e}(X))$.

Si algún peso > 10 , IPW es inestable. En Beca 18 con LPM: peso máximo = 100 (ps recortado a 0.01) $\rightarrow$ colapso.

2. **Effective sample size:** $n_{\text{eff}} = (\sum w_i)^2 / \sum w_i^2$. Si $n_{\text{eff}} \ll n$, los pesos están concentrados y la inferencia es frágil.

3. **Sensibilidad a especificación:** repetir AIPW con (a) LPM lineal, (b) logit bien especificado, (c) logit + interacciones. Si el ATE cambia $> 10\%$, la especificación es frágil.

4. **Doble robustez efectiva:** si AIPW con $e(X)$ correcta coincide con AIPW con $\mu_{t(X)}$ correcta, ambos modelos son plausibles. Si divergen, al menos uno falla — investigar.

Conclusión · En Beca 18: el LPM da pesos extremos (máx = 100) y 150 unidades con ps < 0 . AIPW reduce el sesgo de +25.46 (naive) a +20.80 pero no lo elimina. La especificación logit + outcome model completo eliminaría el sesgo (ver ejercicio S15).

Nivel GCE

1 · Localización (estimador DR)

Métrica principal

τ_{ATE} (AIPW doblemente robusto)

Pregunta activa (1 min)

AIPW es “doubly robust” pero en Beca 18 falla porque ambos modelos están mal especificados. ¿Significa esto que la doble robustez es una ilusión? ¿Qué condiciones prácticas garantizarían que al menos uno de los dos modelos sea correcto? Discutan 1 min.

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq \widehat{W}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

- Estimar el propensity con LPM lineal (OLS de T en X) en lugar de logit. LPM da probabilidades <0 o >1 , pesos negativos y varianza explosiva. IPW requiere logit.
- Pensar que AIPW SIEMPRE elimina el sesgo. NO: la doble robustez exige que al menos uno de los dos modelos (propensity u outcome) esté bien especificado. Si ambos fallan, sesgo residual.
- Reportar AIPW sin inspeccionar la distribución de pesos. Pesos extremos (>10) indican inestabilidad y requieren clipping o pesos estabilizados.
- Confundir positivity empírica con teórica. Aunque el DGP satisface positivity, el modelo estimado puede violarla (p.ej. LPM da $ps < 0$).
- Aplicar AIPW con covariables de alta dimensión sin regularización. En alta dimensión, tanto $e(X)$ como $\mu_t(X)$ requieren penalización (Cap. 23: DML).

Conexiones conceptuales

Conecta con Cap. 3 (matching: otra forma de usar el propensity; IPW pondera, matching empareja), Cap. 5 (IV: cuando el CIA falla, ni IPW ni matching sirven; se necesita un instrumento), Cap. 9 (AIPW formal: propiedad de semiparamétrica y eficiencia asintótica), Cap. 23 — DML (mismo principio de ortogonalidad/doble robustez: combina AIPW con cross-fitting y ML para alta dimensión; resuelve el problema de doble especificación).

Pregunta de discusión

Angrist (1998) usó IPW con logit bien especificado y obtuvo resultados consistentes con el benchmark experimental. ¿Por qué la especificación del propensity es MÁS crítica en IPW que en matching? ¿Qué ganamos con AIPW además de la doble robustez?

Ejercicio (5-10 min)

En Python, modifiquen el snippet del Cap. 4 para que el propensity sea un **logit bien especificado** (estimar los coeficientes del logit verdadero por Newton-Raphson o IRLS; sin sklearn). Verifiquen que: (a) IPW puro recupera el ATE (sesgo < 5 soles), (b) AIPW también lo recupera, (c) incluso si el outcome model sigue omitiendo ingreso_fam, AIPW mantiene sesgo < 5 (doble robustez efectiva). Reportar tabla con las 4 combinaciones: LPM/logit $\times$ OM completo/reducido. (Semilla 42, $n=10\ 000$.)

Resumen

- IPW pondera cada observación por $1/e(X)$ o $1/(1-e(X))$ para crear una pseudo-población balanceada bajo CIA + positivity.
- AIPW combina propensity + outcome model: 'doubly robust' — basta que uno de los dos esté bien especificado.
- En Beca 18 con propensity LPM mal especificado: IPW colapsa (varianza explosiva); AIPW amortigua el sesgo ($+25.46 \rightarrow +20.80$) pero no lo elimina porque ambos modelos fallan.

Referencias clave

- (1) Horvitz, D. & Thompson, D. (1952). A Generalization of Sampling Without Replacement from a Finite Universe. JASA.
- (2) Robins, J., Rotnitzky, A. & Zhao, L. (1994). Estimation of Regression Coefficients When Some Regressors are Not Always Observed. JASA.
- (3) Angrist, J. (1998). Estimating the Labor Market Impact of Voluntary Military Service Using Social Security Data on Military Applicants. Econometrica.

Próximo episodio · Cap. 5 — IV y el rescate instrumental: cuando el CIA falla por confusores no observables, ni IPW ni AIPW pueden salvarnos. Necesitamos un instrumento: una variable Z que afecte T pero no Y directamente. Veremos cómo la distancia al colegio puede ser instrumento para Beca 18 — y por qué 2SLS recupera el ATE donde IPW falla.

Gancho: Si AIPW es “doubly robust”, ¿por qué a veces necesitamos IV? ¿Qué pasa cuando ni el propensity ni el outcome model pueden capturar el confusor?