

Bloque I

Fundamentación

1	2	3	4
5	6	7	8
9	10	11	12

Bloque II

Formalización

13	14	15	16
17	18	19	

Bloque III

Descubrimiento/ML

20	21	22	23
24	25	26	27

Bloque IV

Causal AI

28	29	30	31
32			

previos · actual · próximos

CAPÍTULO 10

Mediación Causal: Descomposición de Efectos y Mecanismos

Bloque I · Nivel GCE: 1 · Localización (con descomposición NDE/NIE)

Variante: teorico-formal

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender por qué la mediación descompone el efecto total en directo (NDE) e indirecto (NIE) mediante contrafactuales anidados $Y(t, M(t'))$.
2. Identificar el supuesto de ignorabilidad secuencial y por qué los confusores mediador-outcome rompen la identificación de NIE.
3. Verificar computacionalmente que la fórmula de mediación (Pearl 2001, VanderWeele 2015) recupera $NDE = 200$, $NIE = 50$, $Total = 250$ en Beca 18.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 10. Leer Cap. 10 del libro (Mediación, NDE/NIE, ignorabilidad secuencial, fórmula de Pearl).

Notebook (pack): notebooks/Bloque_I/notebooks/10_mediacion_causal_descomposicion_efectos_mecanismos.ipynb

Notebook (JB): jupyter_book/content/bloque_01_fundamentacion/10_mediacion_causal.ipynb

Agenda

S01 · Motivación: Beca 18 — ¿vía qué mecanismo sube el ingreso?

S02 · Definición formal: NDE, NIE, Total Effect con contrafactuales anidados

S03 · Ignorabilidad secuencial y supuestos de identificación

S04 · ★ Punto interactivo: ¿hay confusor M-Y no medido?

S05 · Verificación en Python (g-computation · Beca 18 vía educación superior)

S06 · Caso Beca 18: slide de puente con Baron-Kenny (1986)

S07 · Mapeo GCE · Errores · Discusión

Problema

Beca 18 aumenta el ingreso laboral mensual en aproximadamente 250 soles (Cap. 3-4). Pero esta cifra agrega dos mecanismos distintos: (a) un efecto **directo** por señalización de talento y redes con empleadores, y (b) un efecto **indirecto** vía más años de educación superior (el mediador). Sin descomponer el ATE, no podemos decidir qué política intensificar: becas para retención escolar vs. becas para inserción laboral.

Gancho empírico

La **fórmula de mediación** (Pearl 2001) usa contrafactuales anidados $Y(1, M(0))$ para separar ambos canales. En Beca 18: T = beca, M = años de educación superior, Y = ingreso mensual. Estimaremos $NDE = 200$ (directo) y $NIE = 50$ (vía educación) con semilla 42.

Caso del curso · Beca 18 — mediación vía años de educación superior. Caso Baron-Kenny (1986) mediación educativa en paralelo (slide de puente S11).

T (tratamiento)	Beca 18 (binaria). Causa el mediador M y el outcome Y.
M (mediador)	Años de educación superior completados. Intermedio causal entre T e Y.
Y(1, M(0))	Contrafactual anidado: Y bajo T=1, pero con M fijado al valor que tomaría bajo T=0.
NDE	Natural Direct Effect: $E[Y(1,M(0))] - E[Y(0,M(0))]$. Efecto directo de T sobre Y, sin pasar por M.
NIE	Natural Indirect Effect: $E[Y(1,M(1))] - E[Y(1,M(0))]$. Efecto mediado por M, manteniendo T=1.
Total Effect	$E[Y(1,M(1))] - E[Y(0,M(0))]$ = NDE + NIE (mediation formula, Pearl 2001).
Ignorabilidad secuencial	$(Y(t,m), M(t')) \perp T \mid X$ y $Y(t,m) \perp M(t') \mid T, X$. Dos conjuntos de confusores ajustados.
g-computation	Estimador plug-in para NDE/NIE: ajustar modelos de M e Y, luego sustituir contrafactuales.

Mediación causal: NDE, NIE, Total Effect

Sea T el tratamiento, M el mediador, Y el outcome. Definimos los **contrafactuales anidados** $Y(t, m)$ = outcome bajo $T = t$ y $M = m$, y $M(t) =$ mediador bajo $T = t$. Los tres efectos canónicos de la mediación son:

1. **Natural Direct Effect (NDE)**: efecto de T sobre Y manteniendo M en su valor contrafactual bajo $T = 0$.
2. **Natural Indirect Effect (NIE)**: efecto de T sobre Y operando solo vía el cambio en M inducido por T , manteniendo $T = 1$.
3. **Total Effect (TE)**: suma NDE + NIE.

En Beca 18: T = beca, M = años de educación superior, Y = ingreso mensual. La descomposición revela si la beca opera principalmente por señalización (NDE alto) o por acumulación de capital humano (NIE alto).

$$\text{NDE} = \mathbb{E}[Y(1, M(0))] - \mathbb{E}[Y(0, M(0))], \quad \text{NIE} = \mathbb{E}[Y(1, M(1))] - \mathbb{E}[Y(1, M(0))]$$

Supuesto	Implicación	Chequeo en el caso
Ignorabilidad de T	$(Y(t,m), M(t')) \perp T \mid X$. No hay confusores no medidos de T.	Beca 18: ajustamos por nota escolar e ingreso familiar (CIA del Cap. 4).
Ignorabilidad de M	$Y(t,m) \perp M(t') \mid T, X$. No hay confusor mediador-outcome.	Beca 18: ¿habilidad cognitiva no observada afecta M (años educ) e Y (ingreso)? Amenaza.
Consistencia	$Y = Y(T, M(T)); M = M(T)$. Sin interferencia entre unidades.	Beca 18: un estudiante no cambia los años de educación de otro por recibir la beca.
Positividad	$0 < P(T=t \mid X) < 1$ y $0 < P(M=m \mid T, X) < 1$.	Beca 18: hay tratados y controles en cada estrato de X; M tiene soporte continuo.
No interacción $T \times M$	Opcional para Baron-Kenny: $Y(t,m)$ sin término $t \cdot m$. Pearl no lo requiere.	Beca 18: el retorno de un año extra de educación puede depender de tener Beca 18 $\rightarrow$ interacción plausible; Baron-Kenny falla aquí.

Fórmula de mediación (Pearl 2001, VanderWeele 2015)

Bajo ignorabilidad secuencial, los efectos naturales se identifican a partir de la distribución observada mediante las **fórmulas de mediación**: $NDE = \sum_m (\mathbb{E}[Y|T = 1, M = m, X] - \mathbb{E}[Y|T = 0, M = m, X]) \cdot P(M = m | T = 0, X) \cdot P(X)$ $NIE = \sum_m \mathbb{E}[Y|T = 1, M = m, X] \cdot (P(M = m | T = 1, X) - P(M = m | T = 0, X)) \cdot P(X)$ Y se satisface la **descomposición exacta**: $TE = NDE + NIE$. En el caso lineal sin interacción $T \times M$, esto se reduce al producto $a \cdot b$ de Baron-Kenny (1986): $NIE = \hat{a} \cdot \hat{b}$, $NDE = \hat{c}'$. Bajo ignorabilidad secuencial y consistencia, los estimadores plug-in (g-computation) son consistentes para los efectos naturales: $\widehat{NDE} \Rightarrow NDE$, $\widehat{NIE} \Rightarrow NIE$

Demostración: Apéndice de Demostraciones, Cap. 10 · proof_01..05 (Apéndice de Demostraciones del libro). Cubren la fórmula de mediación de Pearl, la equivalencia con Baron-Kenny bajo linealidad sin interacción, los efectos controlados (CDE/NDE) y los bounds bajo ignorabilidad secuencial..

Paso 1. Estimar $\hat{\beta}$: ajustar el modelo de mediador $M = \alpha + \beta T + \varepsilon$ por OLS (etapa mediador).



Paso 2. Estimar $\hat{\delta}$ y $\hat{\theta}$: ajustar $Y = \gamma + \delta T + \theta M + \eta$ por OLS (etapa outcome).



Paso 3. Calcular $\widehat{\text{NDE}} = \hat{\delta}$ (efecto directo, M constante).



Paso 4. Calcular $\widehat{\text{NIE}} = \hat{\theta} \cdot \hat{\beta}$ (efecto indirecto vía M).




Paso 5. Verificar descomposición: $\widehat{\text{TE}} = \widehat{\text{NDE}} + \widehat{\text{NIE}}$. Para Beca 18: $200 + 50 = 250$ soles/mes. ✓

Punto de quiebre · Conceptual

★ En Beca 18, ¿existe un confusor no medido entre M (años de educación superior) e Y (ingreso laboral)? Pista: capacidad cognitiva, motivación, redes familiares. Discutan 1 min: si la respuesta es sí, ¿qué le pasa al supuesto de ignorabilidad de M y, por tanto, al estimador NIE?

🕒 3 min · Votación mano alzada o Mentimeter



U_MY rompe ignorabilidad de M

```

import numpy as np
rng = np.random.default_rng(42)
n = 10_000

# T: Beca 18 (binaria, ~50% takeup)
T = rng.integers(0, 2, n)

# M: años de educación superior
# M(t) = 1 + 0.5*t + tiny noise (beta = 0.5: beca añade 0.5 años)
M = 1 + 0.5*T + rng.normal(0, 0.0001, n)

# Y: ingreso laboral mensual (soles)
# Y(t, m) = 1000 + 200*t + 100*m (delta = 200, theta = 100)
Y = 1000 + 200*T + 100*M

# True effects (analytical):
# NDE = delta = 200 (directo, sin pasar por M)
# NIE = theta * beta = 100 * 0.5 = 50 (indirecto vía educación)
# Total = NDE + NIE = 250

# Stage 1: ajustar M ~ T (estimar beta)
X_m = np.column_stack((np.ones(n), T))
coef_m_full = np.linalg.lstsq(X_m, M, rcond=None)
coef_m = coef_m_full[0]
beta_hat = coef_m[1]

# Stage 2: ajustar Y ~ T + M (estimar delta, theta)
X_y = np.column_stack((np.ones(n), T, M))
coef_y_full = np.linalg.lstsq(X_y, Y, rcond=None)
coef_y = coef_y_full[0]
delta_hat = coef_y[1]
theta_hat = coef_y[2]

# Mediation decomposition (Pearl 2001, g-computation):
# NDE = delta_hat (directo)
# NIE = theta_hat * beta_hat (T -> M -> Y)
NDE = delta_hat
NIE = theta_hat * beta_hat
Total = NDE + NIE

print(f'NDE = {NDE:.2f}')

```

```
print(f'NIE    = {NIE:.2f}')  
print(f'Total  = {Total:.2f}')
```

Salida

```
NDE    = 200.00  
NIE    = 50.00  
Total  = 250.00
```

💡 La fórmula de mediación recupera exactamente $NDE = 200$, $NIE = 50$, $Total = 250$. El 80% del efecto de Beca 18 es directo (señalización/redes) y el 20% es mediado por más años de educación superior.

Slide de puente V5 — Beca 18 (curso) | Baron-Kenny 1986 (libro)

Beca 18 (curso · mediación vía educación superior)	Baron-Kenny 1986 (libro · mediación educativa clásica)
Resultado: NDE = 200 (directo), NIE = 50 (vía años de educación superior), Total = 250 soles/mes.	Resultado: indirecto $a \cdot b$ significativo si c' al ajustar M es menor que c ; mediación parcial si $c' \neq 0$.
Lección transferible: la fórmula de mediación (Pearl) descompone el ATE en directo + indirecto, revelando el mecanismo causal.	Lección transferible: Baron-Kenny asume linealidad y no interacción $T \times M$; Pearl (2001) generaliza con contrafactuales anidados a casos no paramétricos.

Conexión V5 · Ambos casos descomponen el efecto total en directo e indirecto vía un mediador educativo. La transferencia metodológica es directa: Baron-Kenny es el caso lineal-sin-interacción; Pearl/VanderWeele es la generalización contrafactual no paramétrica. Beca 18 ilustra por qué necesitamos la versión general: el retorno de un año extra de educación probablemente depende de tener la beca (interacción $T \times M$).

Técnica: Test de interacción $T \times M$ + sensibilidad a confusor M - Y no medido

1. **Test de interacción $T \times M$:** incluir el término $T \times M$ en la etapa outcome. Si el coeficiente es significativo, Baron-Kenny falla; usar la fórmula de mediación no paramétrica (Pearl).
2. **Sensibilidad a confusor M - Y :** simular un confusor U_{MY} con correlación ρ creciente y reportar cómo cambia NIE. VanderWeele (2015) propone el factor de sesgo $B = \rho_{U_{MY}, M} \cdot \frac{\rho_{U_{MY}, Y}}{1 - \rho_{U_{MY}, M}^2}$.
3. **Bootstrap no paramétrico:** intervalos de confianza para NDE/NIE con 1000 réplicas, ya que $NIE = \hat{\theta} \cdot \hat{\beta}$ tiene distribución sesgada, no normal.

Conclusión · Si $\rho(U_{MY}, M)$ y $\rho(U_{MY}, Y)$ son ambos menores a 0.1, el sesgo en NIE es menor al 5%. En Beca 18, U_{MY} = capacidad cognitiva: ρ plausible de 0.3 $\rightarrow$ requerir ajuste por test estandarizado o análisis de sensibilidad.

Nivel GCE

1 · Localización (con descomposición NDE/NIE)

Métrica principal

NDE, NIE, Total Effect (Pearl 2001). Descomposición contrafactual del ATE en mecanismos directo e indirecto — una descomposición de efectos que requiere la *estructura causal* (DAG con mediador) y los contrafactuales anidados $Y(t, M(t'))$, pero NO el Nivel 2 D_f (distribuciones contrafactuales completas que exige la definición jerárquica de Pearl).

Pregunta activa (1 min)

La mediación descompone el ATE en NDE + NIE vía la **estructura** del DAG con mediador. ¿Por qué NO se confunde con el Nivel 2 de la jerarquía GCE (D_f : distribuciones contrafactuales)? Pista: aquí estimamos **cantidades promedio** (NDE, NIE) vía g-computation, no distribuciones completas de $Y(t, M(t'))$.

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq W^{\wedge}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

Olvidar el supuesto de ignorabilidad de M (mediador-outcome). Confusores no medidos de M-Y rompen la identificación de NIE.

Aplicar Baron-Kenny cuando hay interacción $T \times M$. El producto $a \cdot b$ ya no coincide con NIE bajo interacción.

Reportar NIE sin intervalo de confianza bootstrap. $NIE = a \cdot b$ tiene distribución sesgada, no normal.

Interpretar NIE como efecto causal del mediador M sobre Y. NIE mide el efecto de T vía M, no el efecto directo de M.

Confundir mediación con moderación. Mediación = mecanismo ($T \rightarrow M \rightarrow Y$); moderación = heterogeneidad (W modifica el efecto $T \rightarrow Y$).

Conexiones conceptuales

Conecta con Cap. 9 (Synthetic Control: contrafactual ponderado; ahora contrafactual anidado), Cap. 18 (do-calculus: derivar NDE/NIE formalmente con operadores do), Cap. 19 (contrafactuales: $Y(t, M(t'))$ requiere el framework de potential outcomes anidados), Cap. 25 (heterogeneous effects: si NIE varía por subgrupo, mediación + moderación se combinan).

Pregunta de discusión

Baron-Kenny (1986) propone un test secuencial de 4 pasos para mediación. Pearl (2001) argumenta que este test es insuficiente cuando hay interacción $T \times M$ o confusores mediador-outcome. ¿Están de acuerdo? Den un ejemplo concreto en Beca 18 donde Baron-Kenny daría una conclusión equivocada.

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 10 para añadir un término de interacción $T \times M$ con coeficiente 50 ($Y = 1000 + 200 \cdot T + 100 \cdot M + 50 \cdot T \cdot M$). Verifiquen que el producto $a \cdot b$ de Baron-Kenny ya no coincide con NIE contrafactual. ¿Cuál es la diferencia? (Semilla 42, $n = 10000$.)

Resumen

- La mediación descompone el ATE en NDE (directo) + NIE (indirecto) usando contrafactuales anidados $Y(t, M(t'))$.
- Requiere ignorabilidad secuencial: confusores de T y de M ajustados. Confusores M-Y no medidos rompen NIE.
- Bajo linealidad sin interacción, Pearl = Baron-Kenny: $NIE = a \cdot b$, $NDE = c'$. Bajo interacción, solo Pearl.

Referencias clave

- (1) Pearl, J. (2001). Direct and Indirect Effects. UAI Proceedings.
- (2) VanderWeele, T. (2015). Explanation in Causal Inference: Methods for Mediation and Interaction. Oxford.
- (3) Baron, R. & Kenny, D. (1986). The Moderator-Mediator Variable Distinction in Social Psychological Research. JPSP.

Próximo episodio · Cap. 11 — Sensibilidad de Rosenbaum: cuantificaremos qué tan fuerte debe ser un confusor no medido (como U_{MY} en Beca 18) para revertir la conclusión de la mediación. Aprenderemos a reportar intervalos de sensibilidad robustos.

Gancho: Si U_{MY} (capacidad cognitiva) tuviera $\rho = 0.5$ con M e Y , ¿se desvanecería $NIE = 50$?