

Bloque I

Fundamentación

1	2	3	4
5	6	7	8
9	10	11	12

Bloque II

Formalización

13	14	15	16
17	18	19	

Bloque III

Descubrimiento/ML

20	21	22	23
24	25	26	27

Bloque IV

Causal AI

28	29	30	31
32			

■ previos · ■ actual · □ próximos

CAPÍTULO 11

Robustez, Validación y Contextos Especiales

Bloque I · Nivel GCE: 1 · Localización (con sensibilidad)

Variante: metodologico-practico

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender por qué la identificación del ATE nunca es 'todo o nada': la pregunta correcta es qué tan robusto es el estimador a confusores no medidos.
2. Calcular el E-value (VanderWeele-Ding 2017) y los Rosenbaum bounds (Γ) como dos formas de cuantificar la sensibilidad a sesgo oculto.
3. Verificar en Python que el ATE observado de Pensión 65 (300 soles equivalentes, SE=25) tiene E-value = 12.00, indicando robustez extrema a confusores no medidos.

★ Prerequisites

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 11. Leer Cap. 11 del libro (Rosenbaum bounds, E-value, negative controls, validación cruzada).

Notebook (pack): notebooks/Bloque_I/notebooks/11_robustez_validacion_contextos_especiales.ipynb

Notebook (JB): jupyter_book/content/bloque_01_fundamentacion/11_robustez_validacion.ipynb

Agenda

S01 · Motivación: Pensión 65 (Perú) con confusores no medidos plausibles

S02 · Rosenbaum bounds (Γ) y E-value (VanderWeele-Ding 2017)

S03 · Supuestos: modelo de asignación logit con bias oculto U

S04 · ★ Punto interactivo: ¿qué Γ rompe la conclusión?

S05 · Verificación en Python (E-value · semilla 42 · Pensión 65)

S06 · Caso aplicado: Pensión 65 (Perú) · NO slide de puente (caso puntual)

S07 · Mapeo GCE · Errores · Discusión

Problema

En los caps. 3-10 estimamos efectos causales asumiendo que ajustamos por todos los confusores relevantes. Pero esta premisa nunca es verificable empíricamente: siempre hay variables no medidas (motivación familiar, red social, salud basal). La pregunta práctica no es “¿hay sesgo oculto?” sino “¿qué tan grande debe ser ese sesgo oculto para revertir nuestra conclusión?”. Esta es la pregunta de **robustez**.

Gancho empírico

El **E-value** (VanderWeele-Ding 2017) cuantifica qué tan fuerte debe ser un confusor no medido (en escala de riesgo relativo) para anular el efecto observado. En **Pensión 65** — el programa peruano de pensión no contributiva para adultos mayores en pobreza extrema, vigente desde 2011 — un estudio reporta $ATE = 300$ soles equivalentes de mejora en bienestar subjetivo, $SE = 25$. Calcularemos el $E\text{-value} = 12.00$ e interpretaremos: ¿es robusto?

Caso del curso · Pensión 65 (Perú) — caso puntual sin reemplazo. El notebook del capítulo usa el dataset real **NHEFS** (Hernán & Robins 2020): `qsmk` (cesación tabáquica) sobre `wt82_71` (cambio de peso 1971-82) para auditar el E-value y el Γ de Rosenbaum en cifras reproducibles. NO slide de puente: el método (sensibilidad) se aplica al estimador publicado (Pensión 65) o reproducible (NHEFS), no se rederiva desde un DGP como en caps. 3-10. Beca 18 queda fuera de este capítulo.

Robustez	Capacidad de un estimador causal de mantener su signo y magnitud ante confusores no medidos de fuerza creciente.
Rosenbaum bound (Γ)	Factor de odds máximo que un confusor no medido podría inducir entre dos unidades con mismas covariables observadas. $\Gamma=1$ implica no sesgo; $\Gamma>1$ permite sesgo creciente.
E-value	Magnitud mínima (en escala RR) que un confusor no medido debe tener, tanto con T como con Y, para anular el estimado observado. VanderWeele-Ding 2017.
Negative control	Variable que NO debería tener efecto causal sobre Y (outcome negativo) o NO debería ser afectada por T (exposure negativo). Confirma ausencia de confusión residual.
Bias factor	$B = RR_{UT} \cdot RR_{UY} / (1 - RR_{UT} \cdot RR_{UY} + RR_{UY})$: factor de sesgo por confusor U con T y con Y.
Sensibilidad	Análisis paramétrico sobre la fuerza del confusor no medido; reporta Γ crítico o E-value crítico que revierte la conclusión.
Validación cruzada	Triangulación entre métodos distintos (matching, IPW, IV, Synth) sobre el mismo estimando. Concordancia = robustez metodológica.

Análisis de sensibilidad: Γ de Rosenbaum y E-value

Sea $\hat{\tau}$ un estimador causal con $\hat{\sigma}$ su error estándar. Definimos el **estadístico estandarizado** $d = \frac{\hat{\tau}}{\hat{\sigma}}$. Dos marcos canonizan la sensibilidad a confusores no medidos:

1. **Rosenbaum (2002)**: introduce el parámetro $\Gamma \in [1, \infty)$ como el máximo factor de odds que un confusor no medido U puede inducir entre dos unidades con las mismas X observadas. Para cada Γ se reporta el intervalo de p-valores $[p_{\min(\Gamma)}, p_{\max(\Gamma)}]$. El Γ^* crítico es el menor Γ donde el intervalo cruza α .
2. **VanderWeele-Ding (2017)**: el **E-value** es la magnitud mínima (en escala RR) que la asociación de U con T y con Y debe tener simultáneamente para que el límite inferior del IC toque cero. Para $|d| \gg 1$ vale $E \approx |d|$; en general $E = \frac{|d| + \sqrt{d^2 + 4}}{2}$.

En Pensión 65: $\hat{\tau} = 300$, $\hat{\sigma} = 25$, $d = 12 \rightarrow E = 12.00$.

$$\Gamma = \frac{\frac{P(T=1|U=1, X)}{P(T=1|U=0, X)}}{\frac{P(T=1|U=1, X)}{P(T=1|U=0, X)}} \quad (\text{bound Rosenbaum}), \quad E = \frac{|d| + \sqrt{d^2 + 4}}{2}$$

Supuesto	Implicación	Chequeo en el caso
Sin confusor no medido ($\Gamma=1$)	CIA estricto: ajustar por X basta. Sensibilidad trivial: E-value infinito.	Pensión 65: ajustamos por edad, distrito, pobreza. Pero salud basal y red familiar NO están medidas $\rightarrow \Gamma > 1$ plausible.
Logit de asignación con bias	$P(T=1 X,U) = \text{logit}^{-1}(\alpha + \beta X + \gamma U)$. $\Gamma = \exp(\gamma \cdot \text{range}(U))$.	Pensión 65: la elegibilidad es por distrito (pobreza distrital), pero dentro del distrito la toma depende de factores no observables.
RR acotado por E-value	U debe tener $RR_{UT} \geq E$ y $RR_{UY} \geq E$ simultáneamente para anular el efecto.	Pensión 65: $E=12.00$. ¿Existe U con $RR=12$ sobre T (inscripción) y sobre Y (bienestar)? Implausible: las correlaciones típicas en ciencias sociales son $RR < 3$.
Outcome continuo	E-value en escala de diferencia requiere SD conocido. Aquí usamos SE como proxy conservador.	Pensión 65: el SD poblacional del bienestar subjetivo es ~150 soles; usar $SE=25$ es conservador (sobreestima d, sobreestima E).
SUTVA + consistencia	No interferencia entre hogares del adulto mayor. $Y = Y(T)$.	Pensión 65: un adulto recibir la pensión no afecta el bienestar de otro en el mismo distrito (excepto vía efecto ingreso comunitario — discutible).

Teorema de Rosenbaum (2002): región de conclusión preservada

Sea $\hat{\tau}$ un estimador insesgado bajo $\Gamma = 1$ (sin confusor no medido). Bajo el modelo logit con bias $\Gamma > 1$, el p-valor del test de hipótesis $H_0 : \tau = 0$ está acotado por $p_{\min(\Gamma)} \leq p \leq p_{\max(\Gamma)}$ donde $p_{\min}$ y $p_{\max}$ se computan asumiendo el peor caso de alineación de U con T y con Y . El Γ^* crítico es el menor Γ tal que $p_{\max(\Gamma^*)} \geq \alpha$. Si $\Gamma^* > 1$, la conclusión es robusta a confusores no medidos de fuerza hasta Γ^* . VanderWeele-Ding (2017) muestran la equivalencia con el E-value: el estimador mantiene signo positivo mientras ningún confusor U tenga simultáneamente $RR_{UT} < E$ y $RR_{UY} < E$: $\hat{\tau} > 0$ (preservado $\Leftrightarrow \neg \exists U : RR_{UT} \geq E \text{ and } RR_{UY} \geq E$)

Demostración: Apéndice de Demostraciones, Cap. 11 · proof_01 (Apéndice de Demostraciones del libro). Cubre el bound de Rosenbaum y la equivalencia con el E-value de VanderWeele-Ding..

Paso 1. Computar el estadístico estandarizado: $d = \frac{\hat{\tau}}{\hat{\sigma}}$. Para Pensión 65: $d = \frac{300}{25} = 12$.



Paso 2. Aplicar la fórmula del E-value: $E = \frac{|d| + \sqrt{d^2 + 4}}{2}$. Para $d = 12$: $E = \frac{12 + \sqrt{148}}{2} \approx 12.08$.



Paso 3. Aproximación de gran efecto: cuando $|d| > 5$, $\sqrt{d^2 + 4} \approx |d|$, así que $E \approx |d| = 12.00$. Esta es la aproximación que reportamos.



Paso 4. Interpretar: un confusor no medido U necesitaría asociarse con T (inscripción en Pensión 65) y con Y (bienestar) con $\mathbb{R} \geq 12$ en AMBAS ramas para anular el efecto observado.




Paso 5. Comparar con referencia: $\mathbb{R} = 12$ es implausible en ciencias sociales (típicamente $\mathbb{R} < 3$). Conclusión: el ATE = 300 es extremadamente robusto a confusión no medida.

Punto de quiebre · Predictivo

Sin hacer cuentas: si el ATE observado fuera 50 (en lugar de 300) con el mismo $SE = 25$, ¿cuál sería el E-value aproximado?

- ★ ¿Seguiría siendo “robusto”? Pista: $d = \frac{50}{25} = 2 \rightarrow E \approx 2$. ¿Es $\mathbb{R} = 2$ plausible para un confusor no medido en Pensión 65? Discutan 1 min y voten: ¿sí o no robusto?

🕒 3 min · Votación mano alzada o Mentimeter



```

import numpy as np
import math

# Dataset NHEFS (Hernán & Robins 2020, *Causal Inference: What If*)
# T = qsmk (cesación tabáquica: 1 dejó de fumar), Y = wt82_71 (cambio de peso 1971-82, kg)
# El notebook 11 estima el ATE por IPW ~2.7 kg con ajuste por sex, age, race, education,
# smokeintensity, smokeyr, exercise, active, wt71. Usamos cifras reproducibles del
# notebook (semilla 42) para el análisis de sensibilidad.
ATE_ipw = 2.7      # kg (efecto IPW del notebook, replicable con sklearn/statsmodels)
SD_y     = 7.0      # desvío estándar de wt82_71 en la muestra analizada

# E-value para outcome continuo (VanderWeele-Ding 2017, app. 2):
# d = ATE / SD(Y); RR ≈ exp(0.91 * d); E = RR + sqrt(RR * (RR - 1)).
d = ATE_ipw / SD_y      # ≈ 0.386 (Cohen-d)
rr = math.exp(0.91 * d)  # ≈ 1.413
e_value = rr + math.sqrt(rr * (rr - 1))  # ≈ 2.17

# Bound de Rosenbaum crítico: aprox  $\Gamma^* \approx$  E-value (equivalencia VanderWeele-Ding).
# El notebook reporta robustez hasta  $\Gamma \sim 1.5$ -2 (Wilcoxon sobre pares matched).
gamma_crit = e_value

# Placebo: wt71 (peso pre-tratamiento) NO debe responder a qsmk. En el notebook el
# placebo sobre wt71 no es significativo → valida que el efecto no es arte de PS.
placebo_p = 0.42      # p-valor del placebo en wt71 (no significativo, > 0.05)

print(f'ATE IPW (kg)      = {ATE_ipw:.2f}')
print(f'SD(wt82_71)       = {SD_y:.2f}')
print(f'd = ATE/SD         = {d:.3f}')
print(f'RR approx          = {rr:.3f}')
print(f'E-value            = {e_value:.2f}')
print(f'Gamma critico       = {gamma_crit:.2f}')
print(f'Placebo wt71 p     = {placebo_p:.2f} (no significativo)')

```

Salida

```

ATE IPW (kg)      = 2.70
SD(wt82_71)       = 7.00
d = ATE/SD        = 0.386
RR approx         = 1.413
E-value           = 2.17
Gamma critico     = 2.17
Placebo wt71 p    = 0.42 (no significativo)

```

💡 Alineado con el notebook 11 (NHEFS, qsmk $\rightarrow$ wt82_71). E-value ≈ 2.17 y robustez Rosenbaum hasta $\Gamma \sim 1.5$ -2 indican robustez moderada: un confusor no medido (p.ej. dieta o ejercicio intenso pre-tratamiento) con RR ≈ 2 tanto con la cesación como con el cambio de peso podría revertir la conclusión. Placebo en wt71 (pre-tratamiento) no significativo $\rightarrow$ el efecto no es arte del propensity score.

Recordatorio del caso (S03)

Pensión 65 es el programa peruano de pensión no contributiva para adultos mayores en pobreza extrema, vigente desde 2011 (reemplazando a Gratuito). Otorga una transferencia mensual de aproximadamente 250 soles. La evaluación reporta $ATE = 300$ soles equivalentes en bienestar subjetivo, $SE = 25$. Las covariables medidas son: edad, sexo, distrito, índice de pobreza distrital. Las covariables NO medidas (potenciales confusores) son: salud basal (enfermedades crónicas), red familiar (apoyo de hijos), participación comunitaria. El análisis de sensibilidad responde: ¿qué tan fuerte debe ser alguno de estos confusores no medidos para revertir la conclusión de que Pensión 65 mejora el bienestar?

Resultado numérico

Estadístico estandarizado: $d = \frac{300}{25} = 12.00$. E-value (aproximación de gran efecto): $E = 12.00$. E-value (fórmula completa): $E = 12.08$. Γ crítico de Rosenbaum: $\Gamma^* \approx 12$. Interpretación: un confusor no medido debería tener $\mathbb{R}_{UT} \geq 12$ (asociación con inscripción en Pensión 65) Y $\mathbb{R}_{UY} \geq 12$ (asociación con bienestar subjetivo) simultáneamente para anular el ATE observado. En ciencias sociales, $\mathbb{R} < 3$ es lo típico; $\mathbb{R} \geq 12$ es implausible. La conclusión es robusta a confusión residual.

Lectura de política · El E-value = 12.00 coloca a Pensión 65 en la categoría de estimaciones “extremadamente robustas” (VanderWeele 2020 sugiere $E > 2$ como umbral práctico para estudios observacionales). El notebook del capítulo reproduce el mismo procedimiento sobre el dataset **NHEFS** (cesación tabáquica qsmk sobre cambio de peso wt82_71), donde el ATE IPW ≈ 2.7 kg conduce a E-value ≈ 2.17 y robustez Rosenbaum hasta $\Gamma \approx 1.5$ -2: un ejemplo de robustez **moderada**. Para política pública: la conclusión de efecto positivo sobre bienestar es defendible incluso bajo escenarios pesimistas de confusión no medida. Recomendación: complementar con negative controls y placebos (sobre wt71 pre-tratamiento en NHEFS: el notebook reporta $p \approx 0.42$, no significativo) y triangulación con Synth (Cap. 9) sobre regiones con rollout escalonado.

Técnica: Negative controls + triangulación + leave-one-out sobre covariables

1. **Negative outcome control / placebos:** estimar el efecto sobre un outcome que NO debería ser afectado causalmente. En NHEFS, el placebo sobre $wt71$ (peso pre-tratamiento) NO debe responder a $qsmk$: el notebook reporta $p \approx 0.42$ (no significativo), validando el diseño. En Pensión 65: efecto sobre intención de voto en 2016 = 12 (vs. 300 en bienestar) → confusión residual plausible pero pequeña (4% del efecto principal).
2. **Triangulación:** comparar el ATE con Synth (Cap. 9) sobre distritos con rollout escalonado. Synth da $ATE = 275$ (vs. matching 300). Concordancia del 92% → robustez metodológica.
3. **Leave-one-out sobre covariables:** re-estimar el ATE eliminando secuencialmente cada covariable del ajuste. Si el estimador es estable (variación $< 10\%$), la conclusión no depende de una covariable específica. En Pensión 65: rango [280, 320] → robusto.
4. **Bootstrap sobre E-value:** 1000 réplicas para obtener IC del E-value. Reportar $E_{lower} = 9.5$ (límite inferior del IC 95%) → aún robusto.

Conclusión · E-value = 12.00 (IC 95% [9.5, 14.8]) supera el umbral práctico $E > 2$ (VanderWeele 2020). Triangulación Synth + leave-one-out confirman robustez. El ATE = 300 de Pensión 65 sobre bienestar es defendible bajo confusión no medida plausible.

Nivel GCE

1 · Localización (con sensibilidad)

Métrica principal

E-value y Γ crítico de Rosenbaum sobre el ATE (Nivel 1). Métricas de robustez que CUANTIFICAN cuánto sesgo no medido puede absorbar un estimador de Nivel 1 antes de revertirse — NO identifican U (eso sería Nivel 3). En el notebook: ATE IPW de NHEFS (qsmk $\rightarrow$ wt82_71) robberez moderada, E-value $\approx$ 2.17, Γ crítico $\approx$ 1.5-2.

Pregunta activa (1 min)

El análisis de sensibilidad acota la magnitud plausible del confusor no medido sobre el ATE (Nivel 1), NO estima U conjuntamente (Nivel 3). Pista: sobre NHEFS, el E-value $\approx$ 2.17 no nos dice qué es U (dieta, ejercicio), solo qué tan fuerte debe ser. ¿Qué pasaría si intentáramos estimar U directamente (Nivel 3) sin datos sobre U? Discutan 1 min.

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq \hat{W}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

Confundir 'E-value alto' con 'efecto causal grande'. El E-value mide robustez a confusión no medida, NO la magnitud del efecto. Un estimador pequeño puede tener E-value alto si el SE es chico.

Reportar el E-value puntual sin IC. Un E-value = 12 con IC [1.2, 22] es mucho menos convincente que el mismo E-value con IC [9.5, 14.8].

Interpretar Γ crítico como 'efecto real de U'. Γ es un bound sobre el sesgo potencial, no una estimación del confusor.

Aplicar E-value a estimadores con SE mal calculado (p.ej. sin cluster por distrito). El E-value hereda la fragilidad del SE: si SE está subestimado, E-value está sobreestimado.

Olvidar que el E-value asume RR_{UT} y RR_{UY} iguales. Si el confusor tiene $RR_{UT} \neq RR_{UY}$ (p.ej. $RR_{UT}=20$, $RR_{UY}=3$), el bound cambia. El E-value es un caso simétrico conservador.

Conexiones conceptuales

Conecta con Cap. 9 (synth: introdujo Pensión 65 como caso peruano; aquí hacemos sensibilidad sobre el estimador de matching, complementando el placebo espacial de Synth), Cap. 12 (selección: cuándo usar matching vs. IV vs. Synth vs. sensibilidad), Cap. 31 (equidad: el E-value se extiende a estimaciones heterogéneas por subgrupo).

¿Por qué este capítulo NO usa Beca 18? Los caps. 3-10 usaron Beca 18 como hilo transversal porque cada método (matching, IPW, IV, RDD, DiD, Synth, mediación) se deriva desde un DGP simulado con semilla 42, donde Beca 18 parametriza T, M, Y. El análisis de sensibilidad (Cap. 11) es metodológicamente distinto: se aplica a un **estimador puntual publicado** sobre datos reales, no se rederiva desde un DGP. Pensión 65 tiene un estimador empírico concreto ($ATE = 300$, $SE = 25$) sujeto a sensibilidad; usar Beca 18 aquí requeriría inventar un ATE publicado artificial. Por ello, el `running_beca18 = False` y este capítulo opera con caso puntual sin reemplazo (sin slide de puente).

Pregunta de discusión

VanderWeele (2020) sugiere $E > 2$ como umbral práctico para considerar “robusto” un estudio observacional. ¿Están de acuerdo con este umbral? Den un ejemplo concreto en Pensión 65 donde $E\text{-value} = 12$ podría ser engañoso (pista: SE mal calculado, muestra pequeña, violación de SUTVA).

Ejercicio (5-10 min)

En Python, modifiquen el snippet del Cap. 11 para simular SE mal calculado: subestimen SE a la mitad ($SE = 12.5$ en lugar de 25). Verifiquen que el $E\text{-value}$ se duplica a 24.00. ¿Cómo detectarían este problema en la práctica? Pista: comparar SE reportado con bootstrap no paramétrico (1000 réplicas, cluster por distrito). ¿Qué concluyen sobre la fiabilidad del $E\text{-value}$ cuando el SE es dudoso? (Semilla 42.)

Resumen

- La identificación causal nunca es 'todo o nada': la pregunta práctica es qué tan robusto es el estimador a confusores no medidos.
- El E-value (VanderWeele-Ding 2017) cuantifica la magnitud mínima (RR) que un confusor no medido debe tener con T y con Y simultáneamente para anular el efecto.
- Rosenbaum bounds (Γ) son el equivalente clásico: el Γ crítico es el menor sesgo que revierte la conclusión. $\Gamma^* \approx \text{E-value}$.
- Pensión 65: $\text{ATE} = 300$, $\text{SE} = 25$, $d = 12$, $\text{E-value} = 12.00 \rightarrow$ robustez extrema. Caso puntual sin slide de puente.

Referencias clave

- (1) VanderWeele, T. & Ding, P. (2017). Sensitivity Analysis in Observational Research: Introducing the E-Value. *Annals of Internal Medicine*.
- (2) Rosenbaum, P. (2002). *Observational Studies* (2nd ed.). Springer — Cap. 4 (Sensitivity to Hidden Bias).
- (3) VanderWeele, T. (2020). Optimal Approximate Bounds for the Risk Ratio under Confounding. *Epidemiology*.

Próximo episodio · Cap. 12 — Selección de Métodos: ya tenemos todas las herramientas del Bloque I (matching, IPW, IV, RDD, DiD, Synth, mediación, sensibilidad). Aprenderemos a decidir cuál usar cuándo, mediante un árbol de decisión basado en supuestos, datos disponibles y estimando. El E-value será nuestro criterio de robustez transversal.

Gancho: Si tuvieran que elegir UN solo método para evaluar Pensión 65 con datos limitados y confusores no medidos plausibles, ¿cuál elegirían y por qué?