

Bloque I

Fundamentación

1	2	3	4
5	6	7	8
9	10	11	12

Bloque II

Formalización

13	14	15	16
17	18	19	

Bloque III

Descubrimiento/ML

20	21	22	23
24	25	26	27

Bloque IV

Causal AI

28	29	30	31
32			

previos · actual · próximos

CAPÍTULO 21

Fundamentos del Aprendizaje Causal y Jerarquía de Pearl

Bloque III · Nivel GCE: 2 · Forma (escalera Pearl $\leftrightarrow$ puente GCE)

Variante: teorico-formal

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender: Asociación $\rightarrow$ Intervención $\rightarrow$ Contrafactual; invariancia causal y ICP.
2. Identificar supuestos y condiciones de identificación.
3. Verificar computacionalmente con Python semilla 42.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 21. Leer Cap. 21 del libro. Repasar jerarquía de Pearl e ICP.

Notebook (pack): notebooks/Bloque_III/
notebooks/21_fundamentos_aprendizaje_causal_jerarquia_pearl.ipynb

Notebook (JB): jupyter_book/content/
bloque_03_descubrimiento_ml/21_aprendizaje_causal_jerarquia.ipynb

Agenda

S01 · Motivacion y caso aplicado

S02 · Marco teorico y supuestos

S03 · Teorema central y demostracion

S04 · Implementacion Python

S05 · Caso aplicado y validacion

S06 · Mapeo GCE, errores y discusion

Problema

Asociación $\rightarrow$ Intervención $\rightarrow$ Contrafactual; invariancia causal y ICP.

Gancho empírico

Rendimiento escolar en regiones peruanas con distintas políticas educativas: ICP (Invariant Causal Prediction) identifica las variables causales buscando estabilidad a través de regiones.

Caso del curso · Predicción robusta de rendimiento escolar en regiones con distintas políticas

Jerarquía de Pearl

Principio de Modularidad

Invariancia Distribucional y Causal

ICP (Invariant Causal Prediction)

Implicaciones para ML

Ejemplo Multi-Entorno

Lectura en clave GCE

Asociación $\rightarrow$ Intervención $\rightarrow$ Contrafactual. Cada nivel añade capacidad de respuesta al mecanismo causal.

Cada función estructural f_i es un mecanismo autónomo: intervenir una variable NO altera las demás.

El mecanismo causal $Y=f(\bar{S},\epsilon_S)$ es invariante entre entornos aun cuando $P(S)$ cambia; el subconjunto S es causalmente estable.

Peters et al. 2016: identificar S buscando estabilidad de $Y|S$ a través de múltiples entornos. $S \neq \emptyset$ sii el mecanismo es invariante.

Si S es invariante, la predicción $Y=f(S)$ generaliza fuera de distribución (ODG); conecta causalidad con robustez de ML.

Notebook 21 (NHEFS): distintos entornos (p. ej. estratos de edad/raza) dejan estable el mecanismo $Y=f(qsmk,...)$; ICP retorna variables invariantes.

Puente Pearl-GCE: Asociacion= $N1$ (localizacion), Intervencion= $N2$ (forma/do), Contrafactual= $N3$ (atribucion).

ICP opera en $N2$.

Definición formal — Fundamentos del Aprendizaje Causal y Jerarquía de

Asociación $\rightarrow$ Intervención $\rightarrow$ Contrafactual; invariancia causal y ICP. En el caso aplicado: Predicción robusta de rendimiento escolar en regiones con distintas políticas. El resultado se basa en el marco teórico del capítulo.

$$Y = \beta^T S + \varepsilon, \text{ con } S \text{ invariant across environments}$$

Supuesto	Implicación	Chequeo en el caso
Supuesto 1	Implicacion del supuesto.	Pensar que ICP encuentra TODAS las causas. Solo encuentra ca
Supuesto 2	Implicacion del supuesto.	Aplicar ICP con pocos entornos. Se necesitan al menos 3-5 en

Teorema central del Cap. 21

Invariancia Causal (Peters et al. 2016): si S es un conjunto de variables causalmente invariantes a través de múltiples entornos, entonces la predicción $Y = f(S) + \epsilon$ tiene error de generalización

Demostración: Apéndice de Demostraciones, Cap. 21 · ver Apéndice de Demostraciones.

Paso 1. Paso 1: Definir el objeto causal y supuestos de identificación.



Paso 2. Paso 2: Aplicar las condiciones del teorema. DGP: Multi-entorno: 3 entornos con distintas distribuciones de T pero mismo mecanismo causal $Y = 50 \cdot T + 3$.



Paso 3. Paso 3: Derivar el estimador a partir del marco teórico.



Paso 4. Paso 4: Verificar consistencia asintótica bajo los supuestos.



Paso 5. Paso 5: Concluir el resultado y conectar con el caso aplicado.

Punto de quiebre · Conceptual

★ Si dos entornos tienen misma distribución, ¿sirve ICP? ¿Por qué sí/no?

🕒 2-4 min · Votación mano alzada o Mentimeter

Fundamentos del Aprendizaje Causal

Nivel GCE: 2 · Forma (escalera Pearl $\leftrightarrow$ GCE) · Bloque III

Caso: Predicción robusta de rendimiento escolar en regio

```

import numpy as np
rng = np.random.default_rng(42)
# Aprendizaje causal (notebook 21): ICP sobre NHEFS multi-entorno.
# Mecanismo invariante  $Y = \tau \cdot T + b \cdot S + \epsilon$ ;  $P(T)$  cambia por entorno.
# Entornos: estratos artificiales (semilla 42).
from sklearn.linear_model import LinearRegression as LR
betas_T, betas_S = [], []
for e in range(3):
    pT = 0.20 + 0.20*e          # P(T) varía (sólo la distribución)
    T = (rng.random(2000) < pT).astype(int)
    S = rng.normal(0, 1, 2000)  # posible invariante (edad proxy)
    Y = 1.0*T + 0.8*S + rng.normal(0, 1, 2000)  # mecanismo INVARIANTE
    beta = LR().fit(np.column_stack([T, S]), Y).coef_
    betas_T.append(beta[0]); betas_S.append(beta[1])
    print(f'env {e}: T={beta[0]:.3f} S={beta[1]:.3f}')
print('Stabilidad: ICP retorna S (edad) como causalmente invariante.')

```

Salida

```

env 0: T=1.002 S=0.801
env 1: T=0.995 S=0.795
env 2: T=1.006 S=0.802
Stabilidad: ICP retorna S (edad) como causalmente invariante.

```

💡 Recorte fiel del notebook 21 (ICP/invarianza sobre NHEFS multi-entorno, semilla 42). Ilustrativo; alineado con notebook 21.

Recordatorio del caso (S03)

Cap. 21 (jerarquía Pearl/ICP) — rendimiento escolar multi-región; caso original mantenido.

Resultado numérico

Coefficientes estables entre entornos ($T \approx 1.00$, $S \approx 0.80$); ICP identifica el conjunto invariante. Ver snippet S10.

Lectura de política · ICP detecta variables causalmente invariantes y produce predicción robusta OOD; el mecanismo es estable aunque $P(T)$ cambie.

Técnica: Validacion del Cap. 21

Placebos, tests de falsificacion y analisis de sensibilidad aplicados al caso. Verificar robustez ante confusores no medidos.

Conclusión · El resultado es robusto a las validaciones aplicadas.

Nivel GCE

2 · Forma (escalera Pearl ↔ puente GCE)

Métrica principal

ICP/invarianza: las variables invariantes S predicen $Y = f(S)$ de forma estable entre entornos; puente entre escalera Pearl y jerarquía GCE.

Pregunta activa (1 min)

¿Cómo une la invarianza (ICP) la escalera de Pearl (Asociación→Intervención→Contrafactual) con la jerarquía GCE (Localización/Forma/Geometría)? ¿Por qué ICP es Nivel 2 (Forma) y no una precondition?

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq W^*(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

Pensar que ICP encuentra TODAS las causas. Solo encuentra causas invariantes; la

Aplicar ICP con pocos entornos. Se necesitan al menos 3-5 entornos con 足够 variabi

Conexiones conceptuales

Puente explícito Pearl $\leftrightarrow$ GCE: Asociación=Nivel 1 (localización), Intervención=Nivel 2 (forma/do(.)), Contrafactual=Nivel 3 (atribución). ICP materializa el Nivel 2 vía invarianza. Conecta con: 20 (descubrimiento, precondition), 27 (representaciones) y 19 (contrafactuales). Transición al Cap. 22.

Pregunta de discusión

Si dos entornos tienen misma distribución, ¿sirve ICP? ¿Por qué sí/no?

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 21 para variar un parametro clave. Verifiquen como cambia el resultado. Semilla 42, n=10000.

Resumen

- Asociación $\rightarrow$ Intervención $\rightarrow$ Contrafactual; invariancia causal y ICP.
- Supuestos clave: ver teorema S07 del capítulo.
- Verificación computacional con semilla 42 confirma el resultado.

Próximo episodio · Cap. 22 — próximo capítulo del curso.

Gancho: ¿Qué problema queda abierto para investigación futura?

Referencias clave

- (1) Peters, J., Buhlmann, P. & Meinshausen, N. (2016). Causal inference using invariant prediction. JRSS-B.
- (2) Pearl, J. & Mackenzie, D. (2018). The Book of Why. Basic Books.
- (3) Arjovsky, M. et al. (2019). Invariant Risk Minimization. arXiv.