



■ previos · ■ actual · □ próximos

CAPÍTULO 22

Meta-Learners para Inferencia Causal: S/T/X-Learners y Más

Bloque III · Nivel GCE: 1 · Localización (CATE heterogéneo)

Variante: metodologico-practico

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender el CATE $\tau(x)$ como estimando de localización condicional (Nivel 1 GCE).
2. Identificar supuestos de identificación (CIA + overlap) y de la arquitectura S/T/X/R-Learner.
3. Verificar computacionalmente con Python (semilla 42) el trade-off sesgo-varianza entre meta-learners.

★ Prerequisitos

Lectura: Libro monográfico ``libro/main.pdf`` · Cap. 22 · Meta-Learners (Künzel 2019). Apéndice de Demostraciones: `proof_01`.

Notebook (pack): `notebooks/Bloque_III/notebooks/22_meta_learners_inferencia_causal_stx.ipynb`

Notebook (JB): `jupyter_book/content/bloque_03_descubrimiento_ml/22_meta_learners.ipynb`

Agenda

S01 · Motivación: heterogeneidad causal y Beca 18

S02 · Marco teórico y supuestos de identificación

S03 · Teorema central (Künzel et al. 2019) y demostración

S04 · ★ Punto interactivo: ¿qué meta-learner gana?

S05 · Implementación Python (Proofs-to-Python)

S06 · Caso aplicado · validación · mapeo GCE

S07 · Errores · conexiones · discusión

Problema

Bajo heterogeneidad del tratamiento, $\tau(x) \neq \tau_{\text{ATE}}$. Estimar el efecto condicional permite heterogeneidad por ingreso, género, ruralidad — clave para transferencias focalizadas. La pregunta es: ¿con qué arquitectura de ML?

Gancho empírico

Beca 18 con CATE heterogéneo: ¿quiénes se benefician más? En el notebook del capítulo se compara S-Learner, T-Learner, X-Learner y R-Learner sobre un DGP con $\tau(x) = b_0 + b_1x_1$, evaluando con PEHE.

Caso del curso · Beca 18 — heterogeneidad del efecto por características socioeconómicas

CATE	Conditional Average Treatment Effect: $\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$. Estimando de localización condicional (Nivel 1 GCE).
S-Learner	Un solo modelo $\mu(x, t)$ con t como feature; $\text{CATE} = \mu(x, 1) - \mu(x, 0)$. Riesgo: regulariza el tratamiento hacia cero (sesgo de selección).
T-Learner	Dos modelos separados $\mu_0(x)$ y $\mu_1(x)$; $\text{CATE} = \mu_1(x) - \mu_0(x)$. Sufre cuando el grupo tratado es pequeño.
X-Learner	Künzel 2019: usa información cruzada entre grupos. Robusto con desbalance. Construye τ_1 , τ_0 y combina con $g(x)$ por propensity.
R-Learner	Nie-Wager 2021: optimiza pérdida de Robinson con Cross-Fitting; estima $\tau(x)$ vía ortogonalidad (puente al Cap. 23 DML).
PEHE	Precision in Estimation of Heterogeneous Effect: $\sqrt{\mathbb{E}[(\hat{\tau}(x) - \tau(x))^2]}$. Métrica de error CATE.
BLP	Best Linear Projection of CATE: regresión auxiliar de $\hat{\tau}$ sobre X para diagnosticar heterogeneidad.

CATE y meta-learners

El CATE $\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$ es un funcional de localización condicional (Nivel 1 de GCE). Un meta-learner es una arquitectura que combina modelos de nuisance $\mu_{t(x)}$ y/o propensity $e(x)$ para estimar $\tau(x)$. Cada uno define un sesgo-varianza distinto según el balance de grupos.

$$\tau(x) = \mu_1(x) - \mu_0(x)$$

Supuesto	Implicación	Chequeo en el caso
CIA + overlap	$((Y(1), Y(0)) \text{ independent } T) \text{ mid } X, 0 < e(X) < 1$.	Para $CATE(x)$ en estratos con datos suficiente.
Balance de grupos	$P(T=1)$ ni cercano a 0 ni a 1.	Desbalance favorece X-Learner y R-Learner; T-Learner sufre.
Honesty (Causal Forest de Cap. 24)	CATE se estima fuera de hojas usadas para split.	Para no inflar heterogeneidad por sobre-ajuste.
Smoothness de $\tau(x)$	$\tau(\cdot)$ no brusco en x .	Determina sesgo de S-Learner (regularización) vs T-Learner (varianza).

Teorema central del Cap. 22 (X-Learner, Künzel et al. 2019)

Bajo CIA + overlap y desbalance moderado de grupos, el X-Learner estima el CATE con menor sesgo que el S-Learner (que tiende a regularizar τ hacia 0) y menor varianza que el T-Learner (que sufre con n_1 pequeño). Combina $\tilde{\tau}_1(x) = \mu_1(x) - \widehat{Y_0 \mid x}$ y $\tilde{\tau}_0(x) = \widehat{Y_1 \mid x} - \mu_0(x)$ vía $\tau(x) = g(x)\tilde{\tau}_0(x) + (1 - g(x))\tilde{\tau}_1(x)$, con $g(x)$ una función de propensity (p.ej. $g(x) = e(x)$).

Demostración: Apéndice de Demostraciones, Cap. 22 · proof_01 (Apéndice de Demostraciones del libro)..

Paso 1. Paso 1: Definir el estimando $\tau(x)$ y supuestos (CIA + overlap). Identificar que es un funcional de localización condicional (Nivel 1 GCE), **no** de Geometría (Nivel 3).



Paso 2. Paso 2: Estimar $\mu_0(x)$, $\mu_1(x)$ y $e(x)$ con ML (RF / GBM / NN). Calcular los pseudo-efectos individuales $\tilde{\tau}_1$ en el grupo tratado y $\tilde{\tau}_0$ en el control.



Paso 3. Paso 3: Aprender $\tau(x)$ desde $\tilde{\tau}_0$ y $\tilde{\tau}_1$, combinando con $g(x)$ por propensity.



Paso 4. Paso 4: Verificar consistencia asintótica: bajo $h@mu_t \rightarrow mu_t$ y $h@e \rightarrow e$, $\hat{\tau} \rightarrow \tau$ en MSE.



Paso 5. Paso 5: Evaluar con PEHE (no observable en práctica; requiere DGP conocido como en el notebook 22).

Punto de quiebre · Predictivo

★ Sobre el DGP del notebook 22 ($\tau(x) = b_0 + b_1 x_1$, semilla 42, $n = 2\{, \}000$, tratados = 30%), ¿qué meta-learner tendrá menor PEHE? S, T, X o R? Votación.

🕒 2-4 min · Votación mano alzada o Mentimeter

Meta-Learners — Nivel 1 · Localización (CATE)

S-Learner: 1 modelo $\mu(x, t)$

T-Learner: 2 modelos μ_0, μ_1

X-Learner: combinación cruzada vía $e(x)$

R-Learner: pérdida de Robinson (puente a Cap. 23 DML)

Beca 18 — heterogeneidad por ruralidad/género/ingreso

```

import numpy as np
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.linear_model import LogisticRegressionCV

rng = np.random.default_rng(42)
n = 2_000

# DGP del Cap. 22: CATE heterogeno  $\tau(x) = 2 + 1.5x_1$ 
X = rng.normal(0, 1, (n, 3))
e_logit = -0.7 + 0.5*X[:, 0]
T = (rng.uniform(size=n) < 1/(1+np.exp(-e_logit))).astype(int)
Y0 = 10 + 3*X[:, 0] + 1.5*X[:, 1] + rng.normal(0, 1, n)
tau_true = 2 + 1.5*X[:, 0]
Y1 = Y0 + tau_true
Y = T*Y1 + (1-T)*Y0

# T-Learner
mu1 = GradientBoostingRegressor().fit(X[T==1], Y[T==1])
mu0 = GradientBoostingRegressor().fit(X[T==0], Y[T==0])
tau_T = mu1.predict(X) - mu0.predict(X)

# S-Learner (X con T como feature)
M = GradientBoostingRegressor().fit(np.c_[X, T], Y)
tau_S = M.predict(np.c_[X, np.ones(n)]) - M.predict(np.c_[X, np.zeros(n)])

PEHE_S = np.sqrt(np.mean((tau_S - tau_true)*2))
PEHE_T = np.sqrt(np.mean((tau_T - tau_true)*2))
print(f'PEHE(S) = {PEHE_S:.3f}')
print(f'PEHE(T) = {PEHE_T:.3f}')

```

Salida

```

PEHE(S) = 0.62 # regularizaTau hacia 0 (bias de seleccion)
PEHE(T) = 0.34 # captura heterogeneidad mejor

```

💡 Ilustrativo; alineado con notebook 22 met-learners (semilla 42, DGP $\tau(x)=2+1.5x_1$). X-Learner introducible en clase reusando `mu0`, `mu1`, `e_hat`.

Hilo peruano y referencia del libro

Caso peruano (Beca 18)	Banco de pruebas del libro
Heterogeneidad por ruralidad, género, ingreso familiar; sub-poblaciones clave para focalización.	DGP sintético del notebook 22 ($\tau(x) = 2 + 1.5x_1$); benchmark histórico: IHDP (Hill 2011).
CATE estimado por X-Learner sobre datos administrativos del PRONABEC.	Comparación S/T/X/R con PEHE sobre verdad sembrada en el notebook.
Lección transferible: balance de grupos + smoothness de $\tau(x)$ dictan la elección.	Lección transferible: el método produce estimaciones comparables al Causal Forest del Cap. 24.

Técnica: Bootstrap sobre CATE + honest splitting

Se remuestran 200 veces y se recalcula $\hat{\tau}(x)$ en un punto de evaluación fijo (p. ej. $x = (-1, 0, 0)$). Se reporta el IC del CATE punto. Se complementa con *honest splitting* (mismo principio que Causal Forest, Cap. 24) para evitar inflar heterogeneidad por sobre-ajuste. B-LP ofrece diagnóstico visual.

Conclusión · El CATE estimado por X/R-Learner es robusto al bootstrap; B-LP confirma heterogeneidad por x1.

Nivel GCE
1 · Localización (CATE)

Métrica principal
CATE $\tau(x)$ · PEHE como métrica de error

Pregunta activa (1 min)

El CATE es un funcional de localización condicional, NO de Geometría (W_1 es el Nivel 3). ¿Qué pregunta del PRONABEC (p. ej. “¿cuánto aumenta el ingreso para hogares rurales?”) requiere Nivel 1 condicional y cuál responde ATE?

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq \hat{W}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

Elegir X-Learner por defecto sin diagnosticar balance de grupos. Cada meta-learner tiene fortalezas: S falla si T es relevante; T falla si $n_1 \ll n_0$; X es robusto pero costoso.

Confundir CATE con Nivel 3 (Geometría). El CATE es localización condicional; reservar Geometría para OT/ W_1 .

No reportar PEHE en simulaciones con verdad sembrada (notebook 22). Es la única métrica honesta de error CATE.

OLear heterogeneidad estimada sin honest splitting (riesgo de sobre-ajuste; puente al Cap. 24).

Conexiones conceptuales

Conecta con Caps. 6 (LATE — heterogeneidad por respondientes), 23 (DML — ortogonalidad) y 24 (Causal Forests). Transición natural: el R-Learner es preámbulo del DML de Cap. 23 (misma pérdida ortogonal de Robinson).

Pregunta de discusión

Sobre el DGP del notebook 22, ¿qué meta-learner gana en PEHE cuando $P(T = 1) = 0.05$ vs cuando $P(T = 1) = 0.5$? Votación + discusión.

Ejercicio (5-10 min)

En Python, replique el snippet del Cap. 22 con $P(T = 1) \in \{0.1, 0.3, 0.5\}$ y reporte PEHE de S/T/X-Learner. ¿En qué régimen domina cada uno? (Semilla 42, $n = 2\{, \}000$.)

Resumen

- Los meta-learners estiman el CATE — un funcional de localización condicional (Nivel 1 GCE), no Geometría.
- X-Learner y R-Learner dominan con desbalance de grupos; S-Learner confunde si T se regulariza.
- PEHE es la métrica honesta en simulaciones con verdad sembrada (notebook 22).

Referencias clave

- (1) Künzel, S. et al. (2019). Metalearners for estimating heterogeneous treatment effects. PNAS.
- (2) Nie, X. & Wager, S. (2021). Quasi-oracle estimation of heterogeneous treatment effects. Biometrika.
- (3) Hill, J. (2011). Bayesian nonparametric modeling for causal inference. JCGS.

Próximo episodio · Cap. 23 — Doble Machine Learning: el R-Learner visto aquí se generaliza con ortogonalidad de Neyman y Cross-Fitting para nuisance de alta dimensión.

Gancho: ¿Por qué el R-Learner (equivalente a DML unificado) basta una vez que se tiene ortogonalidad?