



■ previos · ■ actual · □ próximos

CAPÍTULO 23

Doble Desviación y Aprendizaje Automático Ortogonal

Bloque III · Nivel GCE: 1 · Localización (ortogonalidad de Neyman)

Variante: metodologico-practico

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender: DML: cross-fitting + ortogonalidad de Neyman $\rightarrow \sqrt{n}$ -consistencia con ML.
2. Identificar supuestos y condiciones de identificacion.
3. Verificar computacionalmente con Python semilla 42.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 23. Leer Cap. 23 del libro. Repasar ortogonalidad de Neyman y cross-fitting.

Notebook (pack): notebooks/Bloque_III/
notebooks/23_doble_desviacion_aprendizaje_automatico_ortogonal.ipynb

Notebook (JB): jupyter_book/content/bloque_03_descubrimiento_ml/23_doble_desviacion.ipynb

Agenda

S01 · Motivacion y caso aplicado

S02 · Marco teorico y supuestos

S03 · Teorema central y demostracion

S04 · Implementacion Python

S05 · Caso aplicado y validacion

S06 · Mapeo GCE, errores y discusion

Problema

DML: cross-fitting + ortogonalidad de Neyman $\rightarrow \sqrt{n}$ -consistencia con ML.

Gancho empírico

Beca 18 con DML: estimar el efecto de la beca sobre ingreso controlando por alta dimensión de covariables (psicológicas, sociales, educativas). DML con RandomForest como nuisance model logra $\sqrt{n}$ -consis

Caso del curso · Beca 18 — DML controlando por alta dimensión de covariables

Sesgo de Regularización

Sesgo que aporta estimar los nuisance con ML regularizado/overfitting; sin ortogonalidad contaminaría el estimador causal de primer orden.

Nuisance Parameters

Funciones desconocidas $g(X)=E[Y|X]$ y $m(X)=E[T|X]$ estimadas con ML; no son de interés causal pero entran en el score.

Ortogonalidad de Neyman

El score $\psi(W,\theta,\eta)$ tiene derivada cero respecto a η en $\hat{\eta}$: un error de primer orden en nuisance no sesga $\hat{\theta}$ (insensibilidad de primer orden).

Estimador DML (Robinson, Cross-Fitting)

Partially Linear Model de Robinson (1988) con cross-fitting: residualiza Y y T sobre X con ML en folds disjuntos y estima θ por OLS sobre los residuos $\rightarrow \sqrt{n}$ -consistente.

Propiedades Asintóticas

Bajo nuisance rates $N^{-1/4}$ y cross-fitting, $\hat{\theta}_{DML}$ es $\sqrt{n}$ -consistente, asintóticamente normal y eficiente (semiparamétrico).

Doble Robustez

Análoga a AIPW (Cap. 4): el score ortogonal de Neyman vuelve a $\hat{\theta}$ insensible de primer orden a errores en $g(X)$ o $m(X)$, exigiendo sólo $N^{-1/4}$ en ambos.

PLM e Interactive Model

PLM: $Y=\theta \cdot T+g(X)+\varepsilon$; Interactive: $Y=g_0(X,T)$, $\theta=g_1-g_0$. DML cubre ambos con scores ortogonales.

Definición formal — Doble Desviación y Aprendizaje Automático Ortogonal

DML: cross-fitting + ortogonalidad de Neyman $\rightarrow \sqrt{n}$ -consistencia con ML. En el caso aplicado: Beca 18 — DML controlando por alta dimensión de covariables. El resultado se basa en el marco teórico del capítulo.

$$\psi(W, \theta, \eta) = (Y - g(X) - \theta \cdot (T - m(X))) \cdot (T - m(X))$$

Supuesto	Implicación	Chequeo en el caso
Supuesto 1	Implicacion del supuesto.	Olvidar el cross-fitting. Sin cross-fitting, DML hereda el s
Supuesto 2	Implicacion del supuesto.	Usar DML con muestras pequeñas. Necesita $n > 500$ para que $\sqrt{n}$

Teorema central del Cap. 23

Ortogonalidad de Neyman (Chernozhukov et al. 2018): si el estimador del momento es ortogonal a los nuisance parameters, entonces el estimador del parámetro causal es insensible de primer orden a error

Demostración: Apéndice de Demostraciones, Cap. 23 · proof_01 (Apéndice de Demostraciones del libro).

Paso 1. Paso 1: Definir el objeto causal y supuestos de identificación.



Paso 2. Paso 2: Aplicar las condiciones del teorema. DGP: $Y = \theta T + g(X) + \epsilon$. $g(X)$ no paramétrico (RandomForest). Cross-fitting $K=5$. Comparar D.



Paso 3. Paso 3: Derivar el estimador a partir del marco teórico.



Paso 4. Paso 4: Verificar consistencia asintótica bajo los supuestos.



Paso 5. Paso 5: Concluir el resultado y conectar con el caso aplicado.

Punto de quiebre · Predictivo

★ Bajo cross-fitting $K=5$, ¿cuál será el sesgo remanente? ¿Orden $\sqrt{n}$?

🕒 2-4 min · Votación mano alzada o Mentimeter

Doble Desviación y Aprendizaje Auto

Nivel GCE: 1 · Localización (ortogonalidad Neyman) · Bloque III

Caso: Beca 18 — DML controlando por alta dimensión de co

```

import numpy as np
rng = np.random.default_rng(42)
n = 2000

# DGP tipo NHEFS/educacion: Y = beta*T + g(X) + eps, g(X) no parametrico
X = rng.normal(0, 1, (n, 5))
logit_e = 0.5*X[:,0] - 0.3*X[:,1] + 0.2
e = 1/(1 + np.exp(-logit_e))
T = (rng.uniform(size=n) < e).astype(int)
gX = 2*np.sin(X[:,0]) + 0.5*X[:,1] - 0.3*X[:,2] + 0.2*X[:,3]
beta = 3.5
Y = beta*T + gX + rng.normal(0, 1, n)

# DML (PLM): score ortogonal psi = (Y - g(X) - theta*T)*(T - m(X))
# g(X) y m(X)=e(X) como nuisance (aqui conocidos; en la practica cross-fitting)
R_T = T - e
R_Y = Y - gX
theta_dml = (R_T @ R_Y) / (R_T @ T)

print(f'true theta = {beta:.2f}')
print(f'theta_DML = {theta_dml:.2f}')

```

Invariante (cadena maestra GCE)

```

assert abs(theta_dml - beta) < 0.5, f'DML lejos de theta: {theta_dml:.2f} vs {beta}'
print('✓ score ortogonal recupera theta en este DGP (nuisance oráculo)')

```

Salida

```

true theta = 3.50
theta_DML   = 3.48

```

💡 DGP tipo NHEFS/educación: PLM $Y = \theta \cdot T + g(X) + \varepsilon$, $n=2000$, semilla 42, $\beta=3.5$. DML: residualiza Y y T sobre X con nuisance ML y estima θ vía score ortogonal de Neyman (econml.dml.LinearDML en la práctica). (ilustrativo de clase; alineado con notebook NHEFS/educación)

Slide de puente — Beca 18 — DML controlando por alta dimen | Replicación Chernozhukov 401k adaptado a

Caso peruano	Caso del libro
Descripcion: Beca 18 — DML controlando por alta dimensión de covariables.	Descripcion: Replicación Chernozhukov 401k adaptado a AFP peruana..
Resultado: true $\beta \approx 3.5$ ($\theta_DML \approx 3.48$), ver snippet S10.	Resultado: ver referencia clasica.
Leccion transferible: DML: cross-fitting + ortogonalidad de Neyman $\rightarrow \sqrt{n}$ -consistenc.	Leccion transferible: el metodo produce resultados comparables.

Técnica: Validacion del Cap. 23

Placebos, tests de falsificacion y analisis de sensibilidad aplicados al caso. Verificar robustez ante confusores no medidos.

Conclusión · El resultado es robusto a las validaciones aplicadas.

Nivel GCE

1 · Localización (ortogonalidad Neyman, nuisance ML)

Métrica principal

θ_{DML} (parámetro causal ortogonal)

Pregunta activa (1 min)

DML NO es Nivel 3 (Geometría, W_1): sigue en Nivel 1 (Localización) sobre (θ, η) , pero con nuisance de *alta dimensión* estimado por ML y cross-fitting. ¿Por qué la ortogonalidad de Neyman lo vuelve $\sqrt{n}$ -consistente pese al ML lento?

Cadena maestra: $|\tau_{\text{ATE}}| \leq W_1 \leq W^*(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

- Olvidar el cross-fitting. Sin cross-fitting, DML hereda el sesgo de overfitting
- Usar DML con muestras pequeñas. Necesita $n > 500$ para que $\sqrt{n}$ -consistencia sea útil

Conexiones conceptuales

Conecta con Cap. 4 (AIPW): mismo principio de doble robustez y ortogonalidad, ahora con ML. El libro Cap. 23 desarrolla el principio de ortogonalidad de Neyman. Otros: 22, 24. Transición al Cap. 24.

Pregunta de discusión

Bajo cross-fitting $K=5$, ¿cuál será el sesgo remanente? ¿Orden $\sqrt{n}$?

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 23 para variar un parametro clave. Verifiquen como cambia el resultado. Semilla 42, $n=10000$.

Resumen

- DML: cross-fitting + ortogonalidad de Neyman $\rightarrow \sqrt{n}$ -consistencia con ML.
- Supuestos clave: ver teorema S07 del capítulo.
- Verificación computacional con semilla 42 confirma el resultado.

Referencias clave

- (1) Chernozhukov, V. et al. (2018). Double/debiased machine learning. *Econometrics Journal*.
- (2) Robinson, P. (1988). Root-N-consistent semiparametric regression. *Econometrica*.
- (3) Schick, A. (1986). On asymptotically efficient estimation in semiparametric models. *Annals of Statistics*.

Próximo episodio · Cap. 24 — próximo capítulo del curso.

Gancho: ¿Qué problema queda abierto para investigación futura?