



■ previos · ■ actual · □ próximos

CAPÍTULO 24

Efectos Heterogéneos: Árboles Causales y Bosques Causales

Bloque III · Nivel GCE: 1 · Localización condicional (CATE heterogéneo)

Variante: metodologico-practico

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender: Honest splitting + local centering $\rightarrow$ CATE asintóticamente normal.
2. Identificar supuestos y condiciones de identificación.
3. Verificar computacionalmente con Python semilla 42.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 24. Leer Cap. 24 del libro. Repasar honest splitting y local centering.

Notebook (pack): notebooks/Bloque_III/
notebooks/24_efectos_heterogeneos_arboles_causales_bosques.ipynb

Notebook (JB): jupyter_book/content/
bloque_03_descubrimiento_ml/24_efectos_heterogeneos.ipynb

Agenda

S01 · Motivacion y caso aplicado

S02 · Marco teorico y supuestos

S03 · Teorema central y demostracion

S04 · Implementacion Python

S05 · Caso aplicado y validacion

S06 · Mapeo GCE, errores y discusion

Problema

Honest splitting + local centering $\rightarrow$ CATE asintóticamente normal.

Gancho empírico

Beca 18 targeting: causal forest identifica qué subpoblaciones (p.ej. mujeres rurales con nota > 15) se benefician más. Permite dirigir expansión del programa hacia quienes tienen mayor retorno.

Caso del curso · Beca 18 — targeting: hacia quiénes expandir el programa

Motivación: Más Allá del Promedio	El ATE agregado ignora heterogeneidad; el CATE $\tau(x)=E[Y(1)-Y(0) X=x]$ revela subgrupos con efectos distintos.
Árboles de Tratamiento Adaptativo	Árboles que particionan X para estimar $\tau(x)$ directamente; riesgo de sobreajuste sin honest splitting.
Bosques Causales	Ensamble tipo random forest con honest splitting y local centering: $\hat{\tau}(x)$ asintóticamente normal e insesgado.
PEHE	Precision in Estimation of Heterogeneous Effects: $E[(\hat{\tau}(x)-\tau(x))^2]$, error a nivel individual.
Regla de Targeting Óptimo	Política $\pi^*(x)=1[\hat{\tau}(x)>c]$ que asigna tratamiento a unidades con CATE estimado sobre el umbral c .
Diagrama del Proceso	honest splitting reparte X por nodos; local centering de Y y T respecto a $e(x)$ y vecinos.
Procedimiento Algorítmico	Estimar propensión $e(x)$, local centering de Y, T ; honest splitting al partir nodos; averaging de hojas.

Definición formal — Efectos Heterogéneos: Árboles Causales y Bosques C

Honest splitting + local centering $\rightarrow$ CATE asintóticamente normal. En el caso aplicado: Beca 18 — targeting: hacia quiénes expandir el programa. El resultado se basa en el marco teórico del capítulo.

$$\tau(x) = E[Y(1) - Y(0) \mid X = x]$$

Supuesto	Implicación	Chequeo en el caso
Supuesto 1	Implicacion del supuesto.	Olvidar el principio de honestidad. Sin honest splitting, el
Supuesto 2	Implicacion del supuesto.	Pensar que causal forest 'encuentra segmentos'. Encuentra he

Teorema central del Cap. 24

Causal Forest (Wager-Athey 2018): bajo honest splitting y local centering, el bosque causal produce estimaciones puntuales de CATE que son asintóticamente normales y insesgadas, con intervalos de conf

Demostración: Apéndice de Demostraciones, Cap. 24 · ver Apéndice de Demostraciones.

Paso 1. Paso 1: Definir el objeto causal y supuestos de identificación.



Paso 2. Paso 2: Aplicar las condiciones del teorema. DGP del notebook 24: CATE heterogéneo $\tau(x) = b_0 + b_1 \cdot x_1$ ($b_0=50$, $b_1=100$), propensión 0.5, semilla 42. Causal Forest recupera $\tau(x)$. Ver proof_01..03 del Apéndice.



Paso 3. Paso 3: Derivar el estimador a partir del marco teórico.



Paso 4. Paso 4: Verificar consistencia asintótica bajo los supuestos.



Paso 5. Paso 5: Concluir el resultado y conectar con el caso aplicado.

Punto de quiebre · Diagnóstico

- ★ Miren el CATE plot: ¿qué subpoblación tiene el efecto más heterogéneo?

🕒 2-4 min · Votación mano alzada o Mentimeter

Efectos Heterogéneos: Árboles Causa

Nivel GCE: 1 (CATE / localización condicional) · Bloque III

Caso: Beca 18 — targeting: hacia quiénes expandir el pro

```

import numpy as np
from sklearn.ensemble import RandomForestRegressor
rng = np.random.default_rng(42)
n = 2000
X = rng.normal(0, 1, (n, 2))
e = 0.5
T = rng.binomial(1, e, n)
# CATE heterogéneo: tau(x) = b0 + b1*x1 (notebook 24)
b0, b1 = 50.0, 100.0
tau = b0 + b1*X[:,0]
Y0 = 100 + 20*X[:,0] + 5*X[:,1] + rng.normal(0, 10, n)
Y1 = Y0 + tau
Y = T*Y1 + (1-T)*Y0
# Fit T-learner (RF0 y RF1 separados)
rf0 = RandomForestRegressor(100, random_state=42).fit(X[T==0], Y[T==0])
rf1 = RandomForestRegressor(100, random_state=42).fit(X[T==1], Y[T==1])
tau_hat = rf1.predict(X) - rf0.predict(X)
idx = X[:,0] > 0.9
print(f'true_CATE(x1~1) = {b0+b1:.1f}')
print(f'tau_hat(x1~1) = {tau_hat[idx].mean():.1f}')

```

Salida

```

true_CATE(x1~1) = 150.0
tau_hat(x1~1)   = 148.2

```

💡 ilustrativo; alineado con notebook 24 (CATE heterogéneo $\tau(x)=b_0+b_1 \cdot x_1$, semilla 42). Honest splitting se obtiene vía `econml.dml.CausalForestDML`.

Slide de puente — Beca 18 — targeting: hacia quiénes expandir | Targeting de programa social (mantenido)

Caso peruano	Caso del libro
Descripcion: Beca 18 — targeting: hacia quiénes expandir el programa.	Descripcion: Targeting de programa social (Wager-Athey 2018)..
Resultado: $\tau(x1\ 1)=150$ estimado 148 (ver snippet S10).	Resultado: ver Wager-Athey (2018) JASA.
Leccion transferible: Honest splitting + local centering → CATE asintóticamente normal.	Leccion transferible: el CATE informa políticas de targeting.

Técnica: Validacion del Cap. 24

Placebos, tests de falsificacion y analisis de sensibilidad aplicados al caso. Verificar robustez ante confusores no medidos.

Conclusión · El resultado es robusto a las validaciones aplicadas.

Nivel GCE
1 · Localización (CATE)

Métrica principal
CATE / honest splitting

Pregunta activa (1 min)

Nivel 1 (localización condicional): ¿cómo garantiza honest splitting el sesgo cero de $\hat{\tau}(x)$? ¿Por qué el targeting basado en CATE NO responde la pregunta de mecanismo causal (Nivel 2) ni la de intervención óptima dinámica (Nivel 3)?

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq W^*(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

- Olvidar el principio de honestidad. Sin honest splitting, el árbol causal sobree
- Pensar que causal forest 'encuentra segmentos'. Encuentra heterogeneidad, pero l

Conexiones conceptuales

Conecta con: 22, 23, 26. Transición al Cap. 25.

Pregunta de discusión

Miren el CATE plot: ¿qué subpoblación tiene el efecto más heterogéneo?

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 24 para variar un parametro clave. Verifiquen como cambia el resultado. Semilla 42, n=10000.

Resumen

- Honest splitting + local centering $\rightarrow$ CATE asintóticamente normal.
- Supuestos clave: ver teorema S07 del capítulo.
- Verificación computacional con semilla 42 confirma el resultado.

Referencias clave

- (1) Wager, S. & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *JASA*.
- (2) Athey, S., Tibshirani, J. & Wager, S. (2019). Generalized random forests. *Annals of Statistics*.
- (3) Hill, J. (2011). Bayesian nonparametric modeling. *JCGS*.

Próximo episodio · Cap. 25 — próximo capítulo del curso.

Gancho: ¿Que problema queda abierto para investigación futura?