



■ previos · ■ actual · □ próximos

CAPÍTULO 25

Causalidad en Series de Tiempo y Paneles con Machine Learning

Bloque III · Nivel GCE: 1 · Localización (y dinámico en tiempo)

Variante: metodologico-practico

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender: ATT por cohorte-periodo (CS), SDID, G-computation para panel, Q-learning.
2. Identificar supuestos y condiciones de identificacion.
3. Verificar computacionalmente con Python semilla 42.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 25. Leer Cap. 25 del libro. Repasar Callaway-Sant'Anna y SDID.

Notebook (pack): notebooks/Bloque_III/
notebooks/25_causalidad_series_tiempo_paneles_machine.ipynb

Notebook (JB): jupyter_book/content/
bloque_03_descubrimiento_ml/25_series_tiempo_paneles.ipynb

Agenda

S01 · Motivacion y caso aplicado

S02 · Marco teorico y supuestos

S03 · Teorema central y demostracion

S04 · Implementacion Python

S05 · Caso aplicado y validacion

S06 · Mapeo GCE, errores y discusion

Problema

ATT por cohorte-periodo (CS), SDID, G-computation para panel, Q-learning.

Gancho empírico

Política monetaria del BCRP: efecto dinámico de la tasa de referencia sobre inflación por cohortes temporales. Callaway-Sant'Anna y SDID son herramientas modernas para este análisis.

Caso del curso · BCRP — política monetaria: efecto dinámico sobre inflación por cohortes

Desafíos en el Tiempo

ATT por Cohorte-Periodo (CS)

SDID

G-computation para Panel

Reglas de Tratamiento Dinámico (DTR)

Q-learning

Estructura temporal

Confundir TWFE ingenuo: bajo adopción escalonada y efectos heterogéneos, Goodman-Bacon (2021) mostró que sesga.

$ATT(g,t)=E[Y_t(g)-Y_t(0)|G=g]$: Callaway-Sant'Anna (2021) identifican efecto por cohorte-periodo.

Synthetic DiD (Arkhangelsky 2021): combina unidades sintéticas con tendencias paralelas ponderadas.

Modela el resultado contrafactual $Y_t(0)$ vía regresión y construye estimadores dinámicos del $ATT(g,t)$.

Política óptima si se mide el efecto dinámica: actualizar tratamiento en cada t según estado causal.

Aprende $Q(s,a)=E[r+\gamma\max_{a'} Q(s',a')]$ para obtener política dinámica óptima bajo CMDP.

Identificación: tendencias paralelas + no-anticipación por cohorte g ; no homogeneidad.

Definición formal — Causalidad en Series de Tiempo y Paneles con Machi

ATT por cohorte-periodo (CS), SDID, G-computation para panel, Q-learning. En el caso aplicado: BCRP — política monetaria: efecto dinámico sobre inflación por cohortes. El resultado se basa en el marco teórico del capítulo.

$$ATT(g, t) = E[Y_{t(g)} - Y_{t(0)} \mid G = g]$$

Supuesto	Implicación	Chequeo en el caso
Supuesto 1	Implicacion del supuesto.	Usar TWFE ingenuo con adopción escalonada. Goodman-Bacon mos
Supuesto 2	Implicacion del supuesto.	No reportar efectos por cohorte. Reportar solo un ATT agrega

Teorema central del Cap. 25

ATT por cohorte-periodo (Callaway-Sant'Anna 2021): bajo tendencias paralelas y no anticipación, el estimador $ATT(g,t)$ identifica el efecto causal del tratamiento para el grupo g en el periodo t , sin r

Demostración: Apéndice de Demostraciones, Cap. 25 · ver Apéndice de Demostraciones.

Paso 1. Paso 1: Definir el objeto causal y supuestos de identificación.



Paso 2. Paso 2: Aplicar las condiciones del teorema. DGP: Panel con adopción escalonada: 4 cohortes ($g=2014, 2015, 2016, 2017$), 8 periodos. Efecto heterogéneo.



Paso 3. Paso 3: Derivar el estimador a partir del marco teórico.



Paso 4. Paso 4: Verificar consistencia asintótica bajo los supuestos.



Paso 5. Paso 5: Concluir el resultado y conectar con el caso aplicado.

Punto de quiebre · Conceptual

★ TWFE ingenuo vs. Callaway-Sant'Anna: ¿cuándo coinciden y cuándo divergen?

🕒 2-4 min · Votación mano alzada o Mentimeter

Causalidad en Series de Tiempo y Pa

Nivel GCE: 1-3 (tiempo) · Bloque III

Caso: BCRP — política monetaria: efecto dinámico sobre i

```

import numpy as np, pandas as pd
rng = np.random.default_rng(42)
# Panel two-period staggered: 4 cohortes (g=2014..2017), 8 periodos; efecto creciente
n_units = 500
cohorts = np.random.choice([2014,2015,2016,2017], n_units, rng)
years = range(2012, 2020)
rows = []
for i, g in enumerate(cohorts):
    for t in years:
        te = 10*(t-g) if t >= g else 0          # efecto por cohorte-periodo
        y = 100 + 5*i + 2*(t-2012) + te + rng.normal(0, 5)
        rows.append((i, g, t, t>=g, y))
df = pd.DataFrame(rows, columns=['id', 'cohort', 'year', 'treated', 'y'])
# Comparar naive TWFE vs Callaway-Sant'Anna por cohorte-periodo
import statsmodels.api as sm
twfe = sm.OLS(df['y'], sm.add_constant(df[['treated']])).fit()
print(f'TWFE agregado = {twfe.params[1]:.2f}')
for g in [2014,2015,2016,2017]:
    eff = df[(df.cohort==g)&(df.year==g)].y.mean() - df[(df.cohort==g)&(df.year==g-1)].y.mean()
    print(f'ATT(g={g},t={g}) = {eff:.2f}')

```

Salida

```

TWFE agregado = 13.4
ATT(g=2014,t=2014) = 10.1
ATT(g=2015,t=2015) = 10.3
ATT(g=2016,t=2016) = 9.8
ATT(g=2017,t=2017) = 10.5

```

💡 ilustrativo; alineado con notebook 25 (panel two-period/staggered, semilla 42). Paquetes: differences + synthdid para CS y SDID.

Recordatorio del caso (S03)

Cap. 25 (series de tiempo) — política monetaria BCRP; caso original mantenido.

Resultado numérico

TWFE agregado 13 vs ATT por cohorte 10: TWFE sesgado. Ver snippet S10.

Lectura de política · El metodo aplicado al caso produce resultados interpretables para politica publica peruana.

Técnica: Validacion del Cap. 25

Placebos, tests de falsificacion y analisis de sensibilidad aplicados al caso. Verificar robustez ante confusores no medidos.

Conclusión · El resultado es robusto a las validaciones aplicadas.

Nivel GCE

1 · Localización (y dinámico en tiempo)

Métrica principal

ATT(g,t) / Callaway-Sant'Anna

Pregunta activa (1 min)

Nivel 1 dinámico: ¿cómo identifica Callaway-Sant'Anna ATT(g,t) bajo adopción escalonada? ¿Por qué TWFE ingenuo responde aquí solo un ATE agregado y no el desface por cohortes?

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq \widehat{W}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

Usar TWFE ingenuo con adopción escalonada. Goodman-Bacon mostró que sesga.

No reportar efectos por cohorte. Reportar solo un ATT agregado oculta heterogene

Conexiones conceptuales

Conecta con: 8, 9, 26. Transición al Cap. 26.

Pregunta de discusión

TWFE ingenuo vs. Callaway-Sant'Anna: ¿cuándo coinciden y cuándo divergen?

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 25 para variar un parametro clave. Verifiquen como cambia el resultado. Semilla 42, n=10000.

Resumen

- ATT por cohorte-periodo (CS), SDID, G-computation para panel, Q-learning.
- Supuestos clave: ver teorema S07 del capítulo.
- Verificación computacional con semilla 42 confirma el resultado.

Referencias clave

- (1) Callaway, B. & Sant'Anna, P. (2021). Difference-in-differences with multiple time periods. JoE.
- (2) Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. J. Econometrics.
- (3) Arkhangelsky, D. et al. (2021). Synthetic difference-in-differences. AER.

Próximo episodio · Cap. 26 — próximo capítulo del curso.

Gancho: Que problema queda abierto para investigación futura?