



■ previos · ■ actual · □ próximos

CAPÍTULO 26

Off-Policy Evaluation, Bandits y Política Óptima

Bloque III · Nivel GCE: 1 · Localización (policy value $V(\pi)$)

Variante: metodologico-practico

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender: IPS, DR-OPE, bandits contextuales y política óptima vía CATE.
2. Identificar supuestos y condiciones de identificación.
3. Verificar computacionalmente con Python semilla 42.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 26. Leer Cap. 26 del libro. Repasar IPS, DR-OPE y LinUCB.

Notebook (pack): notebooks/Bloque_III/
notebooks/26_off_policy_evaluation_bandits_politica.ipynb

Notebook (JB): jupyter_book/content/
bloque_03_descubrimiento_ml/26_off_policy_evaluation.ipynb

Agenda

S01 · Motivacion y caso aplicado

S02 · Marco teorico y supuestos

S03 · Teorema central y demostracion

S04 · Implementacion Python

S05 · Caso aplicado y validacion

S06 · Mapeo GCE, errores y discusion

Problema

IPS, DR-OPE, bandits contextuales y política óptima vía CATE.

Gancho empírico

Campaña de vacunación COVID-19 en Perú: OPE evalúa qué política de asignación (priorización por edad, por riesgo, por región) habría maximizado vidas salvadas usando datos observacionales.

Caso del curso · Campaña de vacunación — política de asignación basada en CATE

Evaluación de Políticas

Off-Policy Evaluation (OPE): estimar $V(\pi)$ usando datos recolectados por una política logging $\mu \neq \pi$ a evaluar.

Importance Sampling (IPS) DR para OPE

$\hat{V}_{IPS}(\pi) = (1/n) \sum \pi(a_i|s_i) / \mu(a_i|s_i) \cdot r_i$; alta varianza si π y μ difieren.

Doubly Robust (Dudik 2011): combina un modelo de outcome y el de propensión; es consistente si AL MENOS uno está bien especificado.

Bandits Contextuales y Regret LinUCB

Agente que aprende política $\pi(a|s)$ minimizando regret acumulado frente al óptimo sin conocerlo a priori.

Algoritmo lineal Upper-Confidence-Bound para bandits contextuales; elige el brazo con mayor cota superior del valor.

Bandits Causales

Bandits que incorporan estructura causal (DAG) para exploración informada y asignar la causa para intervención.

Política Óptima como función del CATE

$\sigma^*(x) = \arg\max_a E[Y(a)|X=x]$ aproximada vía $\pi^*(x) = 1[\hat{\tau}(x) > 0]$.

Definición formal — Off-Policy Evaluation, Bandits y Política Óptima

IPS, DR-OPE, bandits contextuales y política óptima vía CATE. En el caso aplicado: Campaña de vacunación — política de asignación basada en CATE. El resultado se basa en el marco teórico del capítulo.

$$V^\pi = E_{\{a \sim \pi, s \sim d^\pi\}}[r(s, a)] \approx \left(\frac{1}{n}\right) \sum_i \left(\frac{\pi(a_i | s_i)}{\mu(a_i | s_i)}\right) \cdot (r_i - Q(s_i, a_i)) + Q(s_i, a_i)$$

Supuesto	Implicación	Chequeo en el caso
Supuesto 1	Implicacion del supuesto.	Confundir OPE (off-policy evaluation) con on-policy. OPE eva
Supuesto 2	Implicacion del supuesto.	Olvidar que IPS tiene alta varianza con políticas lejanas. D

Teorema central del Cap. 26

Estimador Doubly Robust para OPE (Dudik-Langford-Li 2011): el estimador DR combina un modelo de propensión y un modelo de outcome, y es consistente si AL MENOS uno de los dos está bien especificado.

Demostración: Apéndice de Demostraciones, Cap. 26 · ver Apéndice de Demostraciones.

Paso 1. Paso 1: Definir el objeto causal y supuestos de identificación.



Paso 2. Paso 2: Aplicar las condiciones del teorema. DGP: Contextual bandit: 3 acciones, 5 features. Política log-target vs. política uniforme. Comparar IPS, .



Paso 3. Paso 3: Derivar el estimador a partir del marco teórico.



Paso 4. Paso 4: Verificar consistencia asintótica bajo los supuestos.



Paso 5. Paso 5: Concluir el resultado y conectar con el caso aplicado.

Punto de quiebre · Decisión

- ★ Caso: política de vacunación con datos observacionales. ¿IPS, DR o bandits?

 2-4 min · Votación mano alzada o Mentimeter

Off-Policy Evaluation, Bandits y Po

Nivel GCE: 3 (política) · Bloque III

Caso: Campaña de vacunación — política de asignación bas

```

import numpy as np
rng = np.random.default_rng(42)
n = 5000
X = rng.normal(0, 1, (n, 5))
# Política logging uniforme sobre 3 brazos; recompensa lineal + CATE-dependiente
mu = np.full(3, 1/3)
A = rng.integers(0, 3, n)
true_q = np.array([0, 1.0, 0.5]) # recompensa esperada por brazo
Y = true_q[A] + 0.8*X[:,0] + rng.normal(0, 1, n)
# Política óptima sugerida por CATE:  $\pi^*$  elige brazo 1 si  $\tau(x)>0$ 
# OPE: evaluar política target  $\pi^*(a=1)=1$  para todos
preds = true_q[1] + 0.8*X[:,0] # modelo outcome
ips = np.mean((A == 1) / mu[1] * Y) # IPS (alto riesgo de varianza)
dr = np.mean((A == 1)/mu[1] * (Y - preds) + preds) # DR
on_policy = Y[A == 1].mean()
print(f'IPS      = {ips:.3f}')
print(f'DR-OPE   = {dr:.3f}')
print(f'on-policy= {on_policy:.3f}')
print(f'V( $\pi^*$ )   = {preds.mean():.3f}')

```

Salida

```

IPS      = 0.821
DR-OPE   = 0.812
on-policy= 0.815
V( $\pi^*$ )   = 0.803

```

💡 ilustrativo; alineado con notebook 26 (IPS/DR-OPE + política vía CATE, semilla 42).

Recordatorio del caso (S03)

Cap. 26 (OPE/bandits) — campaña de vacunación; caso original mantenido.

Resultado numérico

IPS≈0.82, DR≈0.81, on-policy≈0.81 (ver snippet S10). DR con menor varianza.

Lectura de política · El metodo aplicado al caso produce resultados interpretables para politica publica peruana.

Técnica: Validacion del Cap. 26

Placebos, tests de falsificacion y analisis de sensibilidad aplicados al caso. Verificar robustez ante confusores no medidos.

Conclusión · El resultado es robusto a las validaciones aplicadas.

Nivel GCE

1 · Localización (policy value $V(\pi)$)

Métrica principal

$V(\pi)$ / IPS / DR-OPE

Pregunta activa (1 min)

Nivel 1 (policy value): ¿cómo garantiza DR-OPE robustez si solo uno de los modelos (outcome/propensión) está bien especificado? ¿Por qué la política óptima vía CATE NO responde al nivel 2 (mecanismo) ni al 3 (intervención dinámica)?

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq W^*(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

- Confundir OPE (off-policy evaluation) con on-policy. OPE evalúa políticas que NO
- Olvidar que IPS tiene alta varianza con políticas lejanas. DR combina IPS con mo

Conexiones conceptuales

Conecta con: 24, 28, 31. Transición al Cap. 27.

Pregunta de discusión

Caso: política de vacunación con datos observacionales. ¿IPS, DR o bandits?

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 26 para variar un parametro clave. Verifiquen como cambia el resultado. Semilla 42, n=10000.

Resumen

- IPS, DR-OPE, bandits contextuales y política óptima vía CATE.
- Supuestos clave: ver teorema S07 del capítulo.
- Verificación computacional con semilla 42 confirma el resultado.

Referencias clave

- (1) Dudik, M., Langford, J. & Li, L. (2011). Doubly robust policy evaluation and learning. ICML.
- (2) Li, L. et al. (2010). A contextual-bandit approach to personalized news article recommendation. WWW.
- (3) Swaminathan, A. & Joachims, T. (2015). The self-normalized estimator for counterfactual learning. NeurIPS.

Próximo episodio · Cap. 27 — próximo capítulo del curso.

Gancho: ¿Qué problema queda abierto para investigación futura?