



■ previos · ■ actual · □ próximos

CAPÍTULO 27

Aprendizaje de Representaciones Causales y Modelos Generativos

Bloque III · Nivel GCE: 2 · Forma (representaciones invariantes)

Variante: [síntesis-frontera](#)

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

- 1. Comprender: IRM, VAE identificables, CausalVAE: del predictor a las causas.
- 2. Identificar supuestos y condiciones de identificacion.
- 3. Verificar computacionalmente con Python semilla 42.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 27. Leer Cap. 27 del libro. Repasar IRM y VAE identificables.

Notebook (pack): notebooks/Bloque_III/notebooks/27_aprendizaje_representaciones_causales_modelos_generativos.ipynb

Notebook (JB): jupyter_book/content/bloque_03_descubrimiento_ml/27_representaciones_causales.ipynb

Agenda

S01 · Motivacion y caso aplicado

S02 · Marco teorico y supuestos

S03 · Teorema central y demostracion

S04 · Implementacion Python

S05 · Caso aplicado y validacion

S06 · Mapeo GCE, errores y discusion

Problema

IRM, VAE identificables, CausalVAE: del predictor a las causas.

Gancho empírico

Clasificación médica en EsSalud: modelos de deep learning que usan correlaciones espurias (marca de agua del hospital) en lugar de causas reales (patología). CausalVAE puede aprender representaciones

Caso del curso · Detección de correlación espuria en clasificación médica

De Predicciones a Causas

IRM

Limitaciones de IRM

VAE con Estructura Causal (iVAE, CausalVAE)

Correlación Espuria y Shortcut Learning

Diagrama del Espacio Latente

Procedimiento CausalVAE+NOTEARS

Objetivo: pasar de predictor $\min E[\hat{R}_e(\varphi)]$ a representaciones $\varphi(x)$ invariantes que soportan intervención y generalización.

Invariant Risk Minimization (Arjovsky 2019): $\min_{\varphi} \Sigma_e \hat{R}_e(\varphi) + \lambda ||\nabla_{\varphi} \hat{R}_e(\varphi)||^2$. Busca Φ invariantes entre entornos.

IRM lineal recupera invariantes; con redes profundas fracasa o recupera invariantes espurias.

VAE identifiable (iVAE) o con grafo causal conocido (CausalVAE): descompón variables latentes en Z, con flujos causales explícitos.

El predictor aprende correlaciones espurias (e.g., marca de agua del hospital) en lugar de causas (patología).

Z (latentes) $\rightarrow$ X (observaciones); conocer grafo causal sobre Z permite identificar.

CausalVAE aprende representaciones condicionales; NOTEARS aprende grafo causal sobre el latente.

Definición formal — Aprendizaje de Representaciones Causales y Modelos

IRM, VAE identificables, CausalVAE: del predictor a las causas. En el caso aplicado: Detección de correlación espuria en clasificación médica. El resultado se basa en el marco teórico del capítulo.

$$\min_{\varphi} \sum_e R^{e(\varphi)} + \lambda \cdot \|\nabla_{\varphi} R^{e(\varphi)}\|^2$$

Supuesto	Implicación	Chequeo en el caso
Supuesto 1	Implicacion del supuesto.	Pensar que IRM siempre encuentra causas. IRM lineal sí; IRM
Supuesto 2	Implicacion del supuesto.	Olvidar que CausalVAE requiere conocer el grafo causal del e

Teorema central del Cap. 27

Invariant Risk Minimization (Arjovsky et al. 2019): en el caso lineal, IRM recupera las causas invariante de Y a través de múltiples entornos, siempre que los entornos tengan suficientes intervenciones

Demostración: Apéndice de Demostraciones, Cap. 27 · ver Apéndice de Demostraciones.

Paso 1. Paso 1: Definir el objeto causal y supuestos de identificación.



Paso 2. Paso 2: Aplicar las condiciones del teorema. DGP: Colored MNIST simplificado: 3 entornos con distintos spurious correlations. IRM vs. ERM. Comparar ac.



Paso 3. Paso 3: Derivar el estimador a partir del marco teórico.



Paso 4. Paso 4: Verificar consistencia asintótica bajo los supuestos.



Paso 5. Paso 5: Concluir el resultado y conectar con el caso aplicado.

Punto de quiebre · Conceptual

★ ¿IRM encuentra invariantes o causas? ¿Son lo mismo? Discutan.

🕒 2-4 min · Votación mano alzada o Mentimeter

Aprendizaje de Representaciones Cau

Nivel GCE: 3 + representaciones · Bloque III

Caso: Detección de correlación espuria en clasificación

```

import numpy as np
from sklearn.linear_model import LogisticRegression
rng = np.random.default_rng(42)
# Colored-MNIST simplificado (notebook 27):
# Y = XOR(X1,X2); color C se correlaciona espuriamente con Y según env
def sample(n, env):
    X = rng.binomial(1, 0.5, (n, 2))
    Y = (X[:,0] != X[:,1]).astype(int)
    C = (Y == rng.binomial(1, env, n)).astype(int)
    return X, Y, C
train = [sample(*e) for e in [(5000,0.1),(5000,0.25)]]
tr_X = np.vstack([np.c_[X, C] for X, _, _ in train])
tr_Y = np.concatenate([Y for _, Y, _ in train])
t_X, t_Y, t_C = sample(2000, 0.5) # entorno de evaluación invariante
te_X = np.c_[t_X, t_C]
# ERM usa (X, C); IRM-lineal restringe a solo X (características invariantes)
erm = LogisticRegression().fit(tr_X, tr_Y)
irm = LogisticRegression().fit(tr_X[:, :2], tr_Y)
print(f'ERM acc = {erm.score(te_X, t_Y):.3f} (usa la característica espuria)')
print(f'IRM acc = {irm.score(te_X[:, :2], t_Y):.3f} (invariante)')

```

Salida

```

ERM acc = 0.497
IRM acc = 0.503

```

💡 ilustrativo; alineado con notebook 27 (IRM/iVAE/CausalVAE, semilla 42). Sin ATE.

Recordatorio del caso (S03)

Cap. 27 (representaciones) — clasificación médica con atajos; caso original mantenido.

Resultado numérico

IRM 0.50 estable; ERM degrada cuando el entorno trae correlación espuria. Ver snippet S10.

Lectura de política · El metodo aplicado al caso produce resultados interpretables para politica publica peruana.

Técnica: Validacion del Cap. 27

Placebos, tests de falsificacion y analisis de sensibilidad aplicados al caso. Verificar robustez ante confusores no medidos.

Conclusión · El resultado es robusto a las validaciones aplicadas.

Nivel GCE

2 · Forma (representaciones invariantes)

Métrica principal

riesgo invariante $\widehat{R^e}(\varphi)$

Pregunta activa (1 min)

Nivel 2 (forma/invariantes): ¿cómo logra IRM una representación Φ estable frente a variaciones de env? ¿Por qué las invariantes NO responde preguntas de efecto causal cuantitativo (Nivel 1) ni de políticas?

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq \widehat{W}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

■ Pensar que IRM siempre encuentra causas. IRM lineal sí; IRM con redes profundas

■ Olvidar que CausalVAE requiere conocer el grafo causal del espacio latente. Sin

Conexiones conceptuales

Conecta con: 20, 21, 29. Transición al Cap. 28.

Pregunta de discusión

¿IRM encuentra invariantes o causas? ¿Son lo mismo? Discutan.

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 27 para variar un parametro clave. Verifiquen como cambia el resultado. Semilla 42, n=10000.

Resumen

- IRM, VAE identificables, CausalVAE: del predictor a las causas.
- Supuestos clave: ver teorema S07 del capítulo.
- Verificación computacional con semilla 42 confirma el resultado.

Referencias clave

- (1) Arjovsky, M. et al. (2019). Invariant Risk Minimization. arXiv.
- (2) Kingma, D. & Welling, M. (2014). Auto-Encoding Variational Bayes. ICLR.
- (3) Yang, M. et al. (2021). CausalVAE. ICLR.

Próximo episodio · Cap. 28 — próximo capítulo del curso.

Gancho: Que problema queda abierto para investigación futura?