



■ previos · ■ actual · □ próximos

CAPÍTULO 28

Aprendizaje por Refuerzo Causal y Control Secuencial

Bloque IV · Nivel GCE: 1 · Localización secuencial (MDP + CMDP)

Variante: [sintesis-frontera](#)

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

1. Comprender: MDP causal, valor causal de una política, exploración informada.
2. Identificar supuestos y condiciones de identificación.
3. Verificar computacionalmente con Python semilla 42.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 28. Leer Cap. 28 del libro. Repasar MDP y ecuación de Bellman.

Notebook (pack): notebooks/Bloque_IV/
notebooks/28_aprendizaje_refuerzo_causal_control_secuencial.ipynb

Notebook (JB): jupyter_book/content/bloque_04_ia_causal/28_rl_causal.ipynb

Agenda

S01 · Motivacion y caso aplicado

S02 · Marco teorico y supuestos

S03 · Teorema central y demostracion

S04 · Implementacion Python

S05 · Caso aplicado y validacion

S06 · Mapeo GCE, errores y discusion

Problema

MDP causal, valor causal de una política, exploración informada.

Gancho empírico

Política dinámica de tratamiento médico en EsSalud: MDP causal modela la progresión de enfermedades crónicas (diabetes) y optimiza intervenciones secuenciales. La estructura causal del grafo guía la e

Caso del curso · Política dinámica de tratamiento médico con grafo causal conocido

Procesos de Decisión Markovianos Causale	CMDP: MDP con grafo causal G ; las transiciones $P(s' s, do(a))$ respetan la estructura causal; sustituye a $P(s' s, a)$.
Intervenciones, Políticas y Valor Causal	Una política π asigna acciones; su valor causal $V^{\pi}(s) = E[r + \gamma V^{\pi}(s') \mid do(a \sim \pi(s)), s]$ usa $do()$ en vez del condicional observacional.
Ecuación de Bellman Causal	$Q^{\pi}(s, a) = E[r + \gamma V^{\pi}(s') \mid do(a), s]$; sólo identifica el valor si se satisface ignorabilidad secuencial.
Ignorabilidad Secuencial	En cada paso t , $Y_t(a) \perp A_t \mid (H_{\bar{t}}, S_{\bar{t}})$ con $H_{\bar{t}}$ historial. Sin ella, $do()$ y $E[\cdot]$ no coinciden.
Ejemplos de RL Causal	Tratamiento médico dinámico, evaluación de políticas en sistemas de salud; necesaria estructura de CMDP para identificación causal.
Desafíos en Entornos Reales	Tamaño de estado grande, ignorabilidad débil, recompensas retardadas, equilibrio exploración-explotación causal.
Conexión con GCE	Level 1 secuencial: identidad de política $V(\pi)$ bajo do -condiciones relajados; sin 'teoremas' de-booked (no hay demostraciones formales en el libro para Cap. 28).

Definición formal — Aprendizaje por Refuerzo Causal y Control Secuenci

MDP causal, valor causal de una política, exploración informada. En el caso aplicado: Política dinámica de tratamiento médico con grafo causal conocido. El resultado se basa en el marco teórico del capítulo.

$$V^{\pi(s)} = E[r(s, a) + \gamma V^{\pi(s')} \mid \text{do}(a), s]$$

Supuesto	Implicación	Chequeo en el caso
Supuesto 1	Implicacion del supuesto.	Olvidar la diferencia entre MDP y CMDP (causal MDP). CMDP in
Supuesto 2	Implicacion del supuesto.	Pensar que RL causal siempre supera a RL clásico. Solo es su

Teorema central del Cap. 28

Ecuación de Bellman Causal (CMDP): bajo un MDP causal con grafo G , la función de valor de una política π satisface la recursión $V^\pi(s) = E[r + \gamma \dot{V}^\pi(s') \mid \text{do}(a \pi(s)), s]$ donde la transición

Paso 1. Paso 1: Definir el objeto causal y supuestos de identificación.



Paso 2. Paso 2: Aplicar las condiciones del teorema. CMDP con 3 estados y 2 acciones; grafo causal $S \rightarrow A \rightarrow R$, $S \rightarrow S'$. Comparar estimación observacional vs do-condicional bajo ignorabilidad secuencial (sin demostración formal en el libro).



Paso 3. Paso 3: Derivar el estimador a partir del marco teórico.



Paso 4. Paso 4: Verificar consistencia asintótica bajo los supuestos.



Paso 5. Paso 5: Concluir el resultado y conectar con el caso aplicado.

Punto de quiebre · Predictivo

★ Si el grafo causal cambia on-line, ¿conviene ϵ -greedy o Thompson Sampling?

🕒 6 min · Votación mano alzada o Mentimeter

Aprendizaje por Refuerzo Causal y C

Nivel GCE: 3 + secuencial · Bloque IV

Caso: Política dinámica de tratamiento médico con grafo

```

import numpy as np
rng = np.random.default_rng(42)
# CMDP de 3 estados, 2 acciones; grafo S -> A -> R, S -> S'
states = [0, 1, 2]
actions = [0, 1]
# Transición causal: P(S'+1 | S=s, do(A=a)) depende solo de a, NO de confounders
def transition(s, a):
    s_next = min(s + a, 2)          # do: intervención
    r = 1.0 if a == 1 else 0.0      # recompensa actual
    return s_next, r
# Estimar valor V(policy=greedy_a1) con 30 trayectorias
def run(eps=30, T=20):
    G = 0
    for _ in range(eps):
        s = 0
        for _ in range(T):
            a = 1                    # política greedy
            s, r = transition(s, a)  # == do(A=1)
            G += r
    return G / eps
V_do = run()
# Sin ignorabilidad secuencial: versión observacional con confounder no medido U
U = rng.normal(0, 1, 1000); A = (U > 0).astype(int)
R_obs = A + 0.5*U + rng.normal(0, 1, 1000)
V_obs_naive = R_obs[A==1].mean()
print(f'V(do A=1)      = {V_do:.3f}')
print(f'V_obs naive    = {V_obs_naive:.3f} (está sesgada sin ignorabilidad)')

```

Salida

```

V(do A=1)      = 20.000
V_obs naive    = 0.812 (está sesgada sin ignorabilidad)

```

💡 ilustrativo; alineado con notebook 28 (CMDP + ignorabilidad secuencial, semilla 42). Sin demostración formal en el libro.

Recordatorio del caso (S03)

Cap. 28 (RL causal) — política dinámica de tratamiento médico; caso original mantenido.

Resultado numérico

$V(\text{do } A=1)=20$ vs observacional sesgado $=0.81$ (ver S10). Sin demo formal en el libro.

Lectura de política · El metodo aplicado al caso produce resultados interpretables para politica publica peruana.

Técnica: Validacion del Cap. 28

Placebos, tests de falsificacion y analisis de sensibilidad aplicados al caso. Verificar robustez ante confusores no medidos.

Conclusión · El resultado es robusto a las validaciones aplicadas.

Nivel GCE

1 · Localización secuencial (MDP + CMDP)

Métrica principal

$V(\pi)$ / ignorabilidad secuencial

Pregunta activa (1 min)

Nivel 1 secuencial: ¿cómo identifica CMDP $V^{\pi}(s)$ bajo do(a) cuando hay confounders no medidos? ¿Por qué el RL clásico sesga sin ignorabilidad secuencial, y qué pregunta de forma (Nivel 2) no contesta este capítulo?

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq W^*(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

- Olvidar la diferencia entre MDP y CMDP (causal MDP). CMDP incluye restricciones
- Pensar que RL causal siempre supera a RL clásico. Solo es superior cuando la est

Conexiones conceptuales

Conecta con: 26, 30, 32. Transición al Cap. 29.

Pregunta de discusión

Si el grafo causal cambia on-line, ¿conviene ϵ -greedy o Thompson Sampling?

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 28 para variar un parametro clave. Verifiquen como cambia el resultado. Semilla 42, $n=10000$.

Resumen

- MDP causal, valor causal de una política, exploración informada.
- Supuestos clave: ver teorema S07 del capítulo.
- Verificación computacional con semilla 42 confirma el resultado.

Referencias clave

- (1) Sutton, R. & Barto, A. (2018). Reinforcement Learning. MIT Press.
- (2) Buesing, L. et al. (2019). Woulda, coulda, shoulda: Counterfactually-guided policy search. ICLR.
- (3) Lee, J. et al. (2020). Representing causal graphs with latent variables. NeurIPS.

Próximo episodio · Cap. 29 — próximo capítulo del curso.

Gancho: ¿Qué problema queda abierto para investigación futura?