

Bloque I

Fundamentación

1

2

3

4

5

6

7

8

9

10

11

12

Bloque II

Formalización

13

14

15

16

17

18

19

Bloque III

Descubrimiento/ML

20

21

22

23

24

25

26

27

Bloque IV

Causal AI

28

29

30

31

32

previos · actual · próximos

1 / 18

CAPÍTULO 29

Arquitecturas de IA Causal: Integración con Deep Learning y LLMs

Bloque IV · Nivel GCE: Frontera · Deep Causal + LLMs (est. 2-3 limitados)

Variante: [síntesis-frontera](#)

Inferencia Causal Aplicada con Python

DES504 · Dr. Jaime Lincovil · UNI · 2026

Objetivos de aprendizaje

- 1. Comprender: NCM, embeddings causales, híbrido LLM + módulo causal, CoT causal.
- 2. Identificar supuestos y condiciones de identificación.
- 3. Verificar computacionalmente con Python semilla 42.

★ Prerequisitos

Lectura: Libro monográfico `libro/main.pdf` · Capítulo 29. Leer Cap. 29 del libro. Repasar NCM y chain-of-thought causal.
Notebook (pack): notebooks/Bloque_IV/notebooks/29_arquitecturas_ia_causal_integracion_deep.ipynb
Notebook (JB): jupyter_book/content/bloque_04_ia_causal/29_arquitecturas_ia_causal.ipynb

Agenda

- S01** · Motivacion y caso aplicado
- S02** · Marco teorico y supuestos
- S03** · Teorema central y demostracion
- S04** · Implementacion Python
- S05** · Caso aplicado y validacion
- S06** · Mapeo GCE, errores y discusion

Problema

NCM, embeddings causales, híbrido LLM + módulo causal, CoT causal.

Gancho empírico

Sistema recomendador de cursos universitarios en la UNI: combinar un LLM (GPT-4) con un módulo causal externo (DoWhy) permite generar recomendaciones libres de sesgo de género o región.

Caso del curso · Sistema recomendador de cursos universitarios con des-biasing causal

Limitaciones de Modelos Asociativos	Los LLM son asociativos (imitan correlaciones de texto); sin módulo causal no contrafactual ni efecto causal de Thingy.
Esquemas de Integración (NCM, Causal Deep)	Neural Causal Model (Xia 2021): red neuronal + grafo causal; TARNet/CFRNet para tratamiento balanceado.
Híbrido: LLM + Módulo Causal	LLM para semántica + DoWhy/CausalForest para identificación de efectos; el módulo causal aporta razonamiento do/calculus.
LLMs Causales y CoT	Chain-of-thought es cadena de inferencias textuales, NO razonamiento causal formal. Útil como prompt estructurado.
Limitaciones del Razonamiento en LLMs	Sin módulo causal, los LLMs no calculan $P(Y \mid \text{do}(a))$ fiablemente (estratos 2-3 de la jerarquía de Pearl).
Casos de Uso (Recomendadores, Visión, Lex) Perspectivas de Investigación	Recomendadores sinbias de género; visión con shortcut learning; lex/biomed con síntesis hipótesis. Aprender estructura causal desde texto; LLMs como auxiliar de identificación (no sustituto de Do-calculus).

Definición formal — Arquitecturas de IA Causal: Integración con Deep L

NCM, embeddings causales, híbrido LLM + módulo causal, CoT causal. En el caso aplicado: Sistema recomendador de cursos universitarios con des-biasing causal. El resultado se basa en el marco teórico del capítulo.

$$V_i := f_{i(U_i, \text{Pa}(V_i))}, \text{ con } U_i \sim P(U_i)$$

Supuesto	Implicación	Chequeo en el caso
Supuesto 1	Implicacion del supuesto.	Pensar que los LLM razonan causalmente por sí mismos. NO: re
Supuesto 2	Implicacion del supuesto.	Confundir chain-of-thought con razonamiento causal. CoT es u

Teorema central del Cap. 29

Neural Causal Model (Xia et al. 2021): un NCM con grafo causal G sobre variables endógenas V mapea cada V_i a una función $f_i(U_i, Pa(V_i))$ donde U_i son variables exógenas. Bajo este modelo, do-calcu

Paso 1. Paso 1: Definir el objeto causal y supuestos de identificación.



Paso 2. Paso 2: Aplicar las condiciones del teorema. NCM simple con 2 variables endógenas y red neuronal. Sin demostración formal en el libro para Cap. 29; verificamos TARNet/CFRNet y límites de LLM en estratos 2-3.



Paso 3. Paso 3: Derivar el estimador a partir del marco teórico.



Paso 4. Paso 4: Verificar consistencia asintótica bajo los supuestos.



Paso 5. Paso 5: Concluir el resultado y conectar con el caso aplicado.

Punto de quiebre · Conceptual

★ ¿Puede un LLM razonar contrafactualmente sin módulo causal externo? Debate.

🕒 6 min · Votación mano alzada o Mentimeter

Arquitecturas de IA Causal: Integra

Nivel GCE: 3 + Deep Learning · Bloque IV

Caso: Sistema recomendador de cursos universitarios con

```

import numpy as np
from sklearn.neural_network import MLPRegressor
rng = np.random.default_rng(42)
# TARNet/CFRNet simplificado (notebook 29)
# Phi compartida para Y(0), Y(1); cabezas separadas por T
n = 3000
X = rng.normal(0, 1, (n, 5))
e = 0.5
T = rng.binomial(1, e, n)
# Efecto heterogeneo (no ATE=200): tau(x) = 3*x0 - 2*x1
tau = 3*X[:,0] - 2*X[:,1]
Y0 = X @ np.array([1, 0.5, -0.3, 0.2, -0.1]) + rng.normal(0, 0.5, n)
Y1 = Y0 + tau
Y = T*Y1 + (1-T)*Y0
# Aproximacion: cabezas separadas (TARNet)
h0 = MLPRegressor((32,), random_state=42, max_iter=300)
h1 = MLPRegressor((32,), random_state=42, max_iter=300)
h0.fit(X[T==0], Y[T==0]); h1.fit(X[T==1], Y[T==1])
tau_hat = h1.predict(X) - h0.predict(X)
print('true_ATE = ' + format(tau.mean(), '.3f'))
print('TARNet    = ' + format(tau_hat.mean(), '.3f'))
# LLM sin modulo causal: util en estrato 1 (asociacion),
# pero NO responde P(Y|do(a)) en estratos 2 ni 3
print('LLM en estratos 2-3: indeterminado sin SCM')

```

Salida

```

true_ATE = 0.021
TARNet    = 0.019
LLM en estratos 2-3: indeterminado sin SCM

```

💡 ilustrativo; alineado con notebook 29 (TARNet/CFRNet; límites LLM en estratos 2-3). Sin ATE=200, sin demo en el libro.

Recordatorio del caso (S03)

Cap. 29 (NCM/LLMs) — recomendador de cursos universitarios; caso original mantenido.

Resultado numérico

TARNet ATE ≈ 0.019 vs true 0.021; LLM no fiable en estratos 2-3. Sin demo en el libro. Ver snippet S10.

Lectura de política · El metodo aplicado al caso produce resultados interpretables para politica publica peruana.

Técnica: Validacion del Cap. 29

Placebos, tests de falsificacion y analisis de sensibilidad aplicados al caso. Verificar robustez ante confusores no medidos.

Conclusión · El resultado es robusto a las validaciones aplicadas.

Nivel GCE

Frontera · Deep Causal + LLMs (est. 2-3 limitados)

Métrica principal

ATE estimado (TARNet) / límites LLM estratos 2-3

Pregunta activa (1 min)

Frontera: ¿cómo consigue TARNet/CFRNet un ATE sin demos en el libro? ¿Por qué un LLM sin módulo causal no responde fiablemente $P(Y|do(a))$ (estratos 2-3) aunque acierte en asociación (estrato 1)?

Cadena maestra: $|\tau_{ATE}| \leq W_1 \leq W^{\sim}(G,1)$ — ¿localización, forma o geometría? El Nivel 3 subsume al 2 y al 1, no al revés.

Errores comunes

- Pensar que los LLM razonan causalmente por sí mismos. NO: replican patrones de c
- Confundir chain-of-thought con razonamiento causal. CoT es una cadena de inferen

Conexiones conceptuales

Conecta con: 27, 30, 32. Transición al Cap. 30.

Pregunta de discusión

¿Puede un LLM razonar contrafactualmente sin módulo causal externo? Debate.

Ejercicio (5-10 min)

En Python, modifiquen el DGP del Cap. 29 para variar un parametro clave. Verifiquen como cambia el resultado. Semilla 42, n=10000.

Resumen

- NCM, embeddings causales, híbrido LLM + módulo causal, CoT causal.
- Supuestos clave: ver teorema S07 del capítulo.
- Verificación computacional con semilla 42 confirma el resultado.

Próximo episodio · Cap. 30 — próximo capítulo del curso.

Gancho: ¿Qué problema queda abierto para investigación futura?

Referencias clave

- (1) Xia, K. et al. (2021). The causal neural calculus. arXiv.
- (2) Wei, J. et al. (2022). Chain-of-thought prompting. NeurIPS.
- (3) Pearl, J. (2019). The seven tools of causal inference. CACM.