

Guía de Proyectos de Semestre Inferencia Causal Aplicada con Python

Curso de Maestría — Semestre 2026-I

Dr. Jaime Lincovil Curivil

jlincovilc@uni.edu.pe

Abril 2026

Versión revisada — incorpora la Categoría 5 (Cartografía y Meta-Investigación Causal) y una rúbrica de evaluación adaptada a cada etapa, con bandas de desempeño y ponderación explícita por dimensión.

Índice

Nota preliminar	2
1 Criterio de Selección de Proyecto	2
2 Cronograma y Fechas de Entrega	2
3 Rúbrica de Evaluación (Escala 0–20)	3
3.1 Rúbrica — Etapa 1 (Planificación)	3
3.2 Rúbrica — Etapa 2 (Ejecución Primaria)	5
3.3 Rúbrica — Etapa 3 (Finalización)	6
4 Propuestas por Categoría	8
4.1 Categoría 1: Proyectos Teórico-Matemáticos	8
4.2 Categoría 2: Proyectos de Algoritmos (ML / Deep Learning / Descubrimiento)	9
4.3 Categoría 3: Aplicación a Datasets Benchmark	10
4.4 Categoría 4: Replicación de Agentes Causales	11
4.5 Categoría 5: Cartografía y Meta-Investigación Causal	12
5 Especificaciones de Entregables por Etapa	14
5.1 Etapa 1 — Planificación (20%)	14
5.2 Etapa 2 — Ejecución Primaria (30%)	15
5.3 Etapa 3 — Finalización (50%)	15
6 Bibliografía de Referencia Universal	15
6.1 Textos principales	15
6.2 Métodos y algoritmos	15
6.3 Sensibilidad y equidad	16
6.4 Transporte óptimo e IA causal	16
6.5 Referencias adicionales por propuesta	17
6.6 Herramientas y referencias metodológicas — Categoría 5 (NUEVA)	18

Nota preliminar

El proyecto de semestre es la evaluación central del curso. Representa una investigación aplicada de nivel maestría que integra los cuatro bloques temáticos: fundamentos de la Jerarquía GCE, modelos causales estructurales, aprendizaje automático causal y Causal AI. Se espera que cada proyecto evidencie dominio simultáneo de teoría formal, implementación profesional en Python y validación epistémica rigurosa.

La filosofía pedagógica Proofs-to-Python exige que cada resultado teórico se acompañe de verificación computacional reproducible. El uso de herramientas de inteligencia artificial está permitido, pero debe declararse explícitamente y, lo que es más importante, el estudiante debe comprender y poder explicar todo lo que entrega.

1 Criterio de Selección de Proyecto

Los estudiantes seleccionarán una propuesta de entre las disponibles (6 por categoría, salvo la Categoría 5 — ver §4.5), siguiendo la guía de perfil que se presenta en el Cuadro 1. La elección debe ser realista respecto a la formación previa y al tiempo disponible.

Cuadro 1: Guía de selección de proyecto por categoría y perfil

Categoría	Perfil recomendado	Productos principales
Cat. 1 — Teórico-Matemático	Matemáticos, estadísticos con base en análisis funcional y probabilidad medible	Monografía 30–50 pp + notebook verificador
Cat. 2 — Algoritmos ML/DL	Científicos de datos, ingenieros ML con experiencia en PyTorch/scikit-learn	Pipeline completo + benchmark riguroso + reporte técnico
Cat. 3 — Datasets Benchmark	Economistas, epidemiólogos, analistas de políticas públicas	Análisis causal publicable + notebook reproducible
Cat. 4 — Agentes Causales	Ingenieros de IA, desarrolladores de sistemas inteligentes locales	Sistema funcional ejecutable + evaluación causal + reporte
Cat. 5 — Cartografía y Meta-Investigación Causal (NUEVA)	Ciencia de datos aplicada / bibliometría / economistas con interés en ciencia de la ciencia	Corpus reproducible + taxonomía o estimación causal + informe interpretativo

La selección debe comunicarse al docente antes del fin de la semana 1 de mayo de 2026. Se permite un solo cambio de propuesta hasta la primera semana de mayo, previa justificación escrita que explique por qué el proyecto original no es viable.

2 Cronograma y Fechas de Entrega

El proyecto se desarrolla en tres etapas con las fechas límite que se indican en el Cuadro 2.

Cuadro 2: Cronograma de entregas

Etapas	Entregable	Fecha límite	Pond.
1 — Planificación	Propuesta formal: pregunta causal, DAG justificado, estrategia de identificación, plan de datos, código esqueleto	Viernes 15 de mayo de 2026, 23:59 (hora Lima)	20%

Etapa	Entregable	Fecha límite	Pond.
2 — Ejecución Primaria	Implementación parcial: estimación inicial, validación de supuestos, sensibilidad preliminar y reporte intermedio	Viernes 26 de junio de 2026, 23:59 (hora Lima)	30%
3 — Finalización	Proyecto completo: estimación robusta, sensibilidad exhaustiva, interpretación contextual, notebook reproducible e informe en L ^A T _E X	Viernes 24 de julio de 2026, 23:59 (hora Lima)	50%

Condiciones de continuidad:

- Se requiere nota $\geq 10/20$ en la Etapa 1 para presentar la Etapa 2.
- La no entrega de la Etapa 3 implica desaprobación del curso, independientemente de las notas previas.

Las fechas límite son estrictas. Las entregas posteriores al plazo no serán evaluadas salvo casos excepcionales debidamente justificados con anticipación.

3 Rúbrica de Evaluación (Escala 0–20)

Cada etapa se evalúa sobre 8 dimensiones. A diferencia de una rúbrica única aplicada sin cambios a las tres entregas, cada etapa tiene su propio descriptor por dimensión — calibrado a lo que esa etapa efectivamente exige — y su propia ponderación, además de bandas de desempeño intermedias (no solo el máximo). La nota de la etapa se calcula como la suma ponderada de los puntajes por dimensión:

$$\text{Nota}_{\text{etapa}} = \sum_i \text{peso}_i \times \text{puntaje}_i, \quad \text{puntaje}_i \in [0, 20]$$

Esa nota de etapa es luego la que se pondera según el Cuadro 2 (20% / 30% / 50%) para la nota final del curso.

Nota metodológica: para los proyectos de Categoría 5 (ver §4.5), las dimensiones “Identificación” y “Validación y sensibilidad” deben reinterpretarse cuando el proyecto elegido sea de tipo taxonómico/bibliométrico (Opción 1) — allí equivalen, respectivamente, al rigor del esquema de codificación y a la validación cruzada del modelo de tópicos. Cuando el proyecto sea de estimación causal reflexiva (Opción 2), la rúbrica se aplica sin modificaciones.

3.1 Rúbrica — Etapa 1 (Planificación)

Dimensión	Peso 0–5	6–10	11–15	16–20
Formulación causal	20% Pregunta causal ausente, ambigua, o no distinguible de una pregunta puramente asociativa.	Se menciona un nivel GCE o estimando sin definición formal ni justificación.	Nivel GCE y estimando identificados pero con justificación teórica incompleta.	Pregunta ubicada explícitamente en Nivel 1/2/3 GCE; estimando (ATE, LATE, CATE, NDE u otro) formalmente definido y justificado.

Dimensión	Peso	0–5	6–10	11–15	16–20
Especificación del DAG	20%	DAG ausente, incoherente, o no acorde a la pregunta causal planteada.	DAG presente pero con aristas sin sustento teórico claro o variables relevantes ausentes.	DAG presente y mayormente justificado, con vacíos menores en confusores o en el plan de validación.	DAG completo; aristas justificadas por teoría o diseño; confusores obs./no obs. documentados; validación de d-separación planificada (pgmpy).
Identificación	20%	No hay estrategia de identificación o es incompatible con el DAG propuesto.	Se nombra un criterio de identificación sin aplicarlo al caso concreto.	Estrategia mencionada y parcialmente desarrollada, con pasos algebraicos incompletos.	Backdoor, frontdoor o IV aplicado paso a paso con demostración algebraica preliminar; conjunto de ajuste o instrumento propuesto y justificado.
Implementación (código esqueleto)	15%	Código esqueleto ausente o no ejecutable.	Código esqueleto mínimo, poco estructurado o sin documentación.	Código esqueleto presente y funcional, con modularidad o documentación parcial.	Estructura de carpetas y funciones principales con docstrings; pipeline esquematizado de forma modular y ejecutable.
Validación y sensibilidad (plan)	10%	No hay plan de validación ni de sensibilidad.	Plan genérico, no vinculado a los supuestos específicos del proyecto.	El plan menciona pruebas de robustez pertinentes sin justificar por qué son las más adecuadas.	El plan identifica con precisión los supuestos más frágiles (overlap, CIA, faithfulness) y qué pruebas se aplicarán en E2/E3, con justificación teórica.
Interpretación (esperada)	5%	No hay anticipación de resultados ni de su interpretación.	Mención superficial de qué se espera encontrar.	Se anticipa el tipo de resultado esperado sin discutir su interpretación.	Se anticipa con claridad la forma de los resultados esperados y cómo se distinguirá significancia estadística de relevancia práctica.
Originalidad y contexto	5%	No se discute relevancia ni motivación aplicada.	Motivación genérica, sin anclaje al contexto regional.	Relevancia regional mencionada pero poco desarrollada.	El problema es claramente relevante para Latinoamérica/Perú, con motivación aplicada bien argumentada.

Dimensión	Peso	0–5	6–10	11–15	16–20
Transparencia y ética	5%	No hay declaración de fuente de datos ni de uso de IA.	Mención genérica de datos o de IA sin detalle.	Fuente de datos identificada; declaración de IA incompleta.	Fuente de datos, plan de acceso y limitaciones de medición identificadas; declaración preliminar del uso de IA en el desarrollo del plan.

3.2 Rúbrica — Etapa 2 (Ejecución Primaria)

Dimensión	Peso	0–5	6–10	11–15	16–20
Formulación causal	8%	La formulación es incoherente con el resto del proyecto.	La formulación cambió sin justificación o presenta inconsistencias con el DAG/identificación.	Coherencia parcial con la Etapa 1, sin justificar los ajustes realizados.	La pregunta y el estimando se mantienen coherentes con la Etapa 1, o se ajustan con justificación explícita ante hallazgos nuevos.
Especificación del DAG	10%	DAG abandonado o contradicho por la implementación sin explicación.	DAG con inconsistencias menores respecto a los datos observados.	DAG estable pero sin evidencia empírica que lo respalde.	El DAG se mantiene o se refina con evidencia empírica preliminar (ej. tests de independencia), documentando cualquier cambio.
Identificación	12%	La identificación no se aplica o es incompatible con el estimador usado.	Aplicación incompleta o con errores algebraicos menores.	Estrategia aplicada con vacíos menores en la validación empírica.	Estrategia aplicada correctamente sobre datos reales/sintéticos; conjunto de ajuste o instrumento validado empíricamente donde es posible.
Implementación	20%	Código no ejecutable o ausente.	Código parcialmente funcional, con errores no resueltos o sin comentarios.	Código funcional con documentación o control de semillas incompleto.	Notebook v0.3 funcional, comentado, con ≥ 1 estimador implementado, <code>random_state</code> documentado y manejo básico de errores.

Dimensión	Peso	0–5	6–10	11–15	16–20
Validación y sensibilidad	20%	No hay validación de supuestos ni prueba de sensibilidad.	Validación superficial, sin prueba de sensibilidad ejecutada.	Validación de supuestos parcial o prueba de sensibilidad reportada sin interpretación completa.	Se valida overlap/CIA/faithfulness según corresponda y se reporta ≥ 1 de las 3 pruebas exigidas en E3, interpretada correctamente.
Interpretación	10%	No hay interpretación de los resultados obtenidos.	Resultados reportados sin interpretación sustantiva.	Interpretación presente pero sin advertir el carácter preliminar de los resultados.	Los resultados preliminares se interpretan con cautela explícita sobre su carácter provisional.
Originalidad y contexto (análisis de fallos)	10%	No hay análisis de fallos.	Análisis de fallos genérico o superficial.	Se identifican problemas sin plan de resolución claro.	El análisis de fallos identifica problemas concretos del caso de estudio y propone un plan de resolución fundamentado.
Transparencia y ética	10%	No hay declaración de uso de IA en esta etapa.	Declaración de IA incompleta o inconsistente con el código entregado.	Declaración de IA presente pero genérica.	Declaración de IA actualizada y coherente con el trabajo de esta etapa; limitaciones de datos identificadas con evidencia.

3.3 Rúbrica — Etapa 3 (Finalización)

Dimensión	Peso	0–5	6–10	11–15	16–20
Formulación causal	12%	La pregunta causal no está definida o es incoherente con el resto del proyecto.	Nivel GCE mencionado sin justificación teórica del estimando.	Nivel y estimando definidos, justificación parcial.	La pregunta causal está explícitamente ubicada en Nivel 1/2/3 GCE; el estimando (ATE, LATE, CATE o NDE) está formalmente definido y justificado teóricamente.

Dimensión	Peso	0–5	6–10	11–15	16–20
Especificación del DAG	13%	DAG ausente o incompatible con el análisis final.	DAG presente, aristas sin sustento teórico o confusores no documentados.	DAG justificado, confusores documentados parcialmente.	El DAG incluye todas las variables relevantes; aristas ausentes o presentes justificadas por teoría o diseño; confusores obs. o no obs. documentados; se valida d-separación.
Identificación	13%	Sin estrategia de identificación demostrada.	Criterio mencionado sin demostración algebraica.	Identificabilidad demostrada con vacíos menores.	Se demuestra algebraicamente la identificabilidad del estimando; se especifica el conjunto de ajuste mínimo o instrumento válido; se discuten limitaciones de validez externa.
Implementación	13%	Código no reproducible.	Código funcional, poco modular.	Modular y reproducible, con vacíos menores de control de semillas.	El notebook es modular, reproducible y usa librerías apropiadas (DoWhy, EconML, causal-learn); incluye cross-fitting, manejo de missing y control de semillas (<code>random_state</code> documentado).
Validación y sensibilidad	15%	Sin pruebas de robustez.	1 prueba, sin interpretación completa.	2 pruebas interpretadas.	Se reportan al menos 3 pruebas: placebo (variable/umbral/falso), E-value o Γ de Rosenbaum, y estrés distribucional; se interpretan los umbrales de colapso.
Interpretación	12%	Resultados sin incertidumbre reportada.	IC reportado sin discusión.	Distingue significancia/relevancia con vacíos menores.	Los efectos se reportan con IC al 95%; se distingue entre significancia estadística y relevancia práctica; se discuten limitaciones sin sobreinterpretar.

Dimensión	Peso	0–5	6–10	11–15	16–20
Originalidad y contexto	12%	Sin relevancia regional ni aporte aplicado.	Mención superficial.	Aporte aplicado parcial.	El proyecto aborda un problema relevante para Latinoamérica/Perú; incorpora conocimiento de dominio y propone implicancias de política o negocio.
Transparencia y ética	10%	Sin declaración de fuentes, supuestos o uso de IA.	Declaración incompleta.	Declaración completa, sesgos no discutidos.	Se declara la fuente de datos, limitaciones de medición, posibles sesgos éticos y el rol de herramientas de IA en el desarrollo; se adjunta licencia de uso.

4 Propuestas por Categoría

4.1 Categoría 1: Proyectos Teórico-Matemáticos

Estos proyectos requieren reconstrucción formal de demostraciones, extensión teórica, verificación computacional Proofs-to-Python, y un monográfico de 30–50 páginas más notebook reproducible. Perfil: matemáticos y estadísticos con base en análisis funcional y probabilidad medible.

Cuadro 3: Propuestas de la Categoría 1

#	Título	Núcleo teórico	Entregables por etapa	Nivel	Refs. clave
1	Cotas semi-paramétricas para CATE bajo nuisance de alta dimensión	Derivar EIF para $\tau(x)$. Probar linealización asintótica bajo cross-fitting. Establecer tasas de convergencia $n^{-1/2}$ con modelos ML. Comparar eficiencia AIPW vs DML vs R-Learner.	E1: Formulación + espacio tangente + plan de simulación. E2: Derivación EIF + código de verificación de tasas. E3: Monográfico + notebook + análisis de misspecification.	Alto	Hahn (1998); Chernozhukov et al. (2018); Kennedy (2023); van der Vaart (1998)
2	Identificación geométrica vía transporte bicausal $W_{G,1}$	Formalizar acoplamientos bicausales que respetan filtración DAG. Probar dualidad Kantorovich-Rubinstein bajo restricciones causales. Demostrar continuidad Lipschitz de ATE/CATE.	E1: Definiciones + axiomas + DGP sintético. E2: Demostración dualidad + implementación POT. E3: Teorema de completitud geométrica + validación numérica.	Muy Alto*	Cheridito & Eckstein (2025); Villani (2009); Backhoff-Veraguas et al. (2020)

#	Título	Núcleo teórico	Entregables por etapa	Nivel	Refs. clave
3	Unificación de sensibilidad causal: Manski, Rosenbaum y E-value bajo restricciones f -divergencia	Definir conjunto de confusión no observada vía D_f -divergencia. Derivar cotas sharp para ATE. Conectar formalmente con Γ de Rosenbaum y E-value.	E1: Marco axiomático + plan de solver. E2: Derivación de cotas + código de regiones de identificación. E3: Teorema de unificación + estrés en ACIC/IHDP.	Alto	Manski (2003); Rosenbaum (2002); VanderWeele & Ding (2017); Dorn et al. (2021)
4	Complejidad del do-calculus y algoritmo ID en modelos semi-markovianos	Reconstruir prueba de completitud (hedge criterion). Extender a ADMGs con sesgo de selección. Implementar verificador formal en Python.	E1: DAGs/ADMGs + reglas do-calculus + plan de verificador. E2: Demostración hedge + código ID. E3: Teorema de completitud + benchmark en grafos complejos.	Alto	Pearl (2009) Cap. 3–4; Shpitser & Pearl (2006); Bareinboim & Pearl (2016)
5	Teoría asintótica de causal forests e inferencia honesta	Probar consistencia y normalidad asintótica bajo honestidad y subsampling. Derivar descomposición bias-variance. Probar consistencia del infinitesimal jackknife para IC.	E1: Marco teórico + DGP heterogéneo. E2: Demostración linealización + código de cobertura. E3: Teorema de normalidad + comparación DML vs CF.	Alto	Wager & Athey (2018); Athey et al. (2019); Meinshausen (2006)
6	Fundamentos axiomáticos y geométricos de la equidad contrafactual	Formalizar fairness contrafactual vía efectos path-specific. Probar identificabilidad bajo DAGs con atributo sensible. Derivar cotas W_1 entre políticas justas/injustas.	E1: SCM sensible + axiomas de fairness. E2: Identificación NDE/NIE + código de transporte. E3: Teorema de cota geométrica + auditoría ética.	Alto	Kusner et al. (2017); Chiappa (2019); Pearl (2001); Pleiss et al. (2017)

**La propuesta #2 tiene dificultad equivalente a nivel doctoral. Su selección requiere autorización expresa del docente antes del 30 de abril de 2026, mediante solicitud escrita que fundamente la preparación del estudiante para abordarla. Dado el mayor riesgo de identificación incompleta al cierre del semestre, se recomienda aplicar el ajuste de dificultad descrito en el §3 (bonus de hasta +2 pts sobre la nota de Etapa 3, o recalibración de expectativas) para no desincentivar su elección.*

4.2 Categoría 2: Proyectos de Algoritmos (ML / Deep Learning / Descubrimiento)

Pipeline completo de investigación aplicada: diseño algorítmico, implementación modular, benchmarking riguroso, validación de supuestos GCE y análisis de fallos. Perfil: científicos de datos e ingenieros ML.

Cuadro 4: Propuestas de la Categoría 2

#	Título	Arquitectura y pipeline	Validación y métricas	Referencias
1	Descubrimiento estructural + estimación heterogénea bajo confusión latente	FCI/NOTEARS → ADMG → identificación backdoor/frontdoor → DML/CATE → política $\pi^*(x)$. Manejo explícito de latentes y selection bias.	SHD/SID, PEHE, QINI, sensibilidad a faithfulness, placebo en covariables, estrés de overlap.	Spirtes et al. (2000); Zheng et al. (2018); Chernozhukov et al. (2018); Athey & Wager (2021)
2	IRM + causal representation learning para generalización OOD	CausalVAE/IRM → representaciones invariantes → head CATE → evaluación en shifts distribucionales. Regularización Wasserstein.	Invariancia empírica, PEHE OOD, ablación de correlaciones espurias, W_1 entre entornos.	Arjovsky et al. (2019); Peters et al. (2016); Yang et al. (2021); Schölkopf et al. (2021)
3	DML para paneles con adopción escalonada y confusión dinámica	Extensión DML a DiD/SynC con tratamientos heterogéneos en tiempo. Cross-fitting temporal. Estimación de $ATT(g, t)$.	Goodman-Bacon decomp., placebo temporal, cobertura IC, robustez a violaciones de parallel trends.	Chernozhukov et al. (2018); Callaway & Sant'Anna (2021); Sun & Abraham (2021); Roth et al. (2023)
4	Neural causal models para inferencia contrafactual continua	SCM parametrizado por NNs → abduction-action-prediction → estimación PN/PS/PNS → validación contra SCM ground-truth.	CF-MSE, cobertura PN/PS, sensibilidad a priores latentes, comparación con SEM lineales.	Pawlowski et al. (2020); Xia et al. (2022); Pearl (2009) Cap. 7
5	RL causal con exploración informada por estructura (CMDP)	Aprendizaje de grafo de transiciones → Bellman causal $Q(s, do(a))$ → bonus de exploración por incertidumbre causal → comparación con model-free.	Regret causal, eficiencia muestral, recuperación de grafo, robustez a rewards espurios.	Zhang & Bareinboim (2020); Lu et al. (2021); Sutton & Barto (2018)
6	Pipeline automatizado: LLM + verificador DAG + do-calculus + estimación	LLM local propone DAG → verificador pgmpy/DoWhy → solver do-calculus → AIPW/DML → reporte de sensibilidad. Chain-of-thought con validación formal.	Tasa de DAG válidos, éxito de identificación, sesgo estimación, hallucination rate, transparencia.	Kiciman et al. (2023); Jin et al. (2023); Pearl (2009)

Nota de actualización (2026): la propuesta #6 especificaba originalmente un modelo local vía Llama3/Mistral. El panorama de modelos abiertos de peso disponible cambia con frecuencia; se recomienda dejar la elección de modelo abierta (“modelo local vía Ollama/vLLM, p. ej. familia Qwen, Llama, DeepSeek, Gemma o Mistral según hardware disponible”) en vez de fijar un nombre específico, y documentar en el reporte qué modelo y versión exacta se usó.

4.3 Categoría 3: Aplicación a Datasets Benchmark

Pipeline unificado en profundidad (alineado con caps. 3–11 y 24–25 del sílabo): descubrimiento/justificación DAG → identificación algebraica → estimación multi-nivel GCE → validación exhaustiva (≥ 3 pruebas) → decisión/política. Nivel publicación académica.

Cuadro 5: Propuestas de la Categoría 3

#	Dataset / Contexto	Pregunta causal y nivel GCE	Pipeline metodológico	Validación y sensibilidad
1	IHDP	CATE de visitas domiciliarias sobre desarrollo cognitivo. Nivel 1 y 3.	DAG literatura → backdoor → DML/Causal Forest/X-Learner → W_1 geométrico → targeting óptimo.	PEHE, QINI, calibración, E-value, placebo en covariables, estrés de overlap.
2	ACIC 2018	¿Qué estimadores recuperan ATE/CATE bajo confusión no lineal y alta dimensión? Nivel 1 y 2.	Descubrimiento automático → identificación → AIPW, TMLE, DML o Metalearners → taxonomía de fallos.	Ground truth comparison, cobertura IC, bias-variance, Γ de Rosenbaum, análisis de misspecification.
3	Twins	Efecto de bajo peso al nacer en mortalidad infantil con confusión no observada. Nivel 1 + sensibilidad.	DAG con U latente → frontdoor/IV → matching/IPW/AIPW → cotas Manski → E-value/Rosenbaum.	Balance estandarizado, ancho de cotas, curvas de sensibilidad, pruebas de falsificación.
4	LaLonde / NSW	¿Pueden métodos observacionales replicar resultados de RCT de capacitación laboral? Nivel 1 y 3.	DAG → backdoor → AIPW/DiD/SynC → W_1 pre/post → descomposición Goodman-Bacon → placebo temporal.	Comparación con LaLonde (1986) y Dehejia & Wahba (1999), overlap, robustez a parallel trends.
5	STAR (Class Size)	¿La reducción de clase afecta toda la distribución de logro académico? Nivel 2 y 3.	RCT → QTE → divergencias D_f → costo → análisis por subgrupos → política de targeting.	Chequeo de aleatorización, cobertura cuantílica, interpretación geométrica, relevancia práctica.
6	COMPAS / Adult-like sintético	¿Cuánta disparidad racial/de género es causalmente atribuible a caminos ilícitos? Nivel 2 + equidad.	DAG con atributo sensible → path-specific effects → fairness contrafactual → W_1 disparidad → política mitigadora.	Descomposición NDE/NIE, métricas de fairness, costo de debiasing, auditoría ética.

Nota de actualización (2026): además de los seis datasets clásicos anteriores, existen benchmarks recientes que pueden ofrecerse como alternativa u opción #7 — por ejemplo, un benchmark a gran escala de inferencia de redes a partir de datos de perturbación de célula única (Chevalley et al., 2025, Communications Biology), o cámaras causales como banco de pruebas físico real con ground truth conocido (Gamella, Peters & Bühlmann, 2025, Nature Machine Intelligence).

4.4 Categoría 4: Replicación de Agentes Causales

Sistema funcional ejecutable en CPU/GPU moderada. Requiere módulo de razonamiento causal explícito, entorno de interacción, métricas de desempeño causal y reporte de limitaciones epistémicas/éticas. Perfil: ingenieros de IA y desarrolladores.

Cuadro 6: Propuestas de la Categoría 4

#	Agente	Arquitectura causal	Stack local	Métricas	Referencias
1	Causal contextual bandit	DAG de contexto $\rightarrow$ CATE $\rightarrow$ política ε -greedy/UCB basada en $\hat{\tau}(x)$. Selección de brazos vía intervención $\text{do}(a)$.	DoWhy + gym + numpy + env custom. CPU.	Regret causal, sample efficiency, robustez a grafo erróneo vs bandit clásico.	Lattimore et al. (2016); Bareinboim et al. (2022)
2	Agente OPE doubly robust	Datos históricos $\pi_b \rightarrow$ DR-OPE $\rightarrow$ evaluación $\pi_e \rightarrow$ umbral de despliegue seguro.	d3rlpy/custom + EconML + env bandit/RL. Local.	MSE de valor, cobertura IC, fallo bajo positividad violada.	Dudík et al. (2014); Jiang & Li (2016); Thomas et al. (2015)
3	NCM agent para contrafactuales individuales	SCM con NNs $\rightarrow$ abduction $\rightarrow$ action $\rightarrow$ prediction $\rightarrow$ consultas PN/PS/PNS.	PyTorch + pyro/numpyro + loop custom. CPU/GPU moderada.	CF-MSE, calibración PN/PS, sensibilidad a priores.	Xia et al. (2022); Pawlowski et al. (2020); Pearl (2009) Cap. 7
4	LLM + motor causal local	LLM (vía ollama) $\rightarrow$ DAG $\rightarrow$ verificador pgmpy $\rightarrow$ do-calculus $\rightarrow$ AIPW $\rightarrow$ reporte.	ollama + DoWhy + pgmpy + orquestador Python. Local.	Tasa DAG válidos, éxito identificación, hallucination rate.	Kiciman et al. (2023); Jin et al. (2023)
5	Causal RL con exploración estructural (CMDP)	Learner de grafo $\rightarrow$ Bellman causal $Q(s, \text{do}(a)) \rightarrow$ bonus por incertidumbre causal $\rightarrow$ policy update.	stable-baselines3 + env custom + networkx/causal-learn. Local.	Reward acumulado, sample efficiency, precisión de grafo.	Zhang & Bareinboim (2020); Lu et al. (2021)
6	Agente de decisión con equidad contrafactual	DAG con atributo sensible $\rightarrow$ estimador path-specific $\rightarrow$ optimizador con cota W_1 de disparidad.	DoWhy + EconML + POT + optimizador custom. Local.	Utilidad vs W_1 , descomposición NDE/NIE, auditoría ética.	Kusner et al. (2017); Chiappa (2019); Pleiss et al. (2017)

Nota de actualización (2026): igual que en la propuesta #6 de Categoría 2, la propuesta #4 (“LLM local”) debe especificarse con la familia de modelos abierta y no atada a una versión fija; documentar VRAM mínima recomendada según el tamaño de modelo elegido (orientativamente: ~ 8 GB VRAM para modelos $\leq 8B$ cuantizados, 16–24 GB para modelos $\sim 30B$, 40 GB+ para modelos de gama alta), y ofrecer alternativa en la nube para quienes no cuenten con GPU adecuada.

4.5 Categoría 5: Cartografía y Meta-Investigación Causal

Estos proyectos toman como objeto de estudio la propia producción científica en inferencia causal, documentada en canales de seminarios en video. Exigen construir un corpus reproducible (vía API, no scraping manual ad hoc), un esquema de codificación o de identificación causal explícito y justificado, y un producto de investigación verificable. No sustituyen el rigor de las demás categorías: lo trasladan del análisis de un dataset causal al análisis de la comunidad que produce esos datasets. Perfil: científicos de datos con interés en NLP/bibliometría, o economistas y analistas de política interesados en ciencia de la ciencia.

Fuentes primarias sugeridas:

- **CAUSALab** (Harvard T.H. Chan School of Public Health): <https://www.youtube.com/@CAUSALab>
- **Online Causal Inference Seminar** (con apoyo del Departamento de Estadística de Stanford): <https://www.youtube.com/@onlinecausalinferencesemin2364>
- **CausalAI** (Causal Artificial Intelligence Lab, Columbia University): <https://www.youtube.com/@CausalAI> — véase también <https://causalai.net>

Pueden incorporarse canales adicionales si el estudiante los justifica.

Cuadro 7: Propuestas de la Categoría 5

#	Título	Núcleo metodológico	Entregables por etapa	Nivel
1	Cartografía temática y taxonomía GCE de tres tradiciones causales	Corpus vía YouTube Data API + transcripciones (yt-dlp) de los canales CAUSALab (Harvard T.H. Chan), Online Causal Inference Seminar (Stanford) y CausalAI (Columbia) → codificación manual de una muestra estratificada (nivel GCE 1/2/3, estrategia de identificación mencionada, tradición metodológica —resultados potenciales / SCM-do-calculus / ML causal—, dominio de aplicación, país e institución del expositor) con confiabilidad inter-codificador (κ de Cohen) → modelado de tópicos (BERTopic/LDA) sobre el corpus completo, validado contra la codificación manual → red de coocurrencia autor-institución-tema.	E1: pipeline de scraping funcional sobre muestra piloto (≥ 30 videos) + Alto codebook con definiciones operacionales de cada eje + justificación teórica del esquema (por qué estos ejes y no otros) + plan de validación (doble codificación, κ objetivo ≥ 0.7). E2: corpus completo scrapeado y documentado + codificación manual completa de la muestra estratificada + κ reportado + primer modelo de tópicos entrenado + comparación preliminar tópicos automáticos vs. taxonomía manual. E3: análisis de tendencias temporales por eje temático y canal + grafo de coocurrencia autor-institución-tema (networkx/pyvis) + informe interpretativo (¿convergen o divergen las tres tradiciones? ¿qué vacíos temáticos existen, especialmente para LatAm?) + notebook reproducible + repositorio con el corpus (solo metadatos y transcripciones, respetando los términos de uso de YouTube).	Medio-Alto

#	Título	Núcleo metodológico	Entregables por etapa	Nivel
2	¿Presentar en un seminario causa mayor impacto científico? Un estudio causal reflexivo sobre difusión académica	Extracción de expositores + fechas + afiliación de los tres canales → vinculación de cada expositor con su perfil bibliométrico (OpenAlex o Semantic Scholar API: citas acumuladas, producción anual) → diseño de estudio de eventos (DiD/event-study) comparando la trayectoria de citación antes/después de la charla, con grupo de comparación pareado por productividad previa → DAG explícito donde la reputación/senioridad previa es confusor común de {ser invitado, citas futuras}, con la selección a la invitación como amenaza central de identificación → estimación (DiD + AIPW/matching) → sensibilidad (placebo con fecha falsa de “presentación”, E-value para confusión por reputación no observada).	E1: DAG completo con la selección al seminario como mecanismo de confusión central + pregunta causal formal (¿ATT de “presentar” sobre la tasa de citación a 2 años?) + plan de construcción del grupo de control + código esqueleto para las dos APIs (YouTube + OpenAlex/Semantic Scholar). E2: dataset vinculado (expositores + trayectorias de citación) + estimación inicial (DiD simple) + validación del supuesto de tendencias paralelas pre-evento + primer placebo temporal. E3: estimación robusta (AIPW/matching + DiD con controles sintéticos) + ≥ 3 pruebas de sensibilidad + interpretación (con foco en si expositores de instituciones latinoamericanas están sub-representados y cómo eso se relaciona con oportunidades de difusión) + notebook reproducible + informe.	Alto

Notas de aplicación de la rúbrica y de ética:

- Opción 1 (taxonómica): las dimensiones “Identificación” y “Validación y sensibilidad” del §3 deben leerse como “rigor del esquema de codificación (validez de constructo, κ inter-codificador)” y “validación cruzada del modelo de tópicos y sensibilidad a hiperparámetros”, respectivamente.
- Opción 2 (causal reflexiva): la rúbrica se aplica sin modificaciones — es un problema de identificación causal genuino, con un dataset construido por el propio estudiante en vez de un benchmark ya preparado.
- Ambas opciones exigen declarar en “Transparencia y ética” que se usó únicamente la API oficial de YouTube (u otro método que respete sus términos de servicio) para extraer metadatos, descripciones y transcripciones, sin redistribuir ni re-alojar el contenido audiovisual.
- La Opción 2 exige que el estudiante ubique por su cuenta literatura de bibliometría / ciencia de la ciencia sobre efectos de invitación a seminarios en trayectorias de citación, que no forma parte de la bibliografía del curso; esa búsqueda debe reportarse y justificarse en la Etapa 1.

5 Especificaciones de Entregables por Etapa

5.1 Etapa 1 — Planificación (20%)

Extensión: 8–12 páginas. Formato: PDF + código esqueleto en notebook `.ipynb`. Debe incluir:

- Pregunta causal con nivel GCE explícito (1/2/3) y estimando formal (ATE/LATE/CATE/NDE/otros).
- DAG justificado: todas las variables incluidas, aristas sustentadas teóricamente, confusores documentados, validación de d-separación con `pgmpy`.
- Estrategia de identificación algebraica: criterio backdoor/frontdoor/IV aplicado paso a paso.
- Plan de datos: fuente, acceso, descripción de variables, tamaño muestral esperado, DGP sintético si aplica.

- Código esqueleto modular: estructura de carpetas, funciones principales con docstrings, pipeline esquematizado.
- Cronograma personal de 10 semanas con hitos internos.

5.2 Etapa 2 — Ejecución Primaria (30%)

Extensión: 10–15 páginas + notebook v0.3. Debe incluir:

- Estimación inicial: al menos un estimador implementado con resultados numéricos reproducibles.
- Validación de supuestos: overlap/common support, CIA/ignorabilidad, faithfulness según corresponda.
- Sensibilidad preliminar: E-value o Γ de Rosenbaum o prueba placebo (al menos 1 de 3 exigidas en Etapa 3).
- Análisis de fallos: identificación de problemas encontrados y plan de resolución. Esta sección, aunque frecuentemente omitida, es de las más valiosas para el aprendizaje.
- Código en estado v0.3: funcional, comentado, con control de semillas y manejo de errores básico.

5.3 Etapa 3 — Finalización (50%)

Extensión: 25–40 páginas (informe L^AT_EX) + notebook completo + repositorio. Debe incluir:

- Estimación robusta: cross-fitting, estabilización, comparación multi-método (≥ 2 estimadores).
- Sensibilidad exhaustiva: mínimo 3 pruebas de robustez (placebo, E-value/ Γ , estrés distribucional).
- Interpretación contextual: relevancia para Latinoamérica/Perú, implicancias de política o negocio.
- Métricas GCE: reportadas según nivel de Jerarquía abordado.
- Discusión ética: sesgos potenciales, limitaciones de medición, uso de herramientas de IA declarado.
- Reproducibilidad total: `requirements.txt` o `environment.yml`, semillas fijadas, datos o DGP incluidos, licencia de uso.

6 Bibliografía de Referencia Universal

Las siguientes referencias son válidas para todas las categorías. Las propuestas individuales pueden requerir fuentes adicionales.

6.1 Textos principales

- Lincovil, J. y Rojas, H. (2026). *Inferencia Causal Aplicada con Python*. Universidad Nacional de Ingeniería, Lima. (Texto en elaboración; usar artículos originales cuando los capítulos no estén disponibles.)
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.
- Hernán, M. A. y Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC. Disponible en línea sin costo.
- Imbens, G. W. y Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.

6.2 Métodos y algoritmos

- Athey, S., Tibshirani, J. y Wager, S. (2019). Generalized random forests. *The Annals of Statistics*, 47(2), 1148–1178.

- Callaway, B. y Sant’Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200–230.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W. y Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
- Hahn, J. (1998). On the role of the propensity score in efficient semiparametric estimation of average treatment effects. *Econometrica*, 66(2), 315–331.
- Kennedy, E. H. (2023). Semiparametric doubly robust targeted double machine learning: a review. arXiv:2203.06469 [stat.ME].
- Meinshausen, N. (2006). Quantile regression forests. *Journal of Machine Learning Research*, 7, 983–999.
- Peters, J., Janzing, D. y Schölkopf, B. (2017). *Elements of Causal Inference*. MIT Press.
- Spirtes, P., Glymour, C. y Scheines, R. (2000). *Causation, Prediction, and Search* (2nd ed.). MIT Press.
- Sun, L. y Abraham, S. (2021). Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of Econometrics*, 225(2), 175–199.
- Wager, S. y Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228–1242.

6.3 Sensibilidad y equidad

- Chiappa, S. (2019). Path-specific counterfactual fairness. *Proceedings of the AAAI Conference on Artificial Intelligence*, 33(01), 7801–7808.
- Dorn, J., Guo, K. y Kallus, N. (2021). Doubly-valid/doubly-sharp sensitivity analysis for causal inference with unmeasured confounding. arXiv:2112.11449 [stat.ME].
- Kusner, M. J., Loftus, J., Russell, C. y Silva, R. (2017). Counterfactual fairness. *Advances in Neural Information Processing Systems*, 30.
- Manski, C. F. (2003). *Partial Identification of Probability Distributions*. Springer.
- Pleiss, G., Raghavan, M., Wu, F., Kleinberg, J. y Weinberger, K. Q. (2017). On fairness and calibration. *Advances in Neural Information Processing Systems*, 30.
- Rosenbaum, P. R. (2002). *Observational Studies* (2nd ed.). Springer.
- VanderWeele, T. J. y Ding, P. (2017). Sensitivity analysis in observational research: introducing the E-value. *Annals of Internal Medicine*, 167(4), 268–274.

6.4 Transporte óptimo e IA causal

- Bareinboim, E., Correa, J. D., Ibeling, D. y Icard, T. (2022). On Pearl’s hierarchy and the foundations of causal inference. *Proceedings of the National Academy of Sciences*, 119(42), e2205077119.
- Cheridito, P. y Eckstein, S. (2025). Optimal transport and Wasserstein distances for causal models. *Bernoulli*, 31(2), 1351–1376.
- Kiciman, E., Ness, R., Sharma, A. y Tan, C. (2023). Causal reasoning and large language models: opening a new frontier. arXiv:2305.00901 [cs.CL].
- Pawlowski, N., Coelho de Castro, D. y Glocker, B. (2020). Deep structural causal models for tractable counterfactual inference. *Advances in Neural Information Processing Systems*, 33, 857–869.
- Villani, C. (2009). *Optimal Transport: Old and New*. Springer.

- Xia, K., Lee, K.-Z., Bengio, Y. y Bareinboim, E. (2022). Neural causal models for counterfactual identification and estimation. *arXiv:2210.00035 [cs.LG]*.
- Zhang, J. y Bareinboim, E. (2020). Near-optimal reinforcement learning in dynamic treatment regimes. *Advances in Neural Information Processing Systems*, 33, 20340–20351.

6.5 Referencias adicionales por propuesta

- Arjovsky, M., Bottou, L., Gulrajani, I. y Lopez-Paz, D. (2019). Invariant risk minimization. *arXiv:1907.02893 [stat.ML]*.
- Athey, S. y Wager, S. (2021). Policy learning with observational data. *Econometrica*, 89(1), 133–161.
- Backhoff-Veraguas, J., Bartl, D., Beiglböck, M. y Eder, M. (2020). Adapted Wasserstein distances and stability in mathematical finance. *Finance and Stochastics*, 24, 601–632.
- Bareinboim, E. y Pearl, J. (2016). Causal inference and the data-fusion problem. *Proceedings of the National Academy of Sciences*, 113(27), 7345–7352.
- Dehejia, R. H. y Wahba, S. (1999). Causal effects in nonexperimental studies: reevaluating the evaluation of training programs. *Journal of the American Statistical Association*, 94(448), 1053–1062.
- Dudík, M., Langford, J. y Li, L. (2011). Doubly robust policy evaluation and learning. *Proceedings of the 28th International Conference on Machine Learning*, 1097–1104.
- Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254–277.
- Jiang, N. y Li, L. (2016). Doubly robust off-policy value evaluation for reinforcement learning. *Proceedings of the 33rd International Conference on Machine Learning*, 48, 652–661.
- Jin, Z., Liu, J., Lyu, Z., Poff, S., Sachan, M., Mihalcea, R., Diab, M. y Schölkopf, B. (2023). Can large language models infer causation from correlation? *arXiv:2306.05836 [cs.CL]*.
- Lattimore, F., Lattimore, T. y Reid, M. D. (2016). Causal bandits: learning good interventions via causal models. *Proceedings of the 32nd Conference on Uncertainty in Artificial Intelligence*, 417–426.
- LaLonde, R. J. (1986). Evaluating the econometric evaluations of training programs with experimental data. *The American Economic Review*, 76(4), 604–620.
- Lu, Y., Meisami, A. y Tewari, A. (2021). Causal bandits with unknown graph structure. *Advances in Neural Information Processing Systems*, 34, 24817–24828.
- Pearl, J. (2001). Direct and indirect effects. *Proceedings of the 17th Conference on Uncertainty in Artificial Intelligence*, 411–420.
- Peters, J., Bühlmann, P. y Meinshausen, N. (2016). Causal inference by using invariant prediction: identification and confidence intervals. *Journal of the Royal Statistical Society: Series B*, 78(5), 947–1012.
- Roth, J., Sant’Anna, P. H. C., Bilinski, A. y Poe, J. (2023). What’s trending in difference-in-differences? A synthesis of the recent econometrics literature. *Journal of Econometrics*, 235(2), 2218–2244.
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A. y Bengio, Y. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612–634.
- Shpitser, I. y Pearl, J. (2006). Identification of conditional interventional distributions. *Proceedings of the 22nd Conference on Uncertainty in Artificial Intelligence*, 437–444.
- Sutton, R. S. y Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- Thomas, P. S., Theodorou, G. y Ghavamzadeh, M. (2015). High-confidence off-policy evaluation. *Proceedings of the AAAI Conference on Artificial Intelligence*, 29(1).

- van der Vaart, A. W. (1998). *Asymptotic Statistics*. Cambridge University Press.
- Yang, M., Liu, F., Chen, Z., Shen, X., Hao, J. y Wang, J. (2021). CausalVAE: disentangled representation learning via neural structural causal models. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 9593–9602.
- Zheng, X., Aragam, B., Ravikumar, P. y Xing, E. P. (2018). DAGs with NO TEARS: continuous optimization for structure learning. *Advances in Neural Information Processing Systems*, 31.

6.6 Herramientas y referencias metodológicas — Categoría 5 (NUEVA)

- Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794 [cs.CL].
- Priem, J., Piwowar, H. y Orr, R. (2022). OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts. arXiv:2205.01833 [cs.DL].
- CAUSALab, Harvard T.H. Chan School of Public Health. Canal de YouTube: <https://www.youtube.com/@CAUSALab>
- Online Causal Inference Seminar (con apoyo del Departamento de Estadística de Stanford). Canal de YouTube: <https://www.youtube.com/@onlinecausalinferencesemin2364>
- Causal Artificial Intelligence Lab, Columbia University. Canal de YouTube: <https://www.youtube.com/@CausalAI> — sitio del laboratorio: <https://causalai.net>

Para consultas sobre selección de propuesta, ajuste de alcance o autorización de proyectos de nivel doctoral (Cat. 1, propuesta #2), escribir a jlincovilc@uni.edu.pe con asunto: [ICA2026-PROYECTO] antes del 30 de abril de 2026.