


UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ingeniería Económica, Estadística y Ciencias Sociales
Unidad Central de Posgrado



Inferencia Causal Aplicada con Python

Monografía · Texto de posgrado

DES504 — Prof. Dr. Jaime Lincovil

Programa: Maestría en Ciencias e Ingeniería Estadística

Ciclo: 2026

Lima, Perú · 2026

Índice

Derechos de Autor	13
Ficha de la monografía	14
01 La jerarquía GCE	19
1 Filosofía metodológica: Proofs-to-Python	20
2 Cómo leer esta monografía	20
Referencias	20
1 Introducción: Los Tres Niveles de Preguntas Causales	22
11 Conceptos Fundamentales: Resultados Potenciales y la Jerarquía GCE	22
2 Filosofía Metodológica: Proofs-to-Python	23
3 Mapeo Sistemático de la Jerarquía GCE a los 4 Bloques	24
31 Nivel 1: Localización (Bloque I, Capítulos 1–12)	24
32 Nivel 2: Forma (Bloque II, Capítulos 13–19)	24
33 Nivel 3: Geometría (Bloques III–IV, Capítulos 20–32)	24
34 Precondición: Descubrimiento Estructural (Bloque III, Capítulos 20–21)	25
4 Axiomas para una Medida de Discrepancia Causal	25
5 El Contrato Fundamental: SUTVA	26
6 Nivel 1: El Average Treatment Effect y su Ceguera Estructural	27
7 Nivel 2: Divergencias f y Cambios en la Forma Distributiva	27
8 Nivel 3: Transporte Óptimo y la Paradoja Resuelta	28
9 Verificación Computacional: La Dualidad en Acción	29
10 Genealogía del Transporte Óptimo: De Monge a la Inferencia Causal	30
11 Cierre del capítulo	30
Referencias	30
1 El Problema Fundamental de la Inferencia Causal	32
2 Anatomía del Sesgo de Selección	33
21 Identificabilidad de un parámetro causal	34
3 La Independencia Causal y el Mecanismo RCT	34
4 RCT como Nivel 1 en la Jerarquía GCE	35
41 Estimadores para los tres niveles GCE bajo aleatorización	35
5 Implementación Computacional: Simulación de Sesgo y RCT	36
6 Cierre del capítulo	36
Referencias	36
1 El Supuesto de Independencia Condicional (CIA)	38
2 La Maldición de la Dimensionalidad	39
3 Métricas de Distancia Geométricas	40
4 El Teorema de Propensity Score	41
41 Del Teorema a la Práctica: Estrategias de Estimación con el Propensity Score	42
5 Cierre del capítulo	43
Referencias	44
1 La Lógica de Re-Ponderación (IPW)	45
2 Estabilización y Varianzas	46

3	El Estimador Doblemente Robusto (AIPW)	47
4	Límites de Cramér-Rao y Eficiencia Semiparamétrica	48
5	Verificación Computacional: AIPW y Doble Robustez	49
6	Cierre del capítulo	49
	Referencias	49
1	La Falla del CIA y la Anatomía de la Endogeneidad	51
2	La Anatomía del Instrumento Perfecto	52
3	El Estimador de Wald y la Purificación Geométrica (2SLS)	54
31	Proyección Múltiple: Mínimos Cuadrados en Dos Etapas (2SLS)	54
4	El Estimando Local	55
5	Verificación Computacional: Estimador de Wald y 2SLS	55
6	Cierre del capítulo	56
	Referencias	56
1	Heterogeneidad del Efecto Causal y el Marco de Imbens-Angrist	58
2	La Taxonomía de los Cuatro Tipos	59
3	El Teorema LATE (Imbens & Angrist, 1994)	60
4	Implicaciones y Validez Externa del LATE	62
41	El Estimando ITT y su Relación Estructural con el LATE	63
42	Sensibilidad a la violación de la restricción de exclusión	64
5	Verificación Computacional: Taxonomía de Respondientes y LATE vs. ATE	64
6	Cierre del capítulo	65
	Referencias	65
1	Sharp RDD: La Aleatorización en el Umbral	66
2	Estimación No Paramétrica: Regresión Local	67
3	Fuzzy RDD y su Conexión con Variables Instrumentales	69
4	Tests de Validez y Falsificación	70
5	Verificación Computacional: Sharp RDD con Kernel Triangular	72
6	Cierre del capítulo	72
	Referencias	73
1	El Diseño Canónico 2x2 y Tendencias Paralelas	74
2	La Regresión TWFE	75
3	La Descomposición de Goodman-Bacon (2021)	76
4	Estimadores Modernos Robustos	77
5	Verificación Computacional: TWFE vs. Callaway-Sant'Anna en Adopción Escalonada	79
6	Validación Empírica: Tests de Tendencias Paralelas Pre-tratamiento	79
7	Cierre del capítulo	80
	Referencias	80
1	El Problema de la Unidad Tratada Única y el Marco Formal	82
2	El Problema de Optimización: Pesos del Control Sintético	83
3	Propiedades del Estimador y Condiciones de Sesgo	85
4	Inferencia: Tests de Permutación Placebo (Fisher)	86
5	Verificación Computacional: Control Sintético con Test Placebo de Fisher	87
	Referencias	88
1	El Marco Contrafactual Anidado y la Paradoja del Efecto Cero	89

2	Definición Formal de Efectos Causalmente Estructurales	91
3	Condiciones de Identificación (Ignorabilidad Secuencial)	91
4	La Fórmula de Mediación No Paramétrica	92
5	El Colapso Paramétrico: De Pearl a Baron-Kenny	92
51	Confusor entre el Mediador y el Resultado	93
6	Verificación Computacional: NDE y NIE via G-Computation	94
7	Cierre del capítulo	95
	Referencias	95
1	El Colapso de la Ignorabilidad Fuerte y el Reto de los Datos Limitados	97
2	El Modelo de Sensibilidad de Rosenbaum y su Aplicación en Muestras Pequeñas	98
3	El E-Value: Interpretación Universal para Toma de Decisiones	99
4	Causalidad en Contextos del Sur Global: Desafíos y Adaptaciones	100
41	Desafíos Específicos	100
42	Estrategias para Datos Limitados	100
5	El ICE Stress Test en Condiciones Adversas	101
6	Pruebas de Placebo y Falsificación en Muestras Pequeñas	101
7	Caso de Estudio Integrado: Programa Pensión 65 en Perú	102
71	Contexto y Desafíos	102
72	Estrategia de Análisis Integrada	102
73	Implementación en Python	103
74	Resultados y Interpretación	103
8	Conclusiones y Recomendaciones para la Práctica	103
81	Para investigadores en contextos del Sur Global	103
82	Para tomadores de decisión	104
83	Integración con el Pipeline Unificado (Capítulo 12)	104
9	Cierre del capítulo	104
	Referencias	104
1	Introducción	106
2	El Árbol de Decisión Metodológico	106
3	Tabla Comparativa de Métodos	108
4	Ejemplos Aplicados	109
5	Recomendaciones Prácticas	110
51	Sobre la elección del método	110
52	Sobre la defensa de los supuestos	110
53	Sobre la combinación de métodos	111
54	Sobre el contexto peruano y latinoamericano	111
55	Sobre la transparencia y reproducibilidad	111
6	Cierre del Bloque I y Transición al Bloque II	111
	Referencias	112
1	La Asimetría Causal: El Símbolo $:=$	113
2	Variables Exógenas y Endógenas	114
3	El Modelo Causal Estructural: Definición Formal	115
31	El Grafo Acíclico Dirigido (DAG) Asociado	116
4	El Operador $do(\cdot)$: Intervención como Cirugía del Modelo	116

5	La Condición de Markov Causal	117
6	Equivalencia entre los Formalismos de Rubin y Pearl	118
7	Supuestos Codificados en el SCM	118
8	Síntesis del Capítulo	119
	Referencias	119
1	Los Tres Conectores Fundamentales	120
11	Cadena (Pipe)	120
12	Horquilla (Fork / Confounder)	121
13	Colisionador (Collider)	121
2	La Paradoja de Berkson: El Colisionador en Acción	122
3	Caminos y Flujo de Información	123
4	d-Separación: Independencia Condicional desde la Topología	123
5	El Supuesto de Fidelidad (Faithfulness)	124
6	Los Supuestos Codificados en el DAG	125
7	Verificación Gráfica de Independencias: Un Ejemplo Integrador	125
8	Síntesis del Capítulo	126
	Referencias	127
1	Caminos de Puerta Trasera: La Anatomía de la Confusión	128
2	El Criterio Backdoor: Definición y Justificación	129
3	¿Qué Conjuntos Satisfacen el Criterio? Ejemplos	130
4	El Experimento Aleatorio como Caso Especial	130
5	Observational Equivalence y las Limitaciones del Criterio	131
6	Del Criterio a la Estimación: Estrategias Prácticas	131
7	Síntesis del Capítulo	132
	Referencias	132
1	Motivación Histórica: El Debate del Tabaco y el Cáncer	134
2	El Criterio Frontdoor: Definición Formal	135
3	Aplicación al Ejemplo del Tabaco	135
4	Backdoor versus Frontdoor: Una Comparación Sistemática	136
5	Un Ejemplo en Políticas Públicas Peruanas	136
6	Limitaciones y Extensiones	137
7	Síntesis del Capítulo	137
	Referencias	138
1	Una Pregunta Incómoda	139
2	Causa General versus Causa Singular	139
3	El Problema de las Subpoblaciones Contrafactuales	140
4	El Contenido Empírico de un Contrafactual	142
41	La Ley de Ohm como Caso Paradigmático	142
42	Valor Predictivo versus Valor Explicativo	142
5	De la Explicación a la Causa: Enunciados Explicativos	143
51	Explicación General versus Explicación Singular	143
52	Clasificación Práctica: ¿Cuándo Usar Cada Tipo?	144
6	El Ordenamiento Causal de Simon	144
61	Ecuaciones Simétricas y Direcciones Causales	144

62	Implicaciones para el Analista	146
7	Síntesis: La Jerarquía de Preguntas Causales Revisitada	146
8	Síntesis del Capítulo	146
	Referencias	147
1	Motivación: Más Allá del Backdoor y Frontdoor	148
2	Notación y Grafos Mutilados	148
3	Las Tres Reglas del Do-Calculus	149
4	Ejemplos de Aplicación	149
5	Complejidad del Do-Calculus	150
6	El Algoritmo ID	150
7	Identificabilidad vs. No-Identificabilidad	150
8	Construcción de Fórmulas de Identificación	151
9	Síntesis del Capítulo	151
	Referencias	152
1	Resultados Potenciales y el SCM	153
2	El Problema Fundamental de la Inferencia Causal	153
3	El Procedimiento Abducción-Acción-Predicción	154
4	Probabilidades de Necesidad y Suficiencia	154
5	Contrafactuales en el Contexto del Do-Calculus	155
6	Limitaciones de los Contrafactuales Individuales	156
7	Síntesis del Capítulo	156
	Referencias	157
1	Fundamentos del Descubrimiento Causal	158
11	La Condición de Markov Causal	158
12	Fidelidad (Faithfulness)	158
2	Algoritmos Basados en Restricciones (Constraint-based)	159
21	El Algoritmo PC	159
22	El Algoritmo FCI	159
3	Algoritmos Basados en Scores	160
31	GES (Greedy Equivalence Search)	160
4	Descubrimiento Causal como Optimización Continua	160
41	NOTEARS	161
42	LiNGAM	161
5	Métricas de Evaluación en Descubrimiento Causal	161
51	SHD (Structural Hamming Distance)	161
52	SID (Structural Intervention Distance)	162
6	Selección por Estabilidad (Stability Selection)	162
7	Flujo de trabajo para descubrimiento causal	162
8	Síntesis del Capítulo	163
	Referencias	163
1	La Jerarquía de Pearl: Tres Estratos del Razonamiento Causal	165
2	El Principio de Modularidad	166
3	Invariancia Distribucional y Causal	166
31	Invariancia Distribucional	166

32	Invariancia Causal [1]	166
4	ICP: Predicción Causal Invariante	167
5	Implicaciones para el Aprendizaje Automático	168
6	Ejemplo: Invariancia en Datos Multi-Entorno	168
7	Lectura de la jerarquía de Pearl en clave GCE	168
8	Cierre del capítulo	168
	Referencias	168
1	CATE: El Efecto Causal Condicional	170
2	S-Learner: Un Solo Modelo	170
3	T-Learner: Dos Modelos Separados	171
4	X-Learner: Aprendizaje Cruzado	171
5	R-Learner: Descomposición de Robinson	172
6	BLP: Best Linear Prediction de Heterogeneidad	173
7	Comparación de Meta-Learners	173
8	Criterio de selección entre meta-learners	173
9	Cierre del capítulo	174
	Referencias	174
1	El Problema: Sesgo de Regularización	175
11	Nuisance Parameters	175
12	Sesgo de Regularización de Primer Orden	175
2	Ortogonalidad de Neyman [2]	176
3	El Estimador DML	176
31	La Ecuación de Robinson [3] Ortogonalizada	176
32	Cross-Fitting (K-fold)	177
4	Propiedades Asintóticas del DML	177
5	Doble Robustez del DML	177
6	Modelos Estructurales para DML	178
61	Partially Linear Model (PLM)	178
62	Interactive Model (DML para CATE)	178
7	Ejemplo: DML Aplicado al Efecto de la Educación sobre el Ingreso	179
8	Procedimiento DML (esquema monográfico)	179
9	Síntesis del Capítulo	179
	Referencias	180
1	Motivación: más allá del efecto promedio	181
2	Árboles de tratamiento adaptativo	181
21	Particionamiento recursivo para efectos causales	181
22	El principio de honestidad	182
23	Normalidad asintótica del árbol honesto	182
3	Bosques causales	183
31	Agregación de árboles honestos	183
32	Gaussianidad puntual del Causal Forest	183
33	Local centering: ortogonalización en el bosque causal	184
34	PEHE: métrica de evaluación de heterogeneidad	184
4	Regla de targeting óptimo	185

5	Diagrama causal del proceso de estimación	185
6	Procedimiento algorítmico del Causal Forest	185
7	Ejemplos de aplicación	186
8	Síntesis del Capítulo	187
	Referencias	187
1	Desafíos de la inferencia causal en el tiempo	188
11	Estructura causal en panel	188
2	ATT por cohorte-periodo: Callaway y Sant'Anna	188
21	El problema del TWFE con adopción escalonada	188
22	Descomposición por cohorte-periodo	189
3	Synthetic Difference-in-Differences (SDID)	189
31	Motivación y formulación	189
32	Propiedades asintóticas del SDID	190
4	G-computation para datos de panel	190
5	Reglas de Tratamiento Dinámico (DTR) y Q-learning	190
51	Formulación del problema	191
52	Q-learning para DTR	191
6	Estructura temporal de un régimen dinámico	191
7	Cierre del capítulo	191
	Referencias	192
1	Evaluación de políticas a partir de datos observacionales	193
11	Conexión con la jerarquía causal	193
2	Estimador de Importance Sampling (IPS)	193
21	Formulación básica	193
3	Estimador Doubly Robust para OPE	194
31	Combinación de modelo directo e IPS	194
4	Bandits contextuales y regret	195
41	Formulación del problema	195
42	Algoritmo LinUCB	195
5	Bandits causales	195
6	Política óptima como función del CATE	196
7	Procedimiento integrado: de los datos a la política	196
8	Diagrama conceptual de la OPE	197
9	Ejemplos de aplicación	197
10	Síntesis del Capítulo	198
	Referencias	198
1	De las predicciones a las causas: el paradigma de representaciones	199
2	Invariant Risk Minimization (IRM)	199
21	Principio y formulación	199
22	IRM recupera las causas: caso lineal	200
23	Limitaciones y variantes de IRM	200
3	VAE con estructura causal	201
31	Del VAE estándar al VAE identificable	201
32	iVAE: identificabilidad mediante variable auxiliar	201

33	CausalVAE: DAG en el espacio latente	201
4	Correlación espuria y shortcut learning	202
41	El problema en visión por computador	202
42	Shortcut learning en NLP	202
5	Diagrama del espacio latente causal	203
6	Procedimiento algorítmico: CausalVAE con NOTEARS	203
7	Ejemplos de aplicación	204
8	Síntesis del Capítulo	205
	Referencias	205
1	Procesos de decisión Markovianos causales	207
11	MDP causal (CMDP)	207
2	Intervenciones, políticas y valor causal	207
21	Valor causal de una política	207
22	Ecuación de Bellman causal	208
3	Exploración informada por estructura causal	208
4	Desafíos en entornos reales	208
41	Aprendizaje del grafo causal on-line	208
42	Confounders no observados y entornos parcialmente observables	209
43	Escala y complejidad computacional	209
5	Conexión con la jerarquía GCE	209
6	Checklist Riguroso	209
7	Glosario	210
8	Cierre del capítulo	210
	Referencias	210
1	Limitaciones de los modelos puramente asociativos	211
11	Manifestaciones del problema	211
2	Esquemas de integración causal-deep learning	211
21	Neural Causal Models (NCM)	211
22	Causal Deep Learning: embeddings causales	212
23	Híbrido: LLM + módulo causal externo	212
3	Ideas para LLMs causales y razonamiento contrafáctico	212
31	Chain-of-Thought causal	212
32	Limitaciones del razonamiento causal en LLMs	212
4	Casos de uso: sistemas recomendadores, visión y lenguaje	213
41	Sistemas recomendadores causales	213
42	Visión causal	213
5	Perspectivas de investigación	213
6	Conexión con la jerarquía GCE	213
7	Checklist Riguroso	214
8	Glosario	214
9	Cierre del capítulo	215
	Referencias	215
1	Motivación: más allá del agente puramente estocástico	216
2	Definición Formal	216

3	La Condición de Semi Determinismo Causal	217
4	Conexión con la Jerarquía de Pearl	217
5	Arquitectura Computacional	217
51	Módulo Causal Determinístico	217
52	Módulo de Aprendizaje Estadístico	218
6	Propiedades Formales	218
7	Aplicaciones	219
71	Auditoría algorítmica causal	219
72	Política pública	219
8	Conexión con la jerarquía GCE	219
9	Checklist Riguroso	220
10	Glosario	220
11	Cierre del capítulo	220
	Referencias	220
1	Definiciones causales de equidad y no discriminación	222
2	Análisis de caminos lícitos e ilícitos	222
21	Formalización legal	223
22	Contrafactual de equidad individual	223
3	Evaluación causal de sistemas de decisión (crédito, justicia, salud)	223
31	Crédito bancario	223
32	Justicia penal (COMPAS)	223
33	Salud	223
4	Implicancias regulatorias y de gobernanza de IA	224
41	Marco regulatorio europeo (EU AI Act)	224
42	Recomendaciones prácticas	224
5	Conexión con la jerarquía GCE	224
6	Checklist Riguroso	224
7	Glosario	225
8	Cierre del capítulo	225
	Referencias	225
1	La jerarquía de Pearl y su rol en IA	227
2	Agenda de investigación en IA causal	227
21	Descubrimiento causal a partir de datos observacionales	227
22	Generalización y transferencia causal	228
23	IA generativa causal	228
3	Desafíos técnicos: identificabilidad, escalabilidad, validación	228
31	Identificabilidad	228
32	Escalabilidad	228
33	Validación	228
4	Desafíos éticos y sociales	229
41	Responsabilidad algorítmica y causalidad	229
42	Uso del análisis causal para evadir regulación	229
43	Uso en política pública	229
5	Síntesis del curso y líneas para profundización	229

51	Síntesis conceptual	229
52	Líneas de profundización	229
6	Los 7 Pilares de la IA Causal (Pearl, 2019)	230
7	Conexión con la jerarquía GCE	230
8	Checklist Riguroso	230
9	Glosario	231
10	Cierre monográfico	231
	Referencias	232
11	Introducción	233
12	Teoría de Medida: Fundamentos	233
13	Métricas y Divergencias entre Distribuciones	234
131	Divergencias f (Nivel 2 de GCE)	234
132	Métricas Integrales de Probabilidad	235
14	Teoría de Transporte Óptimo	235
141	Problema de Monge	235
142	Problema de Kantorovich	235
15	Distancias de Wasserstein	236
151	Wasserstein-1 y Comparación con Divergencias f	237
16	Transporte Óptimo Causal y Restricciones de Grafo	238
17	Axiomas de una Métrica Causal Ideal	239
18	Conexión con Inferencia Causal	240
	Referencias	241
	Apéndice de Demostraciones	242
181	Capítulo 1: La Paradoja del Efecto Cero	242
182	Capítulo 2: El Problema Fundamental	242
183	Capítulo 3: El Arte del Matching	244
184	Capítulo 4: IPW y Doble Robustez	247
185	Capítulo 5: Variables Instrumentales	251
186	Capítulo 6: LATE y Taxonomía de Respondientes	253
187	Capítulo 7: Regression Discontinuity Design	256
188	Capítulo 8: Difference-in-Differences	258
189	Capítulo 9: Control Sintético	260
1810	Capítulo 10: Mediación Causal	262
1811	Capítulo 11: Robustez y Validación	265
1812	Capítulo 13: Modelos Causales Estructurales	266
1813	Capítulo 14: DAGs y Estructuras Fundamentales	267
1814	Capítulo 15: El Criterio Backdoor	267
1815	Capítulo 16: El Criterio Frontdoor	268
1816	Capítulo 17: Naturaleza de las Causas	269
1817	Capítulo 18: Do-Calculus	269
1818	Capítulo 19: Contrafactuales	271
1819	Capítulo 20: Descubrimiento Causal	271
1820	Capítulo 21: Aprendizaje Causal	272
1821	Capítulo 22: Meta-Learners	272

1822	Capítulo 23: Doble Desviación	273
1823	Capítulo 24: Efectos Heterogéneos	273
1824	Capítulo 25: Series de Tiempo y Paneles	275
1825	Capítulo 26: Off-Policy Evaluation	276
1826	Capítulo 27: Representaciones Causales	277
1827	Capítulo 30: Agentes Semi Determinísticos	277
1828	Nota sobre la cobertura de demostraciones	279
19	Fundamentos de resultados potenciales e identificación	280
20	Diseños y estimandos clásicos (Nivel 1)	280
21	Grafos, SCM y do-cálculo (Nivel 2 / Pearl)	280
22	Transporte óptimo y geometría (Nivel 3 / GCE)	281
23	Aprendizaje automático causal y heterogeneidad	281
24	Sensibilidad, equidad e IA causal	281

Derechos de Autor

Este libro, titulado *Inferencia Causal Aplicada con Python*, es una obra intelectual protegida bajo la legislación peruana (Decreto Legislativo N° 822). Todos los derechos están reservados por la Universidad Nacional de Ingeniería (UNI), Perú.

Se autoriza el uso del contenido exclusivamente para fines educativos, académicos y de investigación, siempre que se reconozca la autoría y no se utilice con fines comerciales.

Prohibiciones:

- No se permite la reproducción total o parcial del contenido con fines comerciales sin autorización previa por escrito de la UNI.
- No se permite la modificación del contenido sin autorización previa.

Cualquier uso del contenido debe incluir el siguiente reconocimiento:

© 2026 Universidad Nacional de Ingeniería (UNI), Perú. Todos los derechos reservados.

Para usos no contemplados en esta licencia, se debe contactar a la UNI a través de su oficina de propiedad intelectual.

Ficha de la monografía

Título	Inferencia Causal Aplicada con Python
Tipo	Monografía / texto de posgrado (curso DES504)
Autoría académica	Prof. Dr. Jaime Lincovil
Institución	Universidad Nacional de Ingeniería (UNI), Lima, Perú
Programa	Maestría en Ciencias e Ingeniería Estadística
Ciclo	2026
Marco unificador	Geometría de la Causalidad Estadística (GCE)
Estructura	32 capítulos en 4 bloques + Apéndice A + Apéndice de Demostraciones
Filosofía	<i>Proofs-to-Python</i> : cada resultado teórico admite verificación computacional
Laboratorio asociado	Jupyter Book y pack de 32 notebooks (material complementario, no sustituye este texto)
Convenciones	Semilla de reproducibilidad 42 en experimentos; notación unificada en la tabla preliminar
Versión editorial	GCE v2 (jerarquía y axiomas 4a/4b alineados; estilo monográfico 2026)

Cómo usar este volumen. El cuerpo monográfico desarrolla teoría, identificación y geometría. Las demostraciones formales de resultados seleccionados se concentran en el Apéndice de Demostraciones. La ejecución de laboratorios y datasets vive en el material Jupyter asociado; aquí se incluyen solo fragmentos de código cuando ilustran un teorema (*Proofs-to-Python*).

Tabla de Notación y Glosario

Símbolo / Acrónimo	Significado
{— Variables Fundamentales y Tratamiento —}	
$\mathbf{X}$	Vector de covariables observadas (confusores, ajuste).
Y	Variable de resultado observada ($Y \in \mathcal{Y}$).
T	Indicadora de tratamiento o asignación ($T \in \{0, 1\}$).
Z	Variable instrumental (asignación exógena).
A	Atributo sensible (equidad, no discriminación) en Cap. 32.
$\mathbf{U}$	Vector de variables exógenas/no observadas (ruido latente).
U	Confusor no observado (en análisis de sensibilidad).
{— Resultados Potenciales y Contrafactuales —}	
$Y(t)$	Resultado potencial bajo tratamiento $T = t$.
$Y_{i(t)}$	Resultado potencial unitario ($i = 1, \dots, n$) bajo $T = t$.
$Y(a)$	Resultado potencial general (efectos promedio).
$Y(t, m)$	Resultado potencial anidado (mediación).
$T_{i(z)}$	Resultado potencial de tratamiento bajo instrumento z (LATE).
$\tau_i = Y_{i(1)} - Y_{i(0)}$	Efecto causal individual (ITE).
{— Estimandos Causales y Efectos —}	
ATE	Efecto Promedio de Tratamiento: $\mathbb{E}[Y(1) - Y(0)]$.
ATT	Efecto en Tratados: $\mathbb{E}[Y(1) - Y(0) \mid T = 1]$.
ATU	Efecto en No Tratados: $\mathbb{E}[Y(1) - Y(0) \mid T = 0]$.
CATE(x)	Efecto Condicional sobre Tratamiento dado $\mathbf{X} = x$.
LATE	Efecto Local sobre Cumplidores (Compliers).
NDE	Efecto Directo Natural ($Y(1, M(0)) - Y(0, M(0))$).
NIE	Efecto Indirecto Natural ($Y(1, M(1)) - Y(1, M(0))$).
ITT	Efecto de Intención de Tratar (Instrumental).
ITE	Efecto Causal Individual (Individual Treatment Effect).
QTE(q)	Efecto de Tratamiento Cuantílico en cuantil q .
{— Propensión, Pesos y Mecanismos —}	
$e(\mathbf{X})$	Propensity Score: $P(T = 1 \mid \mathbf{X})$.
$p(t \mid \mathbf{x})$	Función de probabilidad condicional alternativa.
$\mu_t(\mathbf{X})$	Función de resultado condicional $\mathbb{E}[Y \mid T = t, \mathbf{X}]$.
$\hat{\eta}$	Parámetros de nuisance (μ_t, e, g).
$\pi(x)$	Política óptima o regla de decisión en RL/OPE.
$\pi_{b(x)}$	Política de comportamiento (datos históricos).
ω, w_j	Pesos de unidades (Control Sintético, IPW).
{— Modelos Estructurales y Grafos —}	
$\mathcal{M}$	Modelo Causal Estructural (SCM): tupla $\mathcal{M}$ con componentes $\mathbf{U}, \mathbf{V}, \mathcal{F}, P(\mathbf{U})$
$\mathcal{G}$	Grafo Acíclico Dirigido (DAG) asociado al modelo.
$\mathcal{V}$	Conjuntos de nodos endógenos.
$\text{do}(x)$	Operador de intervención causal.

d-sep	Separación directa en grafos.
pa(V)	Padres directos del nodo V en $\mathcal{G}$.
ch(V)	Hijos directos del nodo V en $\mathcal{G}$.
$\mathcal{F}$	Conjunto de funciones estructurales en SCM.
{— Geometría y Métricas Causales (Jerarquía GCE) —}	
$\mathcal{D}_{\text{loc}}$	Discrepancia de localización: $ \tau_{\text{ATE}} = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] $ (Nivel 1 axiomático).
$\mathbb{P}_{Y(t)}$	Medida de probabilidad contrafactual.
$d(X, Y)$	Métrica base en el espacio de resultados.
$W_{p(\mathbb{P}, \mathbb{Q})}$	Distancia de Wasserstein de orden p .
$W_1(\mathbb{P}, \mathbb{Q})$	Wasserstein-1; cota superior de $ \tau_{\text{ATE}} $ (cadena maestra).
$W^{G,1}(\mathbb{P}, \mathbb{Q})$	Wasserstein causal con acoplamientos bicausales Π_G^{bc} (Nivel 3 causal).
$W_{1,\epsilon}(\mathbb{P}, \mathbb{Q})$	Wasserstein regularizado con parámetro ϵ .
$D_{f(\mathbb{P} \parallel \mathbb{Q})}$	Divergencia f (KL, TV, Chi-cuadrado).
$D_{\{\text{KL}\}}(\mathbb{P} \parallel \mathbb{Q})$	Divergencia Kullback-Leibler ($f(t) = t \log t$).
$D_{\{\text{TV}\}}(\mathbb{P}, \mathbb{Q})$	Distancia de Variación Total ($f(t) = t - 1 $).
$D_{\chi^2}(\mathbb{P} \parallel \mathbb{Q})$	Divergencia Chi-cuadrado ($f(t) = (t - 1)^2$).
$ f _{\{\text{Lip}\}}$	Norma Lipschitz de función f .
L	Constante Lipschitz (cota superior de $ f _{\{\text{Lip}\}}$).
$\Delta f, \delta$	Cambio finito o umbral de corte (RDD).
c	Umbral crítico en Regresión Discontinua (RDD).
h	Ancho de banda local (Kernel).
γ	Acoplamiento (transporte) entre distribuciones.
$\Gamma(\mathbb{P}, \mathbb{Q})$	Conjunto de acoplamientos con marginales $\mathbb{P}$ y $\mathbb{Q}$.
$\Pi_G^{\text{bc}}(\mu, \nu)$	Conjunto de acoplamientos bicausales para grafo $\mathcal{G}$.
{— Inferencia, Validación y Sensibilidad —}	
$\hat{\theta}$	Estimador puntual.
CI_{α}	Intervalo de confianza con nivel α .
Γ	Coefficiente de fragilidad de Rosenbaum.
Γ_{ICE}	Coefficiente de fragilidad del ICE Stress Test.
$\alpha_{\text{conf}}, \beta_{\text{conf}}$	Asociaciones de confusor no observado con tratamiento y resultado.
E-value	Magnitud mínima de confusión para invalidar efecto.
$\varepsilon(n)$	Término de incertidumbre muestral en cotas de Manski adaptadas.
Δ_t	Rango de $\mathbb{E}[Y(t) \mid U]$ sobre U en cotas de Manski.
p	Proporción tratada: $\mathbb{P}(T = 1)$.
τ_{obs}	Diferencia observada de medias: $\mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0]$.
RMSE, MAE	Errores de predicción estándar.
PEHE	Error cuadrático medio de efectos heterogéneos.
QINI	Curva de ganancia acumulada (Targeting).
{— Métodos y Algoritmos —}	
RCT	Ensayo Aleatorizado Controlado (Randomized Controlled Trial).
IPW	Ponderación por Propensión Inversa (Inverse Probability Weighting).
AIPW	IPW Aumentado (Augmented IPW), estimador doblemente robusto.
DML	Doble Machine Learning (Double Machine Learning).

DiD	Diferencias en Diferencias (Difference-in-Differences).
RDD	Regresión Discontinua (Regression Discontinuity Design).
SCM	Control Sintético (Synthetic Control Method).
IV	Variables Instrumentales (Instrumental Variables).
PC	Algoritmo PC (Peter–Clark) para descubrimiento causal.
FCI	Algoritmo FCI (Fast Causal Inference) para grafos con latentes.
GES	Greedy Equivalence Search para descubrimiento causal.
NOTEARS	Algoritmo de optimización continua para DAGs.
LiNGAM	Modelo Lineal No Gaussiano para Causalidad.
Causal Forests	Bosques aleatorios para estimación de CATE.
Meta-Learners	Aprendices meta (S-, T-, X-Learner) para CATE.

Término	Definición
Atributo Sensible	Variable protegida por ley (género, raza) analizada en equidad algorítmica.
Causalidad Necesaria/Suficiente	Medidas probabilísticas PN y PS para atribución legal.
Cross-Fitting	Técnica de remuestreo para estimar parámetros de nuisance sin sobreajuste.
Do-Calculus	Sistema axiomático de Pearl para manipular expresiones con operador do.
Doble Robustez	Propiedad donde el estimador converge si se especifica correctamente uno de dos modelos (propensión o resultado).
Efecto Causal Indirecto (NIE)	Parte del efecto mediada por una vía específica.
Efecto Directo Natural (NDE)	Efecto libre de mecanismos intermedios.
Equidad Contrafactual	Exigencia de igualdad de decisiones entre mundos hipotéticos de género/grupo.
Fidelidad (Faithfulness)	Supuesto de independencia estadística derivada de d-separación en grafos.
Invarianza Causal	Mecanismos estables bajo cambios de entorno o distribución.
Matching Exacto/Aproximado	Técnicas de emparejamiento para restaurar aleatorización condicional.
Nivel 1-3 GCE	Clasificación de evidencia causal (Media, Forma Distribucional, Geometría Óptima).
OPE	Evaluación de políticas Off-Policy (usar datos generados por π_b para evaluar π_e).
Paridad Demográfica	Igualdad de tasas marginales de predicción entre grupos.
Propensity Score Matching	Emparejamiento basado en la propensión estimada.
SUTVA	Supuesto de Valor Único Estable de Tratamiento (no interferencia).
Transporte Óptimo	Proceso de transformar masa distributiva con costo mínimo.
Paradoja del Efecto Cero	Situación donde $\tau_{ATE} = 0$ pero $W_1 > 0$, indicando cambios distribucionales ocultos.
Jerarquía GCE	Geometría de la Causalidad Estadística: Marco unificador de tres niveles (Localización, Forma, Geometría).
ICE Stress Test	Procedimiento de estrés test para evaluar robustez ante confusión no observada.
Sur Global	Contextos epistemológicos con datos limitados, alta heterogeneidad y violaciones sistemáticas de supuestos.
Proofs-to-Python	Filosofía metodológica que traduce teoremas a código verificable.
Pipeline Unificado	Estructura de cinco fases para inferencia causal (Descubrimiento, Identificación, Estimación, Validación, Decisión).
Overlap deficiente	Situación donde las distribuciones de covariables de tratados y no tratados tienen soporte limitado en común.
Missing not at random (MNAR)	Datos faltantes que dependen de valores no observados.
Positividad práctica violada	Cuando $P(T = 1 X) \approx 0$ o ≈ 1 para algunos X , común en programas focalizados.
Cotas de Manski	Intervalos de identificación parcial bajo ignorabilidad débil.
Validación por Placebo	Aplicar el estimador a variables donde el efecto causal debería ser nulo.
Falsificación	Uso de contrafactuales artificiales para evaluar sesgo del estimador.
Regularización fuerte	Uso de penalizaciones agresivas en contextos de datos limitados.
Prior informado	Distribución previa que incorpora conocimiento experto o evidencia anterior.
Shrinkage jerárquico	Contracción parcial hacia la media global en modelos bayesianos con datos escasos.

Tabla 1: Glosario Expandido



Prefacio

La inferencia causal contemporánea enfrenta un desafío integrador: mientras su importancia práctica crece en ciencia de datos y políticas públicas, su fundamentación teórica permanece fragmentada en tradiciones que rara vez se hablan entre sí. Los econométricos operan en el espacio de los resultados potenciales [4], los informáticos en el de los grafos causales [5], y los estadísticos en el de los modelos estructurales — cada comunidad con su propio vocabulario para describir la misma realidad causal. Esa fragmentación no es solo incómoda: produce resultados que parecen contradecirse entre tradiciones, dificulta que el conocimiento se acumule de una a otra, y oscurece los supuestos que hacen válida cualquier afirmación causal.

Este libro parte de una observación simple: toda pregunta causal, sin importar de qué tradición metodológica provenga, puede formularse como una comparación entre dos distribuciones contrafactuales — la que observamos y la que habríamos observado bajo una intervención distinta. Bajo esta perspectiva, la pregunta deja de reducirse a “¿cuál es la diferencia de medias?” y puede convertirse en “¿cuánto cuesta transformar la distribución observada en la que habríamos observado bajo la intervención alternativa?”. Esa reformulación geométrica, que remonta a los desarrollos de [6] y [7] en transporte óptimo, es el hilo que organiza este libro y le da su nombre: **Geometría de la Causalidad Estadística (GCE)**.

1 La jerarquía GCE

La GCE ordena las preguntas causales en tres niveles de profundidad creciente, precedidos por una precondition — ¿conocemos la estructura causal subyacente? — que se desarrolla en el Bloque III.


Nivel GCE	Pregunta central	Métrica principal	Bloque
Precondición†	¿Conocemos la estructura causal?	Validación de DAGs	III (20–27)
Nivel 1: Localización	¿Cambió el centro?	$\tau_{ATE} = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$	I (1–12)
Nivel 2: Forma	¿Cambió la distribución completa?	Divergencias: D_{KL} , D_{TV} , D_{χ^2}	II (13–19)
Nivel 3: Geometría	¿Cuál es el costo mínimo del cambio?	Wasserstein W_1 y W^G , ¹	III–IV (20–32)

Tabla 2: Jerarquía GCE y su mapeo a la estructura del libro

† La Precondición es una fase *lógica* previa a todo análisis causal: sus supuestos (DAG, Markov, fidelidad) se invocan desde el Capítulo 1; sus métodos de descubrimiento automático se desarrollan en el Bloque III.

Los tres niveles están relacionados por una **cadena maestra**: $|\tau_{ATE}| \leq W_1 \leq W^G$,¹. Un efecto promedio grande obliga a un costo de transporte grande, pero la implicación no corre en sentido inverso — y esa asimetría es precisamente la **Paradoja del Efecto Cero** que abre el Capítulo 1: intervenciones que reorganizan radicalmente una distribución (polarizando ingresos, induciendo bimodalidad en salud) pueden reportar un efecto promedio nulo. El Capítulo 1 desarrolla la jerarquía completa — axiomas, cadena maestra, puentes entre niveles — con el detalle que este prefacio no necesita anticipar.

El siguiente diagrama resume, a modo de guía práctica, qué nivel corresponde según el tipo de pregunta:



1 Filosofía metodológica: Proofs-to-Python

Este texto opera bajo una regla metodológica simple: cada teorema debe poder ejecutarse. La filosofía **Proofs-to-Python** exige que todo resultado teórico admita una contraparte computacional verificable, usando ecosistemas como *DoWhy*, *EconML*, *Causal-Learn* o *POT*. En la práctica, esto significa sostener tres registros a la vez: la demostración matemática, la intuición empírica —con atención a dinámicas del Sur Global y a la evaluación de políticas en el Perú— y la implementación computacional. La monografía aspira a cerrar la brecha entre la profundidad teórica de la econometría matemática y la agilidad práctica de la ciencia de datos: que el lector no solo calcule efectos, sino que entienda su geometría.

1 Cómo leer esta monografía

1. **Orden recomendado.** Bloque I (caps. 1–12) para identificación y estimación en el Nivel 1; Bloque II (13–19) para el lenguaje de SCM y do-cálculo; Bloque III (20–27) para descubrimiento y ML causal; Bloque IV (28–32) para fronteras de IA causal y cierre.
2. **Jerarquía GCE como brújula.** Antes de cada método, pregunte: ¿localización ($|\tau_{ATE}|$), forma (D_f) o geometría ($W_1, W^{G,1}$)? La cadena maestra $|\tau_{ATE}| \leq W_1 \leq W^{G,1}$ resume la relación entre niveles.
3. **Cuerpo frente a apéndices.** El cuerpo prioriza enunciados, lectura de resultados y puentes al código. Las demostraciones formales seleccionadas están en el Apéndice de Demostraciones; el Apéndice A concentra fundamentos de medida y transporte óptimo.
4. **Laboratorio.** Los 32 notebooks y el Jupyter Book asociados son el laboratorio de la monografía, no un sustituto del argumento teórico. Cuando el texto incluye código, su función es **verificar** un resultado, no reemplazar el desarrollo.
5. **Público.** Se asume familiaridad con probabilidad, regresión y álgebra lineal a nivel de primer año de maestría. No se asume dominio previo de transporte óptimo ni de do-cálculo.

Lima, 2026

Dr. Jaime Lincovil

Referencias

-
- [1] J. Peters, P. Bühlmann, y N. Meinshausen, «Causal Inference by Using Invariant Prediction: Identification and Confidence Intervals», *Journal of the Royal Statistical Society: Series B*, vol. 78, n.º 5, pp. 947-1012, 2016.
 - [2] J. Neyman, «Optimal Asymptotic Tests of Composite Statistical Hypotheses», en *Probability and Statistics: The Harald Cramér Volume*, Wiley, 1959, pp. 213-234.
 - [3] P. M. Robinson, «Root-N-Consistent Semiparametric Regression», *Econometrica*, vol. 56, n.º 4, pp. 931-954, 1988.
 - [4] D. B. Rubin, «Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies», *Journal of Educational Psychology*, vol. 66, n.º 5, pp. 688-701, 1974.
 - [5] J. Pearl, *Causality: Models, Reasoning, and Inference*, 2.^a ed. Cambridge University Press, 2009.
 - [6] G. Monge, «Mémoire sur la théorie des déblais et des remblais», *Histoire de l'Académie Royale des Sciences de Paris*, 1781.
 - [7] L. V. Kantorovich, «On the Translocation of Masses», *Doklady Akademii Nauk SSSR*, vol. 37, n.º 7-8, pp. 199-201, 1942.

CAPÍTULO 1

La Paradoja del Efecto Cero: Geometría de la Causalidad

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42

Notebook (pack): notebooks/Bloque_I/notebooks/01_paradoja_efecto_cero_geometria_causalidad.ipynb

Jupyter Book: jupyter_book/content/bloque_01_fundamentacion/01_paradoja_efecto_cero.ipynb

Matemática GCE: gce/paper/main.typ (cadena maestra / experimento canónico)

1.1 Introducción: Los Tres Niveles de Preguntas Causales

La inferencia causal contemporánea está fragmentada en tradiciones que rara vez comparten vocabulario. Los econométristas operan en el espacio de resultados potenciales (Imbens & Rubin, 2015; Rubin, 1974), mientras que los informáticos lo hacen en el de grafos causales (Pearl, 2009) — cada uno describiendo la misma realidad con herramientas que, en la superficie, parecen inconmensurables. Este capítulo propone un abordaje unificado: la **Geometría de la Causalidad Estadística** (GCE), que trata toda inferencia causal como un problema de comparación geométrica entre distribuciones.

Para visualizar esta unificación, consideremos un mismo tratamiento antihipertensivo administrado a una cohorte de pacientes con presión arterial elevada. Sobre ese escenario se formulan tres preguntas que operan a profundidades sucesivas:

1. ¿El medicamento reduce, en promedio, la presión arterial sistólica de la población tratada? (Nivel 1: Localización)
2. ¿El medicamento altera no solo el promedio, sino la forma completa de la distribución de presiones —su dispersión, la masa en las colas de riesgo cardiovascular o la aparición de subgrupos con respuestas opuestas? (Nivel 2: Forma)
3. ¿Cuál es el costo mínimo, medido en milímetros de mercurio por paciente, de transformar la distribución de salud observada antes del tratamiento en la distribución que se observa después? (Nivel 3: Geometría)

Este texto adopta la jerarquía GCE para organizar estos métodos bajo un marco coherente.

1.1.1 Conceptos Fundamentales: Resultados Potenciales y la Jerarquía GCE

La inferencia causal contemporánea, bajo el marco de resultados potenciales de Neyman-Rubin, parte de un objeto primitivo: cada unidad i posee dos resultados contrafactuales, $Y_i(1)$ bajo tratamiento y $Y_i(0)$ bajo control (Holland, 1986). El supuesto de SUTVA (Stable Unit Treatment Value Assumption) garantiza que estos resultados estén bien definidos, estableciendo la no interferencia ($Y_i(t_1, \dots, t_N) = Y_i(t_i)$) y la consistencia ($Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$). Esto permite definir las distribuciones poblacionales contrafactuales $\mathbb{P}_{Y(1)}$ y $\mathbb{P}_{Y(0)}$. En consecuencia, toda pregunta causal se reduce a un problema de comparación geométrica: estimar un funcional $\tau_{\mathcal{D}} = \mathcal{D}(\mathbb{P}_{Y(1)}, \mathbb{P}_{Y(0)})$ que mida la discrepancia entre estas dos medidas. La Geometría de la Causalidad Estadística (GCE) propone organizar esta comparación en tres

niveles de complejidad creciente: localización, forma y geometría, cada uno asociado a una familia de métricas $\mathcal{D}$ con propiedades axiomáticas específicas, cuyo nivel más general resuelve la Paradoja del Efecto Cero.

Nivel GCE	Pregunta central	Métrica / Instrumento	Bloque
Precondición ^[†]	¿Conocemos la estructura causal?	Validación de DAGs	III (20–27)
Nivel 1 · Localización	¿Cambió el centro?	$\tau_{ATE} = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$	I (1–12)
Nivel 2 · Forma	¿Cambió la distribución completa?	Divergencias: D_{KL} , D_{TV} , D_{χ^2}	II (13–19)
Nivel 3 · Geometría	¿Cuál es el costo mínimo del cambio?	Wasserstein W_1 y $W^{G,1}$	III–IV (20–32)

Tabla 3: Jerarquía GCE y su mapeo a la estructura del libro

† La Precondición es una fase *lógica* previa a todo análisis causal: sus supuestos (DAG, Markov, fidelidad) se invocan desde el Capítulo 1; sus métodos de descubrimiento automático (PC, FCI, GES) se desarrollan en el Bloque III (caps. 20–27).

La jerarquía GCE organiza los métodos de inferencia causal en niveles de complejidad creciente. El Nivel 1 (Localización) reduce la comparación a un funcional lineal unidimensional (τ_{ATE}), capturando solo desplazamientos en la media. El Nivel 2 (Forma) opera en el espacio de distribuciones completas mediante divergencias f , detectando cambios en varianza, multimodalidad y colas. El Nivel 3 (Geometría) generaliza ambos al cuantificar el costo mínimo de transformar una distribución en otra. En la siguiente sección, presentaremos cuatro axiomas fundamentales que una medida de discrepancia causal ideal debería satisfacer, y a lo largo del libro evaluaremos distintas propuestas (como la diferencia de medias, las divergencias f y las distancias basadas en transporte óptimo) a la luz de estos criterios. La jerarquía GCE opera bajo un supuesto implícito: el grafo causal $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ es conocido o asumido por el investigador, ya sea mediante diseño experimental, teoría de dominio o consenso disciplinar. Cuando $\mathcal{G}$ debe ser *aprendido* desde datos observacionales, el problema se desplaza a un espacio lógicamente previo: el del descubrimiento estructural. El Bloque III de este libro cubre precisamente ese espacio, no como un nivel adicional de la jerarquía GCE, sino como la *precondición* que convierte un problema de estructura desconocida en uno donde la jerarquía puede aplicarse:

- Los Bloques I y II asumen $\mathcal{G}$ conocido (por diseño o especificación teórica).
- El Bloque IV opera en el espacio de convergencia donde sistemas de inteligencia artificial infieren $\hat{\mathcal{G}}$ parcialmente y estiman efectos en los tres niveles de forma simultánea.

1.2 Filosofía Metodológica: Proofs-to-Python

Finalmente, este texto opera bajo la siguiente propuesta metodológica: cada teorema debe ejecutarse. Implementamos la filosofía **Proofs-to-Python**, donde cada resultado teórico se traduce en código verificable usando ecosistemas de vanguardia (*DoWhy*, *EconML*, *Causal-Learn*, *POT*). Exigimos, y facilitamos, el dominio simultáneo de la regla del 1+1+1^{''}: la demostración matemática, la intuición empírica (con especial atención a dinámicas del Global South) y la implementación computacional.

Al concluir, el lector no será solo un usuario de métodos causales, sino un arquitecto capaz de diseñar sistemas de inferencia con garantías formales—precisamente lo que distingue la ciencia de la ingeniería en la era de la IA. Esta obra aspira a cerrar la brecha entre la profundidad teórica de la econometría matemática y la agilidad práctica de la ciencia de datos, produciendo profesionales que no solo calculan efectos, sino que comprenden su geometría.

1.3 Mapeo Sistemático de la Jerarquía GCE a los 4 Bloques

La jerarquía GCE organiza los métodos de inferencia causal en tres niveles principales, precedidos por una precondition crítica. Cada nivel responde a un tipo específico de pregunta causal, utiliza métricas particulares para medir diferencias distribucionales, y se implementa en bloques específicos del libro.

Nivel GCE	Pregunta central	Métrica principal	Bloque	Métodos representativos
Precondición	¿Conocemos la estructura causal?	Validación de DAGs	III (20–27)	PC, FCI, GES, LiNGAM, NOTEARS
Nivel 1 · Localización	¿Cambió el centro?	$\tau_{ATE} = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$	I (1–12)	RCT, Matching, IPW, AIPW, IV, RDD, DiD
Nivel 2 · Forma	¿Cambió la distribución completa?	Divergencias: D_{KL} , D_{TV} , D_{χ^2}	II (13–19)	Mediación, QTE, efectos distribucionales
Nivel 3 · Geometría	¿Cuál es el costo mínimo del cambio?	Wasserstein W_1 y $W^{G,1}$	III–IV (20–32)	DML, Causal Forests, Meta-Learners

Tabla 4: Mapa completo de la jerarquía GCE

1.3.1 Nivel 1: Localización (Bloque I, Capítulos 1–12)

El nivel más básico de la jerarquía GCE se enfoca en cambios en el centro de la distribución. Responde a la pregunta: *¿El tratamiento movió el promedio?*

- **Métrica fundamental:** Average Treatment Effect (ATE)

$$\tau_{ATE} = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] \quad (1.3.1)$$

- **Supuestos clave:** SUTVA, CIA (Ignorabilidad Condicional), overlap, independencia fuerte (para RCT)
- **Limitación crítica: Ceguera estructural.** $\tau_{ATE} = 0$ no implica $P_{Y(1)} = P_{Y(0)}$. El ATE puede ser cero mientras las distribuciones completas difieren sustancialmente (Paradoja del Efecto Cero, Capítulo 1).
- **Métodos principales:** RCT (Cap. 2), Matching (Cap. 3), IPW/AIPW (Cap. 4), Variables Instrumentales (Cap. 5), RDD (Cap. 6), DiD (Cap. 7), Control Sintético (Cap. 8)

1.3.2 Nivel 2: Forma (Bloque II, Capítulos 13–19)

Cuando necesitamos ir más allá del promedio, el nivel 2 examina cambios en la forma completa de la distribución: varianza, asimetría, multimodalidad, colas.

- **Métricas fundamentales:** Divergencias f entre distribuciones

$$D_{f(P,Q)} = \int f\left(\frac{dP}{dQ}\right) dQ \quad (1.3.2)$$

donde casos especiales incluyen KL ($f(t) = t \log t$), TV ($f(t) = |t - 1|$), χ^2 ($f(t) = (t - 1)^2$).

- **Supuestos clave:** Ignorabilidad secuencial (para mediación), fidelidad del grafo causal
- **Limitación crítica: Requiere dominación absoluta** ($P \ll Q$). Las divergencias f son infinitas o indefinidas cuando los soportes son disjuntos.
- **Métodos principales:** Análisis de mediación (Cap. 14), efectos de tratamiento cuantílicos (QTE, Cap. 15), análisis de sensibilidad (Cap. 16)

1.3.3 Nivel 3: Geometría (Bloques III–IV, Capítulos 20–32)

El nivel más profundo considera la transformación completa entre distribuciones. Responde: *¿Cuál es el costo mínimo para transportar masa probabilística de $P_{Y(0)}$ a $P_{Y(1)}$?*

- **Métrica fundamental:** Distancia de Wasserstein de orden 1

$$W_1(P, Q) = \inf_{\gamma \in \Gamma(P, Q)} \int |x - y| d\gamma(x, y) \quad (1.3.3)$$

donde $\Gamma(P, Q)$ es el conjunto de acoplamientos con marginales P y Q .

- **Supuestos clave:** Bicausalidad, continuidad Lipschitz causal
- **Ventaja crítica: Robusta a soportes disjuntos.** A diferencia de las divergencias f , Wasserstein puede medir distancias entre distribuciones con soportes no superpuestos.
- **Métodos principales:** Double Machine Learning (Cap. 24), Causal Forests (Cap. 25), Meta-Learners (Cap. 23), transporte óptimo causal (Cap. 26)

1.3.4 Precondición: Descubrimiento Estructural (Bloque III, Capítulos 20–21)

Antes de cualquier análisis causal, debemos preguntarnos: *¿Conocemos la estructura causal subyacente?*

- **Métrica fundamental:** Validación empírica de DAGs aprendidos
- **Supuestos clave:** Markov causal, fidelidad (faithfulness)
- **Advertencia crítica: Riesgo de sesgo de modelo.** Los DAGs aprendidos automáticamente requieren validación rigurosa (Sección 21.3).
- **Métodos principales:** PC, FCI, GES (Cap. 21), NOTEARS, LiNGAM (Cap. 22)

1.4 Axiomas para una Medida de Discrepancia Causal

Para resolver la crisis de identificación inherente a los métodos tradicionales, no basta con seleccionar herramientas por conveniencia computacional; es imperativo exigir garantías formales. Proponemos que una medida de discrepancia causal $\mathcal{D}(\mathbb{P}_{Y(1)}, \mathbb{P}_{Y(0)})$ —que cuantifique la distancia entre las distribuciones contrafactuales— debería respetar cuatro axiomas fundamentales, inspirados en la teoría de decisiones robustas y en la noción intuitiva de costo de transformar una distribución en otra’.

Convención de Nivel 1. Para que el ATE sea comparable dentro de este marco axiomático (donde $\mathcal{D} \geq 0$), su instancia es el valor absoluto de la diferencia de medias:

$$\mathcal{D}_{\text{loc}}(\mathbb{P}, \mathbb{Q}) := |\mathbb{E}_{\mathbb{P}}[Y] - \mathbb{E}_{\mathbb{Q}}[Y]| = |\tau_{\text{ATE}}|. \quad (1.4.1)$$

El signo de τ_{ATE} se reporta por separado como información **direccional**.

Definición 1.1 (Axioma 1: Separación)

$$\mathcal{D}(\mathbb{P}, \mathbb{Q}) = 0 \Leftrightarrow \mathbb{P} = \mathbb{Q}.$$

Una medida de discrepancia debe ser capaz de distinguir distribuciones diferentes; si el valor es cero, las distribuciones son idénticas en todo punto. Este axioma garantiza la identificación única de la distribución intervenida.

Definición 1.2 (Axioma 2: Interpretabilidad como Costo de Reasignación)

$\mathcal{D}$ cuantifica el trabajo mínimo para transformar $\mathbb{P}$ en $\mathbb{Q}$.

En términos prácticos, responde a la pregunta: ¿cuánto cuesta, en unidades de la variable resultado, transformar la distribución control en la distribución tratamiento? La magnitud de $\mathcal{D}$ debe corresponder a una interpretabilidad física o económica concreta.

Definición 1.3 (Axioma 3: Robustez a Soporte Disjunto)

$\mathcal{D}$ está bien definida para $\mathbb{P} \perp \mathbb{Q}$.

Este axioma exige que la medida funcione incluso cuando las distribuciones tienen soportes que no se superponen, una condición frecuente en intervenciones donde tratamientos desplazan completamente los valores de la variable resultado. Muchas medidas tradicionales divergen a infinito en estos casos, volviéndose inaplicables.

Definición 1.4 (Axioma 4: Estabilidad de Funcionales Causales)

Para la clase $\mathcal{T}$ de funcionales causales de interés, existe $L < \infty$ tal que

$$|T(\mathbb{P}) - T(\mathbb{Q})| \leq L \cdot \mathcal{D}(\mathbb{P}, \mathbb{Q}) \quad \forall T \in \mathcal{T}. \quad (1.4.2)$$

Este axioma se desdobla según la clase $\mathcal{T}$:

1. **Axioma 4a (estabilidad marginal):** $\mathcal{T}$ = funcionales de las distribuciones marginales $\mathbb{P}_{Y(1)}, \mathbb{P}_{Y(0)}$ (medias, cuantiles, funcionales Lipschitz). W_1 lo satisface: la dualidad de Kantorovich–Rubinstein da $|\mathbb{E}_{\mathbb{P}}[f] - \mathbb{E}_{\mathbb{Q}}[f]| \leq |f|_{\text{Lip}} \cdot W_1(\mathbb{P}, \mathbb{Q})$. En particular, W_1 **metriza** la convergencia débil en $\mathcal{P}_1(\mathcal{Y})$ (Villani, 2009, Teorema 6.9).
2. **Axioma 4b (estabilidad intervencional):** $\mathcal{T}$ = funcionales que dependen de **distribuciones condicionales** dadas los padres en $\mathcal{G}$ (efectos do, CATE, valores de políticas secuenciales). W_1 **no** lo satisface; $W^{G,1}$, al restringir a acoplamientos bicausales, sí lo garantiza. **Hipótesis exactas pendientes de cotejo contra Cheridito & Eckstein (2025).**

La formulación antigua del Axioma 4 como mera continuidad respecto a convergencia débil¹ invertía las propiedades de W_1 y $W^{G,1}$: W_1 ya metriza la topología débil, mientras que las distancias bicausales inducen una topología **estrictamente más fina**.

Una medida de discrepancia $\mathcal{D}$ que satisfaga estos axiomas (con 4a y, cuando el problema es intervencional, 4b) constituiría un estándar ideal para la comparación de distribuciones contrafactuales. A lo largo de este libro, evaluaremos distintas propuestas (como $\mathcal{D}_{\text{loc}} = |\tau_{\text{ATE}}|$, las divergencias f y las distancias basadas en transporte óptimo) a la luz de estos criterios.

1.5 El Contrato Fundamental: SUTVA

La identificación del parámetro causal poblacional en el Nivel 3 presupone el cumplimiento de SUTVA, ya que sin el supuesto de no interferencia no existe un problema bien planteado de transporte óptimo entre distribuciones contrafactuales. La violación de este supuesto, común en programas como Juntos en Perú o Bolsa Familia en Brasil, donde los spillovers son endémicos, impide definir unívocamente los resultados potenciales individuales.

Definición 1.5 (SUTVA)

El marco de resultados potenciales requiere:

1. **No Interferencia:** El resultado potencial de la unidad i depende únicamente de su propia asignación:

$$Y_i(t_1, \dots, t_N) = Y_i(t_i) \quad \forall t \in \{0, 1\}^N \quad (1.5.1)$$

2. **Consistencia de Versiones:** El resultado observado corresponde al potencial de la asignación recibida:

$$Y_i = Y_i(T_i) = T_i Y_i(1) + (1 - T_i) Y_i(0) \quad (1.5.2)$$

Bajo SUTVA, cada unidad posee exactamente dos resultados potenciales bien definidos, de los cuales solo uno es observable. La inferencia causal consiste en reconstruir distribuciones de $Y(1)$ y $Y(0)$ a pesar de esta estructura de datos faltantes.

1.6 Nivel 1: El Average Treatment Effect y su Ceguera Estructural

El paradigma dominante, el Average Treatment Effect (τ_{ATE}), opera exclusivamente en el espacio de las medias $\mathbb{R}$. Aunque computacionalmente eficiente, este funcional lineal tiene una insuficiencia estructural: no satisface el Axioma 1 de Separación. El ATE es definido como la diferencia de medias:

$$\tau_{\text{ATE}} := \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]. \quad (1.6.1)$$

Proposición 1.1 (Invarianza del ATE ante Transformaciones Simétricas)

Si una transformación $\mathcal{T}$ de la distribución de resultados mantiene su media ($\mathbb{E}[\mathcal{T}(Y)] = \mathbb{E}[Y]$), entonces el efecto promedio τ_{ATE} es cero, aunque $\mathcal{T}$ altere profundamente la forma de la distribución.

Corolario 1.1 (Ceguera de Nivel 1)

El ATE no satisface el Axioma 1 de Separación: $\tau_{\text{ATE}} = 0$ no implica $\mathbb{P}_{Y(1)} = \mathbb{P}_{Y(0)}$.

Una reforma tributaria que simultáneamente eleve los ingresos de los estratos altos y reduzca los de los medios, con efecto promedio nulo, ilustra la Paradoja del Efecto Cero: el ATE oculta una reconfiguración estructural del bienestar.

1.7 Nivel 2: Divergencias f y Cambios en la Forma Distributiva

Mientras el Nivel 1 opera en el espacio de las medias $\mathbb{R}$, el Nivel 2 considera la distribución completa $\mathbb{P}_Y$. Las divergencias f (Csiszár, 1967) cuantifican diferencias en forma, varianza, multimodalidad y colas:

$$\mathcal{D}_{f(\mathbb{P}, \mathbb{Q})} = \mathbb{E}_{Y \sim q} \left[f \left(\frac{p(Y)}{q(Y)} \right) \right], \quad (1.7.1)$$

donde p y q son las funciones de densidad de las distribuciones $\mathbb{P}$ y $\mathbb{Q}$, respectivamente, y $f: \mathbb{R}_+ \rightarrow \mathbb{R}$ es convexa con $f(1) = 0$ que mide la divergencia de la razón $\frac{p(y)}{q(y)}$. Casos especiales incluyen:

- Kullback-Leibler: $f(t) = t \log t$
- χ^2 : $f(t) = (t - 1)^2$
- Total Variation: $f(t) = \frac{1}{2}|t - 1|$

La divergencia D_f no es una métrica ya que carece de simetría ($D_{f(p,q)} \neq D_{f(q,p)}$) y no satisface la

desigualdad triangular. En contraste, veremos que W_1 es un funcional métrico completo en $\mathcal{P}_1(\mathcal{Y})^1$. La divergencia $D_{f(\mathbb{P}, \mathbb{Q})}$ requiere $\mathbb{P} \ll \mathbb{Q}$ (absoluta continuidad). Cuando $\mathbb{P} \perp \mathbb{Q}$ (soportes disjuntos), $D_f = \infty$ mientras que $W_1 < \infty$ si existe primer momento.

Ejemplo 1.1 (Paradoja del ATE-nulo con cambio de varianza)

Sea $\mathbb{P}_0 = \mathcal{N}(0, 1)$ y $\mathbb{P}_1 = \mathcal{N}(0, \sigma^2)$ con $\sigma^2 \neq 1$. Entonces:

$$\tau_{\text{ATE}} = 0D_{\{\text{KL}\}}(\mathbb{P}_0, \mathbb{P}_1) = \frac{1}{2} \left(\log \sigma^2 + \frac{1}{\sigma^2} - 1 \right) > 0 \quad \text{para } \sigma^2 \neq 1 \quad (1.7.2)$$

El ATE reporta efecto nulo mientras la divergencia KL detecta cambio distributivo en la varianza.

Más allá de su uso como medida de distancia entre distribuciones, las divergencias f permiten formular modelos de sensibilidad ante confusión no medida. La idea central es imponer una cota superior en la divergencia f entre las distribuciones condicionales del factor de confusión U dado el tratamiento, lo que se conoce como la *condición de selección* (f, ρ) . Bajo esta restricción, las cotas identificables para los efectos causales surgen naturalmente de problemas de optimización dual análogos a la dualidad de Kantorovich.

1.8 Nivel 3: Transporte Óptimo y la Paradoja Resuelta

Para superar la incompletitud del Nivel 1, introducimos la métrica de Wasserstein-1 (W_1). Esta métrica no es solo una herramienta estadística, sino la formalización matemática del costo mínimo de reestructuración de masa probabilística, heredera del problema del transportista de Kantorovich.

Sea $(\mathcal{Y}, d)$ un espacio métrico polaco. Denotamos por $\mathcal{P}_1(\mathcal{Y})$ el espacio de medidas de probabilidad con primer momento finito.

Definición 1.6 (Distancia de Wasserstein-1)

La distancia de Wasserstein-1 entre distribuciones $\mathbb{P}$ y $\mathbb{Q}$ es el costo mínimo de transporte:

$$W_1(\mathbb{P}, \mathbb{Q}) = \inf_{\gamma \in \Gamma(\mathbb{P}, \mathbb{Q})} \mathbb{E}_{(X, Y) \sim \gamma} \|X - Y\| = \sup_{\{f \mid |f|_{\text{Lip}} \leq 1\}} (\mathbb{E}_{\mathbb{P}}[f] - \mathbb{E}_{\mathbb{Q}}[f]), \quad (1.8.1)$$

donde el ínfimo se toma sobre todos los acoplamientos γ con marginales $\mathbb{P}$ y $\mathbb{Q}$:

$$\Gamma(\mathbb{P}, \mathbb{Q}) = \{\gamma \in \mathcal{P}(\mathcal{Y} \times \mathcal{Y}) : \gamma(A \times \mathcal{Y}) = \mathbb{P}(A), \gamma(\mathcal{Y} \times B) = \mathbb{Q}(B) \quad \forall A, B \in \mathcal{B}\}. \quad (1.8.2)$$

La distancia de Wasserstein-1 permite detectar lo que el ATE oculta. El siguiente resultado exhibe un caso concreto donde ambas métricas discrepan de forma extrema.

Proposición 1.2 (Paradoja del Efecto Cero - Versión Simplificada)

Sean $\mathbb{P}_0 = \mathcal{N}(0, 1)$ y $\mathbb{P}_1 = \frac{1}{2}\mathcal{N}(-a, \sigma^2) + \frac{1}{2}\mathcal{N}(a, \sigma^2)$ con $a > 0$. Entonces:

$$\mathbb{E}_{\mathbb{P}_1}[Y] - \mathbb{E}_{\mathbb{P}_0}[Y] = 0, \quad W_1(\mathbb{P}_1, \mathbb{P}_0) \geq a - \sqrt{\frac{2}{\pi}} > 0 \quad \text{para } a > \sqrt{\frac{2}{\pi}} \quad (1.8.3)$$

¹Más precisamente: si $(\mathcal{Y}, d)$ es un espacio métrico polaco (completo y separable), entonces $(\mathcal{P}_1(\mathcal{Y}), W_1)$ es también un espacio métrico polaco. Ver Villani (2009, Teorema 6.18).

Demostración.

Paso 1 (ATE nulo): Por simetría de $\mathbb{P}_1$ en torno a 0, $\mathbb{E}_{\mathbb{P}_1}[Y] = 0 = \mathbb{E}_{\mathbb{P}_0}[Y]$.

Paso 2 (cota inferior de W_1): La formulación dual con la función de prueba 1-Lipschitz $f(y) = |y|$ da

$$W_1(\mathbb{P}_1, \mathbb{P}_0) \geq \int |y| d\mathbb{P}_1(y) - \int |y| d\mathbb{P}_0(y). \quad (1.8.4)$$

Para $\mathbb{P}_0$: $\int |y| d\mathbb{P}_0 = \mathbb{E}[|Z|] = \sqrt{2/\pi}$ con $Z \sim \mathcal{N}(0, 1)$.

Para $\mathbb{P}_1$: por la desigualdad de Jensen aplicada a la función convexa $|\cdot|$,

$$\int |y| d\mathbb{P}_1 = \mathbb{E}[|a + \sigma Z|] \geq |\mathbb{E}[a + \sigma Z]| = a. \quad (1.8.5)$$

Por tanto $W_1(\mathbb{P}_1, \mathbb{P}_0) \geq a - \sqrt{2/\pi}$, estrictamente positiva cuando $a > \sqrt{2/\pi}$. □

□

Vale la pena notar que **no** aparece en la cota: σ . La discrepancia depende solo de la separación a entre las modas, no de cuánto se disperse cada componente internamente — la demostración vía Jensen descarta la dispersión desde el primer paso.

Definición 1.7 (Distancia de Wasserstein-1 Causal ($W^{G,1}$))

Para un grafo causal $\mathcal{G}$ (dirigido acíclico y ordenado), la distancia $W^{G,1}$ entre medidas μ y ν es el costo mínimo de transporte restringido a acoplamientos *bicausales* que respetan la filtración inducida por $\mathcal{G}$ (Cheridito & Eckstein, 2025):

$$W^{G,1}(\mu, \nu) = \inf_{\pi \in \Pi_{G(\mu, \nu)}^{bc}} \int |x - y| d\pi(x, y), \quad (1.8.6)$$

donde $\Pi_{G(\mu, \nu)}^{bc}$ denota el conjunto de acoplamientos bicausales tales que preservan las distribuciones condicionales dadas los padres en $\mathcal{G}$:

$$\Pi_{G(\mu, \nu)}^{bc} := \{\pi \in \Gamma(\mu, \nu) : \pi(dy_t | \mathbf{x}_{pa(t)}) \text{ respeta filtración causal}\}. \quad (1.8.7)$$

Como $\Pi_{G(\mu, \nu)}^{bc} \subseteq \Gamma(\mu, \nu)$, se tiene siempre $W^{G,1} \geq W_1$. Esta restricción es la que habilita el **Axioma 4b** (estabilidad intervencional): funcionales que dependen de condicionales dados los padres en $\mathcal{G}$ son Lipschitz bajo $W^{G,1}$, no bajo W_1 ordinaria. **Ver Cheridito & Eckstein (2025)**. Nótese que el ATE ya es 1-Lipschitz respecto de W_1 (Axioma 4a) y **no** es el ejemplo motivador de $W^{G,1}$.

Con estas definiciones en mano, podemos verificar formalmente qué axiomas satisface cada métrica de discrepancia causal.

Corolario 1.2 (Teorema de Completitud Geométrica (Nivel 3))

La distancia de Wasserstein-1 W_1 satisface los Axiomas 1, 2, 3 y **4a** (estabilidad marginal). La distancia causal $W^{G,1}$ satisface adicionalmente el Axioma **4b** (estabilidad intervencional). En particular, **no** se atribuye a $W^{G,1}$ la metrización de la convergencia débil ordinaria — esa es propiedad de W_1 — sino la estabilidad Lipschitz de funcionales intervencionales que W_1 no garantiza.

1.9 Verificación Computacional: La Dualidad en Acción

Validamos los teoremas de incompletitud y completitud mediante demostración constructiva en el laboratorio computacional. El siguiente código verifica empíricamente que la cota dual de Kantorovich-Rubinstein se sostiene y cuantifica la magnitud del error epistémico del Nivel 1.

La simulación confirma $\tau_{ATE} \approx 0$ (-0.14 mmHg, indistinguible de ruido muestral) frente a $W_1 \approx 6.05$ mmHg; el tratamiento debe reorganizar, en promedio, unos 6 mmHg de presión arterial por paciente para transformar la distribución control en la tratada, pese a que el promedio poblacional no se mueve. La verificación de la desigualdad dual ($cota_dual \leq W_1$) valida numéricamente la estructura teórica propuesta.

1.10 Genealogía del Transporte Óptimo: De Monge a la Inferencia Causal

El problema de cuantificar el costo mínimo de transformar una distribución en otra tiene sus raíces en la ingeniería civil del siglo XVIII. Monge (1781) planteó un problema determinista de reasignación puntual de masa, cuya formulación resultó intratable para espacios generales. La ruptura conceptual llegó con Kantorovich (1942), quien introdujo una relajación probabilística que permitió dividir y redistribuir masa, transformando el problema en uno de programación lineal en espacios de medidas. La centralidad del transporte óptimo se confirma por su adopción en múltiples disciplinas: Galichon (2016) la integró en la econometría estructural; Chernozhukov et al. (2017) la emplearon para inferencia semiparamétrica robusta; Arjovsky et al. (2017) la adaptaron al entrenamiento de redes generativas; y Shi et al. (2019) la aplicaron a la estimación causal bajo heterogeneidad no observada. Este linaje culmina con la introducción de la distancia Wasserstein causal $W^{G,1}$ (Cheridito & Eckstein, 2025), que impone la restricción de bicausalidad para respetar la estructura de un grafo causal $\mathcal{G}$.

Nivel	¿Qué Mide? / Cómo lo Mide?	Diferencia Formulación
1. Localización	- Qué: Desplazamiento del centroide. - Cómo: $\mu_1 - \mu_0$ sobre $\mathbb{R}$.	Opera solo con escalares; ignora varianza, forma, soporte. No distingue distribuciones distintas si tienen misma media.
2. Forma	- Qué: Cambio en forma distributiva. - Cómo: Discrepancia punto a punto $f\left(\frac{p}{q}\right)$ vía L^1.	Cada $y \in \mathcal{Y}$ se evalúa independientemente; sin conexión métrica espacial entre valores distintos. Requiere $\mathbb{P} \ll \mathbb{Q}$.
3. Geometría	- Qué: Costo físico de transformar medidas. - Cómo: $\inf_{\gamma} \mathbb{E}_{\gamma} [d(X, Y)]$ en $\Gamma(\mathbb{P}, \mathbb{Q})$.	Integra explícitamente métrica $d(x, y)$ del espacio; compara acoplamientos completos, no densidades puntuales. Robusto a soportes disjuntos.

Tabla 5: Resumen compacto de la jerarquía GCE por nivel. La evolución avanza desde comparaciones puntuales hasta costo estructural completo.

1.11 Cierre del capítulo

Este capítulo abrió la monografía con la tesis GCE: el ATE puede ser ciego y W_1 acota $|\tau_{ATE}|$. La Paradoja del Efecto Cero no es un contratiempo numérico, sino la justificación de subir de localización a geometría.

1.11 Referencias

Arjovsky, M., Chintala, S., & Bottou, L. (2017). Wasserstein GAN. *Proceedings of the 34th International Conference on Machine Learning (ICML)*.

- Cheridito, P., & Eckstein, S. (2025). Optimal transport and Wasserstein distances for causal models. *Bernoulli*, 31(2), 1351-1376.
- Chernozhukov, V., Galichon, A., Hallin, M., & Henry, M. (2017). Monge–Kantorovich Depth, Quantiles, Ranks and Signs. *The Annals of Statistics*, 45(1), 223-256.
- Csiszár, I. (1967). Information-type measures of difference of probability distributions and indirect observation. *Studia Scientiarum Mathematicarum Hungarica*, 2, 299-318.
- Galichon, A. (2016). *Optimal Transport Methods in Economics*. Princeton University Press.
- Holland, P. W. (1986). Statistics and Causal Inference. *Journal of the American Statistical Association*, 81(396), 945-960.
- Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- Kantorovich, L. V. (1942). On the Translocation of Masses. *Doklady Akademii Nauk SSSR*, 37(7–8), 199-201.
- Monge, G. (1781). Mémoire sur la théorie des déblais et des remblais. *Histoire de l'Académie Royale des Sciences de Paris*.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Rubin, D. B. (1974). Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies. *Journal of Educational Psychology*, 66(5), 688-701.
- Shi, C., Blei, D. M., & Veitch, V. (2019). Adapting Neural Networks for the Estimation of Treatment Effects. *Advances in Neural Information Processing Systems (NeurIPS)*.
- Villani, C. (2009). *Optimal Transport: Old and New*. Springer.

CAPÍTULO 2

El Problema Fundamental y la Relevancia de la Aleatorización

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42

Notebook (pack): notebooks/Bloque_I/notebooks/02_problema_fundamental_relevancia_aleatorizacion.ipynb

Jupyter Book: jupyter_book/content/bloque_01_fundamentacion/02_problema_fundamental.ipynb

2.1 El Problema Fundamental de la Inferencia Causal

La inferencia causal se fundamenta en una limitación lógica insalvable: para una misma unidad, es imposible observar simultáneamente sus resultados bajo tratamiento y bajo control. Esto no es solo una restricción práctica, sino el núcleo del *Problema Fundamental de la Inferencia Causal* (Holland, 1986). Formalmente, enfrentamos un problema de reconstrucción: debemos recuperar la distribución conjunta completa de los resultados potenciales $(Y_i(0), Y_i(1))$ (Rubin, 1974) a partir de observaciones parciales donde, para cada unidad, solo vemos una de las dos coordenadas (Imbens & Rubin, 2015).

Definición 2.1 (Vector de Resultados Potenciales)

Para cada unidad $i \in \{1, \dots, N\}$ y cada nivel de tratamiento $t \in \mathcal{T}$, definimos el resultado potencial $Y_i(t) : \Omega \rightarrow \mathcal{Y}$ como una variable aleatoria en el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$. El vector completo de resultados potenciales es:

$$\mathbf{Y}_i = (Y_i(t))_{t \in \mathcal{T}} \in \mathcal{Y}^{|\mathcal{T}|}. \quad (2.1.1)$$

Bajo tratamiento binario $\mathcal{T} = \{0, 1\}$, el vector se reduce a $(Y_i(0), Y_i(1))$.

El vector completo de resultados potenciales es un objeto contrafactual. En la práctica solo observamos una coordenada: aquella que corresponde a la asignación efectivamente recibida. Antes de definir el resultado observado, establecemos el supuesto que da sentido a la notación.

Definición 2.2 (SUTVA (Stable Unit Treatment Value Assumption))

Asumimos SUTVA: (i) **no interferencia** — el tratamiento de la unidad j no afecta el resultado de la unidad i ; (ii) **no versiones múltiples del tratamiento**. Bajo SUTVA, $Y_i(t)$ está bien definido y el resultado observado satisface la ecuación de consistencia.

Definición 2.3 (Resultado Observado y Datos Faltantes)

Sea $T_i \in \{0, 1\}$ la indicadora de asignación al tratamiento. El resultado observado sigue la ecuación de consistencia:

$$Y_i^{\{\text{obs}\}} = T_i Y_i(1) + (1 - T_i) Y_i(0). \quad (2.1.2)$$

De manera análoga, el contrafactual no observado para la unidad i es:

$$Y_i^{\{\text{miss}\}} = (1 - T_i) Y_i(1) + T_i Y_i(0). \quad (2.1.3)$$

Definiendo el efecto causal individual $\tau_i = Y_i(1) - Y_i(0)$, se tiene que τ_i es inherentemente no observable.

Dado que el efecto individual τ_i es inherentemente no observable, la inferencia causal traslada su atención a promedios poblacionales que sí admiten estimación.

Definición 2.4 (Efectos Causales Poblacionales)

Dado que los efectos individuales son no observables, la inferencia se orienta a parámetros agregados:

$$\begin{aligned} \tau_{\text{ATE}} &= \mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[\tau_i] \\ \tau_{\text{ATT}} &= \mathbb{E}[Y(1) - Y(0) \mid T = 1] \\ \tau_{\text{ATU}} &= \mathbb{E}[Y(1) - Y(0) \mid T = 0] \end{aligned} \quad (2.1.4)$$

donde τ_{ATE} denota *Average Treatment Effect*, τ_{ATT} *Average Treatment Effect on the Treated*, y τ_{ATU} *Average Treatment Effect on the Untreated*.

2.2 Anatomía del Sesgo de Selección

En la evaluación de políticas públicas, comparar directamente los resultados de grupos tratados y no tratados rara vez proporciona el efecto causal verdadero. La diferencia cruda de medias no es un estimador causal, sino una mezcla confusa entre el impacto real de la intervención y la heterogeneidad basal del sistema.

Teorema 2.1 (Descomposición del Sesgo de Selección)

La diferencia de medias observacionales entre tratados y no tratados puede descomponerse como:

$$\begin{aligned} \mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0] &= \underbrace{\tau_{\text{ATE}}}_{\text{Efecto Causal}} \\ &+ \underbrace{\mathbb{E}[Y(0) \mid T = 1] - \mathbb{E}[Y(0) \mid T = 0]}_{\text{Sesgo de Selección}} + \underbrace{(\tau_{\text{ATT}} - \tau_{\text{ATU}}) \cdot \mathbb{P}(T = 0)}_{\text{Componente de Heterogeneidad}}. \end{aligned} \quad (2.2.1)$$

Derivación. Partimos de la diferencia de medias observacionales y aplicamos la ecuación de consistencia ($Y = TY(1) + (1 - T)Y(0)$):

$$\mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0] = \mathbb{E}[Y(1) \mid T = 1] - \mathbb{E}[Y(0) \mid T = 0]. \quad (2.2.2)$$

Sumamos y restamos $\mathbb{E}[Y(0) \mid T = 1]$:

$$= \underbrace{\mathbb{E}[Y(1) \mid T = 1] - \mathbb{E}[Y(0) \mid T = 1]}_{\tau_{\text{ATT}}} + \underbrace{\mathbb{E}[Y(0) \mid T = 1] - \mathbb{E}[Y(0) \mid T = 0]}_{\text{Sesgo de Selección}}. \quad (2.2.3)$$

Por esperanza total, $\tau_{\text{ATE}} = \mathbb{P}(T = 1)\tau_{\text{ATT}} + \mathbb{P}(T = 0)\tau_{\text{ATU}}$, lo cual es algebraicamente equivalente a

$$\tau_{\text{ATT}} = \tau_{\text{ATE}} + \mathbb{P}(T = 0) \cdot (\tau_{\text{ATT}} - \tau_{\text{ATU}}). \quad (2.2.4)$$

Sustituyendo τ_{ATT} por esta expresión y reagrupando términos se obtiene la descomposición de tres términos del enunciado.

El sesgo de selección $\mathbb{E}[Y(0) \mid T = 1] - \mathbb{E}[Y(0) \mid T = 0]$ cuantifica cuán diferentes serían los tratados incluso si no hubieran recibido el tratamiento. El Componente de Heterogeneidad, en cambio, **no es un sesgo en sentido estadístico**: no desaparece al aumentar la muestra ni al mejorar el diseño. Refleja que el efecto causal difiere entre tratados y no tratados. Se anula solo bajo homogeneidad ($\tau_{ATT} = \tau_{ATU}$) o cuando $\mathbb{P}(T = 0) \rightarrow 0$.

2.2.1 Identificabilidad de un parámetro causal

Antes de abordar cómo la aleatorización (Fisher, 1935) resuelve el problema fundamental, es preciso definir qué significa que un parámetro causal pueda ser recuperado a partir de los datos observados.

Definición 2.5 (Identificabilidad)

Decimos que un parámetro causal θ (por ejemplo, τ_{ATE} , una divergencia f o la distancia W_1) es **identificable** a partir de la distribución observada $\mathbb{P}(Y, T, \mathbf{X})$ si existe un funcional Φ tal que:

$$\theta = \Phi(\mathbb{P}(Y, T, \mathbf{X})). \quad (2.2.5)$$

En otras palabras, θ puede expresarse exclusivamente en términos de cantidades que podemos estimar de los datos observados, sin depender de contrafactuales no observados.

Bajo el supuesto de independencia fuerte $(Y(0), Y(1)) \perp T$, demostraremos que τ_{ATE} es identificable. Más aún, como veremos a continuación, también lo son las divergencias f y la distancia de Wasserstein, ya que las distribuciones contrafactuales se vuelven directamente observables.

2.3 La Independencia Causal y el Mecanismo RCT

Los Ensayos Controlados Aleatorizados (RCT) ofrecen la solución más directa al problema de identificación causal. Al asignar el tratamiento mediante un proceso aleatorio, se rompe deliberadamente cualquier vínculo sistemático entre la asignación T y las características observables o latentes de las unidades.

Definición 2.6 (Ignorabilidad Completa)

El mecanismo de asignación aleatorizada satisface la independencia fuerte cuando:

$$(Y(0), Y(1)) \perp\!\!\!\perp T, \quad (2.3.1)$$

es decir, el vector completo de resultados potenciales es estadísticamente independiente de la asignación al tratamiento.

La independencia fuerte es la condición que convierte una comparación observacional en una identificación causal. El siguiente teorema formaliza esta conexión.

Teorema 2.2 (Identificación del τ_{ATE} bajo Aleatorización)

Bajo independencia fuerte $(Y(0), Y(1)) \perp\!\!\!\perp T$, el estimador de diferencia de medias observacionales es idénticamente igual al τ_{ATE} poblacional:

$$\mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0] = \tau_{ATE}. \quad (2.3.2)$$

Corolario 2.1 (Balance de Covariables)

Para cualquier vector de covariables $\mathbf{X}$ (pre-tratamiento), la independencia fuerte implica $\mathbf{X} \perp\!\!\!\perp T$, por tanto $\mathbb{E}[\mathbf{X} \mid T = 1] = \mathbb{E}[\mathbf{X} \mid T = 0]$.

2.4 RCT como Nivel 1 en la Jerarquía GCE

Aunque los RCTs resuelven elegantemente el problema de identificación del efecto causal promedio, operan exclusivamente en el **Nivel 1 de la Jerarquía GCE**: la *Localización* centrada en cambios en la media.

Proposición 2.1 (Insuficiencia del ATE como Resumen Distribucional)

Sea un RCT con asignación aleatoria perfecta. El estimador $\hat{\tau}_{\text{ATE}} = \bar{Y}_1 - \bar{Y}_0$ converge en probabilidad a $\tau_{\text{ATE}} = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)]$. Sin embargo, $\hat{\tau}_{\text{ATE}} \xrightarrow{p} 0$ no implica $\mathbb{P}_{Y(1)} = \mathbb{P}_{Y(0)}$.

Incluso con asignación perfectamente aleatoria, el tratamiento puede alterar la varianza, inducir polarización o cambiar las colas de la distribución sin mover la media. Esta limitación no es del diseño RCT —que identifica la distribución completa— sino del parámetro ATE como resumen: el RCT resuelve la identificación, no la insuficiencia del Nivel 1.

2.4.1 Estimadores para los tres niveles GCE bajo aleatorización

Cuando se cumple la independencia fuerte, las distribuciones contrafactuales son directamente observables: $\mathbb{P}_{Y(1)} = \mathbb{P}_{Y \mid T=1}$ y $\mathbb{P}_{Y(0)} = \mathbb{P}_{Y \mid T=0}$. En consecuencia, cualquier funcional que dependa únicamente de estas dos distribuciones es identificable. A continuación, presentamos estimadores naturales para cada nivel de la jerarquía GCE.

- **Nivel 1 – ATE (Localización):** El estimador de diferencia de medias muestrales es insesgado:

$$\hat{\tau}_{\text{ATE}} = \frac{1}{n_1} \sum_{i:T_i=1} Y_i - \frac{1}{n_0} \sum_{i:T_i=0} Y_i, \quad \mathbb{E}[\hat{\tau}_{\text{ATE}}] = \tau_{\text{ATE}}. \quad (2.4.1)$$

Su varianza, derivada por Neyman (1923), es:

$$\text{Var}(\hat{\tau}_{\text{ATE}}) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_0^2}{n_0} - \frac{\sigma_\tau^2}{N}, \quad (2.4.2)$$

donde $\sigma_1^2 = \text{Var}(Y(1))$, $\sigma_0^2 = \text{Var}(Y(0))$, $\sigma_\tau^2 = \text{Var}(\tau_i)$ y $N = n_0 + n_1$. El término σ_τ^2 no es observable, pues depende de la covarianza entre $Y(1)$ y $Y(0)$, nunca observados conjuntamente. En la práctica se usa la cota conservadora

$$\widehat{\text{Var}}(\hat{\tau}_{\text{ATE}}) = \frac{s_1^2}{n_1} + \frac{s_0^2}{n_0}, \quad (2.4.3)$$

y el intervalo de confianza $\hat{\tau}_{\text{ATE}} \pm z_{\alpha/2} \sqrt{\widehat{\text{Var}}(\hat{\tau}_{\text{ATE}})}$.

- **Nivel 2 – Divergencia f (Forma):** Para la divergencia de Kullback-Leibler, un estimador **plug-in** consistente (asintóticamente insesgado) es:

$$\hat{D}_{\text{KL}} = \frac{1}{n_1} \sum_{i:T_i=1} \log \frac{\hat{p}_1(Y_i)}{\hat{p}_0(Y_i)}, \quad (2.4.4)$$

donde $\hat{p}_t$ es un estimador de densidad para el grupo t . En los ejemplos computacionales usamos el estimador de histograma con celdas comunes: dado un conjunto de celdas $B_1, \dots, B_K$ (bins), se

define $\hat{p}_{t(Y_i)} = \hat{f}_{t(b_k)}$ con $\hat{f}_{t(b_k)} = \frac{n_{t,k}}{n_t \Delta_k}$ para la celda b_k que contiene Y_i , donde $n_{t,k}$ es el número de observaciones del grupo t en esa celda y Δ_k su anchura. Una alternativa es el estimador kernel ($\hat{p}_{t(y)} = \frac{1}{n_t h} \sum_i K\left(\frac{Y_i - y}{h}\right)$), con convergencia más suave pero dependiente del ancho de banda h . Ambos son consistentes cuando $n \rightarrow \infty$; en muestras finitas presentan sesgo positivo.

Advertencia (Soporte). La divergencia KL está definida solo si $P_1 \ll P_0$. Si existe una celda k con $n_{0,k} = 0$ y $n_{1,k} > 0$, el estimador plug-in produce $\hat{D}_{KL} = +\infty$. En la práctica se usa suavizado de Laplace ($n_{t,k} + 1$) o se verifica el soporte común antes de estimar. Este problema no ocurre con divergencias simétricas como Jensen-Shannon o Hellinger.

- **Nivel 3 – Distancia de Wasserstein-1 (Geometría):** En una dimensión, el estimador plug-in se define mediante las funciones de distribución empíricas:

$$\widehat{W}_1 = \int_{-\infty}^{\infty} |\hat{F}_1(y) - \hat{F}_0(y)| \, d y, \quad (2.4.5)$$

donde $\hat{F}_t(y) = \frac{1}{n_t} \sum_{i: T_i=t} \mathbf{1}\{Y_i \leq y\}$. Este estimador es **consistente** (converge en probabilidad a W_1 cuando $n_0, n_1 \rightarrow \infty$), pero no es insesgado en muestras finitas: incluso si $W_1 = 0$, $\widehat{W}_1 > 0$ casi seguramente debido a las diferencias muestrales. En la práctica, se utiliza tal cual y su sesgo disminuye con el tamaño muestral.

El siguiente código implementa estos tres estimadores sobre los datos generados por el RCT, permitiendo comparar sus magnitudes y comprender qué información adicional entrega cada nivel.

2.5 Implementación Computacional: Simulación de Sesgo y RCT

Ejemplo 2.1 (Sesgo de selección en Pensión 65)

El MIDIS evalúa si Pensión 65 aumenta el consumo de adultos mayores. La comparación directa entre beneficiarios y no beneficiarios está sesgada: los hogares más pobres y aislados tienen mayor probabilidad de ser elegibles ($\mathbb{E}[Y(0) | T = 1] < \mathbb{E}[Y(0) | T = 0]$). El sesgo de selección es *negativo* — sin corrección, el programa aparece con impacto nulo o incluso negativo. Un piloto RCT en 200 distritos aleatorios elimina el sesgo al garantizar $(Y(0), Y(1)) \perp T$.

Supuestos clave

Supuestos del Capítulo 2 (RCT e Identificación Básica)

1. **SUTVA** (recordatorio; ver definición al inicio del capítulo): no interferencia y no versiones múltiples del tratamiento.
2. **Independencia Fuerte:** $(Y(0), Y(1)) \perp\!\!\!\perp T$ — la asignación al tratamiento es independiente de los resultados potenciales.
3. **Soporte Común:** $0 < \mathbb{P}(T = 1) < 1$, existen unidades tratadas y control en la población.

2.6 Cierre del capítulo

Este capítulo fijó el problema fundamental y el papel de la aleatorización como garante de identificabilidad del ATE. Los capítulos siguientes desarrollan estrategias que, sin aleatorización, reconstruyen el contrafactual bajo supuestos explícitos.

2.6 Referencias



- Fisher, R. A. (1935). *The Design of Experiments*. Oliver, Boyd.
- Holland, P. W. (1986). Statistics and Causal Inference. *Journal of the American Statistical Association*, 81(396), 945-960.
- Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- Rubin, D. B. (1974). Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies. *Journal of Educational Psychology*, 66(5), 688-701.

CAPÍTULO 3

El Arte del Matching: Dimensiones y Distancias

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42**Notebook (pack):** notebooks/Bloque_I/notebooks/03_arte_matching_dimensiones_distancias.ipynb**Jupyter Book:** jupyter_book/content/bloque_01_fundamentacion/03_arte_matching.ipynb

3.1 El Supuesto de Independencia Condicional (CIA)

El marco de selección sobre observables requiere que, condicional a un conjunto de covariables $X \in \mathcal{X} \subseteq \mathbb{R}^p$, la asignación al tratamiento sea independiente de los resultados potenciales. Esta condición habilita la identificación del ATE sin necesidad de aleatorización experimental.

En ausencia de aleatorización, común en contextos de política pública en el Sur Global, como programas de transferencias condicionadas en el Perú rural o capacitación laboral en Lima, la identificación causal se sustenta en el supuesto de Independencia Condicional (CIA). Este supuesto exige que, si se observaran todas las covariables X que influyen en la probabilidad de recibir tratamiento y en el resultado de interés, el tratamiento sería asignado aleatoriamente dentro de cada subgrupo homogéneo de tales características. La función de esta hipótesis es restablecer el equilibrio estadístico que la aleatorización proporciona por diseño.

Definición 3.1 (Independencia Condicional (CIA))

El supuesto de Independencia Condicional, también denominado Ignorabilidad o Unconfoundedness, establece que²:

$$(Y(1), Y(0)) \perp\!\!\!\perp T \mid X \quad (3.1.1)$$

Equivalentemente en términos de la función de probabilidad acumulada, para todo $x \in \mathcal{X}$ y todo $(y_1, y_0) \in \mathcal{Y}^2$:

$$\mathbb{P}(Y(1) \leq y_1, Y(0) \leq y_0 \mid T = 1, X = x) = \mathbb{P}(Y(1) \leq y_1, Y(0) \leq y_0 \mid T = 0, X = x) \quad (3.1.2)$$

El CIA implica que, dentro de subpoblaciones homogéneas en X , la asignación al tratamiento es como si fuera aleatoria. Las diferencias sistemáticas entre tratados y no tratados quedan completamente explicadas por la distribución de X .

Teorema 3.1 (Identificación del ATE bajo CIA)

Si se satisface el supuesto de Independencia Condicional y la condición de soporte común $0 < \mathbb{P}(T = 1 \mid X = x) < 1$ para todo $x \in \mathcal{X}$, entonces el ATE es identificable a partir de la distribución observacional de (Y, T, X) .

²En esta definición utilizamos la notación poblacional $Y(t)$ (sin subíndice) para denotar las variables aleatorias que representan los resultados potenciales en toda la población. La versión con subíndice $Y_{i(t)}$ se reserva para referencias a unidades individuales.

Bajo el CIA, el problema de identificar el ATE se reduce a estimar funciones de regresión condicionales sobre covariables observadas. Las estrategias prácticas para implementar esta identificación incluyen la regresión, el matching y la reponderación mediante el propensity score.

Corolario 3.1 (Estrategias de estimación bajo CIA)

Bajo CIA y soporte común, el ATE puede estimarse mediante:

1. Regresión: Especificar $\mu_{t(x)} = \mathbb{E}[Y \mid T = t, X = x]$ y promediar $\hat{\mu}_1(x) - \hat{\mu}_0(x)$ sobre $\mathbb{P}_X$.
2. Matching: Para cada unidad tratada, encontrar una unidad de control con X similar y comparar outcomes.
3. Propensity Score: Reducir X a $e(X) = \mathbb{P}(T = 1 \mid X)$ y condicionar sobre esta variable escalar.

Este capítulo analiza las estrategias de matching y propensity score, explorando las condiciones geométricas que permiten su aplicación y las limitaciones inherentes a su implementación en contextos de dimensión alta.

3.2 La Maldición de la Dimensionalidad

La intuición detrás del matching es la de comparar unidades con características covariables similares. Para evaluar el efecto de un programa de nutrición en un niño específico en Cusco, se busca otro niño en Puno con perfil similar en edad, peso, altura, nivel educativo de los padres, ingreso familiar y acceso a agua potable, entre otros. A medida que aumenta la cantidad de covariables consideradas, el espacio de comparación crece exponencialmente, haciendo imposible encontrar contrapartes exactas en muestras finitas.

El matching exacto, que requiere $X_j = X_i$, es matemáticamente inalcanzable en espacios continuos. La relajación a matching aproximado bajo una métrica en $\mathbb{R}^p$ enfrenta la maldición de la dimensionalidad: a mayor número de dimensiones, mayor dispersión de los datos. En estos espacios, la distancia entre puntos vecinos se vuelve arbitrariamente grande, lo que implica que el “vecino más cercano” puede no ser clínicamente ni estadísticamente relevante.

Definición 3.2 (Matching Exacto)

Para una unidad tratada i con covariables $X_i \in \mathbb{R}^p$, el conjunto de matches exactos es:

$$\mathcal{M}_i = \{j : T_j = 0, X_j = X_i\} \quad (3.2.1)$$

Si X tiene distribución continua respecto a la medida de Lebesgue en $\mathbb{R}^p$, entonces $\mathbb{P}(|\mathcal{M}_i| \geq 1) = 0$ para muestras finitas.

Dada la imposibilidad del matching exacto, se recurre al aproximado. La probabilidad de encontrar al menos un punto dentro de un radio ε declina exponencialmente con el número de dimensiones.

Proposición 3.1 (Probabilidad de Matching Aproximado)

Sea $\mathcal{X} \subseteq \mathbb{R}^p$ compacto con medida de Lebesgue $\mu(\mathcal{X}) > 0$. Sean $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathbb{P}_X$ con densidad acotada inferiormente por $c > 0$. Para $x_0 \in \mathcal{X}$ y radio $\varepsilon > 0$, la probabilidad de que exista al menos un punto en la bola $B(x_0, \varepsilon)$ es:

$$\mathbb{P}(\exists j : |X_j - x_0| < \varepsilon) = 1 - \left(1 - \frac{V_{p(\varepsilon)} \cdot c}{\mu(\mathcal{X})}\right)^n \quad (3.2.2)$$

donde $V_{p(\varepsilon)} = \frac{\pi^{\frac{p}{2}}}{\Gamma(\frac{p}{2}+1)} \varepsilon^p$ es el volumen de la bola unitaria p -dimensional de radio ε .

El volumen de la bola p -dimensional decrece exponencialmente en p , lo que implica que, para n fijo y ε fijo, la probabilidad de encontrar un match aproximado tiende a cero.

Teorema 3.2 (Colapso Asintótico del Matching)

Para n fijo y ε fijo, la probabilidad de encontrar un match aproximado satisface:

$$\lim_{p \rightarrow \infty} \mathbb{P}(\exists j : |X_j - x_0| < \varepsilon) = 0 \quad (3.2.3)$$

Este resultado implica que, en dimensiones altas, el matching directo es ineficaz. La variabilidad del estimador de matching con vecino más cercano diverge cuando p crece, lo que conduce a estimadores con alto sesgo y varianza.

Corolario 3.2 (Explosión de Varianza del Estimador de Matching)

Sea $\hat{\tau}_{\text{match}}$ el estimador de matching con reemplazo que usa el vecino más cercano. Cuando $p \rightarrow \infty$ con n fijo:

$$\text{Var}[\hat{\tau}_{\text{match}}] \rightarrow \infty \quad (3.2.4)$$

Ante esta limitación geométrica inherente al espacio de covariables multidimensional, el matching directo no es viable sin una transformación de la geometría de comparación.

3.3 Métricas de Distancia Geométricas

La elección de métrica en $\mathbb{R}^p$ determina qué significa similar'' en covariables. En contextos de datos heterogéneos, como bases administrativas en el Sur Global donde ingresos en soles, años de educación y latitud geográfica se combinan, las distancias no invariantes a escala inducen sesgos sistemáticos. La métrica más ingenua es la distancia Euclidiana. Su sensibilidad a la escala implica que variables con rango numérico grande dominan la distancia, ignorando variables clínicamente relevantes pero numéricamente pequeñas.

Definición 3.3 (Distancia Euclidiana)

Para vectores $x_i, x_j \in \mathbb{R}^p$, la distancia Euclidiana es:

$$d_E(x_i, x_j) = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2} = |x_i - x_j|_2 \quad (3.3.1)$$

La falta de invarianza a escala significa que cambiar las unidades de medida altera arbitrariamente la definición de similitud.

Proposición 3.2 (No invarianza de escala de d_E)

Sea $D = \text{diag}(\alpha_1, \dots, \alpha_p)$ con $\alpha_k > 0$. Defina $x' = Dx$. Entonces:

$$d_E(x'_i, x'_j) = \sqrt{\sum_{k=1}^p \alpha_k^2 (x_{ik} - x_{jk})^2} \neq d_E(x_i, x_j) \quad (3.3.2)$$

salvo que $\alpha_1 = \dots = \alpha_p = 1$. En particular, si $\alpha_k = \alpha$ para todo k , entonces $d_E(x'_i, x'_j) = |\alpha| \cdot d_E(x_i, x_j)$.

Para corregir esta distorsión, se introduce la distancia de Mahalanobis, que ajusta las diferencias por la estructura de covarianza.

Definición 3.4 (Distancia de Mahalanobis)

Sea $\Sigma = \mathbb{E}[(X - \mu)(X - \mu)^t]_{\text{op}}$ la matriz de covarianza de X , asumida definida positiva. La distancia de Mahalanobis entre $x_i, x_j \in \mathbb{R}^p$ es:

$$d_{M(x_i, x_j)} = \sqrt{(x_i - x_j)^t \Sigma^{-1} (x_i - x_j)} \quad (3.3.3)$$

La distancia de Mahalanobis es invariante a transformaciones lineales de escala, lo que la hace robusta a cambios en las unidades de medición.

Proposición 3.3 (Invarianza a transformaciones lineales de escala)

Sea D una matriz diagonal con entradas positivas. Defina $X' = DX$. Entonces:

$$d_{M(x'_i, x'_j)} = d_{M(x_i, x_j)} \quad (3.3.4)$$

Esto es lo que hace a Mahalanobis útil con covariables administrativas heterogéneas —ingresos en soles, edad, años de educación—, donde la noción de “similar” no debería depender de en qué unidades se midió cada variable. Entre todas las métricas cuadráticas, la de Mahalanobis minimiza la varianza del sesgo de matching bajo CIA.

Teorema 3.3 (Optimalidad de Mahalanobis para Matching)

Entre todas las métricas de la forma $d_{A(x_i, x_j)} = \sqrt{(x_i - x_j)^t A (x_i - x_j)}$ con A definida positiva, la elección $A = \Sigma^{-1}$ minimiza la varianza asintótica del sesgo de matching debido a diferencias en X .

La razón geométrica es el **whitening**: al escalar por Σ^{-1} , cada dirección del espacio contribuye por igual al balanceo, en vez de que las covariables de mayor varianza dominen la comparación. Aunque la distancia de Mahalanobis corrige la distorsión por escala, no resuelve la maldición de la dimensionalidad. Para reducir la dimensionalidad del problema, se requiere una transformación estructural de las covariables.

3.4 El Teorema de Propensity Score

El propensity score reduce la dimensionalidad del problema de matching de p dimensiones a una sola dimensión, preservando las propiedades de identificación bajo el CIA.

La compresión de X a $e(X) = \mathbb{P}(T = 1 \mid X)$ es factible debido al teorema de Rosenbaum & Rubin (1983), que establece que si $(Y(1), Y(0)) \perp\!\!\!\perp T \mid X$, entonces también $(Y(1), Y(0)) \perp\!\!\!\perp T \mid e(X)$. Esto implica que toda la información de X relevante para la asignación de tratamiento está contenida en el valor escalar $e(X)$. Por tanto, es suficiente para la identificación causal.

Definición 3.5 (Propensity Score)

El propensity score es la probabilidad condicional de recibir tratamiento dado las covariables:

$$e(X) = \mathbb{P}(T = 1 \mid X = x) = \mathbb{E}[T \mid X = x] \quad (3.4.1)$$

Asumimos la condición de soporte común: $0 < e(X) < 1$ para todo $x \in \mathcal{X}$.

La compresión de X a un escalar $e(X)$ sería un artificio algebraico sin el teorema que le otorga validez causal.

Teorema 3.4 (Rosenbaum y Rubin, 1983)

Si $(Y(1), Y(0)) \perp\!\!\!\perp T \mid X$, entonces $(Y(1), Y(0)) \perp\!\!\!\perp T \mid e(X)$.

Bajo este teorema, el problema de matching en $\mathbb{R}^p$ se reduce a un problema equivalente en $\mathbb{R}^1$. El ATE se identifica como la esperanza sobre $e(X)$ de la diferencia de regresiones condicionales en tratamiento y control.

Corolario 3.3 (Identificación vía Propensity Score)

Bajo CIA y soporte común, el ATE se identifica como:

$$\tau_{\text{ATE}} = \mathbb{E}_{e(X)}[\mathbb{E}[Y \mid T = 1, e(X)] - \mathbb{E}[Y \mid T = 0, e(X)]] \quad (3.4.2)$$

En la práctica, esto significa estimar $e(X)$, estratificar o alisar sobre esa única variable escalar, y promediar la diferencia — sin necesidad de balancear las p covariables originales.

3.4.1 Del Teorema a la Práctica: Estrategias de Estimación con el Propensity Score

La expresión de identificación derivada en el corolario anterior,

$$\tau_{\text{ATE}} = \mathbb{E}_{e(X)}[\mathbb{E}[Y \mid T = 1, e(X)] - \mathbb{E}[Y \mid T = 0, e(X)]], \quad (3.4.3)$$

sugiere al menos tres caminos naturales para construir estimadores prácticos. En primer lugar, la **estratificación (subclassification)** divide el rango de $e(X)$ en bloques y calcula el efecto dentro de cada bloque, promediando luego con pesos apropiados. En segundo lugar, el **matching por propensity score** empareja unidades tratadas y controles usando la distancia unidimensional $|e(X_i) - e(X_j)|$, evitando así la maldición de la dimensionalidad. Finalmente, la **regresión sobre el propensity score** modela las funciones de regresión condicionales $\mu_{t(e)} = \mathbb{E}[Y \mid T = t, e(X) = e]$ para $t = 0, 1$, obteniendo un estimador *plug-in* de la forma:

$$\hat{\tau}_{\text{Reg}} = \frac{1}{n} \sum_{i=1}^n [\hat{\mu}_1(\hat{e}(X_i)) - \hat{\mu}_0(\hat{e}(X_i))], \quad (3.4.4)$$

donde $\hat{\mu}_t$ son estimadores de las funciones de regresión condicionales en el propensity score estimado $\hat{e}(X)$.

Existe, sin embargo, una perspectiva alternativa que en lugar de **condicionar** sobre el propensity score, **repondera** la muestra observada. La identidad clave que sustenta esta aproximación es:

$$\mathbb{E}[Y(1)] = \mathbb{E}\left[\frac{TY}{e(X)}\right], \quad (3.4.5)$$

y análogamente $\mathbb{E}[Y(0)] = \mathbb{E}\left[\frac{(1-T)Y}{1-e(X)}\right]$. Esta identidad motiva el estimador de **Inverse Probability Weighting (IPW)**, también conocido como Horvitz-Thompson, cuya forma funcional es la contraparte natural de la estrategia de regresión:

$$\hat{\tau}_{\text{IPW}} = \frac{1}{n} \sum_{i=1}^n \left(\frac{T_i Y_i}{\hat{e}(X_i)} - \frac{(1 - T_i) Y_i}{1 - \hat{e}(X_i)} \right). \quad (3.4.6)$$

Este estimador IPW crudo²² presenta, no obstante, limitaciones prácticas importantes: su varianza puede ser infinita cuando $\hat{e}(X_i)$ se acerca a 0 o a 1, y su eficiencia es generalmente inferior a la de los estimadores basados en regresión. Estas deficiencias motivan el desarrollo del IPW estabilizado y, más aún, del estimador doblemente robusto (AIPW) que combina las virtudes de la regresión y la reponderación. Estas mejoras serán el objeto central del Capítulo 4.

A continuación examinamos con más detalle la intuición y propiedades básicas del estimador IPW, que constituye el puente natural entre las estrategias de condicionamiento (matching, estratificación) y las de reponderación que se explorarán en profundidad en el siguiente capítulo.

La intuición detrás del estimador IPW puede expresarse en términos de pesos: una unidad tratada que tenía una probabilidad muy baja de recibir el tratamiento (por ejemplo, alguien con poca experiencia que decide hacer la maestría) es un caso *extraño* pero muy informativo. Al ponderarla por el inverso de esa probabilidad, estamos amplificando su voz para que represente a todas las unidades similares que no fueron tratadas. De manera análoga, una unidad control con baja probabilidad de ser control (es decir, con alta probabilidad de ser tratada) recibe un peso grande. Formalmente, los pesos se definen como:

$$w_i = \begin{cases} \frac{1}{e(X_i)} & \text{si } T_i = 1 \\ \frac{1}{1-e(X_i)} & \text{si } T_i = 0 \end{cases} \quad (3.4.7)$$

Al aplicar estos pesos, creamos una población ponderada donde la distribución de las covariables es la misma entre tratados y controles. Es como si hubiéramos generado un universo paralelo en el que la asignación del tratamiento es independiente de las características observables, simulando así las condiciones de un experimento aleatorizado.

Esta construcción tiene una interpretación poderosa: el IPW nos permite simular un experimento aleatorizado a partir de datos observacionales. Por eso decimos que crea un entorno pseudoaleatorio: no es que la asignación original haya sido aleatoria, sino que, gracias a las ponderaciones, podemos analizar los datos *como si* lo hubiera sido. La calidad de esta simulación depende crucialmente de la estimación precisa del propensity score $e(X)$, lo que subraya su papel central en el diseño de estudios observacionales.

Ejemplo 3.1 (Matching por PS en programa de capacitación SENATI)

Se evalúa el efecto de un curso de soldadura (tratamiento) sobre el ingreso mensual en Lima. Los participantes son más jóvenes y con menor educación formal que los no participantes. Aplicando el Teorema de Rosenbaum-Rubin, se estima $\hat{e}(X_i) = \hat{\mathbb{P}}(T = 1 | X_i)$ con regresión logística y se empareja cada tratado con su vecino más cercano en $\bar{e}(X)$. El CATE antes del matching es 420 soles/mes (sesgado); después del matching (SMD < 0.10 en todas las covariables) el estimador baja a 280 soles/mes, consistente con el ATE bajo CIA.

Supuestos clave

Supuestos del Capítulo 3 (Matching y Propensity Score)

1. **CIA (Ignorabilidad):** $(Y(0), Y(1)) \perp\!\!\!\perp T \mid X$ — toda confusión es observable.
2. **Soporte Común:** $0 < e(X) < 1$ para todo $x \in \mathcal{X}$ — evita extrapolación.
3. **SUTVA:** Sin interferencias entre unidades.
4. **Modelo de PS correcto:** $\bar{e}(X)$ converge a $e(X)$ — el matching por PS es consistente.

3.5 Cierre del capítulo

El matching traduce la ignorabilidad condicional en un diseño de comparación local. Su validez descansa en el solapamiento y en la calidad de la métrica de distancia; el capítulo siguiente introduce la reponderación por propensity score como alternativa y complemento.

Otras referencias clave de este capítulo: (Hernán & Robins, 2020), (Angrist & Pischke, 2009), (Dehejia & Wahba, 1999), (Abadie & Imbens, 2006).

3.5 Referencias

- Abadie, A., & Imbens, G. W. (2006). Large Sample Properties of Matching Estimators for Average Treatment Effects. *Econometrica*, 74(1), 235-267.
- Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.
- Dehejia, R. H., & Wahba, S. (1999). Causal Effects in Nonexperimental Studies: Reevaluating the Evaluation of Training Programs. *Journal of the American Statistical Association*, 94(448), 1053-1062.
- Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.
- Rosenbaum, P. R., & Rubin, D. B. (1983). The Central Role of the Propensity Score in Observational Studies for Causal Effects. *Biometrika*, 70(1), 41-55.

CAPÍTULO 4

IPW y el Santo Grial de la Doble Robustez

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42**Notebook (pack):** notebooks/Bloque_I/notebooks/04_ipw_santo_grial_doble_robustez.ipynb**Jupyter Book:** jupyter_book/content/bloque_01_fundamentacion/04_ipw_doble_robustez.ipynb**Matemática GCE:** gce/paper/main.typ (cadena maestra / experimento canónico)

Este capítulo retoma y profundiza el estimador de ponderación inversa (IPW) introducido en el Capítulo 3. Allí presentamos un bosquejo de su consistencia; ahora desarrollaremos su teoría completa: el estimador de Horvitz–Thompson (Horvitz & Thompson, 1952) (que no es otro que el IPW), los problemas de varianza, la estabilización, la doble robustez y la eficiencia semiparamétrica.

4.1 La Lógica de Re-Ponderación (IPW)

En contextos de política pública en el Global Sur, como los programas de transferencias condicionadas “Juntos” en el Perú o “Bolsa Familia” en Brasil, la asignación del tratamiento no es un proceso aleatorio puro. La focalización se basa en complejas intersecciones de vulnerabilidades socioeconómicas, condiciones geográficas y fricciones administrativas. Si bien la mayoría de los hogares bajo la línea de pobreza extrema reciben el beneficio, existen casos observados que, compartiendo idénticas características de vulnerabilidad, no fueron focalizados por errores de empadronamiento. Estas unidades representan un recurso potencial para la inferencia causal: poseen las mismas covariables observables que los tratados, pero la asignación real del tratamiento es 0. Sin embargo, en la muestra general, el grupo de control está dominado por hogares de mayores ingresos, lo que introduce un sesgo de selección empírico.

El estimador de Inverse Probability Weighting (IPW) formaliza la intuición de reponderación por relevancia. Para simular el contrafactual de los beneficiarios, se asigna mayor masa probabilística a los no beneficiarios cuyas características multidimensionales los hacen indistinguibles del grupo tratado (es decir, aquellos con un propensity score cercano a 1). En este esquema, cada unidad tratada se pondera por $\frac{1}{e(X_i)}$ para expandir su representación a la población objetivo, mientras que cada unidad de control se pondera por $\frac{1}{1-e(X_i)}$ para corregir su sub-representación relativa.

Definición 4.1 (Estimador Horvitz-Thompson)

El estimador IPW de Horvitz-Thompson para el ATE es la diferencia de medias ponderadas:

$$\hat{\tau}_{\text{IPW}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{T_i Y_i}{\hat{e}(X_i)} - \frac{(1 - T_i) Y_i}{1 - \hat{e}(X_i)} \right] \quad (4.1.1)$$

donde $\hat{e}(X_i)$ es un estimador consistente del propensity score verdadero $e(X_i) = \mathbb{P}(T_i = 1 \mid X_i)$.

Esta formulación es la encarnación algebraica de un cambio de medida geométrica (Teorema de Radon-Nikodym aplicado a inferencia causal). El teorema siguiente establece que, bajo el supuesto de ignorabilidad (CIA), esta transformación del espacio de probabilidad reconstruye el promedio de la población latente de resultados potenciales.

Teorema 4.1 (Identificación IPW)

Bajo el supuesto de Independencia Condicional (CIA) y la condición de soporte común estricto $0 < e(X) < 1$ para todo $x \in \mathcal{X}$, los parámetros contrafactuales poblacionales están identificados por:

$$\mathbb{E}\left[\frac{TY}{e(X)}\right] = \mathbb{E}[Y(1)] \quad \text{y} \quad \mathbb{E}\left[\frac{(1-T)Y}{1-e(X)}\right] = \mathbb{E}[Y(0)] \quad (4.1.2)$$

Corolario 4.1 (Identificación del ATE vía IPW)

Bajo CIA y soporte común, el ATE se identifica paramétricamente como:

$$\tau_{\text{ATE}} = \mathbb{E}\left[\frac{TY}{e(X)} - \frac{(1-T)Y}{1-e(X)}\right] \quad (4.1.3)$$

4.2 Estabilización y Varianzas

El estimador Horvitz-Thompson, aunque correcto en esperanza asintótica, es empíricamente frágil: cuando el propensity score estimado se acerca a los extremos del intervalo (0 o 1), su varianza diverge. Retornando al programa “Juntos”, consideremos un hogar en extrema pobreza con $e(X) = 0.99$. La probabilidad empírica de observar una unidad de control con esta topología que no haya recibido el subsidio es 0.01. Si el algoritmo de muestreo identifica dicha unidad, el estimador HT le asigna un peso de $\frac{1}{1-0.99} = 100$. Cualquier ruido en el resultado Y de esta unidad dominará numéricamente la estimación del ATE contrafactual.

Proposición 4.1 (Divergencia de Varianza de IPW)

Para la unidad i , definiendo el factor de expansión probabilística:

$$w_i = \frac{T_i}{e(X_i)} + \frac{1-T_i}{1-e(X_i)} \quad (4.2.1)$$

La varianza condicional $\mathbb{V}[w_i Y_i \mid X_i]$ diverge hacia infinito a medida que el propensity score viola la condición estricta de soporte común:

$$\lim_{e(X_i) \rightarrow 0^+} \mathbb{V}[w_i Y_i \mid X_i] = \lim_{e(X_i) \rightarrow 1^-} \mathbb{V}[w_i Y_i \mid X_i] = \infty \quad (4.2.2)$$

Intuitivamente, una unidad con $e(X)$ extremo es un caso casi determinista en su asignación: ponderarla por el inverso de una probabilidad cercana a cero amplifica cualquier ruido en su outcome hasta dominar la estimación completa.

Para acotar esta explosión de varianza sin comprometer severamente la consistencia, se aplica la normalización de Hajek. Esta técnica fuerza a que la sumatoria de pesos empíricos en ambos brazos del tratamiento integre exactamente n .

Definición 4.2 (IPW Estabilizado (SIPW))

El estimador IPW estabilizado normaliza los ponderadores por su masa empírica total:

$$\hat{\tau}_{\text{SIPW}} = \frac{\sum_{i=1}^n \frac{T_i Y_i}{\hat{e}(X_i)}}{\sum_{i=1}^n \frac{T_i}{\hat{e}(X_i)}} - \frac{\sum_{i=1}^n \frac{(1-T_i) Y_i}{1-\hat{e}(X_i)}}{\sum_{i=1}^n \frac{1-T_i}{1-\hat{e}(X_i)}} \quad (4.2.3)$$

La estabilización no es un ajuste cosmético: reduce la varianza asintótica del estimador, como establece el siguiente resultado.

Teorema 4.2 (Reducción Asintótica de Varianza)

Sean $\hat{\tau}_{HT}$ y $\hat{\tau}_{SIPW}$ los estimadores de Horvitz-Thompson y Estabilizado, respectivamente. Bajo condiciones estándar de regularidad, se cumple que:

$$\lim_{n \rightarrow \infty} n \cdot \mathbb{V}[\hat{\tau}_{SIPW}] \leq \lim_{n \rightarrow \infty} n \cdot \mathbb{V}[\hat{\tau}_{HT}] \quad (4.2.4)$$

La igualdad se alcanza de forma estricta si y solo si $\mathbb{P}(T = 1) = \mathbb{E}[e(X)]$ (es decir, en diseños experimentales no condicionales).

La normalización introduce una correlación negativa entre numerador y denominador que amortigua las oscilaciones del Horvitz-Thompson original; solo en un diseño experimental puro ($\mathbb{P}(T = 1) = \mathbb{E}[e(X)]$) esa ganancia desaparece y ambos estimadores coinciden en varianza.

Corolario 4.2 (Consistencia de IPW Estabilizado)

Si $\bar{e}(X) \xrightarrow{p} e(X)$ uniformemente y se respeta el umbral de positividad estricto $0 < \delta \leq e(X) \leq 1 - \delta < 1$ c.s., entonces:

$$\hat{\tau}_{SIPW} \xrightarrow{p} \tau_{ATE} \quad (4.2.5)$$

La condición $e(X) > \delta$ hace el trabajo: evita la división por valores arbitrariamente pequeños y mantiene los pesos acotados, lo suficiente para invocar leyes de grandes números y el teorema de Slutsky.

4.3 El Estimador Doblemente Robusto (AIPW)

La arquitectura del IPW reposa íntegramente sobre la correcta especificación funcional del $\hat{e}(X_i)$. Si el modelo para el tratamiento omite no-linealidades, el estimador HT se vuelve sesgado. Por otro lado, la regresión de imputación clásica (G-computation) depende de la parametrización de $\mu_{t(X)}$. El estimador Augmented IPW (AIPW) sintetiza ambas arquitecturas en una estructura de “Doble Robustez”, desarrollada fundamentalmente por Robins et al. (1994). Este estimador converge al parámetro objetivo si al menos uno de los dos modelos (propensity score o outcome) es parametrizado correctamente.

Definición 4.3 (Estimador AIPW)

Sean $\hat{\mu}_1(x)$ y $\hat{\mu}_0(x)$ estimadores consistentes para las funciones de regresión empírica $\mu_{t(x)} = \mathbb{E}[Y | T = t, X = x]$, y sea $\bar{e}(X)$ un estimador del propensity score logístico paramétrico. El estimador AIPW (Augmented Inverse Probability Weighting) se define como:

$$\hat{\tau}_{AIPW} = \frac{1}{n} \sum_{i=1}^n \left[\hat{\mu}_1(X_i) + \frac{T_i}{\hat{e}(X_i)} (Y_i - \hat{\mu}_1(X_i)) \right] - \frac{1}{n} \sum_{i=1}^n \left[\hat{\mu}_0(X_i) + \frac{1 - T_i}{1 - \hat{e}(X_i)} (Y_i - \hat{\mu}_0(X_i)) \right] \quad (3.1)$$

Esta métrica se descompone en una esperanza condicional calculada por G-computation sumada a un término de amortiguación ponderado por $\frac{1}{\hat{e}(X_i)}$. Si el ajuste del outcome es perfecto, el término de corrección se acerca a 0. Si el modelo base $\mu_{t(x)}$ falla pero el propensity score es válido, el estimador penaliza el residuo mediante la probabilidad inversa $\bar{e}(X)$.

Teorema 4.3 (Propiedad de Doble Robustez Analítica)

El estimador $\hat{\tau}_{\text{AIPW}}$ es un estimador uniformemente consistente de τ_{ATE} si se cumple al menos una de las siguientes condiciones de límite estocástico débil:

1. $\bar{e}(X) \xrightarrow{P} e(X)$ (modelo del mecanismo de asignación consistente y no sesgado).
2. $\hat{\mu}_{t(X)} \xrightarrow{P} \mu_{t(X)}$ para $t = 0, 1$ (modelo del outcome condicional consistente).

Proposición 4.2 (Descomposición del Estimador AIPW)

Definiendo los tres componentes:

$$\begin{aligned}\hat{\mu}_t &= \frac{1}{n} \sum_{i=1}^n \hat{\mu}_{t(X_i)} \quad (t = 0, 1), \\ \hat{\tau}_{\text{IPW}} &= \frac{1}{n} \sum_{i=1}^n \left(\frac{T_i Y_i}{\hat{e}(X_i)} - \frac{(1 - T_i) Y_i}{1 - \hat{e}(X_i)} \right), \\ \hat{\tau}_{\text{augment}} &= \frac{1}{n} \sum_{i=1}^n \left(\frac{T_i \hat{\mu}_1(X_i)}{\hat{e}(X_i)} - \frac{(1 - T_i) \hat{\mu}_0(X_i)}{1 - \hat{e}(X_i)} \right),\end{aligned}\tag{4.3.2}$$

el estimador AIPW admite la descomposición algebraica exacta:

$$\hat{\tau}_{\text{AIPW}} = (\hat{\mu}_1 - \hat{\mu}_0) + \hat{\tau}_{\text{IPW}} - \hat{\tau}_{\text{augment}}.\tag{4.3.3}$$

Leída así, el AIPW es un T-learner (regresión directa) más un ajuste IPW menos un término que evita contar dos veces la misma información — la resta es lo que hace que los errores de cada componente se cancelen cuando el otro modelo es correcto.

4.4 Límites de Cramér-Rao y Eficiencia Semiparamétrica

Con AIPW en mano, cabe preguntar si existe un límite teórico a cuánto puede reducirse la varianza de cualquier estimador del ATE bajo CIA — un piso por debajo del cual ningún estimador regular, sin importar su sofisticación, puede bajar. La respuesta la da el principio de límite semiparamétrico (Newey, 1994): bajo CIA, ese piso —el inverso de la información de Fisher del mejor estimador regular posible— se conoce como la Cota de Hahn (Hahn, 1998).

Teorema 4.4 (Cota Semiparamétrica de Varianza de Hahn, 1998)

En el modelo analítico definido bajo variables observacionales estrictas con soporte $\mathcal{X}$, asumiendo la varianza $\sigma_t^2(X) = \mathbb{V}[Y(t) \mid X]$, la varianza asintótica mínima insuperable para estimadores regulares no paramétricos sobre el objetivo τ_{ATE} está delimitada paramétricamente por el funcional:

$$V^* = \mathbb{E} \left[\frac{\sigma_1^2(X)}{e(X)} + \frac{\sigma_0^2(X)}{1 - e(X)} \right] + \text{Var}[\mu_1(X) - \mu_0(X)]\tag{4.4.1}$$

La cota tiene dos componentes: la heterocedasticidad de Y dentro de cada brazo, penalizada por el inverso de la probabilidad de tratamiento, y la varianza del ATE entre subpoblaciones cuando el efecto es heterogéneo.

Teorema 4.5 (Optimalidad Asintótica de AIPW)

Asumiendo estimadores regulares estocásticos para los nuisance models $\bar{e}(X)$ y $\mu^{t(X)}$ que limitan uniformemente a tasas semiparamétricas típicas de orden $n^{\frac{1}{2}}$ (i.e. $\sqrt{n}(\hat{e} - e) = O_{p(1)}$), el estadístico resultante converge en distribución al límite físico analítico:

$$\sqrt{n}(\hat{\tau}_{\text{AIPW}} - \tau_{\text{ATE}}) \xrightarrow{d} \mathcal{N}(0, V^*) \quad (4.4.2)$$

es decir, el AIPW alcanza exactamente la Cota de Hahn: es eficiente en el sentido semiparamétrico establecido por Robins et al. (1994) y Hahn (1998).

Ningún estimador regular basado en (T, X, Y) puede, asintóticamente, tener menor varianza que AIPW — de ahí su centralidad tanto en la práctica clásica como en el ML causal contemporáneo.

4.5 Verificación Computacional: AIPW y Doble Robustez

El siguiente código ilustra la propiedad de doble robustez mediante un experimento controlado: se generan datos con un DGP conocido y se evalúa el estimador AIPW bajo cuatro escenarios de misspecification.

La salida muestra que AIPW es preciso cuando *al menos uno* de los modelos está bien especificado, pero falla solo cuando ambos están mal especificados, ilustrando empíricamente la Propiedad de Doble Robustez.

Ejemplo 4.1 (Doble robustez en evaluación de Juntos)

Se estima el efecto de Juntos sobre el gasto en salud infantil. El propensity score es estimado con regresión logística sobre 12 covariables de pobreza; el outcome model con regresión lineal. Al corromper deliberadamente el outcome model (sesgo de forma funcional), el AIPW sigue siendo consistente porque el PS está correcto. Al corromper el PS pero mantener el outcome model correcto, el AIPW nuevamente converge al valor verdadero. Solo al corromper ambos simultáneamente el estimador falla — verificando empíricamente la Propiedad de Doble Robustez.

Supuestos clave**Supuestos del Capítulo 4 (IPW y AIPW)**

1. **CIA:** $(Y(0), Y(1)) \perp\!\!\!\perp T \mid X$.
2. **Soporte Común:** $0 < e(X) < 1$ para todo x .
3. **Doble Robustez:** Al menos uno de $\{\bar{e}(X), \hat{\mu}_{t(X)}\}$ converge al valor verdadero.
4. **Regularidad:** Momentos finitos de Y ; modelos $\hat{\mu}_t, \hat{e}$ ajustados en muestra independiente (o con cross-fitting) para garantizar $\sqrt{n}$ -consistencia del AIPW.

4.6 Cierre del capítulo

IPW y AIPW formalizan la identificación del ATE vía reponderación y doble robustez. El mensaje monográfico es contractual: sin overlap o con confusión no medida, la ponderación no salva el estimando.

Otras referencias clave de este capítulo: (Angrist & Pischke, 2009), (Dehejia & Wahba, 1999), (Hernán & Robins, 2020), (Imbens & Rubin, 2015), (Rosenbaum & Rubin, 1983).

4.6 Referencias

- Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.
- Dehejia, R. H., & Wahba, S. (1999). Causal Effects in Nonexperimental Studies: Reevaluating the Evaluation of Training Programs. *Journal of the American Statistical Association*, 94(448), 1053-1062.
- Hahn, J. (1998). On the Role of the Propensity Score in Efficient Semiparametric Estimation of Average Treatment Effects. *Econometrica*, 66(2), 315-331.
- Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.
- Horvitz, D. G., & Thompson, D. J. (1952). A Generalization of Sampling Without Replacement from a Finite Universe. *Journal of the American Statistical Association*, 47(260), 663-685.
- Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- Newey, W. K. (1994). The Asymptotic Variance of Semiparametric Estimators. *Econometrica*, 62(6), 1349-1382.
- Robins, J. M., Rotnitzky, A., & Zhao, L. P. (1994). Estimation of Regression Coefficients When Some Regressors are not Always Observed. *Journal of the American Statistical Association*, 89(427), 846-866.
- Rosenbaum, P. R., & Rubin, D. B. (1983). The Central Role of the Propensity Score in Observational Studies for Causal Effects. *Biometrika*, 70(1), 41-55.

CAPÍTULO 5

Variables Instrumentales: Identificación sin Observar el Confusor

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42

Notebook (pack): notebooks/Bloque_I/notebooks/05_abismo_lo_no_observable_rescate.ipynb

Jupyter Book: jupyter_book/content/bloque_01_fundamentacion/05_abismo_observable_instrumental.ipynb

5.1 La Falla del CIA y la Anatomía de la Endogeneidad

El Nivel 1 de la jerarquía GCE se apoya en el supuesto de Independencia Condicional (CIA): si se observaran todas las variables relevantes, la asignación al tratamiento sería independiente del resultado potencial. En la práctica, este supuesto es frecuentemente inválido. Existen factores que determinan simultáneamente la decisión de tratamiento y el resultado de interés, y que no son observables directamente. Factores como la habilidad innata, la motivación, la tolerancia al riesgo o las redes sociales informales no pueden ser medidos plenamente en bases de datos administrativas en contextos del Sur Global.

Consideremos el caso de la estimación del retorno de la educación en América Latina. Supongamos que se desea cuantificar el efecto de un año adicional de educación formal sobre el ingreso laboral. Un modelo de regresión simple o un algoritmo de matching asume que los individuos que eligen estudiar más años son idénticos, salvo por su nivel de escolaridad observada, a aquellos que no lo hacen. En algunos escenarios, este supuesto es insostenible. En el Perú, una persona que culmina una ingeniería en una universidad pública no solo posee más créditos académicos; también es más probable que exhiba mayor perseverancia, un entorno familiar de apoyo más sólido o un nivel de resiliencia intelectual superior. Estos factores (denotado por U) influyen tanto en la decisión de invertir en educación (T) como en la productividad laboral futura (Y). Cuando T y U están correlacionados, el supuesto de CIA se viola.

Los Capítulos 3–4 (Matching, IPW, AIPW) requieren CIA: $(Y(0), Y(1)) \perp\!\!\!\perp T \mid X$. Cuando existen confusores no observados U que correlacionan con T , CIA falla y esos estimadores son inconsistentes. IV rescata la identificación sin observar U , pero paga el precio de requerir un instrumento válido Z . IV no es mejor que IPW; es una solución alternativa para un problema de identificación distinto.

A lo largo de este capítulo trabajaremos con el modelo lineal $Y = \beta_0 + \beta_1 T + U$, donde β_1 denota el efecto causal estructural del tratamiento. Bajo el supuesto de efecto constante, β_1 coincide exactamente con el ATE poblacional: $\beta_1 = \tau_{ATE} = \mathbb{E}[Y(1) - Y(0)]$. Cuando los efectos son heterogéneos (Sección 5.4, y con más detalle en el Capítulo 6), el estimador instrumental converge en cambio a un parámetro distinto, el LATE (τ_{LATE}).

Definición 5.1 (Modelo Estructural con Endogeneidad)

El modelo lineal generador de datos con variable endógena se define como:

$$Y_i = \beta_0 + \beta_1 T_i + U_i \quad (5.1.1)$$

donde U_i representa el vector colapsado de factores no observables tales que:

$$\text{Cov}(T_i, U_i) \neq 0 \quad (5.1.2)$$

La endogeneidad implica rigurosamente que $\mathbb{E}[U_i | T_i] \neq \mathbb{E}[U_i]$, violando el axioma de exogeneidad fuerte del modelo clásico.

La no independencia entre el tratamiento y el término de error es tóxica para el estimador de Mínimos Cuadrados Ordinarios (OLS). El algoritmo de minimización de residuos, incapaz de distinguir entre el efecto de la educación y el efecto de la capacidad innata subyacente, atribuye erróneamente toda la covarianza entre T y Y a β_1 , inflando espuriamente el parámetro de interés.

Proposición 5.1 (Sesgo del Estimador OLS)

El estimador de Mínimos Cuadrados Ordinarios de β_1 en muestras finitas satisface la identidad:

$$\hat{\beta}_{1,OLS} = \beta_1 + \frac{\sum_{i=1}^n (T_i - \bar{T})(U_i - \bar{U})}{\sum_{i=1}^n (T_i - \bar{T})^2} \quad (5.1.3)$$

El resultado asintótico siguiente muestra que este sesgo no es un problema de muestra pequeña: sin importar cuántos datos se recojan, el estimador OLS no converge al parámetro causal verdadero.

Teorema 5.1 (Inconsistencia Asintótica del OLS bajo Endogeneidad)

Bajo endogeneidad, el estimador OLS es asintóticamente inconsistente:

$$\hat{\beta}_{1,OLS} \xrightarrow{p} \beta_1 + \frac{\text{Cov}(T, U)}{\text{Var}(T)} \neq \beta_1. \quad (5.1.4)$$

Corolario 5.1 (Dirección del Sesgo)

Cuando $\text{Cov}(T, U) > 0$ (por ejemplo, mayor habilidad correlaciona con más educación), OLS sobrestima estructuralmente a β_1 ; cuando $\text{Cov}(T, U) < 0$, lo subestima.

Con el Nivel 1 fuera de alcance, la pregunta es directa: ¿puede rescatarse la identificación sin observar U ? Hace falta una fuente de variación en T que sea puramente exógena — una perturbación externa que se comporte, para efectos prácticos, como si hubiera sido asignada al azar.

5.2 La Anatomía del Instrumento Perfecto

La estrategia de Variables Instrumentales (IV), formalizada originalmente por Wright (1928) y Wald (1940), resuelve esto sin controlar por U : se introduce una variable externa Z que mueve la asignación del tratamiento T de forma exógena, aislando así la parte de la variación en T que no está contaminada por el confusor.

Retornando al paradigma educativo: consideremos como variable instrumental Z la distancia geométrica (en kilómetros) desde el hogar natal del estudiante hasta el campus de la universidad pública más cercana, al momento de terminar la escuela secundaria (Card, 1995).

¿Por qué la geometría espacial es un instrumento analíticamente válido? La topografía es indiferente a la capacidad intelectual o genética de un joven. Un estudiante brillante nacido en una provincia altoandina o selvática no posee menor coeficiente intelectual promedio que uno nacido en la zona céntrica de Lima, pero sí enfrenta una restricción presupuestaria y un costo de oportunidad exponencialmente más altos para matricularse presencialmente. Por lo tanto, la distancia afecta fuertemente la variable endógena (años de educación, T). La clave epistemológica radica en que, una vez condicionado por los años efectivos de educación, la distancia no debe influir directamente en la productividad marginal (Y). Haber nacido lejos no hace un profesional más o menos competente per se, salvo por el canal causal exclusivo de haber limitado (o facilitado) el acceso a la educación.

Definición 5.2 (Variable Instrumental)

Una variable Z es un instrumento válido (o “palanca causal”) para la variable endógena T si, y solo si, satisface simultáneamente:

1. Relevancia Fuerte: $\text{Cov}(Z, T) \neq 0$. El instrumento induce variación medible en el tratamiento.
2. Exogeneidad (Independencia y Exclusión): $\text{Cov}(Z, U) = 0$. El instrumento es completamente independiente al espacio de los factores inobservados y no posee ruta causal directa hacia el outcome Y que no pase por T .

el procedimiento avanza en dos etapas, pasamos a la primera:

Criterio	Pregunta guía	Verificación
Relevancia	¿ Z mueve T de forma medible?	$F > 10$ en 1.ª etapa
Exclusión	¿ Z afecta Y solo vía T ?	Justificación teórica/institucional
Independencia	¿ Z es <i>as-if</i> aleatoria dado X ?	Test de balance; diseño de asignación
Monotonicidad	¿Existen Defiers plausibles?	Argumento de dominio; sensibilidad

Tabla 6: Checklist de Validez del Instrumento

Definición 5.3 (Primera Etapa Estructural)

La proyección lineal del instrumento sobre la variable endógena define la ecuación de primera etapa:

$$T_i = \pi_0 + \pi_1 Z_i + v_i \quad (5.2.1)$$

donde $\pi_1 \neq 0$ cuantifica algebraicamente la relevancia del instrumento, y $\mathbb{E}[v_i | Z_i] = 0$.

Aquí está el punto ciego que enfrenta todo investigador aplicado: la Primera Etapa se valida con la significancia estadística de π_1 , pero ningún dato puede demostrar que el instrumento obedece la Restricción de Exclusión.

Teorema 5.2 (No-Testabilidad de la Exogeneidad)

El axioma de relevancia $\text{Cov}(Z, T) \neq 0$ es estrictamente testable en el dominio de los datos observados. Por el contrario, el axioma de exogeneidad $\text{Cov}(Z, U) = 0$ es intrínseca y estructuralmente incontrastable, puesto que el vector de error U pertenece al espacio no observable.

Cualquier test de exogeneidad basado en residuos estimados incurre en circularidad: presupone la validez del estimador que se quiere validar. Dado que $\text{Cov}(Z, U) = 0$ no es testable, la validez de IV depende enteramente de argumentos institucionales, teóricos o de diseño. Un instrumento estadísticamente perfecto” (F alto) pero teóricamente dudoso produce estimaciones inconsistentes. La clave ejecutiva no está en el algoritmo, sino en la validación cualitativa del instrumento.

5.3 El Estimador de Wald y la Purificación Geométrica (2SLS)

Si el instrumento cumple ambos axiomas, la variación que induce en el tratamiento es, por construcción, exógena. El estimador de Wald explota esto directamente: divide la variación que el instrumento produce en el outcome (la “forma reducida”) entre la variación que produce en el tratamiento (la “primera etapa”).

Proposición 5.2 (Derivación del Estimador IV)

Bajo exogeneidad fuerte $\text{Cov}(Z, U) = 0$, el parámetro causal estructural β_1 queda identificado por el ratio:

$$\beta_1 = \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, T)} \quad (5.3.1)$$

Esta relación escalar es el Estimador de Wald.

Definición 5.4 (Estimador Empírico de Wald)

La sustitución de los momentos poblacionales por sus análogos muestrales genera el estimador IV consistente:

$$\hat{\beta}_{IV} = \frac{\widehat{\text{Cov}}(Z, Y)}{\widehat{\text{Cov}}(Z, T)} = \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})(T_i - \bar{T})}. \quad (5.3.2)$$

Aunque el estimador de Wald es consistente, su varianza asintótica revela una vulnerabilidad crítica: instrumentos débiles producen inferencia frágil.

Teorema 5.3 (Distribución Asintótica y el Peligro de los Instrumentos Débiles)

Asumiendo condiciones de regularidad analítica (momentos finitos estacionarios y observaciones i.i.d.), el estimador converge en distribución normal:

$$\sqrt{n}(\hat{\beta}_{IV} - \beta_1) \xrightarrow{d} \mathcal{N}\left(0, \frac{\sigma_U^2}{\text{Var}(Z) \cdot \text{Corr}(Z, T)^2}\right), \quad (5.3.3)$$

donde $\sigma_U^2 = \text{Var}(U)$.

El estimador $\hat{\beta}_{IV}$ es un estimador tipo razón (*ratio estimator*). En muestras finitas, $\mathbb{E}[\hat{\beta}_{IV}] \neq \beta_1$ porque $\mathbb{E}\left[\frac{A}{B}\right] \neq \frac{\mathbb{E}[A]}{\mathbb{E}[B]}$. Bajo los supuestos de relevancia y exogeneidad, $\hat{\beta}_{IV} \xrightarrow{p} \beta_1$ cuando $n \rightarrow \infty$: la inferencia IV descansa en propiedades asintóticas, no en insesgadez muestral. Cuando el instrumento es débil ($\text{Corr}(Z, T) \approx 0$), la aproximación normal falla y los intervalos de confianza sub-cubren. Se recomienda inferencia robusta (Anderson-Rubin, Kleibergen-Paap) cuando $F < 10$.

5.3.1 Proyección Múltiple: Mínimos Cuadrados en Dos Etapas (2SLS)

Con un vector de instrumentos ($Z \in \mathbb{R}^m$, $m > 1$), el estimador escalar de Wald se generaliza a una proyección ortogonal sobre el espacio de los instrumentos: Mínimos Cuadrados en Dos Etapas (2SLS). Conceptualmente, 2SLS funciona en dos pasos:

1. Etapa 1: Proyectamos el tratamiento T sobre el espacio generado por los instrumentos Z . Los valores ajustados $\hat{T}$ retienen solo la variación explicada por factores exógenos, descartando la parte contaminada por el confusor no observado.
2. Etapa 2: Usamos $\hat{T}$ como regresor en la ecuación de interés, aplicando OLS sin riesgo de contaminación endógena.

Definición 5.5 (Matriz de Proyección 2SLS)

Definiendo $\mathbf{X}$ como la matriz conteniendo la variable endógena e interceptos, y $\mathbf{Z}$ la matriz de $m \geq k$ instrumentos. La matriz de proyección ortogonal generada en la primera etapa (Hat Matrix) es:

$$\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}^{\text{top}} \mathbf{Z})^{-1} \mathbf{Z}^{\text{top}} \quad (5.3.4)$$

Por consiguiente, las variables “purificadas” o proyectadas son:

$$\hat{\mathbf{X}} = \mathbf{P}_Z \mathbf{X} \quad (5.3.5)$$

La proyección ortogonal se resume en una expresión algebraica compacta para el estimador 2SLS, que generaliza el caso escalar de Wald.

Teorema 5.4 (Forma Cerrada del Estimador 2SLS)

El estimador de proyección paramétrica 2SLS admite la representación algebraica consolidada:

$$\hat{\beta}_{2SLS} = (\mathbf{X}^{\text{top}} \mathbf{P}_Z \mathbf{X})^{-1} \mathbf{X}^{\text{top}} \mathbf{P}_Z \mathbf{Y} \quad (5.3.6)$$

Cuando $m = k = 1$ (un solo instrumento exacto), este estimador se reduce exactamente a la forma escalar de Wald.

Cuando se usan $m > 1$ instrumentos, el sesgo finito de 2SLS escala aproximadamente como $\frac{m}{n-m-1} \cdot \text{Sesgo}_{\{\text{OLS}\}}$. Evitar sobre-instrumentar: incluir solo Z 's con justificación teórica fuerte y estadístico F individual > 10 . Para $\frac{m}{n}$ alto, considerar estimadores alternativos (LIML, Anderson-Rubin).

5.4 El Estimando Local

Todo lo anterior descansa en un supuesto de homogeneidad que rara vez se sostiene en la práctica: que β_1 es el mismo para toda la población. Un año adicional de escolaridad no necesariamente genera el mismo diferencial salarial para un estudiante de primera generación en Puno que para uno con capital académico familiar consolidado en Lima.

Cuando el efecto es heterogéneo, el ratio $\hat{\beta}_{IV} = \widehat{\text{Cov}}_{\frac{Z,Y}{\text{Cov}}}(Z, T)$ deja de converger al ATE poblacional y converge en cambio a un estimando local — el efecto promedio solo entre quienes cambiaron su tratamiento a causa del instrumento. Este objeto, el Local Average Treatment Effect, fue formalizado por Imbens & Angrist (1994):

$$\tau_{\text{LATE}} = \mathbb{E}[Y(1) - Y(0) \mid T(1) = 1, T(0) = 0], \quad \text{plim } \hat{\beta}_{IV} = \tau_{\text{LATE}} \neq \tau_{\text{ATE}} \quad (5.4.1)$$

salvo que la población consista íntegramente de *compliers*. Identificar τ_{LATE} con rigor exige un tercer axioma —Monotonicidad— y la taxonomía completa de subgrupos de respuesta (Compliers, Always-Takers, Never-Takers, Defiers): el objeto del Capítulo 6. La implicación práctica ya es visible aquí: un LATE estimado con el instrumento Z_1 no necesariamente generaliza a un contexto donde opera Z_2 , porque cada instrumento define su propia subpoblación de compliers.

5.5 Verificación Computacional: Estimador de Wald y 2SLS

El siguiente código implementa manualmente el estimador de Wald y lo compara con 2SLS, incluyendo el diagnóstico de instrumento débil mediante el estadístico F del primer stage. El segundo bloque aplica el análisis completo con los datos reales de Card (1995): estimación 2SLS vía DoWhy, diagnóstico Stock-

Yogo, prueba de Hausman para endogeneidad con errores estándar bootstrap, refutación placebo y tabla de balance del instrumento contra covariables pre-tratamiento.

Un $F < 10$ en el primer stage indica instrumento débil: el sesgo del estimador IV se acerca al sesgo OLS y los intervalos de confianza pierden validez asintótica.

Ejemplo 5.1 (Distancia a universidad como instrumento para educación)

Card (1995) usa la distancia geográfica al college más cercano como instrumento para la escolaridad en estimaciones del retorno a la educación en EE.UU. La relevancia ($\pi_1 < 0$) es verificable: residir lejos de un college reduce significativamente los años de escolaridad ($F \approx 22$). La exogeneidad es plausible pero no testeable: la distancia al college es determinada históricamente y no debería correlacionar con la habilidad innata del individuo, salvo a través de la escolaridad. El estimador IV da un retorno del 13.2%, mayor que el OLS (6.8%), consistente con sesgo a la baja por error de medición en la escolaridad.

Ejemplo contextual (Perú): En evaluaciones del retorno a la educación en zonas rurales andinas, la distancia al centro educativo más cercano (en tiempo de viaje) se ha usado como instrumento para años de escolaridad. La relevancia es verificable: mayor distancia reduce asistencia ($F \approx 18$). La exogeneidad es plausible si la ubicación de escuelas responde a criterios histórico-administrativos no correlacionados con habilidad innata. Sin embargo, si la distancia correlaciona con acceso a mercados laborales o infraestructura, la restricción de exclusión se viola. Este caso ilustra por qué la validación de Z requiere conocimiento profundo del contexto local.

Supuestos clave

Supuestos del Capítulo 5 (Variables Instrumentales)

1. **Relevancia:** $\text{Cov}(Z, T) \neq 0$ — testeable; estadístico $F > 10$ en la primera etapa.
2. **Exogeneidad:** $\text{Cov}(Z, U) = 0$ — *no testeable*; requiere justificación institucional.
3. **Restricción de Exclusión:** Z afecta Y solo a través de T — tampoco testeable directamente.
4. **Monotonicidad (para LATE):** $T_{i(1)} \geq T_{i(0)}$ para todo i — sin Defiers.

Nota: Los supuestos 2 y 3 son la llave maestra'' no-testeable de IV. Su plausibilidad determina la credibilidad del resultado, no el valor- p de la primera etapa.

5.6 Cierre del capítulo

Las variables instrumentales rescatan identificación cuando la ignorabilidad falla, a costa de un estimando local y de supuestos de exclusión no testables. El Capítulo 6 precisa a **quién** responde el LATE.

Otras referencias clave de este capítulo: (Angrist et al., 1996), (Angrist & Pischke, 2009), (Heckman & Vytlačil, 2005), (Hernán & Robins, 2020).

5.6 Referencias

Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.

Angrist, J. D., Imbens, G. W., & Rubin, D. B. (1996). Identification of Causal Effects Using Instrumental Variables. *Journal of the American Statistical Association*, 91(434), 444-455.

Card, D. (1995). Using Geographic Variation in College Proximity to Estimate the Return to Schooling. *Aspects of Labour Market Behaviour: Essays in Honour of John Vanderkamp*, 201-222.

- Heckman, J. J., & Vytlačil, E. (2005). Structural Equations, Treatment Effects, and Econometric Policy Evaluation. *Econometrica*, 73(3), 669-738.
- Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.
- Imbens, G. W., & Angrist, J. D. (1994). Identification and Estimation of Local Average Treatment Effects. *Econometrica*, 62(2), 467-475.
- Wald, A. (1940). The Fitting of Straight Lines if Both Variables are Subject to Error. *The Annals of Mathematical Statistics*, 11(3), 284-300.
- Wright, P. G. (1928). *The Tariff on Animal and Vegetable Oils*. Macmillan.

CAPÍTULO 6

LATE y la Taxonomía de los Respondientes

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42**Notebook (pack):** notebooks/Bloque_I/notebooks/06_late_taxonomia_respondientes.ipynb**Jupyter Book:** jupyter_book/content/bloque_01_fundamentacion/06_late_taxonomia.ipynb

6.1 Heterogeneidad del Efecto Causal y el Marco de Imbens-Angrist

En los capítulos anteriores, simplificamos nuestro mundo mediante el supuesto de efecto constante, asumiendo que el impacto de una intervención es idéntico para todos los individuos: $\beta_{1i} = \beta_1$ de ambos grupos. Sin embargo, este supuesto es, en el mejor de los casos, una conveniencia matemática y, en el peor, una ficción estadística peligrosa. En la realidad de las políticas públicas y la economía aplicada, los tratamientos afectan heterogéneamente a las personas según su contexto, capacidades y preferencias. Un programa de capacitación puede ser transformador para un trabajador desempleado pero irrelevante para otro que ya posee habilidades avanzadas.

El marco de Imbens & Angrist (1994) transformó nuestra comprensión de la inferencia instrumental al formalizar esta heterogeneidad. Nos obliga a enfrentar una verdad incómoda: cuando los efectos varían entre individuos, el estimador de Variables Instrumentales (IV) que estudiamos anteriormente ya no identifica el Efecto Promedio de Tratamiento (ATE) poblacional. En su lugar, bajo condiciones de heterogeneidad, el IV recupera un parámetro diferente, más local y específico, que solo se puede entender si descomponemos la población en tipos de respuesta.

Definición 6.1 (Modelo Heterogéneo)

El modelo lineal con coeficientes aleatorios es:

$$Y_i = \beta_{0i} + \beta_{1i}T_i + U_i \quad (6.1.1)$$

donde β_{1i} varía individualmente con $\mathbb{E}[\beta_{1i}] = \beta_1$ y $\text{Var}(\beta_{1i}) > 0$. El efecto causal del tratamiento para la unidad i es $\tau_i = \beta_{1i}$.

El modelo de coeficientes aleatorios admite una traducción natural al lenguaje de resultados potenciales, donde la heterogeneidad queda explícita en la notación.

Definición 6.2 (Resultados Potenciales con Heterogeneidad)

Formalizando en notación de resultados potenciales:

$$Y_{i(t)} = \beta_{0i} + \beta_{1i} \cdot t + U_i \quad (6.1.2)$$

La variable de tratamiento observada satisface consistencia: $T_i = T_{i(Z_i)}$ donde $Z_i \in \{0, 1\}$ es la asignación instrumental.

Para ilustrar la gravedad de este problema, consideremos el siguiente escenario: nuestro estimador IV puede estar capturando solo una parte de la historia, sobrestimando o subestimando el verdadero efecto promedio en la población.

Teorema 6.1 (No-Identificación del ATE bajo Heterogeneidad)

Bajo heterogeneidad del efecto, el estimador IV no identifica el ATE poblacional:

$$\text{plim } \hat{\beta}_{IV} \neq \mathbb{E}[\beta_{1i}] = \tau_{\{i, \text{ATE}\}} \quad (6.1.3)$$

Dos instrumentos igualmente válidos pueden entonces producir estimaciones numéricamente distintas, simplemente porque mueven a subgrupos distintos de la población. Si el IV no identifica el ATE, ¿qué identifica? La respuesta requiere clasificar a los individuos según cómo responden al instrumento.

6.2 La Taxonomía de los Cuatro Tipos

La respuesta a la pregunta central requiere clasificar a la población según su patrón de respuesta al instrumento. Para entender esto, consideremos un ejemplo concreto de política pública en el contexto peruano: el gobierno lanza un programa nacional de becas universitarias ($Z = 1$: recibir la oferta de la beca). Nuestro tratamiento (T) es la matrícula efectiva en la universidad, y el resultado (Y) es el ingreso laboral futuro.

La intuición sugiere que no todos reaccionan igual a la oferta de la beca:

- Hay estudiantes de familias acomodadas de Lima que asistirán a la universidad con o sin ayuda financiera.
- Hay jóvenes en zonas rurales extremas de la sierra que, incluso con la beca, no pueden dejar sus labores agrícolas o mudarse a la ciudad.
- Y existe un grupo crítico: jóvenes de clase media de ciudades provincianas que desean estudiar, pero están financieramente constreñidos. Para ellos, la beca es la diferencia entre ir o no ir a la universidad.

Esta intuición se formaliza en la taxonomía de Imbens-Angrist. Cada individuo i tiene dos resultados potenciales de tratamiento: $T_{i(0)}$ (tratamiento si $Z = 0$) y $T_{i(1)}$ (tratamiento si $Z = 1$).

Definición 6.3 (Taxonomía de Respondientes)

Para cada individuo i , definimos el tipo según el vector $(T_{i(0)}, T_{i(1)}) \in \{0, 1\}^2$:

Tipo	$T_{i(0)}$	$T_{i(1)}$	Descripción
Compliers (C)	0	1	Toman tratamiento solo si $Z = 1$
Always-Takers (A)	1	1	Siempre toman tratamiento
Never-Takers (N)	0	0	Nunca toman tratamiento
Defiers (D)	1	0	Toman tratamiento solo si $Z = 0$

En nuestro ejemplo:

- Compliers (C): Los jóvenes de clase media que solo se matriculan si reciben la beca.
- Always-Takers (A): Los estudiantes ricos que se matricularían de todos modos.
- Never-Takers (N): Los jóvenes rurales que no pueden asistir bajo ninguna circunstancia.
- Defiers (D): Un grupo teórico extraño: aquellos que solo se matricularían si *no* reciben la beca (quizás por orgullo o rebeldía).

El drama epistemológico es que estos tipos son latentes. Nunca observamos directamente quién es Complier, Always-Taker o Never-Taker; solo vemos el estado de tratamiento observado T y la asignación Z .

Definición 6.4 (Variables Indicadoras)

Las indicadoras de tipo son:

$$C_i = \mathbb{I}\{T_{i(0)} = 0, T_{i(1)} = 1\} A_i = \mathbb{I}\{T_{i(0)} = 1, T_{i(1)} = 1\} N_i = \mathbb{I}\{T_{i(0)} = 0, T_{i(1)} = 0\} D_i = \mathbb{I}\{T_{i(0)} = 1, T_{i(1)} = 0\}$$

Los cuatro tipos constituyen una partición exhaustiva — hecho trivialmente cierto por construcción, pues los indicadores cubren todas las combinaciones de $(T_{i(0)}, T_{i(1)}) \in \{0, 1\}^2$:

$$C_i + A_i + N_i + D_i = 1 \quad \forall i, \quad \mathbb{P}(C) + \mathbb{P}(A) + \mathbb{P}(N) + \mathbb{P}(D) = 1. \quad (6.2.2)$$

En la práctica, para la mayoría de intervenciones sociales positivas (como ofrecer dinero o educación), el grupo de “Defiers” es inexistente o negligible. Es difícil imaginar a alguien que rechace una beca a la que tendría derecho, pero que la aceptara si no se la hubieran ofrecido.

Definición 6.5 (Supuesto de Monotonicidad)

El supuesto de monotonicidad establece que el instrumento no tiene efectos negativos sobre la probabilidad de tratamiento para ningún individuo:

$$T_{i(1)} \geq T_{i(0)} \quad \forall i \quad (6.2.3)$$

Equivalentemente: no existen Defiers en la población.

La monotonicidad elimina del análisis al tipo más problemático. El siguiente resultado muestra que los Defiers desaparecen por completo de la partición poblacional.

Teorema 6.2 (Eliminación de Defiers bajo Monotonicidad)

Bajo monotonicidad, $\mathbb{P}(D_i = 1) = 0$. La partición se reduce a tres tipos:

$$C_i + A_i + N_i = 1 \quad (6.2.4)$$

6.3 El Teorema LATE (Imbens & Angrist, 1994)

Con la taxonomía establecida y el supuesto de monotonicidad en su lugar, estamos listos para responder a la pregunta central: ¿qué está midiendo exactamente nuestro estimador IV? La respuesta, provista por el Teorema de Imbens-Angrist, es uno de los resultados más profundos de la econometría moderna. El estimador IV, bajo heterogeneidad, no habla por toda la población. “Habla” exclusivamente por los Compliers. En nuestro ejemplo de becas, el IV calcula el efecto de la educación universitaria en el ingreso solo para aquellos estudiantes que la beca logró matricular. El efecto para los estudiantes ricos (Always-Takers) o los jóvenes rurales (Never-Takers) se cancela algebraicamente en la ecuación de IV. Es una cancelación silenciosa, matemática, pero con implicaciones dramáticas para la interpretación de la política.

Definición 6.6 (Supuestos del LATE)

El marco LATE requiere cuatro supuestos:

1. Independencia: $(Y_{i(0)}, Y_{i(1)}, T_{i(0)}, T_{i(1)}) \perp\!\!\!\perp Z_i$
2. Restricción de Exclusión: $Y_{i(z,t)} = Y_{i(t)}$ para todo z, t (el instrumento afecta Y solo a través de T)
3. Relevancia: $\mathbb{E}[T_i | Z_i = 1] \neq \mathbb{E}[T_i | Z_i = 0]$
4. Monotonicidad: $T_{i(1)} \geq T_{i(0)}$ para todo i (sin Defiers)

Supuesto	Función en la demostración	Consecuencia si falla
Independencia	Distribución de tipos idéntica en $Z = 0$ y $Z = 1$; permite descomponer esperanzas.	Sesgo de selección instrumental.
Exclusión	Y solo cambia vía T ; cancela términos de Always/Never-Takers.	Estimador captura efectos directos de Z .
Relevancia	Denominador $\mathbb{P}(C) > 0$; evita división por cero.	Varianza infinita; estimador inestable.
Monotonicidad	Elimina Defiers; garantiza $\mathbb{P}(C) = \mathbb{E}[T Z = 1] - \mathbb{E}[T Z = 0]$.	LATE pierde interpretación como promedio coherente.

Tabla 7: Rol de los supuestos en la identificación del LATE

Definición 6.7 (Estimando LATE (Poblacional))

El *Local Average Treatment Effect* (LATE) es el efecto causal promedio condicional a pertenecer al subgrupo de Compliers:

$$\tau_{\text{LATE}} := \mathbb{E}[Y(1) - Y(0) | T(1) = 1, T(0) = 0]. \quad (6.3.1)$$

A diferencia del ATE, que promedia sobre toda la población, τ_{LATE} es un parámetro *local*: identifica el impacto del tratamiento únicamente en las unidades cuya decisión de participar depende del instrumento Z .

Definido el parámetro de interés, el teorema central de Imbens-Angrist establece que el estimador IV lo recupera de forma exacta en el límite poblacional.

Teorema 6.3 (Identificación Poblacional del LATE)

Bajo los cuatro supuestos del LATE, el parámetro IV poblacional satisface:

$$\beta_{\text{IV}}^{\{\text{pop}\}} := \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, T)} = \mathbb{E}[Y(1) - Y(0) | C = 1] = \tau_{\text{LATE}}. \quad (6.3.2)$$

Bajo las mismas condiciones y regularidad estándar, el estimador muestral $\hat{\beta}_{\text{IV}}$ (Wald o 2SLS) es *consistente* para τ_{LATE} :

$$\hat{\beta}_{\text{IV}} \xrightarrow{p} \tau_{\text{LATE}} \quad \text{cuando } n \rightarrow \infty. \quad (6.3.3)$$

La igualdad en el teorema es un resultado de *identificación* (nivel poblacional); la convergencia es una propiedad de *estimación* (nivel muestral).

6.3.0.0.1 Intuición de la identificación.

El numerador $\mathbb{E}[Y | Z = 1] - \mathbb{E}[Y | Z = 0]$ captura el cambio promedio en Y inducido por Z . Bajo exclusión e independencia, solo los Compliers cambian su T y, por tanto, contribuyen a este cambio. El denominador $\mathbb{E}[T | Z = 1] - \mathbb{E}[T | Z = 0]$ mide exactamente la proporción de Compliers. Al dividir, el factor $\mathbb{P}(C)$ se cancela, dejando el efecto promedio *dentro* de ese grupo.

Corolario 6.1 (LATE como efecto promedio en compliers)

El estimador IV identifica el efecto causal promedio para la subpoblación de Compliers: aquellos que cambian su estado de tratamiento en respuesta al instrumento. No identifica el ATE poblacional ni el ATT, salvo que la población consista únicamente de Compliers.

Esto significa que, si el programa de becas tiene un efecto de retorno del 10% según nuestro IV, este retorno es estrictamente el retorno para los estudiantes que se matricularon gracias a la beca. No nos dice nada sobre cuánto ganarían los estudiantes ricos (que ya hubieran estudiado) ni si los estudiantes rurales habrían tenido éxito si hubieran podido ir.

6.4 Implicaciones y Validez Externa del LATE

El descubrimiento del LATE genera una tensión inevitable entre validez interna y externa. Internamente, el IV nos da una estimación limpia y causal para un grupo bien definido (los Compliers). Externamente, sin embargo, nos deja con la duda: ¿qué tan representativos son estos Compliers del resto de la sociedad? El teorema LATE tiene implicaciones profundas para la interpretación y extrapolación de resultados de IV.

Proposición 6.1 (Identificación de la Proporción de Compliers)

La proporción de Compliers en la población es identificable directamente de los datos:

$$\mathbb{P}(C) = \mathbb{E}[T|Z = 1] - \mathbb{E}[T|Z = 0] \quad (6.4.1)$$

Esta proporción mide qué tan “poderoso” es el instrumento: si la diferencia de tasas de matrícula entre becarios y no becarios es grande, el LATE es aplicable a un segmento amplio de la población; si es pequeña, se aplica solo a una fracción minúscula y posiblemente atípica.

Teorema 6.4 (Condición de Equivalencia LATE=ATE)

El LATE coincide con el ATE poblacional si y solo si el efecto causal es constante:

$$\text{LATE} = \tau_{\text{ATE}} \Leftrightarrow \beta_{1i} = \beta_1 \quad \forall i \quad (6.4.2)$$

Si existe heterogeneidad correlacionada con la probabilidad de ser Complier —algo plausible en la mayoría de contextos—, el LATE y el ATE difieren, y asumir que el IV mide el ATE equivale a asumir implícitamente que todos ganan lo mismo con el tratamiento.

Proposición 6.2 (LATE $\neq$ ATT en General)

En general, el LATE difiere del efecto en los tratados:

$$\mathbb{E}[Y(1) - Y(0)|C] \neq \mathbb{E}[Y(1) - Y(0)|T = 1] \quad (6.4.3)$$

Definición 6.8 (Problema de Validez Externa)

El LATE depende del instrumento específico Z utilizado. Diferentes instrumentos Z_1, Z_2 que satisfacen los supuestos del LATE generalmente identifican diferentes subpoblaciones de Compliers:

$$\text{LATE}_{Z_1} = \mathbb{E}[\beta_{1i}|C^{(Z_1)}] \neq \mathbb{E}[\beta_{1i}|C^{(Z_2)}] = \text{LATE}_{Z_2} \quad (6.4.4)$$

Si bien el LATE es identificable, las proporciones individuales de Always-Takers y Never-Takers no lo son, lo que limita nuestra capacidad de caracterizar completamente la población.

Teorema 6.5 (No-Identificabilidad de Always-Takers y Never-Takers)

Las proporciones individuales de Always-Takers y Never-Takers no son separadamente identificables. Solo se identifica su suma:

$$\mathbb{P}(A) + \mathbb{P}(N) = 1 - \mathbb{P}(C) \quad (6.4.5)$$

Corolario 6.2 (Multiplicidad de LATEs)

Diferentes instrumentos válidos producen diferentes LATEs sobre diferentes subpoblaciones de Compliers. No existe un efecto causal del tratamiento “único identificable por IV”; solo existen efectos causales locales específicos al instrumento empleado.

Esta multiplicidad de LATEs constituye el límite fundamental de la validez externa en la inferencia IV: los resultados no son generalizables a otros contextos instrumentales ni a la población completa sin supuestos adicionales fuertes sobre la homogeneidad de efectos o la representatividad de los Compliers. Para el formulador de políticas, el mensaje es claro: un instrumento es una lente específica que ilumina solo una parte del paisaje social. Diseñar políticas basadas únicamente en un LATE requiere una comprensión profunda de quién es ese “Complier” local.

6.4.1 El Estimando ITT y su Relación Estructural con el LATE

En la evaluación de políticas públicas, el formulador de política enfrenta un límite operativo fundamental: puede aleatorizar la oferta del tratamiento (Z), pero no puede garantizar la participación efectiva (T). El Ministerio de Desarrollo e Inclusión Social puede seleccionar aleatoriamente a los hogares que recibirán la oferta del programa **Juntos**, pero no puede obligar a ninguna familia a matricular a sus hijos en la escuela. El estimando que el gobierno puede medir directamente es el **Intention-to-Treat (ITT)**.

Definición 6.9 (Intention-to-Treat)

El estimando ITT mide el efecto causal de la asignación instrumental Z sobre el resultado Y , independientemente del tratamiento efectivo recibido:

$$\tau_{\text{ITT}} = \mathbb{E}[Y \mid Z = 1] - \mathbb{E}[Y \mid Z = 0] \quad (6.4.6)$$

El ITT es identificable sin supuesto de monotonicidad ni restricción de exclusión: basta con la independencia del instrumento. Su limitación es interpretativa: promedia el efecto sobre Compliers con la ausencia de efecto sobre Always-Takers y Never-Takers, atenuando el estimando hacia cero.

Proposición 6.3 (Relación Estructural LATE–ITT)

Bajo los supuestos del LATE, el ITT y el LATE se vinculan mediante la proporción de Compliers:

$$\tau_{\text{ITT}} = \tau_{\text{LATE}} \cdot \mathbb{P}(C) \quad (6.4.7)$$

y por tanto el estimador de Wald no es más que el ITT reescalado:

$$\tau_{\text{LATE}} = \frac{\tau_{\text{ITT}}}{\mathbb{P}(C)} = \mathbb{E}[Y \mid Z = 1] - \mathbb{E}[Y \mid Z = 0] \{ \mathbb{E}[T \mid Z = 1] - \mathbb{E}[T \mid Z = 0] \} \quad (6.4.8)$$

Esta relación tiene una implicación directa para el análisis de programas sociales: el ITT subestima el LATE en la proporción exacta de la tasa de incumplimiento. Si en el programa **Juntos** solo el 60% de los

hogares seleccionados modifican efectivamente su comportamiento de escolaridad, entonces $\mathbb{P}(C) = 0.6$ y el efecto causal real sobre los Compliers es un 67% mayor que el ITT observado. El gobierno mide el ITT; el econometrista rescala por la tasa de compliance para recuperar el LATE.

Cadena de decisión práctica: En evaluaciones de políticas, el gobierno reporta $\hat{\tau}_{\{ITT\}}$ (efecto de la oferta). El econometrista lo convierte en efecto del *tratamiento recibido* dividiendo por la tasa de cumplimiento: $\hat{\tau}_{\{LATE\}} = \frac{\hat{\tau}_{\{ITT\}}}{\hat{\mathbb{P}}}(C)$. Esta relación no es una aproximación: es la base exacta del estimador de Wald. Si $\hat{\mathbb{P}}(C) < 0.2$, el LATE será numéricamente estable pero estadísticamente frágil (varianza inflada por el denominador pequeño).

6.4.2 Sensibilidad a la violación de la restricción de exclusión

La restricción de exclusión (Z afecta Y solo a través de T) no es testable con los datos. Conley et al. (2012) proponen acotar cuánto variaría el LATE si Z tuviera un efecto directo pequeño γ sobre Y . El LATE corregido bajo un efecto directo de magnitud γ es:

$$\tau_{LATE}^{(\gamma)} = \frac{\tau_{ITT} - \gamma}{\mathbb{P}(C)}. \quad (6.4.9)$$

Variando γ en un rango de plausibilidad $[-\delta, \delta]$ se obtiene un intervalo de sensibilidad: si el LATE permanece positivo y económicamente relevante para todo γ en ese rango, la conclusión es robusta a violaciones pequeñas de la exclusión.

6.5 Verificación Computacional: Taxonomía de Respondientes y LATE vs. ATE

El primer bloque simula una población con los cuatro tipos de respondientes y verifica empíricamente que el estimador IV recupera el LATE (no el ATE). El segundo bloque aplica el análisis completo con datos reales de Card (1995): estimador de Wald manual, intervalo de confianza bootstrap, análisis de sensibilidad Conley, gráfico de primera etapa residualizada y heterogeneidad regional del LATE.

Los resultados confirman que $\hat{\beta}_{IV} \rightarrow \tau_{LATE} \neq \tau_{ATE}$ y que $ITT = \tau_{LATE} \cdot \mathbb{P}(C)$, con $\mathbb{P}(C)$ identificable como la diferencia de tasas de tratamiento entre brazos del instrumento.

Ejemplo 6.1 (LATE de beca universitaria en Perú: cadena $ITT \rightarrow LATE$)

Un programa de becas de la PRONABEC asigna aleatoriamente una oferta de beca ($Z = 1$) al 50% de postulantes elegibles. Solo el 60% de los ofertados la aceptan efectivamente ($\mathbb{P}(C) = 0.6$; siempre-tomadores y nunca-tomadores representan el 40% restante). El ITT observable es $\hat{\tau}_{\{ITT\}} = 800$ soles/mes. La primera etapa entrega $\hat{\mathbb{P}}(C) = 0.60$. Aplicando la relación estructural:

$$\hat{\tau}_{\{LATE\}} = \frac{\hat{\tau}_{\{ITT\}}}{\hat{\mathbb{P}}(C)} = \frac{800}{0.60} = 1333 \text{ soles/mes.} \quad (6.5.1)$$

Note que este número **no** es el ATE; es el retorno esperado para el 60% de jóvenes cuya matrícula dependió de la beca (los Compliers). Los Always-Takers y Never-Takers se cancelan algebraicamente en el estimador de Wald.

Supuestos clave**Supuestos del Capítulo 6 (LATE)**

1. **Independencia:** $(Y(0), Y(1), T(0), T(1)) \perp\!\!\!\perp Z$.
2. **Exclusión:** Z afecta Y solo a través de T .
3. **Relevancia:** $\mathbb{E}[T \mid Z = 1] \neq \mathbb{E}[T \mid Z = 0]$.
4. **Monotonicidad:** $T_{i(1)} \geq T_{i(0)}$ para todo i – elimina Defiers.

6.5.0.0.1 Puente al Capítulo 7.

En el *Fuzzy RDD*, la variable $Z = \mathbb{I}\{X \geq c\}$ cumple exactamente el rol de instrumento estudiado aquí. La discontinuidad en $X = c$ induce un salto en $\mathbb{P}(T = 1)$, creando un grupo local de Compliers. El estimador Fuzzy-RDD es algebraicamente idéntico al estimador de Wald aplicado en la vecindad del umbral: $\hat{\tau}_{\{\text{FRD}\}} = \Delta \frac{Y}{\Delta} T = \hat{\tau}_{\{\text{LATE}\}}(X = c)$. El Capítulo 7 extiende esta lógica a diseños con asignación cuasi-aleatoria continua.

6.6 Cierre del capítulo

El LATE responde a una subpoblación latente (compliers), no a la población completa. La monografía fija el contrato: relevancia, exclusión y monotonicidad definen **quién** habla cuando se reporta un IV.

Otras referencias clave de este capítulo: (Angrist et al., 1996), (Angrist & Pischke, 2009), (Vytlačil, 2002), (Bloom, 1984), (Heckman & Vytlačil, 2005), (Abadie, 2003).

6.6 Referencias

- Abadie, A. (2003). Semiparametric Instrumental Variable Estimation of Treatment Response Models. *Journal of Econometrics*, 113(2), 231-263.
- Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.
- Angrist, J. D., Imbens, G. W., & Rubin, D. B. (1996). Identification of Causal Effects Using Instrumental Variables. *Journal of the American Statistical Association*, 91(434), 444-455.
- Bloom, H. S. (1984). Accounting for No-Shows in Experimental Evaluation Designs. *Evaluation Review*, 8(2), 225-246.
- Card, D. (1995). Using Geographic Variation in College Proximity to Estimate the Return to Schooling. *Aspects of Labour Market Behaviour: Essays in Honour of John Vanderkamp*, 201-222.
- Conley, T. G., Hansen, C. B., & Rossi, P. E. (2012). Plausibly Exogenous. *Review of Economics and Statistics*, 94(1), 260-272.
- Heckman, J. J., & Vytlačil, E. (2005). Structural Equations, Treatment Effects, and Econometric Policy Evaluation. *Econometrica*, 73(3), 669-738.
- Imbens, G. W., & Angrist, J. D. (1994). Identification and Estimation of Local Average Treatment Effects. *Econometrica*, 62(2), 467-475.
- Vytlačil, E. (2002). Independence, Monotonicity, and Latent Index Models: An Equivalence Result. *Econometrica*, 70(1), 331-341.

CAPÍTULO 7

Regression Discontinuity Design: La Geometría del Umbral

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42

Notebook (pack): notebooks/Bloque_I/notebooks/07_regression_discontinuity_design_geometria_umbral.ipynb

Jupyter Book: jupyter_book/content/bloque_01_fundamentacion/07_regression_discontinuity.ipynb

7.1 Sharp RDD: La Aleatorización en el Umbral

En nuestra búsqueda de efectos causales en un mundo no aleatorizado, pocas estrategias poseen la elegancia conceptual del Diseño de Regresión Discontinua (RDD). La premisa es intuitiva y poderosa: a menudo, el mundo real funciona a través de umbrales. Ya sea el límite de edad para votar, el puntaje de corte para un préstamo bancario, o, en el caso que nos atañe, el puntaje mínimo para ingresar a la universidad.

Imaginemos el examen de admisión a la Universidad Nacional de Ingeniería (UNI). Miles de estudiantes rinden una prueba estandarizada. La regla es draconiana y pública: si tu puntaje X_i es mayor o igual al cutoff c , eres admitido ($T_i = 1$); si es menor, no lo eres ($T_i = 0$). En este escenario, la diferencia de un solo punto—una respuesta correcta o incorrecta—determina un resultado binario radicalmente distinto. La belleza del RDD reside en que, justo en la vecindad inmediata de ese umbral c , la comparación entre admitidos y no admitidos se vuelve asintóticamente similar a un experimento aleatorio. Los estudiantes con un puntaje de 199.9 son casi idénticos en capacidad y esfuerzo a los que sacaron 200.1; el segundo tuvo un “poco de suerte”, mientras que el primero tuvo “poca mala suerte”.

El lector que ha completado el Capítulo 6 reconocerá una distinción conceptual fundamental: mientras que la Variable Instrumental (IV) utiliza la variación en Z para purgar la endogeneidad del tratamiento T —siendo el instrumento de naturaleza probabilística y susceptible de debilidad—el RDD explota un mecanismo de asignación determinístico: el umbral c . Este determinismo local genera variación cuasi-experimental perfecta en la vecindad inmediata de c . Geométricamente, el efecto causal es el salto: bajo el supuesto de continuidad, $\mathbb{E}[Y|X = x]$ es suave a ambos lados del umbral, y cualquier discontinuidad en $x = c$ es necesariamente imputable al tratamiento. Un gráfico de dispersión de Y contra X mostrará una nube de puntos continua interrumpida por un salto abrupto en c —la geometría del umbral que da título a este capítulo.

El Regression Discontinuity Design (RDD) explota estas reglas de asignación deterministas basadas en una variable continua para identificar efectos causales localmente. Cuando la regla es estricta (asignación perfecta al cruzar el umbral), el diseño se denomina Sharp RDD.

Definición 7.1 (Sharp RDD)

La running variable $X_i \in \mathbb{R}$ determina la asignación mediante umbral c :

$$T_i = \mathbb{I}\{X_i \geq c\} \quad (7.1.1)$$

Los resultados potenciales $Y_{i(1)}, Y_{i(0)}$ satisfacen consistencia: $Y_i = T_i Y_{i(1)} + (1 - T_i) Y_{i(0)}$.

Para que esta intuición de “comparabilidad local” se sostenga matemáticamente, debemos asumir que, en ausencia del tratamiento, el resultado no experimentaría saltos bruscos en el umbral. La función de ingresos laborales futuros Y , por ejemplo, debería ser suave en función de la capacidad del estudiante (X); cualquier discontinuidad observada en los ingresos reales en el punto de corte debe atribuirse al tratamiento (la admisión a la universidad).

Definición 7.2 (Supuesto de Continuidad)

Las funciones de regresión condicional son continuas en el umbral:

$$\lim_{x \downarrow c} \mathbb{E}[Y(0)|X = x] = \lim_{x \uparrow c} \mathbb{E}[Y(0)|X = x] = \mathbb{E}[Y(0)|X = c] \quad \lim_{x \downarrow c} \mathbb{E}[Y(1)|X = x] = \lim_{x \uparrow c} \mathbb{E}[Y(1)|X = x] = \mathbb{E}[Y(1)|X = c]$$

Este supuesto es el corazón del RDD. Nos permite aislar el salto causal del tratamiento de la tendencia subyacente.

Teorema 7.1 (Identificación en Sharp RDD)

Bajo el supuesto de continuidad, el efecto causal en el umbral es identificable:

$$\tau_{\text{SRD}} = \mathbb{E}[Y(1) - Y(0) | X = c] = \lim_{x \downarrow c} \mathbb{E}[Y|X = x] - \lim_{x \uparrow c} \mathbb{E}[Y|X = x] \quad (7.1.3)$$

Es importante notar, sin embargo, que esta es una estimación muy específica.

Corolario 7.1 (Localidad del Estimando)

El parámetro τ_{SRD} es local: identifica el efecto causal promedio únicamente para la subpoblación con $X = c$. No identifica el ATE poblacional $\mathbb{E}[Y(1) - Y(0)]$ ni el ATT sin supuestos adicionales de homogeneidad del efecto. En el contexto de la UNI, esto significa que estamos estimando el retorno de la educación para los estudiantes marginales, aquellos en la frontera de ingreso, y no necesariamente para los mejores estudiantes ni para los que reprobaron ampliamente.

7.2 Estimación No Paramétrica: Regresión Local

Hemos establecido teóricamente que queremos estimar los límites μ_+ y μ_- . Sin embargo, en la práctica nos enfrentamos a un desafío: no tenemos datos infinitos y es improbable que existan observaciones exactamente en $X = c$. En el ejemplo de la UNI, quizás nadie obtuvo exactamente 400.000 puntos; algunos tuvieron 399.9 y otros 400.1. Necesitamos “acercarnos” al umbral utilizando observaciones vecinas.

La estimación de τ_{SRD} requiere aproximar límites laterales de funciones de regresión desconocidas usando solo observaciones cercanas al umbral.

Definición 7.3 (Problema de Estimación)

Se requiere estimar:

$$\mu_+ = \lim_{x \downarrow c} \mathbb{E}[Y|X = x], \quad \mu_- = \lim_{x \uparrow c} \mathbb{E}[Y|X = x] \quad (7.2.1)$$

con estimadores $\hat{\mu}_+$ y $\hat{\mu}_-$ tales que $\hat{\tau}_{\text{SRD}} = \hat{\mu}_+ - \hat{\mu}_-$.

La solución estándar es la regresión local lineal. En lugar de usar toda la muestra (que introduciría sesgo porque la relación entre ingresos y puntaje probablemente no es lineal en todo el rango), ajustamos dos líneas rectas: una para los datos justo a la izquierda del corte y otra para los datos justo a la derecha. Para dar más peso a los puntos más cercanos, usamos funciones de ponderación (kernels) que caen suavemente a cero a medida que nos alejamos de c .

Definición 7.4 (Kernel y Ancho de Banda)

Un kernel $K : \mathbb{R} \rightarrow \mathbb{R}_+$ satisface $\int K(u) du = 1$, $K(u) = K(-u)$, y soporte compacto $[-1, 1]$. Ejemplos:

- Epanechnikov: $K(u) = \frac{3}{4}(1 - u^2)\mathbb{I}\{|u| \leq 1\}$
- Triangular: $K(u) = (1 - |u|)\mathbb{I}\{|u| \leq 1\}$

El kernel escalado es $K_{h(u)} = \frac{1}{h}K\left(\frac{u}{h}\right)$ donde $h > 0$ es el ancho de banda.

El kernel define la ventana de proximidad al umbral, pero no especifica cómo usar las observaciones dentro de esa ventana para aproximar los límites laterales. El siguiente bloque formaliza esta transición: del concepto de ponderación local al problema de estimación de los interceptos μ_+ y μ_- .

Definición 7.5 (Estimadores de Regresión Local)

Para polinomio de orden p , los estimadores $\hat{\mu}_+$ y $\hat{\mu}_-$ resuelven:

$$\hat{\beta}^+ = \arg \min_{\beta} \sum_{i: X_i \geq c} K_{h(X_i - c)} \left(Y_i - \sum_{j=0}^p \beta_j (X_i - c)^j \right)^2 \quad \hat{\beta}^- = \arg \min_{\beta} \sum_{i: X_i < c} K_{h(X_i - c)} \left(Y_i - \sum_{j=0}^p \beta_j (X_i - c)^j \right)^2$$

Los estimadores de los límites son $\hat{\mu}_+ = \hat{\beta}_0^+$ y $\hat{\mu}_- = \hat{\beta}_0^-$.

La estructura de mínimos cuadrados ponderados del problema de optimización admite una solución explícita en forma matricial, lo que permite implementar el estimador sin recurrir a optimización numérica iterativa.

Proposición 7.1 (Solución Cerrada del Estimador de Regresión Local Ponderada)

La solución explícita al programa de regresión local en el lado derecho del umbral es:

$$\hat{\mu}_+ = e_1^{\text{top}} (X_+^{\text{top}} W_+ X_+^{\text{top}})^{-1} X_+^{\text{top}} W_+ Y_+ \quad (7.2.3)$$

donde $e_1 = (1, 0, \dots, 0)^{\text{top}} \in \mathbb{R}^{p+1}$ selecciona el intercepto local, $X_+ \in \mathbb{R}^{n_+ \times (p+1)}$ es la matriz de diseño polinomial con filas $(1, X_i - c, \dots, (X_i - c)^p)$ para $X_i \geq c$, $W_+ = \text{diag}(K_{h(X_i - c)})_{X_i \geq c}$ es la matriz diagonal de pesos kernel, y Y_+ es el vector de resultados para $X_i \geq c$. La solución para $\hat{\mu}_-$ es análoga usando $X_i < c$. Esta expresión es la solución WLS que pondera cada observación por su proximidad al umbral: el bandwidth h controla cuánta información local se usa, siendo el parámetro de resolución del estimador.

Para el estimador de regresión local lineal ($p = 1$), el sesgo es $O(h^2)$ (determinado por la curvatura de la función de regresión subyacente) y la varianza es $O(\frac{1}{Nh})$ (determinada por la densidad de observaciones

en el umbral). El MSE óptimo se minimiza en $h^* = O(N^{-\frac{1}{5}})$, que balancea el crecimiento del sesgo al ampliar h contra la reducción de varianza al incluir más observaciones.

Definición 7.6 (Estimador Final del SRD)

$$\hat{\tau}_{\text{SRD}} = \hat{\mu}_+ - \hat{\mu}_- = \hat{\beta}_0^+ - \hat{\beta}_0^- \quad (7.2.4)$$

Un desafío crucial en esta estimación es elegir el ancho de banda (h). Si h es demasiado grande, usaremos observaciones lejanas al corte (puntajes muy altos y muy bajos) que no son comparables, introduciendo sesgo de especificación. Si h es demasiado pequeño, usaremos muy pocos datos, aumentando drásticamente la varianza de nuestro estimador.

Proposición 7.2 (Trade-off Sesgo-Varianza)

El error cuadrático medio condicional del estimador satisface:

$$\text{Sesgo}[\hat{\tau}_{\text{SRD}}|X] = O(h^{p+1}) \quad \text{Varianza}[\hat{\tau}_{\text{SRD}}|X] = O\left(\frac{1}{Nh}\right) \quad \text{MSE} = O(h^{2(p+1)}) + O\left(\frac{1}{Nh}\right) \quad (7.2.5)$$

Para encontrar el punto óptimo en este trade-off, utilizamos métodos robustos como el de Imbens-Kalyanaraman.

Teorema 7.2 (Ancho de Banda Óptimo de Imbens-Kalyanaraman)

Para regresión local lineal ($p = 1$) con kernel Epanechnikov, el ancho de banda óptimo que minimiza el MSE asintótico es:

$$h_{\text{IK}} = C_{\text{IK}} \cdot \hat{\sigma}_X \cdot N^{-\frac{1}{5}} \quad (7.2.6)$$

donde C_{IK} es una constante que depende de las segundas derivadas de las funciones de regresión y la densidad de X en c .

7.3 Fuzzy RDD y su Conexión con Variables Instrumentales

Hasta ahora hemos asumido un mundo de reglas perfectas: en el Sharp RDD, cruzar el umbral garantiza el tratamiento con probabilidad 1. Sin embargo, la realidad administrativa de las instituciones peruanas a menudo es más compleja. En la admisión universitaria, existen apelaciones, cupos para hijos de trabajadores, becas especiales o estudiantes de regiones fronterizas. Es posible que un estudiante con 399 puntos sea admitido, mientras que otro con 401 puntos decida no matricularse por razones económicas. Cuando la regla de asignación genera un salto en la probabilidad de tratamiento menor que uno, el diseño se denomina Fuzzy RDD. Aquí, el umbral no es el tratamiento, sino un determinante fuerte del mismo. La discontinuidad en el umbral actúa como instrumento para el tratamiento real.

El lector atento habrá notado una profunda conexión narrativa con el Capítulo 6. El Fuzzy RDD no es más que el Teorema LATE aplicado en la vecindad del umbral. La variable Z (estar por encima del corte) es el instrumento para el tratamiento real T (matricularse), y los “Compliers” son aquellos estudiantes marginales que solo se matricularían si cruzan el puntaje de corte.

Definición 7.7 (Fuzzy RDD)

La probabilidad condicional de tratamiento presenta un salto en el umbral:

$$\lim_{x \downarrow c} \mathbb{P}(T = 1 | X = x) - \lim_{x \uparrow c} \mathbb{P}(T = 1 | X = x) = \pi_+ - \pi_- \in (0, 1) \quad (7.3.1)$$

donde $\pi_+ \neq \pi_-$ pero ninguno es 0 ni 1. Se define $Z_i = \mathbb{I}\{X_i \geq c\}$ como asignación instrumental.

Este salto probabilístico más débil que el caso sharp no impide la identificación: simplemente desplaza el estimando del efecto promedio del tratamiento al efecto local sobre los compliers, recuperando la lógica LATE del Capítulo 6.

Teorema 7.3 (Identificación en Fuzzy RDD)

Bajo los supuestos de Relevancia ($\pi_+ \neq \pi_-$), Exclusión (Z afecta Y solo a través de T), Continuidad de $\mathbb{E}[Y(t) | X = x]$, y Monotonicidad ($T_{i(1)} \geq T_{i(0)}$):

$$\tau_{\text{FRD}} = \frac{\mu_+ - \mu_-}{\pi_+ - \pi_-} = \mathbb{E}[Y(1) - Y(0) | X = c, \text{Complier}] \quad (7.3.2)$$

La taxonomía completa de tipos (Compliers, Always-Takers, Never-Takers) del Capítulo 6 se aplica sin modificación en la vecindad del umbral.

Proposición 7.3 (Equivalencia Algebraica con IV)

El estimador Fuzzy RDD es algebraicamente idéntico al estimador de Wald con instrumento $Z_i = \mathbb{I}\{X_i \geq c\}$:

$$\hat{\tau}_{\text{FRD}} = \frac{\hat{\mu}_+ - \hat{\mu}_-}{\hat{\pi}_+ - \hat{\pi}_-} = \frac{\widehat{\text{Cov}}(Z, Y)}{\widehat{\text{Cov}}(Z, T)} = \hat{\beta}_{\text{IV}} \quad (7.3.3)$$

La equivalencia es exacta porque, con un instrumento binario, la covarianza muestral colapsa a una diferencia de medias — el mismo cociente que define a Wald.

7.4 Tests de Validez y Falsificación

La elegancia del RDD no nos exonera de la escéptica labor de validación. La credibilidad de nuestro diseño descansa sobre el supuesto de que el umbral es arbitrario y que los agentes no pueden manipularlo perfectamente. En el contexto de exámenes estandarizados como el de la UNI, esto es un riesgo real: ¿están ocurriendo filtraciones? ¿Los evaluadores están ajustando notas manualmente para aprobar a ciertos candidatos?

La validez del RDD requiere verificar que el supuesto de continuidad no sea violado por comportamiento estratégico de los agentes.

Definición 7.8 (Test de McCrary (2008))

El test de McCrary (2008) evalúa si la densidad de la running variable presenta discontinuidad en el umbral, calculando los límites laterales $f(c^-)$ y $f(c^+)$ y testeando la hipótesis nula:

$$H_0 : f(c^-) = f(c^+) \quad (7.4.1)$$

versus la alternativa de discontinuidad (manipulación del umbral). Formalmente:

$$H_0 : \lim_{x \downarrow c} f_{X(x)} = \lim_{x \uparrow c} f_{X(x)} \quad (7.4.2)$$

La hipótesis nula de continuidad en la densidad debe operacionalizarse mediante un procedimiento estadístico concreto que estime las densidades laterales y construya un estadístico de prueba.

Proposición 7.4 (Procedimiento del Test de McCrary)

El test estima $\hat{f}(c^-)$ y $\hat{f}(c^+)$ mediante regresión local sobre la densidad empírica de la running variable y compara ambos estimados. El procedimiento formal es:

1. Construir un histograma fino de X con celdas de ancho $b \ll h$ (típicamente $b = 2\hat{\sigma}_X n^{-\frac{1}{2}}$).
2. Estimar por regresión local la densidad $\hat{f}(c^-)$ usando celdas en $[c - h_f, c)$ y $\hat{f}(c^+)$ usando celdas en $(c, c + h_f]$.
3. El estadístico de test es $\hat{f}(c^+) - \hat{f}(c^-)$ con varianza estimada por fórmulas analíticas o bootstrap.
4. Bajo H_0 (ausencia de manipulación), $\hat{f}(c^+) - \hat{f}(c^-) \xrightarrow{d} \mathcal{N}(0, \sigma_f^2)$.

Si existe manipulación selectiva (agentes controlan X_i para cruzar c), se observa $\hat{f}(c^+) > \hat{f}(c^-)$ y el rechazo de H_0 invalida la interpretación causal de $\hat{\tau}_{\text{SRD}}$.

El RDD identifica un salto en el *nivel* de $\mathbb{E}[Y|X = x]$ en $x = c$. El Regression Kink Design (RKD), una extensión natural, identifica discontinuidades en la *pendiente* de $\mathbb{E}[Y|X = x]$ en $x = c$ (quiebres o kinks), siendo útil cuando las políticas modifican la tasa marginal de una variable (ej., fórmulas de beneficios con pendientes discontinuas) sin alterar su nivel.

Si observamos una “montaña” de datos acumulándose justo por encima del cutoff y un “valle” justo por debajo, es una señal de alerta de manipulación.

Proposición 7.5 (Implicación de Manipulación)

Si f_X es discontinua en c , el supuesto de continuidad de $\mathbb{E}[Y(t)|X = x]$ no es creíble. Formalmente, si agentes con $\eta_i > \eta^*$ (no observable) manipulan X_i para cruzar c , entonces:

$$\lim_{x \downarrow c} \mathbb{E}[\eta|X = x] \neq \lim_{x \uparrow c} \mathbb{E}[\eta|X = x] \quad (7.4.3)$$

violando continuidad de $\mathbb{E}[Y(0)|X = x]$ si $Y(0)$ depende de η .

Si los estudiantes más ricos o con mejores conexiones logran manipular sus puntajes para cruzar la línea, entonces las características no observables de los admitidos ya no son comparables a las de los rechazados justo en el borde.

Definición 7.9 (Test de Balance de Covariables)

Para covariables predeterminadas W (no afectadas por tratamiento), como el ingreso familiar o el tipo de colegio (estatal vs. particular), se prueba:

$$H_0^W : \lim_{x \downarrow c} \mathbb{E}[W|X = x] = \lim_{x \uparrow c} \mathbb{E}[W|X = x] \quad (7.4.4)$$

Un rechazo indica que la discontinuidad está correlacionada con características observables, sugiriendo selección en el umbral.

Esperaríamos que, justo alrededor del corte de admisión, la proporción de estudiantes de colegios estatales vs. particulares sea continua. Si solo los de colegios particulares (que tienden a tener mayores recursos) aparecen justo por encima del corte, nuestra estimación de ingresos futuros podría estar capturando esta ventaja de origen, no solo el efecto de la educación universitaria.

Definición 7.10 (Tests Placebo)

Se implementan tres tipos de falsificación:

1. Umbrales falsos: Estimar τ_{SRD} en $c' \neq c$ donde no debería existir efecto. Bajo H_0 , $\hat{\tau}(c') \approx 0$.
2. Resultados falsos: Variables Y' que no deberían ser afectadas por T . Bajo exclusión, $\hat{\tau}_{Y'} \approx 0$.
3. Pre-trends en panel: Para datos panel, estimar efectos en periodos $t < 0$ antes de la intervención. Bajo no-anticipación, $\hat{\tau}_{\text{pre}} \approx 0$.

La credibilidad del diseño no depende de un solo test aislado, sino de la convergencia de evidencia proveniente de múltiples estrategias de falsificación complementarias.

Corolario 7.2 (Conjunto de Tests de Validez)

La credibilidad del RDD requiere pasar el test de McCrary (no manipulación), tests de balance (no selección en observables), y tests placebo (no efectos espurios en ubicaciones o resultados alternativos). El fallo en cualquiera invalida la interpretación causal de τ_{SRD} .

7.5 Verificación Computacional: Sharp RDD con Kernel Triangular

El siguiente código implementa un estimador RDD local con kernel triangular y realiza un test placebo en un umbral falso para validar la discontinuidad.

Un salto significativo en el umbral verdadero ($\hat{\tau} \approx 2$) y nulo en el umbral placebo valida la discontinuidad como causal, no como artefacto de la función de regresión.

Ejemplo 7.1 (Examen de admisión UNI como umbral RDD)

El examen de admisión a la UNI establece un puntaje de corte de 600 puntos. Los postulantes que obtienen exactamente 601–605 son comparados con los que obtienen 595–599: ambos grupos tienen características observables (edad, colegio, ingresos familiares) prácticamente idénticas, pues ninguno podía manipular su puntaje con precisión suficiente para cruzar el umbral. El estimador RDD local (con bandwidth $h = 10$ puntos y kernel triangular) estima un efecto de la admisión sobre el ingreso a los 5 años de $\hat{\tau}_{\text{SRD}} = 420$ soles/mes con $\text{IC}_{95\%} = [310, 530]$. El test de McCrary confirma continuidad de la densidad del puntaje en el umbral ($p = 0.42$).

Supuestos clave**Supuestos del Capítulo 7 (RDD Sharp)**

1. **Continuidad:** $\mathbb{E}[Y(t) | X = x]$ es continua en $x = c$ para $t = 0, 1$.
2. **No manipulación:** Los agentes no pueden controlar X con precisión suficiente para cruzar c intencionalmente (test de McCrary).
3. **Soporte local:** Existe masa de observaciones en $[c - h, c + h]$ para un $h > 0$ suficientemente pequeño.

7.6 Cierre del capítulo

El RDD identifica un efecto local en el umbral bajo continuidad de potenciales. La monografía insiste: validez externa limitada y diagnóstico de manipulación (McCrary) son parte del argumento, no un apéndice opcional.

Otras referencias clave de este capítulo: (Thistlethwaite & Campbell, 1960), (Hahn et al., 2001), (Imbens & Lemieux, 2008), (Lee & Lemieux, 2010), (Imbens & Kalyanaraman, 2012).

7.6 Referencias

- Hahn, J., Todd, P., & Klaauw, W. Van der. (2001). Identification and Estimation of Treatment Effects with a Regression-Discontinuity Design. *Econometrica*, 69(1), 201-209.
- Imbens, G. W., & Kalyanaraman, K. (2012). Optimal Bandwidth Choice for the Regression Discontinuity Estimator. *Review of Economic Studies*, 79(3), 933-959.
- Imbens, G. W., & Lemieux, T. (2008). Regression Discontinuity Designs: A Guide to Practice. *Journal of Econometrics*, 142(2), 615-635.
- Lee, D. S., & Lemieux, T. (2010). Regression Discontinuity Designs in Economics. *Journal of Economic Literature*, 48(2), 281-355.
- McCrary, J. (2008). Manipulation of the Running Variable in the Regression Discontinuity Design: A Density Test. *Journal of Econometrics*, 142(2), 698-714.
- Thistlethwaite, D. L., & Campbell, D. T. (1960). Regression-Discontinuity Analysis: An Alternative to the Ex Post Facto Experiment. *Journal of Educational Psychology*, 51(6), 309-317.

CAPÍTULO 8

Difference-in-Differences y la Arquitectura del Tiempo

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42**Notebook (pack):** notebooks/Bloque_I/notebooks/08_difference_in_differences_arquitectura_tiempo.ipynb**Jupyter Book:** jupyter_book/content/bloque_01_fundamentacion/08_difference_in_differences.ipynb**Matemática GCE:** gce/paper/main.typ (cadena maestra / experimento canónico)

8.1 El Diseño Canónico 2x2 y Tendencias Paralelas

Hasta ahora, hemos explorado métodos que dependen crucialmente de la elección observada de covariables o de la existencia de umbrales geográficos arbitrarios. Pero, ¿qué sucede cuando el tratamiento se despliega en el tiempo, afectando a grupos enteros de población simultáneamente? En el “Global Sur”, esta es la norma más que la excepción. Consideremos el caso de la implementación del programa “Pensión 65” en el Perú. El gobierno decide expandir la transferencia monetaria a adultos mayores en pobreza extrema, pero debido a restricciones presupuestales y logísticas, no puede hacerlo a nivel nacional de inmediato. Comienza en las regiones más pobres y aisladas, como Huancavelica y Ayacucho (2012), luego se expande a Cusco y Puno (2013), y finalmente llega a zonas urbanas como Lima (2015). Nos enfrentamos a un escenario de panel: observamos a las mismas regiones (unidades i) a lo largo del tiempo (t), algunas expuestas al programa y otras no.

El diseño Difference-in-Differences (DiD) es la herramienta arquitectónica diseñada para este escenario. Su lógica es elemental pero profunda: en lugar de comparar niveles de consumo entre regiones ricas y pobres (comparación espacial que es sesgada), comparamos la evolución temporal del consumo dentro de cada región antes y después del programa, restando la evolución “normal” observada en las regiones que aún no han recibido el beneficio.

El caso canónico simplifica este escenario a dos grupos y dos periodos.

Definición 8.1 (Marco Panel 2x2)

Considérese panel balanceado con $i = 1, \dots, N$ unidades y $t \in \{0, 1\}$ periodos. La variable de grupo indica exposición al tratamiento:

$$G_i = \{1 \text{ si unidad } i \text{ está en grupo tratado } 0 \text{ si unidad } i \text{ está en grupo control} \quad (8.1.1)$$

La variable de tratamiento es:

$$D_{it} = G_i \cdot \mathbb{I}\{t = 1\} = \{1 \text{ si } G_i = 1 \text{ y } t = 1 \text{ en caso contrario} \quad (8.1.2)$$

Los resultados potenciales son $Y_{it}(0)$ (sin tratamiento) y $Y_{it}(1)$ (con tratamiento). El resultado observado satisface consistencia: $Y_{it} = D_{it}Y_{it}(1) + (1 - D_{it})Y_{it}(0)$.

En nuestro ejemplo, imaginemos un DiD simplificado: comparamos Huancavelica (tratada en 2011-2012) con Lima (no tratada aún). El problema es que Lima es mucho más rica que Huancavelica; la primera diferencia (Niveles) es engañosa. La segunda diferencia (Tendencias) intenta limpiar este sesgo. Para

que funcione, debemos confiar en un supuesto que es, simultáneamente, la mayor fortaleza y la mayor vulnerabilidad del método.

Definición 8.2 (Supuesto de Tendencias Paralelas (PTA))

El supuesto fundamental identificador establece que, en ausencia de tratamiento, los grupos tratado y control habrían seguido trayectorias paralelas:

$$\mathbb{E}[Y_{i1}(0) - Y_{i0}(0) \mid G_i = 1] = \mathbb{E}[Y_{i1}(0) - Y_{i0}(0) \mid G_i = 0] \quad (8.1.3)$$

Equivalentemente, el cambio contrafactual promedio del grupo tratado hubiera sido idéntico al cambio observado del grupo control.

Este es el “leap of faith” epistemológico. Nos pide creer que, si Huancavelica no hubiera recibido la pensión, su consumo habría evolucionado exactamente igual al de Lima. Es intuitivo—ambos son economías peruanas afectadas por inflación y crecimiento macro—pero es fundamentalmente no testeable para el periodo post-tratamiento. Solo podemos validar tendencias paralelas en el pasado ($t = 0$), pero asumimos que se proyectan al futuro ($t = 1$).

Teorema 8.1 (Identificación del ATT en DiD 2x2)

Bajo el supuesto de tendencias paralelas, el estimador DiD identifica el efecto del tratamiento sobre los tratados:

$$\tau_{DD} = (\mathbb{E}[Y_{i1} \mid G_i = 1] - \mathbb{E}[Y_{i0} \mid G_i = 1]) - (\mathbb{E}[Y_{i1} \mid G_i = 0] - \mathbb{E}[Y_{i0} \mid G_i = 0]) = \mathbb{E}[Y_{i1}(1) - Y_{i1}(0) \mid G_i = 1]$$

Corolario 8.1 (Localidad Temporal)

El DiD 2x2 identifica el ATT en el periodo post-tratamiento ($t = 1$) para las unidades tratadas ($G_i = 1$). No identifica el ATE poblacional ni efectos dinámicos en periodos posteriores sin extensiones adicionales.

8.2 La Regresión TWFE

Durante décadas, la comunidad de economistas aplicados ha confiado en una implementación particularmente conveniente del DiD: la regresión de Efectos Fijos de Dos Vías (Two-Way Fixed Effects, TWFE). Esta especificación, $Y_{it} = \alpha_i + \lambda_t + \tau D_{it} + \varepsilon_{it}$, se convirtió en la “navaja suiza” de la evaluación de políticas. Era simple, intuitiva y parecía manejar cualquier tipo de heterogeneidad fija de unidades y shocks agregados de tiempo con un solo comando en Stata o R. Sin embargo, como veremos, esta simplicidad ocultaba un peligro profundo en contextos de adopción escalonada. En diseños staggered adoption, el estimador TWFE puede asignar pesos negativos a algunos grupos tratados (Goodman-Bacon, 2021), lo que produce sesgos cuando los efectos son heterogéneos en el tiempo.

El estimador DiD puede implementarse mediante regresión lineal con efectos fijos de unidad y tiempo, conocida como Two-Way Fixed Effects (TWFE).

Definición 8.3 (Modelo TWFE)

El modelo de regresión especifica:

$$Y_{it} = \alpha_i + \lambda_t + \tau D_{it} + \varepsilon_{it} \quad (8.2.1)$$

donde α_i son efectos fijos de unidad (capturan heterogeneidad invariante en el tiempo), λ_t son efectos fijos de tiempo (capturan shocks comunes), y τ es el parámetro de efecto causal.

En el escenario simple 2x2, esta regresión devuelve exactamente el mismo número que la resta manual de promedios. Su conveniencia radica en que absorbe automáticamente la media de cada región y de cada año, dejando τ como el remanente causal.

Teorema 8.2 (Equivalencia Algebraica DiD-TWFE)

En el diseño canónico 2x2, el estimador OLS de τ en el modelo TWFE es algebraicamente idéntico al estimador DiD:

$$\hat{\tau}_{OLS} = \hat{\tau}_{DiD} \quad (8.2.2)$$

Aunque TWFE es potente, su inferencia requiere cuidado especial con los errores estándar. Dado que observamos al mismo individuo a lo largo del tiempo, los residuos están correlacionados serialmente dentro de cada unidad.

Definición 8.4 (Estimador de Varianza Cluster-Robust)

Bajo correlación serial dentro de unidades, el estimador de varianza cluster a nivel de unidad es:

$$\widehat{\text{Var}}_{\text{cluster}}(\hat{\theta}) = (\mathbf{X}'\mathbf{X})^{-1} \left(\sum_{i=1}^N \mathbf{x}_i' \hat{\varepsilon}_i \hat{\varepsilon}_i' \mathbf{x}_i \right) (\mathbf{X}'\mathbf{X})^{-1} \quad (8.2.3)$$

donde $\mathbf{x}_i = (x_{i1}, \dots, x_{iT_i})'$ es la matriz de covariables de la unidad i y $\hat{\varepsilon}_i$ es el vector de residuos.

8.3 La Descomposición de Goodman-Bacon (2021)

El problema surge cuando abandonamos el mundo simple 2x2 y nos enfrentamos a la realidad del programa “Pensión 65”: la adopción escalonada. Las regiones reciben el tratamiento en diferentes años (cohorte G_i). Durante décadas, los investigadores aplicaron ciegamente TWFE a estos datos. Sin embargo, en 2021, Goodman-Bacon reveló el talón de Aquiles de este procedimiento.

Imaginemos el año 2013. Cusco acaba de recibir la pensión ($G = 2013$). ¿Cuáles son los grupos control disponibles para Cusco en ese año?

1. Lima y Callao, que nunca han recibido el programa (buen control).
2. Huancavelica y Ayacucho, que recibieron el programa en 2012 ($G = 2012$).

Aquí está el desastre: la regresión TWFE no sabe distinguir entre controles “limpios” y controles “ya tratados”. Al calcular el efecto para Cusco en 2013, TWFE utilizará implícitamente a Huancavelica (que ya tiene la pensión) como parte del grupo de comparación. Si el efecto de la pensión acumula con el tiempo (el consumo aumenta más cuanto tiempo más tiempo llevas recibiendo el bono), entonces el consumo de Huancavelica ya está artificialmente elevado. Comparar Cusco con Huancavelica subestimaré el efecto de la pensión en Cusco. TWFE está promediando comparaciones válidas con comparaciones contaminadas.

Cuando diferentes unidades adoptan el tratamiento en diferentes momentos (adopción escalonada), el estimador TWFE promedio se descompone en múltiples comparaciones 2x2, algunas de las cuales usan unidades ya tratadas como controles.

Definición 8.5 (Adopción Escalonada)

El tiempo de adopción $G_i \in \mathcal{G} \cup \{\infty\}$ donde $\mathcal{G}$ es el conjunto de periodos de tratamiento y $G_i = \infty$ denota nunca tratados. La variable de tratamiento es:

$$D_{it} = \mathbb{I}\{t \geq G_i\} \quad (8.3.1)$$

con irreversibilidad: una vez tratado, siempre tratado.

Esta estructura de adopción en múltiples cohortes, aunque empíricamente ubicua, genera un problema de agregación que el estimador TWFE ingenuo no puede manejar sin sesgo.

Teorema 8.3 (Descomposición de Goodman-Bacon)

El estimador TWFE con adopción escalonada se descompone como promedio ponderado de estimadores 2x2:

$$\hat{\tau} = \sum_k w_k \hat{\tau}_k^{2x2}, \quad \sum_k w_k = 1, \quad w_k \in \mathbb{R} \quad (8.3.2)$$

Las comparaciones incluyen: (i) tratado temprano vs. nunca tratado, (ii) tratado tarde vs. nunca tratado, (iii) tratado temprano vs. tratado tarde (usando periodos donde el tarde aún no está tratado), y (iv) tratado temprano vs. tratado tarde (usando periodos donde el tarde ya está tratado). Críticamente, las comparaciones del tipo (iv) pueden recibir **pesos negativos** bajo heterogeneidad dinámica: cuando los efectos son heterogéneos en el tiempo, la unidad ya tratada actúa como control contrafactual negativo, lo que puede hacer que $\hat{\tau}$ sea inconsistente o tenga signo opuesto al efecto verdadero. Estimadores alternativos como Callaway & Sant'Anna (2021) y Sun-Abraham (Sun & Abraham, 2021) resuelven este problema restringiendo las comparaciones a unidades aún no tratadas.

La descomposición de Goodman-Bacon revela que la cuarta categoría—usar unidades ya tratadas como controles—introduce un sesgo sistemático si el efecto del tratamiento cambia con el tiempo.

Proposición 8.1 (Sesgo por Controles Ya Tratados)

Las comparaciones que usan unidades ya tratadas como controles introducen sesgo cuando existen efectos dinámicos. Formalmente, si $ATT(g, t)$ depende del tiempo transcurrido desde la adopción $e = t - g$:

$$\mathbb{E}[Y_{it}(0) \mid G_i = g', t \geq g'] \neq \mathbb{E}[Y_{it}(0) \mid G_i = g', t < g'] \quad (8.3.3)$$

El grupo “control” ya tratado no proporciona una contrafactual válido para el grupo tratado más reciente.

Teorema 8.4 (Condición de Insesgidez de TWFE)

El estimador TWFE es insesgado para el ATT promedio si y solo si el efecto del tratamiento es constante en el tiempo y homogéneo entre cohortes:

$$ATT(g, t) = \tau \quad \forall g \in \mathcal{G}, t \geq g \quad (8.3.4)$$

En otras palabras, TWFE solo funciona si el tratamiento tiene el mismo efecto ayer, hoy y mañana, para todas las regiones — un supuesto fuerte en el contexto de desarrollo social, donde los efectos suelen acumularse o decaer con el tiempo.

8.4 Estimadores Modernos Robustos

Afortunadamente, la literatura metodológica post-2020 ha generado una revolución en la inferencia causal para panel escalonado. Estimadores como los propuestos por Callaway-Sant’Anna y Sun-Abraham nos permiten recuperar efectos heterogéneos y dinámicos sin contaminarnos con grupos “ya tratados”. La solución es simple y radical: cuando estimemos el efecto para Cusco en 2013, ¡prohibido usar a Huancavelica como control!

Los estimadores recientes evitan el sesgo de TWFE al restringir el conjunto de controles válidos y permitir efectos dinámicos heterogéneos. En Python, `pyfixest` implementa TWFE robusto a heterogeneidad dinámica; `differences` implementa el estimador de Callaway-Sant’Anna; y `linearmodels` ofrece estimadores de panel con efectos fijos.

Definición 8.6 (Estimador Callaway-Sant’Anna)

El efecto por cohorte-tiempo se define como:

$$ATT(g, t) = \mathbb{E}[Y_{it}(1) - Y_{it}(0) \mid G_i = g] \quad (8.4.1)$$

La estrategia de identificación usa como controles solo unidades not-yet-treated (que adoptarán después) o never-treated:

$$\widehat{ATT}(g, t) = \mathbb{E}[Y_{it} - Y_{ig-1} \mid G_i = g] - \mathbb{E}[Y_{it} - Y_{ig-1} \mid G_i \in \mathcal{C}(g, t)] \quad (8.4.2)$$

donde $\mathcal{C}(g, t) = \{i : G_i > t\} \cup \{i : G_i = \infty\}$ es el conjunto de controles válidos.

El estimador agregado es:

$$\tau^{\text{agg}} = \sum_{g \in \mathcal{G}} \sum_{t \geq g} w_{g,t} \cdot \widehat{ATT}(g, t) \quad (8.4.3)$$

con ponderaciones $w_{g,t}$ que reflejan el interés de política (simple, calendar time, o cohorte).

En el ejemplo de “Pensión 65”, esto significa que para calcular el efecto en 2013, usamos únicamente a Lima (y otras regiones aún no tratadas) como comparador, ignorando completamente a las regiones pioneras. Esto aísla el efecto puro del tratamiento de la primera exposición, libre de la contaminación de exposiciones previas.

Definición 8.7 (Estimador Sun-Abraham)

El modelo de interacciones cohorte $\times$ tiempo relativo especifica:

$$Y_{it} = \alpha_i + \lambda_t + \sum_{g \in \mathcal{G}} \sum_{e \neq -1} \delta_{g,e} \cdot \mathbb{I}\{G_i = g\} \cdot \mathbb{I}\{t - g = e\} + \varepsilon_{it} \quad (8.4.4)$$

donde $e = t - g$ es el evento tiempo (periodos desde la adopción). El coeficiente $\delta_{g,e}$ identifica $ATT(g, g + e)$ bajo el supuesto de que unidades no tratadas en (g, t) proporcionan contrafactual válido.

Esta aproximación nos permite visualizar dinámicas de tratamiento: ¿el efecto del bono es grande el primer año y luego desaparece? ¿O crece lentamente?

Proposición 8.2 (Equivalencia Bajo Efecto Constante)

Bajo el supuesto de efecto constante $ATT(g, t) = \tau$ para todo $g, t \geq g$:

$$\hat{\tau}_{\text{TWFE}} = \hat{\tau}_{\text{Callaway-Sant’Anna}} = \hat{\tau}_{\text{Sun-Abraham}} = \tau \quad (8.4.5)$$

Todos los estimadores son consistentes para el mismo parámetro.

Corolario 8.2 (Recomendación de Estimación)

Bajo efectos dinámicos heterogéneos ($ATT(g, t)$ varía con g o $t - g$), TWFE está sesgado. Se recomienda usar Callaway-Sant'Anna o Sun-Abraham, que son robustos a heterogeneidad de efectos y evitan el sesgo por controles ya tratados mediante restricciones explícitas del conjunto de comparación válido.

8.5 Verificación Computacional: TWFE vs. Callaway-Sant'Anna en Adopción Escalonada

El siguiente código genera datos panel con adopción escalonada y efectos dinámicos, demostrando el sesgo de TWFE y la corrección de un estimador por cohorte.

El TWFE subestima el efecto promedio cuando los efectos son dinámicos, mientras que el estimador por cohorte lo recupera correctamente al restringir el conjunto de control a unidades no tratadas.

Ejemplo 8.1 (Pensión 65 y adopción escalonada)

Pensión 65 se implementa en diferentes regiones del Perú entre 2012 y 2015. Aplicando TWFE naivamente a los 25 departamentos, se obtiene $\hat{\tau}_{TWFE} = 48$ soles/mes de aumento en consumo de alimentos. Sin embargo, el estimador de Callaway-Sant'Anna, que restringe las comparaciones a unidades aún no tratadas, obtiene $\widehat{ATT}(g, t)$ heterogéneos: las regiones rurales de la sierra muestran efectos de 70–90 soles/mes, mientras que las zonas urbanas exhiben solo 20–30 soles/mes. El TWFE promedia con pesos negativos algunas comparaciones, comprimiendo artificialmente el estimado agregado.

8.6 Validación Empírica: Tests de Tendencias Paralelas Pre-tratamiento

La credibilidad del DiD descansa sobre el supuesto de tendencias paralelas (PTA), que es fundamentalmente inobservable en el período post-tratamiento. Sin embargo, en datos de panel con múltiples períodos pre-tratamiento, podemos buscar evidencia indirecta de su validez examinando si los grupos exhibieron trayectorias paralelas antes de la intervención.

Definición 8.8 (Supuesto PTA: Distinción Identificación vs. Validación)

El PTA establece $\mathbb{E}[Y_{it}(0) - Y_{i,t-1}(0) \mid G_i = 1] = \mathbb{E}[Y_{it}(0) - Y_{i,t-1}(0) \mid G_i = 0]$ para el período post-tratamiento $t = 1$. Este supuesto es sobre la distribución de los resultados potenciales bajo control, *no* sobre los resultados observados. Es inobservable para $t \geq G_i$ (período post) porque $Y_{it}(0)$ no se observa para el grupo tratado. La evidencia de tendencias paralelas pre-tratamiento (observable) es una validación indirecta, no una demostración del supuesto.

La validación indirecta del supuesto de identificación se implementa mediante la inspección de los coeficientes de tiempo relativo al tratamiento, que revelan si las trayectorias eran indistinguibles antes de la intervención.

Definición 8.9 (Regresión de Evento (Event Study) para Validación Pre-tratamiento)

El test de tendencias paralelas especifica:

$$Y_{it} = \alpha_i + \lambda_t + \sum_{k \neq -1} \delta_k \cdot \mathbb{I}\{t - G_i = k\} + \varepsilon_{it} \quad (8.6.1)$$

donde $k = t - G_i$ es el tiempo relativo al tratamiento. El período $k = -1$ se omite como normalización. Los coeficientes $\{\hat{\delta}_k\}_{k < 0}$ son la evidencia pre-tratamiento: bajo PTA, $\hat{\delta}_k \approx 0$ para todo $k < 0$. Los coeficientes $\{\hat{\delta}_k\}_{k \geq 0}$ capturan la dinámica del efecto post-tratamiento.

Ahora bien, el test de event study pre-tratamiento tiene poder estadístico limitado en muestras pequeñas o con pocos períodos pre-tratamiento. Un resultado no significativo ($\hat{\delta}_k \approx 0$ para $k < 0$) no valida el PTA en el período post-tratamiento; solo indica que no hay evidencia observable en contra. En particular, con T_{pre} períodos pre-tratamiento pequeños, incluso violaciones moderadas del PTA pasarán desapercibidas. Por tanto, la ausencia de tendencias pre-tratamiento es condición necesaria para la credibilidad del DiD, pero no suficiente para garantizar el PTA en el período post-tratamiento.

Corolario 8.3 (Coeficientes dinámicos en la regresión de evento)

En la regresión de evento, los coeficientes $\hat{\delta}_k$ para $k < 0$ son los pre-trends⁴⁴: su magnitud y significancia estadística permiten juzgar la plausibilidad del PTA. Los coeficientes $\hat{\delta}_k$ para $k \geq 0$ revelan la dinámica del efecto: si el efecto crece con el tiempo (heterogeneidad dinámica), el estimador TWFE estará sesgado según la descomposición de Goodman-Bacon, y deben usarse los estimadores de Callaway-Sant’Anna o Sun-Abraham.

Supuestos clave**Supuestos del Capítulo 8 (DiD y TWFE)**

1. **Tendencias Paralelas (PTA):** $\mathbb{E}[Y_{it}(0) - Y_{i,t-1}(0) | G_i = 1] = \mathbb{E}[Y_{it}(0) - Y_{i,t-1}(0) | G_i = 0]$.
2. **No Anticipación:** $Y_{it}(d) = Y_{it}(0)$ para $t < G_i$ — el resultado antes del tratamiento no depende de la fecha futura de adopción.
3. **Irreversibilidad:** Una vez tratada, la unidad permanece tratada (adopción estacionaria).
4. **Para TWFE sin sesgo:** Efectos constantes $ATT(g, t) = \tau$ para todo g, t — supuesto muy restrictivo en práctica.

Cuando existe una sola unidad tratada (un país, un estado, una empresa), el promedio de controles es una elección arbitraria que puede sesgar sistemáticamente la inferencia. El Control Sintético del Capítulo 9 resuelve este problema construyendo un contrafactual óptimo como combinación convexa de donantes, cuyos pesos se eligen para maximizar el ajuste en la trayectoria pre-tratamiento de la unidad específica: una generalización del DiD que reemplaza la equiponderación por la optimización convexa.

8.7 Cierre del capítulo

DiD y TWFE son arquitecturas del tiempo: sin tendencias paralelas (o sin estimadores robustos a heterogeneidad dinámica) el estimando agregado puede no ser causalmente interpretable. Goodman-Bacon y Callaway-Sant’Anna no son adornos: delimitan el alcance del TWFE.

Otras referencias clave de este capítulo: (Card & Krueger, 1994), (Bertrand et al., 2004), (Roth, 2022), (Roth et al., 2023).

8.7 Referencias



- Bertrand, M., Duflo, E., & Mullainathan, S. (2004). How Much Should We Trust Differences-in-Differences Estimates?. *The Quarterly Journal of Economics*, 119(1), 249-275.
- Callaway, B., & Sant'Anna, P. H. C. (2021). Difference-in-Differences with Multiple Time Periods. *Journal of Econometrics*, 225(2), 200-230.
- Card, D., & Krueger, A. B. (1994). Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania. *The American Economic Review*, 84(4), 772-793.
- Goodman-Bacon, A. (2021). Difference-in-Differences with Variation in Treatment Timing. *Journal of Econometrics*, 225(2), 254-277.
- Roth, J. (2022). Pretest with Caution: Event-Study Estimates After Testing for Parallel Trends. *American Economic Review: Insights*, 4(3), 305-322.
- Roth, J., Sant'Anna, P. H. C., Bilinski, A., & Poe, J. (2023). What's Trending in Difference-in-Differences? A Synthesis of the Recent Econometrics Literature. *Journal of Econometrics*, 235(2), 2218-2244.
- Sun, L., & Abraham, S. (2021). Estimating Dynamic Treatment Effects in Event Studies with Heterogeneous Treatment Effects. *Journal of Econometrics*, 225(2), 175-199.

CAPÍTULO 9

Control Sintético: la Ingeniería del Contrafactual

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42

Notebook (pack): notebooks/Bloque_I/notebooks/09_control_sintetico_ingenieria_contrafactual.ipynb

Jupyter Book: jupyter_book/content/bloque_01_fundamentacion/09_control_sintetico.ipynb

El diseño *Difference-in-Differences* expuesto en el capítulo anterior se fundamenta en la aplicación uniforme de pesos a través de las unidades de control y en el estricto supuesto de tendencias paralelas. Esta estructura colapsa inevitablemente cuando nos enfrentamos a una unidad tratada única—ya sea una nación, una región o una empresa multinacional, y un grupo de control caracterizado por heterogeneidad estructural significativa. En tales escenarios, el promedio simple de las unidades de control es un contrafactual defectuoso que captura ruido sistémico en lugar de la trayectoria latente de la unidad intervenida. El Método de Control Sintético (SynC) resuelve este impasse reformulando el problema causal no como un ejercicio estadístico de promediación, sino como un problema de optimización convexa. En lugar de asumir tendencias paralelas, SynC construye explícitamente un contrafactual como una combinación ponderada de unidades no tratadas que replique la evolución pre-intervención de la unidad objetivo. El caso canónico de esta metodología es la evaluación de la Proposición 99 en California (1988), donde un impuesto statewide al tabaco afectó a una sola unidad tratada frente a un grupo de 38 estados potenciales de control; aquí, la aplicación de DiD estándar es inviable debido a la imposibilidad de agrupar a los estados de control bajo una única tendencia paralela creíble. Este capítulo desarrolla la arquitectura formal de esta solución, comenzando con el modelo de factores latentes, derivando el problema de optimización que define los pesos sintéticos, analizando las condiciones bajo las cuales el estimador es insesgado y concluyendo con una estrategia de inferencia basada en permutación que elude las limitaciones asintóticas de muestras pequeñas.

9.1 El Problema de la Unidad Tratada Única y el Marco Formal

El Synthetic Control Method (SynC) aborda el escenario donde una única unidad (país, estado, empresa) recibe tratamiento y no existe un control obvio comparable. El método construye un contrafactual como combinación ponderada de unidades no tratadas.

Definición 9.1 (Marco del Control Sintético)

La unidad tratada es $i = 1$, con donor pool $\mathcal{D} = \{2, \dots, J + 1\}$ de J unidades donantes. Los períodos son $t = 1, \dots, T$, con intervención en $T_0 < T$. Los resultados potenciales son $Y_{it}(0)$ (sin tratamiento) y $Y_{it}(1)$ (con tratamiento). El efecto causal de interés es:

$$\tau_{1t} = Y_{1t}(1) - Y_{1t}(0) \quad \text{para } t > T_0 \quad (9.1.1)$$

El obstáculo central de este marco es evidente: el contrafactual $Y_{1t}(0)$ es inobservable por construcción y debe estimarse a partir de las trayectorias observadas de los donantes.

Definición 9.2 (Problema Fundamental)

Para $t > T_0$, el contrafactual $Y_{1t}(0)$ es no observable. El SynC lo estima mediante:

$$\hat{Y}_{1t}(0) = \sum_{j=2}^{J+1} w_j^* Y_{jt} \quad (9.1.2)$$

donde $\mathbf{w}^* = (w_2^*, \dots, w_{J+1}^*)^t$ op son pesos óptimos determinados en el período pre-intervención.

Para construir ese contrafactual, necesitamos un modelo generativo del resultado bajo control que capture la interacción entre factores temporales comunes y características idiosincráticas de cada unidad.

Definición 9.3 (Modelo de Factores Latentes)

El outcome potencial sin tratamiento sigue el modelo factor-interactivo:

$$Y_{it}(0) = \delta_t + \theta_t^{\text{op}} \mathbf{Z}_i + \lambda_t^{\text{op}} \boldsymbol{\mu}_i + \varepsilon_{it} \quad (9.1.3)$$

donde:

- δ_t : intercepto temporal común
- $\mathbf{Z}_i \in \mathbb{R}^r$: covariables observables invariantes en el tiempo
- $\theta_t \in \mathbb{R}^r$: coeficientes temporales de covariables
- $\lambda_t \in \mathbb{R}^F$: factores comunes no observados (interactivos en tiempo)
- $\boldsymbol{\mu}_i \in \mathbb{R}^F$: cargas factoriales unitales (interactivas en unidades)
- ε_{it} : error idiosincrático

El modelo generaliza los efectos fijos aditivos de DiD ($Y_{it}(0) = \alpha_i + \lambda_t + \varepsilon_{it}$) al permitir interacciones factor-carga $\lambda_t^{\text{op}} \boldsymbol{\mu}_i$ que capturan heterogeneidad dinámica en la exposición a shocks comunes — pero esa flexibilidad tiene un costo: los vectores de carga $\boldsymbol{\mu}_i$, que determinan cómo responde cada unidad a los factores comunes, son intrínsecamente no observables, y estimarlos directamente es imposible sin restricciones adicionales.

La salida es no estimar $\boldsymbol{\mu}_i$ en absoluto. Aprovechando la historia pre-intervención de la unidad tratada y el **donor pool**, es posible identificar pesos $\mathbf{w}$ que, usando solo cantidades observables, repliquen la exposición de la unidad tratada a los factores latentes. El problema de optimización busca la combinación convexa de donantes cuyas cargas no observadas absorban las de la unidad tratada, neutralizando así la influencia de los factores confusores en el período post-intervención.

9.2 El Problema de Optimización: Pesos del Control Sintético

El SynC determina los pesos óptimos mediante optimización anidada que minimiza la discrepancia entre la unidad tratada y su contrafactual sintético en el período pre-intervención.

Definición 9.4 (Espacio de Pesos)

Los pesos pertenecen al simplex de dimensión J :

$$\mathcal{W} = \{\mathbf{w} \in \mathbb{R}_+^J : \sum_{j=2}^{J+1} w_j = 1\} \quad (9.2.1)$$

La restricción de no-negatividad y suma unitaria garantiza que el control sintético sea una combinación convexa de donantes, evitando extrapolación fuera del soporte de datos.

Con el espacio de pesos acotado al simplex, el estimador se define naturalmente como la combinación convexa de los resultados observados de los donantes, garantizando que el contrafactual sintético permanezca dentro del soporte empírico de los datos.

Definición 9.5 (Estimador del Control Sintético)

Dados pesos óptimos $\mathbf{w}^*$, el estimador del contrafactual y del efecto causal son:

$$\hat{Y}_{1t}(0) = \sum_{j=2}^{J+1} w_j^* Y_{jt} = \mathbf{w}^{*top} \mathbf{Y}_t \hat{\tau}_{1t} = Y_{1t} - \hat{Y}_{1t}(0) = Y_{1t} - \sum_{j=2}^{J+1} w_j^* Y_{jt} \quad (9.2.2)$$

donde $\mathbf{Y}_t = (Y_{2t}, \dots, Y_{J+1,t})^t$ op.

La determinación de los pesos óptimos no es trivial, pues depende simultáneamente de la matriz de ponderación de predictores $\mathbf{V}$ y de los pesos $\mathbf{w}$ mismos, lo que exige una estructura de optimización en dos niveles.

Definición 9.6 (Optimización Anidada)

La determinación de pesos procede en dos niveles:

Nivel interno (pesos dados $\mathbf{V}$):

$$\mathbf{w}^*(\mathbf{V}) = \arg \min_{\mathbf{w} \in \mathcal{W}} (\mathbf{X}_1 - \mathbf{X}_0 \mathbf{w})^t \text{op } \mathbf{V} (\mathbf{X}_1 - \mathbf{X}_0 \mathbf{w}) \quad (9.2.3)$$

donde $\mathbf{X}_1 \in \mathbb{R}^k$ es el vector de predictores de la unidad tratada (outcomes pre-intervención y covariables), $\mathbf{X}_0 \in \mathbb{R}^{k \times J}$ es la matriz de predictores de donantes, y $\mathbf{V} \in \mathbb{R}^{k \times k}$ es una matriz diagonal semidefinida positiva que pondera la importancia relativa de los predictores.

Nivel externo (matriz $\mathbf{V}$):

$$\mathbf{V}^* = \arg \min_{\mathbf{V} \in \mathcal{V}} \sum_{t=1}^{T_0} \left(Y_{1t} - \sum_{j=2}^{J+1} w_j^*(\mathbf{V}) Y_{jt} \right)^2 \quad (9.2.4)$$

donde $\mathcal{V}$ es el conjunto de matrices diagonales con elementos no-negativos (típicamente con restricción $\text{tr}(\mathbf{V}) = 1$ para normalización).

La restricción de no-negatividad y suma unitaria garantiza que el predictor sintético resida en la envolvente convexa de los donantes, una propiedad que distingue al Control Sintético de los métodos de regresión sin restricciones y previene la extrapolación fuera del soporte muestral.

Proposición 9.1 (Propiedad de Convexidad)

El predictor del control sintético satisface:

$$\hat{\mathbf{X}}_1 = \mathbf{X}_0 \mathbf{w}^* \in \text{Conv}(\{\mathbf{X}_2, \dots, \mathbf{X}_{J+1}\}) \quad (9.2.5)$$

donde $\text{Conv}(\cdot)$ denota la envolvente convexa de las columnas de $\mathbf{X}_0$. Esto contrasta con OLS sin restricciones, que puede producir $\hat{\mathbf{X}}_1$ fuera de la envolvente convexa (extrapolación).

La derivación del estimador mediante optimización anidada produce un mecanismo computacionalmente eficiente y teóricamente atractivo, pero su validez causal no se garantiza por la elegancia algorítmica. Es necesario caracterizar rigurosamente las condiciones bajo las cuales el sesgo del estimador tiende a cero. La pregunta fundamental conecta el desempeño observacional del modelo con la estructura teórica de factores latentes. Específicamente, debemos demostrar que un buen ajuste en las covariables y trayectorias pre-intervención no es una mera coincidencia estadística, sino que implica una congruencia estructural en el espacio no observado. Bajo el marco de factores latentes, minimizar la discrepancia pre-intervención induce una convergencia en las cargas factoriales, tal que la diferencia Δ_μ entre la unidad tratada y su contraparte sintética es asintóticamente despreciable. Esta sección formaliza el límite del error de estimación, vinculando directamente la calidad de la aproximación convexa en el pasado a la magnitud del sesgo en el futuro.

9.3 Propiedades del Estimador y Condiciones de Sesgo

El sesgo del estimador SynC depende de la calidad del ajuste en el espacio de factores latentes y en la trayectoria pre-intervención observada.

Teorema 9.1 (Cota del Error de Estimación)

Bajo el modelo de factores latentes, el error del estimador SynC satisface:

$$|\hat{\tau}_{1t} - \tau_{1t}| \leq |\lambda_t| \cdot |\Delta_\mu| + \left| \sum_{j=2}^{J+1} w_j^* \varepsilon_{jt} - \varepsilon_{1t} \right| \quad (9.3.1)$$

donde $\Delta_\mu = \mu_1 - \sum_{j=2}^{J+1} w_j^* \mu_j$ es el error de aproximación en las cargas factoriales.

Nótese la implicación menos obvia de la cota: aunque el ajuste en covariables **observables** sea perfecto, el sesgo sigue dependiendo de un término no verificable con los datos disponibles — qué tan bien la combinación convexa de donantes replica las cargas factoriales **no observadas** de la unidad tratada.

Corolario 9.1 (Consistencia bajo Ajuste Perfecto)

Si existe $w^* \in \mathcal{W}$ tal que $X_0 w^* = X_1$ (ajuste perfecto en predictores) y $\sum_{j=2}^{J+1} w_j^* \mu_j = \mu_1$ (ajuste perfecto en cargas factoriales), entonces:

$$\lim_{T_0 \rightarrow \infty} |\hat{\tau}_{1t} - \tau_{1t}| = 0 \quad \text{c.s.} \quad (9.3.2)$$

para $t > T_0$, asumiendo $\frac{1}{T_0} \sum_{t=1}^{T_0} \varepsilon_{jt} \rightarrow 0$.

Mientras que el corolario anterior establece consistencia bajo condiciones ideales de ajuste perfecto, el teorema de Abadie-Diamond-Hainmueller relaja este requisito y proporciona una tasa de convergencia finita que depende únicamente de la longitud del período pre-intervención, no del número de donantes.

Teorema 9.2 (Teorema de Sesgo de Abadie-Diamond-Hainmueller (2010))

Si existe $w^* \in \mathcal{W}$ tal que:

1. $\sum_{j=2}^{J+1} w_j^* \mu_j = \mu_1$ (match perfecto en factores latentes no observados), y
2. $\sum_{j=2}^{J+1} w_j^* Y_{jt}(0) = Y_{1t}(0)$ para todo $t \leq T_0$ (match exacto en el período pre-tratamiento),

entonces el sesgo del estimador SynC en el período post-tratamiento satisface:

$$|\mathbb{E}[\hat{\tau}_{1t} - \tau_{1t}]| = O\left(T_0^{-\frac{1}{2}}\right) \quad (9.3.3)$$

La tasa de convergencia depende únicamente de la longitud del período pre-tratamiento, no del número de donantes — por eso el SynC sigue siendo útil cuando el **donor pool** es pequeño, un régimen donde los métodos basados en el número de unidades de control simplemente no aplican.

Cuando el número de predictores k es grande relativo a T_0 , la optimización sin restricciones puede sobreajustar el período pre-tratamiento. La extensión con penalización Ridge (Doudchenko & Imbens, 2016) modifica el problema interno:

$$\mathbf{w}^*(\mathbf{V}, \zeta) = \arg \min_{\mathbf{w} \in \mathcal{W}} \|\mathbf{X}_1 - \mathbf{X}_0 \mathbf{w}\|_{\mathbf{V}}^2 + \zeta \|\mathbf{w}\|_2^2 \quad (9.3.4)$$

donde $\zeta > 0$ introduce regularización que previene la concentración excesiva de los pesos en pocos donantes. Cuando $\zeta \rightarrow \infty$, los pesos tienden a la distribución uniforme $w_j = \frac{1}{J}$, recuperando el DiD de pesos iguales. Cuando $\zeta \rightarrow 0$, la solución converge al SynC original. Este parámetro ζ anticipa el estimador SDiD del Capítulo 12, donde actúa como dial de transición entre los dos extremos metodológicos.

Proposición 9.2 (DiD como Caso Especial del SynC)

El estimador DiD con efectos fijos de unidad y tiempo es un caso especial del SynC cuando:

1. $w_j = \frac{1}{J}$ para todo j (pesos uniformes)
2. $F = 1$ (un solo factor latente, λ_t escalar)
3. $\mu_i = 1$ para todo i (cargas factoriales homogéneas)

Bajo estas condiciones, el modelo se reduce a $Y_{it}(0) = \delta_t + \lambda_t + \varepsilon_{it}$, que es el modelo aditivo de DiD: el Capítulo 8 completo es el caso $F = 1$ con cargas homogéneas de esta arquitectura más general.

Las propiedades asintóticas de la sección anterior no resuelven, por sí solas, cómo construir un intervalo de confianza: el número de unidades donantes J es típicamente pequeño (menos de 20), lo que invalida las aproximaciones del Teorema del Límite Central en las que se apoyaría un error estándar convencional. La alternativa es el enfoque exacto de Fisher: usar el propio **donor pool** para generar la distribución nula bajo la hipótesis de ausencia de efecto, tratando a cada unidad del panel como un caso potencialmente tratado. La inferencia por permutación no depende de distribuciones asintóticas, sino de la variabilidad empírica que resulta de iterar el algoritmo de optimización sobre todas las unidades.

9.4 Inferencia: Tests de Permutación Placebo (Fisher)

La inferencia en SynC no puede basarse en teoría asintótica estándar porque J es típicamente pequeño (menos de 20 donantes). Se recurre a tests de permutación exactos bajo el principio de intercambiabilidad.

El test evalúa $H_0 : \tau_{1t} = 0$ para todo $t > T_0$ (no efecto del tratamiento). La distribución nula se construye mediante permutación de la etiqueta de tratado entre unidades.

El marco de Fisher exige un procedimiento operativo que asigne a cada unidad del panel, incluyendo la genuinamente tratada, el rol de placebo para construir la distribución nula empírica.

El test de Fisher-Exacto para SynC procede en cuatro pasos:

Paso 1: Para cada unidad $j \in \{1, \dots, J + 1\}$, aplicar el algoritmo SynC como si j fuera la unidad tratada, usando las demás J unidades como donor pool. Obtener pesos óptimos $\mathbf{w}^{*(j)}$ y contrafactual $\hat{Y}_{jt}^{(j)}(0)$.

Paso 2: Calcular los efectos placebo para cada unidad en el período post-intervención:

$$\hat{\tau}_{jt}^{\text{placebo}} = Y_{jt} - \hat{Y}_{jt}^{(j)}(0) \quad \text{para } t > T_0 \quad (9.4.1)$$

Paso 3: Calcular la estadística de resumen RMSPE (Root Mean Squared Prediction Error) ratio para cada unidad:

$$r_j = \frac{\text{RMSPE}_{\text{post}}(j)}{\text{RMSPE}_{\text{pre}}(j)} = \frac{\sqrt{\frac{1}{T-T_0} \sum_{t=T_0+1}^T (\hat{\tau}_{jt}^{\text{placebo}})^2}}{\sqrt{\frac{1}{T_0} \sum_{t=1}^{T_0} (Y_{jt} - \hat{Y}_{jt}^{(j)}(0))^2}} \quad (9.4.2)$$

Paso 4: Calcular el p-valor exacto de Fisher:

$$p = \frac{|\{j \in \{1, \dots, J+1\} : r_j \geq r_1\}|}{J+1} \quad (9.4.3)$$

donde r_1 es la estadística de la unidad realmente tratada.

La validez del test de permutación descansa sobre la intercambiabilidad de las unidades bajo la hipótesis nula, una propiedad que el modelo de factores latentes garantiza cuando ninguna unidad ha recibido tratamiento.

Proposición 9.3 (Intercambiabilidad bajo H_0)

Bajo la hipótesis nula de no efecto del tratamiento ($\tau_{jt} = 0$ para todo $j, t > T_0$), la distribución conjunta de $(r_1, \dots, r_{J+1})$ es intercambiable: invariante ante permutaciones de los índices de unidad.

La intercambiabilidad es lo que hace exacto al p-valor resultante: no depende de aproximaciones asintóticas, la limitación que precisamente motivó abandonar los intervalos de confianza estándar.

Corolario 9.2 (p-valor exacto del test de permutación)

Un p-valor pequeño ($p < \alpha$) indica que la unidad tratada exhibe una discrepancia post/pre-intervención significativamente mayor que la de las unidades placebo, rechazando H_0 de no efecto. La inferencia es exacta para el test de Fisher, pero la generalización a poblaciones superpobladas requiere supuestos adicionales de muestreo.

El Control Sintético trata al contrafactual no como un parámetro derivado de supuestos paramétricos, sino como la solución de un problema de optimización convexa — una aproximación que aísla el efecto de una intervención sobre una unidad única, pero cuya validez depende por completo de la calidad y diversidad del **donor pool**: sin restricciones paramétricas de por medio, un grupo de control que no contenga una combinación válida de la unidad tratada deja al método sin manera de detectarlo. Es, por esa razón, un método particularmente usado en el Sur Global para evaluar políticas nacionales o subnacionales — transferencias monetarias en Brasil (Bolsa Família), programas de seguridad en Colombia y Perú — donde escasean unidades comparables a gran escala. El SynC responde “cuál fue el efecto” de una política; no dice nada sobre los mecanismos por los que ese efecto se produjo. El Capítulo 10 aborda esa pregunta distinta, descomponiendo el efecto agregado en los canales causales que lo componen.

9.5 Verificación Computacional: Control Sintético con Test Placebo de Fisher

El siguiente código implementa el método de Control Sintético mediante optimización convexa en el símplex y valida el efecto con el test placebo de Fisher.

El test placebo de Fisher da evidencia exacta sin depender de supuestos asintóticos: un p -valor pequeño indica que la discrepancia post-tratamiento de la unidad tratada es mayor que la de la mayoría de placebos.

Ejemplo 9.1 (Control Sintético para la reforma educativa de Ucayali)

Ucayali implementa en 2014 una reforma de jornada escolar ampliada (JEC) para sus escuelas secundarias rurales. Los donantes potenciales son los otros 24 departamentos. El algoritmo de SynC busca pesos $(\omega_1, \dots, \omega_{24})$ que minimicen el error de pre-tratamiento 2009–2013 en tasa de conclusión secundaria: la combinación convexa óptima asigna peso 0.41 a Amazonas, 0.31 a Madre de Dios y 0.28 a Loreto. Post-2014, Ucayali supera al sintético en 3.2 pp/año (acumulado 2014–2018 = 16.1 pp). El test placebo de Fisher asigna a cada departamento el rol de tratado: solo 2 de los 24 placebos exhiben un RMSPE post/pre mayor que el de Ucayali, dando $p = \frac{2}{24} \approx 0.08$.

Supuestos clave

Supuestos del Capítulo 9 (Control Sintético)

1. **Modelo de Factor Latente:** $Y_{jt}(0) = \lambda_t' \mu_j + \varepsilon_{jt}$, con $\mathbb{E}[\varepsilon_{jt} | \lambda_t, \mu_j] = 0$.
2. **Donor pool diverso:** Las unidades de control $j = 1, \dots, J$ abarcan el espacio de factores del tratado.
3. **Ajuste pre-tratamiento:** T_0 suficientemente grande para que $\sum_j \omega_j^* \mu_j \approx \mu_1$.
4. **No interferencia:** El tratamiento de la unidad 1 no afecta los outcomes de los donantes.

Otras referencias clave de este capítulo: (Abadie & Gardeazabal, 2003), (Abadie et al., 2010), (Abadie, 2021), (Arkhangelsky et al., 2021).

9.5 Referencias

- Abadie, A. (2021). Using Synthetic Controls: Feasibility, Data Requirements, and Methodological Aspects. *Journal of Economic Literature*, 59(2), 391-425.
- Abadie, A., & Gardeazabal, J. (2003). The Economic Costs of Conflict: A Case Study of the Basque Country. *American Economic Review*, 93(1), 113-132.
- Abadie, A., Diamond, A., & Hainmueller, J. (2010). Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California's Tobacco Control Program. *Journal of the American Statistical Association*, 105(490), 493-505.
- Arkhangelsky, D., Athey, S., Hirshberg, D. A., Imbens, G. W., & Wager, S. (2021). Synthetic Difference-in-Differences. *American Economic Review*, 111(12), 4088-4118.
- Doudchenko, N., & Imbens, G. W. (2016). *Balancing, Regression, Difference-in-Differences and Synthetic Control Methods: A Synthesis* (technical report No. 22791).

CAPÍTULO 10

Mediación Causal: Descomposición de Efectos y Mecanismos

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42

Notebook (pack): notebooks/Bloque_I/notebooks/10_mediacion_causal_descomposicion_efectos_mecanismos.ipynb

Jupyter Book: jupyter_book/content/bloque_01_fundamentacion/10_mediacion_causal.ipynb

El Control Sintético, desarrollado en el capítulo anterior, ofrece una respuesta rigurosa a la pregunta de la magnitud, aislando el impacto agregado de una intervención mediante la ingeniería de un contrafactual como optimización convexa. Sin embargo, este agregado es epistemológicamente opaco. Saber que una política redujo la pobreza es insuficiente para la formulación de políticas futuras; la pregunta fundamental no es “¿cuánto?” sino “¿por qué?”. Esta indagación sobre mecanismos es, quizás, la interrogante más antigua de la ciencia aplicada: rara vez nos interesa solo si una droga cura, sino **cómo** opera; rara vez nos interesa solo si un programa de transferencias condicionadas mejora la nutrición infantil, sino si el efecto se transmite por la relajación de la restricción presupuestaria (canal de ingreso directo) o por la obligatoriedad de controles médicos (canal de información en salud). Consideremos el programa “Juntos” en Perú o “Bolsa Família” en Brasil: la estimación del efecto total no nos permite distinguir entre estos canales. El enfoque clásico de Baron & Kenny (1986), que a menudo domina la literatura aplicada, ofrece una simplicidad algebraica tentadora—la multiplicación de coeficientes de regresión—pero esta simplicidad esconde una fragilidad epistemológica severa. Este capítulo construye la arquitectura contrafactual completa necesaria para diseccionar los mecanismos causales, moviendo más allá de las correlaciones estadísticas hacia el aislamiento de vías de transmisión específicas.

El análisis de mediación opera en el Nivel 1 de la jerarquía GCE: sus estimandos fundamentales (NDE, NIE) son esperanzas de diferencias de resultados potenciales, análogos al ATE pero definidos sobre resultados anidados $Y(t, m)$. Este capítulo completa la taxonomía del Nivel 1 añadiendo la dimensión de mecanismo. El Bloque II generalizará este marco para preguntar: ¿en qué cuantiles de la distribución de Y operan los mecanismos de mediación?

10.1 El Marco Contrafactual Anidado y la Paradoja del Efecto Cero

El análisis de mediación causal requiere un sistema de variables estructurales donde el tratamiento T afecta un mediador M , que a su vez afecta el resultado Y , potencialmente con efectos directos residuales de T sobre Y .

Definición 10.1 (Sistema de Variables Estructurales)

El sistema causal de mediación consiste en:

- $T \in \{0, 1\}$: variable de tratamiento
- $M \in \mathcal{M}$: variable mediadora con distribución condicional
- $Y \in \mathbb{R}$: variable de resultado
- $X \in \mathcal{X}$: covariables de control observables

La estructura temporal es $T \rightarrow M \rightarrow Y$, con posible flecha directa $T \rightarrow Y$.

Antes de definir efectos, necesitamos precisar cómo el mediador responde al tratamiento, generalizando la noción de resultados potenciales al eslabón intermedio de la cadena causal.

Definición 10.2 (Potenciales del Mediador)

Para cada nivel de tratamiento $t \in \{0, 1\}$, el resultado potencial del mediador es:

$$M_{i(t)} \in \mathcal{M} \quad (10.1.1)$$

El mediador observado satisface consistencia: $M_i = M_{i(T_i)}$.

Con el mediador potencial definido, el resultado potencial se anida para reflejar la dependencia simultánea del tratamiento directo y del valor del mediador, creando un espacio contrafactual bidimensional.

Definición 10.3 (Potenciales Anidados del Resultado)

El resultado potencial es función de tanto el tratamiento como el valor del mediador:

$$Y_{i(t,m)} \in \mathbb{R} \quad \text{para } t \in \{0, 1\}, m \in \mathcal{M} \quad (10.1.2)$$

Esta notación anidada permite evaluar el resultado bajo cualquier combinación de tratamiento y mediador.

Axioma 10.1 (Consistencia Anidada)

El resultado observado satisface:

$$Y_i = Y_{i(T_i, M_{i(T_i)})} \quad (10.1.3)$$

El valor observado corresponde al potencial evaluado en el tratamiento recibido y el mediador inducido por ese tratamiento.

Proposición 10.1 (Paradoja del Efecto Cero en Mediación)

Es posible que el efecto total del tratamiento sea cero mientras existen efectos directo e indirecto no nulos que se cancelan exactamente.

La “Paradoja del Efecto Cero” ilustrada por el contraejemplo $(-1)^{t+m}$ no es un mero artificio matemático; representa una realidad estructural en sistemas complejos donde las vías de transmisión se antagonizan mutuamente. Una intervención puede ser completamente ineficaz en el agregado porque su canal beneficioso es cancelado perfectamente por un efecto directo perjudicial. Esta realidad exige una precisión quirúrgica en nuestras definiciones. No podemos hablar de “el efecto del mecanismo” como una entidad monolítica. Es imperativo distinguir entre el Efecto Directo Controlado (CDE), que requeriría manipulación experimental del mediador, y los Efectos Naturales Directos e Indirectos (NDE, NIE). Estas no son meras variantes algebraicas, sino respuestas a preguntas causales radicalmente distintas, cada una encapsulando una política de intervención implícita diferente y única.

10.2 Definición Formal de Efectos Causalmente Estructurales

La descomposición del efecto total requiere definir efectos que mantengan el mediador en niveles específicos o lo dejen evolucionar naturalmente.

Definición 10.4 (Efecto Directo Controlado (CDE))

El efecto directo del tratamiento manteniendo el mediador fijo en nivel m es:

$$\text{CDE}(m, x) = \mathbb{E}[Y(1, m) - Y(0, m) \mid X = x] \quad (10.2.1)$$

Esta cantidad es identificable pero requiere manipulación experimental del mediador.

Definición 10.5 (Efecto Directo Natural (NDE))

El efecto directo natural mantiene el mediador en el nivel que habría tomado bajo control:

$$\text{NDE}(x) = \mathbb{E}[Y(1, M(0)) - Y(0, M(0)) \mid X = x] \quad (10.2.2)$$

El contrafactual $Y(1, M(0))$ requiere que el mediador evolucione bajo $T = 0$ mientras el resultado se evalúa bajo $T = 1$.

Definición 10.6 (Efecto Indirecto Natural (NIE))

El efecto indirecto natural captura el cambio en el resultado debido al cambio inducido en el mediador, manteniendo el tratamiento fijo en $T = 1$:

$$\text{NIE}(x) = \mathbb{E}[Y(1, M(1)) - Y(1, M(0)) \mid X = x] \quad (10.2.3)$$

Teorema 10.1 (Descomposición Aditiva de Efectos Naturales)

El efecto total se descompone aditivamente en efecto directo natural e indirecto natural:

$$\text{ATE}(x) = \text{NDE}(x) + \text{NIE}(x) \quad (10.2.4)$$

La tensión central en la identificación de los efectos naturales reside en la naturaleza de los contrafactuales requeridos. El NDE, por ejemplo, evalúa el resultado bajo $T = 1$ mientras mantiene el mediador en el valor que habría tomado bajo $T = 0$. Esta construcción implica contrafactuales anidados —mundos híbridos donde el tratamiento y el mediador se fijan de manera independiente— que no corresponden a ninguna intervención física realizable en un único mundo. En consecuencia, la identificación de estos efectos no-intervencionistas exige supuestos más fuertes y costosos que los requeridos para el ATE estándar. El precio por revelar el mecanismo es epistemológico: debemos asumir independencia entre contrafactuales que residen en universos paralelos.

10.3 Condiciones de Identificación (Ignorabilidad Secuencial)

La identificación de efectos naturales requiere supuestos más fuertes que el CIA estándar, incluyendo independencia entre contrafactuales de diferentes mundos.

Definición 10.7 (Supuestos de Ignorabilidad Secuencial)

1. Ignorabilidad del Tratamiento: $(Y(t, m), M(t')) \perp\!\!\!\perp T \mid X$ para todo t, t', m
2. Ignorabilidad del Mediador: $Y(t, m) \perp\!\!\!\perp M \mid T = t, X$ para todo t, m
3. Independencia Cross-World: $Y(t, m) \perp\!\!\!\perp M(t') \mid X$ para todo t, t', m con $t \neq t'$

Teorema 10.2 (Identificación de Efectos Naturales)

Bajo ignorabilidad secuencial, los efectos naturales se identifican como:

$$NIE(x) = \sum_{m \in \mathcal{M}} \mathbb{E}[Y \mid T = 1, M = m, X = x] - \mathbb{E}[Y \mid T = 0, M = m, X = x] \mathbb{P}(M = m \mid T = 0, X = x)$$

El supuesto de independencia cross-world es fundamental pero intrínsecamente no testeable, ya que involucra correlaciones entre contrafactuales de diferentes mundos ($Y(1, m)$ y $M(0)$) que nunca se observan simultáneamente.

La condición de independencia cross-world constituye quizás el supuesto más honesto, a la vez que más exigente, de la econometría aplicada. Reconocemos implícitamente su no-testabilidad—no podemos observar $Y(1, m)$ y $M(0)$ simultáneamente—pero procedemos a examinar qué inferencias serían posibles si se mantuviera. La resolución de esta tensión teórica se encuentra en la Fórmula de Mediación de Pearl. Esta formulación demuestra que, bajo la estructura de ignorabilidad secuencial, estos complejos contrafactuales anidados colapsan elegantemente a cantidades puramente observacionales mediante el uso de expectativas iteradas, permitiéndonos calcular, desde los datos de un solo mundo, las distancias entre estos universos paralelos hipotéticos.

10.4 La Fórmula de Mediación No Paramétrica

La fórmula de mediación de Pearl (Pearl, 2001) proporciona una representación integral de los efectos naturales bajo los supuestos de identificación.

Teorema 10.3 (Fórmula de Mediación de Pearl)

Para mediador continuo o discreto con densidad/densidad de probabilidad sobre $\mathcal{M}$, el efecto directo natural se identifica como:

$$NDE(x) = \int_{\mathcal{M}} (\mathbb{E}[Y \mid T = 1, M = m, X = x] - \mathbb{E}[Y \mid T = 0, M = m, X = x]) d\mathbb{P}(M = m \mid T = 1, X = x)$$

Corolario 10.1 (Fórmula del NIE)

Por la descomposición aditiva $ATE = NDE + NIE$:

$$NIE(x) = \int_{\mathcal{M}} \mathbb{E}[Y \mid T = 1, M = m, X = x] (d\mathbb{P}(M = m \mid T = 1, X = x) - d\mathbb{P}(M = m \mid T = 0, X = x))$$

La fórmula de Pearl es general y no paramétrica, pero su aplicación práctica exige estimar expectativas condicionales flexibles en dimensión potencialmente alta — computacionalmente exigente. En la práctica, los investigadores a menudo recurren en cambio a los Modelos de Ecuaciones Estructurales Lineales (LSEM), el enfoque de Baron-Kenny: una aproximación tratable cuando el mundo se comporta linealmente, pero que produce estimaciones inconsistentes en cuanto el proceso generador de datos se desvía de la linealidad o contiene interacciones.

10.5 El Colapso Paramétrico: De Pearl a Baron-Kenny

El enfoque lineal de Baron-Kenny emerge como caso especial cuando todas las relaciones son modeladas linealmente sin interacciones.

Definición 10.8 (Ecuaciones del LSEM)

El Linear Structural Equation Model especifica:

$$M_i = \alpha_0 + \alpha_1 T_i + \alpha_2^{\text{op}} X_i + \varepsilon_{\text{Mi}} \quad Y_i = \beta_0 + \beta_1 T_i + \beta_2 M_i + \beta_3^{\text{op}} X_i + \varepsilon_{\text{Yi}} \quad (10.5.1)$$

con $\mathbb{E}[\varepsilon_{\text{Mi}} | T_i, X_i] = 0$ y $\mathbb{E}[\varepsilon_{\text{Yi}} | T_i, M_i, X_i] = 0$.

Lema 10.1 (Forma Contrafactual del LSEM)

Bajo el LSEM, los potenciales anidados tienen representación lineal explícita:

$$M_{i(t)} = \alpha_0 + \alpha_1 t + \alpha_2^{\text{op}} X_i + \varepsilon_{\text{Mi}(t,m)} \quad Y_{i(t,m)} = \beta_0 + \beta_1 t + \beta_2 m + \beta_3^{\text{op}} X_i + \varepsilon_{\text{Yi}} \quad (10.5.2)$$

La ausencia de término de interacción $T \times M$ es crítica para la linealidad de la descomposición.

Teorema 10.4 (Colapso Lineal de Efectos Naturales)

En el LSEM sin interacciones, los efectos naturales colapsan a:

$$\text{NDE} = \beta_1 \quad \text{y} \quad \text{NIE} = \alpha_1 \beta_2 \quad (10.5.3)$$

Corolario 10.2 (Equivalencia Asintótica con Baron-Kenny)

El método de Baron-Kenny, que estima $\hat{\beta}_1$ de la regresión de Y sobre T controlando por M , y $\hat{\alpha}_1 \hat{\beta}_2$ del producto de coeficientes de las regresiones de M sobre T y Y sobre M (ajustado), converge asintóticamente a los efectos naturales NDE y NIE cuando el DGP es lineal sin interacciones.

Proposición 10.2 (Fragilidad del Enfoque Lineal)

El colapso $\text{NDE} = \beta_1$ y $\text{NIE} = \alpha_1 \beta_2$ es extremadamente frágil. Se viola bajo:

1. Interacciones: Si $Y_i = \beta_0 + \beta_1 T_i + \beta_2 M_i + \beta_4 T_i M_i + \varepsilon_{\text{Yi}}$, entonces $\text{NDE} = \beta_1 + \beta_4 \mathbb{E}[M(0)]$, que varía con la distribución del mediador.
2. No linealidades: Transformaciones no lineales de M (log, polinomios) hacen que la fórmula del producto sea inconsistente para los efectos naturales definidos contrafactualmente.
3. Heterogeneidad: Si β_{2i} varía individualmente y está correlacionado con $M_{i(t)}$, el efecto indirecto promedio no es el producto de promedios.

Proposición 10.3 (Fórmulas Correctas bajo Interacción $T \times M$)

Si el modelo de resultado especifica interacción:

$$Y_i = \beta_0 + \beta_1 T_i + \beta_2 M_i + \beta_4 T_i M_i + \beta_3^{\text{op}} X_i + \varepsilon_{\text{Yi}} \quad (10.5.4)$$

entonces las fórmulas de Baron-Kenny $\widehat{\text{NDE}} = \hat{\beta}_1$ y $\widehat{\text{NIE}} = \hat{\alpha}_1 \hat{\beta}_2$ son inconsistentes. Las expresiones correctas para los efectos naturales son:

$$\text{NDE} = \beta_1 + \beta_4 \cdot \mathbb{E}[M(0) | X] \quad \text{NIE} = (\beta_2 + \beta_4) \cdot \alpha_1 \quad (10.5.5)$$

donde α_1 es el coeficiente de T en la regresión del mediador. El sesgo introducido por Baron-Kenny es $\beta_4 \cdot \mathbb{E}[M(0)]$ en el NDE y $\beta_4 \cdot \alpha_1$ en el NIE. Esta falla del método clásico ilustra la Paradoja del Efecto Cero en mediación': con $\beta_4 < 0$ suficientemente negativo, un NDE positivo real puede aparecer como nulo bajo Baron-Kenny.

10.5.1 Confusor entre el Mediador y el Resultado

Una violación frecuente en la práctica empírica es la existencia de un confusor no observado U entre el mediador M y el resultado Y . En el programa Juntos, por ejemplo, la motivación intrínseca del hogar puede afectar tanto la asistencia a controles médicos (M) como los resultados de nutrición (Y) de manera no observada.

Proposición 10.4 (Sesgo por Confusor M - Y no Observado)

Si existe un confusor no observado U tal que $U \rightarrow M$ y $U \rightarrow Y$, la condición de ignorabilidad del mediador $Y(t, m) \perp\!\!\!\perp M \mid T = t, X$ se viola. En este caso, la fórmula de mediación produce estimados sesgados:

$$\widehat{\text{NDE}}^{\text{sesgado}} = \text{NDE} + \underbrace{\mathbb{E}[\gamma_U \cdot \text{Cov}(T, U \mid X)]}_{\text{sesgo por confusor M-Y}} \quad (10.5.6)$$

donde γ_U es el efecto de U sobre Y (no identificado sin U observable).

Cuando U no es observable, existen tres estrategias para lidiar con el confusor M - Y :

1. Si U puede medirse, agregarla como covariable en la regresión de Y sobre (T, M, X, U) .
2. Si existe un instrumento Z_M para M (que afecta M pero no Y directamente), usar IV para identificar el efecto de M sobre Y purgando el sesgo de U (Tchetgen Tchetgen & VanderWeele, 2014).
3. Reportar análisis de sensibilidad: cuán fuerte debe ser la asociación de U con (M, Y) para que el NDE cambie de signo.

Teorema 10.5 (Generalidad de la Fórmula de Pearl)

La fórmula de mediación no paramétrica:

$$\text{NDE}(x) = \int_{\mathcal{M}} (\mu(1, m, x) - \mu(0, m, x)) d\mathbb{P}(m \mid 0, x) \quad (10.5.7)$$

donde $\mu(t, m, x) = \mathbb{E}[Y \mid T = t, M = m, X = x]$, es válida para cualquier forma funcional de las relaciones $T \rightarrow M$ y $(T, M) \rightarrow Y$, incluyendo no linealidades, interacciones, y heterogeneidad no observada (bajo ignorabilidad secuencial).

Axioma 10.2 (Principio de Modelación Causal)

En mediación, la especificación paramétrica debe servir al estimando contrafactual, no al revés. El enfoque lineal de Baron-Kenny es una calculadora válida solo bajo condiciones de razor-thin; el análisis robusto requiere la fórmula de Pearl implementada mediante modelos flexibles (series, kernels, ML) para las funciones $\mu(t, m, x)$ y la distribución del mediador.

10.6 Verificación Computacional: NDE y NIE via G-Computation

El siguiente código compara la estimación de Baron-Kenny (lineal) con la fórmula de Pearl (g-computation no paramétrica), mostrando su equivalencia bajo linealidad y su divergencia bajo interacción.

Ejemplo 10.1 (Mediación causal en el programa Juntos – Perú)

El programa Juntos transfiere ingresos condicionados a hogares rurales ($T = 1$) con la condición de asistir a controles de salud ($M = 1$). El resultado de interés es la tasa de anemia infantil (Y). Una evaluación naive reporta $\hat{\tau}_{ATE} \approx -4.2$ pp. La descomposición de Pearl revela: el canal directo (alivio de pobreza, mejor alimentación, sin pasar por controles) contribuye $\widehat{NDE} \approx -1.8$ pp, y el canal indirecto (cumplimiento de controles médicos) contribuye $\widehat{NIE} \approx -2.4$ pp. El método de Baron-Kenny produce idénticos resultados porque la relación $M \rightarrow Y$ es aproximadamente lineal en este contexto; sin embargo, si se introduce la interacción $T \times M$ (hogares que reciben transferencia Y asisten a controles tienen acceso a nutrición suplementaria), el NIE aumenta a -3.1 pp y el NDE se reduce, ilustrando la fragilidad del enfoque lineal.

Supuestos clave**Supuestos del Capítulo 10 (Mediación Causal)**

1. **Ignorabilidad del Tratamiento:** $(Y(t, m), M(t')) \perp\!\!\!\perp T \mid X$ para todo t, t', m . El tratamiento es como-si-aleatorio dado X .
2. **Ignorabilidad del Mediador:** $Y(t, m) \perp\!\!\!\perp M \mid T = t, X$ para todo t, m . No hay confusión no observada entre M e Y dado (T, X) .
3. **Independencia Cross-World:** $Y(t, m) \perp\!\!\!\perp M(t') \mid X$ para $t \neq t'$. Los contrafactuales de mundos distintos son independientes dado X — supuesto no testeable.
4. **Consistencia Anidada:** $Y_i = Y_{i(T_i, M_{i(T_i)})}$ y $M_i = M_{i(T_i)}$ — no hay versiones múltiples de tratamiento ni mediador.

10.7 Cierre del capítulo

La mediación causal es la comparación rigurosa de contrafactuales anidados bajo ignorabilidad secuencial: la fórmula de Pearl es válida para cualquier forma funcional, mientras que Baron-Kenny es una proyección paramétrica válida solo bajo linealidad estricta. Estas descomposiciones descansan enteramente sobre supuestos de identificación no testeables, en particular la independencia cross-world — reportar NDE/NIE sin el DAG de mediación que los justifica es incompleto. El Capítulo 11 evalúa precisamente eso: qué tan frágiles son estas inferencias ante la violación de supuestos críticos y no observables.

Otras referencias clave de este capítulo: (Robins & Greenland, 1992), (Imai et al., 2010), (Vander-Weele, 2015).

10.7 Referencias

- Baron, R. M., & Kenny, D. A. (1986). The Moderator-Mediator Variable Distinction in Social Psychological Research: Conceptual, Strategic, and Statistical Considerations. *Journal of Personality and Social Psychology*, 51(6), 1173-1182.
- Imai, K., Keele, L., & Tingley, D. (2010). A General Approach to Causal Mediation Analysis. *Psychological Methods*, 15(4), 309-334.
- Pearl, J. (2001). Direct and Indirect Effects. *Proceedings of the Seventeenth Conference on Uncertainty in Artificial Intelligence (UAI-01)*, 411-420.
- Robins, J. M., & Greenland, S. (1992). Identifiability and Exchangeability for Direct and Indirect Effects. *Epidemiology*, 3(2), 143-155.

- Tchetgen Tchetgen, E. J., & VanderWeele, T. J. (2014). On Identification of Natural Direct Effects when a Confounder of the Mediator is Observed. *Biometrics*, 70(3), 670-677.
- VanderWeele, T. J. (2015). *Explanation in Causal Inference: Methods for Mediation and Interaction*. Oxford University Press.

CAPÍTULO 11

Robustez, Validación y Contextos Especiales

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42

Notebook (pack): notebooks/Bloque_I/notebooks/11_robustez_validacion_contextos_especiales.ipynb

Jupyter Book: jupyter_book/content/bloque_01_fundamentacion/11_robustez_validacion.ipynb

Hasta el capítulo anterior, toda nuestra arquitectura metodológica descansó sobre el pilar de la ignorabilidad fuerte⁴, un ideal de limpieza causal que rara vez se materializa en la complejidad de los datos sociales del mundo real. Este capítulo marca un quiebre epistemológico necesario: reconocer que asumir la ausencia total de confusión no observada es, en el mejor de los casos, una ilusión de precisión y, en el peor, una negligencia metodológica. El objetivo de esta sección transita desde la estimación puntual ingenua hacia la identificación parcial y el estrés test; la pregunta deja de ser ¿cuál es el efecto exacto?⁵ para convertirse en ¿qué tan potente debe ser un factor oculto para destruir nuestra inferencia?⁶.

Consideremos la evaluación de programas como Qali Warma⁷ o Beca 18⁸ en el Perú: podemos controlar meticulosamente por ingresos y notas, pero factores inobservables como la motivación intrínseca familiar o redes políticas locales acechan inevitablemente en las sombras de la varianza residual. La sensibilidad no es un accesorio, sino el prerequisite de la honestidad científica, especialmente en contextos del Sur Global donde los datos son escasos, los supuestos de identificación son más difíciles de cumplir, y las consecuencias de decisiones erróneas pueden ser devastadoras.

11.1 El Colapso de la Ignorabilidad Fuerte y el Reto de los Datos Limitados

La ignorabilidad fuerte $(Y(0), Y(1)) \perp\!\!\!\perp T \mid X$ es irrealizable empíricamente cuando existen confusores no observados, y este problema se exagera en contextos donde los datos son limitados, los sistemas de medición son incompletos, y la heterogeneidad contextual es extrema. El análisis de sensibilidad cuantifica cómo la violación de este supuesto afecta la identificación, pero en condiciones de escasez de datos, debemos ir más allá de los métodos estándar.

Definición 11.1 (Variable de Confusión No Observada en Contextos Complejos)

Sea $U \in \mathcal{U}$ una variable no observada que afecta tanto la asignación al tratamiento como los resultados potenciales. En contextos del Sur Global, U típicamente representa:

- Factores socio-culturales no medidos (capital social, redes informales)
- Heterogeneidad institucional subnacional
- Sesgos de medición sistemáticos en sistemas administrativos incompletos
- Factores históricos y coloniales persistentes

La ignorabilidad débil establece que el tratamiento es independiente de los resultados potenciales condicional en observables y no observables:

$$(Y(0), Y(1)) \perp\!\!\!\perp T \mid (X, U) \quad (11.1.1)$$

Sin observar U , el ATE no está puntualmente identificado.

En condiciones de datos limitados y alta heterogeneidad, debemos adoptar un enfoque más conservador:

$$\mathbb{E}[Y(t) \mid T = 1, X, U] - \mathbb{E}[Y(t) \mid T = 0, X, U] \neq 0 \quad \text{para } t \in \{0, 1\} \quad (11.1.2)$$

Presumimos que algún grado de confusión residual existe siempre, y nuestro análisis debe cuantificar qué tan fuerte debe ser para invalidar nuestras conclusiones.

Teorema 11.1 (Identificación Parcial del ATE con Datos Limitados (Cotas de Manski Adaptadas))

Bajo ignorabilidad débil y datos limitados ($n < 500$), el ATE satisface cotas sharp adaptadas. Definamos: $\tau_{\text{obs}} = \mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0]$ (diferencia de medias observada), $p = \mathbb{P}(T = 1)$ (prevalencia del tratamiento), $\Delta_t = \sup Y(t) - \inf Y(t)$ (rango del resultado potencial t). Entonces:

$$\tau_{\text{ATE}} \in [\tau_{\text{obs}} - \Delta_0(1 - p) - \Delta_1 p - \varepsilon(n), \tau_{\text{obs}} + \Delta_0(1 - p) + \Delta_1 p + \varepsilon(n)] \quad (11.1.3)$$

donde $\varepsilon(n)$ es un término de incertidumbre que crece como $O\left(\frac{1}{\sqrt{n}}\right)$, reflejando la mayor varianza en muestras pequeñas. Esta cota es más conservadora que la estándar de Manski (1990), incorporando explícitamente la incertidumbre muestral.

Cuando n es pequeño, $\varepsilon(n)$ es grande, y las cotas se expanden significativamente. Esto refleja la realidad epistemológica: con datos limitados, debemos ser más cautelosos y reportar intervalos de identificación más amplios, incluso bajo supuestos optimistas sobre confusión no observada.

11.2 El Modelo de Sensibilidad de Rosenbaum y su Aplicación en Muestras Pequeñas

El modelo de Rosenbaum (2002) parametriza la violación de ignorabilidad mediante el odds ratio de asignación al tratamiento, pero su implementación en muestras pequeñas requiere adaptaciones.

Definición 11.2 (Parámetro Γ de Rosenbaum Adaptado)

La sensibilidad al confusor no observado se parametriza por $\Gamma \geq 1$ tal que:

$$\frac{1}{\Gamma} \leq \frac{\mathbb{P}^{T_i=1 \mid X_i, U_i}(T_i = 0 \mid X_i, U_i)}{\mathbb{P}^{T_j=1 \mid X_j, U_j}(T_j = 0 \mid X_j, U_j)} \leq \Gamma \quad (11.2.1)$$

Para muestras pequeñas ($n < 200$), recomendamos usar tests exactos en lugar de aproximaciones asintóticas, y reportar el valor crítico Γ^* para el cual el p-valor cruza el umbral $\alpha = 0.10$ (más conservador que $\alpha = 0.05$).

Teorema 11.2 (Cotas de Rosenbaum con Corrección por Tamaño Muestral)

Bajo la hipótesis nula fuerte de Fisher:

$$H_0 : Y_{i(1)} = Y_{i(0)} \quad \text{para toda unidad } i = 1, \dots, n, \quad (11.2.2)$$

frente a la alternativa $H_1 : \exists i$ tal que $Y_{i(1)} \neq Y_{i(0)}$, y para un parámetro de sensibilidad $\Gamma \geq 1$, el p-valor para el estadístico de prueba S satisface:

$$p^-(\Gamma, n) \leq \text{p-valor} \leq p^+(\Gamma, n) \quad (11.2.3)$$

donde:

$$p^-(\Gamma, n) = \mathbb{P}\left(\sum_{i,j} p_{ij}^- Z_{ij} \geq s_{\text{obs}} \mid n\right) \quad p^+(\Gamma, n) = \mathbb{P}\left(\sum_{i,j} p_{ij}^+ Z_{ij} \geq s_{\text{obs}} \mid n\right) \quad (11.2.4)$$

con $p_{ij}^- = \frac{1}{1+\Gamma}$ y $p_{ij}^+ = \frac{\Gamma}{1+\Gamma}$. Las probabilidades deben calcularse mediante simulación exacta o permutación cuando n es pequeño, en que Z_{ij} es una variable indicadora de la dirección de la comparación en cada par o estrato, S es el estadístico de prueba (por ejemplo, suma de rangos) y $s_{\{\text{obs}\}}$ es su valor observado en la muestra.

Definición 11.3 (Valor Crítico Γ^* de Rosenbaum)

El valor crítico Γ^* es el valor más pequeño de Γ para el cual el p-valor máximo cruza el umbral de significancia α :

$$\Gamma^* = \min\{\Gamma \geq 1 : p^+(\Gamma, n) \geq \alpha\} \quad (11.2.5)$$

La interpretación es operacional: *el resultado es significativo al $\alpha\%$ para $\Gamma \leq \Gamma^*$* . Si $\Gamma^* > 2$, el resultado es robusto a un confusor que hasta duplica las odds de tratamiento entre unidades emparejadas. Si $\Gamma^* < 1.5$, la evidencia es frágil.

Ejemplo 11.1 (Valor crítico Γ^* y Pensión 65)

Suponga que el test de Wilcoxon de rangos con signo produce $p^+(\Gamma = 1) = 0.03$ (significativo al 5%) y $p^+(\Gamma = 1.8) = 0.06$ (no significativo al 5%). Entonces $\Gamma^* \approx 1.8$: la conclusión de efecto positivo se mantiene mientras un confusor no observado no altere las odds de tratamiento por más de un factor de 1.8. En el contexto de programas sociales, donde la focalización por puntaje SISFOH es razonablemente precisa, este nivel de robustez se considera moderadamente satisfactorio.

Ambas métricas cuantifican robustez a confusión no observada, pero desde perspectivas complementarias. El parámetro Γ opera en el espacio de odds ratios de tratamiento (interpretable en diseños de matching y estudios observacionales con outcomes continuos), mientras que el E-Value opera en el espacio de riesgos relativos (más natural en epidemiología y outcomes binarios). Γ responde ¿cuánto puede diferir la probabilidad de tratamiento entre unidades emparejadas?; el E-Value responde ¿qué tan fuerte debe ser la asociación del confusor con tratamiento y resultado simultáneamente?. Usar ambas métricas es preferible a usar solo una.

11.3 El E-Value: Interpretación Universal para Toma de Decisiones

El E-value cuantifica la magnitud mínima de asociación confusora requerida para explicar completamente un efecto observado, ofreciendo una métrica intuitiva para comunicar incertidumbre a tomadores de decisiones no técnicos.

Definición 11.4 (E-Value Adaptado para Contextos del Sur Global)

Para un riesgo relativo observado $RR_{\text{obs}} > 1$ estimado con datos limitados, el E-value se define como:

$$E\text{-value} = RR_{\text{obs}} + \sqrt{RR_{\text{obs}}(RR_{\text{obs}} - 1)} + \delta(n) \quad (11.3.1)$$

donde $\delta(n)$ es un término de ajuste conservador que crece cuando n es pequeño, reflejando mayor incertidumbre muestral. Para $n < 200$, recomendamos $\delta(n) = 0.5 \cdot \left(\frac{1}{\sqrt{n}}\right)$.

Teorema 11.3 (Uso práctico del E-Value)

Un E-value de E significa que para explicar completamente la asociación observada, necesitaríamos un confusor no observado U que esté asociado con tanto el tratamiento como el resultado con riesgos relativos de al menos E cada uno. En contextos de políticas públicas:

- $E < 1.5$: Evidencia frágil, fácilmente explicable por confusión plausible
- $1.5 \leq E < 2.5$: Evidencia moderadamente robusta
- $E \geq 2.5$: Evidencia robusta, requeriría confusión sustancial para invalidarla

11.4 Causalidad en Contextos del Sur Global: Desafíos y Adaptaciones

La inferencia causal en contextos del Sur Global —América Latina, África, Asia del Sur y Sudeste Asiático— enfrenta desafíos metodológicos únicos que van más allá de la aplicación mecánica de métodos estándar. El término ‘Sur Global’ no es solo geográfico sino epistemológico: se refiere a contextos donde los datos son escasos, costosos de recolectar, y donde las intervenciones de política a menudo se implementan en entornos con alta heterogeneidad no observada.

11.4.1 Desafíos Específicos

- **Muestras pequeñas:** Estudios con $n < 500$ son comunes, especialmente en evaluaciones locales o subnacionales. Para un efecto estandarizado $d = 0.2$ (pequeño pero relevante en política social), se requiere $n > 600$ para potencia del 80% con $\alpha = 0.05$. En muchos contextos del Sur Global, muestras de este tamaño son inviables.
- **Missing data no aleatorio:** La falta de datos suele correlacionarse con variables socioeconómicas (pobreza, ruralidad, género), violando el supuesto de Missing at Random (MAR).
- **Positividad práctica violada:** Programas sociales focalizados crean situaciones donde para los extremadamente pobres: $P(T = 1|X) \approx 1$ (todos son elegibles) y para los no pobres: $P(T = 1|X) \approx 0$ (ninguno es elegible), generando **overlap deficiente**.
- **Heterogeneidad contextual extrema:** Los efectos del tratamiento varían dramáticamente por región, etnia, género, y contexto institucional. Un ATE promedio puede enmascarar efectos beneficiosos en algunos subgrupos y efectos nulos o negativos en otros.

11.4.2 Estrategias para Datos Limitados

11.4.2.1 Inferencia Causal Bayesiana con Priors Informados

Incorporar información previa (priors) de estudios anteriores o conocimiento de expertos compensa la escasez de datos. Para el CATE (Conditional Average Treatment Effect):

$$\tau(x) = \mathbb{E}[Y(1) - Y(0)|X = x] \quad (11.4.1)$$

Especificar un prior jerárquico por región:

$$\tau_r \sim \mathcal{N}(\mu_{\text{tau}}, \sigma_{\text{tau}}^2), \quad \mu_{\text{tau}} \sim \mathcal{N}(0, 1), \quad \sigma_{\text{tau}} \sim \text{Expon}(1) \quad (11.4.2)$$

Esto permite shrinkage' parcial hacia la media global cuando los datos regionales son limitados, mientras permite heterogeneidad cuando hay evidencia suficiente.

11.4.2.2 Double Machine Learning con Regularización Fuerte

Cuando n es pequeño pero p (número de covariables) es moderado, usar regularización agresiva:

- **Propensity score:** Regresión logística con penalización Ridge/Lasso y parámetro $\lambda = O\left(\frac{1}{\sqrt{n}}\right)$
- **Outcome model:** Ridge regression con α grande para prevenir overfitting
- **Cross-validation** con k pequeño ($k = 3$ o $k = 5$) para maximizar datos de entrenamiento

11.4.2.3 Manejo de Overlap Deficiente

- **Trimming adaptativo:** Eliminar unidades con propensity score extremo, pero con umbrales adaptados al tamaño muestral:

$$\text{Umbral inferior} = \max(0.05, q_{5\%}(\bar{e}(X))), \quad \text{Umbral superior} = \min(0.95, q_{95\%}(\bar{e}(X))) \quad (11.4.3)$$

- **Overlap Weights:** Ponderar por la varianza del propensity score:

$$w_i = \hat{e}(X_i)(1 - \hat{e}(X_i)) \quad (11.4.4)$$

Estas ponderaciones maximizan la eficiencia en la subpoblación con mejor overlap.

11.5 El ICE Stress Test en Condiciones Adversas

El ICE (Impact Confounding Explorer) Stress Test evalúa la robustez de conclusiones causales ante violaciones graduales de ignorabilidad, y debe adaptarse para contextos con datos limitados.

Definición 11.5 (ICE Stress Test Adaptado)

El procedimiento de estrés test consta de tres pasos adaptados:

1. **Perturbación Parametrizada Conservadora:** Introducir un confusor no observado U con asociaciones (α, β) donde variamos en una grilla más restringida $[0, 0.5] \times [0, 0.5]$ (en lugar de $[0, 1] \times [0, 1]$) para reflejar mayor incertidumbre.
2. **Recálculo con Bootstrap:** Para cada par (α, β) , calcular el estimando ajustado $\hat{\tau}(\alpha, \beta)$ usando bootstrap ($B = 1000$ repeticiones) para incorporar incertidumbre muestral.
3. **Umbral de Colapso Conservador:** Encontrar el mínimo $\Gamma_{\text{ICE}} = \min\{\alpha \cdot \beta : \text{IC}_{95\%}(\hat{\tau}(\alpha, \beta)) \text{ contiene el cero}\}$.

La interpretación de Γ_{ICE} en contextos del Sur Global sigue una clasificación más estricta:

- **Muy Frágil:** $\Gamma_{\text{ICE}} < 0.025$. Una confusión menor (correlaciones de 0.16×0.16) revierte la conclusión.
- **Frágil:** $0.025 \leq \Gamma_{\text{ICE}} < 0.10$. Requiere confusión moderada para reversión.
- **Aceptablemente Robusta:** $\Gamma_{\text{ICE}} \geq 0.10$. Solo confusión sustancial (correlaciones > 0.3) amenaza la conclusión.

11.6 Pruebas de Placebo y Falsificación en Muestras Pequeñas

Las pruebas de placebo evalúan la credibilidad de supuestos de identificación aplicando el estimador a escenarios donde el efecto causal debería ser nulo. En muestras pequeñas, estas pruebas requieren adaptaciones.

Definición 11.6 (Variable Placebo para Contextos Complejos)

Una variable placebo Y^{placebo} debe satisfacer no solo $\mathbb{E}[Y^{\text{placebo}}(1) - Y^{\text{placebo}}(0) | X] = 0$, sino también tener una distribución similar a Y en términos de varianza y autocorrelación. En contextos con datos limitados, recomendamos:

- Variables de resultado medidas antes del tratamiento (pre-treatment outcomes)
- Variables afectadas por canales no causales (ej. edad, género cuando el tratamiento no afecta estas variables)
- Variables sintéticas construidas para imitar la estructura de dependencia de Y

Teorema 11.4 (Poder de Tests Placebo en Muestras Pequeñas)

En una muestra de tamaño n , la potencia de un test placebo para detectar una violación de tamaño δ es aproximadamente:

$$\text{Potencia} \approx \Phi\left(\frac{\delta\sqrt{n}}{\sigma} - z_{1-\alpha}\right) \quad (11.6.1)$$

donde Φ es la CDF normal estándar, σ es la desviación estándar del efecto placebo, y $z_{1-\alpha}$ es el cuantil normal. Para $n < 200$, incluso violaciones moderadas ($\delta = 0.3\sigma$) tienen potencia baja ($< 60\%$ con $\alpha = 0.05$).

Corolario 11.1 (Recomendación para Muestras Pequeñas)

En contextos con $n < 200$:

1. Usar $\alpha = 0.10$ en lugar de 0.05 para tests placebo
2. Reportar tamaños de efecto estandarizados en lugar de solo significancia estadística
3. Complementar con análisis gráficos de tendencias pre-tratamiento
4. Considerar tests de permutación exactos cuando sea posible

11.7 Caso de Estudio Integrado: Programa Pensión 65 en Perú

11.7.1 Contexto y Desafíos

Pensión 65 es un programa de transferencias monetarias a adultos mayores en situación de pobreza extrema en Perú. La evaluación enfrenta tres desafíos típicos del Sur Global:

1. Muestras pequeñas en regiones rurales ($n < 100$ en algunas provincias)
2. Casi todos los pobres extremos son elegibles (violación de positividad)
3. Alta correlación espacial del tratamiento (vecindarios completos son tratados)

11.7.2 Estrategia de Análisis Integrada

Implementamos un pipeline que combina todas las técnicas discutidas:

1. **Agrupación regional:** Combinar provincias pequeñas en super-regiones por similitud socioeconómica y geográfica.

2. **CATE bayesiano:** Especificar un modelo jerárquico con prior $\tau_r \sim \mathcal{N}^+(0, 25)$ (efecto positivo pero acotado).
3. **Análisis de sensibilidad múltiple:** Reportar:
 - Estimador AIPW con trimming adaptativo
 - E-value para el efecto principal
 - ICE Stress Test con $\alpha, \beta \in [0, 0.6]$
 - Bounds de Manski con corrección por tamaño muestral
1. **Validación rigurosa:**
 - Tests placebo en períodos pre-tratamiento
 - Falsificación usando variables no afectadas (edad, género)
 - Validación cruzada con Synthetic Control Method

11.7.3 Implementación en Python

11.7.4 Resultados y Interpretación

Aplicando este pipeline integrado a datos de Pensión 65:

- **ATE estimado:** 45 soles/mes (aproximadamente USD 12)
- **Intervalo de confianza 95%:** [15, 75] soles/mes (amplio por tamaño muestral pequeño)
- **E-value:** 2.3 (robustez moderada-alta)
- **ICE Gamma:** 0.08 (clasificado como Frágil“)
- **Heterogeneidad:** Efecto mayor en regiones andinas (+62 soles) que costeñas (+28 soles)

El efecto positivo de Pensión 65 es estadísticamente detectable pero moderadamente robusto a confusión. La fragilidad indicada por ICE Gamma sugiere que confusión moderada ($\alpha = \beta \approx 0.28$) podría revertir la conclusión. En políticas públicas, esto justifica:

1. Continuar el programa dado el efecto positivo y E-value aceptable
2. Invertir en mejor medición para reducir confusión residual
3. Monitorear heterogeneidad regional para ajustar focalización

11.8 Conclusiones y Recomendaciones para la Práctica

La inferencia causal en contextos complejos y con datos limitados requiere un cambio de paradigma: de la búsqueda de precisión puntual a la gestión transparente de incertidumbre. Recomendaciones clave:

11.8.1 Para investigadores en contextos del Sur Global

1. **Transparencia radical:** Documentar explícitamente todas las limitaciones de datos, violaciones de supuestos, y adaptaciones metodológicas.
2. **Análisis de sensibilidad múltiple:** Reportar siempre:
 - E-value para el efecto principal
 - ICE Stress Test o análisis de Rosenbaum
 - Bounds de identificación parcial (Manski)
 - Resultados bajo diferentes especificaciones y métodos
1. **Validación rigurosa:** Implementar tests placebo, falsificaciones, y validación cruzada incluso (especialmente) cuando la muestra es pequeña.
2. **Comunicación honesta:** Presentar intervalos de confianza en lugar de estimaciones puntuales, y clasificar la robustez usando escalas como la propuesta en este capítulo.

11.8.2 Para tomadores de decisión

1. **Exigir robustez, no precisión:** Un intervalo de confianza amplio pero honesto es preferible a una estimación precisa pero frágil.
2. **Entender métricas de incertidumbre:** Familiarizarse con E-values, ICE Gamma, y clasificaciones de robustez para interpretar evidencia causal.
3. **Invertir en mejor datos:** La escasez de datos es un problema estructural que requiere inversión sostenida en sistemas de monitoreo y evaluación.
4. **Considerar heterogeneidad:** Preguntar no solo ¿funciona? sino ¿para quién funciona y bajo qué condiciones?''

11.8.3 Integración con el Pipeline Unificado (Capítulo 12)

Las estrategias presentadas en este capítulo se integran naturalmente en el Pipeline Unificado de Inferencia Causal:

- **Fase 1 (Descubrimiento):** Validar grafos causales con conocimiento de dominio cuando los datos son limitados.
- **Fase 2 (Identificación):** Considerar instrumentos naturales o diseños de regresión discontinua cuando el overlap es deficiente, y evaluar sensibilidad a violaciones de supuestos.
- **Fase 3 (Estimación):** Aplicar los métodos adaptativos descritos en este capítulo, con regularización fuerte y validación cruzada conservadora.
- **Fase 4 (Validación):** Implementar batería completa de tests: placebo, falsificación, ICE Stress Test, E-value.
- **Fase 5 (Decisión):** Incorporar clasificación de robustez y heterogeneidad contextual en las recomendaciones de política.

La robustez no es un complemento opcional a la estimación: es la tercera etapa del pipeline inferencial, formalizada en el Capítulo 12 como el operador $\Phi = (\mathcal{I}, \mathcal{E}, \mathcal{V})$.

11.9 Cierre del capítulo

Sensibilidad y placebos convierten una estimación en un argumento. E-values y cotas de Rosenbaum no “prueban” causalidad; cuantifican cuánta confusión no medida haría colapsar la conclusión — el mismo criterio, adaptado, con el que este bloque completo debe leerse.

Otras referencias clave de este capítulo: (VanderWeele & Ding, 2017), (Cinelli & Hazlett, 2020), (Imbens & Rubin, 2015), (Pearl, 2009).

11.9 Referencias

- Cinelli, C., & Hazlett, C. (2020). Making Sense of Sensitivity: Extending Omitted Variable Bias. *Journal of the Royal Statistical Society: Series B*, 82(1), 39-67.
- Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- Manski, C. F. (1990). Nonparametric Bounds on Treatment Effects. *American Economic Review, Papers and Proceedings*, 80(2), 319-323.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Rosenbaum, P. R. (2002). *Observational Studies* (2.^a ed.). Springer.

VanderWeele, T. J., & Ding, P. (2017). Sensitivity Analysis in Observational Research: Introducing the E-Value. *Annals of Internal Medicine*, 167(4), 268-274.

CAPÍTULO 12

Guía Práctica de Selección de Métodos — Síntesis del Bloque I

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque I · Semilla 42

Notebook (pack): notebooks/Bloque_I/notebooks/12_guia_practica_seleccion_metodos_sintesis.ipynb

Jupyter Book: jupyter_book/content/bloque_01_fundamentacion/12_seleccion_metodos.ipynb

12.1 Introducción

A lo largo de los once capítulos anteriores, hemos recorrido un camino que va desde el problema fundamental de la inferencia causal —la imposibilidad de observar a una misma unidad bajo tratamiento y control simultáneamente— hasta un conjunto de diez estrategias metodológicas que permiten abordar esta limitación. Hemos visto ensayos controlados aleatorizados, métodos de emparejamiento, ponderación por probabilidad inversa, variables instrumentales, diseños de regresión discontinua, diferencias en diferencias, control sintético, mediación causal y análisis de sensibilidad.

Llegados a este punto, el estudiante podría sentir que tiene muchas herramientas en sus manos, pero no necesariamente saber cuál usar en cada situación. Ese es exactamente el propósito de este capítulo de cierre.

Los métodos que hemos estudiado no son técnicas intercambiables. Cada uno responde a un tipo específico de problema, depende de supuestos distintos, y produce estimaciones con interpretaciones diferentes. Usar el método equivocado no es neutral: puede generar estimaciones sesgadas, conclusiones erróneas y, en el contexto de políticas públicas, decisiones que afectan negativamente la vida de las personas.

Este capítulo ofrece una guía práctica para la selección de métodos. No se trata de un recetario automático, sino de un marco de reflexión que integra tres elementos: la naturaleza de la pregunta de investigación, la estructura de los datos disponibles, y los supuestos que estamos dispuestos a defender ante nuestros pares académicos y ante la sociedad.

12.2 El Árbol de Decisión Metodológico

La mejor manera de seleccionar un método de inferencia causal es avanzar por etapas, eliminando opciones a medida que la naturaleza de nuestros datos y el contexto de la intervención nos imponen restricciones. El siguiente árbol de decisión resume este proceso.

Paso 1: ¿Es posible asignar el tratamiento de forma aleatoria?

Si la respuesta es afirmativa, nos encontramos ante el estándar de oro de la inferencia causal. Un ensayo controlado aleatorizado (RCT) elimina, por construcción, el sesgo de selección. No requiere modelar la asignación al tratamiento. Sus resultados son los más fáciles de defender. Sin embargo, en contextos

de políticas públicas (programas de transferencias, reformas educativas, intervenciones sanitarias), la aleatorización no siempre es viable por razones éticas, políticas o logísticas.

- Si **sí** se puede aleatorizar → **RCT** (Capítulo 2).
- Si **no** se puede aleatorizar → pasar al Paso 2.

Paso 2: ¿Confiamos en que hemos medido todas las variables relevantes que determinan la asignación al tratamiento?

Esta es la pregunta más difícil y honesta que un investigador debe hacerse. Si estamos dispuestos a defender que, una vez que controlamos por un conjunto de variables observables (ingreso, educación, ubicación geográfica, etc.), el tratamiento se asigna “como si fuera aleatorio”, entonces podemos usar métodos de selección sobre observables.

- Si **sí** confiamos en que no hay variables omitidas importantes → **Matching** (Capítulo 3) o **IPW/AIPW** (Capítulo 4).
- Si **no** estamos seguros y sospechamos que existen factores no observados influyendo → pasar al Paso 3.

Paso 3: ¿Existe una variable externa (instrumento) que genere variación en el tratamiento de manera “como si fuera aleatoria”, pero que no afecte el resultado directamente?

Cuando sospechamos que factores como la motivación, la habilidad innata o las redes sociales influyen tanto en quién recibe el tratamiento como en el resultado, necesitamos una fuente externa de variación. Una variable instrumental es una “palanca” que mueve el tratamiento sin estar correlacionada con los factores no observados.

- Si **sí** existe un instrumento creíble → **Variables Instrumentales / LATE** (Capítulos 5 y 6).
- Si **no** existe tal instrumento → pasar al Paso 4.

Paso 4: ¿La asignación al tratamiento está determinada por un umbral o punto de corte en una variable continua?

Muchas políticas públicas utilizan reglas explícitas: un puntaje mínimo para una beca, una edad límite para un beneficio, un índice de pobreza para un programa social. Cuando estas reglas se aplican de manera consistente, las unidades justo por encima y justo por debajo del umbral son comparables, y cualquier diferencia en el resultado puede atribuirse al tratamiento.

- Si **sí** existe un umbral claro y la regla se respeta → **Regresión Discontinua (RDD)** (Capítulo 7).
- Si **no** existe tal umbral → pasar al Paso 5.

Paso 5: ¿Contamos con datos de panel y existe un grupo de unidades que nunca recibe el tratamiento?

Cuando observamos a las mismas unidades a lo largo del tiempo y algunas reciben tratamiento en un momento determinado mientras otras no, podemos comparar la evolución de ambos grupos. La clave es asumir que, en ausencia del tratamiento, ambos grupos habrían seguido la misma tendencia.

- Si **sí** hay múltiples unidades tratadas y no tratadas con datos antes y después → **Diferencias en Diferencias (DiD)** (Capítulo 8).
- Si hay una **sola unidad tratada** pero varias unidades de control → **Control Sintético** (Capítulo 9).
- Si **no** contamos con datos de panel → considerar **identificación parcial y análisis de sensibilidad** (Capítulo 11).

Paso 6: ¿El interés está en entender a través de qué mecanismo opera el tratamiento?

Más allá de estimar si un programa funciona, muchas veces queremos saber por qué funciona. ¿El efecto de una transferencia monetaria opera a través del aumento del ingreso disponible o a través de la exigencia de controles médicos? Para este tipo de preguntas necesitamos análisis de mediación.

- → **Mediación Causal** (Capítulo 10), siempre que se cumplan supuestos adicionales sobre la secuencia de variables.

Este árbol de decisión no es un algoritmo inflexible, sino una guía. En la práctica, la investigación rigurosa suele combinar múltiples métodos y someter los resultados a diversas pruebas de robustez.

12.3 Tabla Comparativa de Métodos

La siguiente tabla sintetiza los aspectos más relevantes de cada método del Bloque I, de modo que el estudiante pueda compararlos rápidamente.

Método	¿Cuándo usarlo?	Supuestos principales	Ventajas	Limitaciones
RCT	Cuando es posible asignar aleatoriamente el tratamiento	Aleatorización efectiva; SUTVA (sin interferencia entre unidades)	Estándar de oro; resultados creíbles y fáciles de comunicar	Costoso; problemas éticos; validez externa limitada
Matching / IPW	Cuando se confía en haber medido todas las variables de confusión relevantes	CIA (independencia condicional); Soporte común (overlap)	Intuitivo; fácil de implementar; flexible con muchas covariables	No resuelve confusión no observada; sensible a propensity scores extremos
AIPW (Doble Robusto)	Mismo contexto que Matching/IPW, pero se quiere protección adicional contra errores de especificación	CIA; Soporte común; al menos un modelo correctamente especificado	Dos oportunidades de acierto; más robusto que IPW o regresión por separado	Mayor complejidad computacional; requiere más cuidado en implementación
Variables Instrumentales (IV / LA-TE)	Cuando hay confundidores no observados y se cuenta con un instrumento creíble	Relevancia (Z correlaciona con T); Exclusión (Z afecta Y solo vía T); Monotonicidad	Resuelve endogeneidad; marco teórico sólido (LATE)	Instrumento válido difícil de encontrar; estima efecto local (LATE), no ATE poblacional; instrumentos débiles generan inestabilidad
Regresión Discontinua (RDD)	Cuando la asignación se basa en un umbral claro en una variable continua	Continuidad de la función de regresión; No manipulación del umbral	Credibilidad alta (cuasi-experimento); supuestos relativamente débiles; verificable	Estima efecto solo en el umbral; requiere muchos datos cerca del corte; sensible a la elección del ancho de banda
Diferencias en Diferencias (DiD)	Cuando hay datos de panel con grupos tratados y no tratados, antes y después de la intervención	Tendencias paralelas en ausencia de tratamiento; Sin efectos spillover entre grupos	Fácil de entender y comunicar; ampliamente usado en políticas públicas	Supuesto de tendencias paralelas no testeable directamente; sesgo en adopción escalonada
Control Sintético (SynC)	Cuando hay una sola unidad tratada y varias unidades de	Modelo de factores latentes; Buen ajuste pre-intervención	Útil para estudios de caso único (países, regiones); construye contrafactual explí-	Requiere período pre-intervención largo; sensible a la calidad del <i>donor</i>

	control con datos de panel largos		cito; no extrapola fuera del soporte	<i>pool</i> ; inferencia ba- sada en placebos
Mediación Causal	Cuando se quiere descomponer el efecto total en sus mecanismos (directo vs. indirecto)	Ignorabilidad secuencial; Independencia <i>cross-world</i> (no testeable)	Responde preguntas de mecanismos (“¿por qué funciona?”); marco contra-factual coherente	Supuestos muy exigentes; difícil de defender ante audiencias escépticas; requiere mediador bien medido
Análisis de Sensibilidad	Siempre, pero especialmente cuando los supuestos de identificación son debatibles	Modelo paramétrico de confusión no observada	Cuantifica robustez; herramienta de honestidad intelectual	No “prueba” nada; sensible a la especificación del modelo de sensibilidad

Esta tabla no debe leerse como una clasificación de “mejor” a “peor”. Cada método es adecuado para contextos distintos. Lo importante es que el investigador sea capaz de explicar por qué el método elegido es apropiado para su problema específico.

12.4 Ejemplos Aplicados

A continuación presentamos ejemplos breves, basados en contextos realistas del Perú y América Latina, que ilustran cuándo y cómo se aplica cada método.

RCT – Evaluación de un programa de capacitación laboral. Imaginemos que el Ministerio de Trabajo del Perú quiere evaluar el impacto de un curso de capacitación en habilidades digitales para jóvenes de Lima. Se inscriben 2,000 jóvenes. De ellos, 1,000 son seleccionados aleatoriamente para recibir la capacitación y 1,000 conforman el grupo de control. Se comparan sus ingresos laborales seis meses después. La aleatorización garantiza que cualquier diferencia en ingresos entre grupos se deba al programa y no a características previas de los jóvenes.

Matching / IPW – Programa “Juntos” en zonas rurales. El programa de transferencias condicionadas “Juntos” entrega incentivos económicos a hogares en pobreza extrema, condicionados a la asistencia escolar y controles de salud de los niños. Dado que el programa no es aleatorio (se focaliza en hogares pobres), no podemos comparar directamente beneficiarios y no beneficiarios. Usando matching por propensity score, emparejamos a cada hogar beneficiario con un hogar no beneficiario que tenga características similares (ingreso, educación de la madre, acceso a agua potable, etc.). La diferencia en resultados entre estos hogares emparejados nos da una estimación del efecto del programa.

Variables Instrumentales – Retorno de la educación en zonas rurales. Supongamos que queremos estimar el efecto de un año adicional de educación sobre los ingresos en zonas rurales del Perú. El problema es que las personas que deciden estudiar más años pueden tener mayor habilidad o motivación, factores no observados que también afectan sus ingresos. Como instrumento, podemos usar la distancia a la escuela secundaria más cercana. La distancia afecta la decisión de estudiar (relevancia), pero no debería afectar los ingresos directamente, una vez que controlamos por educación (exclusión). El estimador IV nos dará el efecto de la educación para aquellas personas cuya decisión de estudiar fue influenciada por la distancia (los “compliers”).

RDD – Beca 18 para educación superior. El programa “Beca 18” del PRONABEC otorga becas universitarias a estudiantes de alto rendimiento académico y bajos recursos. El puntaje de un examen

de admisión determina quién recibe la beca: los que obtienen 600 puntos o más son becados; los que obtienen menos, no. Comparando a los estudiantes justo por encima del umbral (digamos, 601 puntos) con aquellos justo por debajo (599 puntos), podemos estimar el efecto de la beca sobre su desempeño universitario o ingresos futuros, asumiendo que los estudiantes a ambos lados del corte son similares en todos los demás aspectos.

DiD – Expansión de “Pensión 65”. El programa “Pensión 65” otorga una transferencia mensual a adultos mayores en pobreza extrema. Se implementó primero en regiones como Huancavelica y Ayacucho en 2012, y se expandió gradualmente a todo el país. Podemos comparar la evolución del consumo en Huancavelica (tratada) con la evolución en regiones que aún no recibían el programa (control), antes y después de 2012. La diferencia entre estas dos diferencias (cambio en tratados menos cambio en controles) nos da el efecto del programa, asumiendo que ambas regiones habrían seguido trayectorias similares sin la intervención.

Control Sintético – Evaluación de la reforma del tabaco en California. En 1988, California implementó un impuesto estatal al tabaco muy superior al de otros estados. Para evaluar su efecto sobre el consumo de tabaco, no hay un control obvio (California es una unidad única). El método de Control Sintético construye un “California sintético” como una combinación ponderada de otros estados que replica la evolución del consumo de tabaco en California antes de la reforma. La diferencia entre el consumo real de California y el de su versión sintética después de 1988 es el efecto estimado de la política. Este método es particularmente útil para evaluar reformas a nivel de país o región en América Latina.

Mediación Causal – ¿Cómo opera el efecto de “Juntos” sobre la nutrición infantil? Sabemos que “Juntos” mejora la nutrición infantil. Pero, ¿es porque las transferencias alivian la restricción presupuestaria y permiten comprar más alimentos (efecto directo), o porque el programa exige controles de salud mensuales que mejoran las prácticas de cuidado infantil (efecto indirecto a través del mediador “visitas al centro de salud”)? El análisis de mediación permite descomponer el efecto total en estas dos vías, ayudando a diseñar intervenciones más efectivas y focalizadas.

12.5 Recomendaciones Prácticas

La experiencia en la enseñanza y aplicación de estos métodos nos permite ofrecer las siguientes recomendaciones concretas.

12.5.1 Sobre la elección del método

No existe un método “superior” en abstracto. El método adecuado es aquel cuyos supuestos son más plausibles dados los datos y el contexto de la intervención. La recomendación principal es: empiece siempre por el método más simple cuyos supuestos pueda defender. Si puede hacer un RCT, hágalo. Si no puede aleatorizar pero confía en haber medido las variables de confusión relevantes, use matching o IPW. A medida que los supuestos se vuelven más difíciles de sostener, los métodos se vuelven más complejos y sus estimaciones más locales o condicionales.

12.5.2 Sobre la defensa de los supuestos

La credibilidad de un estudio causal no depende de la sofisticación del método, sino de la plausibilidad de sus supuestos. Antes de publicar o presentar sus resultados, pregúntese:

- ¿Puedo explicarle a un colega escéptico por qué el supuesto de independencia condicional se cumple en mi estudio?
- ¿Puedo justificar por qué el instrumento que uso satisface la restricción de exclusión?
- ¿He probado la robustez de mis resultados variando el ancho de banda en un RDD?
- ¿He reportado el análisis de sensibilidad (Rosenbaum Γ^* o E-Value)?

Un estudio acompañado de pruebas de robustez y una discusión honesta de limitaciones vale más que un estudio con un método complejo y supuestos no examinados.

12.5.3 Sobre la combinación de métodos

En la investigación aplicada de calidad, es cada vez más común reportar múltiples estimaciones usando diferentes métodos. Si los resultados son consistentes entre métodos, la confianza en las conclusiones aumenta. Si divergen, el investigador debe explorar por qué ocurre esa divergencia, lo que suele revelar aspectos interesantes sobre la naturaleza del problema.

12.5.4 Sobre el contexto peruano y latinoamericano

Los métodos de inferencia causal fueron desarrollados principalmente en países con sistemas de datos robustos y capacidad institucional significativa. En contextos como el peruano, es necesario adaptarlos considerando:

- **Muestras pequeñas:** Muchas evaluaciones de programas subnacionales tienen tamaños muestrales reducidos. En estos casos, los errores estándar serán grandes y los intervalos de confianza amplios. Sea honesto al reportar esta incertidumbre y evite conclusiones categóricas.
- **Datos administrativos incompletos:** Es frecuente que las bases de datos tengan valores perdidos, errores de medición o coberturas parciales. Documente estos problemas y, cuando sea posible, use métodos robustos a datos faltantes.
- **Heterogeneidad geográfica y cultural:** Los efectos promedios pueden ocultar realidades muy distintas entre la costa, la sierra y la selva, o entre zonas urbanas y rurales. Siempre que el tamaño muestral lo permita, explore efectos heterogéneos.
- **Viabilidad política:** Muchos métodos requieren condiciones ideales (aleatorización, umbrales respetados, instrumentos válidos) que pueden no estar disponibles. No fuerce los datos a encajar en un método; mejor adapte el método a la realidad de los datos.

12.5.5 Sobre la transparencia y reproducibilidad

Un estudio causal es, ante todo, un ejercicio de transparencia. Reporte claramente:

- La pregunta causal que motiva el análisis.
- Los supuestos de identificación y por qué son plausibles.
- El método de estimación y sus detalles de implementación.
- Todas las pruebas de robustez realizadas, incluidas aquellas que no respaldan sus hallazgos.
- El código y los datos, en la medida de lo posible.

La inferencia causal no es un truco de magia estadística. Es un proceso disciplinado de construcción de argumentos basados en datos, supuestos explícitos y razonamiento contrafactual.

12.6 Cierre del Bloque I y Transición al Bloque II

Al término de este primer bloque, el estudiante ha adquirido un conjunto sólido de herramientas para responder una pregunta fundamental: ¿cuál es el efecto promedio de un tratamiento sobre un resultado? Hemos aprendido a hacer esta pregunta bajo distintas condiciones –con y sin aleatorización, con y sin confusores observables y no observables, con datos transversales y de panel, con unidades tratadas únicas y múltiples.

Pero esta pregunta, siendo central, es solo el comienzo.

El Nivel 1 de la jerarquía GCE, que hemos explorado en estos doce capítulos, comprime toda la riqueza de las distribuciones contrafactuales en un solo número: la diferencia de medias. Este resumen es útil, pero también puede ser engañoso. Como vimos en el Capítulo 1 con la Paradoja del Efecto Cero, dos distribuciones pueden ser radicalmente diferentes y tener el mismo promedio. Una intervención puede no cambiar la media pero sí aumentar la desigualdad (efecto en la varianza), o puede beneficiar a unos y perjudicar a otros (efectos heterogéneos que se cancelan en el promedio).

El Bloque II, que comenzaremos a continuación, nos invita a subir un nivel en la jerarquía: ya no preguntaremos solo “¿cambió el promedio?”, sino ¿cambió la distribución completa? Para ello, necesitaremos un lenguaje más rico y preciso para describir las relaciones causales. Ese lenguaje es el de los Modelos Causales Estructurales (SCM) y los Grafos Acíclicos Dirigidos (DAGs).

En el Bloque II, en lugar de depender exclusivamente de supuestos estadísticos como la independencia condicional, podremos dibujar explícitamente nuestras hipótesis sobre cómo se relacionan las variables. Este enfoque gráfico nos permitirá identificar efectos causales en situaciones que los métodos del Bloque I no pueden resolver, como la identificación a través de un mediador (criterio frontdoor) o el análisis formal de colisionadores.

La transición entre estos dos bloques representa un cambio de mirada: de la estimación a la representación, de preguntarnos “¿cómo obtengo un número?” a preguntarnos “¿qué estructura de relaciones estoy asumiendo?”. Ambos niveles son necesarios. Los métodos del Bloque I son herramientas poderosas de estimación; los del Bloque II son herramientas de clarificación conceptual y estructural.

Como investigadores aplicados, nuestro objetivo no es solo producir estimaciones, sino construir argumentos causales rigurosos, defendibles y, sobre todo, útiles para la toma de decisiones. Los próximos capítulos nos darán el vocabulario y la sintaxis para hacerlo con mayor precisión.

Lecturas complementarias para el cierre del Bloque I

- *Mostly Harmless Econometrics* (Angrist & Pischke, 2009, Capítulo 1: una introducción accesible a la filosofía del diseño de investigación).
- *Causal Inference: The Mixtape* (Cunningham, 2021, Capítulo 1 y Conclusiones: una guía práctica con énfasis en aplicaciones).
- *The Effect: An Introduction to Research Design and Causality* (Huntington-Klein, 2022, Capítulo 20: discute el proceso de selección de métodos desde una perspectiva aplicada).

12.6 Referencias

Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.

Cunningham, S. (2021). *Causal Inference: The Mixtape*. Yale University Press.

Huntington-Klein, N. (2022). *The Effect: An Introduction to Research Design and Causality*. CRC Press.

CAPÍTULO 13

Modelos Causales Estructurales (SCM): La Anatomía del Mecanismo

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque II · Semilla 42

Notebook (pack): notebooks/Bloque_II/notebooks/13_modelos_causales_estructurales_scm_anatomia_mecanismo.ipynb

Jupyter Book: jupyter_book/content/bloque_02_formalizacion/13_scm_anatomia_mecanismo.ipynb

El Bloque I nos enseñó a identificar efectos causales explotando variación exógena: experimentos, umbrales, tendencias temporales y variables instrumentales. Todos esos métodos comparten una virtud y una limitación: *identifican* efectos sin necesidad de especificar *cómo* opera el mecanismo causal. El diseño hace el trabajo de identificación.

El Bloque II adopta una perspectiva complementaria, originada en el trabajo seminal de Pearl (2009): construir modelos que representen explícitamente el mecanismo generativo del mundo. La herramienta central es el **Modelo Causal Estructural** (SCM, por *Structural Causal Model*). Mientras que el marco de resultados potenciales de Rubin (Rubin, 1974) trata los contrafactuales como objetos primitivos, el SCM los deriva como consecuencias de un sistema de ecuaciones que codifica nuestra teoría sustantiva sobre el mundo. Esta diferencia no es meramente estética: el SCM nos permite responder preguntas que el marco de Rubin deja sin respuesta, como la identificación cuando los confusores no son observables (criterio frontdoor), la descomposición precisa de efectos de mediación, o el transporte de conclusiones causales entre poblaciones.

En este capítulo construimos la anatomía del SCM desde sus componentes fundamentales. Comenzamos con la asimetría causal que distingue una ecuación estructural de una algebraica, definimos formalmente cada elemento de la tupla $\mathcal{M} = \langle U, V, F, P(U) \rangle$, y culminamos con dos resultados fundacionales: la Condición de Markov Causal y la equivalencia formal entre los marcos de Rubin y Pearl.

13.1 La Asimetría Causal: El Símbolo $:=$

La diferencia entre una *ecuación algebraica* y una *ecuación estructural* es la diferencia entre describir una regularidad asociativa y especificar un mecanismo generativo. Considere la relación entre inversión educativa X y rendimiento escolar Y :

$$Y = \alpha + \beta X + U. \quad (13.1.1)$$

En álgebra, esta ecuación puede despejarse en cualquier dirección: $X = \frac{Y - \alpha - U}{\beta}$. En causalidad esto no es válido. La ecuación estructural se escribe con el símbolo de asignación $:=$ para enfatizar la dirección:

$$Y := \alpha + \beta X + U. \quad (13.1.2)$$

El significado es radicalmente distinto: X *causa* Y , no al revés. Si intervenimos sobre X (cambiando la inversión educativa), Y cambia de acuerdo con el mecanismo $\alpha + \beta X + U$. Pero si intervenimos sobre Y (manipulando artificialmente el rendimiento), X no se altera. Esta asimetría es la esencia de la causalidad y no puede ser capturada por el lenguaje de la probabilidad condicional estándar.

Definición 13.1 (Función estructural (f_i))

Para cada variable endógena $V_i \in \mathbf{V}$, la *función estructural* f_i es el mecanismo que determina su valor:

$$V_i := f_i(\text{pa}(V_i), U_i), \quad (13.1.3)$$

donde $\text{pa}(V_i) \subseteq \mathbf{V} \setminus \{V_i\}$ son los *padres* (causas directas) de V_i en el modelo, y $U_i \in \mathbf{U}$ es el término de error o ruido exógeno específico de V_i . La notación $:=$ (asignación) es deliberada: indica que el valor de V_i es *determinado por* sus padres y su ruido, y no a la inversa.

Esta definición captura un aspecto crucial que escapa a la notación de regresión convencional. En una regresión $Y = \beta X + \epsilon$, el símbolo $=$ es algebraicamente simétrico; en una función estructural $Y := f_{Y(X, U_Y)}$, la asimetría es explícita e irrevocable. La diferencia es análoga a la que existe entre una fotografía (asociación) y un diagrama de flujo de un proceso industrial (mecanismo). En el programa *Juntos* del MIDIS (Perú), el rendimiento escolar de un niño depende causalmente del bono recibido por su hogar. Si las autoridades escolares inflaran artificialmente los puntajes, el bono no aumentaría retroactivamente. El mecanismo opera en una sola dirección.

13.2 Variables Exógenas y Endógenas

En cualquier sistema causal existen dos tipos de variables, distinguidas por si su valor es determinado dentro o fuera del modelo.

Definición 13.2 (Variables exógenas (U))

Las *variables exógenas* $\mathbf{U} = \{U_1, U_2, \dots, U_k\}$ son aquellas cuyos valores son determinados por factores externos al modelo. Su comportamiento está gobernado por una distribución conjunta $P(\mathbf{U})$ que el analista toma como dada. Cada U_i representa factores no modelados que influyen en una variable endógena específica V_i . En el contexto del Sur Global, las variables exógenas frecuentemente capturan: heterogeneidad no observada (motivación, talento, capital social), shocks idiosincráticos (enfermedad repentina, desastre natural), y factores históricos no medidos (herencia colonial, geografía, redes familiares).

Definición 13.3 (Variables endógenas (V))

Las *variables endógenas* $\mathbf{V} = \{V_1, V_2, \dots, V_n\}$ son aquellas cuyos valores son determinados por el modelo mediante las funciones estructurales. Para cada V_i , existe un mecanismo $V_i := f_{i(\text{pa}(V_i), U_i)}$ que establece su valor en función de otras variables endógenas (sus padres) y su ruido exógeno específico. Las variables endógenas son, al menos en principio, observables.

La distinción entre exógenas y endógenas no es ontológica sino epistemológica: refleja lo que el analista elige modelar y lo que elige dejar como primitivo externo. Un mismo factor (digamos, la motivación de un estudiante) puede ser endógeno en un modelo que incluya sus determinantes (educación de los padres, calidad escolar) o exógeno en un modelo más acotado. La decisión refleja el alcance de la teoría sustantiva disponible.

Ejemplo 13.1 (Exógenas en una política de transferencias)

En la evaluación del programa *Pensión 65* (Perú), la variable endógena principal es el consumo del hogar Y . Son variables endógenas también el estado de elegibilidad y la recepción efectiva de la transferencia. Las variables exógenas U_Y incluyen shocks climáticos que afectan la producción agrícola del hogar, enfermedades no anticipadas de sus miembros, y fluctuaciones en los precios locales de alimentos — factores que el programa no determina pero que afectan el resultado. La distribución $P(U)$ codifica nuestra incertidumbre sobre estos factores.

13.3 El Modelo Causal Estructural: Definición Formal

Con los elementos anteriores podemos ensamblar la definición completa del SCM, que constituye el objeto matemático central de todo el Bloque II.

Definición 13.4 (Modelo Causal Estructural (SCM))

Un *Modelo Causal Estructural* (SCM) es una tupla

$$\mathcal{M} = \langle U, V, F, P(U) \rangle, \quad (13.3.1)$$

donde:

- $U = \{U_1, U_2, \dots, U_k\}$ es un conjunto de *variables exógenas*, con distribución conjunta $P(U)$ que codifica toda la incertidumbre externa al modelo.
- $V = \{V_1, V_2, \dots, V_n\}$ es un conjunto de *variables endógenas*, cuyos valores son determinados internamente por el modelo.
- $F = \{f_1, f_2, \dots, f_n\}$ es un conjunto de *funciones estructurales*, donde para cada $V_i \in V$:

$$V_i := f_i(\text{pa}(V_i), U_i), \quad (13.3.2)$$
 con $\text{pa}(V_i) \subseteq V$ denotando los padres (causas directas) de V_i .
- $P(U)$ es una distribución de probabilidad sobre U que induce, junto con F , una distribución única sobre V .

La genealogía intelectual de esta definición merece ser explicitada. Wright (1921) introdujo los *diagramas de sendero* (*path diagrams*) en genética de poblaciones, representando sistemas de ecuaciones lineales con grafos dirigidos. Haavelmo (1943) formalizó las implicaciones estadísticas de sistemas de ecuaciones simultáneas en econometría, estableciendo la distinción crucial entre forma estructural y forma reducida, y demostrando que los parámetros estructurales son invariantes ante intervenciones — una propiedad que los coeficientes de regresión no poseen. Pearl (2009) unifica y generaliza ambas tradiciones: la estructura gráfica de Wright porta ahora contenido semántico preciso sobre intervenciones en el sentido de Haavelmo, y se añade una capa contrafactual explícita que ninguno de sus predecesores había formalizado completamente.

Ejemplo 13.2 (SCM para una política educativa)

Considere la evaluación del programa *Juntos* (transferencias condicionadas del MIDIS, Perú). Sean:

- L : nivel educativo de la madre (variable de contexto, determinada).
- T : monto del bono recibido (tratamiento).
- Y : rendimiento escolar del niño (resultado).

El SCM se especifica como:

$$L := U_L \quad T := f_{T(L, U_T)} \quad Y := f_{Y(T, L, U_Y)} \quad (13.3.3)$$

donde U_L, U_T, U_Y son ruidos exógenos mutuamente independientes. La variable L es un *confusor*: afecta tanto la asignación del bono (hogares con madres más educadas pueden tener diferente elegibilidad) como el resultado (madres más educadas apoyan más el estudio). La distribución conjunta observable factoriza, por la Condición de Markov, como:

$$P(L, T, Y) = P(L) \cdot P(T | L) \cdot P(Y | T, L). \quad (13.3.4)$$

13.3.1 El Grafo Acíclico Dirigido (DAG) Asociado

Todo SCM induce un grafo cuyas aristas codifican las dependencias causales directas entre variables endógenas.

Definición 13.5 (Grafo Acíclico Dirigido (DAG) asociado)

Dado un SCM $\mathcal{M} = \langle U, V, F, P(U) \rangle$, su DAG asociado $\mathcal{G} = (V, \mathcal{E})$ tiene como vértices las variables endógenas V , y existe una arista dirigida $V_j \rightarrow V_i$ en $\mathcal{E}$ si y solo si $V_j \in \text{pa}(V_i)$, es decir, si V_j aparece como argumento en la función estructural f_i . El grafo es acíclico por construcción: no existen secuencias de aristas que formen un ciclo dirigido, lo que garantiza que el sistema de ecuaciones estructurales tenga una solución única para cada realización de U .

El DAG del Ejemplo 190 muestra a L como confusor (aristas $L \rightarrow T$ y $L \rightarrow Y$) y a T como causa directa de Y . Las variables exógenas U_i se representan con aristas discontinuas para enfatizar que son fuentes externas de variación. Notemos que la aciclicidad del grafo refleja una suposición sustantiva: el sistema no contiene ciclos de retroalimentación instantánea. En el ejemplo, el rendimiento escolar Y no afecta retroactivamente al bono T ni a la educación materna L en el mismo período.

13.4 El Operador $\text{do}(\cdot)$: Intervención como Cirugía del Modelo

La contribución más distintiva del marco SCM es la formalización precisa de la diferencia entre *observar* y *hacer*. Esta distinción, que subyace a toda inferencia causal, se operacionaliza mediante el operador $\text{do}(\cdot)$.

Definición 13.6 (Operador $\text{do}(\cdot)$)

Para un conjunto de variables $X \subseteq V$ y valores x en su dominio, la expresión $P_{\text{do}(X=x)}(V)$ denota la *distribución post-intervencional*: la distribución que resultaría si, mediante una intervención externa, forzáramos X a tomar el valor x , independientemente de sus causas naturales. Esta distribución es, en general, diferente de la distribución condicional observacional $P(V | X = x)$. La diferencia entre ambas es precisamente el sesgo de confusión.

La distinción se ilustra con el contraste entre dos procedimientos:

- **Observar** $T = t$: Condicionamos en el subconjunto de unidades que recibieron $T = t$. El confusor L sigue operando; las unidades seleccionadas difieren sistemáticamente de la población en características basales.
- **Hacer** $\text{do}(T = t)$: Intervenimos forzando toda unidad a recibir $T = t$, independientemente de L . Es el análogo formal de un experimento aleatorio perfecto.

Definición 13.7 (Submodelo mutilado)

Dado un SCM $\mathcal{M}$ y un conjunto de variables $\mathbf{X} \subseteq \mathbf{V}$ con valores $\mathbf{x}$, el *submodelo mutilado* $\mathcal{M}_{\text{do}(\mathbf{X}=\mathbf{x})}$ se obtiene mediante dos operaciones:

1. **Reemplazo de ecuaciones:** Para cada $X_i \in \mathbf{X}$, la función estructural $X_i := f_{i(\text{pa}(X_i), U_i)}$ se reemplaza por la asignación constante $X_i := x_i$.
2. **Mutilación del grafo:** En el DAG $\mathcal{G}$, se eliminan todas las aristas entrantes a cada $X_i \in \mathbf{X}$. El grafo resultante se denota $\mathcal{G}_{\overline{\mathbf{X}}}$.

La distribución post-intervencional es la distribución inducida por $\mathcal{M}_{\text{do}(\mathbf{X}=\mathbf{x})}$ sobre las variables restantes.

La noción de mutilación es quirúrgica y precisa. Al intervenir $\text{do}(T = t)$ en el Ejemplo 190, la arista $L \rightarrow T$ es eliminada. L ya no determina T ; el tratamiento se asigna externamente. La distribución post-intervencional resultante es:

$$P_{\text{do}(T=t)}(Y) = \sum_{\ell} P(Y \mid T = t, L = \ell) P(L = \ell). \quad (13.4.1)$$

Esta es la *fórmula de ajuste por la puerta trasera* que estudiaremos sistemáticamente en el Capítulo 15. Por ahora, notemos que la expresión a la derecha involucra únicamente cantidades observacionales: podemos estimar $P_{\text{do}(T=t)}(Y)$ sin realizar el experimento, *siempre que* el conjunto $\{L\}$ bloquee adecuadamente los caminos de confusión.

Ejemplo 13.3 (Observar versus hacer: la paradoja del chocolate)

Países con mayor consumo per cápita de chocolate tienen, en promedio, más premios Nobel per cápita (Messerli, 2012). ¿Implica esto que forzar a la población peruana a consumir más chocolate aumentaría sus probabilidades de ganar un Nobel? La respuesta es no. El Producto Interno Bruto (PIB) es un confusor: determina tanto el consumo de chocolate (bien de lujo) como la inversión en investigación científica. Al *observar* países con alto consumo de chocolate, estamos seleccionando indirectamente países ricos. Al *hacer* $\text{do}(\text{Chocolate} = \text{alto})$, cortamos la arista $\text{PIB} \rightarrow \text{Chocolate}$: la intervención obliga a consumir chocolate sin alterar el PIB. El efecto causal es nulo: $P_{\{\text{do}(\text{Chocolate})\}}(\text{Nobel}) = P(\text{Nobel})$.

La brecha entre $P(\text{Nobel} \mid \text{Chocolate} = \text{alto})$ y $P_{\{\text{do}(\text{Chocolate} = \text{alto})\}}(\text{Nobel})$ es precisamente el sesgo de confusión que el SCM nos permite cuantificar y, bajo condiciones adecuadas, eliminar.

13.5 La Condición de Markov Causal

La estructura de dependencias codificada en el DAG tiene una contrapartida probabilística fundamental: la factorización de la distribución conjunta. Este resultado conecta la topología del grafo con las independencias condicionales en los datos.

Teorema 13.1 (Condición de Markov Causal)

Sea $\mathcal{M} = \langle \mathbf{U}, \mathbf{V}, \mathbf{F}, P(\mathbf{U}) \rangle$ un SCM con DAG acíclico $\mathcal{G}$, y supóngase que las variables exógenas $U_1, \dots, U_n$ son mutuamente independientes. Entonces la distribución conjunta de las variables endógenas factoriza según $\mathcal{G}$:

$$P(V_1, \dots, V_n) = \prod_{i=1}^n P(V_i \mid \text{pa}(V_i)). \quad (13.5.1)$$

La Condición de Markov Causal es el puente que conecta la especificación cualitativa del DAG con las distribuciones de probabilidad que podemos estimar desde los datos. Si un investigador propone el DAG $\mathcal{G}$ como representación del mecanismo causal, la distribución observada *debe* factorizar según $\mathcal{G}$; de lo contrario, el DAG está mal especificado. Esta implicación testeable constituye una de las pocas vías de validación empírica de los supuestos causales, y será explotada sistemáticamente en el Bloque III sobre descubrimiento estructural.

13.6 Equivalencia entre los Formalismos de Rubin y Pearl

Los dos lenguajes dominantes de la inferencia causal —resultados potenciales (Rubin, 1974) y modelos causales estructurales (Pearl, 2009)— son matemáticamente equivalentes bajo condiciones de regularidad. Explicitar esta equivalencia es crucial para que el estudiante transite fluidamente entre ambos marcos.

Teorema 13.2 (Equivalencia Rubin-Pearl)

Sea $\mathcal{M} = \langle \mathbf{U}, \mathbf{V}, \mathbf{F}, P(\mathbf{U}) \rangle$ un SCM, y sea $T \in \mathbf{V}$ una variable de tratamiento con valores en $\{0, 1\}$. Definase el resultado potencial de Rubin como:

$$Y(t) := Y_{\mathcal{M}_{\text{do}(T=t)}}, \quad (13.6.1)$$

es decir, el valor de Y en el submodelo mutilado donde se fuerza $\text{do}(T = t)$. Entonces, para toda unidad i y todo $t \in \{0, 1\}$:

1. $Y_{i(t)}$ está bien definido como variable aleatoria en el espacio de probabilidad inducido por $P(\mathbf{U})$.
2. $Y_i^{\{\text{obs}\}} = T_i Y_{i(1)} + (1 - T_i) Y_{i(0)}$ (consistencia).
3. $\mathbb{E}[Y(t)] = \mathbb{E}_{\text{do}(T=t)}[Y]$.

La equivalencia no implica que ambos marcos sean intercambiables en la práctica. El SCM especifica el mecanismo generativo f_Y que produce $Y(t)$; el marco de Rubin lo deja implícito como objeto primitivo. Para estimandos del Nivel 1 de la jerarquía GCE (ATE, ATT, LATE), ambos producen conclusiones idénticas. La ventaja del SCM emerge en niveles superiores y en problemas donde la estructura del mecanismo es necesaria: identificación mediante criterio frontdoor (Capítulo 16), descomposición de efectos de mediación (Capítulo 10), y transporte de conclusiones entre poblaciones (Bloque IV). El SCM no reemplaza a Rubin: lo subsume y lo extiende.

13.7 Supuestos Codificados en el SCM

Al especificar un SCM, el analista está realizando afirmaciones sustantivas sobre el mundo que conviene explicitar:

1. **Exclusión:** La ausencia de una arista $V_j \rightarrow V_i$ en el DAG afirma que V_j no tiene efecto causal directo sobre V_i , condicional en los demás padres de V_i . Equivalentemente, $V_j \notin \text{pa}(V_i)$.
2. **Aciclicidad:** No existen ciclos de retroalimentación. El sistema es estable o se analiza en equilibrio de corte transversal.
3. **Independencia de exógenas:** Los ruidos U_i son mutuamente independientes, lo que equivale a afirmar que no existen confusores no observados entre variables endógenas más allá de los modelados explícitamente (supuesto de suficiencia causal).
4. **Invariancia:** Cada función estructural f_i es un mecanismo autónomo que permanece invariante ante intervenciones sobre otras variables del sistema.

Cada arista ausente es un supuesto tan fuerte como cada arista presente. Dibujar un DAG no es un ejercicio decorativo: es una declaración de teoría causal que debe justificarse con conocimiento de dominio, diseño institucional o evidencia empírica auxiliar.

13.8 Síntesis del Capítulo

- Un **Modelo Causal Estructural** es una tupla $\mathcal{M} = \langle U, V, F, P(U) \rangle$ que especifica explícitamente los mecanismos generativos de cada variable endógena.
- Las **variables exógenas** U representan factores externos al modelo con distribución $P(U)$; las **variables endógenas** V son determinadas por las funciones estructurales F .
- Las **funciones estructurales** $V_i := f_{i(\text{pa}(V_i), U_i)}$ usan el símbolo de asignación $:=$ para codificar la asimetría causal: cambiar una causa altera el efecto, pero no a la inversa.
- El **DAG asociado** $\mathcal{G}$ tiene una arista $V_j \rightarrow V_i$ si y solo si V_j es padre de V_i en el SCM.
- El **operador** $\text{do}(\cdot)$ formaliza la intervención: $P_{\text{do}(T=t)}(Y)$ es la distribución post-intervencional en el **submodelo mutilado** $\mathcal{M}_{\text{do}(T=t)}$, donde se eliminan las aristas entrantes a T .
- La **Condición de Markov Causal** establece que, bajo independencia de los U_i , la distribución conjunta factoriza como $P(V) = \prod_i P(V_i | \text{pa}(V_i))$.
- Los formalismos de **Rubin y Pearl** son matemáticamente equivalentes: $Y(t) = Y_{\mathcal{M}_{\text{do}(T=t)}}$. El SCM añade la especificación explícita del mecanismo generativo.

El Capítulo 14 profundiza en la topología del DAG, presentando las tres estructuras fundamentales —cadenas, horquillas y colisionadores— que determinan el flujo de información y la d-separación, el concepto central para leer independencias condicionales directamente del grafo.

Otras referencias clave de este capítulo: (Peters et al., 2017).

13.8 Referencias

- Haavelmo, T. (1943). The Statistical Implications of a System of Simultaneous Equations. *Econometrica*, 11(1), 1-12.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of Causal Inference: Foundations and Learning Algorithms*. MIT Press.
- Rubin, D. B. (1974). Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies. *Journal of Educational Psychology*, 66(5), 688-701.
- Wright, S. (1921). Correlation and Causation. *Journal of Agricultural Research*, 20(7), 557-585.

CAPÍTULO 14

DAGs y Estructuras Fundamentales: El Flujo de Información

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque II · Semilla 42

Notebook (pack): notebooks/Bloque_II/notebooks/14_dags_estructuras_fundamentales_flujo_informacion.ipynb

Jupyter Book: jupyter_book/content/bloque_02_formalizacion/14_dags_flujo_informacion.ipynb

En el capítulo anterior construimos el Modelo Causal Estructural y establecimos que todo SCM induce un Grafo Acíclico Dirigido (DAG) cuyas aristas codifican dependencias causales directas. Ahora examinamos la topología de ese grafo: ¿qué caminos conectan sus nodos?, ¿por dónde fluye la información estadística?, ¿cuándo dos conjuntos de variables se vuelven dependientes o independientes entre sí?

La respuesta a estas preguntas descansa en tres estructuras elementales —la cadena, la horquilla y el colisionador— que se combinan para construir cualquier DAG, por complejo que sea. Reconocer estas estructuras y entender cómo responden al condicionamiento es la habilidad analítica más importante del analista causal que trabaja con grafos. A partir de estos tres bloques elementales construiremos el concepto de *d-separación*, el criterio gráfico que permite leer independencias condicionales directamente de la topología del DAG sin necesidad de álgebra probabilística. Culminaremos con el examen de los supuestos codificados en un DAG y la noción de fidelidad que garantiza que la lectura gráfica sea completa.

14.1 Los Tres Conectores Fundamentales

Todo camino en un DAG está compuesto por combinaciones de exactamente tres patrones elementales. Dado un nodo central B y dos nodos A, C conectados a él, solo existen tres configuraciones posibles. La conducta de cada una frente al condicionamiento determina completamente el flujo de información en el grafo.

14.1.1 Cadena (Pipe)

La cadena es la estructura de mediación más simple: una variable causa a otra, que a su vez causa a una tercera.

$$A \rightarrow B \rightarrow C$$

Figura 1: Cadena (Pipe): $A \rightarrow B \rightarrow C$

Definición 14.1 (Cadena)

La estructura $A \rightarrow B \rightarrow C$ se denomina *cadena* o *pipe*. La información fluye secuencialmente de A a C a través de B .

- **Sin condicionar en B :** A y C son dependientes: $A \not\perp\!\!\!\perp C$. La variación en A se transmite a C vía B .
- **Condicionando en B :** Se bloquea el flujo: $A \perp\!\!\!\perp C \mid B$. Conocido B , A no aporta información adicional sobre C .

En el contexto del programa *Juntos* (Perú), la secuencia Bono $\rightarrow$ Asistencia escolar $\rightarrow$ Rendimiento es una cadena. El bono aumenta la asistencia, y la asistencia mejora el rendimiento. Si condicionamos en la asistencia escolar, el bono y el rendimiento se vuelven independientes: para niños con el mismo nivel de asistencia, el monto del bono no predice adicionalmente el rendimiento. Esta es la lógica detrás de la pregunta: ¿el efecto del bono opera *exclusivamente* a través de la asistencia?

14.1.2 Horquilla (Fork / Confounder)

La horquilla es la estructura de confusión: una causa común afecta a dos variables que, de otro modo, no tendrían relación causal entre sí.

$$B \leftarrow A \rightarrow C$$

Figura 2: Horquilla (Fork): $B \leftarrow A \rightarrow C$

Definición 14.2 (Horquilla (Fork))

La estructura $B \leftarrow A \rightarrow C$ se denomina *horquilla*. A es la *causa común* o *confusor* de B y C .

- **Sin condicionar en A :** B y C son dependientes: $B \not\perp\!\!\!\perp C$. Exhiben correlación espuria aunque ninguna cause a la otra.
- **Condicionando en A :** Se bloquea la correlación espuria: $B \perp\!\!\!\perp C \mid A$. Conocida la causa común, las consecuencias son independientes.

En la evaluación de *Pensión 65*, el nivel socioeconómico A determina tanto la probabilidad de recibir la transferencia B como el consumo basal del hogar C . En datos observacionales, B y C aparecen correlacionados, pero esta correlación es espuria: no refleja un efecto causal de la transferencia sobre el consumo, sino la acción de la causa común. Condicionar en A (comparar hogares de similar nivel socioeconómico) elimina esta correlación espuria y aísla el efecto causal. Esta es precisamente la lógica del ajuste por confusores.

14.1.3 Colisionador (Collider)

El colisionador es la estructura más contraintuitiva y, por ello, la fuente más frecuente de errores en el análisis aplicado.

$$A \rightarrow B \leftarrow C$$

Figura 3: Colisionador (Collider): $A \rightarrow B \leftarrow C$

Definición 14.3 (Colisionador (Collider))

La estructura $A \rightarrow B \leftarrow C$ se denomina *colisionador*. Ambas flechas colisionan en B , que es consecuencia común de A y C .

- **Sin condicionar en B :** El camino está **bloqueado** por defecto: $A \perp\!\!\!\perp C$. Dos causas independientes de un mismo efecto no están correlacionadas en la población general.
- **Condicionando en B (o en cualquier descendiente de B):** El camino se **abre**: $A \neg \perp\!\!\!\perp C \mid B$. Se induce una asociación espuria entre las causas.

El comportamiento del colisionador es la inversión exacta de la cadena y la horquilla: mientras que en aquellas el condicionamiento *bloquea* el flujo de información, en el colisionador el condicionamiento lo *abre*. Esta inversión es la responsable de algunos de los sesgos más insidiosos en la práctica empírica, como veremos a continuación.

14.2 La Paradoja de Berkson: El Colisionador en Acción

El fenómeno por el cual condicionar en un colisionador induce asociación entre sus causas fue identificado por Berkson (1946) en el contexto de estudios hospitalarios, y constituye una de las advertencias más importantes para el analista aplicado.

Definición 14.4 (Paradoja de Berkson)

La *Paradoja de Berkson* es el fenómeno por el cual dos variables independientes en la población general se vuelven condicionalmente dependientes (y típicamente correlacionadas negativamente) cuando se condiciona en un colisionador común o en un descendiente de este. Es una manifestación del *sesgo de selección* inducido por el diseño muestral o por el control estadístico inapropiado.

Ejemplo 14.1 (Berkson en admisiones universitarias)

Considere el proceso de admisión a una universidad selectiva como la Universidad Nacional Mayor de San Marcos. Sean:

- H : habilidad académica del postulante (medida por examen de admisión).
- D : dedicación a actividades extracurriculares (deportes, voluntariado).
- A : admisión ($A = 1$ si es admitido).

El DAG es $H \rightarrow A \leftarrow D$: la admisión depende tanto de la habilidad académica como de la dedicación extracurricular (esta última valorada en entrevistas o puntajes complementarios).

En la población general de postulantes, H y D son independientes: hay estudiantes muy hábiles con poca dedicación extracurricular, estudiantes con mucha dedicación pero habilidad modesta, y todo el espectro intermedio. Sin embargo, si condicionamos en $A = 1$ (analizamos solo a los admitidos), observaremos una *correlación negativa* entre H y D . Entre los admitidos, un estudiante con baja habilidad académica debe compensar con alta dedicación extracurricular para haber sido admitido, y viceversa. Esta correlación negativa es completamente artificial: no refleja ninguna relación causal entre H y D , sino la restricción impuesta por el filtro de admisión.

Si un investigador inadvertido controlara por la variable de admisión en un estudio sobre los determinantes del rendimiento universitario, induciría una asociación espuria entre habilidad y dedicación que contaminaría todas las estimaciones subsecuentes.

Ejemplo 14.2 (Sesgo de selección en datos COVID-19)

Durante la pandemia de COVID-19 en el Perú (2020–2021), los datos de pacientes hospitalizados mostraban una correlación negativa entre diabetes e hipertensión como comorbilidades: los pacientes hospitalizados con diabetes tendían a tener menor prevalencia de hipertensión, y viceversa. Sin embargo, en la población general peruana, ambas condiciones están positivamente correlacionadas (comparten factores de riesgo como obesidad y edad). El DAG es Diabetes $\rightarrow$ Hospitalización $\leftarrow$ Hipertensión. La hospitalización actúa como colisionador: un paciente puede ser hospitalizado por COVID-19 grave debido a diabetes, a hipertensión, o a ambas. Al condicionar en hospitalización (la muestra observada), se induce la correlación negativa espuria. Los estudios basados exclusivamente en datos hospitalarios subestimaron sistemáticamente la asociación poblacional entre comorbilidades.

Este fenómeno aparece en tres contextos aplicados recurrentes: (1) cuando la muestra es seleccionada en función de un colisionador (*sesgo de selección muestral*); (2) cuando el analista ajusta estadísticamente por un colisionador o un descendiente suyo (*sesgo de control excesivo*); y (3) cuando se estratifica el análisis por categorías definidas por un colisionador (*sesgo de estratificación*). En los tres casos, la dirección del sesgo es impredecible y puede generar asociaciones de signo opuesto al verdadero.

14.3 Caminos y Flujo de Información

Con los tres conectores fundamentales definidos, podemos formalizar las nociones de camino y bloqueo que subyacen a toda la teoría de identificación gráfica.

Definición 14.5 (Camino (Path))

Un *camino* en un DAG $\mathcal{G} = (V, \mathcal{E})$ entre dos nodos $X, Y \in V$ es una secuencia finita de nodos distintos $\langle X = V_0, V_1, \dots, V_k = Y \rangle$ tal que, para cada $j = 0, \dots, k-1$, existe una arista entre V_j y V_{j+1} en *cualquier dirección* (es decir, $V_j \rightarrow V_{j+1}$ o $V_j \leftarrow V_{j+1}$). El camino se considera en el grafo no dirigido subyacente. Un camino puede contener aristas en direcciones opuestas; de hecho, los caminos de confusión típicamente alternan direcciones.

Definición 14.6 (Camino bloqueado)

Un camino p entre X e Y está *bloqueado* por un conjunto de nodos $Z \subseteq V \setminus \{X, Y\}$ si se cumple al menos una de las siguientes condiciones:

1. p contiene una **cadena** $A \rightarrow B \rightarrow C$ o una **horquilla** $A \leftarrow B \rightarrow C$, y el nodo intermedio B pertenece a Z .
2. p contiene un **colisionador** $A \rightarrow B \leftarrow C$, y ni B ni ninguno de sus descendientes pertenecen a Z .

Si ninguna de estas condiciones se cumple, el camino está *activo* (abierto) y transmite asociación estadística entre X e Y .

La Definición 204 codifica formalmente la intuición desarrollada en la sección anterior. Una cadena o una horquilla transmiten información a menos que el nodo intermedio sea condicionado; un colisionador bloquea el flujo a menos que él (o algún descendiente) sea condicionado. La regla nemotécnica es: *el condicionamiento bloquea cadenas y horquillas, pero abre colisionadores*.

14.4 d-Separación: Independencia Condicional desde la Topología

La *d-separación* (de *directional separation*) es el concepto central que conecta la topología del DAG con la estructura de independencias condicionales de la distribución de probabilidad. Fue introducida por Pearl (1988) y constituye el criterio gráfico fundamental para leer relaciones de independencia sin necesidad de manipular expresiones algebraicas.

Definición 14.7 (d-separación)

Sean X , Y y Z tres conjuntos disjuntos de nodos en un DAG $\mathcal{G}$. Decimos que X e Y están *d-separados* por Z , y escribimos $X \perp_d Y \mid Z$, si y solo si Z bloquea **todos** los caminos entre cada nodo $X \in X$ y cada nodo $Y \in Y$.

La d-separación es un concepto puramente gráfico: puede verificarse inspeccionando el DAG sin consultar los datos. Su importancia radica en que, bajo condiciones que precisaremos a continuación, la d-separación en el grafo *implica* independencia condicional en la distribución de probabilidad. Esta correspondencia es el puente que permite al analista razonar sobre el problema de identificación directamente sobre el dibujo.

Teorema 14.1 (Soundness y Completeness de la d-separación)

Sea $\mathcal{M} = \langle U, V, F, P(U) \rangle$ un SCM con DAG $\mathcal{G}$ y distribución inducida $P(V)$.

1. **Soundness (Corrección):** Si $X \perp_d Y \mid Z$ en $\mathcal{G}$, entonces $X \perp\!\!\!\perp Y \mid Z$ en $P(V)$. Es decir, toda d-separación implica una independencia condicional en *toda* distribución compatible con $\mathcal{G}$.
2. **Completeness (bajo fidelidad):** Si la distribución $P(V)$ es fiel a $\mathcal{G}$, entonces la inversa también se cumple: $X \perp\!\!\!\perp Y \mid Z$ en $P(V)$ implica $X \perp_d Y \mid Z$ en $\mathcal{G}$. Toda independencia condicional en los datos es explicada por la topología del grafo.

La propiedad de soundness es universal: se cumple para toda distribución compatible con el DAG, sin supuestos adicionales. La completitud, en cambio, requiere el supuesto de fidelidad que examinamos a continuación.

14.5 El Supuesto de Fidelidad (Faithfulness)

La factorización de Markov garantiza que las independencias implicadas por el grafo se verifiquen en los datos. Pero ¿qué garantiza que *todas* las independencias en los datos estén implicadas por el grafo? Sin esta garantía inversa, el grafo podría ser demasiado denso (contener aristas innecesarias) y aún así ser compatible con los datos.

Definición 14.8 (Distribución fiel (Faithfulness))

Una distribución de probabilidad P es *fiel* a un DAG $\mathcal{G}$ si para toda terna de conjuntos disjuntos (X, Y, Z) se cumple:

$$X \perp\!\!\!\perp Y \mid Z \text{ en } P \implies X \perp_d Y \mid Z \text{ en } \mathcal{G}. \quad (14.5.1)$$

En palabras: *toda* independencia condicional presente en P está implicada por la estructura de d-separación de $\mathcal{G}$. No existen independencias accidentales” que surjan por cancelación algebraica de parámetros en lugar de por la topología del grafo.

La fidelidad es la implicación **recíproca** de la soundness de la d-separación: si $X \perp\!\!\!\perp Y \mid Z$ en P , entonces $X \perp_d Y \mid Z$ en $\mathcal{G}$. No debe confundirse con la soundness (dirección opuesta: d-separación implica independencia). Peters et al. (2017, Definición 6.33) establecen esta distinción formal.

La violación de fidelidad ocurre cuando dos caminos entre X e Y transmiten asociaciones de igual magnitud pero signo opuesto que se cancelan exactamente, produciendo independencia estadística sin que el grafo la implique. Por ejemplo, si el efecto directo $T \rightarrow Y$ es $\beta = +2$ y el efecto a través de un confusor $T \leftarrow L \rightarrow Y$ es -2 , la correlación marginal entre T e Y puede ser nula por cancelación. En este caso, $T \perp\!\!\!\perp Y$ en P pero T y Y no están d-separados por $\emptyset$ en $\mathcal{G}$.

Afortunadamente, el conjunto de parámetros que producen cancelaciones exactas tiene medida de Lebesgue cero en el espacio de parámetros de un modelo lineal ((Spirtes et al., 2000) ; (Meek, 1995)). En otras palabras, la fidelidad es el caso genérico: una distribución elegida al azar compatible con un DAG será fiel a él con probabilidad 1. En la práctica aplicada, sin embargo, pueden existir restricciones sustantivas (por ejemplo, mecanismos de equilibrio que imponen cancelaciones) que violen fidelidad. El analista debe ser consciente de esta posibilidad, particularmente en sistemas sociales donde existen fuerzas compensatorias institucionalizadas.

14.6 Los Supuestos Codificados en el DAG

Al proponer un DAG $\mathcal{G}$ como representación del mecanismo causal, el analista está realizando afirmaciones sustantivas cuyo costo epistemológico conviene explicitar. Cada elemento del DAG —y cada elemento ausente— codifica un supuesto.

1. **Exclusión (arista ausente):** La ausencia de una arista $V_j \rightarrow V_i$ afirma que V_j no ejerce efecto causal directo sobre V_i , condicional en $\text{pa}(V_i)$. Este es un supuesto de *exclusión*: la variable ausente está excluida del mecanismo generativo de V_i . En un DAG con k nodos, hay $\binom{k}{2}$ posibles aristas dirigidas; cada una de las aristas no dibujadas es una afirmación de exclusión tan fuerte como cada arista dibujada es una afirmación de causalidad directa.
2. **Aciclicidad:** $\mathcal{G}$ no contiene ciclos dirigidos. Esto implica que el sistema causal es estable o se analiza en equilibrio de corte transversal; no existen ciclos de retroalimentación instantánea. En contextos dinámicos, la aciclicidad puede recuperarse desagregando temporalmente las variables (incluyendo rezagos).
3. **Suficiencia causal (Markov):** Los ruidos exógenos U_i de distintas variables endógenas son mutuamente independientes. Esto equivale a afirmar que *no existen confusores no observados* entre pares de variables endógenas más allá de los modelados explícitamente como nodos en $\mathcal{G}$. La presencia de una variable latente que afecta simultáneamente a V_i y V_j viola este supuesto y requeriría representación explícita (por ejemplo, mediante aristas bidireccionales en grafos aumentados).
4. **Invariancia estructural:** Cada mecanismo f_i es autónomo y no se altera cuando se interviene sobre otras partes del sistema. Esta propiedad, central en la noción de modularidad de Pearl, es la que legitima la mutilación del grafo para representar intervenciones.

La construcción de un DAG no es un ejercicio decorativo ni un formalismo vacío. Cada arista dibujada y cada arista omitida constituye una hipótesis causal que debe ser defendida con teoría sustantiva, conocimiento institucional o evidencia empírica. Un DAG es, en esencia, la destilación gráfica de la teoría causal del investigador.

14.7 Verificación Gráfica de Independencias: Un Ejemplo Integrador

Para consolidar los conceptos presentados, apliquemos la d-separación a un DAG con cierta complejidad. Considere el siguiente grafo, motivado por la evaluación del programa *Juntos* con covariables adicionales:

Donde: E = educación materna, T = bono, M = asistencia escolar, Y = rendimiento, L = nivel socioeconómico de la comunidad.

- ¿Están E e Y d-separados por $\{T\}$? Caminos entre E e Y : (1) $E \rightarrow T \rightarrow Y$ (cadena), (2) $E \rightarrow T \rightarrow M \rightarrow Y$ (cadenas). Ambos contienen a T como nodo intermedio en cadenas. Condicionar en T bloquea ambos caminos. Por tanto, $E \perp_d Y \mid T$: **sí**.
- ¿Están T e Y d-separados por $\{M\}$? Caminos: (1) $T \rightarrow Y$ (directo, sin nodo intermedio), (2) $T \rightarrow M \rightarrow Y$ (cadena con M), (3) $T \leftarrow L \rightarrow Y$ (horquilla con L). El camino (1) no contiene ningún nodo intermedio, por lo que no puede ser bloqueado. El camino (2) se bloquea con M , y el camino (3) no se bloquea porque $L \notin \{M\}$. Como el camino (1) permanece abierto, T e Y **no** están d-separados por $\{M\}$.
- ¿Están T e Y d-separados por $\{L, M\}$? Añadiendo L a Z : el camino (1) sigue abierto (sin nodo intermedio). Conclusión: **no**. Ningún conjunto que excluya a un nodo en un camino directo puede d-separar los extremos.

14.8 Síntesis del Capítulo

- Los tres **conectores fundamentales** —cadena ($A \rightarrow B \rightarrow C$), horquilla ($A \leftarrow B \rightarrow C$) y colisionador ($A \rightarrow B \leftarrow C$)— determinan completamente el flujo de información en cualquier DAG.
- En **cadena** y **horquillas**, el condicionamiento en el nodo intermedio *bloquea* el flujo de asociación. En **colisionadores**, el condicionamiento *abre* el flujo, induciendo asociación espuria.
- La **Paradoja de Berkson** es la manifestación práctica del sesgo por colisionador: condicionar en una consecuencia común crea correlación entre causas independientes.
- Un **camino bloqueado** por Z es aquel que contiene una cadena u horquilla con nodo intermedio en Z , o un colisionador cuyo nodo de colisión (y sus descendientes) están fuera de Z .
- La **d-separación** ($X \perp_d Y \mid Z$) se verifica cuando Z bloquea *todos* los caminos entre X e Y . Es sound: implica independencia condicional en toda distribución compatible con el DAG.
- Bajo **fidelidad** (ausencia de cancelaciones accidentales de parámetros), la d-separación es además completa: toda independencia en los datos corresponde a una d-separación en el grafo.
- Cada DAG codifica supuestos de **exclusión** (aristas ausentes), **aciclicidad**, **suficiencia causal** (independencia de ruidos exógenos) e **invariancia estructural**.

El Capítulo 15 introduce el **Criterio Backdoor**, que utiliza la maquinaria de d-separación para identificar sistemáticamente conjuntos de variables de ajuste que eliminan el sesgo de confusión y permiten estimar efectos causales a partir de datos observacionales.

Supuestos clave

Supuestos del Capítulo 14 (DAGs y Estructuras Fundamentales)

1. **Suficiencia causal:** Toda causa común de dos o más variables en $\mathcal{G}$ está representada explícitamente como nodo. Sin este supuesto, la d-separación no implica independencia condicional (pueden existir caminos de confusión abiertos a través de variables latentes).
2. **Fidelidad:** Las únicas independencias condicionales en P son las implicadas por d-separación en $\mathcal{G}$. Se excluyen cancelaciones accidentales de parámetros.
3. **Aciclicidad:** $\mathcal{G}$ no contiene ciclos dirigidos. La ordenación topológica existe y la factorización de Markov es aplicable.
4. **Positividad distribucional:** $P(V_i = v \mid \text{pa}(V_i) = \mathbf{p}) > 0$ para todos los valores en el soporte, garantizando que las densidades condicionales estén bien definidas.

Otras referencias clave de este capítulo: (Verma & Pearl, 1988)  ³.

14.8 Referencias

- Berkson, J. (1946). Limitations of the Application of Fourfold Table Analysis to Hospital Data. *Biometrics Bulletin*, 2(3), 47-53.
- Meek, C. (1995). Strong Completeness and Faithfulness in Bayesian Networks. *Proceedings of the 11th Conference on Uncertainty in Artificial Intelligence (UAI 1995)*, 411-418.
- Pearl, J. (1988). *Probabilistic Reasoning in Intelligent Systems*. Morgan Kaufmann.
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of Causal Inference: Foundations and Learning Algorithms*. MIT Press.
- Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, Prediction, and Search* (2.^a ed.). MIT Press.
- Verma, T., & Pearl, J. (1988). Causal Networks: Semantics and Expressiveness. *Proceedings of the Fourth Workshop on Uncertainty in Artificial Intelligence (UAI 1988)*, 69-76.

³Este capítulo citaba antes la misma obra dos veces con venues contradictorios (“Proceedings of AAAI-88” y “Fourth Workshop on Uncertainty in Artificial Intelligence (UAI 1988)”). Se adopta la versión UAI 1988; pendiente de cotejo bibliográfico primario si se requiere certeza absoluta sobre el venue original.

CAPÍTULO 15

El Criterio Backdoor: El Arte del Ajuste

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque II · Semilla 42**Notebook (pack):** notebooks/Bloque_II/notebooks/15_criterio_backdoor_arte_ajuste.ipynb**Jupyter Book:** jupyter_book/content/bloque_02_formalizacion/15_criterio_backdoor.ipynb

Disponemos ya del SCM, del DAG y de la d-separación como herramienta para leer independencias condicionales desde la topología del grafo. Ahora enfrentamos la pregunta práctica que motiva todo el edificio teórico: dado un grafo causal $\mathcal{G}$ y datos puramente observacionales, ¿existe un conjunto de variables Z que, al ser incluidas en el ajuste —ya sea mediante regresión, estratificación, o ponderación— elimine por completo el sesgo de confusión y permita estimar $P_{\text{do}(T=t)}(Y)$, el efecto causal de T sobre Y ?

La respuesta es el **Criterio Backdoor**, formulado por Judea Pearl en 1993. Este criterio proporciona una condición suficiente —gráfica y verificable— para que un conjunto de covariables Z permita identificar el efecto causal a partir de datos observacionales. Su importancia no puede ser exagerada: constituye el puente operativo entre la especificación cualitativa del DAG y la estimación cuantitativa del efecto causal. En este capítulo desarrollamos el criterio con rigor, demostramos la fórmula de ajuste asociada, examinamos ejemplos en el contexto de políticas públicas peruanas, y discutimos sus limitaciones y supuestos.

15.1 Caminos de Puerta Trasera: La Anatomía de la Confusión

El primer paso para eliminar el sesgo de confusión es identificar sus portadores topológicos: los caminos que transmiten asociación espuria entre el tratamiento y el resultado.

Definición 15.1 (Caminos de puerta trasera (Backdoor Path))

Un camino entre T e Y en un DAG $\mathcal{G}$ es un *camino de puerta trasera* si **comienza con una arista que entra en T** . Formalmente, el camino tiene la forma $T \leftarrow V_1 \cdots V_k \rightarrow Y$ o $T \leftarrow V_1 \cdots V_k \leftarrow Y$, donde la primera arista desde T es $T \leftarrow V_1$. Estos caminos transmiten correlación espuria (confusión) porque una causa común de T e Y (o una cadena de ellas) induce asociación no causal entre ambos.

La metáfora es evocadora: la confusión entra al sistema por la puerta de atrás de la variable de tratamiento, a diferencia del efecto causal genuino que sale por la puerta del frente $T \rightarrow \cdots \rightarrow Y$. Los caminos que comienzan con una arista *saliente* de T ($T \rightarrow V_1 \cdots$) son caminos causales dirigidos y no deben ser bloqueados si queremos estimar el efecto total. El arte del ajuste consiste precisamente en bloquear todos los caminos de puerta trasera sin bloquear ninguno de los caminos causales dirigidos.

Ejemplo 15.1 (Caminos de puerta trasera en el programa Juntos)

En el DAG del programa *Juntos*: $L \rightarrow T$, $L \rightarrow Y$, $T \rightarrow Y$, tenemos exactamente dos caminos entre T e Y :

- $T \rightarrow Y$: camino causal dirigido (no es de puerta trasera).
- $T \leftarrow L \rightarrow Y$: camino de puerta trasera (comienza con arista entrante a T).

El confusor L (nivel educativo de la madre) induce una asociación espuria entre T e Y a través del camino de puerta trasera. Si no ajustamos por L , la estimación del efecto de T sobre Y estará contaminada por esta vía de confusión.

15.2 El Criterio Backdoor: Definición y Justificación

Definición 15.2 (Criterio Backdoor)

Un conjunto de variables observables $Z \subseteq V \setminus \{T, Y\}$ satisface el *criterio backdoor* con respecto al par ordenado (T, Y) en un DAG $\mathcal{G}$ si se cumplen dos condiciones:

1. **Ninguna variable en Z es descendiente de T .** Formalmente, $Z \cap \text{De}(T) = \emptyset$, donde $\text{De}(T)$ denota el conjunto de descendientes de T en $\mathcal{G}$.
2. **Z d-separa T de Y en el grafo mutilado $\mathcal{G}_{\underline{T}}$.** El grafo $\mathcal{G}_{\underline{T}}$ se obtiene eliminando de $\mathcal{G}$ todas las aristas salientes de T ($T \rightarrow V_j$ para todo V_j).

La intuición detrás de cada condición merece ser explicitada. La condición (1) prohíbe incluir descendientes del tratamiento en el conjunto de ajuste. Incluir un descendiente de T —típicamente un mediador— bloquearía parte del efecto causal que queremos estimar. Peor aún, si el descendiente es además un colisionador, condicionar en él abriría caminos espurios, induciendo el sesgo de Berkson que estudiamos en el Capítulo 14. La condición (2) exige que Z bloquee todos los caminos de puerta trasera. Al eliminar las aristas salientes de T en $\mathcal{G}_{\underline{T}}$, los únicos caminos que permanecen entre T e Y son precisamente los de puerta trasera. Si Z los d-separa en $\mathcal{G}_{\underline{T}}$, entonces ningún camino de confusión transmite asociación espuria.

Teorema 15.1 (Fórmula de Ajuste Backdoor)

Sea $\mathcal{G}$ un DAG compatible con un SCM $\mathcal{M}$ y sea Z un conjunto que satisface el criterio backdoor para (T, Y) . Entonces, el efecto causal de T sobre Y es identificable a partir de la distribución observacional mediante:

$$P_{\text{do}(T=t)}(Y = y) = \sum_{\mathbf{z}} P(Y = y \mid T = t, \mathbf{Z} = \mathbf{z}) P(\mathbf{Z} = \mathbf{z}). \quad (15.2.1)$$

Para el caso continuo, la suma se reemplaza por una integral. En términos de esperanzas:

$$\mathbb{E}_{\text{do}(T=t)}[Y] = \sum_{\mathbf{z}} \mathbb{E}[Y \mid T = t, \mathbf{Z} = \mathbf{z}] P(\mathbf{Z} = \mathbf{z}). \quad (15.2.2)$$

La demostración se apoya en dos invariancias bajo $\text{do}(T = t)$: la distribución de Z no se altera por la intervención, y el mecanismo que genera Y a partir de (T, Z) permanece intacto — ambas son consecuencia directa de las dos condiciones del criterio. La fórmula resultante es extraordinariamente práctica: expresa el efecto causal como un promedio ponderado de efectos condicionales observacionales, donde los pesos son las probabilidades marginales de las variables de ajuste. No requiere modelar el mecanismo de asignación del tratamiento ni las funciones estructurales completas; solo requiere que el conjunto Z

satisfaga el criterio gráfico y que podamos estimar las cantidades condicionales $P(Y | T, Z)$ y $P(Z)$ desde los datos.

15.3 ¿Qué Conjuntos Satisfacen el Criterio? Ejemplos

La aplicación del criterio backdoor es un ejercicio de inspección gráfica. Examinemos varios DAGs prototípicos.

Ejemplo 15.2 (Confusor único: el caso canónico)

DAG: $L \rightarrow T, L \rightarrow Y, T \rightarrow Y$. Candidatos para Z :

- $Z = \emptyset$: En $\mathcal{G}_T$, el camino $T \leftarrow L \rightarrow Y$ no está bloqueado. No satisface.
- $Z = \{L\}$: L no es descendiente de T . En $\mathcal{G}_T$, L bloquea la horquilla $T \leftarrow L \rightarrow Y$. **Satisface.**

Fórmula: $P_{\text{do}(T=t)}(Y) = \sum_{\ell} P(Y | T = t, L = \ell)P(L = \ell)$.

Ejemplo 15.3 (Múltiples confusores)

DAG: $L_1 \rightarrow T, L_1 \rightarrow Y, L_2 \rightarrow T, L_2 \rightarrow Y, T \rightarrow Y$, y además $L_1 \rightarrow L_2$. Caminos de puerta trasera:

- $T \leftarrow L_1 \rightarrow Y$
- $T \leftarrow L_2 \rightarrow Y$
- $T \leftarrow L_1 \rightarrow L_2 \rightarrow Y$

$Z = \{L_1\}$ bloquea el primer y tercer camino (contienen horquilla/cadena con L_1), pero no el segundo ($T \leftarrow L_2 \rightarrow Y$ requiere condicionar en L_2). $Z = \{L_2\}$ bloquea el segundo y tercer camino pero no el primero. $Z = \{L_1, L_2\}$ bloquea los tres. **Conclusión:** $\{L_1, L_2\}$ satisface el criterio, y también $\{L_2\}$ si L_1 solo afecta a Y a través de L_2 , en cuyo caso $L_1 \rightarrow Y$ estaría ausente.

Ejemplo 15.4 (Caso con mediador: cuidado con la condición 1)

DAG: $T \rightarrow M \rightarrow Y$, con confusor $L \rightarrow T, L \rightarrow Y$. Caminos: $T \rightarrow M \rightarrow Y$ (causal), $T \leftarrow L \rightarrow Y$ (puerta trasera). $Z = \{L\}$ satisface el criterio: L no es descendiente de T y bloquea la puerta trasera. Pero $Z = \{L, M\}$ **no** satisface: M es descendiente de T , violando la condición (1). Ajustar por el mediador M bloquearía parte del efecto causal que queremos estimar.

15.4 El Experimento Aleatorio como Caso Especial

Un experimento controlado aleatorizado (RCT) puede entenderse, en el lenguaje de los DAGs, como el caso en que el tratamiento no tiene padres (excepto el mecanismo de aleatorización, que es independiente de todo lo demás). Formalmente, en un RCT, $\text{pa}(T) = \emptyset$ en el DAG que representa el diseño experimental.

En este caso, **no existen caminos de puerta trasera** hacia T , porque ningún nodo tiene una arista dirigida hacia T . El conjunto vacío $Z = \emptyset$ satisface trivialmente el criterio backdoor: no hay nada que bloquear. La fórmula de ajuste colapsa a:

$$P_{\text{do}(T=t)}(Y) = P(Y | T = t), \quad (15.4.1)$$

que es exactamente la igualdad que demostramos en el Capítulo 2 bajo independencia fuerte. El RCT es, por tanto, el caso especial y más simple del criterio backdoor.

15.5 Observational Equivalence y las Limitaciones del Criterio

No todo efecto causal es identificable mediante el criterio backdoor. Existen DAGs donde ningún conjunto observable satisface el criterio, típicamente porque el confusor no es observado y no hay variables proxy que permitan bloquear la puerta trasera.

Definición 15.3 (O-equivalencia (Observational Equivalence))

Dos DAGs $\mathcal{G}_1$ y $\mathcal{G}_2$ son *observacionalmente equivalentes* si implican exactamente el mismo conjunto de independencias condicionales (la misma estructura de d-separación). En tal caso, ninguna cantidad puramente observacional puede distinguir entre ellos; se requiere una intervención o supuestos adicionales.

La equivalencia observacional tiene una implicación práctica fundamental: los datos observacionales *no pueden* distinguir entre $A \rightarrow B$ y $A \leftarrow B$ cuando no hay otras variables que rompan la simetría. Esta limitación subraya la importancia de la teoría sustantiva y el conocimiento de dominio en la especificación del DAG. Sin una justificación externa de la dirección de las aristas, el criterio backdoor puede aplicarse a un grafo incorrecto, produciendo un conjunto de ajuste inválido.

Ejemplo 15.5 (Fallo del criterio backdoor por confusor no observable)

Considere el DAG: $U \rightarrow T$, $U \rightarrow Y$, $T \rightarrow Y$, donde U no es observado. El único camino de puerta trasera es $T \leftarrow U \rightarrow Y$. Como U no está disponible, ningún subconjunto de variables observables puede bloquear este camino. El criterio backdoor no puede satisfacerse con datos observacionales. Se requiere un instrumento (Capítulos 5–6) o el criterio frontdoor (Capítulo 16).

15.6 Del Criterio a la Estimación: Estrategias Prácticas

Una vez identificado un conjunto Z que satisface el criterio backdoor, existen múltiples estrategias para estimar el efecto causal. Las tres principales son:

1. **Estratificación y estandarización:** Estimar $\mathbb{E}[Y \mid T = t, Z = z]$ dentro de cada estrato definido por Z y luego promediar sobre la distribución marginal de Z . Es la implementación más directa de la fórmula de ajuste.
2. **Regresión con ajuste:** Incluir Z como covariables en un modelo de regresión para $\mathbb{E}[Y \mid T, Z]$. Bajo linealidad, el coeficiente de T estima el efecto causal. Esta estrategia es válida solo si el modelo está correctamente especificado.
3. **Ponderación por probabilidad inversa (IPW):** Estimar $P(T = t \mid Z = z)$ y ponderar las observaciones por el inverso de esta probabilidad. Bajo el criterio backdoor, el estimador IPW es consistente para el ATE.

Las tres estrategias son asintóticamente equivalentes bajo correcta especificación, pero difieren en su desempeño en muestras finitas y en su sensibilidad a errores de modelo. La combinación de regresión y ponderación (AIPW, Capítulo 4) ofrece protección doble contra mala especificación.

Ejemplo 15.6 (Ajuste backdoor en la práctica: Pensión 65)

Para estimar el efecto del programa *Pensión 65* sobre el consumo de los hogares de adultos mayores en Perú, se identifica el siguiente DAG: $E \rightarrow T$, $E \rightarrow Y$, $T \rightarrow Y$, donde E es el índice de elegibilidad (basado en el Sistema de Focalización de Hogares), T es la recepción de la transferencia, e Y es el consumo mensual per cápita. El camino de puerta trasera es $T \leftarrow E \rightarrow Y$. El conjunto $Z = \{E\}$ satisface el criterio backdoor: E no es descendiente de T (la elegibilidad se determina antes de la transferencia) y bloquea la horquilla de confusión. La fórmula de ajuste:

$$\mathbb{E}_{\text{do}(T=t)}[Y] = \sum_e \mathbb{E}[Y \mid T = t, E = e]P(E = e) \quad (15.6.1)$$

indica que debemos: (1) estimar el consumo esperado para hogares con y sin transferencia *dentro de cada nivel de elegibilidad*, y (2) promediar estos efectos específicos por nivel usando como pesos la distribución poblacional de la elegibilidad. Esto produce el efecto causal ajustado, libre de la confusión inducida por el hecho de que los hogares más pobres (mayor elegibilidad) tienen sistemáticamente menor consumo basal.

Este ejemplo ilustra un principio general: el criterio backdoor transforma un problema de identificación causal en un problema de estimación estadística. Una vez que el DAG ha sido validado y el conjunto Z ha sido identificado gráficamente, la tarea restante es puramente estadística: estimar esperanzas condicionales y marginales desde los datos. La calidad de la inferencia causal dependerá entonces de la calidad de estas estimaciones estadísticas y, crucialmente, de la correctitud del DAG subyacente. Como advierten Hernán & Robins (2020), ningún método de ajuste puede compensar un DAG mal especificado.

15.7 Síntesis del Capítulo

- Un **camino de puerta trasera** entre T e Y comienza con una arista entrante a T ($T \leftarrow \dots$). Estos caminos transmiten el sesgo de confusión.
- El **Criterio Backdoor** exige dos condiciones: (1) ningún elemento de Z es descendiente de T , y (2) Z d-separa T de Y en el grafo mutilado $\mathcal{G}_{\underline{T}}$ (sin aristas salientes de T).
- La **Fórmula de Ajuste Backdoor**: $P_{\text{do}(T=t)}(Y) = \sum_z P(Y \mid T = t, Z = z)P(Z = z)$ expresa el efecto causal como promedio de efectos condicionales.
- El **experimento aleatorio** es el caso especial con $Z = \emptyset$, donde no existen caminos de puerta trasera.
- La **O-equivalencia** advierte que dos DAGs pueden ser indistinguibles desde datos observacionales, subrayando la necesidad de teoría sustantiva para especificar el grafo.
- Cuando el confusor no es observable, el criterio backdoor no es aplicable; se requieren estrategias alternativas como variables instrumentales o el criterio frontdoor.

El Capítulo 16 presenta el **Criterio Frontdoor**, una estrategia de identificación que permite estimar efectos causales incluso cuando el confusor es completamente no observable, siempre que exista un mediador que intercepte el efecto del tratamiento sobre el resultado.

Otras referencias clave de este capítulo: (Hernán & Robins, 2020), (Pearl, 1993), (Pearl, 2009), (Pearl et al., 2016), (Shpitser & Pearl, 2006).

15.7 Referencias

Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.



- Pearl, J. (1993). Comment: Graphical Models, Causality and Intervention. *Statistical Science*, 8(3), 266-269.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Pearl, J., Glymour, M., & Jewell, N. P. (2016). *Causal Inference in Statistics: A Primer*. Wiley.
- Shpitser, I., & Pearl, J. (2006). Identification of Conditional Interventional Distributions. *Proceedings of the 22nd Conference on Uncertainty in Artificial Intelligence (UAI 2006)*, 437-444.

CAPÍTULO 16

El Criterio Frontdoor: Identificación sin Observar Confusores

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque II · Semilla 42

Notebook (pack): notebooks/Bloque_II/

notebooks/16_criterio_frontdoor_identificacion_sin_observar_confusores.ipynb

Jupyter Book: jupyter_book/content/bloque_02_formalizacion/16_criterio_frontdoor.ipynb

El criterio backdoor que desarrollamos en el capítulo anterior resuelve elegantemente el problema de identificación cuando los confusores son observables. Pero en muchos estudios sociales, epidemiológicos y económicos —particularmente en contextos como el peruano y latinoamericano, donde los sistemas de registro administrativo son incompletos— los confusores cruciales no pueden ser medidos. La motivación, el capital social, las redes familiares, la habilidad innata, los activos ocultos: todos ellos afectan simultáneamente la asignación del tratamiento y el resultado, pero residen fuera del alcance de nuestras bases de datos.

El **Criterio Frontdoor**, introducido por Pearl (1995), es una de las contribuciones más elegantes y sorprendentes de la teoría de identificación gráfica. Bajo condiciones precisas, permite estimar el efecto causal de T sobre Y incluso cuando el confusor U es **completamente no observable**, siempre que exista un mediador M que intercepte todo el efecto causal y que, a su vez, no sea confundido con el resultado. La intuición es notable: si no podemos bloquear la puerta trasera porque el confusor está oculto, podemos entrar por la puerta del frente’, descomponiendo el efecto en dos tramos identificables por separado.

16.1 Motivación Histórica: El Debate del Tabaco y el Cáncer

El criterio frontdoor no es un artificio matemático; tiene raíces en uno de los debates científicos más importantes del siglo XX. Durante las décadas de 1950 y 1960, la comunidad epidemiológica debatía si la asociación observada entre fumar tabaco y el cáncer de pulmón era causal o espuria. R. A. Fisher —el gigante de la estadística del siglo XX— argumentaba que un factor genético no observado U (una predisposición constitucional) podía causar tanto el hábito de fumar como el cáncer de pulmón, explicando la correlación sin necesidad de invocar un efecto causal del tabaco.

La estructura causal del debate es:

- T : hábito de fumar (tratamiento).
- Y : cáncer de pulmón (resultado).
- U : predisposición genética no observada (confusor).

El DAG es $U \rightarrow T, U \rightarrow Y, T \rightarrow Y$. El confusor U no es medible (al menos no en esa época). El criterio backdoor no puede aplicarse.

Pero existe una variable intermedia observable: M , la cantidad de alquitrán depositado en los pulmones. El alquitrán es producido por el acto de fumar y es un carcinógeno conocido. Crucialmente, la predis-

posición genética U no afecta la cantidad de alquitrán excepto a través de cuánto se fuma. El DAG completo es:

La línea discontinua desde U enfatiza que esta variable no es observada por el analista. La pregunta es: ¿podemos estimar el efecto causal de fumar sobre el cáncer sin medir U ? La respuesta, gracias al criterio frontdoor, es afirmativa.

16.2 El Criterio Frontdoor: Definición Formal

Definición 16.1 (Criterio Frontdoor)

Un conjunto de variables observables $M \subseteq V\{T, Y\}$ satisface el *criterio frontdoor* con respecto al par ordenado (T, Y) en un DAG $\mathcal{G}$ si se cumplen tres condiciones:

1. **Interceptación completa:** Todo camino causal dirigido de T a Y pasa por algún elemento de M . Formalmente, M intercepta todos los caminos dirigidos $T \rightarrow \dots \rightarrow Y$.
2. **No confusión del primer tramo:** No existen caminos de puerta trasera no bloqueados entre T y M . Es decir, el efecto causal de T sobre M es identificable sin ajuste adicional (o bien, existe un conjunto que satisface el criterio backdoor para (T, M)).
3. **No confusión del segundo tramo dado T :** Todos los caminos de puerta trasera entre M e Y están bloqueados por T . Equivalentemente, T satisface el criterio backdoor para (M, Y) .

Las tres condiciones tienen interpretaciones intuitivas precisas. La condición (1) exige que M sea un *mediador completo*: no existe un camino directo $T \rightarrow Y$ que eluda a M . La condición (2) garantiza que podamos identificar el efecto de T sobre M sin preocuparnos por confusión —en el ejemplo del tabaco, U no causa directamente el alquitrán excepto a través del hábito de fumar. La condición (3) es la más sutil: exige que, una vez que condicionamos en T , el efecto de M sobre Y esté libre de confusión. En el ejemplo, la predisposición genética U afecta a Y directamente, pero el camino de puerta trasera $M \leftarrow T \leftarrow U \rightarrow Y$ está bloqueado por T (es una horquilla en U con T como nodo condicionado). Nótese que T actúa aquí como variable de ajuste para la relación $M \rightarrow Y$.

Teorema 16.1 (Fórmula de Identificación Frontdoor)

Sea $\mathcal{G}$ un DAG compatible con un SCM $\mathcal{M}$ y sea M un conjunto que satisface el criterio frontdoor para (T, Y) . Entonces el efecto causal de T sobre Y es identificable mediante:

$$P_{\text{do}(T=t)}(Y=y) = \sum_m P(M=m \mid T=t) \sum_{t'} P(Y=y \mid T=t', M=m) P(T=t') \quad (16.2.1)$$

La estructura de la fórmula frontdoor revela su lógica interna. El primer factor, $P(M=m \mid T=t)$, captura el efecto del tratamiento sobre el mediador: ¿cómo cambia la distribución del mediador cuando se interviene sobre T ? El segundo factor, la suma interna sobre t' , captura el efecto del mediador sobre el resultado, ajustando por T para eliminar la confusión de U . La combinación de ambos produce el efecto total, incluso sin haber observado nunca el confusor U .

16.3 Aplicación al Ejemplo del Tabaco

Ejemplo 16.1 (Efecto del tabaco sobre el cáncer vía alquitrán)

Con $T \in \{0, 1\}$ (fumar/no fumar), M = nivel de alquitrán en pulmones, Y = incidencia de cáncer, y U = predisposición genética no observada, verificamos las condiciones del criterio frontdoor:

1. **Interceptación completa:** Todo el efecto de fumar sobre el cáncer opera a través del alquitrán depositado en los pulmones. No hay un camino directo $T \rightarrow Y$ que eluda a M . **Cumple.**
2. **No confusión $T \rightarrow M$:** El único camino de puerta trasera entre T y M sería $T \leftarrow U \rightarrow Y \leftarrow M$, pero esta trayectoria contiene el colisionador Y (no condicionado, por tanto bloqueado). No hay caminos de puerta trasera abiertos. **Cumple.**
3. **No confusión $M \rightarrow Y$ dado T :** El camino de puerta trasera es $M \leftarrow T \leftarrow U \rightarrow Y$. Este es una horquilla en U con T como nodo. Como T es condicionado en la fórmula, el camino está bloqueado. **Cumple.**

Por tanto, $M = \{M\}$ satisface el criterio frontdoor, y la fórmula de identificación es:

$$P_{\text{do}(T=t)}(Y=y) = \sum_m P(M=m \mid T=t) \sum_{t' \in \{0,1\}} P(Y=y \mid T=t', M=m) P(T=t') \quad (16.3.1)$$

Cada cantidad a la derecha del signo igual es estimable desde datos observacionales de (T, M, Y) . El confusor U nunca aparece.

La importancia histórica de este resultado trasciende lo metodológico: el criterio frontdoor proporcionó una refutación formal de la crítica de Fisher, demostrando que la hipótesis causal fumar causa cáncer¹⁶ es testeable incluso en presencia de un confusor genético no observado, siempre que exista un mediador observable como el alquitrán que satisfaga las condiciones.

16.4 Backdoor versus Frontdoor: Una Comparación Sistemática

Los criterios backdoor y frontdoor no son mutuamente excluyentes; son dos estrategias de identificación que se aplican en contextos diferentes y que, de hecho, son casos particulares de un sistema deductivo más general: el **do-calculus** de Pearl (1995), que será objeto del Capítulo 17.

Dimensión	Criterio Backdoor	Criterio Frontdoor
Requerimiento	Confusores observados (o proxies)	Mediador observable
Confusor no observado	No puede manejarlo	Lo maneja elegantemente
Estructura típica	$L \rightarrow T, L \rightarrow Y, T \rightarrow Y$ con L observado	$U \rightarrow T, U \rightarrow Y, T \rightarrow M \rightarrow Y$ con U latente
Ajuste	Condiciona en variables pre-tratamiento	Condiciona en T para el tramo $M \rightarrow Y$
Fórmula	$\sum_z P(Y \mid T, z) P(z)$	$\sum_m P(m \mid T) \sum_{t'} P(Y \mid t', m) P(t')$
Limitación principal	Requiere medir todos los confusores	Requiere mediador completo y no confundido

En la práctica aplicada, la elección entre backdoor y frontdoor no siempre es binaria. Frecuentemente existen múltiples conjuntos que satisfacen cada criterio, y la práctica recomendada es reportar estimaciones bajo varios conjuntos de ajuste válidos como análisis de sensibilidad. Si las estimaciones son estables bajo diferentes elecciones de Z o M , la conclusión se fortalece.

16.5 Un Ejemplo en Políticas Públicas Peruanas

Ejemplo 16.2 (Efecto de la capacitación laboral sobre el ingreso)

Considere el programa *Jóvenes Productivos* del Ministerio de Trabajo del Perú, que ofrece capacitación en habilidades técnicas a jóvenes de bajos recursos. El objetivo es estimar el efecto de la capacitación T sobre el ingreso laboral Y a los seis meses de egreso. Existe un confusor no observado crucial: la *motivación* U . Los jóvenes más motivados tienen mayor probabilidad de inscribirse en el programa y obtendrían mayores ingresos incluso sin capacitación. El DAG es $U \rightarrow T$, $U \rightarrow Y$, y $T \rightarrow Y$, con U no medido. El criterio backdoor no puede aplicarse.

Sin embargo, el programa induce un mediador observable: la *certificación de competencias* M que los participantes obtienen al aprobar el curso. La certificación es valorada por los empleadores y aumenta la empleabilidad. El DAG se extiende a $T \rightarrow M \rightarrow Y$, con $U \rightarrow T$, $U \rightarrow Y$.

Verifiquemos las condiciones frontdoor:

1. **Interceptación:** ¿Todo el efecto de la capacitación sobre el ingreso pasa por la certificación? Es plausible: el programa no ofrece contactos laborales directos ni subsidios posteriores; la certificación es el principal producto valorado por el mercado.
2. **No confusión $T \rightarrow M$:** ¿Existe un camino de puerta trasera entre T y M ? La motivación U afecta a T , pero no directamente a M excepto a través de T (la certificación se obtiene por completar el curso, no por motivación). **Cumple.**
3. **No confusión $M \rightarrow Y$ dado T :** El camino $M \leftarrow T \leftarrow U \rightarrow Y$ está bloqueado al condicionar en T (horquilla en U). **Cumple.**

La fórmula frontdoor permite estimar el efecto causal de la capacitación sobre el ingreso utilizando solo datos de (T, M, Y) —es decir, participación en el programa, obtención de certificación, e ingreso laboral— sin necesidad de medir la motivación. Este es precisamente el tipo de datos que un registro administrativo del programa puede proporcionar de forma rutinaria.

16.6 Limitaciones y Extensiones

El criterio frontdoor, a pesar de su elegancia, opera bajo condiciones exigentes que no siempre se satisfacen en la práctica:

1. **Mediación completa:** La condición de que M intercepte *todos* los caminos dirigidos de T a Y es fuerte. Si existe un efecto directo $T \rightarrow Y$ que no pasa por M , la fórmula frontdoor subestima el efecto total (omite el canal directo).
2. **No confusión del primer tramo:** Si existe un confusor no observado que afecta simultáneamente a T y a M , la identificación del primer tramo falla. Esta situación puede darse, por ejemplo, si la motivación afecta tanto la inscripción en el programa como el desempeño en el examen de certificación.
3. **No confusión del segundo tramo:** Si existe una variable no observada que afecta simultáneamente a M e Y incluso después de condicionar en T , el segundo tramo no es identificable.
4. **Positividad:** La fórmula involucra $P(M = m \mid T = t)$ y $P(T = t')$; ambas deben ser estrictamente positivas en todo el soporte relevante.

Cuando estas condiciones no se satisfacen, existen generalizaciones como el criterio frontdoor condicional (que permite covariables adicionales) y el algoritmo de identificación completo basado en el do-calculus. Estos temas se abordan en el Capítulo 17.

16.7 Síntesis del Capítulo

- El **Criterio Frontdoor** permite identificar efectos causales cuando el confusor U es no observable pero existe un mediador M que satisface tres condiciones: (1) M intercepta todos los caminos $T \rightarrow Y$, (2) no hay confusión no bloqueada entre T y M , y (3) T bloquea los caminos de puerta trasera entre M e Y .
- La **Fórmula Frontdoor**: $P_{\text{do}(T=t)}(Y) = \sum_m P(m \mid T=t) \sum_{t'} P(Y \mid T=t', m) P(T=t')$ descompone el efecto total en dos tramos identificables.
- El **debate Fisher–Pearl** sobre tabaco y cáncer ilustra la motivación histórica: el criterio frontdoor demuestra que la hipótesis causal es testeable incluso con confusores genéticos no medidos.
- **Backdoor vs. Frontdoor**: Backdoor requiere confusores observados; frontdoor requiere un mediador observable y permite confusores latentes. Ambos son casos especiales del **do-calculus**.
- En políticas públicas peruanas (como *Jóvenes Productivos*), el criterio frontdoor ofrece una estrategia de identificación viable con datos administrativos rutinarios, sin necesidad de medir constructos latentes como la motivación.

El Capítulo 17 unifica los criterios backdoor y frontdoor bajo el **do-calculus**, el sistema axiomático completo de Pearl para la identificación de efectos causales en cualquier DAG, proporcionando las tres reglas que permiten transformar expresiones intervencionales en observacionales.

Supuestos clave

Supuestos del Capítulo 16 (Criterio Frontdoor)

1. **Mediación completa**: M intercepta todas las vías dirigidas $T \rightarrow Y$. No existe un camino causal directo $T \rightarrow Y$ que eluda a M . Si existe tal camino, el efecto estimado por la fórmula frontdoor es solo el efecto indirecto a través de M .
2. **No confusión $T-M$** : Todos los caminos de puerta trasera entre T y M están bloqueados (ya sea por el conjunto vacío o por covariables observadas adicionales). El efecto $T \rightarrow M$ es identificable.
3. **No confusión $M-Y$ dado T** : Condicionando en T , no existen caminos de puerta trasera abiertos entre M e Y . T actúa como conjunto de ajuste válido para identificar el efecto $M \rightarrow Y$.
4. **Positividad**: $P(M=m \mid T=t) > 0$ para todo m en el soporte y todo $t \in \mathcal{T}$, y $P(T=t) > 0$ para todo t . Estas condiciones garantizan que la suma sobre m y t' en la fórmula esté bien definida.

Otras referencias clave de este capítulo: (Pearl et al., 2016)⁴, (Pearl, 2009), (Pearl & Mackenzie, 2018), (Shpitser & Pearl, 2006).

16.7 Referencias

- Pearl, J. (1995). Causal Diagrams for Empirical Research. *Biometrika*, 82(4), 669-688.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Pearl, J., & Mackenzie, D. (2018). *The Book of Why: The New Science of Cause and Effect*. Basic Books.
- Pearl, J., Glymour, M., & Jewell, N. P. (2016). *Causal Inference in Statistics: A Primer*. Wiley.
- Shpitser, I., & Pearl, J. (2006). Identification of Joint Interventional Distributions in Recursive Semi-Markovian Causal Models. *Proceedings of the 21st National Conference on Artificial Intelligence (AAAI 2006)*, 1219-1226.

⁴Corregido el orden de autoría respecto de una versión previa de este capítulo, que citaba esta obra como “Glymour, Pearl & Jewell” — el autor principal de *Causal Inference in Statistics: A Primer* (Wiley, 2016) es Judea Pearl.

CAPÍTULO 17

La Naturaleza de las Causas: Singular, General y Empírico

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque II · Semilla 42**Notebook (pack):** notebooks/Bloque_II/notebooks/17_naturaleza_causas_singular_general_empirico.ipynb**Jupyter Book:** jupyter_book/content/bloque_02_formalizacion/17_naturaleza_causas.ipynb

El racionamiento causal responde cuánto vale $P_{\text{do}(T)}(Y)$ en una población, pero no responde si *este* tratamiento causó *este* resultado en *este* paciente. El capítulo anterior construyó el andamiaje algebraico de la identificación causal; este capítulo da un paso atrás y pregunta: ¿*qué estamos midiendo realmente?* ¿Es lo mismo preguntar “¿fumar aumenta el riesgo de cáncer en la población?” que preguntar “¿el tabaquismo de Ernesto causó su cáncer?” Estas preguntas pertenecen a niveles ontológicamente distintos, y confundirlas no es solo un error semántico sino una fuente de conclusiones incorrectas, litigios mal resueltos y políticas públicas mal diseñadas.

El presente capítulo establece con precisión la distinción entre **causa general** y **causa singular**, examina el contenido empírico de los contrafactuales que sustentan cada tipo, y muestra cómo el criterio de ordenamiento causal de Simon explica de dónde provienen las flechas de un DAG. Estos fundamentos filosóficos no son ornamentales: son los cimientos que dan sentido a todo el do-calculus y a los métodos computacionales que siguen.

17.1 Una Pregunta Incómoda

Considérese el siguiente diálogo, frecuente en sesiones de análisis de datos:

Analista A: Estimamos $P_{\text{do}(T=1)}(Y) - P_{\text{do}(T=0)}(Y) = 0.12$. El tratamiento tiene un efecto positivo.” **Analista B:** Pero el paciente 47 recibió el tratamiento y empeoró. ¿El tratamiento le causó el daño?” **Analista A:** Eso no puedo decirlo con mi estimación.”

El Analista A tiene razón: la estimación de un efecto promedio poblacional no responde la pregunta del Analista B. Esta tensión no es una limitación técnica superable con más datos; es una distinción conceptual fundamental. La pregunta del Analista B requiere un tipo diferente de respuesta causal. A lo largo de los capítulos anteriores hemos utilizado implícitamente dos nociones de causa sin distinguirlas:

1. Enunciados del tipo $P_{\text{do}(t)}(Y) > P_{\text{do}(t')}(Y)$, que describen el efecto de una intervención sobre la distribución de Y en una *población*.
2. Enunciados del tipo el evento $X = x$ causó $Y = y$ en la unidad u ”, que atribuyen responsabilidad a un evento particular en un individuo particular.

El primer tipo corresponde a la **causa general** (o *type causation*); el segundo, a la **causa singular** (o *token causation*). Precisar esta distinción es el objetivo de las secciones que siguen.

17.2 Causa General versus Causa Singular



Definición 17.1 (Causa General)

Decimos que T es una *causa general* de Y si existe algún par de valores $t \neq t'$ tal que

$$P_{\text{do}(T=t)}(Y) \neq P_{\text{do}(T=t')}(Y). \quad (17.2.1)$$

En particular, T *aumenta la probabilidad* de $Y = y$ si

$$P_{\text{do}(t)}(y) > P_{\text{do}(t')}(y). \quad (17.2.2)$$

Este enunciado es estimable desde datos poblacionales y no requiere información a nivel de individuo.

Definición 17.2 (Causa Singular)

El evento $T = t$ *causó* $Y = y$ en la unidad i si

$$Y_{i(t=y)} \neq Y_{i(t' \neq y)} \quad (17.2.3)$$

para algún valor alternativo t' . Aquí $Y_{i(t)}$ denota el resultado potencial de Y para la unidad i cuando T es forzado a tomar el valor t mediante una intervención.

La diferencia es radical: la causa general habla de distribuciones; la causa singular habla de trayectorias individuales. La primera puede estimarse con un experimento aleatorizado; la segunda requiere conocer (o inferir) la función estructural que rige a la unidad u .

Ejemplo 17.1 (El medicamento con efecto poblacional positivo)

Supóngase un modelo estructural con dos tipos de pacientes:

- **Tipo A** (60% de la población): el medicamento los cura ($Y_1(u) = 1, Y_0(u) = 0$).
- **Tipo B** (40% de la población): el medicamento los daña ($Y_1(u) = 0, Y_0(u) = 1$).

El efecto promedio poblacional es

$$\text{ATE} = P(Y_1 = 1) - P(Y_0 = 1) = 0.6 - 0.4 = 0.2 > 0. \quad (17.2.4)$$

La *causa general* es positiva: el medicamento aumenta la probabilidad de recuperación en la población. Sin embargo, para un paciente de Tipo B, el medicamento es la *causa singular* de su deterioro: $Y_1(u) = 0 \neq 1 = Y_0(u)$.

Este ejemplo ilustra que la causa singular no es reducible a la general: un efecto poblacional positivo es perfectamente compatible con daño individual en una fracción de pacientes.

La lista que sigue, adaptada de Pearl (2009, §7.2.3), presenta distintos enunciados causales junto con su semántica en términos de resultados potenciales $Y_{x(u)}$:

- **X es causa de Y** : existen $x \neq x'$ y una unidad u tal que $Y_{x(u)} \neq Y_{x'}(u)$.
- **X es causa directa de Y** : existen $x \neq x'$, una realización r de $V\{X, Y\}$, y una unidad u tal que $Y_{x,r}(u) \neq Y_{x',r}(u)$.
- **El evento $X = x$ puede haber causado $Y = y$** : $X(u) = x, Y(u) = y$, y existe u tal que $Y_{x'}(u) \neq y$ para algún $x' \neq x$.
- **$Y = y$ ocurrió a pesar de $X = x$** : $X(u) = x, Y(u) = y$, y $P(Y_{x'} = y)$ es baja; es decir, la intervención alternativa x' habría producido el resultado con alta probabilidad.

Estos enunciados no son equivalentes entre sí ni reducibles al lenguaje de probabilidades condicionales ordinarias. Cada uno requiere el vocabulario contrafactual de los resultados potenciales $Y_{x(u)}$.

17.3 El Problema de las Subpoblaciones Contrafactuales

Ante la brecha entre causa general y causa singular, los filósofos de la tradición probabilista intentaron un rescate: si la causalidad singular no puede reducirse directamente a probabilidades incondicionales, quizás pueda reducirse a probabilidades *condicionales* en la subpoblación correcta.

Definición 17.3 (Condición de Rescate Probabilista)

El evento C es causa de E si existe una partición $Z = z$ del espacio muestral tal que

$$P(E \mid C, Z = z) > P(E \mid C^c, Z = z). \quad (17.3.1)$$

La subpoblación $Z = z$ rescata la relación causal al eliminar la confusión de fondo.

La estrategia parece razonable, pero tropieza con dos dificultades insalvables que ilustran los siguientes ejemplos.

Ejemplo 17.2 (La vacuna que causa la enfermedad que previene)

Una vacuna V contra la gripe tiene los siguientes efectos en la población:

Subpoblación	$P(\text{Gripe} \mid V = 1)$	$P(\text{Gripe} \mid V = 0)$
Todos	0.05	0.20
Inmunosuprimidos	0.30	0.10

A nivel poblacional, la vacuna *reduce* la gripe ($0.05 < 0.20$): es una causa general negativa (preventiva). Sin embargo, en la subpoblación de pacientes inmunosuprimidos, la vacuna *aumenta* la gripe ($0.30 > 0.10$). Para un paciente inmunosuprimido que contrajo gripe tras vacunarse, la vacuna puede ser la causa singular de su enfermedad. El probabilismo no puede capturar esto sin invocar la subpoblación inmunosuprimido, que es precisamente el tipo de información que la causa singular requiere sobre la unidad i .

Ejemplo 17.3 (La píldora anticonceptiva de Hesslow)

Hesslow (1976) propone el siguiente escenario: la píldora anticonceptiva P aumenta el riesgo de trombosis T a través de mecanismos hormonales, pero también previene el embarazo E , que a su vez es un factor de riesgo aún mayor de trombosis. En la población total:

$$P(T = 1 \mid P = 1) < P(T = 1 \mid P = 0). \quad (17.3.2)$$

La píldora *reduce* la trombosis a nivel poblacional. Sin embargo, para una mujer que no habría quedado embarazada de todos modos (independientemente de la píldora), la toma de la píldora sí aumenta su riesgo de trombosis, y por tanto puede ser su causa singular.

La subpoblación rescatadora es mujeres que no habrían quedado embarazadas sin la píldora, definida en términos explícitamente contrafactuales: $E_0(u) = 0$. El probabilismo no escapa a los contrafactuales; simplemente los *oculta* dentro de la definición de la subpoblación de ajuste.

Teorema 17.1 (Inevitabilidad de los Contrafactuales para la Causa Singular)

No existe una partición $Z = z$ definida en términos puramente observacionales (es decir, sin invocar resultados potenciales $Y_{i(t)}$) que sea siempre suficiente para que la condición de rescate probabilista (Definición 227) coincida con la causa singular (Definición 225).

Este teorema establece que la causa singular no puede reducirse a causa general mediante ninguna partición observacional del espacio muestral. Cualquier intento de definir subpoblaciones “rescatadoras” en términos puramente observacionales termina presuponiendo los mismos contrafactuales que pretende evitar. Esto demuestra que

los contrafactuales son ontológicamente necesarios para la causalidad a nivel individual y justifica el andamiaje del SCM para abordar preguntas del Nivel 3 de la Escalera Causal.

La conclusión es que la causalidad singular requiere contrafactuales de manera ineludible, y los modelos estructurales (SCM) proveen precisamente el andamiaje formal para manejarlos de manera coherente y computacionalmente tratable.

17.4 El Contenido Empírico de un Contrafactual

Una objeción frecuente a los enunciados contrafactuales es epistemológica: ¿Cómo podemos verificar algo que no ocurrió? Un contrafactual que habla de lo que *hubiera pasado* parece condenado a ser irrefutable, y por tanto científicamente vacío.“ Esta sección desmonta esa objeción.

17.4.1 La Ley de Ohm como Caso Paradigmático

Considérese la Ley de Ohm, $V = IR$. Su contenido empírico puede codificarse de dos maneras:

1. **Forma predictiva:** Si en el instante t_0 medimos corriente I_0 y voltaje V_0 , entonces para cualquier instante futuro $t > t_0$, si la corriente es $I(t)$, el voltaje será $V(t) = \frac{V_0}{I_0} I(t)$, *ceteris paribus*.
2. **Forma contrafactual:** Si en el instante t_0 medimos corriente I_0 y voltaje V_0 , entonces, *de haber sido* la corriente I en lugar de I_0 , el voltaje habría sido $V = \frac{V_0}{I_0} I$.

Ambas formas tienen exactamente el mismo contenido empírico: a partir de una sola medición (I_0, V_0) , generan infinitas predicciones verificables. La forma contrafactual no es conjetural“ en ningún sentido que la predictiva no lo sea también.

Definición 17.4 (Invariantes de un Contrafactual)

Para que un enunciado contrafactual tenga contenido empírico verificable, deben permanecer invariantes dos componentes entre el mundo factual y el contrafactual:

1. Las **leyes o mecanismos** $\{f_i\}$ del modelo estructural: las ecuaciones que describen cómo operan los procesos del sistema.
2. Las **condiciones de frontera** U : los factores de fondo (variables exógenas) que no son directamente determinados por las intervenciones contempladas.

El contrafactual es empíricamente útil porque especifica implícitamente qué condiciones se mantienen (las del mundo factual) sin necesidad de enumerarlas.

Esta es la ventaja profunda de la notación contrafactual sobre la notación predictiva: no necesitamos especificar el *ceteris paribus* explícitamente porque el contrafactual lo codifica de forma implícita al anclar la situación hipotética al mismo conjunto U del mundo real.

17.4.2 Valor Predictivo versus Valor Explicativo

El contenido empírico de un contrafactual puede descomponerse en dos dimensiones:

- **Valor predictivo:** la capacidad del contrafactual de generar predicciones aplicables en situaciones futuras.
- **Valor explicativo:** la capacidad del contrafactual de revelar la política funcional $y = f(x, u)$ que rige el sistema.

Ejemplo 17.4 (La apuesta con moneda)

Apostamos cara o sello; ganamos un sol si acertamos y lo perdemos si fallamos. Apostamos cara y ganamos. Consideremos el contrafactual: De haber apostado sello, habría perdido un sol.”

- **Valor predictivo bajo:** Para que este contrafactual prediga que *la próxima* apuesta a sello resultará en derrota, necesitaríamos que el resultado de la moneda sea el mismo. Esto solo ocurre en circunstancias especiales (moneda física fija, conocimiento del resultado).
- **Valor explicativo alto:** El enunciado nos revela que el pagador tiene una política consistente — compara la apuesta con algún estándar y decide ganancia o pérdida coherentemente. Esta información es valiosa para un inspector del sistema, aunque no para el apostador común.

El valor explicativo del contrafactual no depende de su utilidad predictiva inmediata. Es útil porque revela la estructura de la función $f(x, u)$, lo cual habilita razonar sobre manipulaciones futuras del sistema.

La lección es que los contrafactuales tienen pleno contenido empírico; su verificabilidad” no requiere regresar al pasado sino aplicar los mismos mecanismos en situaciones futuras análogas, o razonar sobre qué predicciones se derivarían de alterar el sistema.

17.5 De la Explicación a la Causa: Enunciados Explicativos

La noción de explicación está íntimamente ligada a la causalidad, pero no son idénticas. Según la máxima clásica, un síntoma explica nuestra *creencia* en una enfermedad, pero no explica la enfermedad misma. Esta distinción tiene consecuencias computacionales directas.

17.5.1 Explicación General versus Explicación Singular

Definición 17.5 (Poder Explicativo Probabilístico)

Una medida probabilística del poder explicativo de C respecto de E es la razón de verosimilitud:

$$L(C \rightarrow E) = \frac{P(E \mid C)}{P(E \mid \neg C)}. \quad (17.5.1)$$

Esta medida tiene fallas conocidas: cualquier variable h con asociación espuria suficientemente alta con E puede superar en L a una causa genuina de E con efecto modesto. El problema es que L no captura la *fuerza de la conexión causal*, solo la asociación.

Definición 17.6 (Poder Explicativo Causal)

Una medida causal del poder explicativo de $X = x$ respecto de $Y = y$, dado que ambos han ocurrido, es la *probabilidad de necesidad*:

$$PN(x, y) = P(Y_{x'} \neq y \mid X = x, Y = y), \quad (17.5.2)$$

donde x' es el valor alternativo de X . Esta expresión es la probabilidad de que, de no haber ocurrido $X = x$, el resultado $Y = y$ no hubiera ocurrido.

La medida PN pertenece al Nivel 3 de la Escalera Causal: requiere probabilidades contrafactuales y, en general, información sobre los mecanismos $\{f_i\}$ del modelo estructural, no solo sobre la distribución observacional.

Ejemplo 17.5 (Discriminación de explicaciones con PN)

Considérese un paciente que recibió un medicamento ($X = 1$) y se recuperó ($Y = 1$). Tenemos dos candidatos explicativos: el medicamento X y el descanso D (que también ocurrió).

- Si $PN(X = 1, Y = 1) = 0.85$: con alta probabilidad, de no haber tomado el medicamento, no se habría recuperado. El medicamento es una explicación fuerte de la recuperación.
- Si $PN(D = 1, Y = 1) = 0.30$: incluso sin descanso, con probabilidad 0.70 se habría recuperado igualmente. El descanso es una explicación débil.

La razón de verosimilitud L podría favorecer a D si D y Y tienen alta asociación en la población (e.g., porque los pacientes que descansan son más jóvenes). La PN corrige esto al condicionar en la información individual $X = x, Y = y$, anclando el análisis al caso específico.

17.5.2 Clasificación Práctica: ¿Cuándo Usar Cada Tipo?

La distinción entre causa general y causa singular no es solo filosófica; tiene consecuencias para el diseño de políticas y el manejo de la responsabilidad:

- **Causa general (Nivel 2 de la Escalera Causal)**: adecuada para el *diseño de políticas poblacionales*. Si queremos decidir si financiar un programa de salud, la pregunta relevante es $P_{\text{do}(T=1)}(Y) - P_{\text{do}(T=0)}(Y)$. Basta con estudios observacionales bien diseñados o ensayos aleatorios.
- **Causa singular (Nivel 3 de la Escalera Causal)**: necesaria para *atribución de responsabilidad, litigios, medicina personalizada*. Si queremos determinar si el tabaquismo causó el cáncer de un individuo específico, necesitamos estimar $P(Y_{x'} \neq y \mid X = x, Y = y)$, lo que requiere un modelo estructural y supuestos sobre los mecanismos.

Jerarquía de preguntas causales

Nivel	Pregunta	Herramienta
1. Asociación	$P(Y X)$	Estadística descriptiva
2. Intervención	$P(Y \text{do}(X))$	Do-calculus, RCT
3. Contrafactuales	$P(Y_{x'} X = x', Y = y)$	SCM, abducción

Tabla 8: Jerarquía de preguntas causales de Pearl

17.6 El Ordenamiento Causal de Simon

Los capítulos anteriores han utilizado DAGs cuyas flechas se asumen como dadas por el analista. Surge entonces una pregunta fundamental: ¿de dónde provienen esas flechas? ¿Son una elección arbitraria del modelador o emergen de la estructura del problema? Herbert Simon (1953) ofreció una respuesta precisa a esta pregunta.

17.6.1 Ecuaciones Simétricas y Direcciones Causales

Los fenómenos naturales se describen frecuentemente mediante *restricciones simétricas* — ecuaciones que no privilegian ninguna variable como dependiente:

$$G_{k(x_1, \dots, x_l, u_1, \dots, u_m)} = 0, \quad k = 1, \dots, n. \quad (17.6.1)$$

En un circuito eléctrico, la Ley de Ohm $V - IR = 0$ no dice en sí misma si es la corriente la que determina el voltaje o viceversa. ¿Cómo emerge entonces la asimetría causal?

Definición 17.7 (Criterio de Ordenamiento de Simon)

Un sistema de ecuaciones simétricas $\{G_k\}$ admite una *dirección causal única* si y solo si existe una **correspondencia biunívoca** entre ecuaciones y variables dependientes, tal que cada ecuación puede resolverse para *exactamente una* variable, y esta correspondencia es *única*.

Formalmente: el problema de *matching* entre el conjunto de ecuaciones $\{G_k\}$ y el conjunto de variables endógenas V tiene una solución única. Esta correspondencia se determina por criterios puramente topológicos — cómo las variables están agrupadas en ecuaciones — y define una variable dependiente V_k para cada ecuación G_k .

Ejemplo 17.6 (El pelotón de fusilamiento revisitado)

El sistema del pelotón de fusilamiento (Pearl, 2009, §7.1.2) puede describirse mediante las siguientes restricciones simétricas:

$$\mathcal{S} = \{G_1(C, U), G_2(A, C), G_3(B, C), G_4(A, B, D)\}, \quad (17.6.2)$$

donde U es la orden del tribunal, C la señal del capitán, A el disparo del fusilero A, B el disparo del fusilero B y D la muerte del prisionero.

Aplicando el criterio de Simon:

- G_1 involucra solo $\{C, U\}$. Dado que U es exógeno, la única variable endógena es C . Matching: $G_1 \leftrightarrow C$.
- G_2 involucra $\{A, C\}$. Ya que C está asignada, la única libre es A . Matching: $G_2 \leftrightarrow A$.
- G_3 involucra $\{B, C\}$. Análogamente: $G_3 \leftrightarrow B$.
- G_4 involucra $\{A, B, D\}$. Con A y B asignadas, la única libre es D . Matching: $G_4 \leftrightarrow D$.

El matching es único, y el DAG resultante tiene las flechas $U \rightarrow C \rightarrow A \rightarrow D$, $C \rightarrow B \rightarrow D$, que coinciden exactamente con la intuición causal del problema. La direccionalidad causal *no fue impuesta* por el analista; emergió de la estructura de las restricciones.

DAG del pelotón de fusilamiento

$$U \rightarrow C \rightarrow A \rightarrow D$$

$$C \rightarrow B \rightarrow D$$

U = orden del tribunal, C = señal del capitán, A = disparo del fusilero A, B = disparo del fusilero B, D = muerte.

Figura 4: DAG del pelotón de fusilamiento (Pearl, 2009)

El criterio de Simon *falla* cuando el sistema de ecuaciones debe resolverse como un bloque, es decir, cuando no hay forma de separar las variables una a una. El caso canónico es el modelo de equilibrio económico:

Ejemplo 17.7 (Demanda y precio en equilibrio)

El sistema de ecuaciones de demanda y precio:

$$q = b_1 p + d_1 i + u_1 \quad (\text{ecuación de demanda}), \quad p = b_2 q + d_2 w + u_2 \quad (\text{ecuación de precio}) \quad (17.6.3)$$

debe resolverse simultáneamente para (q, p) . El matching entre ecuaciones y variables no es único: podría asignarse q a la primera ecuación y p a la segunda, o viceversa.

La dirección causal en este sistema *no emerge* de la estructura algebraica, sino del *conocimiento de materia*: sabemos que el ingreso del hogar i afecta directamente la demanda (no el precio), y que el salario w afecta directamente los costos de producción (no la demanda directa del consumidor). Es esta información la que clasifica la primera ecuación como ecuación de demanda y la segunda como ecuación de precio.

Teorema 17.2 (Simon (1953): Condición para la Causalidad Única)

Sea $\mathcal{S} = \{G_{k(V,U)} = 0\}_{k=1}^n$ un sistema de restricciones simétricas con variables endógenas V y variables exógenas U . Existe una dirección causal única (es decir, una asignación unívoca de variable dependiente a cada ecuación) si y solo si el problema de matching entre $\mathcal{S}$ y V tiene **solución única**. Cuando esta condición se satisface, la asignación produce un grafo acíclico dirigido (DAG) que representa unívocamente la estructura causal del sistema.

17.6.2 Implicaciones para el Analista

El resultado de Simon tiene dos consecuencias prácticas para quienes construyen DAGs:

1. **Las flechas no son arbitrarias.** Cuando el matching es único, las flechas del DAG están determinadas por la estructura mecánica del problema, no por preferencias del analista. Esto da una justificación objetiva a la asimetría causal.
2. **Cuando el matching no es único, se requiere conocimiento de materia.** En sistemas con bucles de retroalimentación o ecuaciones simultáneas (como el modelo demanda-precio), la dirección causal requiere información sobre qué variables son instrumentos independientes³ y cuáles son resultantes⁴. Esta información no puede extraerse de los datos; debe ser provista por el analista a partir de su comprensión del dominio.

La conexión con los capítulos anteriores es directa: el do-calculus opera sobre DAGs cuyas flechas se asumen dadas. El criterio de Simon muestra que esta asunción no es arbitraria — en la mayoría de los sistemas físicos y sociales bien especificados, las flechas emergen de la estructura de los mecanismos, y solo en casos de ecuaciones simultáneas requieren juicio experto adicional.

17.7 Síntesis: La Jerarquía de Preguntas Causales Revisitada

Este capítulo ha añadido una dimensión adicional a la Escalera Causal de Pearl (ver Capítulo 1):

La causa general (Nivel 2) requiere el do-calculus y es el objeto de los capítulos 15–18. La causa singular (Nivel 3) requiere adicionalmente las probabilidades de necesidad y suficiencia, y será el objeto del capítulo siguiente.

El ordenamiento de Simon cierra el círculo: explica de dónde vienen los mecanismos $\{f_i\}$ y las flechas del DAG que constituyen el punto de partida de toda la maquinaria desarrollada en este curso.

17.8 Síntesis del Capítulo

- La **causa general** se define como $P_{\text{do}(x)}(Y) \neq P_{\text{do}(x')}(Y)$ y describe el efecto de una intervención a nivel poblacional; es el objeto del do-calculus y estimable desde datos observacionales con supuestos adecuados.
- La **causa singular** se define mediante resultados potenciales: $Y_{x(u)} = y \wedge Y_{x'}(u) \neq y$, y atribuye responsabilidad a un evento en una unidad específica; requiere modelos estructurales con información funcional.
- La causa singular **no es reducible** a la causa general: un efecto poblacional positivo es compatible con daño individual en subgrupos de pacientes.
- El intento probabilista de rescatar la causa singular mediante subpoblaciones condicionales **fracasa**: las subpoblaciones rescatadoras son definidas en vocabulario contrafactual, no observacional. Los contrafactuales son **ineludibles** para la causalidad singular.

- Los **contrafactuales tienen pleno contenido empírico**: son equivalentes a enunciados predictivos que generan infinitas predicciones a partir de una sola medición, siempre que los mecanismos $\{f_i\}$ y las condiciones de frontera U permanezcan invariantes.
- El **poder explicativo causal** se mide con la probabilidad de necesidad PN, que requiere información del Nivel 3 y captura la fuerza de la conexión causal individual, a diferencia de la razón de verosimilitud probabilística.
- El **ordenamiento de Simon** muestra que las flechas de un DAG no son arbitrarias: en sistemas con correspondencia biunívoca entre ecuaciones y variables, la dirección causal emerge unívocamente de la estructura mecánica; en sistemas simultáneos, requiere conocimiento de materia.
- La distinción singular/general tiene consecuencias prácticas directas: *políticas públicas* requieren causa general; *litigios, medicina personalizada y atribución* requieren causa singular.

DoWhy traduce la teoría del do-calculus a la práctica computacional, mostrando cómo identificar automáticamente efectos causales generales en grafos complejos.

Supuestos clave

Supuestos del Capítulo 17 (La Naturaleza de las Causas)

1. **Autonomía de mecanismos**: Cada ecuación estructural f_i representa un proceso físico o social independiente, modificable en principio sin alterar los demás. Este supuesto es necesario para que la distinción singular/general sea coherente: sin autonomía, el resultado potencial $Y_{x(u)}$ no estaría bien definido, pues una intervención sobre X podría alterar todos los mecanismos simultáneamente.
2. **Persistencia de U** : Las variables exógenas (de fondo) U permanecen constantes entre el mundo factual y el hipotético del contrafactual. Esta condición es necesaria para que un enunciado contrafactual tenga contenido empírico verificable (Definición Definición 231). En fenómenos cuánticos donde U se renueva en cada instante, los contrafactuales pierden utilidad predictiva aunque mantienen valor explicativo.
3. **Recursividad del sistema**: El sistema causal es acíclico (recursivo), lo que garantiza que el problema de matching de Simon produzca un DAG sin ciclos y que los resultados potenciales $Y_{x(u)}$ tengan solución única. En sistemas con retroalimentación, se requieren modelos dinámicos o la condición de reversibilidad (Pearl, 2009, §7.3).

Otras referencias clave de este capítulo: (Simon, 1953), (Eells, 1991), (Cartwright, 1989), (Lewis, 1973), (Galles & Pearl, 1997), (Rubin, 1974).

17.8 Referencias

Cartwright, N. (1989). *Nature's Capacities and Their Measurement*. Clarendon Press.

Eells, E. (1991). *Probabilistic Causality*. Cambridge University Press.

Galles, D., & Pearl, J. (1997). An Axiomatic Characterization of Causal Counterfactuals. *Foundations of Science*, 3(1), 151-182.

Hesslow, G. (1976). Two Notes on the Probabilistic Approach to Causality. *Philosophy of Science*, 43(2), 290-292.

Lewis, D. (1973). Causation. *Journal of Philosophy*, 70(17), 556-567.

Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.

Rubin, D. B. (1974). Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies. *Journal of Educational Psychology*, 66(5), 688-701.

Simon, H. A. (1953). Causal Ordering and Identifiability. En W. C. Hood & T. C. Koopmans (eds.), *Studies in Econometric Method: Studies in Econometric Method* (pp. 49-74). Wiley.

CAPÍTULO 18

Do-Calculus: El Sistema Axiomático de la Causalidad

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque II · Semilla 42**Notebook (pack):** notebooks/Bloque_II/notebooks/18_do_calculus_sistema_axiomatico_causalidad.ipynb**Jupyter Book:** jupyter_book/content/bloque_02_formalizacion/18_do_calculus.ipynb

Los criterios backdoor y frontdoor resuelven casos particulares. Pero, ¿existe un sistema general que nos diga, para *cualquier* grafo causal, si un efecto $P_{\text{do}(T)}(Y)$ es identificable y cómo expresarlo en términos observacionales? La respuesta es afirmativa: el **do-calculus**, introducido por Pearl (1995) y completado por Shpitser & Pearl (2006).

El do-calculus es un sistema de tres reglas de inferencia que gobiernan la relación entre distribuciones observacionales e intervencionales. Su belleza radica en que reduce la identificabilidad causal a un problema puramente *sintáctico* sobre grafos.

18.1 Motivación: Más Allá del Backdoor y Frontdoor

Considérese el DAG de la Figura 1, donde U_1 y U_2 son confusores no observados y M es un mediador:




Figura 5: DAG con confusores no observados y mediador

Ni el criterio backdoor (porque U_1, U_2 no son observados) ni el frontdoor (el camino $T \rightarrow Y$ no pasa por M) se aplican directamente. Sin embargo, el efecto $P_{\text{do}(T)}(Y)$ es identificable, y el do-calculus lo demuestra.

18.2 Notación y Grafos Mutilados

Definición 18.1 (Grafo mutilado)

Dado un DAG $\mathcal{G}$, el *grafo mutilado* $\mathcal{G}_{\overline{X}}$ se obtiene eliminando de $\mathcal{G}$ todas las aristas **entrantes** a las variables en X . Análogamente, $\mathcal{G}_{\underline{X}}$ se obtiene eliminando todas las aristas **salientes** de X .

La notación compuesta $\mathcal{G}_{\overline{X}\underline{Z}}$ denota la eliminación simultánea de aristas entrantes a X y salientes de Z . Esta operación de mutilación es la contraparte gráfica de la intervención $\text{do}(X)$.

Definición 18.2 (d-separación en grafos mutilados)

Escribimos $(Y \perp\!\!\!\perp_d Z \mid X, W)_{\mathcal{G}_{\overline{XZ}}}$ para denotar que Y está d-separada de Z dadas X, W en el grafo $\mathcal{G}_{\overline{XZ}}$.

18.3 Las Tres Reglas del Do-Calculus

Teorema 18.1 (Regla 1: Inserción/eliminación de observaciones)

Sea $\mathcal{G}$ el DAG causal. Si $Y \perp\!\!\!\perp_d Z \mid X, W$ en $\mathcal{G}_{\overline{X}}$, entonces:

$$P_{\text{do}(x)}(y \mid z, w) = P_{\text{do}(x)}(y \mid w). \quad (18.3.1)$$

Intuitivamente, la Regla 1 dice que si Z no aporta información sobre Y una vez que conocemos X y W en el mundo intervenido, entonces condicionar en Z es irrelevante.

Teorema 18.2 (Regla 2: Intercambio acción/observación)

Si $Y \perp\!\!\!\perp_d Z \mid X, W$ en $\mathcal{G}_{\overline{XZ}}$, entonces:

$$P_{\text{do}(x), \text{do}(z)}(y \mid w) = P_{\text{do}(x)}(y \mid z, w). \quad (18.3.2)$$

Intuitivamente, la Regla 2 dice que al eliminar el efecto causal de Z sobre Y , intervenir sobre Z equivale a simplemente condicionar en su valor observado.

Teorema 18.3 (Regla 3: Inserción/eliminación de intervenciones)

Si $Y \perp\!\!\!\perp_d Z \mid X, W$ en $\mathcal{G}_{\overline{X, Z(W)}}$, donde $Z(W)$ es el conjunto de nodos en Z que no son ancestros de W en $\mathcal{G}_{\overline{X}}$, entonces:

$$P_{\text{do}(x), \text{do}(z)}(y \mid w) = P_{\text{do}(x)}(y \mid w). \quad (18.3.3)$$

Intuitivamente, la Regla 3 dice que si el efecto de Z sobre Y está completamente mediado por W , intervenir sobre Z no altera la distribución de Y dado W .

18.4 Ejemplos de Aplicación

Ejemplo 18.1 (Derivación de la fórmula backdoor)

Considérese $\mathcal{G}: Z \rightarrow T, Z \rightarrow Y, T \rightarrow Y$. Queremos identificar $P_{\text{do}(t)}(y)$.

1. **Paso 1:** $P_{\text{do}(t)}(y) = \sum_z P_{\text{do}(t)}(y \mid z) P_{\text{do}(t)}(z)$ (probabilidad total).
2. **Paso 2:** Por la Regla 2, ¿podemos intercambiar $\text{do}(t)$ por t en $P_{\text{do}(t)}(y \mid z)$? Verifiquemos: en $\mathcal{G}_{\overline{T}}$, T e Y están d-separados por Z (el camino $T \leftarrow Z \rightarrow Y$ se bloquea condicionando en Z). Entonces $P_{\text{do}(t)}(y \mid z) = P(y \mid t, z)$.
3. **Paso 3:** Por la Regla 3, $P_{\text{do}(t)}(z) = P(z)$, pues T no es ancestro de Z en $\mathcal{G}_{\overline{T}}$ (de hecho, Z es ancestro de T). Verifiquemos: en $\mathcal{G}_{\overline{T}}$, $Z \perp\!\!\!\perp_d T$, luego $P_{\text{do}(t)}(z) = P(z)$.
4. **Conclusión:** $P_{\text{do}(t)}(y) = \sum_z P(y \mid t, z) P(z)$.

Esta es exactamente la fórmula de ajuste backdoor.

Ejemplo 18.2 (Derivación de la fórmula frontdoor)

Considérese el DAG del tabaco: $U \rightarrow T$, $U \rightarrow Y$, $T \rightarrow M$, $M \rightarrow Y$, con U no observado. El efecto $P_{\text{do}(t)}(y)$ se deriva así:

1. $P_{\text{do}(t)}(y) = \sum_m P_{\text{do}(t)}(y | m) P_{\text{do}(t)}(m)$.
2. Para $P_{\text{do}(t)}(m)$: en $\mathcal{G}_{\underline{T}}$, no hay caminos de puerta trasera de T a M (el único camino $T \leftarrow U \rightarrow Y \leftarrow M$ está bloqueado por el colisionador Y). Regla 2 da $P_{\text{do}(t)}(m) = P(m | t)$.
3. Para $P_{\text{do}(t)}(y | m)$: aplíquese $P_{\text{do}(t)}(y | m) = \sum_{t'} P_{\text{do}(t)}(y | t', m) P_{\text{do}(t)}(t' | m)$. Por la Regla 2 en $\mathcal{G}_{\overline{T\overline{T}}}$, $P_{\text{do}(t)}(y | t', m) = P(y | t', m)$. Por la Regla 3, $P_{\text{do}(t)}(t' | m) = P(t')$ (pues T y T' son independientes bajo la intervención y no hay confusión).
4. **Conclusión:** $P_{\text{do}(t)}(y) = \sum_m P(m | t) \sum_{t'} P(y | t', m) P(t')$.

18.5 Completitud del Do-Calculus

Teorema 18.4 (Completitud del Do-Calculus, Shpitser & Pearl 2006)

Sea $\mathcal{G}$ un DAG causal y $P(V)$ una distribución positiva sobre las variables observadas V . Si el efecto causal $P_{\text{do}(X)}(Y)$ es identificable a partir de $P(V)$, entonces existe una secuencia finita de aplicaciones de las tres reglas del do-calculus que transforma $P_{\text{do}(X)}(Y)$ en una expresión libre del operador $\text{do}(\cdot)$.

Este resultado es fundamental: establece que el do-calculus no es meramente una herramienta útil sino un sistema **completo**. No existe ningún efecto identificable que no pueda derivarse con estas tres reglas. La demostración de Shpitser & Pearl (2006) es constructiva: usa el Algoritmo ID y la noción de *hedge* para caracterizar precisamente cuándo un efecto no es identificable, algoritmo que se presenta a continuación.

18.6 El Algoritmo ID

Método 18.1 (Algoritmo ID (Shpitser & Pearl, 2006))

Dado un DAG $\mathcal{G}$ y una consulta causal $P_{\text{do}(X)}(Y)$, el algoritmo ID procede recursivamente:

1. Si $X = \emptyset$, devolver $P(Y)$ (identidad).
2. Si existe $v \in V(X \cup Y)$ tal que eliminar v del problema reduce la dimensionalidad, aplicar marginalización.
3. Si Y puede particionarse según componentes conexas en $\mathcal{G}_{\overline{X}}$, aplicar factorización.
4. Aplicar la regla del do-calculus que corresponda según la estructura de independencias en los grafos mutilados.
5. Si ninguna regla se aplica, el efecto es **no identificable**.

La implementación del Algoritmo ID se encuentra en la librería DoWhy (Python) y en *causaleffect* (R), lo que permite automatizar la derivación de fórmulas de identificación para grafos complejos.

18.7 Identificabilidad vs. No-Identificabilidad

Definición 18.3 (Efecto no identificable)

Un efecto causal $P_{\text{do}(X)}(Y)$ es *no identificable* desde $P(V)$ en $\mathcal{G}$ si existen dos SCMs compatibles con $\mathcal{G}$ que inducen la misma distribución observacional $P(V)$ pero diferentes distribuciones intervencionales $P_{\text{do}(X)}(Y)$.

Ejemplo 18.3 (El grafo de la cucharita“ (bow-free graph))

El caso más simple de no-identificabilidad es el grafo con arco bidireccional: $T \leftrightarrow Y$, que representa un confusor no observado U que afecta directamente tanto a T como a Y , **sin** mediadores observados:

Grafo bow-free (cucharita)

$$T \leftrightarrow Y$$

Arco bidireccional: confusor no observado U afecta T e Y directamente.

Figura 6: Grafo bow-free: no-identificabilidad por confusor no observado

En este grafo, el Algoritmo ID no puede eliminar el operador $\text{do}(T)$. Ningún conjunto observado bloquea la puerta trasera porque la variable de confusión no es observada, y no existe un mediador que permita aplicar el criterio frontdoor. El efecto $P_{\text{do}(T)}(Y)$ es **no identificable**.

18.8 Construcción de Fórmulas de Identificación

Las tres reglas se aplican iterativamente sobre una expresión objetivo. El procedimiento general es:

1. **Expansión:** Introducir variables mediante la regla de la probabilidad total: $P_{\text{do}(x)}(y) = \sum_z P_{\text{do}(x)}(y | z) P_{\text{do}(x)}(z)$.
2. **Eliminación de do :** Aplicar la Regla 2 para reemplazar $\text{do}(x)$ por x cuando la d-separación lo permita.
3. **Simplificación:** Aplicar las Reglas 1 y 3 para eliminar condicionamientos y $\text{do}(\cdot)$ superfluos.
4. **Iteración:** Repetir hasta obtener una expresión libre del operador $\text{do}(\cdot)$.

Este proceso es mecánico y ha sido completamente automatizado. El software DoWhy implementa este procedimiento para la identificación automática de efectos causales.

18.9 Síntesis del Capítulo

- El **do-calculus** es un sistema axiomático de tres reglas que gobierna la transformación de expresiones intervencionales en observacionales.
- La **Regla 1** permite insertar o eliminar observaciones cuando existe d-separación condicional bajo la intervención.
- La **Regla 2** permite intercambiar una intervención por una observación cuando la variable intervenida ha perdido su efecto causal residual sobre la respuesta.
- La **Regla 3** permite eliminar intervenciones cuando su efecto está completamente mediado por las variables de condicionamiento.
- El **Teorema de Completitud** (Shpitser & Pearl, 2006) garantiza que toda fórmula de identificación puede derivarse con estas tres reglas.
- El **Algoritmo ID** implementa la derivación de manera automática y constituye el núcleo computacional de la identificabilidad causal moderna.

- La presencia de **confusores no observados sin mediadores** (grafos tipo *bow*) produce efectos no identificables.

DoWhy traduce esta teoría a la práctica computacional, mostrando cómo el do-calculus se aplica automáticamente para identificar efectos causales en programas reales de política pública.

Otras referencias clave de este capítulo: (Pearl, 2009), (Huang & Valtorta, 2006), (Bareinboim & Pearl, 2016).

18.9 Referencias

Bareinboim, E., & Pearl, J. (2016). Causal Inference and the Data-Fusion Problem. *Proceedings of the National Academy of Sciences*, 113(27), 7345-7352.

Huang, Y., & Valtorta, M. (2006). Pearl's Calculus of Intervention is Complete. *Proceedings of the 22nd Conference on Uncertainty in Artificial Intelligence (UAI-06)*, 217-224.

Pearl, J. (1995). Causal Diagrams for Empirical Research. *Biometrika*, 82(4), 669-688.

Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.

Shpitser, I., & Pearl, J. (2006). Identification of Joint Interventional Distributions in Recursive Semi-Markovian Causal Models. *Proceedings of the 21st National Conference on Artificial Intelligence (AAAI 2006)*, 1219-1226.

CAPÍTULO 19

Contrafactuales: El Tercer Nivel de la Escalera

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque II · Semilla 42**Notebook (pack):** notebooks/Bloque_II/notebooks/19_contrafactuales_tercer_nivel_escalera.ipynb**Jupyter Book:** jupyter_book/content/bloque_02_formalizacion/19_contrafactuales.ipynb

Hasta ahora hemos operado en los primeros dos niveles de la Escalera Causal de Pearl: el Nivel 1 (Asociación: $P(Y | T)$) y el Nivel 2 (Intervención: $P_{\text{do}(T)}(Y)$). El Nivel 3 — el pináculo de la pirámide — aborda preguntas **contrafactuales**: ¿qué habría ocurrido con esta unidad específica si hubiéramos actuado de manera diferente?

Las preguntas contrafactuales son ubicuas en la práctica:

- ¿Fue la vacuna la causa de la reacción adversa en *este* paciente?
- ¿Habría aprobado *este* estudiante el examen sin la tutoría?
- ¿Cuánto del crecimiento económico perdido es atribuible a la pandemia?

A diferencia de las preguntas del Nivel 2 (efectos promedio poblacionales), las del Nivel 3 requieren razonar sobre **unidades individuales** y comparar el hecho observado con el escenario hipotético no-observado.

19.1 Resultados Potenciales y el SCM

Definición 19.1 (Resultado potencial $Y_{t(u)}$)

Sea $\mathcal{M}$ un SCM. Para una unidad u (caracterizada por la realización $U = u$ de las variables exógenas), el **resultado potencial** $Y_{t(u)}$ es el valor que la variable endógena Y toma en el submodelo mutilado $\mathcal{M}_{\text{do}(T=t)}$:

$$Y_{t(u)} \equiv Y_{\mathcal{M}_{\text{do}(T=t)}}(u). \quad (19.1.1)$$

Esta definición conecta directamente los resultados potenciales del marco de Rubin con el SCM de Pearl. La diferencia crucial es que en el SCM, $Y_{t(u)}$ se *calcula* a partir de las ecuaciones estructurales y la realización de U , mientras que en el marco de Rubin, $Y_{t(u)}$ es una variable primitiva.

Definición 19.2 (Efecto Individual del Tratamiento (ITE))

Para una unidad u , el **Efecto Individual del Tratamiento (ITE)** es:

$$\tau(u) = Y_1(u) - Y_0(u). \quad (19.1.2)$$

El ITE es la diferencia entre el resultado bajo tratamiento y el resultado bajo control para *la misma* unidad.

19.2 El Problema Fundamental de la Inferencia Causal

Principio 19.1 (Problema Fundamental de la Inferencia Causal)

Para cualquier unidad u , solo uno de los dos resultados potenciales $Y_1(u)$ y $Y_0(u)$ es observado. El otro es **contrafactual** e irremediablemente inobservable.

Esta imposibilidad lógica — no podemos observar simultáneamente los dos mundos hipotéticos — es lo que Holland (1986) denominó el *Problema Fundamental de la Inferencia Causal*. Toda la maquinaria de la inferencia causal (aleatorización, ajuste, do-calculus, variables instrumentales) puede entenderse como estrategias para sortear este obstáculo y recuperar, al menos en valor esperado, la distribución de los contrafactuales.

19.3 El Procedimiento Abducción-Acción-Predicción

Aunque el contrafactual es inobservable, el SCM permite *acotarlo* probabilísticamente mediante el procedimiento de tres pasos conocido como **Abducción-Acción-Predicción** (Pearl, 2009):

Método 19.1 (Abducción-Acción-Predicción para Contrafactuales)

Dado un SCM $\mathcal{M}$, evidencia observacional $E = e$ (valores de algunas variables endógenas), y una consulta contrafactual de la forma ¿cuál sería el valor de Y si hubiésemos fijado $T = t'$?:

1. **Abducción:** Actualizar la distribución de las variables exógenas U condicionando en la evidencia: calcular $P(U \mid E = e)$. Este paso infiere “el estado latente del mundo que explica lo observado.
2. **Acción:** Modificar el SCM reemplazando la ecuación estructural de T por $T = t'$ (mutilación), obteniendo el submodelo $\mathcal{M}_{\text{do}(T=t')}$.
3. **Predicción:** Propagar la distribución actualizada $P(U \mid E = e)$ a través del submodelo mutilado $\mathcal{M}_{\text{do}(T=t')}$ para calcular $P\left(Y_{\mathcal{M}_{\text{do}(T=t')}} \mid E = e\right)$, es decir, la distribución del resultado contrafactual.

Ejemplo 19.1 (Contrafactual en un modelo lineal simple)

Considérese el SCM lineal:

$$T = \alpha_T + \beta_T U + \epsilon_T, Y = \alpha_Y + \tau T + \beta_Y U + \epsilon_Y, \quad (19.3.1)$$

con $U \sim \mathcal{N}(0, 1)$, $\epsilon_T, \epsilon_Y \sim \mathcal{N}(0, \sigma^2)$ independientes. Observamos $(T = t_{\text{obs}}, Y = y_{\text{obs}})$ para una unidad.

La consulta contrafactual es: ¿qué valor habría tomado Y si T se hubiera fijado a t' ?

1. **Abducción:** De la ecuación de T , $u_{\text{est}} = \frac{t_{\text{obs}} - \alpha_T}{\beta_T}$ (ignorando ϵ_T por simplicidad). Esta es la mejor estimación del estado latente U que explica $T = t_{\text{obs}}$.
2. **Acción:** Mutilamos $\mathcal{M}$ fijando $T = t'$.
3. **Predicción:** $Y_{t'}(u_{\text{est}}) = \alpha_Y + \tau t' + \beta_Y u_{\text{est}}$. El ITE estimado es $\hat{\tau}(u) = \tau \cdot (1 - 0) + \beta_{Y(0)} = \tau$, que coincide con el ATE bajo linealidad.

En este modelo simple, el ITE es constante (τ). Pero en modelos no lineales o con heterogeneidad en U , el ITE varía entre unidades, y el procedimiento AAP captura precisamente esta variación.

19.4 Probabilidades de Necesidad y Suficiencia

En el Nivel 3, las preguntas trascienden el efecto promedio y se adentran en la **atribución causal**. Las tres probabilidades canónicas son:

Definición 19.3 (Probabilidad de Suficiencia (PS))

La **Probabilidad de Suficiencia** de T para Y es la probabilidad de que una unidad que no recibió el tratamiento ($T = 0$) y no experimentó el resultado ($Y = 0$) *habría* experimentado $Y = 1$ si hubiera recibido $T = 1$:

$$PS = P(Y_1 = 1 \mid T = 0, Y = 0). \quad (19.4.1)$$

Definición 19.4 (Probabilidad de Necesidad (PN))

La **Probabilidad de Necesidad** de T para Y es la probabilidad de que una unidad que recibió el tratamiento ($T = 1$) y experimentó el resultado ($Y = 1$) *no* lo habría experimentado sin tratamiento:

$$PN = P(Y_0 = 0 \mid T = 1, Y = 1). \quad (19.4.2)$$

Definición 19.5 (Probabilidad de Necesidad y Suficiencia (PNS))

La **Probabilidad de Necesidad y Suficiencia** es la probabilidad conjunta de que $T = 1$ sea necesario y suficiente para $Y = 1$:

$$PNS = P(Y_1 = 1, Y_0 = 0). \quad (19.4.3)$$

Estas definiciones son fundamentales para aplicaciones como la atribución de responsabilidad en derecho, la evaluación de reacciones adversas a medicamentos, y la personalización de tratamientos.

Teorema 19.1 (Descomposición de la PNS)

Bajo la condición de monotonía $Y_1(u) \geq Y_0(u)$ para todo u ,

$$PNS = P(Y = 1 \mid T = 1) - P(Y = 1 \mid T = 0). \quad (19.4.4)$$

En este caso, la PNS coincide con el ATE en escala de diferencia de riesgos si T es aleatorizado.

Ejemplo 19.2 (Cálculo de PN para un fármaco)

Un ensayo clínico con T = fármaco vs. placebo, Y = recuperación. Datos: $P(Y = 1 \mid T = 1) = 0.70$, $P(Y = 1 \mid T = 0) = 0.50$.

La Probabilidad de Necesidad es:

$$PN = \frac{P(Y = 1 \mid T = 1) - P(Y = 1 \mid T = 0)}{P(Y = 1 \mid T = 1)} = \frac{0.70 - 0.50}{0.70} = 0.286. \quad (19.4.5)$$

De cada 100 pacientes tratados que se recuperaron, aproximadamente 29 no se habrían recuperado sin el fármaco. Los 71 restantes se habrían recuperado espontáneamente. Esta información es crucial para la decisión clínica individualizada y la atribución de responsabilidad en farmacovigilancia.

19.5 Contrafactuales en el Contexto del Do-Calculus

Las tres probabilidades (PS, PN, PNS) pueden expresarse en términos de distribuciones intervencionales y, bajo ciertas condiciones, identificarse mediante el do-calculus:

$$\begin{aligned}
 \text{PN} &= \frac{P(Y = 1) - P_{\text{do}(T=0)}(Y = 1)}{P(T = 1, Y = 1)}, \\
 \text{PS} &= \frac{P_{\text{do}(T=1)}(Y = 1) - P(Y = 1)}{P(T = 0, Y = 0)}, \\
 \text{PNS} &= P_{\text{do}(T=1)}(Y = 1) - P_{\text{do}(T=0)}(Y = 1).
 \end{aligned} \tag{19.5.1}$$

Relación entre PN, PS y PNS

PN	Probabilidad de Necesidad: ¿ $T = 1$ causó $Y = 1$?
PS	Probabilidad de Suficiencia: ¿ $T = 1$ produciría $Y = 1$?
PNS	Probabilidad de Necesidad y Suficiencia

Tabla 9: Medidas de atribución causal: PN, PS y PNS

El tránsito del Nivel 2 al Nivel 3 requiere el SCM completo o, equivalentemente, la distribución conjunta de los resultados potenciales, no solo sus marginales.

19.6 Limitaciones de los Contrafactuales Individuales

Aunque conceptualmente poderosos, los contrafactuales individuales tienen limitaciones importantes:

1. **No verificabilidad:** El ITE nunca es directamente observable; su estimación depende crucialmente de la correcta especificación del SCM y de la distribución $P(U)$.
2. **Sensibilidad a $P(U)$:** En modelos no lineales, la inferencia contrafactual es altamente sensible a supuestos sobre la distribución y dimensionalidad de U .
3. **Identificabilidad parcial:** Sin supuestos adicionales (monotonía, independencia condicional), PS, PN y PNS solo son identificables en sus cotas.

19.7 Síntesis del Capítulo

- El **Nivel 3** de la Escalera Causal aborda preguntas sobre unidades individuales: ¿qué habría ocurrido si...?
- El **resultado potencial** $Y_{t(u)}$ es el valor que Y toma en el submodelo mutilado $\mathcal{M}_{\text{do}(T=t)}$ para la unidad u .
- El **Problema Fundamental de la Inferencia Causal** es que solo uno de los dos resultados potenciales es observable; el otro es contrafactual.
- El procedimiento de **Abducción-Acción-Predicción** permite calcular distribuciones contrafactuales a partir del SCM: (1) inferir U | evidencia, (2) mutilar T , (3) propagar.
- Las **probabilidades de necesidad y suficiencia** (PN, PS, PNS) cuantifican la atribución causal a nivel individual y tienen aplicaciones en derecho, medicina personalizada y evaluación de políticas.
- La **PNS** bajo monotonía coincide con el ATE; sin monotonía, está acotada por el ATE y la probabilidad de prevención.

El Capítulo 19 cierra el Bloque II (formalización) integrando resultados potenciales, SCM y do-cálculo en el estrato contrafactual, y deja preparado el paso al Bloque III (descubrimiento y ML causal).

Supuestos clave**Supuestos del Capítulo 19 (Contrafactuales)**

1. **SCM completamente especificado:** Para inferencia contrafactual individual, se requiere el SCM completo, incluyendo la distribución conjunta $P(U)$ de las variables exógenas. Sin $P(U)$, solo son posibles cotas.
2. **Monotonía (para PNS puntual):** $Y_1(u) \geq Y_0(u)$ para todo u (o la desigualdad inversa). Este supuesto descarta la existencia de unidades para las que el tratamiento es preventivo.
3. **Independencia condicional (para PN/PS):** Las distribuciones intervencionales $P_{\text{do}(T=t)}(Y)$ deben ser identificables mediante los métodos del Nivel 2 (backdoor, frontdoor, do-calculus).
4. **Exogeneidad de U :** Las variables exógenas U son independientes entre sí; de lo contrario, la abducción requiere modelar la dependencia conjunta.

Otras referencias clave de este capítulo: (Pearl, 2009), (Rubin, 1974), (Tian & Pearl, 2000), (Bareinboim & Pearl, 2016).

19.7 Referencias

- Bareinboim, E., & Pearl, J. (2016). Causal Inference and the Data-Fusion Problem. *Proceedings of the National Academy of Sciences*, 113(27), 7345-7352.
- Holland, P. W. (1986). Statistics and Causal Inference. *Journal of the American Statistical Association*, 81(396), 945-960.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Rubin, D. B. (1974). Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies. *Journal of Educational Psychology*, 66(5), 688-701.
- Tian, J., & Pearl, J. (2000). Probabilities of Causation: Bounds and Identification. *Annals of Mathematics and Artificial Intelligence*, 28, 287-313.

CAPÍTULO 20

Descubrimiento Causal: Flujo de Trabajo Completo

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque III · Semilla 42

Notebook (pack): notebooks/Bloque_III/notebooks/20_descubrimiento_causal_flujo_trabajo_restricciones.ipynb

Jupyter Book: jupyter_book/content/bloque_03_descubrimiento_ml/20_descubrimiento_causal.ipynb

El Bloque II asumió que conocíamos el DAG. Pero en la práctica, el grafo causal rara vez se conoce con certeza. El **descubrimiento causal** (causal discovery) aborda la pregunta inversa: dados solo datos observacionales $\mathcal{D} = \{X_i\}_{i=1}^n$ con $X \in \mathbb{R}^d$, ¿podemos recuperar (total o parcialmente) la estructura del DAG subyacente?

Este capítulo presenta los fundamentos teóricos y los algoritmos principales de descubrimiento causal, desde los tests de independencia condicional hasta la optimización continua.

20.1 Fundamentos del Descubrimiento Causal

20.1.1 La Condición de Markov Causal

Definición 20.1 (Condición de Markov Causal)

Sea $\mathcal{G} = (\mathbf{V}, \mathbf{E})$ un DAG y P una distribución de probabilidad sobre $\mathbf{V}$. Decimos que P satisface la *condición de Markov causal* respecto a $\mathcal{G}$ si para toda variable $V_i \in \mathbf{V}$:

$$V_i \perp\!\!\!\perp \text{ND}(V_i) \mid \text{Pa}(V_i), \quad (20.1.1)$$

donde $\text{ND}(V_i)$ denota el conjunto de **no-descendientes** de V_i (excluyendo sus padres) y $\text{Pa}(V_i)$ es el conjunto de padres de V_i en $\mathcal{G}$.

Esta condición es la *piedra angular* del descubrimiento causal: cada variable es condicionalmente independiente de sus no-descendientes (excluyendo padres) dados sus padres directos. En un SCM con errores independientes, la condición de Markov se satisface automáticamente.

20.1.2 Fidelidad (Faithfulness)

Definición 20.2 (Fidelidad)

Una distribución P es *fiel* (faithful) al DAG $\mathcal{G}$ si toda independencia condicional presente en P está **implicada** por la estructura de d-separación de $\mathcal{G}$. Equivalentemente: si $X \perp\!\!\!\perp Y \mid Z$ en P , entonces Z d-separa X de Y en $\mathcal{G}$.

La fidelidad excluye cancelaciones fortuitas de parámetros que produzcan independencias no codificadas en el grafo. Bajo Markov y fidelidad, las independencias condicionales en los datos **caracterizan** las d-separaciones del DAG.

Observación 20.1 (Violaciones de fidelidad)

La fidelidad puede fallar, por ejemplo, cuando dos caminos causales se cancelan exactamente: $T \xrightarrow{+\beta} M \xrightarrow{+\gamma} Y$ y $T \xrightarrow{-\beta} Y$ producen $T \perp\!\!\!\perp Y$ en los datos aunque no hay d-separación. Tales cancelaciones exactas tienen medida de Lebesgue cero en el espacio de parámetros.

20.2 Algoritmos Basados en Restricciones (Constraint-based)

20.2.1 El Algoritmo PC

Definición 20.3 (Algoritmo PC (Spirtes & Glymour, 1991))

El algoritmo PC es el método *constraint-based* canónico para descubrimiento causal. Opera en dos fases:

Fase 1: Descubrimiento del esqueleto.

1. Inicializar el grafo completo no dirigido $\mathcal{C}$ sobre las d variables (todas las aristas presentes).
2. Para $k = 0, 1, 2, \dots$ hasta que ninguna arista pueda eliminarse:
3. Para cada arista $X - Y$ en $\mathcal{C}$ con $|\text{Adj}(X)\{Y\}| \geq k$:
4. Para cada subconjunto $S \subseteq \text{Adj}(X)\{Y\}$ con $|S| = k$:
5. Testear $H_0 : X \perp\!\!\!\perp Y \mid S$.
6. Si no se rechaza H_0 , eliminar la arista $X - Y$ y registrar S como conjunto separador $\text{Sep}(X, Y)$.

Fase 2: Orientación de aristas.

7. **Orientar v-colisionadores:** Para cada triple no adyacente $X - Z - Y$ en el esqueleto, si $Z \notin \text{Sep}(X, Y)$, orientar $X \rightarrow Z \leftarrow Y$ (estructura de colisionador).
8. **Propagar orientaciones** mediante las reglas de Meek (R1–R4):
9. Si $X \rightarrow Y - Z$ y X, Z no son adyacentes, orientar $Y \rightarrow Z$ (evitar nuevo v-colisionador).
10. Si $X \rightarrow Y \rightarrow Z$ y $X - Z$, orientar $X \rightarrow Z$ (evitar ciclo).
11. Si $X - Y \leftarrow Z, X - W \leftarrow Z, X - Z$, y $W - Y$, orientar $X \rightarrow Z$ si W e Y no son adyacentes.
12. Orientaciones para evitar ciclos en estructuras más complejas.

El resultado de PC es un **CPDAG** (Completed Partially Directed Acyclic Graph) que representa la clase de equivalencia de Markov del DAG verdadero: aristas dirigidas donde la orientación es identificable, aristas no dirigidas donde hay ambigüedad.

Teorema 20.1 (Teorema de Meek (Meek, 1995) – Completitud de reglas de orientación)

Sea $\mathcal{P}$ un PDAG obtenido tras orientar v-colisionadores en un esqueleto consistente con un DAG $\mathcal{G}^*$. La aplicación exhaustiva de las cuatro reglas de orientación de Meek (R1–R4) produce exactamente el CPDAG $[\mathcal{G}^*]$ de la clase de equivalencia de $\mathcal{G}^*$. Ninguna regla adicional puede orientar más aristas sin asumir información extra.

20.2.2 El Algoritmo FCI

Definición 20.4 (Algoritmo FCI (Fast Causal Inference))

El algoritmo FCI (Spirtes et al., 2000) extiende PC para entornos con **variables latentes** y **variables de selección**. Mientras PC asume *sufficiency* (todas las causas comunes son observadas), FCI permite confusores no medidos.

El procedimiento de FCI:

1. **Fase 1 (esqueleto):** Similar a PC, pero con tests de independencia que incluyen conjuntos S potencialmente más grandes (los *Possible-D-SEP* de cada variable).
2. **Fase 2 (orientación):** Identifica aristas con la marca especial $\circ \rightarrow$ (podría existir variable latente). El resultado es un **PAG** (Partial Ancestral Graph), donde:
 - $X \rightarrow Y$: X es ancestro de Y .
 - $X \circ \rightarrow Y$: Y no es ancestro de X .
 - $X \circ - \circ Y$: relación indeterminada (podría haber confusor latente).
1. **Fase 3 (reglas):** Aplica 10 reglas de orientación (Zhang, 2008) específicas para PAGs.

El PAG resume todo lo identificable sobre el DAG subyacente en presencia de variables latentes. Las aristas $\circ \rightarrow$ indican que no se puede descartar un confusor no medido.

20.3 Algoritmos Basados en Scores

20.3.1 GES (Greedy Equivalence Search)

Definición 20.5 (Algoritmo GES)

GES (Chickering, 2002) maximiza un score de ajuste (típicamente BIC) sobre el espacio de **CPDAGs** mediante búsqueda voraz en dos fases:

Fase forward (inserción):

1. Partir del grafo vacío $\mathcal{G}_0$ (sin aristas).
2. En cada paso, considerar todas las inserciones de una arista (dirigida o no) que aumenten el score BIC:

$$\text{BIC}(\mathcal{G}) = \log P(\mathcal{D} \mid \hat{\theta}, \mathcal{G}) - \frac{k}{2} \log n, \quad (20.3.1)$$

donde k es el número de parámetros libres y $\hat{\theta}$ son los estimadores máximo-verosímiles bajo $\mathcal{G}$.

3. Insertar la arista que produce el mayor incremento en BIC.
4. Repetir hasta que ninguna inserción mejore el score.

Fase backward (eliminación):

5. Partir del grafo resultante de la fase forward.
6. En cada paso, eliminar la arista cuya remoción más aumente el BIC.
7. Repetir hasta que ninguna eliminación mejore el score.

GES es **asintóticamente correcto**: si la distribución es fiel a un DAG y $n \rightarrow \infty$, GES recupera el CPDAG verdadero. Su eficiencia se debe a que opera sobre clases de equivalencia, no sobre DAGs individuales.

20.4 Descubrimiento Causal como Optimización Continua

20.4.1 NOTEARS

Definición 20.6 (Algoritmo NOTEARS (Zheng et al., 2018))

NOTEARS formula el descubrimiento causal como optimización continua. Sea $\mathbf{W} \in \mathbb{R}^{d \times d}$ la matriz de adyacencia ponderada del DAG ($W_{ij} \neq 0$ si $X_j \rightarrow X_i$). La restricción de aciclicidad se expresa como:

$$h(\mathbf{W}) = \text{tr}(e^{\mathbf{W} \circ \mathbf{W}}) - d = 0, \quad (20.4.1)$$

donde $\circ$ denota el producto elemento a elemento (Hadamard) y $e^{\mathbf{M}}$ es la matriz exponencial. La traza de $e^{\mathbf{W} \circ \mathbf{W}}$ iguala d si y solo si el grafo es acíclico.

El problema de optimización es:

$$\min_{\mathbf{W}} \frac{1}{2n} \|\mathbf{X} - \mathbf{XW}\|_F^2 + \lambda \|\mathbf{W}\|_1 \quad \text{sujeto a} \quad h(\mathbf{W}) = 0, \quad (20.4.2)$$

que se resuelve mediante el método de Lagrangiano aumentado (L-BFGS). NOTEARS es escalable a cientos de variables y admite extensiones no lineales (NOTEARS-MLP).

20.4.2 LiNGAM

Definición 20.7 (Modelo LiNGAM)

El modelo **Linear Non-Gaussian Acyclic Model** (Shimizu et al., 2006) asume:

$$X_i = \sum_{\{j: X_j \in \text{Pa}(X_i)\}} b_{ij} X_j + e_i, \quad (20.4.3)$$

donde los errores e_i son **no gaussianos**, mutuamente independientes, y el grafo de dependencias es un DAG.

Teorema 20.2 (Identificabilidad de LiNGAM)

Bajo el modelo LiNGAM con errores no gaussianos i.i.d. y DAG acíclico, la matriz de coeficientes $\mathbf{B}$ (y por tanto el DAG completo) es **identificable** a partir de datos puramente observacionales. No hay ambigüedad de clase de equivalencia.

A diferencia de PC y GES, LiNGAM **no** sufre ambigüedad de clase de equivalencia: la matriz $\mathbf{B}$ se recupera de manera única (salvo permutación y escala) mediante ICA, produciendo un DAG completamente dirigido. La contrapartida es el supuesto fuerte de no gaussianidad y linealidad.

20.5 Métricas de Evaluación en Descubrimiento Causal

20.5.1 SHD (Structural Hamming Distance)

Definición 20.8 (SHD)

La *Structural Hamming Distance* entre dos grafos $\hat{\mathcal{G}}$ y $\mathcal{G}^*$ (sobre el mismo conjunto de nodos) se define como el número mínimo de operaciones elementales necesarias para transformar $\hat{\mathcal{G}}$ en $\mathcal{G}^*$:

$$\text{SHD}(\hat{\mathcal{G}}, \mathcal{G}^*) = \# \text{inserciones} + \# \text{eliminaciones} + \# \text{inversiones de aristas.} \quad (20.5.1)$$

Cada arista ausente en $\mathcal{G}^*$ pero presente en $\hat{\mathcal{G}}$ cuenta como inserción (falso positivo); cada arista en $\mathcal{G}^*$ ausente en $\hat{\mathcal{G}}$ cuenta como eliminación (falso negativo); cada arista con orientación incorrecta cuenta como inversión.

20.5.2 SID (Structural Intervention Distance)**Definición 20.9 (SID)**

La *Structural Intervention Distance* (Peters & Bühlmann, 2015) mide la discrepancia entre $\hat{\mathcal{G}}$ y $\mathcal{G}^*$ en términos de **consecuencias causales** (no meramente topológicas):

$$\text{SID}(\hat{\mathcal{G}}, \mathcal{G}^*) = \left| \left\{ (X, Y) : \text{el conjunto de ajuste backdoor válido en } \hat{\mathcal{G}} \text{ difiere del de } \mathcal{G}^* \right\} \right|. \quad (20.5.2)$$

Un par (X, Y) cuenta si el efecto causal de X sobre Y sería incorrectamente estimado usando el DAG aprendido $\hat{\mathcal{G}}$.

SHD penaliza errores irrelevantes para inferencia causal (por ejemplo, orientar una arista que no afecta ningún ajuste). SID es más relevante en la práctica porque mide el impacto en la estimación de efectos.

20.6 Selección por Estabilidad (Stability Selection)**Proposición 20.1 (Stability Selection para descubrimiento causal)**

Para cada arista potencial e_{ij} (de X_j a X_i), se define la *probabilidad de selección estable*:

$$\Pi_{ij}^{\{\text{stab}\}} = \mathbb{E}_{\mathcal{D}_B} \left[\mathbf{1}\{e_{ij} \in \hat{\mathcal{G}}(A, \mathcal{D}_B)\} \right], \quad (20.6.1)$$

donde $\mathcal{D}_B$ es una submuestra aleatoria del 50% de los datos (sin reemplazo) y $\hat{\mathcal{G}}(A, \mathcal{D}_B)$ es el grafo estimado por el algoritmo A sobre $\mathcal{D}_B$.

Se retienen las aristas con $\Pi_{ij}^{\{\text{stab}\}} \geq \pi_{\{\text{thr}\}}$ (típicamente $\pi_{\{\text{thr}\}} = 0.8$). Bajo condiciones de intercambiabilidad, la tasa esperada de falsos positivos está acotada por:

$$\mathbb{E}[\text{FP}] \leq \frac{1}{2\pi_{\{\text{thr}\}} - 1} \cdot \frac{q_{\text{Lambda}}^2}{d}, \quad (20.6.2)$$

donde q_{Lambda} es el número esperado de aristas seleccionadas en una submuestra. Stability selection provee control de error en muestra finita sin supuestos distribucionales fuertes.

20.7 Flujo de trabajo para descubrimiento causal

Un proyecto de descubrimiento causal, en la lógica de esta monografía, sigue cuatro decisiones encadenadas:

1. **Supuestos:** ¿Markov + fidelidad bastan, o hay latentes (FCI/PAG)?
2. **Familia de algoritmos:** restricciones (PC), scores (GES) o optimización continua (NOTEARS); no-gaussianidad (LiNGAM) si el diseño lo permite.

3. **Evaluación:** SHD/SID en sintéticos; estabilidad de aristas y sensibilidad a tests en datos reales.
4. **Uso aguas abajo:** el grafo estimado es **precondición** GCE, no un oráculo; toda identificación posterior debe reportar incertidumbre sobre $\hat{\mathcal{G}}$.

20.8 Síntesis del Capítulo

- La **condición de Markov causal** y la **fidelidad** vinculan independencias condicionales con d-separaciones en el DAG.
- Los algoritmos **constraint-based** (PC, FCI) usan tests de independencia para construir el esqueleto y luego orientan aristas con reglas lógicas (Meek R1–R4).
- Los algoritmos **basados en scores** (GES) maximizan BIC sobre el espacio de CPDAGs con búsqueda voraz.
- **NOTEARS** reformula el descubrimiento como optimización continua con restricción de aciclicidad $h(W) = 0$.
- **LiNGAM** explota la no gaussianidad para identificar completamente el DAG sin ambigüedad de clase de equivalencia.
- **SHD** y **SID** miden la calidad del grafo recuperado; SID es más relevante para inferencia causal.
- **Stability selection** controla la tasa de falsos positivos mediante submuestreo repetido.

El Capítulo 21 formaliza la jerarquía de Pearl y conecta el descubrimiento causal con el aprendizaje causal invariante a través de entornos.

Supuestos clave

Supuestos del Capítulo 20 (Descubrimiento Causal)

1. **Markov causal:** La distribución P satisface la condición de Markov respecto al DAG verdadero $\mathcal{G}^*$ (siempre se cumple en un SCM bien definido).
2. **Fidelidad:** P es fiel a $\mathcal{G}^*$; no existen cancelaciones exactas de parámetros que produzcan independencias espurias.
3. **Suficiencia causal (para PC/GES/LiNGAM/NOTEARS):** Todas las causas comunes de las variables observadas son observadas; no hay confusores latentes.
4. **No gaussianidad (para LiNGAM):** Los errores e_i son no gaussianos; de lo contrario, LiNGAM no es identificable.
5. **Linealidad (para LiNGAM y NOTEARS básico):** Las relaciones entre variables son lineales; las extensiones no lineales (NOTEARS-MLP) relajan este supuesto.
6. **Idealización asintótica:** Las garantías de convergencia de PC, GES y FCI son asintóticas ($n \rightarrow \infty$); en muestras finitas, la potencia de los tests de independencia condicional puede ser limitada.

Otras referencias clave de este capítulo: (Meinshausen & Bühlmann, 2010).

20.8 Referencias

- Chickering, D. M. (2002). Optimal Structure Identification with Greedy Search. *Journal of Machine Learning Research*, 3, 507-554.
- Meek, C. (1995). Causal Inference and Causal Explanation with Background Knowledge. *Proceedings of the 11th Conference on Uncertainty in Artificial Intelligence (UAI 1995)*, 403-410.
- Meinshausen, N., & Bühlmann, P. (2010). Stability Selection. *Journal of the Royal Statistical Society: Series B*, 72(4), 417-473.
- Peters, J., & Bühlmann, P. (2015). Structural Intervention Distance for Evaluating Causal Graphs. *Neural Computation*, 27(3), 771-799.

- Shimizu, S., Hoyer, P. O., Hyvärinen, A., & Kerminen, A. (2006). A Linear Non-Gaussian Acyclic Model for Causal Discovery. *Journal of Machine Learning Research*, 7, 2003-2030.
- Spirtes, P., & Glymour, C. (1991). An Algorithm for Fast Recovery of Sparse Causal Graphs. *Social Science Computer Review*, 9(1), 62-72.
- Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, Prediction, and Search* (2.^a ed.). MIT Press.
- Zheng, X., Aragam, B., Ravikumar, P., & Xing, E. P. (2018). DAGs with NO TEARS: Continuous Optimization for Structure Learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

CAPÍTULO 21

Fundamentos del Aprendizaje Causal y Jerarquía de Pearl

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque III · Semilla 42

Notebook (pack): notebooks/Bloque_III/notebooks/21_fundamentos_aprendizaje_causal_jerarquia_pearl.ipynb

Jupyter Book: jupyter_book/content/bloque_03_descubrimiento_ml/21_aprendizaje_causal_jerarquia.ipynb

El Capítulo 20 mostró cómo *descubrir* el grafo. Ahora abordamos una pregunta más profunda: ¿qué significa *aprender* relaciones causales que se transfieran a nuevos entornos? El **aprendizaje causal** (causal learning) busca predictores que no solo se ajusten a los datos de entrenamiento, sino que mantengan su validez bajo intervenciones y cambios distribucionales.

Este capítulo presenta los fundamentos teóricos: la jerarquía de Pearl, la invariancia causal y el algoritmo ICP como puente entre la teoría y la práctica.

21.1 La Jerarquía de Pearl: Tres Estratos del Razonamiento Causal

Definición 21.1 (Jerarquía de Pearl (Tres estratos))

Pearl (2009) y Pearl (2019) organizan toda pregunta causal en tres estratos de complejidad creciente. Cada estrato tiene su propia sintaxis, semántica y límites epistémicos:

1. **Estrato 1 — Asociación:** $P(Y \mid X = x)$. Preguntas puramente estadísticas: ¿cómo cambia la distribución de Y al *observar* $X = x$? Sintaxis: condicionamiento. Responde el ML clásico y la estadística descriptiva.
2. **Estrato 2 — Intervención:** $P(Y \mid \text{do}(X = x))$. Preguntas sobre el efecto de *actuar*: ¿qué distribución de Y resulta si forzamos $X = x$? Sintaxis: operador $\text{do}(\cdot)$. Requiere información causal (DAG, SCM, o experimento).
3. **Estrato 3 — Contrafactual:** $P(Y_x \mid X = x', Y = y')$. Preguntas sobre mundos hipotéticos a nivel individual: ¿qué habría pasado con Y para *este* individuo si X hubiera sido x , dado que observamos $X = x'$ e $Y = y'$? Requiere un SCM completamente especificado.

La jerarquía es **estricta**: cada estrato es estrictamente más expresivo que el anterior. Las preguntas de un estrato no pueden, en general, responderse con solo información de estratos inferiores.

Teorema 21.1 (Imposibilidad de reducción entre estratos (Pearl, 2019))

No existe algoritmo que, recibiendo como entrada únicamente la distribución observacional $P(V)$ (Estrato 1), pueda computar consistentemente $P(Y \mid \text{do}(X = x))$ (Estrato 2) para un par arbitrario (X, Y) sin supuestos estructurales adicionales (como la estructura del DAG). Análogamente, no existe algoritmo que, con solo $P(Y \mid \text{do}(X = x))$, compute $P(Y_x \mid X = x', Y = y')$ (Estrato 3) sin el SCM completo.

Dos modelos distintos pueden generar la misma distribución observacional pero diferir en sus respuestas a intervenciones, lo cual es precisamente lo que hace estricta la jerarquía.

Corolario 21.1 (Implicación práctica)

Ningún modelo de ML puramente predictivo (Estrato 1) puede, por sí mismo, garantizar respuestas correctas a preguntas intervencionales (Estrato 2) sin incorporar supuestos causales. La inferencia causal es **estructuralmente** más demandante que la predicción.

21.2 El Principio de Modularidad

Definición 21.2 (Principio de Modularidad)

En un SCM $\mathcal{M} = (\mathbf{V}, \mathbf{U}, \mathcal{F})$, cada mecanismo $f_i \in \mathcal{F}$ especifica cómo V_i depende de sus padres y de su ruido exógeno U_i . El *principio de modularidad* establece que cada f_i puede ser **alterado** (intervenido) independientemente de los demás mecanismos. Formalmente, la intervención $\text{do}(V_i = v_i)$ reemplaza f_i por una función constante mientras $\mathcal{F}\{f_i\}$ permanece invariante.

Este principio es la base del operador $\text{do}(\cdot)$ y justifica la noción de *mutilación del grafo*: al intervenir sobre V_i , solo se modifica la ecuación estructural de V_i , dejando intactas las demás relaciones causales. Sin modularidad, no podríamos predecir el efecto de una intervención a partir del conocimiento pre-intervención.

Observación 21.1 (Modularidad e independencia causal)

La modularidad implica que los mecanismos causales son **independientes** en el sentido de que:

$$P(V_1, \dots, V_d) = \prod_{i=1}^d P(V_i \mid \text{Pa}(V_i)), \quad (21.2.1)$$

y cada factor $P(V_i \mid \text{Pa}(V_i))$ representa un mecanismo autónomo. Esta factorización es la *descomposición de Markov* del SCM.

21.3 Invariancia Distribucional y Causal

21.3.1 Invariancia Distribucional

Definición 21.3 (Invariancia distribucional entre entornos)

Sea $\mathcal{E} = \{e_1, e_2, \dots\}$ un conjunto de entornos (poblaciones, configuraciones experimentales, momentos temporales). Un predictor $f : \mathcal{X} \rightarrow \mathcal{Y}$ es *distribucionalmente invariante* entre entornos si:

$$P^e(Y \mid f(X)) = P^{e'}(Y \mid f(X)), \quad \forall e, e' \in \mathcal{E}. \quad (21.3.1)$$

Es decir, la distribución condicional del resultado dado el predictor es la misma en todos los entornos.

Esta noción de invariancia es puramente estadística (Estrato 1). La invariancia *causal*, en contraste, apela a la estructura generativa.

21.3.2 Invariancia Causal (Peters et al., 2016)

Definición 21.4 (Invariancia causal)

Sea $\mathcal{G}$ un DAG causal sobre $\mathbf{V}$. Un subconjunto de covariables $\mathbf{S} \subseteq \mathbf{V} \setminus \{Y\}$ satisface la *invariancia causal* respecto a Y si el mecanismo condicional:

$$P^e(Y \mid \mathbf{X}_{\mathbf{S}}) \quad (21.3.2)$$

es **invariante** a través de entornos $e \in \mathcal{E}$, mientras que las distribuciones de las causas $P^e(\mathbf{X}_{\mathbf{S}})$ pueden variar arbitrariamente entre entornos.

La intuición es profunda: si $\mathbf{S}$ son los **padres causales directos** de Y , entonces el mecanismo $P(Y \mid \text{Pa}(Y))$ es un mecanismo estable de la naturaleza, mientras que $P(\text{Pa}(Y))$ puede cambiar con el entorno (por ejemplo, por intervenciones sobre las causas).

Corolario 21.2 (Criterio de selección de variables por invariancia)

Si un predictor f utiliza **únicamente** las causas directas de Y (i.e., $f(X) = f(\text{Pa}(Y))$), entonces la distribución condicional $P^e(Y \mid f(X))$ es invariante entre entornos, porque el mecanismo $P(Y \mid \text{Pa}(Y))$ es un módulo autónomo del SCM que no se altera por cambios en otros mecanismos.

Este corolario conecta directamente el principio de modularidad con la invariancia predictiva: un modelo que usa solo las causas es *robusto* a cambios distribucionales.

21.4 ICP: Predicción Causal Invariante

Definición 21.5 (Algoritmo ICP (Invariant Causal Prediction))

El algoritmo ICP (Peters et al., 2016, Peters, Bühlmann y Meinshausen) invierte el razonamiento: en lugar de asumir conocidas las causas y verificar la invariancia, **busca** el subconjunto $\mathbf{S}^* \subseteq \{1, \dots, p\}$ de covariables tal que:

$$P^e(Y \mid \mathbf{X}_{\mathbf{S}^*}) \text{ es invariante a través de } e \in \mathcal{E}. \quad (21.4.1)$$

Bajo condiciones de identificabilidad, $\mathbf{S}^*$ es exactamente el conjunto de **padres causales** de Y .

El procedimiento de ICP se estructura como sigue:

1. **Entrada:** Datos de Y y $\mathbf{X}$ en múltiples entornos $\mathcal{E} = \{e_1, \dots, e_E\}$, nivel de significancia α .
2. **Inicializar:** $\hat{\mathbf{S}} \leftarrow \emptyset, \mathcal{C} \leftarrow$ todos los subconjuntos de $\{1, \dots, p\}$.
3. Para cada subconjunto $\mathbf{S} \in \mathcal{C}$:
4. Ajustar un modelo de regresión $Y \sim \mathbf{X}_{\mathbf{S}}$ (lineal, aditivo, o no paramétrico según supuestos) en cada entorno e por separado.
5. Testear la hipótesis nula:

$$H_{0,\mathbf{S}} : \text{los coeficientes (o funciones) de } Y \sim \mathbf{X}_{\mathbf{S}} \text{ son idénticos en todos los entornos } e \in \mathcal{E}. \quad (21.4.2)$$

6. Si $H_{0,\mathbf{S}}$ no se rechaza al nivel α , incluir $\mathbf{S}$ en el conjunto de conjuntos invariantes $\mathcal{I}$.

Salida: $\hat{\mathbf{S}} = \bigcap_{\mathbf{S} \in \mathcal{I}} \mathbf{S}$, la intersección de todos los conjuntos invariantes. Las variables en $\hat{\mathbf{S}}$ son las causas directas inferidas de Y .

Observación 21.2 (Control de error)

ICP garantiza que $P(\hat{\mathbf{S}} \subseteq \text{Pa}(Y)) \geq 1 - \alpha$. Es decir, con alta probabilidad, **todas** las variables en $\hat{\mathbf{S}}$ son verdaderos padres causales. La intersección puede ser conservadora ($\hat{\mathbf{S}}$ puede ser subconjunto propio de $\text{Pa}(Y)$), pero no incluye falsos positivos.

21.5 Implicaciones para el Aprendizaje Automático

La jerarquía de Pearl y la teoría de invariancia tienen consecuencias profundas para el diseño de sistemas de ML:

1. **Robustez a cambios distribucionales:** Un modelo que captura relaciones causales (no meras correlaciones) generaliza a nuevos entornos. Si $P_{\{\text{train}\}}(X) \neq P_{\{\text{test}\}}(X)$ pero el mecanismo $P(Y \mid \text{Pa}(Y))$ es invariante, el predictor causal mantiene su calibración.
2. **Transferencia de aprendizaje:** El conocimiento causal se transfiere entre dominios porque los mecanismos son modulares. Aprender $P(Y \mid \text{Pa}(Y))$ en un entorno es suficiente para predecir en cualquier otro donde ese mecanismo no haya sido intervenido.
3. **Explicabilidad:** Las causas directas proveen explicaciones que responden a preguntas contrafactuales (¿por qué este valor de Y ? Porque X_j tomó este valor, y el mecanismo f_j lo transformó así').
4. **Selección de variables:** ICP y métodos relacionados seleccionan variables con una justificación causal, no meramente predictiva. Esto evita incluir variables espurias que mejoran la predicción en el conjunto de entrenamiento pero fallan en producción.

21.6 Ejemplo: Invariancia en Datos Multi-Entorno

Ejemplo 21.1 (Predicción de rendimiento escolar en tres regiones)

Se mide el rendimiento escolar Y en tres regiones ($e \in \{1, 2, 3\}$) con covariables: X_1 = educación materna, X_2 = ingreso familiar, X_3 = asistencia escolar. El DAG causal es:

$$X_1 \rightarrow X_2 \rightarrow X_3 \rightarrow Y, \quad X_1 \rightarrow Y. \quad (21.6.1)$$

El mecanismo $P(Y \mid X_1, X_3)$ (padres de Y) es invariante porque representa la ley estable que vincula educación materna y asistencia con rendimiento. En cambio, $P(Y \mid X_2)$ puede variar entre regiones porque la relación $X_2 \rightarrow Y$ está mediada por X_3 , cuyo mecanismo puede cambiar.

ICP, aplicado sobre datos de las tres regiones, identificará $\hat{S} = \{X_1, X_3\}$ como el conjunto invariante, recuperando correctamente los padres causales de Y .

21.7 Lectura de la jerarquía de Pearl en clave GCE

La escalera de Pearl (asociación $\rightarrow$ intervención $\rightarrow$ contrafactual) y la jerarquía GCE (localización $\rightarrow$ forma $\rightarrow$ geometría) no son rivales: la primera ordena **tipos de pregunta**; la segunda, **tipos de discrepancia** entre distribuciones contrafactuales. Un predictor de estrato 1 puede ser excelente en $P(Y \mid X)$ y fallar en $P(Y \mid \text{do}(X))$ o en $W_1(P_{Y(1)}, P_{Y(0)})$.

21.8 Cierre del capítulo

La jerarquía de Pearl fija límites de lo deducible: sin supuestos estructurales no hay escalada de asociación a intervención ni a contrafactual. El aprendizaje causal hereda esos límites; no los disuelve el ML.

21.8 Referencias

- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Pearl, J. (2019). The Seven Tools of Causal Inference, with Reflections on Machine Learning. *Communications of the ACM*, 62(3), 54-60.
- Peters, J., Bühlmann, P., & Meinshausen, N. (2016). Causal Inference by Using Invariant Prediction: Identification and Confidence Intervals. *Journal of the Royal Statistical Society: Series B*, 78(5), 947-1012.

CAPÍTULO 22

Meta-Learners para Inferencia Causal: S/T/X-Learners y Más

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque III · Semilla 42

Notebook (pack): notebooks/Bloque_III/notebooks/22_meta_learners_inferencia_causal_stx.ipynb

Jupyter Book: jupyter_book/content/bloque_03_descubrimiento_ml/22_meta_learners.ipynb

El ATE resume el efecto promedio poblacional, pero las políticas modernas demandan **heterogeneidad**: ¿para quién funciona el tratamiento? El **CATE** (Conditional Average Treatment Effect) responde esta pregunta. Este capítulo presenta los **meta-learners** — S-, T-, X- y R-learners — que convierten cualquier algoritmo de ML supervisado en un estimador de efectos causales heterogéneos.

22.1 CATE: El Efecto Causal Condicional

Definición 22.1 (CATE (Conditional Average Treatment Effect))

Sea Y^1 el resultado potencial bajo tratamiento y Y^0 bajo control. El *efecto causal condicional promedio* dado $\mathbf{X} = \mathbf{x}$ es:

$$\tau(\mathbf{x}) = \mathbb{E}[Y(1) - Y(0) \mid \mathbf{X} = \mathbf{x}]. \quad (22.1.1)$$

Bajo ignorabilidad (unconfoundedness) $Y^1, Y^0 \perp\!\!\!\perp T \mid \mathbf{X}$, el CATE es identificable y se escribe como:

$$\tau(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}, T = 1] - \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}, T = 0]. \quad (22.1.2)$$

El CATE $\tau(\mathbf{x})$ mide el efecto del tratamiento **condicional** en el perfil de covariables $\mathbf{x}$. Dos individuos con distintos $\mathbf{x}$ pueden tener efectos diametralmente opuestos: uno se beneficia, otro resulta perjudicado. Identificar esta heterogeneidad es el objetivo de la *medicina personalizada*, las *políticas targeting* y la *optimización de intervenciones*.

Observación 22.1 (CATE vs ATE)

El ATE es la esperanza del CATE sobre la distribución de $\mathbf{X}$: $\text{ATE} = \mathbb{E}_{\mathbf{X}}[\tau(\mathbf{X})]$. El CATE contiene toda la información sobre heterogeneidad; el ATE la colapsa en un solo número.

22.2 S-Learner: Un Solo Modelo

Definición 22.2 (S-Learner (Single Learner))

El *S-learner* estima una única función de regresión $\hat{\mu}(\mathbf{x}, a)$ que predice Y usando $\mathbf{X}$ y el indicador de tratamiento A como covariables:

$$\hat{\mu}(\mathbf{x}, a) = \hat{\mathbb{E}}[Y \mid \mathbf{X} = \mathbf{x}, A = a]. \quad (22.2.1)$$

El CATE se estima por diferencia:

$$\hat{\tau}_{S(\mathbf{x})} = \hat{\mu}(\mathbf{x}, 1) - \hat{\mu}(\mathbf{x}, 0). \quad (22.2.2)$$

El S-learner es el enfoque más directo: se incluye A como una covariable más en cualquier modelo de regresión (bosque aleatorio, gradient boosting, red neuronal). Su **limitación principal** es que muchos algoritmos de ML aplican regularización que puede *shrinkear* el coeficiente asociado a A hacia cero, especialmente cuando el tratamiento tiene un efecto pequeño relativo al ruido o cuando A está correlacionado con otras covariables. Si el modelo no captura adecuadamente la interacción entre A y $\mathbf{X}$, el CATE estimado colapsa a una constante.

Observación 22.2 (S-learner y regularización)

Bajo regularización ℓ_1 (Lasso), el S-learner tiende a excluir A del modelo si su contribución marginal a la predicción de Y es pequeña comparada con la de $\mathbf{X}$. Esto produce $\hat{\tau}_{S(\mathbf{x})} \approx 0$ para todo $\mathbf{x}$, incluso cuando existe un efecto causal genuino. La regularización no distingue entre el rol *predictivo* y el rol *causal* de A .

22.3 T-Learner: Dos Modelos Separados

Definición 22.3 (T-Learner (Two Learners))

El *T-learner* entrena dos modelos de regresión independientes:

$$\hat{\mu}_1(\mathbf{x}) = \hat{\mathbb{E}}[Y \mid \mathbf{X} = \mathbf{x}, A = 1], \hat{\mu}_0(\mathbf{x}) = \hat{\mathbb{E}}[Y \mid \mathbf{X} = \mathbf{x}, A = 0]. \quad (22.3.1)$$

El CATE se estima como:

$$\hat{\tau}_{T(\mathbf{x})} = \hat{\mu}_1(\mathbf{x}) - \hat{\mu}_0(\mathbf{x}). \quad (22.3.2)$$

A diferencia del S-learner, el T-learner **no** regulariza el tratamiento porque A no aparece como covariable: los modelos se entrenan en submuestras separadas (tratados y controles). Esto evita el shrinkage del efecto. Sin embargo, el T-learner tiene sus propias limitaciones:

1. **Desbalance de muestra:** Si $n_1 \ll n_0$ (tratamiento raro), $\hat{\mu}_1$ se estima con alta varianza mientras $\hat{\mu}_0$ es preciso. La diferencia hereda la varianza de ambos.
2. **Falta de compartición de información:** Los modelos no comparten estructura. Si la relación $\mathbf{X} \rightarrow Y$ es similar en ambos grupos (salvo por el efecto del tratamiento), el T-learner no aprovecha esta similitud y paga un precio en varianza.
3. **Extrapolación:** Si el soporte de $\mathbf{X}$ difiere entre tratados y controles, $\hat{\mu}_1(\mathbf{x})$ puede evaluarse en regiones donde solo hay controles, y viceversa.

22.4 X-Learner: Aprendizaje Cruzado

Definición 22.4 (X-Learner (Cross Learner) (Künzel et al., 2019))

El *X-learner* aborda las limitaciones del T-learner mediante una estrategia de **pseudo-tratamientos** en tres etapas:

Etapas 1 – Modelos base: Estimar $\hat{\mu}_1(\mathbf{x})$ y $\hat{\mu}_0(\mathbf{x})$ como en el T-learner.

Etapas 2 – Pseudo-efectos: Construir efectos observados'' imputando el contrafactual faltante:

$$\begin{aligned}\tilde{D}_i^1 &= Y_i - \hat{\mu}_0(\mathbf{X}_i), \quad \text{para unidades tratadas } (A_i = 1), \\ \tilde{D}_i^0 &= \hat{\mu}_1(\mathbf{X}_i) - Y_i, \quad \text{para unidades de control } (A_i = 0).\end{aligned}\quad (22.4.1)$$

Estos $\tilde{D}_i^1$ y $\tilde{D}_i^0$ son **pseudo-efectos**: aproximan $\tau(\mathbf{X}_i)$ usando el modelo del grupo contrario para imputar el contrafactual.

Etapas 3 – Modelos de CATE: Estimar dos modelos de $\tau(\mathbf{x})$:

$$\begin{aligned}\hat{\tau}_1(\mathbf{x}) &= \hat{\mathbb{E}}[\tilde{D}^1 \mid \mathbf{X} = \mathbf{x}], \\ \hat{\tau}_0(\mathbf{x}) &= \hat{\mathbb{E}}[\tilde{D}^0 \mid \mathbf{X} = \mathbf{x}],\end{aligned}\quad (22.4.2)$$

y combinarlos ponderando por el propensity score estimado $\hat{e}(\mathbf{x})$:

$$\hat{\tau}_{X(\mathbf{x})} = \hat{e}(\mathbf{x})\hat{\tau}_0(\mathbf{x}) + (1 - \hat{e}(\mathbf{x}))\hat{\tau}_1(\mathbf{x}). \quad (22.4.3)$$

Observación 22.3 (Robustez al desbalance)

La ponderación por $\hat{e}(\mathbf{x})$ da más peso a $\hat{\tau}_0$ (modelo entrenado en controles) cuando $\mathbf{x}$ es típico de los tratados, y más peso a $\hat{\tau}_1$ cuando $\mathbf{x}$ es típico de los controles. Esto reduce el problema de extrapolación: en regiones con pocos tratados, el X-learner confía más en el modelo entrenado en controles.

El X-learner es particularmente efectivo cuando el desbalance entre grupos es severo. Künzel et al. (2019) demuestran mediante simulaciones extensivas que el X-learner supera al S- y T-learner en términos de MSE del CATE cuando $n_1 \ll n_0$ o viceversa.

22.5 R-Learner: Descomposición de Robinson

Definición 22.5 (R-Learner (Nie & Wager, 2021))

El *R-learner* se basa en la **descomposición de Robinson** (1988), que desacopla el efecto del tratamiento de las funciones nuisance. Definiendo:

$$m(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}], \quad e(\mathbf{x}) = \mathbb{E}[A \mid \mathbf{X} = \mathbf{x}], \quad (22.5.1)$$

la descomposición es:

$$Y_i - m(\mathbf{X}_i) = \tau(\mathbf{X}_i)(A_i - e(\mathbf{X}_i)) + \epsilon_i, \quad \mathbb{E}[\epsilon_i \mid \mathbf{X}_i, A_i] = 0. \quad (22.5.2)$$

Esta ecuación revela que, una vez sustraídas las medias condicionales $m(\mathbf{x})$ y $e(\mathbf{x})$, la relación entre los residuos es lineal en $\tau(\mathbf{x})$ con covariable'' $A_i - e(\mathbf{X}_i)$. El R-learner estima $\tau(\cdot)$ minimizando la función de pérdida regularizada:

$$\hat{\tau}_{R(\cdot)} = \arg \min_{\tau} \left\{ \frac{1}{n} \sum_{i=1}^n \left((Y_i - \hat{m}^{(-i)}(\mathbf{X}_i)) - \tau(\mathbf{X}_i)(A_i - \hat{e}^{(-i)}(\mathbf{X}_i)) \right)^2 + \Lambda_{n(\tau(\cdot))} \right\}, \quad (22.5.3)$$

donde $\hat{m}^{(-i)}$ y $\hat{e}^{(-i)}$ son estimadores *out-of-fold* (vía cross-fitting) y Λ_n es un término de regularización sobre la complejidad de $\tau(\cdot)$.

Teorema 22.1 (Tasa casi óptima del R-learner (Nie & Wager, 2021))

Bajo condiciones de regularidad (suavidad de τ , m , e y convergencia suficiente de sus estimadores preliminares), el R-learner alcanza una tasa de convergencia para $\hat{\tau}_R$ que iguala—salvo factores logarítmicos—la tasa óptima de estimar una función de regresión estándar de la misma suavidad. Los errores en la estimación de m y e entran **solo a segundo orden**, permitiendo el uso de estimadores de ML regularizados (que convergen a tasa $o_P(n^{-\frac{1}{4}})$) sin sacrificar la eficiencia de $\hat{\tau}_R$.

22.6 BLP: Best Linear Prediction de Heterogeneidad

Definición 22.6 (BLP (Best Linear Prediction) (Chernozhukov et al., 2018))

Una vez obtenido un estimador $\hat{\tau}(\mathbf{X}_i)$ del CATE, es crucial verificar si captura heterogeneidad genuina. La **Best Linear Prediction** construye una regresión de pseudo-resultados sobre $\hat{\tau}(\mathbf{X}_i)$:

$$\tilde{Y}_i = \beta_0 + \beta_1 \hat{\tau}(\mathbf{X}_i) + u_i, \quad (22.6.1)$$

donde $\tilde{Y}_i$ es un outcome transformado (ortogonalizado). El test de heterogeneidad es:

$$H_0 : \beta_1 = 0 \quad (\text{ausencia de heterogeneidad capturada por } \hat{\tau}). \quad (22.6.2)$$

Bajo H_0 , $\hat{\tau}(\mathbf{X}_i)$ no predice los pseudo-resultados mejor que una constante, indicando que el estimador de CATE no identifica variación sistemática en los efectos. Rechazar H_0 ($\beta_1 > 0$) evidencia que $\hat{\tau}$ captura heterogeneidad real.

El procedimiento BLP se implementa típicamente con **muestras divididas** (cross-fitting) para evitar overfitting: una mitad de los datos estima $\hat{\tau}$, la otra mitad estima la regresión BLP.

22.7 Comparación de Meta-Learners

Propiedad	S-learner	T-learner	X-learner
Núm. de modelos	1	2	4
Tratamiento como covariable	Sí	No (split)	No (imputación cruzada)
Regularización del efecto	Riesgo de shrinkage	No shrinkage	No shrinkage
Robustez a desbalance	Baja	Media	Alta
Eficiencia estadística	Alta (comparte datos)	Baja (no comparte)	Media (imputa)
Uso de propensity score	No	No	Sí (ponderación)

Tabla 10: Comparación de S-, T-, X- y R-learners

El R-learner ocupa una categoría aparte: a diferencia de S, T y X, no estima $\mu_{a(x)}$ directamente, sino que aprende $\tau(x)$ a partir de los residuos ortogonalizados. Esto lo hace particularmente adecuado cuando el efecto es esparso o estructurado y las funciones nuisance son complejas.

22.8 Criterio de selección entre meta-learners

1. **S-learner:** pocas observaciones o efecto casi nulo y se prioriza regularización conjunta; riesgo de enmascarar $\tau(x)$.
2. **T-learner:** solapamiento razonable y se desea flexibilidad por brazo; ineficiente si un brazo es pequeño.
3. **X-learner:** desbalance de tratados/controles; aprovecha el brazo mayor para imputar el menor.
4. **R-learner / DR-learner:** se dispone de buenos nuisance (m, e) y se busca optimalidad para $\tau(x)$ vía residualización.

En todos los casos, el reporte monográfico exige overlap, métrica de evaluación (p. ej. PEHE en sintéticos) y, cuando sea posible, comparación entre al menos dos meta-learners.

22.9 Cierre del capítulo

Los meta-learners estiman el CATE reutilizando regresión supervisada. Su valor monográfico es la modularidad (S/T/X/R) y la honestidad sobre nuisance y solapamiento, no la promesa de un único algoritmo universal.

22.9 Referencias

- Chernozhukov, V., Demirer, M., Duflo, E., & Fernández-Val, I. (2018). *Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments* (technical report No. 24678).
- Künzel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B. (2019). Metalearners for Estimating Heterogeneous Treatment Effects Using Machine Learning. *Proceedings of the National Academy of Sciences*, 116(10), 4156-4165.
- Nie, X., & Wager, S. (2021). Quasi-Oracle Estimation of Heterogeneous Treatment Effects. *Biometrika*, 108(2), 299-319.

CAPÍTULO 23

Doble Desviación y Aprendizaje Automático Ortogonal

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque III · Semilla 42

Notebook (pack): notebooks/Bloque_III/notebooks/23_doble_desviacion_aprendizaje_automatiko_ortogonal.ipynb

Jupyter Book: jupyter_book/content/bloque_03_descubrimiento_ml/23_doble_desviacion.ipynb

Matemática GCE: gce/paper/main.typ (cadena maestra / experimento canónico)

El Capítulo 22 mostró que el R-learner alcanza tasas casi óptimas porque ortogonaliza el efecto de tratamiento respecto a las funciones nuisance. Este capítulo desarrolla la teoría general que sustenta ese resultado: el **Double/Debiased Machine Learning (DML)** (Chernozhukov et al., 2018).

DML resuelve un problema fundamental del ML aplicado a la inferencia: cómo usar estimadores de ML regularizados (que introducen sesgo de regularización) sin comprometer la validez de la inferencia estadística sobre parámetros causales de interés.

23.1 El Problema: Sesgo de Regularización

23.1.1 Nuisance Parameters

Definición 23.1 (Nuisance parameters)

En inferencia semiparamétrica, los *nuisance parameters* (parámetros molestos) son funciones de $\mathbf{X}$ que deben estimarse para construir el estimador del parámetro de interés θ , pero que no son en sí mismas el objeto de inferencia. En el contexto causal:

$$\eta(\mathbf{X}) = (m(\mathbf{X}), e(\mathbf{X})), \quad (23.1.1)$$

donde $m(\mathbf{X}) = \mathbb{E}[Y \mid \mathbf{X}]$ es la función de regresión del outcome y $e(\mathbf{X}) = \mathbb{E}[A \mid \mathbf{X}]$ es el propensity score.

En principio, podríamos estimar η mediante cualquier método de ML (bosques aleatorios, gradient boosting, redes neuronales) y luego usarlo en una fórmula plug-in. Pero surge un problema fundamental.

23.1.2 Sesgo de Regularización de Primer Orden

Definición 23.2 (Sesgo de regularización (primer orden))

Cuando los nuisance parameters η se estiman con métodos de ML regularizados (Lasso, boosting, random forest), el estimador $\hat{\eta}$ converge a η_0 a tasa $o_P(n^{-\frac{1}{4}})$ pero **no** a tasa $o_P(n^{-\frac{1}{2}})$. Si el estimador plug-in $\hat{\theta}_{\{\text{plug-in}\}}$ usa $\hat{\eta}$ directamente, el sesgo de regularización de $\hat{\eta}$ se transmite a $\hat{\theta}$ a **primer orden**:

$$\sqrt{n}(\hat{\theta}_{\{\text{plug-in}\}} - \theta_0) = \frac{1}{\sqrt{n}} \sum_{(i=1)^n \psi(W_i, \theta_0, \eta_0)} + \underbrace{\sqrt{n} \mathbb{E}[B(X)(\hat{\eta}(X) - \eta_0(X))]}_{\text{sesgo de primer orden}} + o_P(1) \quad (23.1.2)$$

El término de sesgo $\sqrt{n} \mathbb{E}[B(\hat{\eta} - \eta_0)]$ puede diverger si $\hat{\eta}$ converge más lento que $n^{-\frac{1}{2}}$, destruyendo la normalidad asintótica del estimador.

Este es el **problema central** del ML para inferencia: los métodos que mejor predicen (ML regularizado) son precisamente los que introducen sesgo de regularización que vicia la inferencia sobre θ .

23.2 Ortogonalidad de Neyman (Neyman, 1959)

Definición 23.3 (Condición de ortogonalidad de Neyman)

Sea $\psi(W, \theta, \eta)$ una función de score (moment condition) tal que $\mathbb{E}[\psi(W, \theta_0, \eta_0)] = 0$ identifica θ_0 . La función ψ satisface la *condición de ortogonalidad de Neyman* respecto a η si la derivada de Gateaux en η_0 se anula:

$$\frac{\partial}{\partial r} \mathbb{E}[\psi(W, \theta_0, \eta_0 + r(\eta - \eta_0))] |_{r=0} = 0, \quad (23.2.1)$$

para toda dirección $\eta - \eta_0$ en un espacio adecuado.

Cuando esta condición se cumple, el sesgo inducido por estimar η es de **segundo orden**: depende de $(\hat{\eta} - \eta_0)^2$, una cantidad que converge a tasa $o_P(n^{-\frac{1}{2}})$ si $\hat{\eta} - \eta_0 = o_P(n^{-\frac{1}{4}})$. Esto significa que podemos estimar η con métodos de ML que convergen a tasa $n^{-\frac{1}{4}}$ y aun así obtener inferencia $\sqrt{n}$ -consistente para θ .

Observación 23.1 (Intuición geométrica)

La ortogonalidad de Neyman generaliza la noción de que η es un *parámetro ortogonal* a θ en el sentido de la geometría de la información. Pequeñas perturbaciones en η no afectan las ecuaciones de estimación de θ en el primer orden de la expansión de Taylor funcional.

23.3 El Estimador DML

23.3.1 La Ecuación de Robinson (Robinson, 1988) Ortogonalizada

Definición 23.4 (Estimador DML (Double/Debiased Machine Learning))

Para el modelo causal básico con ATE constante, el score ortogonalizado de Neyman para $\theta = \mathbb{E}[Y^1 - Y^0]$ es:

$$\psi(W_i, \theta, \eta) = (Y_i - \ell(\mathbf{X}_i)) - \theta(A_i - m(\mathbf{X}_i)), \quad (23.3.1)$$

donde $\ell(\mathbf{X}) = \mathbb{E}[Y \mid \mathbf{X}, A = 0] + \theta \cdot m(\mathbf{X})$ juega un papel análogo a $m(\mathbf{X})$ en la formulación del Capítulo 22. En la práctica se usan los residuos ortogonalizados:

$$\tilde{Y}_i = Y_i - \hat{\ell}(\mathbf{X}_i), \quad \tilde{A}_i = A_i - \hat{m}(\mathbf{X}_i). \quad (23.3.2)$$

El estimador DML es la regresión por MCO de $\tilde{Y}_i$ sobre $\tilde{A}_i$:

$$\hat{\theta}_{\{\text{DML}\}} = \sum_{i=1}^n \tilde{A}_i \tilde{Y}_i \left\{ \sum_{i=1}^n \tilde{A}_i^2 \right\}^{-1}. \quad (23.3.3)$$

La intuición es elegante: una vez que descontamos'' de Y y A toda la variación explicable por $\mathbf{X}$ (a través de $\hat{\ell}$ y $\hat{m}$), la relación remanente entre los residuos captura el efecto causal θ libre de confusión.

23.3.2 Cross-Fitting (K-fold)**Definición 23.5 (Cross-fitting)**

Para prevenir el **overfitting bias** (sesgo por reutilizar las mismas observaciones para estimar η y para evaluar ψ), DML emplea *cross-fitting* en K pliegues:

1. Particionar los datos $\{1, \dots, n\}$ en K pliegues $I_1, \dots, I_K$ de tamaño aproximadamente $\frac{n}{K}$.
2. Para cada pliegue $k = 1, \dots, K$:

El cross-fitting garantiza que $\hat{\eta}^{(-k)}$ es independiente de las observaciones en I_k , eliminando el sesgo de overfitting. Típicamente se usa $K = 5$ (recomendación estándar de Chernozhukov et al., 2018).

23.4 Propiedades Asintóticas del DML**Teorema 23.1 (Normalidad asintótica del DML (Chernozhukov et al., 2018))**

Bajo las siguientes condiciones:

1. $\psi(W, \theta, \eta)$ satisface la condición de ortogonalidad de Neyman en η_0 ;
2. $\hat{\eta}$ converge a η_0 a tasa $o_{P(n^{-\frac{1}{4}})}$ en norma L_2 : $|\hat{\eta} - \eta_0|_{P,2} = o_{P(n^{-\frac{1}{4}})}$;
3. Cross-fitting en K pliegues (fijo);
4. Condiciones de momentos y regularidad estándar;

se tiene:

$$\sqrt{n}(\hat{\theta}_{\{\text{DML}\}} - \theta_0) \xrightarrow{d} \mathcal{N}(0, \sigma_{\{\text{DML}\}}^2), \quad (23.4.1)$$

donde $\sigma_{\{\text{DML}\}}^2 = \mathbb{E} \left[\frac{\psi(W, \theta_0, \eta_0)^2}{(\mathbb{E}[\tilde{A}^2])^2} \right]$. En particular, los intervalos de confianza basados en esta distribución normal son **asintóticamente válidos** aun cuando $\hat{\eta}$ se estime con métodos de ML fuertemente regularizados.

23.5 Doble Robustez del DML

Definición 23.6 (Doble robustez del DML)

El estimador DML es *doblemente robusto*: $\hat{\theta}_{\{\text{DML}\}}$ es consistente para θ_0 si **al menos uno** de los dos nuisance parameters $(\hat{\ell}, \hat{m})$ está correctamente especificado:

- Si $\hat{m}(\mathbf{X}) \xrightarrow{P} m_0(\mathbf{X})$, $\hat{\theta}_{\{\text{DML}\}}$ es consistente incluso si $\hat{\ell}(\mathbf{X})$ es inconsistente.
- Si $\hat{\ell}(\mathbf{X}) \xrightarrow{P} \ell_0(\mathbf{X})$, $\hat{\theta}_{\{\text{DML}\}}$ es consistente incluso si $\hat{m}(\mathbf{X})$ es inconsistente.

Esta propiedad otorga una protección valiosa contra la mala especificación: basta con estimar correctamente **una** de las dos funciones nuisance para obtener consistencia. En la práctica, si se usan métodos de ML flexibles (que aproximan bien ambas), la doble robustez provee un margen adicional de seguridad.

Observación 23.2 (Comparación con AIPW)

El estimador DML para ATE es algebraicamente equivalente al estimador AIPW (Augmented Inverse Probability Weighting) cuando se usa el score de Neyman ortogonalizado. Ambos comparten la propiedad de doble robustez. La innovación de DML es el **marco inferencial** completo: cross-fitting + score de Neyman + normalidad asintótica con ML regularizado.

23.6 Modelos Estructurales para DML

23.6.1 Partially Linear Model (PLM)

Definición 23.7 (Partially Linear Model para DML)

El modelo parcialmente lineal asume:

$$Y = \theta W + g(\mathbf{X}) + \epsilon, \quad \mathbb{E}[\epsilon \mid W, \mathbf{X}] = 0, \quad (23.6.1)$$

donde θ es el efecto causal constante del tratamiento W , y $g(\mathbf{X})$ es una función nuisance arbitraria (no lineal). El score ortogonalizado es:

$$\psi(W_i, Y_i, \mathbf{X}_i, \theta, g, m) = (Y_i - g(\mathbf{X}_i) - \theta(W_i - m(\mathbf{X}_i)))(W_i - m(\mathbf{X}_i)), \quad (23.6.2)$$

con $m(\mathbf{X}) = \mathbb{E}[W \mid \mathbf{X}]$. La nulidad de la derivada de Gateaux respecto a g y m es fácilmente verificable.

El PLM es el caballo de batalla del DML: captura la idea de que el efecto del tratamiento es constante pero la relación entre $\mathbf{X}$ y el outcome puede ser arbitrariamente compleja. En la práctica, g y m se estiman con cualquier regresor de ML (gradient boosting, redes neuronales, random forest) en cada pliegue del cross-fitting.

23.6.2 Interactive Model (DML para CATE)

Definición 23.8 (Interactive Model para CATE)

Cuando el efecto del tratamiento es heterogéneo, se generaliza el PLM a:

$$Y = \theta(\mathbf{X})W + g(\mathbf{X}) + \epsilon, \quad \mathbb{E}[\epsilon \mid W, \mathbf{X}] = 0. \quad (23.6.3)$$

Aquí $\theta(\mathbf{X})$ es el CATE. La estimación combina DML con el R-learner: en cada pliegue se estiman g y m fuera de muestra, se construyen residuos $\tilde{Y}_i$ y $\tilde{W}_i$, y se ajusta un modelo de ML para $\theta(\mathbf{X})$ sobre los residuos:

$$\tilde{Y}_i = \theta(\mathbf{X}_i)\tilde{W}_i + \text{ruido}. \quad (23.6.4)$$

Esta combinación DML + R-learner hereda lo mejor de ambos mundos: la ortogonalización de Neyman elimina el sesgo de primer orden de los nuisance parameters, mientras que el R-learner captura la heterogeneidad arbitraria de $\theta(\mathbf{X})$ usando ML flexible.

23.7 Ejemplo: DML Aplicado al Efecto de la Educación sobre el Ingreso

Ejemplo 23.1 (Ecuación de Mincer con DML)

La ecuación de Mincer (1974) modela el log-ingreso Y en función de años de educación W y experiencia laboral $\mathbf{X}$:

$$\log(\text{ingreso}) = \theta \cdot \text{educación} + g(\text{experiencia, edad, región}) + \epsilon. \quad (23.7.1)$$

El parámetro θ es el retorno causal a la educación (ATE). Las covariables $\mathbf{X}$ incluyen experiencia, experiencia2, edad, región, y otros determinantes del ingreso que también pueden predecir el nivel educativo W .

Datos: Encuesta Nacional de Hogares ($n \approx 20\{, \}000$).

Procedimiento DML:

1. Dividir en $K = 5$ pliegues.
2. En cada pliegue k , estimar $\hat{g}^{(-k)}$ (ingreso predicho por $\mathbf{X}$) y $\hat{m}^{(-k)}$ (educación predicha por $\mathbf{X}$) usando gradient boosting.
3. Construir $\tilde{Y}_i = \log(\text{ingreso}_i) - \hat{g}^{(-k)}(\mathbf{X}_i)$ y $\tilde{W}_i = \text{educación}_i - \hat{m}^{(-k)}(\mathbf{X}_i)$.
4. Estimar $\hat{\theta}_{\{\text{DML}\}}$ por MCO de $\tilde{Y}$ sobre $\tilde{W}$, y construir IC al 95% usando el error estándar robusto.

Resultado: $\hat{\theta}_{\{\text{DML}\}} = 0.078$ (IC 95%: $[0.071, 0.085]$). Cada año adicional de educación aumenta el ingreso en aproximadamente 7.8%, controlando flexiblemente por experiencia y demás covariables.

23.8 Procedimiento DML (esquema monográfico)

El flujo operativo del DML puede resumirse en cuatro pasos, todos ellos exigibles en la escritura del argumento causal:

1. **Partición:** dividir la muestra en K pliegues para cross-fitting.
2. **Nuisance fuera de pliegue:** en cada pliegue k , estimar $\hat{\ell}^{(-k)}$ y $\hat{m}^{(-k)}$ (o $\hat{e}^{(-k)}$) solo con datos $i \notin$ pliegue k .
3. **Score ortogonal:** formar residuos $\tilde{Y}_i = Y_i - \hat{\ell}^{(-k)}(\mathbf{X}_i)$ y $\tilde{A}_i = A_i - \hat{m}^{(-k)}(\mathbf{X}_i)$; estimar θ por el score de Neyman (p. ej. MCO de $\tilde{Y}$ sobre $\tilde{A}$ en el modelo parcialmente lineal).
4. **Inferencia:** promediar estimadores por pliegue y reportar varianza robusta / IC asintóticos bajo la tasa producto $o_P\left(n^{-\frac{1}{2}}\right)$ de errores de nuisance.

23.9 Síntesis del Capítulo

- Los **nuisance parameters** $\eta(\mathbf{X}) = (m(\mathbf{X}), e(\mathbf{X}))$ son funciones auxiliares que deben estimarse pero no son el objeto de inferencia. Su estimación con ML regularizado introduce un **sesgo de regularización** de primer orden que vicia la inferencia plug-in sobre θ .

- La **condición de ortogonalidad de Neyman** exige que la derivada de Gateaux del score respecto a η se anule en η_0 . Esto degrada el sesgo por estimar η a **segundo orden**, haciendo que errores $o_P(n^{-\frac{1}{4}})$ en $\hat{\eta}$ sean asintóticamente inocuos para $\hat{\theta}$.
- El **estimador DML** construye residuos ortogonalizados $\tilde{Y}_i = Y_i - \hat{\ell}(\mathbf{X}_i)$ y $\tilde{A}_i = A_i - \hat{m}(\mathbf{X}_i)$ y estima θ por MCO sobre estos residuos. El **cross-fitting** (K pliegues) previene el sesgo de overfitting al estimar $\hat{\eta}$ fuera de muestra.
- Bajo ortogonalidad de Neyman y convergencia $o_P(n^{-\frac{1}{4}})$ de $\hat{\eta}$, $\hat{\theta}_{\{\text{DML}\}}$ es **asintóticamente normal** con varianza estimable. Los intervalos de confianza son válidos incluso con nuisance estimados por ML regularizado.
- El DML es **doblemente robusto**: consistente si al menos uno de $\hat{\ell}$ o $\hat{m}$ está correctamente especificado.
- Los modelos **Partially Linear** e **Interactive** extienden DML a efectos constantes (ATE) y heterogéneos (CATE), respectivamente.

Este capítulo consolida la pieza de inferencia $\sqrt{n}$ -válida con ML del Bloque III. Los capítulos siguientes extienden la heterogeneidad (bosques causales), paneles y evaluación off-policy sin abandonar el contrato de ortogonalidad y validación.

Otras referencias clave de este capítulo: (Robins & Rotnitzky, 1995), (Nie & Wager, 2021), (Laan & Rose, 2011), (Bickel et al., 1993).

23.9 Referencias

- Bickel, P. J., Klaassen, C. A. J., Ritov, Y., & Wellner, J. A. (1993). *Efficient and Adaptive Estimation for Semiparametric Models*. Johns Hopkins University Press.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1-C68.
- Laan, M. J. van der, & Rose, S. (2011). *Targeted Learning: Causal Inference for Observational and Experimental Data*. Springer.
- Neyman, J. (1959). Optimal Asymptotic Tests of Composite Statistical Hypotheses. En *Probability and Statistics: The Harald Cramér Volume: Probability and Statistics: The Harald Cramér Volume* (pp. 213-234). Wiley.
- Nie, X., & Wager, S. (2021). Quasi-Oracle Estimation of Heterogeneous Treatment Effects. *Biometrika*, 108(2), 299-319.
- Robins, J. M., & Rotnitzky, A. (1995). Semiparametric Efficiency in Multivariate Regression Models with Missing Data. *Journal of the American Statistical Association*, 90(429), 122-129.
- Robinson, P. M. (1988). Root-N-Consistent Semiparametric Regression. *Econometrica*, 56(4), 931-954.

CAPÍTULO 24

Efectos Heterogéneos: Árboles Causales y Bosques Causales

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque III · Semilla 42**Notebook (pack):** notebooks/Bloque_III/notebooks/24_efectos_heterogeneos_arboles_causales_bosques.ipynb**Jupyter Book:** jupyter_book/content/bloque_03_descubrimiento_ml/24_efectos_heterogeneos.ipynb

24.1 Motivación: más allá del efecto promedio

Los capítulos anteriores han establecido que el efecto promedio del tratamiento (ATE) es una cantidad insuficiente cuando la respuesta a la intervención varía entre subpoblaciones. En medicina, un fármaco puede beneficiar a unos pacientes y perjudicar a otros; en política social, un programa de transferencias puede tener retornos muy distintos según el nivel de pobreza basal. La pregunta que abordamos en este capítulo es: ¿cómo estimar $\tau(x) = \mathbb{E}[Y^1 - Y^0 \mid X = x]$ con inferencia válida punto a punto?

Los meta-learners del capítulo 23 producen estimaciones puntuales de $\tau(x)$ pero sin garantías de inferencia local. Los árboles y bosques causales de Athey & Imbens (2016) y Wager & Athey (2018) resuelven esta limitación: proporcionan estimadores de $\tau(x)$ junto con errores estándar e intervalos de confianza asintóticamente válidos para cada x .

Definición 24.1 (CATE y su estimación local)

El efecto de tratamiento promedio condicional se define como

$$\tau(x) = \mathbb{E}[Y^1 - Y^0 \mid X = x]. \quad (24.1.1)$$

Bajo ignorabilidad fuerte $(Y^0, Y^1) \perp\!\!\!\perp A \mid X$ y soporte común $0 < \mathbb{P}(A = 1 \mid X = x) < 1$, se tiene

$$\tau(x) = \mathbb{E}[Y \mid A = 1, X = x] - \mathbb{E}[Y \mid A = 0, X = x]. \quad (24.1.2)$$

El desafío es estimar esta diferencia de forma no paramétrica con inferencia válida.

24.2 Árboles de tratamiento adaptativo

24.2.1 Particionamiento recursivo para efectos causales

Los árboles de regresión estándar (CART) particionan el espacio de covariables para minimizar la varianza de Y dentro de cada hoja. En contraste, un árbol causal debe particionar para revelar *heterogeneidad en el efecto del tratamiento*, no en el resultado.

Definición 24.2 (Árbol de tratamiento adaptativo (Athey & Imbens, 2016))

Un *árbol de tratamiento adaptativo* particiona el espacio de covariables $\mathcal{X}$ en K celdas disjuntas $\{\mathcal{L}_1, \dots, \mathcal{L}_K\}$. Dentro de cada celda $\mathcal{L}$, el efecto se estima como

$$\hat{\tau}(\mathcal{L}) = \frac{1}{|\mathcal{I}_1(\mathcal{L})|} \sum_{i \in \mathcal{I}_1(\mathcal{L})} Y_i - \frac{1}{|\mathcal{I}_0(\mathcal{L})|} \sum_{i \in \mathcal{I}_0(\mathcal{L})} Y_i, \quad (24.2.1)$$

donde $\mathcal{I}_a(\mathcal{L}) = \{i : X_i \in \mathcal{L}, A_i = a\}$. El criterio de partición en un nodo $\mathcal{L}$ que se divide en $\mathcal{L}_L$ y $\mathcal{L}_R$ (por una variable X_j y un corte c) maximiza la ganancia en varianza del efecto:

$$\Delta(\mathcal{L}, j, c) = \widehat{\text{Var}}[\hat{\tau}(\mathcal{L}_L)] + \widehat{\text{Var}}[\hat{\tau}(\mathcal{L}_R)] - \widehat{\text{Var}}[\hat{\tau}(\mathcal{L})], \quad (24.2.2)$$

donde $\widehat{\text{Var}}[\hat{\tau}(\mathcal{L})] = \frac{S_1^2(\mathcal{L})}{n_1(\mathcal{L})} + \frac{S_0^2(\mathcal{L})}{n_0(\mathcal{L})}$, con $S_a^2(\mathcal{L})$ la varianza muestral de Y en el brazo a dentro de $\mathcal{L}$.

del criterio: maximizar Δ equivale a buscar la división que produce la mayor diferencia entre los efectos estimados en las hojas hijas y el efecto en la hoja padre. Esto difiere del CART estándar, que maximiza la reducción en varianza de Y . La penalización implícita por tamaños de muestra $n_{a(\mathcal{L})}$ evita divisiones en celdas con pocas observaciones en algún brazo.

24.2.2 El principio de honestidad

Un árbol ingenuo que usa los mismos datos para construir la partición y estimar los efectos produce sobreajuste: las diferencias $\hat{\tau}(\mathcal{L})$ estarán infladas porque la partición se eligió precisamente para maximizarlas. La *honestidad* resuelve este problema.

Definición 24.3 (Árbol honesto (Athey & Imbens, 2016))

Un árbol causal es *honesto* si existe una partición de los datos en dos submuestras disjuntas:

1. **Muestra de construcción** $\mathcal{S}^{\{\text{tr}\}}$: se usa exclusivamente para determinar la estructura del árbol (variables de división y puntos de corte).
2. **Muestra de estimación** $\mathcal{S}^{\{\text{est}\}}$: se usa exclusivamente para estimar $\hat{\tau}(\mathcal{L})$ dentro de cada hoja ya construida.

Para cada observación i , la celda $\hat{\mathcal{L}}(X_i)$ que la contiene fue determinada sin usar la información de i . Formalmente, $\hat{\mathcal{L}}(x)$ es medible respecto a $\mathcal{S}^{\{\text{tr}\}}$ y el estimador $\hat{\tau}(\hat{\mathcal{L}}(x))$ se calcula sobre $\mathcal{S}^{\{\text{est}\}}$.

La honestidad es el análogo en árboles del *sample splitting* en inferencia semiparamétrica (capítulo 23). Garantiza que, condicional en la estructura del árbol, los estimadores dentro de cada hoja son diferencias de medias insesgadas sobre datos independientes, eliminando el sesgo de selección de la partición.

24.2.3 Normalidad asintótica del árbol honesto

Teorema 24.1 (Normalidad asintótica del árbol honesto (Athey & Imbens, 2016))

Sea $\hat{\mathcal{L}}(x)$ la hoja que contiene a x en un árbol honesto. Bajo las siguientes condiciones:

1. **Soporte común:** existe $\eta > 0$ tal que $\eta \leq \mathbb{P}(A = 1 \mid X = x) \leq 1 - \eta$ para todo $x \in \mathcal{X}$.
2. **Tamaño mínimo de hoja:** $|\mathcal{S}^{\{\text{est}\}} \cap \mathcal{L}| \geq k$ para toda hoja $\mathcal{L}$, con $k \rightarrow \infty$ cuando $n \rightarrow \infty$.
3. **Árbol balanceado:** la profundidad del árbol crece como $o(\log n)$ y el número de hojas $K_n = o(\sqrt{n})$.
4. **Momentos finitos:** $\mathbb{E}[Y^4 \mid X, A] < \infty$ y las varianzas condicionales de Y son acotadas lejos de cero.

Entonces, para casi todo x en el soporte de X ,

$$\frac{\hat{\tau}(\hat{\mathcal{L}}(x)) - \tau(x)}{\sqrt{\hat{V}(x)}} \xrightarrow{d} \mathcal{N}(0, 1), \quad (24.2.3)$$

donde $\hat{V}(x) = \frac{\hat{\sigma}_1^2(\hat{\mathcal{L}}(x))}{n_1(\hat{\mathcal{L}}(x))} + \frac{\hat{\sigma}_0^2(\hat{\mathcal{L}}(x))}{n_0(\hat{\mathcal{L}}(x))}$, con $\hat{\sigma}_a^2$ la varianza muestral de Y en el brazo a dentro de la hoja.

24.3 Bosques causales

24.3.1 Agregación de árboles honestos

Así como el Random Forest de Breiman (2001) reduce la varianza del árbol individual promediando muchos árboles, el **bosque causal** (Causal Forest) agrega B árboles causales honestos para obtener un estimador más estable de $\tau(x)$.

Definición 24.4 (Bosque causal (Wager & Athey, 2018))

Dado un punto $x \in \mathcal{X}$, el estimador del bosque causal se define como

$$\hat{\tau}(x) = \frac{\sum_{i=1}^n \alpha_{i(x)} (Y_i - \hat{\mu}^{(-i)}(X_i)) (A_i - \hat{e}^{(-i)}(X_i))}{\sum_{i=1}^n \alpha_{i(x)} (A_i - \hat{e}^{(-i)}(X_i))^2}, \quad (24.3.1)$$

donde:

- $\alpha_{i(x)} = \frac{1}{B} \sum_{b=1}^B \frac{\mathbf{1}(i \in \mathcal{L}_{b(x)})}{|\mathcal{L}_{b(x)}|}$ es el peso que el bosque asigna a la observación i para predecir en x , promediando sobre los B árboles.
- $\mathcal{L}_{b(x)}$ denota la hoja del árbol b que contiene a x .
- $\hat{\mu}^{(-i)}(X_i)$ y $\hat{e}^{(-i)}(X_i)$ son estimaciones *out-of-bag* de $\mathbb{E}[Y \mid X = X_i]$ y $\mathbb{E}[A \mid X = X_i]$, respectivamente.

La fórmula tiene una interpretación de **mínimos cuadrados ponderados localmente**: $\hat{\tau}(x)$ es el coeficiente de la regresión de los residuos de Y sobre los residuos de A , ponderados por la similitud $\alpha_{i(x)}$ entre X_i y x . Esto conecta el bosque causal con el R-learner del capítulo 23.

24.3.2 Gaussianidad puntual del Causal Forest

Teorema 24.2 (Gaussianidad puntual del Causal Forest (Wager & Athey, 2018))

Sea $\hat{\tau}(x)$ el estimador del bosque causal con B árboles, cada uno entrenado en una submuestra de tamaño s_n (sin reemplazo, $s_n \sim n^{\text{beta}}$ con $0 < \beta < 1$). Bajo las mismas condiciones del Teorema Teorema 313, más:

1. **Subsampling:** $s_n \rightarrow \infty$, $\frac{s_n}{n} \rightarrow 0$ (el tamaño de submuestra crece pero es asintóticamente despreciable frente a n).
2. **Honestidad:** cada árbol usa división honesta de la submuestra.
3. **Condiciones de crecimiento:** $\min_{\mathcal{L}} |\mathcal{L}| \gg s_n^{\frac{1}{2}}$ y el diámetro máximo de las hojas tiende a cero.

Entonces, para casi todo x ,

$$\sqrt{s_n}(\hat{\tau}(x) - \tau(x)) \xrightarrow{d} \mathcal{N}(0, \sigma^2(x)), \quad (24.3.2)$$

donde $\sigma^2(x)$ es estimable de manera consistente mediante el *jackknife infinitesimal*:

$$\hat{\sigma}^2(x) = \frac{n-1}{n} \left(\frac{n}{n-s_n} \right)^2 \sum_{i=1}^n \text{Cov}_* \left(\hat{\tau}_{b(x)}, N_{bi} \right)^2, \quad (24.3.3)$$

con N_{bi} el indicador de que la observación i aparece en la submuestra del árbol b y Cov_* la covarianza empírica sobre los B árboles.

24.3.3 Local centering: ortogonalización en el bosque causal

Una innovación práctica crucial es el *local centering* (también llamado ortogonalización previa):

Definición 24.5 (Local centering (ortogonalización en bosque causal))

El procedimiento de *local centering* transforma las variables originales antes de entrenar el bosque causal:

1. Estimar $\hat{m}(x) = \hat{\mathbb{E}}[Y | X = x]$ usando un Random Forest de regresión estándar (u otro método de ML supervisado).
2. Estimar $\hat{e}(x) = \hat{\mathbb{E}}[A | X = x]$ usando un Random Forest de clasificación (o regresión logística regularizada).
3. Construir los residuos: $\tilde{Y}_i = Y_i - \hat{m}(X_i)$, $\tilde{A}_i = A_i - \hat{e}(X_i)$.
4. Entrenar el bosque causal sobre los datos transformados $\{(\tilde{Y}_i, \tilde{A}_i, X_i)\}_{i=1}^n$.

El estimador resultante es

$$\hat{\tau}_{\{\text{LC}\}}(x) = \frac{\sum_{i=1}^n \alpha_{i(x)} \tilde{Y}_i \tilde{A}_i}{\sum_{i=1}^n \alpha_{i(x)} \tilde{A}_i^2}. \quad (24.3.4)$$

El local centering reduce el sesgo porque $\mathbb{E}[\tilde{Y} | X] = \tau(X) \cdot \tilde{A}$ asintóticamente, eliminando la necesidad de que el bosque capture la relación directa $X \rightarrow Y$ (modelada por $\hat{m}$) y $X \rightarrow A$ (modelada por $\hat{e}$). Esto es análogo a la ortogonalización de Robinson (1988) usada en DML (capítulo 23), pero aplicada localmente a través de los pesos adaptativos del bosque. Nótese que si $\hat{m}$ y $\hat{e}$ se estiman con cross-fitting, la doble robustez se preserva también en este contexto.

24.3.4 PEHE: métrica de evaluación de heterogeneidad

Cuando se dispone de datos simulados o semisintéticos donde $\tau(x)$ es conocido (por construcción), la calidad de la estimación de heterogeneidad se mide con el PEHE.

Definición 24.6 (PEHE (Precision in Estimation of Heterogeneous Treatment Effects))

El *PEHE* (Hill, 2011) se define como la raíz del error cuadrático medio entre el CATE estimado y el verdadero:

$$\text{PEHE} = \sqrt{\mathbb{E}_X[(\hat{\tau}(X) - \tau(X))^2]}. \quad (24.3.5)$$

En una muestra finita, se estima empíricamente como

$$\widehat{\text{PEHE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{\tau}(X_i) - \tau(X_i))^2}. \quad (24.3.6)$$

El PEHE admite la descomposición sesgo-varianza: $\text{PEHE}^2 = \text{Var}(\hat{\tau}) + (\mathbb{E}[\hat{\tau}] - \tau)^2$. Un buen estimador de CATE minimiza ambos componentes simultáneamente. En aplicaciones reales donde $\tau(x)$ es desconocido, se utilizan métricas proxy como el área bajo la curva QINI (Radcliffe, 2007) o el coeficiente de calibración del BLP (Best Linear Projection de Chernozhukov et al. (2018)).

24.4 Regla de targeting óptimo

Una vez estimado $\hat{\tau}(x)$, surge la pregunta de política: ¿a quién tratar?

Proposición 24.1 (Regla de targeting óptimo)

Sea $c > 0$ el costo de administrar el tratamiento y $v > 0$ el valor monetario de una unidad de resultado Y ($v = 1$ si Y ya está expresado en unidades de beneficio). Bajo ignorabilidad y tratamiento binario, la política que maximiza el beneficio neto esperado es:

$$\pi^*(x) = \mathbf{1}\left(\tau(x) \geq \frac{c}{v}\right). \quad (24.4.1)$$

El beneficio incremental esperado de esta política sobre no tratar a nadie es

$$\Delta(\pi^*) = \mathbb{E}\left[\tau(X) \cdot \mathbf{1}\left(\tau(X) \geq \frac{c}{v}\right)\right] - \frac{c}{v} \cdot \mathbb{P}\left(\tau(X) \geq \frac{c}{v}\right). \quad (24.4.2)$$

En la práctica, $\tau(x)$ se reemplaza por $\hat{\tau}(x)$ obtenido del bosque causal, y el umbral $\frac{c}{v}$ puede calibrarse para satisfacer restricciones presupuestarias. El capítulo 27 profundiza en la evaluación de políticas aprendidas mediante off-policy evaluation.

24.5 Diagrama causal del proceso de estimación

El bosque causal estima $\tau(X)$ directamente a partir de (X, A, Y) sin necesidad de modelar explícitamente la relación $X \rightarrow Y$ (salvo en la etapa de local centering, donde esta relación se utiliza para reducir sesgo). La honestidad garantiza que el error de estimación de la estructura del árbol no contamina asintóticamente la inferencia sobre $\tau(x)$.

24.6 Procedimiento algorítmico del Causal Forest

A continuación se describe el algoritmo completo en forma estructurada, integrando todos los elementos anteriores.

Método 24.1 (Causal Forest con local centering y jackknife infinitesimal)

Entrada: Datos $\{(X_i, A_i, Y_i)\}_{i=1}^n$, número de árboles B , tamaño de submuestra s_n , K folds para cross-fitting.

Paso 1 – Local centering (ortogonalización):

1. Dividir aleatoriamente los índices $\{1, \dots, n\}$ en K pliegues $\mathcal{I}_1, \dots, \mathcal{I}_K$ de tamaño similar.
2. Para cada pliegue $k = 1, \dots, K$:

Paso 2 – Construcción del bosque:

1. Para $b = 1$ a B :

Paso 3 – Predicción para un punto x :

1. Para cada árbol b , identificar la hoja $\mathcal{L}_{b(x)}$ que contiene a x .
2. Calcular los pesos: $\alpha_{i(x)} = \frac{1}{B} \sum_{b=1}^B \frac{\mathbf{1}(i \in \mathcal{L}_{b(x)})}{|\mathcal{L}_{b(x)}|}$.
3. Estimar: $\hat{\tau}(x) = \frac{\sum_{i=1}^n \alpha_{i(x)} Y_i A_i}{\sum_{i=1}^n \alpha_{i(x)} A_i^2}$.

Paso 4 – Inferencia:

1. Calcular la varianza por jackknife infinitesimal:

$$\hat{\sigma}^2(x) = \frac{n-1}{n} \left(\frac{n}{n-s_n} \right)^2 \sum_{i=1}^n \left(\frac{1}{B} \sum_{b=1}^B (\hat{\tau}_{b(x)} - \hat{\tau}(x)) \left(N_{bi} - \frac{s_n}{n} \right) \right)^2. \quad (24.6.1)$$

2. Construir el intervalo de confianza de nivel $1 - \alpha$:

$$\text{IC}_{1-\alpha}(x) = \left[\hat{\tau}(x) - z_{\frac{\alpha}{2}} \cdot \hat{\sigma} \frac{x}{\sqrt{s_n}}, \hat{\tau}(x) + z_{\frac{\alpha}{2}} \cdot \hat{\sigma} \frac{x}{\sqrt{s_n}} \right]. \quad (24.6.2)$$

Salida: $\hat{\tau}(x)$ e intervalo de confianza para cada punto x de interés.

24.7 Ejemplos de aplicación

Ejemplo 24.1 (Personalización de tratamiento médico)

En un ensayo clínico de antihipertensivos, se registran $X = (\text{edad}, \text{presión basal}, \text{IMC}, \text{sexo})$, $A \in \{\text{fármaco nuevo}, \text{estándar}\}$ e $Y = \text{reducción de presión sistólica en mmHg}$. Se entrena un bosque causal con $B = 2000$ árboles y local centering. Los resultados revelan que pacientes jóvenes (< 45 años) con presión basal moderada muestran $\hat{\tau}(x) \approx -2.1$ mmHg (IC 95%: $[-3.8, -0.4]$), indicando que el fármaco nuevo es inferior al estándar en este subgrupo. En contraste, adultos mayores (≥ 65 años) con hipertensión severa muestran $\hat{\tau}(x) \approx 5.7$ mmHg (IC 95%: $[3.2, 8.1]$). Este hallazgo, obtenido sin preespecificar subgrupos, motiva un análisis confirmatorio estratificado y potencialmente una indicación personalizada.

Ejemplo 24.2 (Marketing: targeting de promociones)

Una cadena de retail dispone de covariables $X = (\text{frecuencia de compra}, \text{gasto promedio}, \text{categoría favorita}, \text{antigüedad})$, tratamiento $A = \text{envío de cupón de descuento}$, y resultado $Y = \text{gasto incremental en la semana siguiente}$. Con un costo del cupón $c = 3\$$ y valor marginal $v = 1$, la regla de targeting óptimo prescribe enviar el cupón solo a clientes con $\hat{\tau}(x_i) \geq 3$. El bosque causal revela que solo el 28% de los clientes satisface este umbral; el 72% restante tiene un efecto estimado menor que el costo o incluso negativo (clientes que habrían comprado de todas formas, generando pérdida por el descuento). La política selectiva produce un beneficio incremental estimado de 1.87\$ por cliente en la base, frente a 0.32\$ de la política universal.

24.8 Síntesis del Capítulo

Este capítulo ha presentado los árboles causales y bosques causales como herramientas para la estimación no paramétrica de efectos heterogéneos del tratamiento con inferencia puntual válida. La honestidad —separación de las muestras de construcción y estimación— es el principio clave que permite la normalidad asintótica del estimador dentro de cada hoja. El bosque causal agrega árboles honestos entrenados en submuestras y, combinado con local centering (ortogonalización previa de Y y A respecto a X), produce estimadores del CATE con intervalos de confianza asintóticamente válidos mediante el jackknife infinitesimal. La regla de targeting óptimo conecta la estimación del CATE con la toma de decisiones: tratar si y solo si $\hat{\tau}(x) \geq \frac{c}{v}$, maximizando el beneficio neto esperado.

Supuestos clave

1. **Ignorabilidad fuerte:** $(Y^0, Y^1) \perp\!\!\!\perp A \mid X$.
2. **Soporte común:** existe $\eta > 0$ tal que $\eta \leq \mathbb{P}(A = 1 \mid X = x) \leq 1 - \eta$ para todo $x \in \mathcal{X}$.
3. **SUTVA:** el resultado potencial de cada unidad no depende del tratamiento asignado a otras unidades.
4. **Honestidad:** la estructura del árbol se determina en una submuestra disjunta de aquella donde se estiman los efectos dentro de cada hoja.
5. **Condiciones de crecimiento:** el número de hojas $K_n = o(\sqrt{n})$, el tamaño mínimo de hoja tiende a infinito, y la profundidad del árbol crece como $o(\log n)$.
6. **Momentos finitos:** $\mathbb{E}[Y^4 \mid X, A] < \infty$ y la varianza condicional $\text{Var}(Y \mid X, A)$ está acotada lejos de cero.
7. **Subsampling:** $s_n \rightarrow \infty$ y $\frac{s_n}{n} \rightarrow 0$ cuando $n \rightarrow \infty$.

En el próximo capítulo extendemos la inferencia causal al dominio temporal, abordando los desafíos de dependencia serial, confounders dinámicos y políticas de tratamiento secuenciales mediante métodos de diferencias en diferencias con machine learning y Q-learning para reglas dinámicas.

Otras referencias clave de este capítulo: (Athey et al., 2019), (Efron, 2014).

24.8 Referencias

- Athey, S., & Imbens, G. (2016). Recursive Partitioning for Heterogeneous Causal Effects. *Proceedings of the National Academy of Sciences*, 113(27), 7353-7360.
- Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized Random Forests. *The Annals of Statistics*, 47(2), 1148-1178.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
- Chernozhukov, V., Demirer, M., Duflo, E., & Fernández-Val, I. (2018). *Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments* (technical report No. 24678).
- Efron, B. (2014). Estimation and Accuracy after Model Selection. *Journal of the American Statistical Association*, 109(507), 991-1007.
- Hill, J. L. (2011). Bayesian Nonparametric Modeling for Causal Inference. *Journal of Computational and Graphical Statistics*, 20(1), 217-240.
- Radcliffe, N. J. (2007). Using Control Groups to Target on Predicted Lift. *Journal of Direct, Data and Digital Marketing Practice*, 9(1), 14-27.
- Robinson, P. M. (1988). Root-N-Consistent Semiparametric Regression. *Econometrica*, 56(4), 931-954.
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests. *Journal of the American Statistical Association*, 113(523), 1228-1242.

CAPÍTULO 25

Causalidad en Series de Tiempo y Paneles con Machine Learning

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque III · Semilla 42**Notebook (pack):** notebooks/Bloque_III/notebooks/25-causalidad_series_tiempo_paneles_machine.ipynb**Jupyter Book:** jupyter_book/content/bloque_03_descubrimiento_ml/25_series_tiempo_paneles.ipynb

25.1 Desafíos de la inferencia causal en el tiempo

Los capítulos previos han asumido —explícita o implícitamente— que las observaciones son independientes e idénticamente distribuidas. En datos de panel y series de tiempo, esta premisa se desmorona. La dependencia temporal introduce cuatro desafíos fundamentales:

Definición 25.1 (Desafíos de inferencia causal temporal)

La inferencia causal con datos longitudinales debe enfrentar:

1. **Dependencia temporal:** el resultado en t depende de resultados y covariables en $t-1, t-2, \dots$, violando la independencia entre unidades del SUTVA tradicional. La dependencia serial puede ser de corto alcance (estacionaria) o de largo alcance (no estacionaria).
2. **Confounders dinámicos:** una covariable X_{t-1} puede ser simultáneamente (i) predictora del tratamiento A_t , (ii) consecuencia del tratamiento previo A_{t-1} , y (iii) causa del resultado Y_t . Esta triple función —confounder, mediador y colider— hace que el ajuste estándar por regresión sesgue la estimación.
3. **Anticipación y spillovers:** los agentes económicos anticipan intervenciones y ajustan su comportamiento antes de que ocurran (efectos Ashenfelter's dip). Los spillovers espaciales o de red violan SUTVA: el tratamiento de la unidad i afecta el resultado de j .
4. **Heterogeneidad no observada variante en el tiempo:** los efectos fijos de unidad α_i capturan confounders constantes, pero no aquellos que evolucionan con t . Si α_{it} varía y se correlaciona con A_{it} , ni los efectos fijos ni las primeras diferencias resuelven el problema.

25.1.1 Estructura causal en panel

Considérese un panel balanceado con N unidades y T periodos donde el tratamiento binario A_{it} se activa en $t = g_i$ para la unidad i (diseño de adopción escalonada). El DAG simplificado para una unidad es: El efecto de A_{i2} sobre Y_{i3} requiere bloquear la puerta trasera $A_{i2} \leftarrow X_{i1} \rightarrow Y_{i3}$ y $A_{i2} \leftarrow X_{i1} \leftarrow \alpha_i \rightarrow Y_{i3}$. Los efectos fijos absorben α_i pero no X_{i1} si este varía en el tiempo.

25.2 ATT por cohorte-periodo: Callaway y Sant'Anna

25.2.1 El problema del TWFE con adopción escalonada



El estimador *Two-Way Fixed Effects* (TWFE) clásico,

$$Y_{it} = \alpha_i + \beta_t + \tau D_{it} + \epsilon_{it}, \quad (25.2.1)$$

es ubicuo en la práctica. Sin embargo, con adopción escalonada (distintas unidades se tratan en distintos momentos), $\hat{\tau}_{\{TWFE\}}$ es un promedio ponderado de efectos de tratamiento donde algunas ponderaciones pueden ser negativas Goodman-Bacon (2021)⁵.

25.2.2 Descomposición por cohorte-periodo

Callaway & Sant'Anna (2021) proponen descomponer el problema en efectos *grupo-tiempo*:

Definición 25.2 (ATT por grupo-tiempo)

Para una cohorte g (unidades tratadas por primera vez en el periodo g) y un periodo $t \geq g$, el efecto promedio del tratamiento sobre los tratados de esa cohorte en ese periodo es:

$$ATT(g, t) = \mathbb{E}[Y_{t(g)} - Y_{t(\infty)} \mid G = g], \quad (25.2.2)$$

donde $Y_{t(g)}$ es el resultado potencial bajo tratamiento desde g y $Y_{t(\infty)}$ es el resultado potencial bajo *nunca tratamiento*. La identificación se logra usando como grupo de control únicamente:

1. Unidades **nunca tratadas** ($G = \infty$), o
2. Unidades **aún no tratadas** en t ($G > t$).

Bajo el supuesto de tendencias paralelas condicionales $-\mathbb{E}[Y_{t(\infty)} - Y_{g-1}(\infty) \mid X, G = g] = \mathbb{E}[Y_{t(\infty)} - Y_{g-1}(\infty) \mid X, G = \infty]$, el $ATT(g, t)$ se estima mediante un estimador doubly robust que combina regresión del resultado y ponderación por propensity score de cohorte. La agregación a un ATT global se realiza promediando los $ATT(g, t)$ con ponderaciones basadas en el tamaño de cada cohorte, evitando así las ponderaciones negativas del TWFE.

25.3 Synthetic Difference-in-Differences (SDID)

25.3.1 Motivación y formulación

El SDID de Arkhangelsky et al. (2021) sintetiza dos tradiciones: el control sintético (Abadie et al., 2010, que pondera unidades de control para igualar tendencias pre-tratamiento) y el DiD, que pondera periodos para igualar tendencias temporales.

Definición 25.3 (Estimador SDID)

Sean $N_{\{tr\}}$ unidades tratadas (todas tratadas en el mismo periodo $T_0 + 1$) y $N_{\{co\}}$ unidades de control nunca tratadas. El estimador SDID resuelve:

$$(\hat{\tau}, \hat{\alpha}, \hat{\beta}) = \arg \min_{\tau, \alpha, \beta} \sum_{i=1}^N \sum_{t=1}^T (Y_{it} - \alpha_i - \beta_t - \tau D_{it})^2 \hat{\omega}_i \hat{\lambda}_t, \quad (25.3.1)$$

donde:

- $\hat{\omega}_i \geq 0$ son pesos de unidad que minimizan la discrepancia pre-tratamiento entre el promedio ponderado de controles y el promedio de tratados: $\sum_i \hat{\omega}_i = 1$, y para cada $t \leq T_0$, $\sum_{i: D_i=0} \hat{\omega}_i Y_{it} \approx \frac{1}{N_{\{tr\}}} \sum_{i: D_i=1} Y_{it}$.
- $\hat{\lambda}_t \geq 0$ son pesos de periodo que minimizan la discrepancia entre el promedio pre-tratamiento y el post-tratamiento para los controles: $\sum_t \hat{\lambda}_t = 1$, $\sum_{t=1}^{T_0} \hat{\lambda}_t = 1$, $\lambda_t = 0$ para $t > T_0$.

⁵Véase también Chaisemartin & D'Haultfoeulle (2020), que documenta el mismo fenómeno de forma independiente.

Los pesos se obtienen mediante programación cuadrática con restricciones de simplex, análogo al control sintético pero en ambas dimensiones. El balanceo dual (unidades $\times$ periodos) confiere al SDID propiedades de doble robustez.

25.3.2 Propiedades asintóticas del SDID

Teorema 25.1 (Consistencia del SDID (Arkhangelsky et al., 2021))

Supóngase que el resultado potencial sin tratamiento sigue un modelo de factores interactivos:

$$Y_{it}(0) = \alpha_i + \beta_t + \sum_{r=1}^R \gamma_{ir} \delta_{tr} + \epsilon_{it}, \quad (25.3.2)$$

donde ϵ_{it} es ruido idiosincrático con $\mathbb{E}[\epsilon_{it}] = 0$ e independiente del tratamiento. Si R es fijo y los pesos $\hat{\omega}_i, \hat{\lambda}_t$ convergen a pesos poblacionales que balancean los primeros R factores, entonces:

$$\hat{\tau}_{\{\text{SDID}\}} \xrightarrow{P} \tau_{\{\text{ATT}\}}, \quad (25.3.3)$$

cuando $N_{\{\text{tr}\}}, N_{\{\text{co}\}}, T_0 \rightarrow \infty$. Más aún, $\hat{\tau}_{\{\text{SDID}\}}$ es asintóticamente normal con varianza estimable mediante bootstrap por unidad (no por periodo, para preservar la estructura de dependencia).

25.4 G-computation para datos de panel

Cuando el tratamiento varía en el tiempo y las covariables son afectadas por tratamientos pasados, se requiere un enfoque secuencial.

Definición 25.4 (G-computation para panel (Robins, 1986))

Sea $\bar{A}_T = (A_1, \dots, A_T)$ una secuencia de tratamientos y $\bar{X}_T$ la historia de covariables. Bajo **ignorabilidad secuencial**:

$$Y_{T(\bar{a})} \perp\!\!\!\perp A_t \mid \bar{X}_t, \bar{A}_{t-1} = \bar{a}_{t-1}, \quad \forall t, \quad (25.4.1)$$

el resultado potencial esperado bajo el régimen $\bar{a}$ se identifica mediante la fórmula G:

$$\mathbb{E}[Y_{T(\bar{a})}] = \int \dots \int \mathbb{E}[Y_T \mid \bar{X}_T, \bar{A}_T = \bar{a}] \times \prod_{t=1}^T dP(X_t \mid \bar{X}_{t-1}, \bar{A}_{t-1} = \bar{a}_{t-1}). \quad (25.4.2)$$

El procedimiento de estimación con ML es:

1. Para cada $t = 1, \dots, T$, estimar la densidad condicional $\hat{p}_t(X_t \mid \bar{X}_{t-1}, \bar{A}_{t-1})$ usando modelos generativos flexibles (GANs, VAEs condicionales, o directamente Random Forest cuantílico).
2. Estimar $\hat{\mu}_{T(\bar{X}_T, \bar{A}_T)} = \hat{\mathbb{E}}[Y_T \mid \bar{X}_T, \bar{A}_T]$ mediante cualquier método de regresión supervisada (Gradient Boosting, redes neuronales).
3. Simular M trayectorias bajo el régimen $\bar{a}$: para $m = 1, \dots, M$, muestrear secuencialmente $X_t^{(m)} \sim \hat{p}_t(\cdot \mid \bar{X}_{t-1}^{(m)}, \bar{a}_{t-1})$ y luego predecir $\hat{Y}_T^{(m)} = \hat{\mu}_{T(\bar{X}_T^{(m)}, \bar{a})}$.
4. Estimar $\hat{\mathbb{E}}[Y_{T(\bar{a})}] = \frac{1}{M} \sum_{m=1}^M \hat{Y}_T^{(m)}$.

Este procedimiento, conocido como *G-computation Monte Carlo*, es computacionalmente intensivo pero conceptualmente transparente: simula el contrafactual bajo el régimen de interés marginalizando sobre la distribución de las covariables intermedias.

25.5 Reglas de Tratamiento Dinámico (DTR) y Q-learning

25.5.1 Formulación del problema

Definición 25.5 (Regla de Tratamiento Dinámico (DTR))

Una *regla de tratamiento dinámico* es una secuencia de funciones de decisión $d = (d_1, \dots, d_T)$ donde $d_t : \mathcal{H}_t \rightarrow \{0, 1\}$ mapea la historia $H_t = (\bar{X}_t, \bar{A}_{t-1}, \bar{Y}_{t-1})$ a una decisión de tratamiento en el periodo t . El objetivo es encontrar el régimen óptimo:

$$d^* = \arg \max_{d \in \mathcal{D}} \mathbb{E}[Y_{T(d)}], \quad (25.5.1)$$

donde $\mathcal{D}$ es la clase de reglas admisibles y $Y_{T(d)}$ es el resultado potencial bajo el régimen d .

Las DTR son fundamentales en medicina personalizada (tratamientos adaptativos como quimioterapia según respuesta), educación (intervenciones escalonadas según progreso) y robótica (políticas secuenciales).

25.5.2 Q-learning para DTR

Método 25.1 (Q-learning para Reglas de Tratamiento Dinámico (DTR))

Entrada: Datos longitudinales $\{(H_{it}, A_{it}, Y_{it})\}_{i=1}^n$ para $t = 1, \dots, T$, con Y_{iT} el resultado final. **Procedimiento (retroceso temporal):**

1. **Paso T (último periodo):** Ajustar el modelo Q para el resultado final:

$$\hat{Q}_{T(H_T, A_T)} = \hat{\mathbb{E}}[Y_T \mid H_T, A_T], \quad (25.5.2)$$

utilizando cualquier método de ML supervisado (Random Forest, GBM, red neuronal). Este modelo estima el valor esperado del resultado final condicional en la historia completa y la última acción.

2. **Para $t = T - 1$ hasta 1 (retroceso):**

Salida: Secuencia de reglas de tratamiento $\hat{d}^* = (\hat{d}_1^*, \dots, \hat{d}_T^*)$.

El Q-learning es una adaptación del algoritmo de *fitted Q-iteration* del aprendizaje por refuerzo (capítulo 26) al contexto causal. La diferencia crucial es que en inferencia causal los datos son observacionales (no generados por exploración) y se requiere el supuesto de ignorabilidad secuencial para identificar las Q-funciones. La maximización en el paso de retroceso asume que el soporte de A_t dado H_t es completo (no hay acciones con probabilidad cero en la muestra).

25.6 Estructura temporal de un régimen dinámico

Un DTR opera sobre historias $H_t = (\bar{X}_t, \bar{A}_{t-1})$: en cada etapa t se elige A_t y se actualiza el estado. La identificación del valor de una política requiere ignorabilidad secuencial y positividad en cada t . El retroceso (g-computation / Q-learning causal) construye Q_t desde $t = T$ hasta $t = 1$; confundir este esquema con un TWFE de panel es un error de nivel GCE: el primero es control secuencial, el segundo es localización bajo tendencias paralelas.

25.7 Cierre del capítulo

Paneles y regímenes dinámicos exigen ignorabilidad secuencial y soporte en cada etapa. TWFE, estimadores por cohorte y Q-learning causal son herramientas distintas: confundirlas es confundir diseño con control secuencial.

Otras referencias clave de este capítulo: (Murphy, 2003).

25.7 Referencias

- Abadie, A., Diamond, A., & Hainmueller, J. (2010). Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California's Tobacco Control Program. *Journal of the American Statistical Association*, 105(490), 493-505.
- Arkhangelsky, D., Athey, S., Hirshberg, D. A., Imbens, G. W., & Wager, S. (2021). Synthetic Difference-in-Differences. *American Economic Review*, 111(12), 4088-4118.
- Callaway, B., & Sant'Anna, P. H. C. (2021). Difference-in-Differences with Multiple Time Periods. *Journal of Econometrics*, 225(2), 200-230.
- Chaisemartin, C. de, & D'Haultfœuille, X. (2020). Two-Way Fixed Effects Estimators with Heterogeneous Treatment Effects. *American Economic Review*, 110(9), 2964-2996.
- Goodman-Bacon, A. (2021). Difference-in-Differences with Variation in Treatment Timing. *Journal of Econometrics*, 225(2), 254-277.
- Murphy, S. A. (2003). Optimal Dynamic Treatment Regimes. *Journal of the Royal Statistical Society: Series B*, 65(2), 331-355.
- Robins, J. (1986). A New Approach to Causal Inference in Mortality Studies with a Sustained Exposure Period—Application to Control of the Healthy Worker Survivor Effect. *Mathematical Modelling*, 7(9-12), 1393-1512.

CAPÍTULO 26

Off-Policy Evaluation, Bandits y Política Óptima

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque III · Semilla 42**Notebook (pack):** notebooks/Bloque_III/notebooks/26_off_policy_evaluation_bandits_politica.ipynb**Jupyter Book:** jupyter_book/content/bloque_03_descubrimiento_ml/26_off_policy_evaluation.ipynb

26.1 Evaluación de políticas a partir de datos observacionales

En los capítulos 23–25 abordamos la estimación del CATE $\tau(x)$ y la política óptima $\pi^*(x) = \mathbf{1}(\tau(x) \geq \frac{c}{v})$. Pero una pregunta fundamental queda sin responder: ¿cómo evaluar el valor de una política π_e usando datos generados por una política distinta π_b ? Este es el problema de la **evaluación off-policy** (OPE, *Off-Policy Evaluation*), central en sistemas de recomendación, ensayos clínicos adaptativos y política pública.

Definición 26.1 (Política de comportamiento y política evaluada)

Sean:

- $\pi_{b(a|x)} = \mathbb{P}(A = a | X = x)$ la **política de comportamiento** (también llamada *logging policy*) que generó los datos históricos $\mathcal{D} = \{(X_i, A_i, Y_i)\}_{i=1}^n$.
- $\pi_{e(a|x)}$ la **política evaluada** (o *target policy*), que puede ser determinista: $\pi_{e(x)} \in \{0, 1\}$.

El **soporte común** requiere que $\pi_{e(a|x)} > 0 \Rightarrow \pi_{b(a|x)} > 0$ para todo (x, a) . Sin esta condición, hay acciones que la política evaluada tomaría pero que nunca se observaron en los datos, imposibilitando la evaluación sin extrapolación.

El valor de una política π es la recompensa esperada si las acciones se eligen según π :

$$V(\pi) = \mathbb{E}_{X \sim P_X, A \sim \pi(\cdot|X)}[Y] = \mathbb{E}_X \left[\sum_{a \in \{0,1\}} \pi(a | X) \cdot \mathbb{E}[Y | X, A = a] \right]. \quad (26.1.1)$$

26.1.1 Conexión con la jerarquía causal

El valor $V(\pi_e)$ corresponde al resultado esperado bajo la intervención $\text{do}(A = \pi_{e(X)})$ en el sentido del do-cálculo de Pearl (capítulo 18). La identificabilidad de $V(\pi_e)$ a partir de datos observacionales requiere ignorabilidad: $(Y^0, Y^1) \perp\!\!\!\perp A | X$, exactamente el mismo supuesto que para el ATE y el CATE. Si existen confounders no observados, la OPE requiere estructura causal adicional (variables instrumentales, restricciones de exclusión, o diseños de discontinuidad).

26.2 Estimador de Importance Sampling (IPS)

26.2.1 Formulación básica



El estimador más directo para OPE es el *Inverse Propensity Scoring* (IPS), que repondera las observaciones según la razón de probabilidades entre la política evaluada y la de comportamiento.

Definición 26.2 (Estimador IPS para OPE)

$$\hat{V}_{\{\text{IPS}\}}(\pi_e) = \frac{1}{n} \sum_{i=1}^n \frac{\pi_e(A_i | X_i)}{\pi_b(A_i | X_i)} Y_i. \quad (26.2.1)$$

Para política determinista $\pi_{e(x)} \in \{0, 1\}$, el peso es $w_i = \mathbf{1}_{\frac{A_i = \pi_e(X_i)}{\pi_b(A_i | X_i)}}$.

Proposición 26.1 (Inesgamiento del IPS)

Bajo soporte común e ignorabilidad, $\mathbb{E}[\hat{V}_{\{\text{IPS}\}}(\pi_e)] = V(\pi_e)$.

Limitación fundamental: la varianza del IPS puede ser arbitrariamente grande si π_e difiere sustancialmente de π_b , porque los pesos $w_i = \frac{\pi_e}{\pi_b}$ pueden ser muy grandes para algunas observaciones. La varianza asintótica es

$$\text{Var}(\hat{V}_{\{\text{IPS}\}}) = \frac{1}{n} \mathbb{E} \left[\left(\frac{\pi_e(A|X)}{\pi_b(A|X)} \right)^2 \text{Var}(Y | X, A) \right] + \frac{1}{n} \text{Var}(\mathbb{E}[Y | X, \pi_e]), \quad (26.2.2)$$

donde el primer término involucra el segundo momento de los pesos y puede dominar cuando $\frac{\pi_e}{\pi_b}$ tiene colas pesadas.

26.3 Estimador Doubly Robust para OPE

26.3.1 Combinación de modelo directo e IPS

El estimador *Doubly Robust* (DR-OPE) combina un modelo de resultado $\hat{Q}(x, a) = \hat{\mathbb{E}}[Y | X = x, A = a]$ con la corrección por propensity score, heredando las ventajas de ambos enfoques.

Definición 26.3 (Estimador DR para Off-Policy Evaluation)

$$\hat{V}_{\{\text{DR}\}}(\pi_e) = \frac{1}{n} \sum_{i=1}^n \left[\hat{V}_{\{\text{DM}\}}^{(i)}(\pi_e) + \frac{\pi_e(A_i | X_i)}{\pi_b(A_i | X_i)} (Y_i - \hat{Q}(X_i, A_i)) \right], \quad (26.3.1)$$

donde $\hat{V}_{\{\text{DM}\}}^{(i)}(\pi_e) = \sum_{a \in \{0,1\}} \pi_e(a | X_i) \cdot \hat{Q}(X_i, a)$ es la predicción del modelo directo para la política π_e en el punto X_i . Equivalentemente:

$$\hat{V}_{\{\text{DR}\}}(\pi_e) = \frac{1}{n} \sum_{i=1}^n \left[\hat{Q}(X_i, \pi_e(X_i)) + \frac{\mathbf{1}(A_i = \pi_e(X_i))}{\pi_b(A_i | X_i)} (Y_i - \hat{Q}(X_i, A_i)) \right], \quad (26.3.2)$$

para π_e determinista.

Teorema 26.1 (Doble robustez del DR-OPE (Dudík et al., 2011))

El estimador $\hat{V}_{\{\text{DR}\}}(\pi_e)$ es consistente para $V(\pi_e)$ si se cumple **al menos una** de las siguientes condiciones:

1. **Modelo de resultado correcto:** $\hat{Q}(x, a) \xrightarrow{p} Q_0(x, a) = \mathbb{E}[Y | X = x, A = a]$ para todo (x, a) .
2. **Modelo de propensity correcto:** $\hat{\pi}_{b(a|x)} \xrightarrow{p} \pi_{b(a|x)}$ para todo (x, a) .

Si ambos modelos son correctos, el estimador alcanza la cota de eficiencia semiparamétrica.

26.4 Bandits contextuales y regret

26.4.1 Formulación del problema

En el problema del **bandit contextual** (contextual bandit), un agente interactúa con el entorno durante T rondas. En cada ronda t :

1. Se observa un contexto $X_t \in \mathcal{X}$ (posiblemente adversarial o estocástico).
2. El agente elige una acción $A_t \in \mathcal{A}$ según su política actual π_t .
3. Se observa (y se recibe) una recompensa $Y_t \sim P(Y | X_t, A_t)$.

El objetivo es maximizar la recompensa acumulada $\sum_{t=1}^T Y_t$, equivalentemente, minimizar el **regret** (arrepentimiento).

Definición 26.4 (Regret en bandits contextuales)

Sea π^* la política óptima (la que maximiza $V(\pi)$). El *regret* acumulado tras T rondas es:

$$R_T = \sum_{t=1}^T (V(\pi^*) - \mathbb{E}[Y_t | X_t, A_t \sim \pi_t]). \quad (26.4.1)$$

El *regret esperado* es $\mathbb{E}[R_T]$, donde la esperanza es sobre la aleatoriedad en X_t , A_t e Y_t . Un algoritmo es *no-regret* si $\mathbb{E}[\frac{R_T}{T}] \rightarrow 0$ cuando $T \rightarrow \infty$.

26.4.2 Algoritmo LinUCB

El algoritmo **LinUCB** (Li et al., 2010) es uno de los más utilizados para bandits contextuales con recompensa lineal.

Método 26.1 (LinUCB (Linear Upper Confidence Bound))

Supuesto: $\mathbb{E}[Y | X, A = a] = X^t \text{op } \theta_a$ para cada brazo $a \in \{0, 1\}$, con $\theta_a \in \mathbb{R}^p$ desconocido. **Inicialización:** Para cada brazo a , $A_a = I_p$ (matriz identidad $p \times p$), $b_a = \mathbf{0}_p$.

Para cada ronda $t = 1, 2, \dots, T$:

1. Observar el contexto $X_t \in \mathbb{R}^p$.
2. Para cada brazo a , calcular:

$$\hat{\theta}_a = A_a^{-1} b_a, \quad \text{UCB}_a = X_t^t \text{op } \hat{\theta}_a + \alpha \sqrt{X_t^t \text{op } A_a^{-1} X_t}, \quad (26.4.2)$$

donde $\alpha > 0$ es el parámetro de exploración (típicamente $\alpha = 1 + \sqrt{\log \frac{2}{\delta}}$ para garantías teóricas).

3. Seleccionar $A_t = \arg \max_a \text{UCB}_a$.
4. Observar recompensa Y_t .
5. Actualizar: $A_{A_t} \leftarrow A_{A_t} + X_t X_t^t \text{op}$, $b_{A_t} \leftarrow b_{A_t} + X_t Y_t$.

El término $\alpha \sqrt{X_t^t \text{op } A_a^{-1} X_t}$ es el **bonus de exploración**: grande cuando el brazo a ha sido poco explorado en regiones del espacio de contextos cercanas a X_t , forzando al algoritmo a probar acciones inciertas. Este principio —optimismo frente a la incertidumbre— es la columna vertebral de los algoritmos UCB.

La tasa de regret del LinUCB es $\mathbb{E}[R_T] = O(\sqrt{Tp \log T})$, óptima salvo factores logarítmicos.

26.5 Bandits causales

Los bandits causales ((Lattimore et al., 2016) ; (Lu et al., 2021)) incorporan conocimiento del grafo causal subyacente para mejorar la eficiencia de la exploración.

Definición 26.5 (Bandits causales)

Un *bandit causal* es un bandit contextual donde se conoce (o se aprende) la estructura causal entre las variables. La idea clave es que si una variable X_j es causa de Y y puede intervenir, la información obtenida al intervenir X_j es **transferible** entre brazos. Formalmente, si $X_j \rightarrow Y$ en el DAG, entonces $\mathbb{E}[Y \mid \text{do}(X_j = x_j)]$ es invariante a la política de asignación de A , lo que permite:

1. Usar datos de un brazo para mejorar las estimaciones en otros brazos (transferencia de información).
2. Diseñar estrategias de exploración que intervengan variables causales upstream para aprender más rápido las relaciones downstream.

Ejemplo 26.1 (Bandit causal en salud digital)

Una app de salud asigna recomendaciones $A \in \{\text{ejercicio, dieta}\}$. El contexto X incluye el nivel basal de actividad física. Se sabe que X causa Y (pérdida de peso) independientemente de A . Un bandit estándar estima $\mathbb{E}[Y \mid X, A = a]$ por separado para cada a . Un bandit causal comparte la estimación del efecto de X sobre Y entre brazos, reduciendo la varianza cuando un brazo tiene pocas observaciones. La función de recompensa se modela como $Y = f(X) + g(A, X) + \epsilon$, donde f (el efecto basal de X) se comparte entre brazos.

26.6 Política óptima como función del CATE

Cerramos el círculo conectando OPE, bandits y estimación del CATE.

Proposición 26.2 (Política óptima como función del CATE)

Bajo ignorabilidad y tratamiento binario con costo c y valor marginal v , la política que maximiza el valor esperado neto es:

$$\pi^*(x) = \mathbf{1}\left(\tau(x) \geq \frac{c}{v}\right), \quad (26.6.1)$$

donde $\tau(x) = \mathbb{E}[Y^1 - Y^0 \mid X = x]$ es el CATE. El valor de esta política es:

$$V(\pi^*) = \mathbb{E}[Y^0] + \mathbb{E}\left[\left(\tau(X) - \frac{c}{v}\right) \cdot \mathbf{1}\left(\tau(X) \geq \frac{c}{v}\right)\right] \cdot v. \quad (26.6.2)$$

Esta proposición establece el puente definitivo entre los capítulos 23–25 (estimación del CATE) y este capítulo (evaluación de políticas): **estimar el CATE es equivalente a aprender la política óptima, y evaluar una política es equivalente a estimar el valor esperado del CATE sobre la subpoblación tratada.**

26.7 Procedimiento integrado: de los datos a la política

Método 26.2 (Pipeline completo de aprendizaje y evaluación de políticas)**Entrada:** Datos observacionales $\mathcal{D} = \{(X_i, A_i, Y_i)\}_{i=1}^n$.**Paso 1 – Estimación de nuisance:**

- Estimar $\hat{e}(x) = \hat{\mathbb{P}}(A = 1 \mid X = x)$ (propensity score) mediante regresión logística regularizada o Gradient Boosting.
- Estimar $\hat{Q}(x, a) = \hat{\mathbb{E}}[Y \mid X = x, A = a]$ mediante cualquier método de regresión supervisada.

Paso 2 – Estimación del CATE:

- Calcular $\hat{\tau}(x) = \hat{Q}(x, 1) - \hat{Q}(x, 0)$ (método directo), o usar un bosque causal (capítulo 24) para estimación no paramétrica con inferencia.

Paso 3 – Aprendizaje de la política:

- Dado un umbral de costo-beneficio $\lambda = \frac{c}{v}$, definir $\hat{\pi}^*(x) = \mathbf{1}(\hat{\tau}(x) \geq \lambda)$.

Paso 4 – Evaluación off-policy de $\hat{\pi}^*$:

- Estimar $V(\hat{\pi}^*)$ mediante el estimador DR-OPE con cross-fitting ($K = 5$ folds):

$$\hat{V}_{\{\text{DR}\}} = \frac{1}{n} \sum_{i=1}^n \left[\hat{Q}^{(-k(i))}(X_i, \hat{\pi}^*(X_i)) + \frac{\mathbf{1}(A_i = \hat{\pi}^*(X_i))}{\hat{e}^{(-k(i))}(X_i)} (Y_i - \hat{Q}^{(-k(i))}(X_i, A_i)) \right]. \quad (26.7.1)$$

Paso 5 – Comparación:

- Comparar $\hat{V}_{\{\text{DR}\}}(\hat{\pi}^*)$ con $\hat{V}_{\{\text{DR}\}}(\pi_b)$ (valor de la política de comportamiento) para cuantificar la mejora.

Salida: Política $\hat{\pi}^*$ y estimación de su valor $V(\hat{\pi}^*)$ con intervalo de confianza.

26.8 Diagrama conceptual de la OPE

Los datos $\mathcal{D}$ se generan bajo la política de comportamiento π_b . A partir de $\mathcal{D}$, se aprende una política candidata π_e (usando CATE) y *simultáneamente* se evalúa su valor $\hat{V}(\pi_e)$ usando los mismos datos — siempre que se emplee cross-fitting para evitar sobreajuste en la evaluación.

26.9 Ejemplos de aplicación

Ejemplo 26.2 (Evaluación de política de retención de clientes)

Una empresa de telecomunicaciones tiene datos de una política histórica π_b que ofrecía descuentos según antigüedad y gasto. Propone una nueva política π_e basada en un bosque causal: ofrece descuento solo a clientes con $\hat{\tau}(x) > 15\$$ (ingreso incremental esperado). Con $n = 50\{, \}000$, el propensity score estimado tiene AUC 0.82. La evaluación DR-OPE arroja $\hat{V}_{\{\text{DR}\}}(\pi_e) = 23.7\$$ por cliente (IC 95%: [22.1, 25.3]) frente a $\hat{V}_{\{\text{DR}\}}(\pi_b) = 19.2\$$. La mejora de 4.5\$ por cliente justifica el cambio de política.

Ejemplo 26.3 (Bandit contextual en recomendación de noticias)

Un portal de noticias implementa LinUCB para personalizar titulares. El contexto X_t incluye hora del día, dispositivo e historial de clics. Hay $K = 20$ titulares candidatos por visita. El algoritmo explora durante las primeras $10\{, \}000$ impresiones (regret inicial) y luego explota. Tras $100\{, \}000$ rondas, la tasa de clics (CTR) de LinUCB es 3.8% frente a 2.9% de la política editorial estática (A/B test de referencia). El regret por ronda converge a cero empíricamente.

26.10 Síntesis del Capítulo

Este capítulo ha presentado el marco de evaluación off-policy (OPE) como el eslabón que conecta la estimación causal con la toma de decisiones. El estimador IPS repondera observaciones por la razón $\frac{\pi_e}{\pi_b}$ y es insesgado pero potencialmente de alta varianza. El estimador DR-OPE combina un modelo directo de la recompensa con la corrección IPS, logrando doble robustez: consistencia si el modelo de resultado o el de propensity es correcto. En el contexto adaptativo, los bandits contextuales (LinUCB) equilibran exploración y explotación mediante bonos de optimismo, mientras que los bandits causales incorporan estructura causal para transferir información entre brazos. La política óptima se expresa como función del CATE, cerrando el círculo entre estimación de efectos heterogéneos y aprendizaje de políticas.

Supuestos clave

1. **Ignorabilidad fuerte:** $(Y^0, Y^1) \perp\!\!\!\perp A \mid X$.
2. **Soporte común para OPE:** $\pi_{e(a \mid x)} > 0 \Rightarrow \pi_{b(a \mid x)} \geq \eta > 0$ para todo (x, a) .
3. **SUTVA:** el resultado potencial de cada unidad no depende del tratamiento de otras.
4. **Modelo de recompensa lineal** (para LinUCB): $\mathbb{E}[Y \mid X, A = a] = X^t \text{op } \theta_a$, con $\|\theta_a\|_2 \leq S$ y $\|X_t\|_2 \leq L$.
5. **Entorno estacionario** (para bandits): la distribución $P(X, Y^0, Y^1)$ no cambia a lo largo de las rondas.
6. **Cross-fitting** (para DR-OPE): la estimación de $\hat{Q}$ y $\hat{\pi}_b$ y la evaluación de $\hat{V}$ usan particiones disjuntas de los datos.

En el próximo capítulo exploramos el aprendizaje de representaciones causales y modelos generativos, donde el objetivo no es estimar un efecto sino aprender transformaciones $\Phi : \mathcal{X} \rightarrow \mathcal{Z}$ del espacio de observables a un espacio latente que capture la estructura causal subyacente, permitiendo generalización fuera de distribución e invariancia entre entornos.

Otras referencias clave de este capítulo: (Swaminathan & Joachims, 2015), (Kallus & Zhou, 2018), (Athey & Wager, 2021).

26.10 Referencias

- Athey, S., & Wager, S. (2021). Policy Learning with Observational Data. *Econometrica*, 89(1), 133-161.
- Dudík, M., Langford, J., & Li, L. (2011). Doubly Robust Policy Evaluation and Learning. *Proceedings of the 28th International Conference on Machine Learning (ICML)*, 1097-1104.
- Kallus, N., & Zhou, A. (2018). Policy Evaluation and Optimization with Continuous Treatments. *Proceedings of the 21st International Conference on Artificial Intelligence and Statistics (AISTATS)*.
- Lattimore, F., Lattimore, T., & Reid, M. D. (2016). Causal Bandits: Learning Good Interventions via Causal Inference. *Advances in Neural Information Processing Systems (NeurIPS)*, 29.
- Li, L., Chu, W., Langford, J., & Schapire, R. E. (2010). A Contextual-Bandit Approach to Personalized News Article Recommendation. *Proceedings of the 19th International Conference on World Wide Web (WWW)*, 661-670.
- Lu, Y., Cabannes, T., & Lazaric, A. (2021). Regret Analysis of Bandit Problems with Causal Background Knowledge. *Proceedings of the 37th Conference on Uncertainty in Artificial Intelligence (UAI)*.
- Swaminathan, A., & Joachims, T. (2015). The Self-Normalized Estimator for Counterfactual Learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 28.

CAPÍTULO 27

Aprendizaje de Representaciones Causales y Modelos Generativos

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque III · Semilla 42**Notebook (pack):** notebooks/Bloque_III/

notebooks/27_aprendizaje_representaciones_causales_modelos_generativos.ipynb

Jupyter Book: jupyter_book/content/bloque_03_descubrimiento_ml/27_representaciones_causales.ipynb

27.1 De las predicciones a las causas: el paradigma de representaciones

Los capítulos precedentes han tratado la inferencia causal desde una perspectiva estadística clásica: dados datos observacionales, estimar el efecto de A sobre Y . Este capítulo aborda un objetivo más ambicioso: **aprender una representación** $\Phi: \mathcal{X} \rightarrow \mathcal{Z}$ del espacio de observables que capture la estructura causal del mundo, de modo que las relaciones aprendidas se generalicen a nuevos entornos y sean robustas a cambios de distribución.

Definición 27.1 (Representación causal (Schölkopf et al., 2021))

Una representación $Z = \Phi(X)$ con $Z \in \mathbb{R}^d$ es *causal* si satisface tres condiciones:

1. **Estructura causal:** existe un DAG $\mathcal{G}$ sobre los nodos $\{Z_1, \dots, Z_d\}$ y un mapeo generativo $p(X | Z)$ tal que X se genera a partir de Z mediante mecanismos causales independientes: $p(Z) = \prod_{i=1}^d p(Z_i | \text{Pa}_{\mathcal{G}}(Z_i))$.
2. **Invariancia entre entornos:** para cada mecanismo $p(Z_i | \text{Pa}(Z_i))$, su distribución condicional es invariante a través de todos los entornos $e \in \mathcal{E}$ considerados. Lo que cambia entre entornos es $p(\text{Pa}(Z_i))$ (la distribución de las causas), no el mecanismo que genera el efecto.
3. **Interpretabilidad intervencional:** una intervención $\text{do}(Z_i = z_i)$ en el espacio latente corresponde a modificar únicamente el mecanismo $p(Z_i | \text{Pa}(Z_i))$ (reemplazándolo por una masa puntual en z_i) sin alterar ningún otro mecanismo. Esto es la *modularidad* del capítulo 21 trasladada al espacio latente.

La diferencia fundamental con una representación estadística (como la de un autoencoder estándar) es que la independencia marginal $\mathbb{E}[Z_i Z_j] = 0$ no garantiza independencia causal $Z_i \perp\!\!\!\perp Z_j$. Una representación causal requiere que los factores latentes estén organizados según un orden causal que refleje los mecanismos generativos del mundo.

27.2 Invariant Risk Minimization (IRM)

27.2.1 Principio y formulación



El problema de la **correlación espuria** (spurious correlation) es el talón de Aquiles del aprendizaje automático predictivo: un clasificador puede alcanzar alta precisión en el conjunto de entrenamiento explotando asociaciones estadísticas que no son causales y que desaparecen bajo cambios de distribución. Por ejemplo, un modelo puede aprender a detectar camellos por el fondo desértico en lugar de por la morfología del animal; al evaluarlo en un zoológico, falla estrepitosamente.

Definición 27.2 (IRM (Invariant Risk Minimization) (Arjovsky et al., 2019))

Dado un conjunto de entornos de entrenamiento $\mathcal{E}_{\{\text{tr}\}} = \{e_1, \dots, e_m\}$, el objetivo de IRM es aprender una representación $\Phi : \mathcal{X} \rightarrow \mathcal{H}$ y un clasificador $w : \mathcal{H} \rightarrow \mathcal{Y}$ tales que w sea simultáneamente óptimo en **todos** los entornos:

$$\min_{\Phi, w} \sum_{e \in \mathcal{E}_{\{\text{tr}\}}} R^{e(w \circ \Phi)} \quad \text{sujeto a} \quad w \in \arg \min_{\bar{w}} R^{e(\bar{w} \circ \Phi)}, \forall e \in \mathcal{E}_{\{\text{tr}\}}, \quad (27.2.1)$$

donde $R^{e(f)} = \mathbb{E}_{(X,Y) \sim P^e}[\ell(f(X), Y)]$ es el riesgo en el entorno e .

La restricción exige que w sea un minimizador del riesgo en cada entorno por separado dado Φ . En la práctica, esta restricción bi-nivel se relaja mediante una penalización lagrangiana diferenciable (IRMv1):

$$\mathcal{L}_{\{\text{IRM}\}}(\Phi, w) = \sum_{e \in \mathcal{E}_{\{\text{tr}\}}} R^{e(w \circ \Phi)} + \lambda \sum_{e \in \mathcal{E}_{\{\text{tr}\}}} \left\| \nabla_{w|w=1.0} R^{e(w \circ \Phi)} \right\|^2, \quad (27.2.2)$$

donde la penalización mide cuánto cambiaría el riesgo en cada entorno si se modificara w , evaluado en $w = 1$ (un escalar ficticio que multiplica la salida de Φ). Si Φ captura las causas invariantes de Y , la dirección del gradiente del riesgo respecto a w es idéntica en todos los entornos.

27.2.2 IRM recupera las causas: caso lineal

Teorema 27.1 (IRM recupera causas en el caso lineal (Arjovsky et al., 2019))

Considérese el modelo generativo lineal:

$$Y = X_S^T \gamma + \epsilon, \quad \epsilon \perp\!\!\!\perp X_S, \quad (27.2.3)$$

donde $S \subseteq \{1, \dots, p\}$ es el conjunto de causas de Y (padres en el DAG). Sean los entornos $e \in \mathcal{E}_{\{\text{tr}\}}$ tales que $\text{Var}_{P^e}(X_S)$ varía entre entornos pero γ es invariante. Supóngase que $\Phi(X) = X$ (representación identidad) y $w \in \mathbb{R}^p$. Entonces, para $\lambda > 0$ suficientemente grande, la solución de IRMv1 satisface:

$$\text{supp}(\hat{w}) \subseteq S, \quad (27.2.4)$$

es decir, IRM asigna peso cero a las variables que no son causas de Y , recuperando el conjunto causal con alta probabilidad.

27.2.3 Limitaciones y variantes de IRM

La práctica ha revelado que IRM puede fallar cuando:

- El número de entornos es pequeño ($m \leq 2$) y la variación entre ellos es insuficiente para identificar S .
- La distribución de las causas X_S también cambia entre entornos de manera que imita el efecto de las no-causas.

Variantes posteriores abordan estas limitaciones:

- **REx** (Risk Extrapolation) (Krueger et al., 2021): en lugar de penalizar el gradiente, minimiza directamente la varianza del riesgo entre entornos: $\mathcal{L}_{\{\text{REx}\}} = \sum_e R^e + \beta \text{Var}_{e(R^e)}$.

- **AND-Mask** (Parascandolo et al., 2021): solo actualiza parámetros cuyos gradientes tienen el mismo signo en todos los entornos, implementando una forma discreta de invariancia.
- **EIIL** (Environment Inference for Invariant Learning) (Creager et al., 2021): aprende automáticamente la partición de los datos en entornos cuando estos no están anotados, maximizando la violación de invariancia para identificar entornos latentes.

27.3 VAE con estructura causal

27.3.1 Del VAE estándar al VAE identificable

El Variational Autoencoder (VAE) (Kingma & Welling, 2014) maximiza la cota inferior de evidencia (ELBO):

$$\mathcal{L}_{\{\text{VAE}\}} = \mathbb{E}_{q_{\varphi}(\mathbf{z} | \mathbf{x})} [\log p_{\theta}(\mathbf{x} | \mathbf{z})] - \text{KL}(q_{\varphi}(\mathbf{z} | \mathbf{x}) | p(\mathbf{z})), \quad (27.3.1)$$

donde típicamente $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$. Sin embargo, el prior factorial $\mathcal{N}(\mathbf{0}, \mathbf{I})$ impone independencia marginal entre los factores latentes, no independencia causal. Dos variables pueden ser marginalmente independientes y aun así estar conectadas causalmente (ejemplo: $Z_1 \rightarrow Z_2$ con $\mathbb{E}[Z_1] = 0$ produce $\mathbb{E}[Z_1 Z_2] \neq 0$ en general).

27.3.2 iVAE: identificabilidad mediante variable auxiliar

Definición 27.3 (iVAE (Identifiable VAE) (Khemakhem et al., 2020))

El iVAE introduce una variable auxiliar observada $\mathbf{u}$ (que puede representar el entorno, la clase, el tiempo o cualquier etiqueta disponible) y modela el prior condicional como:

$$p(\mathbf{z} | \mathbf{u}) = \prod_{i=1}^d p_{i(z_i | \mathbf{u})}, \quad (27.3.2)$$

donde cada p_i pertenece a una familia exponencial condicional. Bajo las condiciones de (i) suficiencia de $\mathbf{u}$ para identificar la distribución de $\mathbf{z}$, (ii) variabilidad suficiente de $\mathbf{u}$ (el jacobiano de los parámetros naturales respecto a $\mathbf{u}$ tiene rango completo), y (iii) monotonicidad de las funciones de mezcla, los factores latentes son **identificados salvo permutación y reparametrización por componentes**.

El procedimiento de entrenamiento del iVAE es:

1. Codificar: $q_{\varphi}(\mathbf{z} | \mathbf{x}, \mathbf{u})$ — el codificador puede condicionar en $\mathbf{u}$.
2. Decodificar: $p_{\theta}(\mathbf{x} | \mathbf{z})$ — el decodificador es independiente de $\mathbf{u}$, pues $\mathbf{u}$ afecta a $\mathbf{x}$ solo a través de $\mathbf{z}$.
3. Prior condicional: $p(\mathbf{z} | \mathbf{u}) = \prod_i p_{i(z_i | \mathbf{u})}$ con parámetros modelados por una red neuronal que toma $\mathbf{u}$ como entrada.

La identificabilidad del iVAE contrasta con el VAE estándar, donde los factores latentes no son identificables (existen infinitas reparametrizaciones que producen la misma distribución marginal $p(\mathbf{x})$). Esta propiedad es crucial para la interpretación causal de las dimensiones latentes.

27.3.3 CausalVAE: DAG en el espacio latente

Definición 27.4 (CausalVAE (Yang et al., 2021))

El *CausalVAE* reemplaza el prior factorial del VAE por un **modelo estructural causal lineal** en el espacio latente:

$$z = B^{\text{top}} z + \epsilon = (I - B^{\text{top}})^{-1} \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \Sigma), \quad (27.3.3)$$

donde $B \in \mathbb{R}^{d \times d}$ es una matriz de adyacencia causal **aprendida** cuyas entradas B_{ij} representan la fuerza del efecto causal $Z_j \rightarrow Z_i$. La aciclicidad del DAG se impone mediante la restricción de NOTEARS (Zheng et al., 2018):

$$h(B) = \text{tr}(e^{B \odot B}) - d = 0, \quad (27.3.4)$$

donde e^M es la matriz exponencial. La función de pérdida del CausalVAE es:

$$\mathcal{L}_{\{\text{CausalVAE}\}} = \mathcal{L}_{\{\text{VAE}\}} - \lambda_1 h(B) - \lambda_2 \left\| z^{\text{top}} \frac{z}{n} - I \right\|_F^2, \quad (27.3.5)$$

donde el último término fomenta que las variables latentes sean incorreladas marginalmente (ortogonalidad), complementando la estructura causal codificada en B .

El procedimiento de entrenamiento alterna entre:

1. **Paso generativo:** muestrear $\epsilon \sim \mathcal{N}(\mathbf{0}, \Sigma)$, calcular $z = (I - B^{\text{top}})^{-1} \epsilon$, decodificar $\hat{x} = p_{\theta}(x | z)$.
2. **Paso inferencial:** codificar $z \sim q_{\varphi}(z | x)$, calcular la ELBO y las penalizaciones de aciclicidad y ortogonalidad.
3. **Actualización:** optimizar θ , φ , B y Σ conjuntamente.

La matriz B aprendida revela la estructura causal entre los factores latentes. Por ejemplo, en datos de rostros, CausalVAE puede descubrir que la identidad causa la forma de los rasgos, y estos causan la textura.

27.4 Correlación espuria y shortcut learning

27.4.1 El problema en visión por computador

Definición 27.5 (Correlación espuria (spurious correlation))

Una *correlación espuria* es una asociación estadística entre una variable de entrada X_j y la etiqueta Y que (i) está presente en los datos de entrenamiento pero (ii) no es causal: $X_j \dashv \rightarrow Y$ en el DAG verdadero, y (iii) desaparece o se invierte bajo cambios de distribución o intervenciones. Formalmente, si S es el conjunto de causas de Y , entonces $X_j \notin S$ pero $\text{Cov}(X_j, Y) \neq 0$ en la distribución de entrenamiento $P^{\{\text{train}\}}$.

El ejemplo canónico es **ColorMNIST**: dígitos MNIST coloreados de modo que el color está correlacionado con el dígito en el entorno de entrenamiento (e.g., dígitos 0–4 son rojos, 5–9 son verdes), pero esta correlación se rompe en el entorno de prueba (colores asignados aleatoriamente). Un clasificador estándar (ERM) alcanza $\sim 70\%$ de precisión en prueba (cerca del azar balanceado), mientras que IRM mantiene un desempeño superior al capturar la forma como causa invariante.

27.4.2 Shortcut learning en NLP

Definición 27.6 (Shortcut learning en NLP)

En procesamiento de lenguaje natural, el *shortcut learning* describe el fenómeno donde modelos profundos explotan heurísticas léxicas superficiales que correlacionan con la etiqueta en los datos de entrenamiento pero no constituyen causas. Ejemplos documentados incluyen:

- En inferencia de lenguaje natural (NLI), la presencia de la palabra “not” correlaciona fuertemente con la clase “contradiction”, llevando al modelo a ignorar la estructura sintáctica.
- En análisis de sentimiento, palabras como “film” o “actor” en reseñas de cine correlacionan con sentimiento positivo en ciertos corpus, sin ser inherentemente positivas.
- En respuesta a preguntas, el modelo puede aprender a responder basándose en la similitud lexical pregunta-contexto en lugar de comprensión lectora.

La **representación causal en NLP** busca identificar las unidades léxicas, sintácticas o semánticas que son causas del label, no meros correlatos. Estrategias incluyen:

1. **Data augmentation contrafactual:** generar ejemplos donde se modifican palabras no causales manteniendo las causales, forzando al modelo a depender de las segundas.
2. **Causal attention:** modificar los pesos de atención del transformer para penalizar tokens cuya correlación con el label varía entre entornos.
3. **Entornos sintéticos:** crear entornos de entrenamiento donde la correlación espuria se manipula (similar a ColorMNIST pero para texto), entrenando con IRM.

27.5 Diagrama del espacio latente causal

El diagrama ilustra la arquitectura conceptual: el observable $\mathbf{X}$ (imagen, texto) es generado por factores latentes $\mathbf{Z}$ organizados en un DAG causal ($Z_1 \rightarrow Z_3, Z_2 \rightarrow Z_3$). Solo algunos factores (Z_3) son causas directas del label Y . La representación causal $\Phi : \mathbf{X} \rightarrow \mathbf{Z}$ debe recuperar este DAG y los mecanismos que lo componen, de modo que intervenciones sobre $\mathbf{Z}$ (e.g., cambiar Z_1) produzcan cambios predecibles en $\mathbf{X}$ a través del decodificador.

27.6 Procedimiento algorítmico: CausalVAE con NOTEARS

Método 27.1 (CausalVAE: aprendizaje de representaciones causales con DAG latente)

Entrada: Datos $\{x_i\}_{i=1}^n$, dimensionalidad latente d , hiperparámetros λ_1 (aciclicidad), λ_2 (ortogonalidad).

Inicialización: Inicializar el codificador $q_{\varphi}(z | x)$, el decodificador $p_{\theta}(x | z)$, la matriz causal B (con ceros en la diagonal y valores pequeños aleatorios fuera de ella), y la matriz de covarianzas del ruido $\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_d^2)$.

Para cada época:

1. **Muestreo del prior estructural:**

- Muestrear $\epsilon \sim \mathcal{N}(\mathbf{0}, \Sigma)$.
- Calcular $z_{\{\text{prior}\}} = (I - B^{\text{top}})^{-1} \epsilon$ (resolviendo el sistema lineal, no invirtiendo la matriz).

1. **Inferencia variacional:**

- Para cada x_i en el mini-lote, obtener $(\mu_i, \sigma_i^2) = \text{Encoder}_{\varphi}(x_i)$.
- Muestrear $z_i \sim \mathcal{N}(\mu_i, \text{diag}(\sigma_i^2))$ usando la reparametrización.
- Reconstruir $\hat{x}_i = \text{Decoder}_{\theta}(z_i)$.

1. **Cálculo de la función de pérdida:**

- $\mathcal{L}_{\{\text{recon}\}} = \frac{1}{|B|} \sum_i \|x_i - \hat{x}_i\|^2$ (o log-verosimilitud según el tipo de dato).
- $\mathcal{L}_{\{\text{KL}\}} = \frac{1}{|B|} \sum_i \text{KL}(\mathcal{N}(\mu_i, \sigma_i^2) | \mathcal{N}(\mathbf{0}, (I - B^{\text{top}})^{-1} \Sigma (I - B)^{-1}))$.
- $\mathcal{L}_{\{\text{acyclic}\}} = \text{tr}(e^{B \odot B}) - d$ (restricción NOTEARS).
- $\mathcal{L}_{\{\text{orth}\}} = \|\frac{1}{n} Z^{\text{top}} Z - I\|_F^2$ (ortogonalidad empírica de las latentes).

1. **Actualización:** $\mathcal{L}_{\{\text{total}\}} = \mathcal{L}_{\{\text{recon}\}} + \mathcal{L}_{\{\text{KL}\}} + \lambda_1 \mathcal{L}_{\{\text{acyclic}\}} + \lambda_2 \mathcal{L}_{\{\text{orth}\}}$. Retropropagar y actualizar $\varphi, \theta, B, \Sigma$.

Salida: Representación $\Phi = \text{Encoder}_{\text{phi}}$, DAG latente $\mathcal{G}(B)$, y modelo generativo $p_{\theta}(x | z)$.

27.7 Ejemplos de aplicación

Ejemplo 27.1 (Robustez a correlaciones espurias en imagen)

En el benchmark ColorMNIST, se entrenan tres modelos: (a) ERM estándar, (b) IRM con $\lambda = 100$, (c) CausalVAE con $d = 8$ factores latentes. Los resultados en el entorno de prueba (donde color y dígito son independientes) son: ERM 71.2%, IRM 82.5%, CausalVAE 84.1%. La inspección de la matriz B del CausalVAE revela que dos factores latentes (asociados a la forma del dígito) son padres del clasificador, mientras que el factor asociado al color es un nodo hoja sin conexión a Y , confirmando que el modelo aprendió a separar causa de correlato espurio.

Ejemplo 27.2 (Shortcut learning en clasificación de sentimiento)

Un corpus de reseñas de productos contiene la palabra excelente²⁴ desproporcionadamente en reseñas positivas. Un clasificador BERT afinado con ERM aprende a predecir sentimiento positivo cada vez que ve excelente²⁴, fallando en oraciones como El producto dista de ser excelente²⁴. Al entrenar con IRM en dos entornos —reseñas originales y reseñas con aumentación contrafactual (negando adjetivos)—, el modelo resultante es robusto a la negación. La representación causal aprendida por la capa [CLS] de BERT asigna pesos bajos a tokens con alta correlación espuria entre entornos.

Ejemplo 27.3 (Descubrimiento causal en datos de expresión génica)

Se aplica CausalVAE a datos de expresión de $p = 1000$ genes en $n = 500$ pacientes con dos entornos (tejido sano vs. tumoral, variable auxiliar u). La matriz B aprendida ($d = 20$ factores) revela un sub-DAG de 5 factores asociados a vías metabólicas, donde los factores upstream corresponden a genes reguladores y los downstream a genes efectores. Intervenciones simuladas sobre factores upstream (cambiando su valor en el espacio latente) producen cambios en la expresión reconstruida de los genes downstream consistentes con el conocimiento biológico establecido.

27.8 Síntesis del Capítulo

Este capítulo ha presentado el aprendizaje de representaciones causales como un paradigma que trasciende la estimación de efectos para aspirar a la recuperación de la estructura generativa del mundo. Una representación causal $Z = \Phi(X)$ organiza los factores latentes según un DAG, con mecanismos invariantes entre entornos y con interpretación intervencional. IRM aprende representaciones forzando que el clasificador óptimo sobre ellas sea el mismo en todos los entornos, recuperando las causas de Y en el caso lineal. El iVAE logra identificabilidad de los factores latentes mediante una variable auxiliar u (entorno, clase), y el CausalVAE impone explícitamente una estructura DAG en el espacio latente usando la restricción NOTEARS. La correlación espuria y el shortcut learning son las patologías que estas representaciones buscan remediar, con aplicaciones en visión, NLP y genómica.

Supuestos clave

1. **Modularidad:** los mecanismos causales $p(Z_i | \text{Pa}(Z_i))$ son independientes entre sí y pueden intervenir sin afectar a otros.
2. **Invariancia entre entornos:** $p(Y | \text{Pa}(Y))$ es invariante para todos los entornos considerados.
3. **Variabilidad de entornos:** las distribuciones de las causas $p(\text{Pa}(Y))$ varían suficientemente entre entornos para identificar el conjunto causal.
4. **Suficiencia de u** (para iVAE): la variable auxiliar contiene toda la información sobre la distribución de los factores latentes.
5. **Aciclicidad:** el DAG latente $\mathcal{G}$ no contiene ciclos dirigidos.
6. **Linealidad del SCM latente** (para CausalVAE): $z = B^{\text{top}} z + \epsilon$ con funciones de mezcla no lineales del decodificador.
7. **Dimensionalidad suficiente:** $d = \dim(Z)$ es mayor o igual que la dimensionalidad intrínseca de los factores causales.

Con este capítulo cerramos el Bloque III. De los fundamentos de resultados potenciales y diseños cuasi-experimentales (Bloque I, capítulos 1–12), pasando por los SCM, DAGs y el do-cálculo de Pearl (Bloque II, capítulos 13–19), hasta el descubrimiento causal, el machine learning causal y las representaciones causales (Bloque III, capítulos 20–27), el lector ha adquirido las herramientas para diseñar, estimar y criticar inferencias causales en contextos aplicados. El Bloque IV (capítulos 28–32) cierra la monografía con la integración de la causalidad en arquitecturas de IA moderna.

27.8 Referencias

Arjovsky, M., Bottou, L., Gulrajani, I., & Lopez-Paz, D. (2019). Invariant Risk Minimization. *arXiv:1907.02893*.

- Creager, E., Jacobsen, J.-H., & Zemel, R. (2021,). Environment Inference for Invariant Learning. *Proceedings of the 38th International Conference on Machine Learning (ICML)*.
- Khemakhem, I., Kingma, D., Monti, R., & Hyvärinen, A. (2020). Variational Autoencoders and Nonlinear ICA: A Unifying Framework. *Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics (AISTATS)*, 4166-4176.
- Kingma, D. P., & Welling, M. (2014,). Auto-Encoding Variational Bayes. *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*.
- Krueger, D., Caballero, E., Jacobsen, J.-H., Zhang, A., Binas, J., Zhang, D., Le Priol, R., & Courville, A. (2021,). Out-of-Distribution Generalization via Risk Extrapolation. *Proceedings of the 38th International Conference on Machine Learning (ICML)*.
- Parascandolo, G., Neitz, A., Orvieto, A., Gresele, L., & Schölkopf, B. (2021,). Learning Explanations that are Hard to Vary. *Proceedings of the 9th International Conference on Learning Representations (ICLR)*.
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward Causal Representation Learning. *Proceedings of the IEEE*, 109(5), 612-634.
- Yang, M., Liu, F., Chen, Z., Shen, X., Hao, J., & Wang, J. (2021). CausalVAE: Disentangled Representation Learning via Neural Structural Causal Models. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 9593-9602.
- Zheng, X., Aragam, B., Ravikumar, P., & Xing, E. P. (2018). DAGs with NO TEARS: Continuous Optimization for Structure Learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

CAPÍTULO 28

Aprendizaje por Refuerzo Causal y Control Secuencial

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque IV · Semilla 42**Notebook (pack):** notebooks/Bloque_IV/notebooks/28_aprendizaje_refuerzo_causal_control_secuencial.ipynb**Jupyter Book:** jupyter_book/content/bloque_04_ia_causal/28_rl_causal.ipynb

28.1 Procesos de decisión Markovianos causales

El aprendizaje por refuerzo (RL) estándar modela la interacción agente-entorno como un **Proceso de Decisión de Markov** (MDP):

Definición 28.1 (MDP)

Un MDP es una tupla $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$ donde $\mathcal{S}$ es el espacio de estados, $\mathcal{A}$ el de acciones, $P(s' | s, a)$ la dinámica de transición, $R(s, a)$ la función de recompensa y $\gamma \in [0, 1)$ el factor de descuento.

El RL estándar aprende P y R por ensayo y error. Su limitación causal fundamental es que trata la dinámica $P(s' | s, a)$ como una caja negra: no distingue entre el efecto directo de a sobre s' y las correlaciones espurias presentes en el entorno de entrenamiento.

28.1.1 MDP causal (CMDP)

Definición 28.2 (MDP causal (Lu et al., 2021))

Un *MDP causal* extiende el MDP estándar con un DAG $\mathcal{G}$ sobre las variables del estado $S = (S^1, \dots, S^k)$ y la acción A , donde cada variable satisface el MCE:

$$S_{t+1}^j = f_j(\text{Pa}_{\mathcal{G}}(S_{t+1}^j), \epsilon_{t+1}^j). \quad (28.1.1)$$

El grafo $\mathcal{G}$ codifica cuáles variables del estado son afectadas directamente por la acción A , cuáles se ven solo indirectamente, y qué relaciones son invariantes entre entornos de entrenamiento y despliegue.

Proposición 28.1 (Transferencia de política bajo cambio de entorno)

Si la política π solo depende de las causas directas de la recompensa R en $\mathcal{G}$, entonces π es transferible a cualquier entorno que comparta los mismos mecanismos causales f_j , independientemente de cambios en distribuciones marginales.

28.2 Intervenciones, políticas y valor causal

28.2.1 Valor causal de una política



En el CMDP, ejecutar la acción a en el estado s corresponde a la intervención $\text{do}(A_t = a)$. El valor causal de la política π es:

$$V_{\{\text{causal}\}}^{\pi}(s) = \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t R_t \mid S_0 = s, A_t \sim \pi(\cdot \mid S_t), \text{do} \right], \quad (28.2.1)$$

donde el operador do garantiza que la estimación del valor no está contaminada por el sesgo de confounding observacional.

28.2.2 Ecuación de Bellman causal

Teorema 28.1 (Ecuación de Bellman causal)

Bajo el modelo CMDP, el valor óptimo satisface:

$$V^*(s) = \max_a \left[R(s, a) + \gamma \sum_{s'} P_{\{\text{do}(a)\}}(s' \mid s) V^*(s') \right], \quad (28.2.2)$$

donde $P_{\{\text{do}(a)\}}(s' \mid s) = \sum_{\text{pa}} P(s' \mid \text{pa}, a) P(\text{pa} \mid s)$ es la distribución de transición bajo intervención, identificable mediante la fórmula de ajuste si no hay confounders no observados en $\mathcal{G}$.

28.3 Exploración informada por estructura causal

La exploración eficiente es uno de los problemas centrales del RL: el agente debe explorar suficientemente para aprender V^* sin desperdiciar demasiadas interacciones. La estructura causal permite **exploración dirigida**:

1. **Intervenciones sobre variables causales de alto impacto**: actuar sobre variables que son causas directas de R reduce el espacio de búsqueda.
2. **Actualización de creencias por d-separación**: observar S^j da información sobre S^k solo si están d-conectados en $\mathcal{G}$. Esto permite actualizar las estimaciones de $Q(s, a)$ de forma más eficiente que con actualizaciones tabula rasa.
3. **Curiosidad causal** (Sontakke et al., 2021): la recompensa de exploración se define como el cambio esperado en la estimación del grafo causal $\hat{\mathcal{G}}$ al ejecutar la acción a : $r_t^{\{\text{intr}\}} = \text{IG}(\hat{\mathcal{G}}, S_{t+1} \mid \text{do}(A_t = a))$, donde IG es la ganancia de información.

Definición 28.3 (Causal curiosity)

La recompensa intrínseca de curiosidad causal es

$$r^{\{\text{intr}\}}(s, a) = \text{KL}(P(\mathcal{G} \mid \mathcal{D} \cup \{(s, a, s')\}) \mid P(\mathcal{G} \mid \mathcal{D})), \quad (28.3.1)$$

que incentiva al agente a ejecutar acciones que cambien más su creencia sobre la estructura causal del entorno.

28.4 Desafíos en entornos reales

28.4.1 Aprendizaje del grafo causal on-line

En entornos reales el grafo $\mathcal{G}$ es desconocido y debe aprenderse *en línea* durante la interacción. Esto crea un bucle entre descubrimiento causal (cap. 20) y aprendizaje de la política:

1. El agente explora y acumula transiciones (s_t, a_t, s_{t+1}) .
2. Periódicamente se re-estima $\hat{\mathcal{G}}$ con algoritmos como PC o LiNGAM.
3. La estimación actualizada guía la exploración en el siguiente tramo.

28.4.2 Confounders no observados y entornos parcialmente observables

Si existen variables latentes U que confunden la relación $A_t \rightarrow S_{t+1}$, la ecuación de Bellman causal no es directamente identificable. Las soluciones incluyen:

- **POMDP causal:** extender el espacio de estados con variables latentes estimadas por filtrado (filtro de partículas, LSTM).
- **IV en RL:** si existe una variable instrumental Z_t (fuente de aleatoriedad exógena), estimar $P_{\{do(a)\}}$ via IV.
- **Robustez minimax:** optimizar contra el peor escenario de confounder dentro de un conjunto de ambigüedad, produciendo políticas conservadoras pero transferibles.

28.4.3 Escala y complejidad computacional

El mayor obstáculo práctico es la complejidad de mantener y actualizar $\hat{\mathcal{G}}$ en espacios de estado de alta dimensión (robótica, videojuegos, sistemas de salud). Investigación activa combina redes neuronales causales (NOTEARS diferenciable, DAG-GNN) con arquitecturas de RL modernas (PPO, SAC) para abordar este reto.

28.5 Conexión con la jerarquía GCE

El aprendizaje por refuerzo causal opera en los tres niveles de la jerarquía GCE de forma secuencial:

- **Nivel 1 (ATE medio):** el retorno esperado $V^{\pi} = \mathbb{E} \left[\sum_t \gamma^t R_t \mid do(A_t = \pi(S_t)) \right]$ es una media ponderada por descuento — Nivel 1. El RL estándar sin ajuste causal estima este valor con sesgo cuando existen confounders en las transiciones.
- **Nivel 2 (distribucional):** comparar distribuciones de políticas $P^{\pi(R_{\{acum\}})}$ vs. $P^{\pi'}(R_{\{acum\}})$ mediante divergencia KL o χ^2 cuantifica la superioridad de una política no solo en media sino en toda la distribución de resultados. Fundamental para aplicaciones médicas donde el riesgo de cola importa.
- **Nivel 3 (Wasserstein):** la distancia $W_1 \left(P^{\pi(R_{\{acum\}})}, P^{\pi^*}(R_{\{acum\}}) \right)$ entre la distribución de retornos de la política aprendida y la óptima mide el costo de suboptimalidad en unidades del reward acumulado. Minimizar esta distancia es el objetivo del RL causal desde la perspectiva del transporte óptimo.
- **DTR como caso especial:** los regímenes dinámicos de tratamiento (DTR) de la literatura médica son políticas causales de horizonte finito. La evaluación off-policy de un DTR requiere estimar $W_{p(P^{\hat{\pi}}(Y), P^{\pi^*}(Y))}$ para decidir si la política aprendida vale la pena implementar.

28.6 Checklist Riguroso

1. Verificar si el MDP tiene confounders en las transiciones: $P(S' \mid S, A) \neq P(S' \mid do(A), S)$.
2. Si hay confounders: construir el DAG del entorno antes de estimar la función Q .
3. Usar Q-learning causal (estado completo incluyendo posibles proxies del confounder).
4. Aplicar el Teorema de Bellman causal sólo si el DAG garantiza identificabilidad.
5. Con confounders no observados: recurrir a IV en RL o a políticas robustas minimax.

6. Aplicar evaluación off-policy (OPE, Cap. 26) antes de desplegar la política.
7. Para DTR médico: validar con el Sepsis simulator (Oberst & Sontag, 2019, Oberst y Sontag) antes de datos reales.
8. Reportar la distribución completa de retornos (no solo la media) para evaluar riesgo de cola.
9. Testear transferibilidad: si el entorno cambia, ¿se mantiene la política óptima?
10. Conectar con el Cap. 20 para actualizar $\hat{\mathcal{G}}$ periódicamente durante la interacción.

28.7 Glosario

- **MDP causal (CMDP)**: MDP extendido con un DAG $\mathcal{G}$ que codifica los mecanismos causales del entorno.
- **Función de valor causal** $V_{\{\text{causal}\}}^{\text{pi}}$: retorno esperado bajo do-cálculo, sin sesgo de confounding.
- **Ecuación de Bellman causal**: versión intervenida de la ecuación de optimalidad usando $P_{\text{do}(a)}(s' | s)$.
- **Curiosidad causal**: recompensa intrínseca proporcional a la ganancia de información sobre $\mathcal{G}$.
- **DTR (Dynamic Treatment Regime)**: secuencia de reglas de decisión $\pi_{t(H_t)}$ basadas en historial.
- **Deconfounded RL**: RL que elimina el sesgo de confounders en los logs usando métodos de variables instrumentales.
- **Counterfactual OPE**: evaluación off-policy de trayectorias completas usando contrafactuales.
- **POMDP causal**: extensión parcialmente observable del CMDP con variables latentes estimadas.
- **Transferencia de política**: capacidad de una política aprendida en un entorno de funcionar en otro con mismos mecanismos causales.
- **Robustez minimax**: política que maximiza el valor bajo el peor escenario de confounder en un conjunto de ambigüedad.

28.8 Cierre del capítulo

El RL causal exige distinguir dinámica, confusión y políticas. Sin un grafo (o supuestos equivalentes) sobre el MDP, la “política óptima” puede ser un artefacto del entorno de entrenamiento.

Otras referencias clave de este capítulo: (Bareinboim, 2025), (Xiong, 2022).

28.8 Referencias

- Bareinboim, E. (2025). *Causal Artificial Intelligence: A Roadmap for Building Causally Intelligent Systems*. Wiley-IEEE Press.
- Lu, C., Schölkopf, B., & Hernández-Lobato, J. M. (2021). Invariant Causal Imitation Learning for Generalizable Policies. *Advances in Neural Information Processing Systems (NeurIPS)*, 34.
- Oberst, M., & Sontag, D. (2019,). Counterfactual Off-Policy Evaluation with Gumbel-Max Structural Causal Models. *Proceedings of the 36th International Conference on Machine Learning (ICML)*.
- Sontakke, S. A., Mehrjou, A., Itti, L., & Schölkopf, B. (2021,). Causal Curiosity: RL Agents Discovering Self-Supervised Experiments for Causal Representation Learning. *Proceedings of the 38th International Conference on Machine Learning (ICML)*.
- Xiong, M. (2022). *Artificial Intelligence and Causal Inference*. Chapman, Hall/CRC.

CAPÍTULO 29

Arquitecturas de IA Causal: Integración con Deep Learning y LLMs

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque IV · Semilla 42**Notebook (pack):** notebooks/Bloque_IV/notebooks/29_arquitecturas_ia_causal_integracion_deep.ipynb**Jupyter Book:** jupyter_book/content/bloque_04_ia_causal/29_arquitecturas_ia_causal.ipynb

29.1 Limitaciones de los modelos puramente asociativos

Los modelos de deep learning (redes convolucionales, transformers, LLMs) son los mejores aproximadores de funciones conocidos para tareas de percepción y generación de lenguaje. Sin embargo, su diseño los confina al **estrato 1 de la jerarquía de Pearl**: aprenden $P(Y | X)$ de la distribución de entrenamiento, sin acceso nativo a $P(Y | \text{do}(X))$ ni a contrafactuales.

29.1.1 Manifestaciones del problema

1. **Shortcut learning**: los transformers aprenden correlaciones textuales espurias. GPT-4 puede decir que los fumadores tienen mayor esperanza de vida” si ese patrón aparece en el texto de entrenamiento (correlación oculta por la estructura etaria de los estudios).
2. **Hallucination**: los LLMs generan texto *plausible* según $P(\text{texto})$ sin un modelo del mundo que restrinja las afirmaciones causales.
3. **Falla bajo distributional shift**: modelos de diagnóstico clínico entrenados en un hospital fallan en otro porque aprenden artefactos (correlaciones espurias) en lugar de mecanismos causales.
4. **Imposibilidad de planificación contrafáctica**: un chatbot que responde si hubieras tomado el medicamento, habrías mejorado” no tiene mecanismo para evaluar ese contrafactual; solo replica patrones lingüísticos de su corpus.

29.2 Esquemas de integración causal–deep learning

Existen cuatro paradigmas principales de integración:

29.2.1 Neural Causal Models (NCM)

Xia et al. (2021) proponen parametrizar los mecanismos del MCE como redes neuronales:

$$V_i = f_{\theta_i}(\text{Pa}(V_i), \epsilon_i), \quad (29.2.1)$$

donde f_{θ_i} es una red neuronal con parámetros θ_i . El modelo se entrena maximizando la verosimilitud observacional y puede responder preguntas de los tres estratos:

- **Estrato 1**: evaluar $P(Y | X = x)$ mediante muestreo.
- **Estrato 2**: mutilar el grafo $\text{do}(X = x)$ y mostrar.
- **Estrato 3**: abducción + acción + predicción con ruido inferido.

Definición 29.1 (NCM (Xia et al., 2021))

Un *Neural Causal Model* es un MCE $\langle U, V, F_{\text{theta}}, P(U) \rangle$ donde cada $f_i \in F_{\text{theta}}$ es una red neuronal y $P(U)$ es un prior difuso (e.g. gaussiano normalizing flow).

29.2.2 Causal Deep Learning: embeddings causales

Una segunda estrategia inyecta la estructura causal en la arquitectura:

- **Causal attention masking:** en el transformer, la máscara de atención refleja el DAG causal; Z_i solo puede atender a sus causas $\text{Pa}(Z_i)$.
- **Structurally constrained VAE:** el prior del VAE se diseña como un SCM (CausalVAE, cap. 27).
- **GNN causal:** redes de grafos donde las aristas representan relaciones causales y el paso de mensajes sigue el orden topológico del DAG.

29.2.3 Híbrido: LLM + módulo causal externo

Una arquitectura pragmática mantiene el LLM como módulo de lenguaje y lo acopla con un motor causal externo:

1. El LLM extrae entidades, relaciones y la pregunta causal del texto del usuario.
2. El motor causal (DoWhy, gRPC sobre el MCE) evalúa $P(Y \mid \text{do}(X))$ o el contrafactual.
3. El LLM formatea la respuesta en lenguaje natural.

29.3 Ideas para LLMs causales y razonamiento contrafáctico**29.3.1 Chain-of-Thought causal**

Estudios recientes ((Kiciman et al., 2023) ; (Jin et al., 2023)) muestran que los LLMs de gran escala tienen capacidades emergentes de razonamiento causal cuando se les pide razonar paso a paso (*chain-of-thought*):

Ejemplo 29.1 (Prompt causal con CoT)

Pregunta: Si el banco central sube la tasa de interés, ¿qué pasa con la inflación? Razona paso a paso.

Respuesta esperada: 1. Una tasa más alta encarece el crédito. 2. El crédito más caro reduce el consumo y la inversión. 3. Menor demanda agregada reduce la presión sobre los precios. 4. Por tanto, la inflación tiende a bajar.

El LLM reproduce la cadena causal del mecanismo de transmisión monetaria, aunque sin garantía de corrección en casos no vistos en el entrenamiento.

29.3.2 Limitaciones del razonamiento causal en LLMs**Proposición 29.1 (LLMs no hacen do-cálculo genuino)**

Los LLMs actuales no implementan la operación $\text{do}(\cdot)$: responden preguntas del tipo ¿qué pasa si X? interpolando patrones lingüísticos de su corpus, no evaluando modelos intervenidos. Bajo distribución out-of-distribution, sus respuestas causales son no fiables.

Para superar esta limitación, la integración con motores causales formales (DoWhy, PyCausal) o con NCMs es la dirección más prometedora.

29.4 Casos de uso: sistemas recomendadores, visión y lenguaje

29.4.1 Sistemas recomendadores causales

Los recomendadores basados en filtrado colaborativo capturan correlaciones $P(\text{click} \mid \text{user}, \text{item})$ pero no $P(\text{compra} \mid \text{do}(\text{mostrar item}))$. La diferencia es sustancial cuando hay sesgo de exposición (popularity bias). La solución causal usa IPW o DML:

$$\hat{\tau}(\text{usuario}, \text{item}) = \hat{\mu}_1(u, i) - \hat{\mu}_0(u, i), \quad (29.4.1)$$

donde $\hat{\mu}_a$ se estima con embeddings causales que separan la preferencia intrínseca del usuario de la correlación de exposición.

29.4.2 Visión causal

En visión, los NCMs generan contraejemplos visuales: dada una imagen x con predicción $\hat{y}$, el modelo responde ¿cómo habría sido la imagen si la clase fuera $y' \neq \hat{y}$? mediante abducción sobre los ruidos latentes. Esto permite:

- **Explicabilidad:** el mapa de diferencia $x' - x$ muestra qué regiones cambiaron causalmente.
- **Augmentación contrafactual:** generar imágenes con atributos intervenidos para entrenar modelos más robustos.

29.5 Perspectivas de investigación

Las direcciones más activas en IA causal al momento de publicación incluyen:

1. **Identificabilidad en NCMs:** bajo qué supuestos los NCMs son identificables desde datos observacionales (análogo a los teoremas de Shimizu y Hoyer para modelos funcionales, cap. 20).
2. **LLMs como oráculos de conocimiento previo:** usar LLMs para inicializar el DAG causal con aristas probables, que luego se refinan con datos.
3. **Causal world models para RL:** combinar NCMs con simuladores diferenciables para que los agentes planifiquen mediante razonamiento contrafactual antes de actuar (cap. 28).
4. **Auditoría causal de modelos de ML:** usar el do-cálculo para certificar que decisiones automatizadas (crédito, contratación, diagnóstico) no son causalmente discriminatorias (conexión con cap. 31).
5. **Benchmarks causales:** CausalBench, CladderBench, causalQA — datasets estándar para evaluar el razonamiento causal de modelos de IA.

29.6 Conexión con la jerarquía GCE

Las arquitecturas de IA causal mapean directamente los tres niveles de la jerarquía GCE:

- **Nivel 1 (Asociación):** los modelos puramente asociativos (transformers, LLMs sin motor causal) estiman $P(Y \mid X)$ desde la distribución de entrenamiento. Operan exclusivamente en Nivel 1 y fallan bajo distributional shift causal porque no distinguen correlación de causalidad.

- **Nivel 2 (IRM / invarianza distribucional):** Kaddour et al. (2022) muestran que las arquitecturas modulares alineadas al DAG preservan $P^{e(Y | \Phi(X))}$ entre entornos e . Esta invarianza distribucional es exactamente el Nivel 2 de la jerarquía GCE: comparar distribuciones condicionales bajo diferentes intervenciones.
- **Nivel 3 (NCM + Wasserstein):** los Neural Causal Models permiten muestrear la distribución completa de resultados bajo do-intervenciones y contrafactuales. La distancia Wasserstein $W_p(P^{\text{do}(X=x)}, P^{\text{do}(X=x')})$ mide el costo geométrico de cambiar la intervención — Nivel 3 completo.
- **Recomendadores causales:** la brecha entre $P(\text{compra} | \text{obs})$ y $P(\text{compra} | \text{do}(\text{mostrar}))$ es una distancia KL de Nivel 2. El sesgo de popularidad (*popularitybias*) es una divergencia Wasserstein medible que los modelos asociativos no pueden corregir.

29.7 Checklist Riguroso

1. Antes de usar un LLM como motor causal, verificar con CLADDER si responde correctamente preguntas de Estrato 2 y 3.
2. Para NCMs: verificar identificabilidad del MCE desde datos observacionales antes de confiar en las estimaciones.
3. Usar la arquitectura modular (NCM, causal attention masking) solo si el DAG es conocido o estimado con confianza.
4. Para recomendadores: implementar IPW o DML para corregir sesgo de popularidad antes de optimizar el ranking.
5. Evaluar los modelos causales en entornos out-of-distribution, no solo en la distribución de entrenamiento.
6. Con LLMs: usar chain-of-thought causal + motor externo (DoWhy) para preguntas que requieran do-cálculo.
7. Reportar la distancia Wasserstein entre distribuciones observacionales e intervencionales como métrica de debiasing.
8. Para visión causal: validar las imágenes contrafactuales generadas con criterios de realizabilidad (plausibilidad visual).
9. No asumir que un LLM grande hace do-cálculo genuino; realizar benchmark con CLADDER o CausalBench.
10. Documentar qué estratificación de Pearl alcanza la arquitectura elegida.

29.8 Glosario

- **NCM (Neural Causal Model):** MCE donde cada mecanismo f_i es una red neuronal.
- **Causal attention masking:** máscara de atención en transformers que refleja el DAG causal.
- **Causal world model:** modelo que permite simulación contrafactual para planificación de RL.
- **Chain-of-thought causal:** técnica de prompting que induce al LLM a razonar paso a paso causalmente.
- **Popularity bias:** sesgo de exposición en recomendadores donde ítems populares aparecen más, creando una correlación espuria.
- **CLADDER:** benchmark de razonamiento causal para LLMs con preguntas de los 3 estratos de Pearl.

- **GNN causal:** red de grafos donde las aristas son relaciones causales y el paso de mensajes sigue el orden topológico.
- **Abducción:** en un NCM, inferir los ruidos latentes U a partir de las observaciones (Estrato 3, paso 1).
- **CausalVAE:** VAE con estructura DAG en el espacio latente para aprendizaje de representaciones causales.
- **LLM + motor causal:** arquitectura híbrida donde el LLM extrae la pregunta y el motor causal la evalúa formalmente.

29.9 Cierre del capítulo

Las arquitecturas profundas y los LLMs no escalan automáticamente la escalera de Pearl. Este capítulo ancla la pretensión de IA causal a identificación, representaciones y límites empíricos.

Otras referencias clave de este capítulo: (Bareinboim, 2025), (Pearl & Mackenzie, 2018).

29.9 Referencias

- Bareinboim, E. (2025). *Causal Artificial Intelligence: A Roadmap for Building Causally Intelligent Systems*. Wiley-IEEE Press.
- Jin, Z., Liu, J., Lyu, Z., Poff, S., Sachan, M., Mihalcea, R., Diab, M., & Schölkopf, B. (2023). CLadder: A Benchmark to Assess Causal Reasoning Capabilities of Language Models. *arXiv:2312.04350*.
- Kaddour, J., Lynch, A., Liu, Q., Kusner, M. J., & Silva, R. (2022). Causal Machine Learning: A Survey and Open Problems. *arXiv preprint arXiv:2206.15475*.
- Kiciman, E., Ness, R., Sharma, A., & Tan, C. (2023). Causal Reasoning and Large Language Models. *arXiv:2305.00050*.
- Pearl, J., & Mackenzie, D. (2018). *The Book of Why: The New Science of Cause and Effect*. Basic Books.
- Xia, K., Lee, K.-Z., Bengio, Y., & Bareinboim, E. (2021). The Causal-Neural Connection. *Advances in Neural Information Processing Systems (NeurIPS)*, 34.

CAPÍTULO 30

Agentes Estadísticos Causal Semi Determinísticos

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque IV · Semilla 42**Notebook (pack):** notebooks/Bloque_IV/notebooks/30_agentes_estadisticos_causal_semi_deterministicos.ipynb**Jupyter Book:** jupyter_book/content/bloque_04_ia_causal/30_agentes_semi_deterministicos.ipynb

30.1 Motivación: más allá del agente puramente estocástico

Los agentes de IA causal que hemos estudiado en los capítulos anteriores operan en un espectro que va desde el puramente asociativo (Nivel 1 de la jerarquía de Pearl) hasta el contrafactual (Nivel 3). Sin embargo, una limitación fundamental persiste: los agentes puramente estocásticos —aquellos que muestrean acciones desde una distribución aprendida— son incapaces de garantizar consistencia en sus decisiones frente a las mismas estructuras causales. Un agente que, ante el mismo DAG y la misma evidencia, puede tomar decisiones diferentes en dos ejecuciones, carece de *determinismo causal*: su comportamiento no es explicable como consecuencia necesaria de su modelo causal.

Este capítulo introduce el marco de los **Agentes Estadísticos Causal Semi Determinísticos** (ASCSD), una clase de agentes que combinan la estructura determinística del razonamiento causal con la flexibilidad estadística del aprendizaje automático. La palabra *semi* captura la tensión productiva: el agente es determinístico en su lógica de decisión (dado un estado causal, la acción es única y reproducible), pero estocástico en su aprendizaje (los parámetros del modelo se actualizan vía inferencia estadística).

30.2 Definición Formal

Definición 30.1 (Agente Estadístico Causal Semi Determinístico (ASCSD))

Un ASCSD es una tupla $\mathcal{A} = (\mathcal{G}, \mathcal{S}, \pi, \mathcal{U})$ donde:

1. $\mathcal{G} = (\mathbf{V}, \mathbf{E})$ es un DAG causal que codifica las relaciones causales conocidas del dominio.
2. $\mathcal{S} = (\mathcal{S}_t)_{t \geq 0}$ es una secuencia de estados causales, donde cada $\mathcal{S}_t$ es una realización de las variables endógenas $\mathbf{V}$ en el tiempo t .
3. $\pi : \mathcal{S} \rightarrow \mathcal{A}$ es una **política causal determinística** que mapea cada estado causal a una única acción $a \in \mathcal{A}$, donde $\mathcal{A}$ es el espacio de acciones.
4. $\mathcal{U} : \mathcal{D} \rightarrow \pi$ es un **actualizador estadístico** que, dado un conjunto de datos $\mathcal{D} = \{(s_i, a_i, r_i)\}_{i=1}^n$, produce una nueva política π' mediante inferencia estadística.

La arquitectura ASCSD se distingue de los agentes puramente estocásticos en un aspecto crucial: la política π es una **función determinística** del estado causal, no una distribución $\pi(a \mid s)$. Esto garantiza que, para un modelo causal fijo $\mathcal{G}$ y un estado observado s , la acción del agente es *siempre la misma*.

La variabilidad proviene exclusivamente de $\mathcal{U}$: cuando el agente aprende, la política cambia; cuando el agente ejecuta, la política es fija.

30.3 La Condición de Semi Determinismo Causal

Definición 30.2 (Condición de Semi Determinismo Causal (CSDC))

Un agente $\mathcal{A} = (\mathcal{G}, \mathcal{S}, \pi, \mathcal{U})$ satisface la CSDC si:

1. **Determinismo en ejecución:** Para todo par de estados causales idénticos $s, s' \in \mathcal{S}$ con $s = s'$, se cumple $\pi(s) = \pi(s')$.
2. **Estocasticidad en aprendizaje:** El actualizador $\mathcal{U}$ es un procedimiento de inferencia estadística que produce π' como realización de una distribución posterior $P(\pi' \mid \mathcal{D}, \mathcal{G})$.
3. **Consistencia causal:** Si $\mathcal{G}$ implica $\text{do}(A = a) \rightarrow Y = y$ bajo el estado s , entonces $\pi(s) = a$ siempre que la regla de decisión lo prescriba.

La CSDC establece una separación nítida entre la *ejecución* (determinística) y el *aprendizaje* (estocástico). Esta separación no es meramente arquitectónica: tiene consecuencias fundamentales para la explicabilidad, la auditoría y la equidad del agente.

30.4 Conexión con la Jerarquía de Pearl

El ASCSD opera en los tres niveles de la jerarquía de Pearl de manera estratificada:

1. **Nivel 1 (Asociación):** El actualizador $\mathcal{U}$ utiliza datos observacionales $\mathcal{D}$ para estimar parámetros. En este nivel, el agente es puramente estocástico: aprende distribuciones condicionales $P(Y \mid X)$.
2. **Nivel 2 (Intervención):** La política π utiliza el DAG $\mathcal{G}$ para seleccionar acciones basadas en efectos interвенionales $P(Y \mid \text{do}(A = a))$. En este nivel, el agente es determinístico: dada la estructura causal, la acción es única.
3. **Nivel 3 (Contrafactual):** El agente puede razonar sobre mundos alternativos: “si hubiera tomado la acción a' en lugar de a , el resultado habría sido y' ”. Este nivel permite la auditoría contrafactual de las decisiones del agente.

Teorema 30.1 (Descomposición ASCSD de la política óptima)

Bajo la CSDC, la política óptima π^* de un ASCSD se descompone como:

$$\pi^*(s) = \operatorname{argmax}_{a \in \mathcal{A}} \mathbb{E}_{\mathcal{U}}[Y \mid \text{do}(A = a), s; \mathcal{G}] \quad (30.4.1)$$

donde la expectativa se toma sobre la distribución posterior de los parámetros del modelo causal $\mathcal{G}$, condicionando en el estado s y la intervención $\text{do}(A = a)$.

Esta descomposición revela que la optimalidad del ASCSD depende de dos fuentes de incertidumbre: la incertidumbre *epistémica* (sobre los parámetros del modelo, capturada por $\mathbb{E}_{\mathcal{U}}$) y la incertidumbre *aleatoria* (sobre los resultados, capturada por $P(Y \mid \text{do}(A = a))$). El semi determinismo garantiza que, una vez resuelta la incertidumbre epistémica (i.e., fijados los parámetros), la acción es determinística.

30.5 Arquitectura Computacional

30.5.1 Módulo Causal Determinístico

El módulo causal determinístico implementa la política π como un programa que, dado un estado s y un DAG $\mathcal{G}$, ejecuta el siguiente procedimiento:

Método 30.1 (Ejecución determinística del ASCSD)

Dado un estado causal s y un DAG $\mathcal{G}$:

1. **Identificación:** Para cada acción candidata $a \in \mathcal{A}$, verificar si el efecto $P(Y \mid \text{do}(A = a), s)$ es identificable en $\mathcal{G}$.
2. **Estimación:** Si es identificable, estimar $\mathbb{E}[Y \mid \text{do}(A = a), s]$ usando el estimand derivado por el Algoritmo ID.
3. **Selección:** Retornar $a^* = \arg\max_a \mathbb{E}[Y \mid \text{do}(A = a), s]$.
4. **Fallback:** Si el efecto no es identificable, recurrir a cotas de Manski o a análisis de sensibilidad.

Este procedimiento es *determinístico*: dados s y $\mathcal{G}$, el resultado es siempre a^* . No hay muestreo, no hay aleatoriedad. La acción es una consecuencia necesaria del modelo causal.

30.5.2 Módulo de Aprendizaje Estadístico

El módulo de aprendizaje $\mathcal{U}$ actualiza los parámetros del modelo causal $\mathcal{G}$ a partir de datos observacionales e intervencionales:

Método 30.2 (Actualización estadística del ASCSD)

Dado un conjunto de datos $\mathcal{D} = \{(s_i, a_i, y_i)\}_{i=1}^n$:

1. **Actualización paramétrica:** Estimar los mecanismos causales $f_i \in \mathcal{G}$ mediante métodos de ML (redes neuronales, bosques, etc.) con cross-fitting.
2. **Actualización estructural:** Si el DAG no es conocido, ejecutar descubrimiento causal (PC, NOTEARS) sobre $\mathcal{D}$ para obtener $\hat{\mathcal{G}}$.
3. **Validación:** Aplicar pruebas de refutación (placebo, confusor sintético) y análisis de sensibilidad (e-values, Rosenbaum bounds).
4. **Política resultante:** $\pi' = \mathcal{U}(\mathcal{D})$ es la nueva política determinística.

La actualización es *estocástica*: diferentes muestras de datos o diferentes inicializaciones del algoritmo de aprendizaje pueden producir políticas π' diferentes. Pero una vez que π' está fija, la ejecución es determinística.

30.6 Propiedades Formales

Teorema 30.2 (Consistencia del ASCSD bajo CSDC)

Si el DAG $\mathcal{G}$ es correcto y el actualizador $\mathcal{U}$ es consistente, entonces la política π_t del ASCSD converge a la política causal óptima π^* cuando $n \rightarrow \infty$:

$$\pi_t \xrightarrow[a.s.]{} \pi^* \quad \text{cuando } t \rightarrow \infty, \quad (30.6.1)$$

donde $\pi^*(s) = \arg\max_a \mathbb{E}[Y \mid \text{do}(A = a), s; \mathcal{G}^*]$ y $\mathcal{G}^*$ es el DAG verdadero.

Teorema 30.3 (Reproducibilidad del ASCSD)

Bajo la CSDC, si dos agentes $\mathcal{A}_1$ y $\mathcal{A}_2$ comparten el mismo DAG $\mathcal{G}$, los mismos parámetros $\hat{\theta}$ y el mismo estado s , entonces sus acciones son idénticas:

$$\pi_1(s) = \pi_2(s) \quad \forall s \in \mathcal{S}. \quad (30.6.2)$$

Esta propiedad es fundamental para la *auditoría algorítmica*: un agente ASCSD puede ser auditado reproduciendo exactamente sus decisiones, algo imposible con agentes puramente estocásticos.

30.7 Aplicaciones

30.7.1 Auditoría algorítmica causal

Un ASCSD en un sistema de crédito puede ser auditado de la siguiente manera:

1. **Reproducibilidad:** Dado el mismo perfil de solicitante, el agente siempre toma la misma decisión (acepta o rechaza).
2. **Equidad contrafactual:** Se puede preguntar: “si el solicitante hubiera tenido un atributo sensible diferente (género, raza), la decisión habría cambiado?” Esta es una pregunta de Nivel 3 que el ASCSD puede responder porque su política es determinística.
3. **Explicabilidad:** La decisión del agente se explica como consecuencia necesaria del modelo causal: “el agente aprobó el crédito porque, según el DAG, el efecto de aprobar sobre la probabilidad de repago es mayor que el de rechazar, condicional en el perfil del solicitante”.

30.7.2 Política pública

En programas sociales (e.g., Pensión 65, Juntos), un ASCSD puede:

1. **Determinar** la elegibilidad de un beneficiario de manera determinística, garantizando consistencia.
2. **Aprender** de datos administrativos para mejorar la focalización, actualizando la política periódicamente.
3. **Auditar** si la asignación es causalmente justa: si cambiar el atributo de etnicidad no cambia la decisión, el agente satisface equidad contrafactual.

30.8 Conexión con la jerarquía GCE

El ASCSD integra los tres niveles de la jerarquía GCE:

- **Nivel 1 (ATE):** El actualizador $\mathcal{U}$ estima efectos causales promedio a partir de datos observacionales. La calidad de la política π depende de la precisión de estas estimaciones.
- **Nivel 2 (Divergencia KL):** La selección de acciones compara distribuciones intervencionales $P(Y \mid \text{do}(A = a))$ entre acciones candidatas. La divergencia KL entre la distribución del resultado bajo la acción óptima y las alternativas cuantifica la *ganancia informacional* de la decisión.
- **Nivel 3 (Wasserstein):** La auditoría contrafactual compara la distribución del resultado bajo la acción tomada con la distribución bajo la acción alternativa (no tomada). La distancia Wasserstein $W_1(P(Y \mid \text{do}(A = a)), P(Y \mid \text{do}(A = a')))$ mide el *costo de transporte* entre mundos posibles, cuantificando el arrepentimiento causal.

30.9 Checklist Riguroso

1. Verificar que la política π es determinística: para todo s , $\pi(s)$ es único y reproducible.
2. Verificar que el actualizador $\mathcal{U}$ es estadísticamente consistente: los mecanismos estimados convergen a los verdaderos.
3. Si el DAG no es conocido, usar descubrimiento causal con validación (stability selection, SHD/SID).
4. Para auditoría de equidad: verificar que $\pi(s_{A \leftarrow a'}) = \pi(s)$ para todo atributo sensible A y valor alternativo a' .
5. Reportar la incertidumbre epistémica: la política π es determinística, pero los parámetros que la definen tienen intervalos de confianza.
6. En política pública: documentar el DAG, los datos de entrenamiento y la versión de la política π_t usada en cada decisión.
7. Si el efecto no es identificable: usar cotas de Manski y reportar la ambigüedad residual.
8. Para RL secuencial: extender el ASCSD a procesos de decisión markovianos causales (Cap. 28) manteniendo la CSDC en cada paso.

30.10 Glosario

- **ASCSD:** Agente Estadístico Causal Semi Determinístico. Agente cuya ejecución es determinística pero cuyo aprendizaje es estocástico.
- **CSDC:** Condición de Semi Determinismo Causal. Exige determinismo en ejecución y estocasticidad en aprendizaje.
- **Política causal determinística:** Función $\pi : \mathcal{S} \rightarrow \mathcal{A}$ que mapea estados causales a acciones únicas.
- **Actualizador estadístico:** Procedimiento $\mathcal{U}$ que actualiza la política π a partir de datos mediante inferencia estadística.
- **Incertidumbre epistémica:** Incertidumbre sobre los parámetros del modelo causal, reducible con más datos.
- **Incertidumbre aleatoria:** Incertidumbre inherente al resultado de una intervención, irreducible.
- **Reproducibilidad:** Propiedad de un agente de producir la misma acción ante el mismo estado, garantizada por la CSDC.
- **Equidad contrafactual:** Condición que exige que la decisión del agente no cambie si el atributo sensible hubiera sido diferente.

30.11 Cierre del capítulo

Los agentes semi-determinísticos formalizan la idea de un pipeline causal auditable: grafo, identificación, estimación y refutación como contrato. Sin ese contrato, un “agente” solo automatiza la confusión.

Otras referencias clave de este capítulo: (Pearl, 2009), (Bareinboim, 2025), (Kusner et al., 2017), (Manski, 1990), (Rosenbaum, 2002), (Spirtes et al., 2000).

30.11 Referencias

Bareinboim, E. (2025). *Causal Artificial Intelligence: A Roadmap for Building Causally Intelligent Systems*. Wiley-IEEE Press.

- Kusner, M. J., Loftus, J., Russell, C., & Silva, R. (2017). Counterfactual Fairness. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Manski, C. F. (1990). Nonparametric Bounds on Treatment Effects. *American Economic Review, Papers and Proceedings*, 80(2), 319-323.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Rosenbaum, P. R. (2002). *Observational Studies* (2.^a ed.). Springer.
- Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, Prediction, and Search* (2.^a ed.). MIT Press.

CAPÍTULO 31

Equidad, Ética y Regulación desde la Perspectiva Causal

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque IV · Semilla 42**Notebook (pack):** notebooks/Bloque_IV/notebooks/31_equidad_etica_regulacion_desde_perspectiva.ipynb**Jupyter Book:** jupyter_book/content/bloque_04_ia_causal/31_equidad_etica.ipynb

31.1 Definiciones causales de equidad y no discriminación

Las definiciones estadísticas de equidad (paridad demográfica, igualdad de oportunidades, equidad predictiva) son métricas de **estrato 1**: describen la distribución conjunta $P(Y, A, X)$ sin distinguir entre efectos causales directos de A (el atributo sensible) sobre $\hat{Y}$ y correlaciones mediadas por variables legítimas.

Definición 31.1 (Paridad demográfica estadística)

Un clasificador $\hat{Y}$ satisface *paridad demográfica* si $P(\hat{Y} = 1 \mid A = 1) = P(\hat{Y} = 1 \mid A = 0)$. Esta condición es independiente del efecto causal de A sobre Y .

La limitación es evidente: si A (género) afecta $\hat{Y}$ (salario predicho) exclusivamente a través de experiencia laboral y educación (variables legítimas), la violación de paridad demográfica no es necesariamente discriminatoria. El enfoque causal distingue:

Definición 31.2 (Efecto causal total, directo y de camino)

Sea A el atributo sensible (género, raza), X covariables de mérito, M mediadores, Y la decisión. Se define:

- **TCE** (Total Causal Effect): $P(Y_{A=1}) - P(Y_{A=0})$ — efecto total de cambiar A .
- **NDE** (Natural Direct Effect): $\mathbb{E}[Y_{A=1, M_{A=0}} - Y_{A=0, M_{A=0}}]$ — efecto de A sobre Y bloqueando los mediadores.
- **NIE** (Natural Indirect Effect): $\mathbb{E}[Y_{A=1, M_{A=1}} - Y_{A=1, M_{A=0}}]$ — efecto de A sobre Y a través de los mediadores.

Teorema 31.1 (Descomposición TCP-NDE-NIE)

Bajo las condiciones de identificabilidad de Pearl (2001):

$$\text{TCE} = \text{NDE} + \text{NIE}. \quad (31.1.1)$$

La discriminación causal directa corresponde a $\text{NDE} \neq 0$; la discriminación indirecta a $\text{NIE} \neq 0$ a través de caminos ilícitos.

31.2 Análisis de caminos lícitos e ilícitos



31.2.1 Formalización legal

El marco causal permite operacionalizar la distinción legal entre *disparate treatment* (discriminación directa) y *disparate impact* (discriminación indirecta):

Definición 31.3 (Camino causal lícito e ilícito)

En un DAG con atributo sensible A , decisión $\hat{Y}$ y variables X :

- Un camino $A \rightarrow \dots \rightarrow \hat{Y}$ es *lícito* si pasa exclusivamente a través de variables de mérito o productividad (e.g. experiencia, titulación).
- Un camino es *ilícito* si pasa a través de variables que el sistema legal o ético prohíbe como justificación (e.g. raza $\rightarrow$ barrio $\rightarrow$ crédito, cuando el barrio actúa como proxy racial).

Definición 31.4 (Efecto de camino controlado (Pathway-specific effect))

El efecto de A sobre $\hat{Y}$ a través de un conjunto de caminos Π es:

$$\text{PSE}_{\Pi} = \mathbb{E} \left[\hat{Y}_{A=1}^{\Pi} - \hat{Y}_{A=0}^{\Pi} \right], \quad (31.2.1)$$

donde $\hat{Y}_{A=a}^{\Pi}$ bloquea todos los caminos excepto los de Π .

Un sistema es **causalmente justo** si el efecto de A sobre $\hat{Y}$ a través de caminos ilícitos es nulo: $\text{PSE}_{\{\Pi_{\text{ilícito}}\}} = 0$.

31.2.2 Contrafactual de equidad individual

La *counterfactual fairness* (Kusner et al., 2017) exige que la decisión para un individuo (x, a) sea la misma en el mundo contrafactual donde A hubiera tomado el valor opuesto:

$$P(\hat{Y}_{A=a'} = y \mid X = x, A = a) = P(\hat{Y} = y \mid X = x, A = a), \quad (31.2.2)$$

para todo par (a, a') . Esta es una condición de **estrato 3** (contrafactual).

31.3 Evaluación causal de sistemas de decisión (crédito, justicia, salud)

31.3.1 Crédito bancario

En un modelo de scoring crediticio, A = raza, X = ingreso, historial crediticio, M = zona geográfica. Si la zona geográfica es proxy racial (discriminación histórica materializada en la geografía), el camino $A \rightarrow M \rightarrow$ crédito es ilícito aunque el banco no use la raza explícitamente. El análisis causal detecta este caso; la auditoría estadística estándar no necesariamente lo haría.

31.3.2 Justicia penal (COMPAS)

El algoritmo COMPAS predice reincidencia criminal. Análisis causales mostraron que errores diferenciales por raza no pueden atribuirse a discriminación directa de la variable raza (no incluida) sino a proxies correlacionados que capturan desigualdades sistémicas. La intervención correctiva no es reentrenar el modelo sino abordar las causas estructurales de esas desigualdades, lo que está fuera del alcance del algoritmo.

31.3.3 Salud

El algoritmo descrito por Obermeyer et al. (2019) para priorizar cuidados de salud usaba costos como proxy de necesidad médica. Dado que el costo histórico de atención es menor para pacientes negros (por barreras de acceso), el algoritmo infraestimó sistemáticamente su necesidad. La solución causal reemplaza el proxy sesgado por una estimación del resultado de salud directamente.

31.4 Implicancias regulatorias y de gobernanza de IA

31.4.1 Marco regulatorio europeo (EU AI Act)

El Reglamento de IA de la UE (2024) clasifica los sistemas de IA en cuatro categorías de riesgo. Los sistemas de alto riesgo (crédito, empleo, justicia, salud) deben:

1. Documentar las variables usadas y su posible proxy causal con atributos sensibles.
2. Realizar evaluaciones de impacto de equidad (*fundamental rights impact assessment*).
3. Demostrar que los sesgos identificados han sido mitigados razonablemente.

El análisis de caminos causales es la herramienta técnica más adecuada para satisfacer estos requisitos.

31.4.2 Recomendaciones prácticas

- **Construir el DAG antes de entrenar el modelo:** identificar explícitamente atributos sensibles, mediadores lícitos e ilícitos, covariables de mérito y potenciales confounders.
- **Estimar NDE y PSE:** cuantificar qué fracción del efecto de A pasa por caminos ilícitos.
- **Intervención minimal:** modificar el modelo solo en la medida necesaria para eliminar el efecto ilícito, preservando el efecto lícito (mérito).
- **Auditoría externa periódica:** la estructura causal del entorno cambia con el tiempo (cambios en el mercado laboral, en la distribución de la población), por lo que la auditoría es un proceso continuo.

31.5 Conexión con la jerarquía GCE

La equidad causal opera en los tres niveles de la jerarquía GCE con precisión creciente:

- **Nivel 1 (paridad estadística):** la paridad demográfica $P(\hat{Y} = 1 \mid A = 1) = P(\hat{Y} = 1 \mid A = 0)$ es una condición de Nivel 1 — comparación de medias bajo la distribución observacional. El Teorema de Imposibilidad (Chouldechova, 2017) demuestra que no se pueden satisfacer simultáneamente calibración, FPR balanceada y PPV balanceada excepto en casos triviales.
- **Nivel 2 (equidad distribucional):** comparar la distribución completa de $P(\hat{Y} \mid \text{do}(A = a))$ entre grupos es una condición de Nivel 2. Los efectos de camino específico (PSE) operan en este nivel: D_{KL} entre distribuciones de decisiones bajo el camino ilícito debe ser cero.
- **Nivel 3 (equidad contrafactual):** la counterfactual fairness de Kusner et al. (2017) exige $P(\hat{Y}_{A \leftarrow a} \mid X = x, A = a) = P(\hat{Y} \mid X = x, A = a)$ para toda observación individual — condición de Estrato 3. Requiere modelar el DAG completo con mecanismos causales y ruidos atómicos para cada individuo.
- **Aplicación Nivel 2:** la inequidad en programas sociales peruanos (Pensión 65, Juntos) puede cuantificarse como $D_{\text{KL}}(P(Y \mid \text{do}(A = \text{etnicidad})), P(Y \mid \text{do}(A = \text{referencia})))$ restringida a caminos ilícitos del DAG del programa.

31.6 Checklist Riguroso

1. Construir el DAG *antes* de entrenar el clasificador: identificar atributo sensible A , mediadores lícitos e ilícitos.
2. Distinguir *disparate treatment* ($NDE \neq 0$) de *disparate impact* ($NIE \neq 0$ por caminos ilícitos).
3. Estimar PSE ilícito mediante g-computation o DoWhy, no solo la diferencia de tasas de predicción.
4. Aplicar el Teorema de Imposibilidad: no intentar satisfacer simultáneamente paridad, calibración y equidad de error.
5. Para equidad contrafactual: verificar identificabilidad del contrafactual $Y_{A \leftarrow a'}$ desde el DAG.
6. Reportar el PSE ilícito junto con la métrica predictiva (AUC, F1) en el informe de auditoría.
7. Con aif360 o fairlearn: usar `MetaFairClassifier` con constraint de equidad de oportunidades.
8. Con datos LATAM: mapear la variable de etnicidad al DAG correctamente, considerando auto-identificación vs. raza asignada.
9. Realizar auditoría periódica: la estructura causal (y la discriminación) cambia con el tiempo.
10. Documentar claramente qué definición de equidad se usa y por qué, con justificación legal o ética.

31.7 Glosario

- **TCE** (*Total Causal Effect*): efecto causal total de A sobre $\hat{Y}$, suma de todos los caminos.
- **NDE** (*Natural Direct Effect*): efecto de A sobre $\hat{Y}$ bloqueando los mediadores.
- **NIE** (*Natural Indirect Effect*): efecto de A sobre $\hat{Y}$ a través de los mediadores.
- **PSE** (*Path-Specific Effect*): efecto de A sobre $\hat{Y}$ a través de un subconjunto de caminos.
- **Counterfactual fairness**: exigencia de que la decisión sea la misma en el mundo contrafactual donde A es distinto.
- **Paridad demográfica**: $P(\hat{Y} = 1 \mid A = 1) = P(\hat{Y} = 1 \mid A = 0)$; condición de Estrato 1.
- **Disparate treatment**: discriminación directa; A afecta $\hat{Y}$ por caminos ilícitos.
- **Disparate impact**: discriminación indirecta; proxies de A afectan $\hat{Y}$.
- **Camino lícito**: camino $A \rightarrow \dots \rightarrow \hat{Y}$ a través de variables de mérito o productividad.
- **Teorema de Imposibilidad** (Chouldechova, 2017): calibración, FPR balanceada y PPV balanceada no pueden satisfacerse simultáneamente en general.

31.8 Cierre del capítulo

La equidad contrafactual exige descomponer caminos y declarar qué rutas son ilegítimas. Sin DAG y sin estimandos path-specific, la “justicia algorítmica” se reduce a paridad estadística de Nivel 1.

Otras referencias clave de este capítulo: (Nabi & Shpitser, 2018), (Bareinboim, 2025).

31.8 Referencias

- Bareinboim, E. (2025). *Causal Artificial Intelligence: A Roadmap for Building Causally Intelligent Systems*. Wiley-IEEE Press.
- Chouldechova, A. (2017). Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments. *Big Data*, 5(2), 153-163.
- Kusner, M. J., Loftus, J., Russell, C., & Silva, R. (2017). Counterfactual Fairness. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Nabi, R., & Shpitser, I. (2018). Fair Inference on Outcomes. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32.

- Obermeyer, Z., Powers, B., Vogeli, C., & Mullainathan, S. (2019). Dissecting Racial Bias in an Algorithm Used to Manage the Health of Populations. *Science*, 366(6464), 447-453.
- Pearl, J. (2001). Direct and Indirect Effects. *Proceedings of the Seventeenth Conference on Uncertainty in Artificial Intelligence (UAI-01)*, 411-420.

CAPÍTULO 32

Hoja de Ruta de la IA Causal y Problemas Abiertos

Inferencia Causal Aplicada con Python · DES504 · Prof. Dr. Jaime Lincovil

Laboratorio — Bloque IV · Semilla 42

Notebook (pack): notebooks/Bloque_IV/notebooks/32_hoja_ruta_ia_causal_problemas.ipynb

Jupyter Book: jupyter_book/content/bloque_04_ia_causal/32_hoja_ruta.ipynb

32.1 La jerarquía de Pearl y su rol en IA

El curso ha recorrido los tres estratos de la jerarquía de Pearl como columna vertebral de la inteligencia artificial causal:

1. **Estrato 1 — Asociación:** $P(Y | X = x)$. Las técnicas de aprendizaje estadístico clásico (regresión, redes neuronales, árboles de decisión) operan en este estrato. Permiten predecir, clasificar y describir, pero son frágiles ante cambios de distribución porque no distinguen correlación de causalidad.
2. **Estrato 2 — Intervención:** $P(Y | \text{do}(X = x))$. El cálculo-d o, los DAGs y los métodos de inferencia causal potencial (RCT, DiD, IV, RD) pertenecen aquí. Permiten responder ¿qué pasará si actuamos? pero no ¿por qué sucedió?.
3. **Estrato 3 — Contrafactual:** $P(Y_x | X = x', Y = y')$. El razonamiento contrafactual individual, la equidad causal, la responsabilidad causal y los NCMs operan en este estrato. Es el nivel propio de la causalidad que los seres humanos usan para atribuir causas, imaginar alternativas y aprender de la experiencia.

Teorema 32.1 (Imposibilidad de escalada sin modelo estructural)

Ningún algoritmo que opera exclusivamente en el estrato 1 puede responder preguntas de estrato 2 o 3 sin supuestos estructurales adicionales (Pearl, 2009). Esta es la razón fundamental por la que el ML predictivo falla ante distributional shift causal.

El rol de la jerarquía en IA es prescriptivo: para que un sistema de IA sea *causalmente inteligente*, debe integrar capacidades de los tres estratos en lugar de optimizar métricas del estrato 1.

32.2 Agenda de investigación en IA causal

32.2.1 Descubrimiento causal a partir de datos observacionales

El problema de descubrir la estructura causal (el DAG) de los datos es central y sigue abierto en el caso general. Las líneas activas de investigación incluyen:

- **Explotación de no-linealidades y no-gaussianidad:** métodos como LiNGAM, ANM y RECI infieren la dirección causal a partir de asimetrías en la distribución de residuos.

- **Descubrimiento causal diferenciable:** NOTEARS, DAGMA y variantes modernas formulan la búsqueda del DAG como un problema de optimización continua con restricción de aciclicidad $h(W) = 0$.
- **Aprendizaje causal profundo:** integrar el descubrimiento causal con redes neuronales para escalas con miles de variables (genómica, imágenes).

32.2.2 Generalización y transferencia causal

- **Invariant risk minimization (IRM)** y sus extensiones buscan representaciones causales que sean estables entre entornos.
- **Domain adaptation causal:** identificar qué partes del mecanismo causal cambian entre source y target (mecanismos modulares).
- **Transporte causal** (Bareinboim & Pearl, 2016, Bareinboim y Pearl): bajo qué condiciones los resultados de un entorno son transportables a otro con distribución diferente.

32.2.3 IA generativa causal

Los modelos generativos (VAEs, flujos normalizantes, GANs) pueden integrarse con SCMs para permitir muestreo de contrafactuales a nivel de imagen o texto. Esto abre aplicaciones en medicina (¿cómo se vería la imagen de un paciente si hubiera recibido otro tratamiento?), en auditorías de equidad y en la generación de datos sintéticos causalmente válidos.

32.3 Desafíos técnicos: identificabilidad, escalabilidad, validación

32.3.1 Identificabilidad

- La identificación de efectos causales en grafos con variables latentes comunes es un problema no resuelto en el caso general.
- El algoritmo ID (Shpitser & Pearl, 2006) y su extensión multi-cadena resuelven el problema para grafos arbitrarios, pero la validación empírica del DAG asumido permanece difícil.
- **Semidentificación:** en algunos casos solo se puede identificar una banda de valores (bounds, Manski) en lugar de un valor puntual.

32.3.2 Escalabilidad

- Los algoritmos de búsqueda estructural (PC, FCI, GES) tienen complejidad superexponencial en el número de variables. Los enfoques diferenciables reducen el problema pero a costa de garantías de recuperación exacta.
- La estimación de efectos causales con ML (X-learner, CausalForest, DML) escala bien, pero la construcción y validación del DAG no.

32.3.3 Validación

- Los DAGs son supuestos no observables directamente desde los datos. La validación requiere experimentos controlados, conocimiento de dominio o pruebas de independencia condicional (que son potencialmente erróneas en muestras finitas).
- Las pruebas de robustez (sensibilidad al confounding no observado, análisis de Rosenbaum, e-values) son esenciales para reportar la incertidumbre en las conclusiones causales.

32.4 Desafíos éticos y sociales

La aplicación de la inferencia causal no es éticamente neutral. Los principales desafíos son:

32.4.1 Responsabilidad algorítmica y causalidad

Atribuir responsabilidad legal o moral por los resultados de un sistema de IA requiere razonamiento contrafactual: ¿habría ocurrido el daño si el sistema hubiera actuado de modo diferente? Esta es una pregunta de estrato 3. Los marcos de responsabilidad algorítmica basados únicamente en estadísticas descriptivas son insuficientes.

32.4.2 Uso del análisis causal para evadir regulación

El análisis de caminos causales puede ser mal usado para demostrar ‘que la discriminación pasa por caminos lícitos cuando la estructura del grafo ha sido diseñada instrumentalmente para ese fin. La auditoría causal debe ser independiente y basarse en el estado del arte epistemológico del dominio.

32.4.3 Uso en política pública

Las intervenciones causales a gran escala (programas sociales, regulaciones, algoritmos de salud pública) afectan a millones de personas. La responsabilidad del analista causal incluye:

- Reportar explícitamente los supuestos del análisis y su plausibilidad.
- Estimar la incertidumbre de las conclusiones, no solo el estimador puntual.
- Considerar efectos de equilibrio general que los SCMs locales no capturan.

32.5 Síntesis del curso y líneas para profundización

32.5.1 Síntesis conceptual

Esta monografía ha establecido una progresión coherente desde los fundamentos del razonamiento causal hasta las fronteras de la IA causal, organizada por la jerarquía GCE:

- **Bloque I – Nivel 1, Localización (caps. 1–12):** resultados potenciales, RCT, matching, IPW/AIPW, IV, LATE, RDD, DiD, control sintético, mediación, sensibilidad y guía de selección de métodos.
- **Bloque II – Nivel 2 y formalización Pearl (caps. 13–19):** SCM, DAGs, d-separación, backdoor y frontdoor, naturaleza de las causas, do-cálculo y contrafactuales.
- **Bloque III – Precondición y ML causal (caps. 20–27):** descubrimiento estructural, meta-learners, DML, bosques causales, paneles, OPE y representaciones causales.
- **Bloque IV – Geometría e IA causal (caps. 28–32):** RL causal, arquitecturas profundas y LLMs, agentes semi-determinísticos, equidad contrafactual y hoja de ruta.

32.5.2 Líneas de profundización

- **Econometría causal avanzada:** (Angrist & Pischke, 2009), (Imbens & Rubin, 2015).
- **Descubrimiento causal:** (Spirtes et al., 2000) ; (Peters et al., 2017).
- **ML causal con teoría:** (Wager & Athey, 2018), (Chernozhukov et al., 2018).
- **IA causal:** (Schölkopf et al., 2021), (Bareinboim, 2025).
- **Equidad causal:** (Kusner et al., 2017), (Nabi & Shpitser, 2018).

32.6 Los 7 Pilares de la IA Causal (Pearl, 2019)

Pearl (2019) identificó siete capacidades causales fundamentales que una inteligencia artificial genuinamente causal debe dominar. La siguiente tabla mapea cada pilar a los estratos de la jerarquía, las herramientas desarrolladas en este libro, y el estado actual de los LLMs:

Pilar	Estrato	Capacidad	Herramienta	Caps.	LLMs
1. Predictibilidad	Nivel 1 (Asoc.)	$P(Y X = x)$	ML supervisado, regresión	1–6	Sí (nativo)
2. Intervención	Nivel 2 (Interv.)	$P(Y \text{do}(X = x))$	DAGs, do-cálculo, RCT	7–12, 13–16	Parcial (CoT)
3. Contrafactuales	Nivel 3 (CF)	$P(Y_{x'} X = x', Y = y')$	SCM, NCM, abducción	13, 19, 29	No (sin MCE)
4. Atribución	Nivel 3 (CF)	PoC, PN, PS	Efecto de camino, PSE	19, 31	No
5. Explicabilidad	Nivel 2–3	Por qué Y ocurrió	NDE/NIE, SHAP causal	10, 31	Parcial
6. Control	Nivel 2–3	Política óptima	RL causal, DTR, OPE	26, 28	No
7. Descubrimiento	Meta-nivel	Aprender G desde datos	PC, GES, LiN-GAM, NO-TEARS	20	Emergente

Tabla 11: Los 7 pilares de la IA causal (Pearl, 2019) mapeados al libro

Los LLMs actuales cubren nativamente solo el Pilar 1 (Nivel 1). Los Pilares 3, 4 y 6 requieren Modelos Causales Estructurales (MCE) explícitos — el problema abierto central de la IA causal.

32.7 Conexión con la jerarquía GCE

El cierre de la monografía reafirma que la jerarquía GCE es la métrica unificadora del volumen:

- **Nivel 1 → localización:** desde la diferencia de medias del Cap. 1 hasta el DML del Cap. 23, el Bloque I estima cantidades de localización. La progresión es cómo identificar $\mathbb{E}[Y(1) - Y(0)]$ con cada vez menos supuestos de diseño.
- **Nivel 2 → forma:** el Bloque II y parte del III entregan herramientas para comparar distribuciones bajo intervenciones. Divergencias f (p. ej. KL, TV) cuantifican el cambio distribucional completo, no solo su media.
- **Nivel 3 → geometría:** el transporte óptimo (W_1 , $W^{G,1}$) y, en el Bloque IV, RL causal, representaciones y equidad contrafactual operan en la geometría de mundos posibles. Los LLMs actuales no alcanzan este nivel de forma nativa.
- **La conjetura de Pearl como desafío:** una IA verdaderamente inteligente debe integrar los tres estratos de la escalera causal y los tres niveles GCE. La tabla de los 7 pilares muestra que los LLMs de 2026 cubren nativamente solo el Pilar 1. Los Pilares 3, 4 y 6 requieren MCEs explícitos — el problema abierto central de la IA causal.

32.8 Checklist Riguroso

1. Al concluir un proyecto causal, verificar en qué nivel de la jerarquía GCE opera: ¿localización ($|\tau_{ATE}|$), forma (D_f) o geometría (W_1)?
2. Si el proyecto usó un LLM para razonamiento causal: validar con CLADDER qué estratos cubre realmente.
3. Reportar siempre los supuestos del DAG y su plausibilidad con conocimiento de dominio.
4. Para alta dimensión: usar métodos diferenciables (NOTEARS, DAGMA) pero reportar sus garantías de recuperación.
5. En política pública: reportar efectos de equilibrio general que el SCM local no captura.
6. Incluir análisis de sensibilidad (e-values, límites de Manski) antes de reportar conclusiones causales.
7. Si el proyecto tiene componente de equidad: construir el DAG primero y estimar PSE ilícito formalmente.
8. Para RL causal: verificar que la política aprendida es transferible entre entornos con mismos mecanismos.
9. Proponer una contribución: ¿qué pilar de Pearl avanza tu proyecto?, ¿qué brechas cierras?
10. Compartir el código y el DAG: la reproducibilidad causal incluye el modelo estructural, no solo los datos.

32.9 Glosario

- **Los 7 pilares de Pearl:** predictibilidad, intervención, contrafactuales, atribución, explicabilidad, control, descubrimiento.
- **Causal Foundation Model:** modelo pre-entrenado con capacidad de razonamiento causal en los 3 estratos.
- **Identificabilidad:** propiedad de un parámetro causal de ser recuperable únicamente desde la distribución observacional.
- **Semidentificación:** cuando solo se puede obtener un intervalo de valores (límites de Manski) en lugar de una cantidad puntual.
- **NOTEARS:** formulación diferenciable del descubrimiento causal; $h(\mathbf{W}) = \text{tr}(e^{\mathbf{W} \odot \mathbf{W}}) - d = 0$.
- **E-value:** medida de robustez causal; el mínimo odds ratio de confounding no observado que borraría un efecto.
- **Transporte causal:** traslado de conclusiones causales de un distribucional P^s a otro P^t con diferente marginal.
- **Brechas para LLMs:** los Pilares 3 (contrafactuales), 4 (atribución) y 6 (control) requieren MCE explícito.
- **Pipeline causal end-to-end:** DAG $\rightarrow$ identificación $\rightarrow$ estimación $\rightarrow$ validación $\rightarrow$ decisión.
- **Jerarquía GCE como métrica unificadora:** Nivel 1 = $|\tau_{ATE}|$; Nivel 2 = divergencias f ; Nivel 3 = $W_1 / W^{G,1}$.

32.10 Cierre monográfico

Esta monografía ha defendido una tesis única: **toda pregunta causal es, en última instancia, una comparación geométrica entre distribuciones contrafactuales**, y la jerarquía GCE ordena esa comparación en localización, forma y costo de transporte. El camino del lector ha sido:

1. **Comprender** por qué el ATE puede ser ciego (Paradoja del Efecto Cero) y por qué W_1 acota $|\tau_{ATE}|$.

2. **Dominar** el lenguaje de identificación (resultados potenciales, SCM, do-cálculo) sin abandonar la implementación verificable.

3. **Cruzar** hacia el ML y la IA causal sin perder el contrato de supuestos, sensibilidad y refutación.

Lo que queda abierto —descubrimiento a gran escala, transporte entre entornos, contrafactuales en modelos generativos, equidad path-specific en sistemas reales— no es un fracaso del marco, sino su frontera. La monografía no cierra la causalidad; fija un vocabulario y una geometría con los que esa frontera puede discutirse con rigor.

Quien complete este volumen con el laboratorio asociado habrá adquirido no solo un catálogo de estimadores, sino un criterio: saber **qué nivel GCE** responde a su pregunta, **qué supuestos** lo sostienen y **qué falla** cuando el mundo se niega a coincidir con el modelo.

Otras referencias clave de este capítulo: (Pearl, 2009), (Pearl & Mackenzie, 2018).

32.10 Referencias

- Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.
- Bareinboim, E. (2025). *Causal Artificial Intelligence: A Roadmap for Building Causally Intelligent Systems*. Wiley-IEEE Press.
- Bareinboim, E., & Pearl, J. (2016). Causal Inference and the Data-Fusion Problem. *Proceedings of the National Academy of Sciences*, 113(27), 7345-7352.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1-C68.
- Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- Kusner, M. J., Loftus, J., Russell, C., & Silva, R. (2017). Counterfactual Fairness. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Nabi, R., & Shpitser, I. (2018). Fair Inference on Outcomes. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.^a ed.). Cambridge University Press.
- Pearl, J. (2019). The Seven Tools of Causal Inference, with Reflections on Machine Learning. *Communications of the ACM*, 62(3), 54-60.
- Pearl, J., & Mackenzie, D. (2018). *The Book of Why: The New Science of Cause and Effect*. Basic Books.
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of Causal Inference: Foundations and Learning Algorithms*. MIT Press.
- Schölkopf, B., Locatello, F., Bauer, S., Ke, N. R., Kalchbrenner, N., Goyal, A., & Bengio, Y. (2021). Toward Causal Representation Learning. *Proceedings of the IEEE*, 109(5), 612-634.
- Shpitser, I., & Pearl, J. (2006). Identification of Joint Interventional Distributions in Recursive Semi-Markovian Causal Models. *Proceedings of the 21st National Conference on Artificial Intelligence (AAAI 2006)*, 1219-1226.
- Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, Prediction, and Search* (2.^a ed.). MIT Press.
- Wager, S., & Athey, S. (2018). Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests. *Journal of the American Statistical Association*, 113(523), 1228-1242.

Apéndice A: Fundamentos de Medida y Transporte Óptimo

32.11 Introducción

Este apéndice presenta los fundamentos matemáticos de teoría de medida y transporte óptimo que sustentan la Geometría de la Causalidad Estadística (GCE) desarrollada en el libro principal. El objetivo es proporcionar una referencia autocontenida para lectores que deseen profundizar en los aspectos formales de las métricas utilizadas en los Niveles 2 y 3 de la jerarquía GCE.

La inferencia causal contemporánea, bajo el marco de resultados potenciales, reduce toda pregunta causal a un problema de comparación geométrica entre distribuciones contrafactuales $\mathbb{P}_{Y(1)}$ y $\mathbb{P}_{Y(0)}$. Este apéndice formaliza el espacio matemático donde esta comparación tiene lugar, estableciendo las propiedades de las métricas que permiten medir diferencias distribucionales de manera rigurosa.

32.12 Teoría de Medida: Fundamentos

Definición 32.1 (Espacio de Medida)

Un **espacio de medida** es una tripleta $(\Omega, \mathcal{F}, \mu)$ donde:

- Ω es un conjunto no vacío (espacio muestral)
- $\mathcal{F}$ es una σ -álgebra sobre Ω (conjunto de eventos medibles)
- $\mu : \mathcal{F} \rightarrow [0, \infty]$ es una medida (función que asigna tamaño“ a conjuntos)

La medida satisface:

1. $\mu(\emptyset) = 0$
2. σ -aditividad: Para cualquier colección numerable de conjuntos disjuntos $\{A_i\}_{i=1}^{\infty} \subseteq \mathcal{F}$,

$$\mu\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mu(A_i) \quad (32.12.1)$$

En inferencia causal, el espacio de medida más relevante es $(\mathcal{Y}, \mathcal{B}(\mathcal{Y}), \mathbb{P})$ donde $\mathcal{Y} \subseteq \mathbb{R}^d$ es el espacio de resultados, $\mathcal{B}(\mathcal{Y})$ es la σ -álgebra de Borel, y $\mathbb{P}$ es una medida de probabilidad que asigna masa a subconjuntos de resultados posibles.

Definición 32.2 (Medida de Probabilidad)

Una medida $\mathbb{P}$ sobre $(\Omega, \mathcal{F})$ es una **medida de probabilidad** si $\mathbb{P}(\Omega) = 1$. Para inferencia causal, trabajamos con:

- $\mathbb{P}_{Y(0)}$: Distribución del resultado potencial bajo control
- $\mathbb{P}_{Y(1)}$: Distribución del resultado potencial bajo tratamiento

Definición 32.3 (Distribución y Función de Distribución)

La **distribución** de una variable aleatoria $Y : \Omega \rightarrow \mathcal{Y}$ es la medida de probabilidad $\mathbb{P}_Y$ definida por $\mathbb{P}_{Y(B)} = \mathbb{P}(Y^{-1}(B))$ para $B \in \mathcal{B}(\mathcal{Y})$.

La **función de distribución acumulativa** (CDF) es $F_{Y(y)} = \mathbb{P}(Y \leq y)$. Para distribuciones continuas, existe una **función de densidad** f_Y tal que $\mathbb{P}_{Y(B)} = \int_B f_{Y(y)} \, d y$.

Definición 32.4 (Espacio $\mathcal{P}_{p(\mathcal{Y})}$)

Para $p \geq 1$, definimos el espacio de medidas de probabilidad con momento p -ésimo finito:

$$\mathcal{P}_{p(\mathcal{Y})} = \{\mathbb{P} \in \mathcal{P}(\mathcal{Y}) : \int_{\mathcal{Y}} |y|^p \, d\mathbb{P}(y) < \infty\} \quad (32.12.2)$$

donde $\mathcal{P}(\mathcal{Y})$ denota el conjunto de todas las medidas de probabilidad sobre $\mathcal{Y}$.

32.13 Métricas y Divergencias entre Distribuciones

Comparar distribuciones requiere métricas o divergencias que cuantifiquen su distancia'. En la jerarquía GCE, utilizamos tres familias principales.

32.13.1 Divergencias f (Nivel 2 de GCE)

Definición 32.5 (Divergencia f (Csiszár, 1967))

Sea $f : \mathbb{R}_+ \rightarrow \mathbb{R}$ convexa con $f(1) = 0$. Para medidas de probabilidad $\mathbb{P}, \mathbb{Q}$ con $\mathbb{P} \ll \mathbb{Q}$ ($\mathbb{P}$ absolutamente continua respecto a $\mathbb{Q}$), la divergencia f es:

$$D_{f(\mathbb{P} | \mathbb{Q})} = \int_{\mathcal{Y}} f\left(\frac{d\mathbb{P}}{d\mathbb{Q}}\right) d\mathbb{Q} \quad (32.13.1)$$

donde $\frac{d\mathbb{P}}{d\mathbb{Q}}$ es la derivada de Radon-Nikodym (densidad de $\mathbb{P}$ respecto a $\mathbb{Q}$).

Teorema 32.2 (Propiedades de Divergencias f)

1. **No-negatividad:** $D_{f(\mathbb{P} | \mathbb{Q})} \geq 0$ con igualdad si y solo si $\mathbb{P} = \mathbb{Q}$ casi seguramente.
2. **Convexidad:** $D_{f(\lambda\mathbb{P}_1 + (1-\lambda)\mathbb{P}_2 | \mathbb{Q})} \leq \lambda D_{f(\mathbb{P}_1 | \mathbb{Q})} + (1-\lambda) D_{f(\mathbb{P}_2 | \mathbb{Q})}$.
3. **Monotonía bajo transformaciones:** Para cualquier transformación medible T , $D_{f(\mathbb{P} \circ T^{-1} | \mathbb{Q} \circ T^{-1})} \leq D_{f(\mathbb{P} | \mathbb{Q})}$.

Ejemplo 32.1 (Divergencias Canónicas)

- **Kullback-Leibler:** $f(t) = t \log t$, $D_{\{\text{KL}\}}(\mathbb{P} | \mathbb{Q}) = \int \log\left(\frac{d\mathbb{P}}{d\mathbb{Q}}\right) d\mathbb{P}$
- **Variación Total:** $f(t) = \frac{1}{2}|t-1|$, $D_{\{\text{TV}\}}(\mathbb{P}, \mathbb{Q}) = \frac{1}{2} \int |d\mathbb{P} - d\mathbb{Q}|$
- **χ^2 -Divergencia:** $f(t) = (t-1)^2$, $D_{\chi^2}(\mathbb{P} | \mathbb{Q}) = \int \left(\frac{d\mathbb{P}}{d\mathbb{Q}} - 1\right)^2 d\mathbb{Q}$
- **Divergencia de Hellinger:** $f(t) = (\sqrt{t} - 1)^2$, $D_H^2(\mathbb{P}, \mathbb{Q}) = \frac{1}{2} \int (\sqrt{d\mathbb{P}} - \sqrt{d\mathbb{Q}})^2$

Teorema 32.3 (Limitaciones de Divergencias f)

Las divergencias f tienen dos limitaciones fundamentales para inferencia causal:

1. **Requieren continuidad absoluta:** $D_{f(\mathbb{P}|\mathbb{Q})}$ es infinita o indefinida cuando $\mathbb{P} \perp \mathbb{Q}$ (soportes disjuntos).
2. **No son métricas:** Generalmente no son simétricas ($D_{f(\mathbb{P}|\mathbb{Q})} \neq D_{f(\mathbb{Q}|\mathbb{P})}$) y no satisfacen la desigualdad triangular.

32.13.2 Métricas Integrales de Probabilidad**Definición 32.6 (Distancia de Lévy-Prokhorov)**

Para medidas de probabilidad $\mathbb{P}, \mathbb{Q}$ sobre un espacio métrico $(\mathcal{Y}, d)$, la distancia de Lévy-Prokhorov es:

$$\pi(\mathbb{P}, \mathbb{Q}) = \inf\{\varepsilon > 0 : \mathbb{P}(A) \leq \mathbb{Q}(A^{\text{epsilon}}) + \varepsilon \text{ para todo } A \in \mathcal{B}(\mathcal{Y})\} \quad (32.13.2)$$

donde $A^{\text{epsilon}} = \{y \in \mathcal{Y} : d(y, A) < \varepsilon\}$.

Teorema 32.4 (Propiedades de Lévy-Prokhorov)

1. π es una métrica en $\mathcal{P}(\mathcal{Y})$.
2. $\pi(\mathbb{P}_n, \mathbb{P}) \rightarrow 0$ si y solo si $\mathbb{P}_n$ converge débilmente a $\mathbb{P}$.
3. Para $\mathcal{Y} = \mathbb{R}$, $\pi(\mathbb{P}, \mathbb{Q}) \leq \sup_{y \in \mathbb{R}} |F_{\mathbb{P}}(y) - F_{\mathbb{Q}}(y)|$.

32.14 Teoría de Transporte Óptimo

El transporte óptimo, iniciado por Monge (1781) y formalizado por Kantorovich (1942), proporciona una teoría geométrica para comparar distribuciones que supera las limitaciones de las divergencias f .

32.14.1 Problema de Monge**Definición 32.7 (Problema de Monge)**

Dadas dos medidas de probabilidad $\mathbb{P}, \mathbb{Q}$ sobre $\mathcal{Y}$ y una función de costo $c : \mathcal{Y} \times \mathcal{Y} \rightarrow [0, \infty]$, encontrar un mapa transportador $T : \mathcal{Y} \rightarrow \mathcal{Y}$ que empuje $\mathbb{P}$ hacia $\mathbb{Q}$ ($T_{\text{hash}} \mathbb{P} = \mathbb{Q}$) minimizando el costo total:

$$\inf_{T: T_{\text{hash}} \mathbb{P} = \mathbb{Q}} \int_{\mathcal{Y}} c(y, T(y)) d\mathbb{P}(y) \quad (32.14.1)$$

donde $T_{\text{hash}} \mathbb{P}(B) = \mathbb{P}(T^{-1}(B))$ es la medida imagen.

El problema de Monge es altamente no lineal y puede no tener solución cuando $\mathbb{P}$ tiene masa atómica y $\mathbb{Q}$ es continua.

32.14.2 Problema de Kantorovich**Definición 32.8 (Acoplamiento)**

Un **acoplamiento** entre $\mathbb{P}$ y $\mathbb{Q}$ es una medida de probabilidad γ sobre $\mathcal{Y} \times \mathcal{Y}$ con marginales $\mathbb{P}$ y $\mathbb{Q}$:

$$\gamma(A \times \mathcal{Y}) = \mathbb{P}(A), \quad \gamma(\mathcal{Y} \times B) = \mathbb{Q}(B) \quad \forall A, B \in \mathcal{B}(\mathcal{Y}) \quad (32.14.2)$$

Denotamos $\Gamma(\mathbb{P}, \mathbb{Q})$ el conjunto de todos los acoplamientos.

Definición 32.9 (Problema de Kantorovich)

Para medidas $\mathbb{P}, \mathbb{Q} \in \mathcal{P}(\mathcal{Y})$ y función de costo $c : \mathcal{Y} \times \mathcal{Y} \rightarrow [0, \infty]$, encontrar:

$$\inf_{\gamma \in \Gamma(\mathbb{P}, \mathbb{Q})} \int_{\mathcal{Y} \times \mathcal{Y}} c(y, y') d\gamma(y, y') \quad (32.14.3)$$

Teorema 32.5 (Relación Monge-Kantorovich)

1. El problema de Kantorovich es una relajación convexa del problema de Monge.
2. Siempre existe solución al problema de Kantorovich (bajo condiciones de semicontinuidad inferior de c).
3. Cuando existe un mapa transportador óptimo T^* para el problema de Monge, entonces $\gamma^* = (\text{id} \times T^*)_{\text{hash}} \mathbb{P}$ es solución del problema de Kantorovich.

32.15 Distancias de Wasserstein

Definición 32.10 (Distancia de Wasserstein de orden p)

Para $p \geq 1$ y $\mathbb{P}, \mathbb{Q} \in \mathcal{P}_p(\mathcal{Y})$, la distancia de Wasserstein- p es:

$$W_{p(\mathbb{P}, \mathbb{Q})} = \left(\inf_{\gamma \in \Gamma(\mathbb{P}, \mathbb{Q})} \int_{\mathcal{Y} \times \mathcal{Y}} d(y, y')^p d\gamma(y, y') \right)^{\frac{1}{p}} \quad (32.15.1)$$

donde d es la métrica subyacente en $\mathcal{Y}$.

Teorema 32.6 (Propiedades de W_p)

1. **Métrica:** W_p es una métrica en $\mathcal{P}_p(\mathcal{Y})$ (satisface identidad, simetría, desigualdad triangular).
2. **Convergencia débil + momentos:** $W_{p(\mathbb{P}_n, \mathbb{P})} \rightarrow 0$ si y solo si $\mathbb{P}_n \rightarrow \mathbb{P}$ débilmente y $\int |y|^p d\mathbb{P}_n(y) \rightarrow \int |y|^p d\mathbb{P}(y)$.
3. **Monotonía:** Para $1 \leq p \leq q$, $W_{p(\mathbb{P}, \mathbb{Q})} \leq W_{q(\mathbb{P}, \mathbb{Q})}$.
4. **Desigualdad de transporte:** Para cualquier función f Lipschitz con constante L , $|\mathbb{E}_{\mathbb{P}}[f] - \mathbb{E}_{\mathbb{Q}}[f]| \leq L \cdot W_1(\mathbb{P}, \mathbb{Q})$.

Teorema 32.7 (Dualidad de Kantorovich-Rubinstein)

Para $p = 1$, la distancia de Wasserstein admite una representación dual:

$$W_1(\mathbb{P}, \mathbb{Q}) = \sup_{\{f \in \text{Lip}_1(\mathcal{Y})\}} \left(\int_{\mathcal{Y}} f d\mathbb{P} - \int_{\mathcal{Y}} f d\mathbb{Q} \right) \quad (32.15.2)$$

donde $\text{Lip}_1(\mathcal{Y}) = \{f : \mathcal{Y} \rightarrow \mathbb{R} : |f(y) - f(y')| \leq d(y, y') \text{ para todo } y, y' \in \mathcal{Y}\}$.

La distancia de Wasserstein-1 admite una representación dual como el supremo de la diferencia de expectativas sobre todas las funciones 1-Lipschitz. Esto conecta el transporte óptimo con la teoría de desigualdades de acoplamiento y proporciona una vía computacional: en lugar de resolver el problema primal de Kantorovich, se puede maximizar sobre funciones Lipschitz, lo que abre la puerta a métodos basados en redes neuronales (como las GANs con regularización Lipschitz). Esta dualidad es la base del Axioma 4a (estabilidad marginal): toda función f Lipschitz satisface $|\mathbb{E}_{\mathbb{P}}[f] - \mathbb{E}_{\mathbb{Q}}[f]| \leq \|f\|_{\{\text{Lip}\}} \cdot W_1(\mathbb{P}, \mathbb{Q})$.

32.15.1 Wasserstein-1 y Comparación con Divergencias f

Teorema 32.8 (Relación entre W_1 y Divergencias f)

Sean $\mathbb{P}, \mathbb{Q} \in \mathcal{P}_1(\mathcal{Y})$ con $\mathbb{P} \ll \mathbb{Q}$. Entonces:

1. $W_1(\mathbb{P}, \mathbb{Q}) \leq \text{diam}(\mathcal{Y}) \cdot D_{\{\text{TV}\}}(\mathbb{P}, \mathbb{Q})$
2. Si $\mathcal{Y} = \mathbb{R}$ y las densidades son Lipschitz, $W_1(\mathbb{P}, \mathbb{Q}) \leq C \cdot D_{\{\text{KL}\}}(\mathbb{P} \mid \mathbb{Q})^{\frac{1}{2}}$
3. En general, W_1 y D_f inducen topologías diferentes: W_1 induce la topología débil, mientras $D_{\{\text{KL}\}}$ induce una topología más fuerte.

Ejemplo 32.2 (Paradoja del Efecto Cero - Formalización)

Sean $\mathbb{P}_0 = \mathcal{N}(0, 1)$ y $\mathbb{P}_1 = \frac{1}{2}\mathcal{N}(-a, \sigma^2) + \frac{1}{2}\mathcal{N}(a, \sigma^2)$ con $a > 0$. Entonces:

$$\mathbb{E}_{\mathbb{P}_1}[Y] - \mathbb{E}_{\mathbb{P}_0}[Y] = 0, D_{\{\text{KL}\}}(\mathbb{P}_1 \mid \mathbb{P}_0) \leq a^2 + \sigma^2 - 1 - \log(\sigma^2) > 0, W_1(\mathbb{P}_1, \mathbb{P}_0) \geq a - \sqrt{\frac{2}{\pi}} > 0 \quad (32.15.3)$$

Demostración.

Paso 1 (ATE nulo): Por simetría de $\mathbb{P}_1$ en torno a 0,

$$\mathbb{E}_{\mathbb{P}_1}[Y] = \frac{1}{2}(-a) + \frac{1}{2}(a) = 0 = \mathbb{E}_{\mathbb{P}_0}[Y]. \quad (32.15.4)$$

Paso 2 (cota inferior de W_1): Aplicamos la formulación dual de Kantorovich-Rubinstein con la función de prueba 1-Lipschitz $f(y) = |y|$:

$$W_1(\mathbb{P}_1, \mathbb{P}_0) \geq \int |y| d\mathbb{P}_1(y) - \int |y| d\mathbb{P}_0(y). \quad (32.15.5)$$

Para $\mathbb{P}_0$: Si $Z \sim \mathcal{N}(0, 1)$, entonces

$$\int |y| d\mathbb{P}_0(y) = \mathbb{E}[|Z|] = \sqrt{\frac{2}{\pi}} \approx 0.798. \quad (32.15.6)$$

Para $\mathbb{P}_1$: La mezcla es simétrica, así que podemos escribir

$$\int |y| d\mathbb{P}_1(y) = \mathbb{E}[|a + \sigma Z|] \quad (32.15.7)$$

donde $Z \sim \mathcal{N}(0, 1)$ con probabilidad $\frac{1}{2}$ desplazado a $-a$ y con probabilidad $\frac{1}{2}$ desplazado a a . Por la desigualdad de Jensen aplicada a la función convexa $|\cdot|$:

$$\mathbb{E}[|a + \sigma Z|] \geq |\mathbb{E}[a + \sigma Z]| = |a| = a. \quad (32.15.8)$$

Por tanto,

$$W_1(\mathbb{P}_1, \mathbb{P}_0) \geq a - \sqrt{\frac{2}{\pi}}, \quad (32.15.9)$$

que es estrictamente positiva cuando $a > \sqrt{\frac{2}{\pi}} \approx 0.798$. $\square$

Paso 3 (cota de Jensen para $D_{\{\text{KL}\}}$): La divergencia KL no es lineal en mezclas. La fórmula presentada es la **cota superior de Jensen**:

$$D_{\{\text{KL}\}}(\mathbb{P}_1 \mid \mathbb{P}_0) \leq \frac{1}{2}D_{\{\text{KL}\}}(\mathcal{N}(-a, \sigma^2) \mid \mathbb{P}_0) + \frac{1}{2}D_{\{\text{KL}\}}(\mathcal{N}(a, \sigma^2) \mid \mathbb{P}_0). \quad (32.15.10)$$

Para cada componente gaussiana $\mathcal{N}(\pm a, \sigma^2)$ respecto a $\mathcal{N}(0, 1)$, tenemos

$$D_{\{\text{KL}\}}(\mathcal{N}(\pm a, \sigma^2) \mid \mathcal{N}(0, 1)) = \frac{1}{2} \left(\frac{(\pm a)^2}{1} + \frac{\sigma^2}{1} - 1 - \log(\sigma^2) \right). \quad (32.15.11)$$

Por simetría, ambos términos son iguales, y la cota resulta en

$$D_{\{\text{KL}\}}(\mathbb{P}_1 \mid \mathbb{P}_0) \leq a^2 + \sigma^2 - 1 - \log(\sigma^2). \quad (32.15.12)$$

El valor exacto requiere integración numérica de $\int p_1(y) \log\left(\frac{p_1(y)}{p_0(y)}\right) dy$.

Nota técnica: La cota de W_1 es independiente de σ , lo que muestra que el transporte detecta el desplazamiento de masa incluso cuando las componentes individuales tienen varianzas arbitrarias. La verificación numérica confirma: $(a, \sigma) = (2, 1)$: $W_1 \approx 1.224 \geq 1.202$; $(a, \sigma) = (1, 0.5)$: $W_1 \approx 0.248 \geq 0.202$; $(a, \sigma) = (0.9, 0.1)$: $W_1 \approx 0.429 \geq 0.102$; $(a, \sigma) = (1, 1)$: $W_1 \approx 0.366 \geq 0.202$.

El ATE (Nivel 1) reporta efecto nulo, mientras $D_{\{KL\}}$ (Nivel 2) y W_1 (Nivel 3) detectan cambios distribucionales sustanciales.

32.16 Transporte Óptimo Causal y Restricciones de Grafo

Para inferencia causal, necesitamos una noción de distancia que respete la estructura causal subyacente.

Definición 32.11 (Grafo Causal Dirigido Acíclico - DAG)

Un DAG $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ consiste en:

- $\mathcal{V}$: conjunto de vértices (variables)
- $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$: conjunto de aristas dirigidas sin ciclos

Para $v \in \mathcal{V}$, denotamos $\text{pa}(v)$ los padres de v en $\mathcal{G}$.

Definición 32.12 (Modelo Causal Estructural - SCM)

Un Modelo Causal Estructural sobre $\mathcal{G}$ es una colección de ecuaciones:

$$X_v = f_v(X_{\{\text{pa}(v)\}}, \varepsilon_v), \quad v \in \mathcal{V} \quad (32.16.1)$$

donde $\{\varepsilon_v\}$ son variables exógenas independientes.

Definición 32.13 (Acoplamiento Bicausal)

Sean $\mathbb{P}, \mathbb{Q}$ distribuciones sobre variables $\mathbf{X} = (X_1, \dots, X_d)$ compatibles con un DAG $\mathcal{G}$. Un acoplamiento $\gamma \in \Gamma(\mathbb{P}, \mathbb{Q})$ es **bicausal** si para cada $v \in \mathcal{V}$, condicional en los valores de las variables padre $\mathbf{X}_{\{\text{pa}(v)\}}$, las distribuciones marginales de X_v bajo $\mathbb{P}$ y $\mathbb{Q}$ se preservan.

Definición 32.14 (Distancia de Wasserstein Causal)

Para un DAG $\mathcal{G}$ y medidas $\mathbb{P}, \mathbb{Q} \in \mathcal{P}_1(\mathcal{V})$, la distancia de Wasserstein causal de orden 1 es:

$$W_1^{\mathcal{G}}(\mathbb{P}, \mathbb{Q}) = \inf_{\{\pi \in \Pi_{\mathcal{G}(\mathbb{P}, \mathbb{Q})}^{\text{bc}}\}} \int |\mathbf{x} - \mathbf{y}| d\pi(\mathbf{x}, \mathbf{y}) \quad (32.16.2)$$

donde $\Pi_{\mathcal{G}(\mathbb{P}, \mathbb{Q})}^{\text{bc}}$ es el conjunto de acoplamientos bicausales respecto a $\mathcal{G}$ (misma notación que en el Capítulo 1; equivalente a $\Gamma_{\mathcal{G}}^{\{\text{bc}\}}$ de la literatura de OT adaptado).

Teorema 32.9 (Propiedades de $W_1^{\mathcal{G}}$)

1. **Métrica:** $W_1^{\mathcal{G}}$ es una métrica en el espacio de medidas compatibles con $\mathcal{G}$.
2. **Cota inferior:** $W_1^{\mathcal{G}}(\mathbb{P}, \mathbb{Q}) \geq W_1(\mathbb{P}, \mathbb{Q})$ para todo $\mathbb{P}, \mathbb{Q}$.
3. **Continuidad Lipschitz causal:** Para cualquier funcional causal ψ identificable en $\mathcal{G}$, existe $C < \infty$ tal que $|\psi(\mathbb{P}) - \psi(\mathbb{Q})| \leq C \cdot W_1^{\mathcal{G}}(\mathbb{P}, \mathbb{Q})$.
4. **Invarianza bajo intervenciones** ⚠: Si $\text{do}(X_i = x_i)$ es una intervención en $\mathcal{G}$, entonces $W_1^{\mathcal{G}}(\mathbb{P}_{\{\text{do}(X_i = x_i)\}}, \mathbb{Q}_{\{\text{do}(X_i = x_i)\}}) \leq W_1^{\mathcal{G}}(\mathbb{P}, \mathbb{Q})$.

 **Nota de verificación:** La propiedad de invarianza bajo intervenciones (punto 4) está pendiente de cotejo formal contra Cheridito & Eckstein (2025). La literatura de distancias adaptadas establece resultados análogos para problemas de decisión secuencial, pero no se ha verificado contra la fuente primaria citada.

32.17 Axiomas de una Métrica Causal Ideal

La jerarquía GCE se fundamenta en cuatro axiomas que establecen las propiedades deseables de una medida de discrepancia causal $\mathcal{D}(\mathbb{P}, \mathbb{Q})$:

Definición 32.15 (Axiomas de una Métrica Causal)

Axioma 1 (Separación). $\mathcal{D}(\mathbb{P}, \mathbb{Q}) = 0 \Leftrightarrow \mathbb{P} = \mathbb{Q}$.

Axioma 2 (Interpretabilidad como costo de reasignación). $\mathcal{D}$ cuantifica, en unidades de la variable resultado, el trabajo mínimo para transformar $\mathbb{P}$ en $\mathbb{Q}$.

Axioma 3 (Robustez a soporte disjunto). $\mathcal{D}$ está bien definida y es finita (bajo momentos finitos) incluso cuando $\mathbb{P} \perp \mathbb{Q}$.

Axioma 4 (Estabilidad de funcionales causales). Este axioma se desdobra según la clase $\mathcal{T}$ de funcionales:

- **Axioma 4a (estabilidad marginal):** Para funcionales de las distribuciones marginales $\mathbb{P}_{Y(1)}, \mathbb{P}_{Y(0)}$ (medias, cuantiles, funcionales Lipschitz), existe $L < \infty$ tal que $|T(\mathbb{P}) - T(\mathbb{Q})| \leq L \cdot \mathcal{D}(\mathbb{P}, \mathbb{Q})$ para todo $T \in \mathcal{T}$.
- **Axioma 4b (estabilidad intervencional):** Para funcionales que dependen de distribuciones condicionales dadas los padres en $\mathcal{G}$ (efectos do, CATE, valores de políticas secuenciales), existe $L < \infty$ tal que $|T(\mathbb{P}) - T(\mathbb{Q})| \leq L \cdot \mathcal{D}(\mathbb{P}, \mathbb{Q})$ para todo $T \in \mathcal{T}$.

Teorema 32.10 (Comparación de Métricas frente a los Axiomas)

La siguiente tabla resume cómo las diferentes medidas de discrepancia satisfacen los axiomas:

Axioma	$\mathcal{D}_{\{\text{loc}\}} = \tau_{\{\text{ATE}\}} $ (Nivel 1)	D_f (Nivel 2)	W_1 (Nivel 3)	$W_1^{\mathcal{G}}$ (Nivel 3 causal)
1. Separación	× (Paradoja del Efecto Cero)	✓	✓	✓
2. Costo de reasignación	× en general (coincide solo bajo traslación pura)	× (no es métrica: asimétrica, sin desigualdad triangular, sin interpretación de costo)	✓ (es el costo óptimo por definición)	✓ (costo óptimo restringido; $W_1^{\mathcal{G}} \geq W_1$)
3. Soporte disjunto	✓ (siempre finita)	× ($D_f = \infty$ o indefinida si $\mathbb{P}$ no es abs. continua respecto de $\mathbb{Q}$)	✓ (finita en $\mathcal{P}_1$)	✓
4a. Estabilidad marginal	✓	× (KL y TV no son continuas bajo convergencia débil)	✓ (metriza convergencia débil en $\mathcal{P}_1$)	✓ (topología más fina que la de W_1)
4b. Estabilidad intervencional	×	×	×	✓ 

⚠ **Nota de verificación:** El Axioma 4b para $W_1^{\mathcal{G}}$ está pendiente de cotejo formal contra Cheridito & Eckstein (2025). La literatura de distancias adaptadas (Backhoff-Veraguas et al.) establece resultados análogos para problemas de decisión secuencial, pero no se ha verificado contra la fuente primaria citada.

32.18 Conexión con Inferencia Causal

Teorema 32.11 (Jerarquía GCE - Formalización)

La jerarquía GCE se formaliza como una cadena de **embeddings** de espacios (esquema con mapas explícitos):

$$(\mathbb{R}, |\cdot|) \hookrightarrow (\mathcal{P}(\mathcal{Y}), D_f) \hookrightarrow (\mathcal{P}_1(\mathcal{Y}), W_1) \hookrightarrow (\mathcal{P}_1^{\mathcal{G}}(\mathcal{Y}), W_1^{\mathcal{G}}) \quad (32.18.1)$$

donde los mapas de embedding se definen como sigue:

1. $\mathbb{R} \hookrightarrow \mathcal{P}(\mathcal{Y})$: $c \mapsto \delta_c$ (medida de Dirac en c). Bajo este mapa, $|c - c'|$ se recupera como $W_1(\delta_c, \delta_{c'})$ cuando $\mathcal{Y} = \mathbb{R}$ con la métrica usual. El Nivel 1 axiomático usa $\mathcal{D}_{\text{loc}} = |\tau_{\text{ATE}}|$, no τ_{ATE} con signo.
2. $\mathcal{P}(\mathcal{Y}) \hookrightarrow \mathcal{P}_1(\mathcal{Y})$: inclusión de medidas con primer momento finito (el dominio natural de W_1).
3. $\mathcal{P}_1(\mathcal{Y}) \hookrightarrow \mathcal{P}_1^{\mathcal{G}}(\mathcal{Y})$: mismo conjunto de medidas, equipado con la métrica más fina $W_1^{\mathcal{G}}$ (acoplamientos restringidos a Π_G^{bc}).

Interpretación por nivel:

- $(\mathbb{R}, |\cdot|)$ vía Dirac: localización unidimensional
- $(\mathcal{P}(\mathcal{Y}), D_f)$: Nivel 2 (Forma), divergencias f
- $(\mathcal{P}_1(\mathcal{Y}), W_1)$: Nivel 3 (Geometría), Wasserstein
- $(\mathcal{P}_1^{\mathcal{G}}(\mathcal{Y}), W_1^{\mathcal{G}})$: Nivel 3 causal

Nota: la flecha $D_f \hookrightarrow W_1$ es un **esquema** de refinamiento axiomático, no una isometría ni una dominancia métrica universal (véase prefacio: topologías no comparables en general).

Teorema 32.12 (Identificación Causal con Transporte Óptimo)

Bajo los supuestos de un SCM con grafo $\mathcal{G}$, el problema de identificación del ATE se puede formular como:

$$\tau_{\{\text{ATE}\}} = \mathbb{E}_{\mathbb{P}_{Y(1)}}[Y] - \mathbb{E}_{\mathbb{P}_{Y(0)}}[Y] = \int y d\mathbb{P}_{Y(1)}(y) - \int y d\mathbb{P}_{Y(0)}(y) \quad (32.18.2)$$

donde $\mathbb{P}_{Y(1)}$ y $\mathbb{P}_{Y(0)}$ son las distribuciones contrafactuales. Si $f(y) = y$ es Lipschitz (espacio acotado), entonces por la dualidad de Kantorovich-Rubinstein:

$$|\tau_{\{\text{ATE}\}}| \leq W_1(\mathbb{P}_{Y(1)}, \mathbb{P}_{Y(0)}) \leq W_1^{\mathcal{G}}(\mathbb{P}_{Y(1)}, \mathbb{P}_{Y(0)}) \quad (32.18.3)$$

Esto establece que $D_{\{\text{loc}\}} = |\tau_{\{\text{ATE}\}}|$ es siempre una cota inferior de la distancia de Wasserstein, no al revés.

Corolario 32.1 (Lectura geométrica del efecto causal)

1. El ATE es la proyección unidimensional de la distancia de Wasserstein completa.
2. W_1 proporciona una **cota superior** universal para $|\tau_{\{\text{ATE}\}}|$; equivalentemente, $|\tau_{\{\text{ATE}\}}|$ es una cota inferior de W_1 .
3. La Paradoja del Efecto Cero ocurre cuando $\tau_{\{\text{ATE}\}} \approx 0$ pero $W_1 \gg 0$.
4. $W_1^{\mathcal{G}}$ proporciona una cota más ajustada que incorpora conocimiento estructural.

Otras referencias clave de este apéndice: (Billingsley, 1999), (Villani, 2003), (Santambrogio, 2015),

(Peyré & Cuturi, 2019)⁶.

32.18 Referencias

- Billingsley, P. (1999). *Convergence of Probability Measures* (2.^a ed.). Wiley.
- Cheridito, P., & Eckstein, S. (2025). Optimal transport and Wasserstein distances for causal models. *Bernoulli*, 31(2), 1351-1376.
- Csiszár, I. (1967). Information-type measures of difference of probability distributions and indirect observation. *Studia Scientiarum Mathematicarum Hungarica*, 2, 299-318.
- Kantorovich, L. V. (1942). On the Translocation of Masses. *Doklady Akademii Nauk SSSR*, 37(7-8), 199-201.
- Monge, G. (1781). Mémoire sur la théorie des déblais et des remblais. *Histoire de l'Académie Royale des Sciences de Paris*.
- Peyré, G., & Cuturi, M. (2019). Computational Optimal Transport. *Foundations and Trends in Machine Learning*, 11(5-6), 355-607.
- Santambrogio, F. (2015). *Optimal Transport for Applied Mathematicians*. Birkhäuser.
- Villani, C. (2003). *Topics in Optimal Transportation*. American Mathematical Society.

⁶La cita de Cheridito & Eckstein (2025) en una versión previa de este apéndice decía “Causal Optimal Transport. Preprint.” — título y venue incorrectos/incompletos. La referencia correcta, ya usada consistentemente en el resto del libro y en el paper GCE, es Cheridito & Eckstein (2025).

32.18 Apéndice de Demostraciones

32.18.1 Capítulo 1: La Paradoja del Efecto Cero

Proposición A.1 (Invarianza del ATE ante Transformaciones Simétricas)

Si una transformación $\mathcal{T}$ de la distribución de resultados mantiene su media ($\mathbb{E}[\mathcal{T}(Y)] = \mathbb{E}[Y]$), entonces el efecto promedio τ_{ATE} es cero, aunque $\mathcal{T}$ altere profundamente la forma de la distribución.

Demostración.

Por definición: $\tau_{\text{ATE}} = \mathbb{E}_{\mathcal{T}(\mathbb{P}_0)}[Y] - \mathbb{E}_{\mathbb{P}_0}[Y] = \mu - \mu = 0$. La transformación puede alterar varianza, forma, multimodalidad o colas; si preserva el primer momento, el ATE registra efecto nulo.

□

Proposición A.2 (Paradoja del Efecto Cero - Versión Simplificada)

Sean $\mathbb{P}_0 = \mathcal{N}(0, 1)$ y $\mathbb{P}_1 = \frac{1}{2}\mathcal{N}(-a, \sigma^2) + \frac{1}{2}\mathcal{N}(a, \sigma^2)$ con $a > 0$. Entonces:

$$\mathbb{E}_{\mathbb{P}_1}[Y] - \mathbb{E}_{\mathbb{P}_0}[Y] = 0, \quad W_1(\mathbb{P}_1, \mathbb{P}_0) \geq a - \sqrt{\frac{2}{\pi}} > 0 \quad \text{para } a > \sqrt{\frac{2}{\pi}} \quad (32.18.1)$$

Demostración.

Paso 1 (ATE nulo): Por simetría de $\mathbb{P}_1$ en torno a 0, $\mathbb{E}_{\mathbb{P}_1}[Y] = 0 = \mathbb{E}_{\mathbb{P}_0}[Y]$.

Paso 2 (Cota inferior de W_1): La formulación dual de Kantorovich-Rubinstein con la función de prueba 1-Lipschitz

$f(y) = |y|$ da:

$$W_1(\mathbb{P}_1, \mathbb{P}_0) \geq \int |y| d\mathbb{P}_1(y) - \int |y| d\mathbb{P}_0(y) \quad (32.18.2)$$

Para $\mathbb{P}_0$:

$$\int |y| d\mathbb{P}_0(y) = \mathbb{E}[|Z|] = \sqrt{\frac{2}{\pi}} \quad \text{con } Z \sim \mathcal{N}(0, 1) \quad (32.18.3)$$

Para $\mathbb{P}_1$: Por la desigualdad de Jensen aplicada a la función convexa $|\cdot|$,

$$\int |y| d\mathbb{P}_1(y) = \mathbb{E}[|a + \sigma Z|] \geq |\mathbb{E}[a + \sigma Z]| = a \quad (32.18.4)$$

Por tanto:

$$W_1(\mathbb{P}_1, \mathbb{P}_0) \geq a - \sqrt{\frac{2}{\pi}} > 0 \quad \text{para } a > \sqrt{\frac{2}{\pi}}. \quad \blacksquare \quad (32.18.5)$$

Observación 32.1

Clave: Esta cota es *independiente de σ* — depende solo de la separación a entre las modas, no de la dispersión interna de cada componente. La demostración original contenía un error que introducía dependencia espuria de σ .

□

32.18.2 Capítulo 2: El Problema Fundamental

Teorema A.1 (Descomposición del Sesgo de Selección)

La diferencia de medias observacionales entre tratados y no tratados puede descomponerse como:

$$\mathbb{E}[Y | T = 1] - \mathbb{E}[Y | T = 0] = \tau_{ATE} + (\mathbb{E}[Y(0) | T = 1] - \mathbb{E}[Y(0) | T = 0]) + (\tau_{ATT} - \tau_{ATU}) \mathbb{P}(T = 0) \quad (32.18.6)$$

Demostración.

Expandimos la diferencia de medias observacionales utilizando la ecuación de consistencia:

$$\mathbb{E}[Y | T = 1] = \mathbb{E}[Y(1) | T = 1] \quad (32.18.7)$$

y

$$\mathbb{E}[Y | T = 0] = \mathbb{E}[Y(0) | T = 0] \quad (32.18.8)$$

Sumando y restando $\mathbb{E}[Y(0) | T = 1]$:

$$\mathbb{E}[Y | T = 1] - \mathbb{E}[Y | T = 0] = \underbrace{\mathbb{E}[Y(1) - Y(0) | T = 1]}_{\tau_{ATT}} + \underbrace{\mathbb{E}[Y(0) | T = 1] - \mathbb{E}[Y(0) | T = 0]}_{\text{Sesgo de Selección}} \quad (32.18.9)$$

Usando $\tau_{ATE} = \tau_{ATT} \cdot \mathbb{P}(T = 1) + \tau_{ATU} \cdot \mathbb{P}(T = 0)$:

$$\tau_{ATT} - \tau_{ATE} = (\tau_{ATT} - \tau_{ATU}) \cdot \mathbb{P}(T = 0) \quad (32.18.10)$$

Sustituyendo:

$$\mathbb{E}[Y | T = 1] - \mathbb{E}[Y | T = 0] = \tau_{ATE} + (\tau_{ATT} - \tau_{ATU}) \cdot \mathbb{P}(T = 0) + (\mathbb{E}[Y(0) | T = 1] - \mathbb{E}[Y(0) | T = 0]) \quad (32.18.11)$$

□

Teorema A.2 (Identificación del τ_{ATE} bajo Aleatorización)

Bajo independencia fuerte ($Y(0), Y(1) \perp\!\!\!\perp T$), el estimador de diferencia de medias observacionales es idénticamente igual al τ_{ATE} poblacional:

$$\mathbb{E}[Y | T = 1] - \mathbb{E}[Y | T = 0] = \tau_{ATE} \quad (32.18.12)$$

Demostración.

Debido a la independencia fuerte, tenemos que $Y(0) \perp\!\!\!\perp T$ y $Y(1) \perp\!\!\!\perp T$ marginalmente. Por consiguiente:

$$\mathbb{E}[Y | T = 1] = \mathbb{E}[Y(1) | T = 1] = \mathbb{E}[Y(1)] \mathbb{E}[Y | T = 0] = \mathbb{E}[Y(0) | T = 0] = \mathbb{E}[Y(0)]. \quad (32.18.13)$$

Restando ambas ecuaciones:

$$\mathbb{E}[Y | T = 1] - \mathbb{E}[Y | T = 0] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] = \tau_{ATE} \quad (32.18.14)$$

□

Proposición A.3 (Ceguera Distributional del RCT)

Sea un RCT con asignación aleatoria perfecta. El estimador $\hat{\tau}_{(ATE = \bar{Y}_1 - \bar{Y}_0)}$ converge en probabilidad a

$$\tau_{(ATE = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)])}. \text{ Sin embargo, } \hat{\tau}_{(ATE \rightarrow 0)} \text{ no implica } \mathbb{P}_{(Y(1) = \mathbb{P}_{Y(0)}}.$$

Demostración.

Por el Teorema de Identificación bajo Aleatorización, $\hat{\tau}_{ATE}$ es consistente para τ_{ATE} . Si $\tau_{ATE=0}$, entonces $\mathbb{E}[Y(1)] = \mathbb{E}[Y(0)]$. No obstante, las distribuciones pueden diferir en varianza, forma o multimodalidad. Considérese un escenario donde $Y(0) \sim \mathcal{N}(0, 1)$ y $Y(1)$ es una mezcla equiprobable de $\mathcal{N}(-\delta, \sigma^2)$ y $\mathcal{N}(\delta, \sigma^2)$ con $\delta > 0$ elegido tal que la media permanece en cero. El RCT detectará $\tau_{(ATE=0)}$, pero el tratamiento habrá aumentado la varianza y generado polarización.

□

32.18.3 Capítulo 3: El Arte del Matching

Teorema A.3 (Identificación del ATE bajo CIA)

Si se satisface el supuesto de Independencia Condicional y la condición de soporte común $0 < \mathbb{P}(T = 1 \mid X = x) < 1$ para todo $x \in \mathcal{X}$, entonces el ATE es identificable a partir de la distribución observacional de (Y, T, X) .

Demostración.

La demostración procede por condicionamiento iterado y sustitución bajo CIA:

$$\begin{aligned}
 \tau_{\text{ATE}} &= \mathbb{E}[Y(1) - Y(0)] \\
 &= \mathbb{E}_X[\mathbb{E}[Y(1) - Y(0) \mid X]] \quad (\text{Ley de esperanzas iteradas}) \\
 &= \mathbb{E}_X[\mathbb{E}[Y(1) \mid X] - \mathbb{E}[Y(0) \mid X]] \quad (\text{Linealidad}) \\
 &= \mathbb{E}_X[\mathbb{E}[Y(1) \mid T = 1, X] - \mathbb{E}[Y(0) \mid T = 0, X]] \quad (\text{CIA}) \\
 &= \mathbb{E}_X[\mathbb{E}[Y \mid T = 1, X] - \mathbb{E}[Y \mid T = 0, X]] \quad (\text{Consistencia}) \\
 &= \int_{\mathcal{X}} (\mathbb{E}[Y \mid T = 1, X = x] - \mathbb{E}[Y \mid T = 0, X = x]) d\mathbb{P}_{X(x)} \\
 &= \Phi(Y, T).
 \end{aligned} \tag{32.18.15}$$

La última expresión depende únicamente de cantidades observables Y e T : la distribución marginal de X y las regresiones condicionales $\mathbb{E}[Y \mid T, X]$. La condición de soporte común garantiza que ambos términos estén definidos para todo $x \in \mathcal{X}$. □

Proposición A.4 (Probabilidad de Matching Aproximado)

Sea $\mathcal{X} \subseteq \mathbb{R}^p$ compacto con medida de Lebesgue $\mu(\mathcal{X}) > 0$. Sean $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathbb{P}_X$ con densidad acotada inferiormente por $c > 0$. Para $x_0 \in \mathcal{X}$ y radio $\varepsilon > 0$, la probabilidad de que exista al menos un punto en la bola $B(x_0, \varepsilon)$ es:

$$\mathbb{P}(\exists j : |X_j - x_0| < \varepsilon) = 1 - \left(1 - \frac{V_{p(\varepsilon)} \cdot c}{\mu(\mathcal{X})}\right)^n \tag{32.18.16}$$

donde $V_{p(\varepsilon)} = \frac{\pi^{\frac{p}{2}}}{\Gamma(\frac{p}{2}+1)} \varepsilon^p$ es el volumen de la bola unitaria p -dimensional de radio ε .

Demostración.

La probabilidad de que un punto X_j caiga en $B(x_0, \varepsilon)$ es:

$$\mathbb{P}(X_j \in B(x_0, \varepsilon)) = \int_{B(x_0, \varepsilon)} d\mathbb{P}_{X(x)} \geq c \cdot V_{p(\varepsilon)} \tag{32.18.17}$$

Por independencia, la probabilidad de que ninguno de los n puntos caiga en la bola es:

$$\mathbb{P}(\forall j : |X_j - x_0| \geq \varepsilon) = (1 - \mathbb{P}(X_j \in B(x_0, \varepsilon)))^n \leq (1 - c \cdot V_{p(\varepsilon)})^n \tag{32.18.18}$$

Tomando el complemento y aproximando $\mathbb{P}_X$ por la densidad uniforme sobre $\mathcal{X}$ (normalización por $\mu(\mathcal{X})$) se obtiene el resultado. □

Teorema A.4 (Colapso Asintótico del Matching)

Para n fijo y ε fijo, la probabilidad de encontrar un match aproximado satisface:

$$\lim_{p \rightarrow \infty} \mathbb{P}(\exists j : |X_j - x_0| < \varepsilon) = 0 \quad (32.18.19)$$

Demostración.

El volumen de la bola p -dimensional tiene comportamiento asintótico:

$$V_{p(\varepsilon)} = \frac{\pi^{\frac{p}{2}}}{\Gamma(\frac{p}{2} + 1)} \varepsilon^p \sim \frac{1}{\sqrt{\pi p}} \left(\frac{2\pi e}{p} \right)^{\frac{p}{2}} \varepsilon^p \rightarrow 0 \quad \text{cuando } p \rightarrow \infty \quad (32.18.20)$$

Por la proposición anterior:

$$\mathbb{P}(\exists j : |X_j - x_0| < \varepsilon) = 1 - \left(1 - \frac{V_{p(\varepsilon)}}{\mu(\mathcal{X})} \right)^n \approx 1 - e^{-n \frac{V_{p(\varepsilon)}}{\mu(\mathcal{X})}} \rightarrow 0 \quad (32.18.21)$$

donde usamos $(1 - \frac{x}{n})^n \rightarrow e^{-x}$ y $V_{p(\varepsilon)} \rightarrow 0$ exponencialmente rápido en p .

□

Corolario A.1 (Explosión de Varianza del Estimador de Matching)

Sea $\hat{\tau}_{\text{match}}$ el estimador de matching con reemplazo que usa el vecino más cercano. Cuando $p \rightarrow \infty$ con n fijo:

$$\text{Var}[\hat{\tau}_{\text{match}}] \rightarrow \infty \quad (32.18.22)$$

Demostración.

Bajo continuidad Lipschitz de $\mu_0(x) = \mathbb{E}[Y(0) | X = x]$ con constante L , el sesgo del vecino más cercano satisface:

$$|\mathbb{E}[Y(0) | X_{N(i)}] - \mathbb{E}[Y(0) | X_i]| \leq L |X_{N(i)} - X_i|. \quad (32.18.23)$$

Por el Teorema de Colapso Asintótico, $|X_{N(i)} - X_i| \xrightarrow{p} \infty$ cuando $p \rightarrow \infty$ con n fijo (la bola de radio fijo casi seguramente no contiene observaciones). Luego el error cuadrático medio diverge:

$$\text{MSE}(\hat{\tau}_{\text{match}}) \geq L^2 \mathbb{E}[|X_{N(i)} - X_i|^2] \rightarrow \infty. \quad (32.18.24)$$

Para un análisis formal de la varianza asintótica en dimensión fija (y la necesidad de corrección de sesgo incluso en ese caso), ver Abadie & Imbens (2006).

□

Proposición A.5 (Invarianza a transformaciones lineares de escala)

Sea $D = \text{diag}(\alpha_1, \dots, \alpha_p)$ con $\alpha_k > 0$. Defina $X' = DX$. Entonces:

$$d_M(x'_i, x'_j) = d_M(x_i, x_j) \quad (32.18.25)$$

Demostración.

La matriz de covarianza transformada es $\Sigma' = D\Sigma D^{-1}$. Entonces:

$$d_M^2(x'_i, x'_j) = (Dx_i - Dx_j)^T p(D\Sigma D^{-1})^{-1} (Dx_i - Dx_j) = (x_i - x_j)^T pD^{-1} D^{-1} \Sigma^{-1} D^{-1} D (x_i - x_j) = (x_i - x_j)^T p\Sigma^{-1} (x_i - x_j) = d_M^2(x_i, x_j) \quad (32.18.26)$$

□

Teorema A.5 (Optimalidad de Mahalanobis para Matching)

Entre todas las métricas de la forma $d_{A(x_i, x_j)} = \sqrt{(x_i - x_j)^T p A (x_i - x_j)}$ con A definida positiva, la elección $A = \Sigma^{-1}$ minimiza la varianza asintótica del sesgo de matching debido a diferencias en X .

Bosquejo de demostración.

El sesgo de matching para la unidad i es aproximadamente $\nabla \mu_0(X_i)^T p (X_{N(i)} - X_i)$ donde $\mu_0(x) = \mathbb{E}[Y(0) | X = x]$. La varianza de este sesgo depende de $\mathbb{E}[(X_{N(i)} - X_i)(X_{N(i)} - X_i)^T p]$. Bajo la métrica d_A , el vecino más cercano minimiza $(x_i - x_j)^T p A (x_i - x_j)$. La matriz $A = \Sigma^{-1}$ “blanquea” el espacio, haciendo que todas las direcciones tengan varianza unitaria y que la distancia geométrica corresponda con la distancia estadística. $\square$

Teorema A.6 (Rosenbaum y Rubin, 1983)

Si $(Y(1), Y(0)) \perp\!\!\!\perp T | X$, entonces $(Y(1), Y(0)) \perp\!\!\!\perp T | e(X)$.

Demostración.

La demostración procede en cuatro pasos:

Paso 1: Por definición de $e(X)$:

$$\mathbb{P}(T = 1 | e(X)) = \mathbb{E}[T | e(X)] = \mathbb{E}[\mathbb{E}[T | X] | e(X)] = \mathbb{E}[e(X) | e(X)] = e(X) \quad (32.18.27)$$

Paso 2: Mostramos que $X \perp\!\!\!\perp T | e(X)$. Para cualquier conjunto medible $A \subseteq \mathcal{X}$:

$$\mathbb{P}(X \in A | T = 1, e(X) = e_0) = \frac{\mathbb{P}(X \in A, T = 1 | e(X) = e_0)}{\mathbb{P}(T = 1 | e(X) = e_0)} = \frac{\mathbb{E}[\mathbb{I}(X \in A) \cdot e(X) | e(X) = e_0]}{e_0} = \frac{e_0 \cdot \mathbb{P}(X \in A | e(X) = e_0)}{e_0} = \mathbb{P}(X \in A | e(X) = e_0) \quad (32.18.28)$$

Análogamente para $T = 0$. Por tanto $X \perp\!\!\!\perp T | e(X)$.

Paso 3 (Lema de independencia condicional): Si $A \perp\!\!\!\perp B | C$ y $A \perp\!\!\!\perp D | (B, C)$, entonces $A \perp\!\!\!\perp (B, D) | C$.

Paso 4 (Aplicación): Tomamos $A = (Y(1), Y(0))$, $B = X$, $C = e(X)$, $D = T$.

- $A \perp\!\!\!\perp B | C$: Dado $e(X)$, X no contiene información adicional sobre $(Y(1), Y(0))$ (esto requiere un argumento adicional de suficiencia).
- $A \perp\!\!\!\perp D | (B, C)$: Por CIA, $(Y(1), Y(0)) \perp\!\!\!\perp T | X$, y dado X , $e(X)$ es función medible de X . Por el lema, $(Y(1), Y(0)) \perp\!\!\!\perp (X, T) | e(X)$, lo cual implica $(Y(1), Y(0)) \perp\!\!\!\perp T | e(X)$. $\square$

Corolario A.2 (Identificación vía Propensity Score)

Bajo CIA y soporte común, el ATE se identifica como:

$$\tau_{\text{ATE}} = \mathbb{E}_{e(X)}[\mathbb{E}[Y | T = 1, e(X)] - \mathbb{E}[Y | T = 0, e(X)]] \quad (32.18.29)$$

Demostración.

Por el teorema de Rosenbaum-Rubin, CIA implica ignorabilidad condicional al propensity score. Aplicando el teorema de identificación del ATE con $e(X)$ en lugar de X :

$$\tau_{\text{ATE}} = \mathbb{E}[\mathbb{E}[Y(1) - Y(0) | e(X)]] = \mathbb{E}[\mathbb{E}[Y(1) | T = 1, e(X)] - \mathbb{E}[Y(0) | T = 0, e(X)]] = \mathbb{E}_{e(X)}[\mathbb{E}[Y | T = 1, e(X)] - \mathbb{E}[Y | T = 0, e(X)]] \quad (32.18.30)$$

$\square$

Teorema A.7 (Identificación IPW por Reponderación)

Bajo CIA y soporte común, se cumple:

$$\mathbb{E}[Y(1)] = \mathbb{E}\left[\frac{TY}{e(X)}\right] \quad \text{y} \quad \mathbb{E}[Y(0)] = \mathbb{E}\left[\frac{(1-T)Y}{1-e(X)}\right] \quad (32.18.31)$$

Bosquejo de consistencia.

Para el primer término:

$$\mathbb{E}\left[\frac{TY}{e(X)}\right] = \mathbb{E}_X\left[\frac{1}{e(X)}\mathbb{E}[TY \mid X]\right] = \mathbb{E}_X\left[\frac{1}{e(X)}\mathbb{E}[TY(1) \mid X]\right] \quad (\text{Consistencia}) = \mathbb{E}_X\left[\frac{1}{e(X)}\mathbb{E}[T \mid X]\mathbb{E}[Y(1) \mid X]\right] \quad (\text{CIA}) = \mathbb{E}_X\left[\frac{e(X)}{e(X)}\mathbb{E}[Y(1) \mid X]\right] = \mathbb{E}[Y(1)]$$

Análogamente, el segundo término da $\mathbb{E}[Y(0)]$. La diferencia es τ_{ATE} . □

32.18.4 Capítulo 4: IPW y Doble Robustez**Teorema A.8 (Identificación IPW)**

Bajo el supuesto de Independencia Condicional (CIA) y la condición de soporte común estricto $0 < e(X) < 1$ para todo $x \in \mathcal{X}$, los parámetros contrafactuales poblacionales están identificados por:

$$\mathbb{E}\left[\frac{TY}{e(X)}\right] = \mathbb{E}[Y(1)] \quad \text{y} \quad \mathbb{E}\left[\frac{(1-T)Y}{1-e(X)}\right] = \mathbb{E}[Y(0)] \quad (32.18.33)$$

Demostración.

La demostración procede por iteración de esperanzas y aplicación secuencial de consistencia y CIA:

$$\begin{aligned} \mathbb{E}\left[\frac{TY}{e(X)}\right] &= \mathbb{E}_X\left[\mathbb{E}\left[\frac{TY}{e(X)} \mid X\right]\right] \quad (\text{Ley de Esperanzas Iteradas}) \\ &= \mathbb{E}_X\left[\frac{1}{e(X)}\mathbb{E}[TY \mid X]\right] \quad (\text{Linealidad}) \\ &= \mathbb{E}_X\left[\frac{1}{e(X)}\mathbb{E}[TY(1) \mid X]\right] \quad (\text{Consistencia}) \\ &= \mathbb{E}_X\left[\frac{1}{e(X)}\mathbb{E}[T \mid X]\mathbb{E}[Y(1) \mid X]\right] \quad (\text{CIA}) \\ &= \mathbb{E}_X\left[\frac{e(X)}{e(X)}\mathbb{E}[Y(1) \mid X]\right] \\ &= \mathbb{E}_X[\mathbb{E}[Y(1) \mid X]] \\ &= \mathbb{E}[Y(1)] \quad (\text{Ley de Esperanzas Iteradas}) \end{aligned} \quad (32.18.34)$$

Análogamente se demuestra para el dominio de control evaluando $(1-T)\frac{Y}{1-e(X)}$ y $Y(0)$. □

Corolario A.3 (Identificación del ATE vía IPW)

Bajo CIA y soporte común, el ATE se identifica paramétricamente como:

$$\tau_{ATE} = \mathbb{E}\left[\frac{TY}{e(X)} - \frac{(1-T)Y}{1-e(X)}\right] \quad (32.18.35)$$

Demostración.

Restando las dos igualdades del Teorema de Identificación IPW:

$$\mathbb{E}\left[\frac{TY}{e(X)}\right] - \mathbb{E}\left[\frac{(1-T)Y}{1-e(X)}\right] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] = \tau_{\text{ATE}} \quad (32.18.36)$$

□

Proposición A.6 (Divergencia de Varianza de IPW)

Para la unidad i , definiendo el factor de expansión probabilística:

$$w_i = \frac{T_i}{e(X_i)} + \frac{1-T_i}{1-e(X_i)} \quad (32.18.37)$$

La varianza condicional $\mathbb{V}[w_i Y_i | X_i]$ diverge hacia infinito a medida que el propensity score viola la condición estricta de soporte común:

$$\lim_{e(X_i) \rightarrow 0^+} \mathbb{V}[w_i Y_i | X_i] = \lim_{e(X_i) \rightarrow 1^-} \mathbb{V}[w_i Y_i | X_i] = \infty \quad (32.18.38)$$

Demostración.

Condiciona en $X_i = x$ y asumiendo $T_i = 1$ (evento con probabilidad $e(X)$):

$$w_i Y_i = \frac{Y_{i(1)}}{e(X)} \quad (32.18.39)$$

La varianza condicional es:

$$\mathbb{V}[w_i Y_i | X_i = x] = \frac{\mathbb{V}[Y(1) | X = x]}{e(X)^2} = \frac{\sigma_1^2(x)}{e(X)^2} \quad (32.18.40)$$

De manera simétrica, condicional en $T_i = 0$:

$$\mathbb{V}[w_i Y_i | X_i = x] = \frac{\sigma_0^2(x)}{(1-e(X))^2} \quad (32.18.41)$$

Aplicando la ley de varianza total condicional:

$$\begin{aligned} \mathbb{V}[w_i Y_i | X_i = x] &= e(X) \cdot \frac{\sigma_1^2(x)}{e(X)^2} + (1-e(X)) \cdot \frac{\sigma_0^2(x)}{(1-e(X))^2} \\ &= \frac{\sigma_1^2(x)}{e(X)} + \frac{\sigma_0^2(x)}{1-e(X)} \end{aligned} \quad (32.18.42)$$

Es trivial observar que $\lim_{e(X) \rightarrow 0^+} \mathbb{V}[w_i Y_i | X_i] = \infty$ y $\lim_{e(X) \rightarrow 1^-} \mathbb{V}[w_i Y_i | X_i] = \infty$.

□

Teorema A.9 (Reducción Asintótica de Varianza)

Sean $\hat{\tau}_{\text{HT}}$ y $\hat{\tau}_{\text{SIPW}}$ los estimadores de Horvitz-Thompson y Estabilizado, respectivamente. Bajo condiciones estándar de regularidad, se cumple que:

$$\lim_{n \rightarrow \infty} n \cdot \mathbb{V}[\hat{\tau}_{\text{SIPW}}] \leq \lim_{n \rightarrow \infty} n \cdot \mathbb{V}[\hat{\tau}_{\text{HT}}] \quad (32.18.43)$$

La igualdad se alcanza de forma estricta si y solo si $\mathbb{P}(T = 1) = \mathbb{E}[e(X)]$ (es decir, en diseños experimentales no condicionales).

Bosquejo de demostración.

El estimador SIPW constituye un estadístico de ratio. Mediante el Teorema de Slutsky y el Método Delta, la expansión de Taylor de primer orden revela que la covarianza entre el numerador y el denominador induce una correlación negativa que amortigua el comportamiento errático de los pesos individuales aislados.

□

Corolario A.4 (Consistencia de IPW Estabilizado)

Si $\bar{e}(X) \xrightarrow{p} e(X)$ uniformemente y se respeta el umbral de positividad estricto $0 < \delta \leq e(X) \leq 1 - \delta < 1$ c.s., entonces:

$$\hat{\tau}_{\text{SIPW}} \xrightarrow{p} \tau_{\text{ATE}} \quad (32.18.44)$$
Demostración.

Por la Ley Débil de los Grandes Números para procesos empíricos, los denominadores convergen en probabilidad a 1:

$$\frac{1}{n} \sum_{i=1}^n \frac{T_i}{\hat{e}(X_i)} \xrightarrow{p} \mathbb{E} \left[\frac{T}{e(X)} \right] = \mathbb{E}_X \left[\frac{\mathbb{E}[T|X]}{e(X)} \right] = \mathbb{E}_X \left[\frac{e(X)}{e(X)} \right] = 1 \quad (32.18.45)$$

Los numeradores convergen a $\mathbb{E}[Y(1)]$ y $\mathbb{E}[Y(0)]$ respectivamente. Aplicando el Teorema de Slutsky, el estadístico converge al diferencial de medias contrafactuales, el ATE.

□

Teorema A.10 (Propiedad de Doble Robustez Analítica)

El estimador $\hat{\tau}_{\text{AIPW}}$ es un estimador uniformemente consistente de τ_{ATE} si se cumple al menos una de las siguientes condiciones de límite estocástico débil:

1. $\bar{e}(X) \xrightarrow{p} e(X)$ (modelo del mecanismo de asignación consistente y no sesgado).
2. $\hat{\mu}_{t(X)} \xrightarrow{p} \mu_{t(X)}$ para $t = 0, 1$ (modelo del outcome condicional consistente).

Demostración.

Se demuestra separadamente la convergencia asintótica para ambas especificaciones.

Parte A: Propensity score parametrizado correctamente ($\hat{e}(X) \xrightarrow{p} e(X)$). El sumando de augmentación para los tratados:

$$\frac{1}{n} \sum_{i=1}^n \frac{T_i}{\hat{e}(X_i)} (Y_i - \hat{\mu}_1(X_i)) \quad (32.18.46)$$

Sea que $\hat{\mu}_1(X)$ converja a un pseudo-límite parametrizado erróneo $\mu_1^*(X)$. Evaluando la esperanza iterada en X :

$$\begin{aligned} \mathbb{E} \left[\frac{T}{\hat{e}(X)} (Y(1) - \mu_1^*(X)) \right] &= \mathbb{E}_X \left[\frac{\mathbb{E}[T|X]}{\hat{e}(X)} \mathbb{E}[Y(1) - \mu_1^*(X) | X] \right] \\ &\xrightarrow{p} \mathbb{E}_X \left[\frac{e(X)}{e(X)} \mathbb{E}[Y(1) - \mu_1^*(X) | X] \right] \\ &= \mathbb{E}_X [\mathbb{E}[Y(1) - \mu_1^*(X) | X]] \\ &= \mathbb{E}[Y(1) - \mu_1^*(X)] \end{aligned} \quad (32.18.47)$$

El estimador AIPW se escribe como:

$$\hat{\tau}_{\text{AIPW}} = \mathbb{E}[Y(1)] - \mathbb{E}[\mu_1^*(X)] + \mathbb{E}[\mu_1^*(X)] - \mathbb{E}[Y(0)] + \text{términos de corrección análogos} \rightarrow \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] = \tau_{\text{ATE}} \quad (32.18.48)$$

Parte B: Outcome model parametrizado correctamente ($\hat{\mu}_t(X) \xrightarrow{p} \mu_t(X)$). Sea un score $e^*(X)$ que limite a un parámetro fallido $e^*(X) \neq e(X)$. Evaluando:

$$\begin{aligned} \hat{\tau}_{\text{AIPW}} &\xrightarrow{p} \mathbb{E}[\mu_1(X) - \mu_0(X)] \\ &+ \mathbb{E} \left[\frac{T}{e^*(X)} (Y(1) - \mu_1(X)) \right] - \mathbb{E} \left[\frac{1-T}{1-e^*(X)} (Y(0) - \mu_0(X)) \right] \end{aligned} \quad (32.18.49)$$

El término cruzado:

$$\mathbb{E} \left[\frac{T}{e^*(X)} (Y(1) - \mu_1(X)) \right] = \mathbb{E}_X \left[\frac{\mathbb{E}[T|X]}{e^*(X)} \mathbb{E}[Y(1) - \mu_1(X) | X] \right] = \mathbb{E}_X \left[\frac{e(X)}{e^*(X)} (\mathbb{E}[Y(1) | X] - \mu_1(X)) \right] = 0 \quad (32.18.50)$$

Por lo tanto, la métrica entera colapsa a $\mathbb{E}[\mu_1(X) - \mu_0(X)] = \mathbb{E}[Y(1) - Y(0)] = \tau_{\text{ATE}}$, asumiendo $Y(t) \perp\!\!\!\perp T \mid X$. $\square$

Proposición A.7 (Descomposición Métrica Estructural del Estimador AIPW)

Definiendo los tres componentes:

$$\begin{aligned} \hat{\mu}_t &= \frac{1}{n} \sum_{i=1}^n \hat{\mu}_{t(X_i)} \quad (t = 0, 1), \\ \hat{\tau}_{\text{IPW}} &= \frac{1}{n} \sum_{i=1}^n \left(\frac{T_i Y_i}{\hat{e}(X_i)} - \frac{(1-T_i) Y_i}{1-\hat{e}(X_i)} \right), \\ \hat{\tau}_{\text{augment}} &= \frac{1}{n} \sum_{i=1}^n \left(\frac{T_i \hat{\mu}_1(X_i)}{\hat{e}(X_i)} - \frac{(1-T_i) \hat{\mu}_0(X_i)}{1-\hat{e}(X_i)} \right), \end{aligned} \quad (32.18.51)$$

el estimador AIPW admite la descomposición algebraica exacta:

$$\hat{\tau}_{\text{AIPW}} = (\hat{\mu}_1 - \hat{\mu}_0) + \hat{\tau}_{\text{IPW}} - \hat{\tau}_{\text{augment}} \quad (32.18.52)$$

Demostración.

El estimador AIPW es por definición:

$$\hat{\tau}_{\text{AIPW}} = \frac{1}{n} \sum_i \left[\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + \frac{T_i(Y_i - \hat{\mu}_1(X_i))}{\hat{e}(X_i)} - \frac{(1 - T_i)(Y_i - \hat{\mu}_0(X_i))}{1 - \hat{e}(X_i)} \right]. \quad (32.18.53)$$

Expandiendo los términos de corrección:

$$\frac{T_i(Y_i - \hat{\mu}_1(X_i))}{\hat{e}(X_i)} = \frac{T_i Y_i}{\hat{e}(X_i)} - \frac{T_i \hat{\mu}_1(X_i)}{\hat{e}(X_i)}, \quad (32.18.54)$$

y análogamente para el control. Reagrupando:

$$\begin{aligned} \hat{\tau}_{\text{AIPW}} &= \underbrace{(\hat{\mu}_1 - \hat{\mu}_0)}_{\text{T-Learner}} \\ &\quad + \underbrace{\frac{1}{n} \sum_i \left(\frac{T_i Y_i}{\hat{e}(X_i)} - \frac{(1 - T_i) Y_i}{1 - \hat{e}(X_i)} \right)}_{\hat{\tau}_{\text{IPW}}} \\ &\quad - \underbrace{\frac{1}{n} \sum_i \left(\frac{T_i \hat{\mu}_1(X_i)}{\hat{e}(X_i)} - \frac{(1 - T_i) \hat{\mu}_0(X_i)}{1 - \hat{e}(X_i)} \right)}_{\hat{\tau}_{\text{augment}}}. \end{aligned} \quad (32.18.55)$$

□

32.18.5 Capítulo 5: Variables Instrumentales**Proposición A.8 (Sesgo del Estimador OLS)**

El estimador de Mínimos Cuadrados Ordinarios de β_1 en muestras finitas satisface la identidad:

$$\hat{\beta}_{1,OLS} = \beta_1 + \left(\sum_{i=1}^n (T_i - \bar{T}) \right) \frac{(U_i - \bar{U})}{\sum_{i=1}^n (T_i - \bar{T})^2} \quad (32.18.56)$$

Demostración.

Sustituyendo el modelo estructural generador en la forma cerrada de OLS:

$$= \left(\sum_{i=1}^n (T_i - \bar{T}) \right) \frac{(\beta_0 + \beta_1 T_i + U_i - \beta_0 - \beta_1 \bar{T} - \bar{U})}{\sum_{i=1}^n (T_i - \bar{T})^2} \setminus = \left(\sum_{i=1}^n (T_i - \bar{T}) \right) \frac{(\beta_1 (T_i - \bar{T}) + (U_i - \bar{U}))}{\sum_{i=1}^n (T_i - \bar{T})^2} \setminus = \beta_1 \frac{\sum_{i=1}^n (T_i - \bar{T})^2}{\sum_{i=1}^n (T_i - \bar{T})^2} + \left(\sum_{i=1}^n (T_i - \bar{T}) \right) \frac{(U_i - \bar{U})}{\sum_{i=1}^n (T_i - \bar{T})^2} \quad (32.18.57)$$

□

Teorema A.11 (Inconsistencia Asintótica del OLS bajo Endogeneidad)

Bajo endogeneidad, el estimador OLS es asintóticamente inconsistente:

$$\hat{\beta}_{1,OLS} \xrightarrow{p} \beta_1 + \text{Cov} \frac{T, U}{\text{Var}(T) \neq \beta_1}. \quad (32.18.58)$$

Demostración.

Aplicando la Ley Fuerte de los Grandes Números al estimador expandido:

$$\text{plim } \hat{\beta}_{1,OLS} = \beta_1 + \text{plim} \left[\left(\frac{1}{n} \sum_{i=1}^n (T_i - \bar{T}) \frac{(U_i - \bar{U})}{\frac{1}{n} \sum_{i=1}^n (T_i - \bar{T})^2} \right) \right] = \beta_1 + \left(\text{plim} \frac{\left[\frac{1}{n} \sum_{i=1}^n (T_i - \bar{T})(U_i - \bar{U}) \right]}{\text{plim} \left[\frac{1}{n} \sum_{i=1}^n (T_i - \bar{T})^2 \right]} \right) = \beta_1 + \frac{\text{Cov}(T, U)}{\text{Var}(T)}, \quad (32.18.59)$$

en que plim denota el límite en probabilidad. Dada la condición estructural de endogeneidad $\text{Cov}(T, U) \neq 0$, se genera un sesgo asintótico de magnitud exacta $(\text{Cov} \frac{T, U}{\text{Var}(T)})$.

□

Teorema A.12 (No-Testabilidad de la Exogeneidad)

El axioma de relevancia $\text{Cov}(Z, T) \neq 0$ es estrictamente testable en el dominio de los datos observados. Por el contrario, el axioma de exogeneidad $\text{Cov}(Z, U) = 0$ es intrínseca y estructuralmente incontrastable, puesto que el vector de error U pertenece al espacio no observable.

Demostración.

1. *Testabilidad de Relevancia.* El escalar π_1 en el sub-modelo $T = \pi_0 + \pi_1 Z + v$ es estimable consistentemente vía OLS bajo $\mathbb{E}[v | Z] = 0$. El estadístico $t = \frac{\hat{\pi}_1}{\text{se}(\hat{\pi}_1)}$ o el estadístico F de la primera etapa permiten rechazar empíricamente $H_0 : \pi_1 = 0$.
2. *Incontrastabilidad Estructural.* La covarianza $\text{Cov}(Z, U) = \mathbb{E}[ZU] - \mathbb{E}[Z]\mathbb{E}[U]$ requiere observar directamente $U = Y - \beta_0 - \beta_1 T$. Como β_0, β_1 son desconocidos (OLS es sesgado bajo endogeneidad), U es latente e incalculable. Cualquier intento de testear exogeneidad con residuos proyectados $\hat{U}$ colapsa en circularidad lógica: los residuos se extraen asumiendo a priori la consistencia del estimador, que a su vez exige la exogeneidad de Z .

□

Proposición A.9 (Derivación Paramétrica del Estimador IV)

Bajo exogeneidad fuerte $\text{Cov}(Z, U) = 0$, el parámetro causal estructural β_1 queda unívocamente identificado por el ratio:

$$\beta_1 = \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, T)} \quad (32.18.60)$$

Demostración.

Evaluando el operador de covarianza con respecto a Z sobre la ecuación estructural:

$$\text{Cov}(Z, Y) = \text{Cov}(Z, \beta_0 + \beta_1 T + U) = \beta_1 \text{Cov}(Z, T) + \text{Cov}(Z, U) \quad (32.18.61)$$

Bajo la condición $\text{Cov}(Z, U) = 0$, se deduce:

$$\beta_1 = \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, T)} \quad (32.18.62)$$

□

Teorema A.13 (Distribución Asintótica y el Peligro de los Instrumentos Débiles)

Asumiendo condiciones de regularidad analítica (momentos finitos estacionarios y observaciones i.i.d.), el estimador converge en distribución normal:

$$\sqrt{n}(\hat{\beta}_{IV} - \beta_1) \xrightarrow{d} \mathcal{N}\left(0, \frac{\sigma_U^2}{\text{Var}(Z) \cdot \text{Corr}(Z, T)^2}\right), \quad (32.18.63)$$

donde $\sigma_U^2 = \text{Var}(U)$.

Bosquejo.

Escribimos $\hat{\beta}_{IV} - \beta_1 = \frac{n^{-1} \sum_i Z_i U_i}{n^{-1} \sum_i Z_i T_i}$. Por el TCL, $n^{-\frac{1}{2}} \sum_i Z_{(iU)_i} \xrightarrow{d} \mathcal{N}(0, \text{Var}(ZU))$. Por la LGN, el denominador converge en probabilidad a $\text{Cov}(Z, T) = \sigma_Z \sigma_T \text{Corr}(Z, T)$. El Teorema Delta da la varianza asintótica como $\frac{\sigma_U^2}{[\text{Var}(Z) \cdot \text{Corr}(Z, T)^2]}$. Cuando $\text{Corr}(Z, T) \rightarrow 0$ (instrumento débil), la varianza explota y el test de Wald pierde validez en muestras finitas.

□

32.18.6 Capítulo 6: LATE y Taxonomía de Respondientes**Teorema A.14 (No-Identificación del ATE bajo Heterogeneidad)**

Bajo heterogeneidad del efecto, el estimador IV no identifica el ATE poblacional:

$$\text{plim } \hat{\beta}_{IV} \neq \mathbb{E}[\beta_{1i}] = \tau_{i, \text{ATE}} \quad (32.18.64)$$

Contraejemplo.

Considere una población con dos grupos de igual tamaño ($\mathbb{P}(H) = \mathbb{P}(L) = 0.5$):

- Grupo H: $\tau_H = 2$ (efecto alto), son Compliers ($T_{i(0)} = 0, T_{i(1)} = 1$)
- Grupo L: $\tau_L = 0$ (sin efecto), son Never-Takers ($T_{i(0)} = T_{i(1)} = 0$)

El ATE verdadero pondera ambos grupos: $\tau_{\text{ATE}} = 0.5 \cdot 2 + 0.5 \cdot 0 = 1$.

El instrumento Z solo mueve el comportamiento de H (los únicos Compliers). Por tanto $\mathbb{P}(\text{Complier}) = \mathbb{P}(H) = 0.5$, con $\tau_{\text{LATE}} = \mathbb{E}[\tau_i \mid \text{Complier}] = \tau_H = 2$. Usando la fórmula de Wald:

$$\begin{aligned} \mathbb{E}[Y \mid Z = 1] - \mathbb{E}[Y \mid Z = 0] &= \tau_H \cdot \mathbb{P}(H) = 2 \cdot 0.5 = 1 \quad \text{ITT} \\ \mathbb{E}[T \mid Z = 1] - \mathbb{E}[T \mid Z = 0] &= 1 \cdot \mathbb{P}(H) = 0.5 \quad \text{compliance rate} \end{aligned} \quad (32.18.65)$$

Por tanto $\hat{\beta}_{IV} \rightarrow \frac{\text{ITT}}{\mathbb{P}}(C) = \frac{1}{0.5} = 2 = \tau_{\text{LATE}} \neq 1 = \tau_{\text{ATE}}$. El IV identifica el efecto solo en los Compliers, no en la población total.

□

Teorema A.15 (Eliminación de Defiers bajo Monotonicidad)

Bajo monotonicidad, $\mathbb{P}(D_i = 1) = 0$. La partición se reduce a tres tipos:

$$C_i + A_i + N_i = 1 \quad (32.18.66)$$

Demostración.

Por contradicción: suponga que existe i con $D_i = 1$. Entonces $T_{i(1)} = 0$ y $T_{i(0)} = 1$, implicando $T_{i(1)} < T_{i(0)}$, que viola monotonicidad $T_{i(1)} \geq T_{i(0)}$. Por tanto, si monotonicidad vale para todo i , no puede existir ningún Defier.

La partición original $C_i + A_i + N_i + D_i = 1$ con $\mathbb{P}(D) = 0$ implica $C_i + A_i + N_i = 1$ casi seguramente.

□

Teorema A.16 (Identificación Poblacional del LATE)

Bajo los cuatro supuestos del LATE, el parámetro IV poblacional satisface:

$$\beta_{IV}^{\text{pop}} := \frac{\text{Cov}(Z, Y)}{\text{Cov}(Z, T)} = \mathbb{E}[Y(1) - Y(0) \mid C = 1] = \tau_{\text{LATE}} \quad (32.18.67)$$

Demostración.

La demostración procede en seis pasos, descomponiendo por tipos y aplicando los supuestos.

Paso 1: Descomposición del numerador por tipos

Por independencia, la distribución de tipos es idéntica en $Z = 0$ y $Z = 1$. Descomponemos $\mathbb{E}[Y|Z = 1]$:

$$\begin{aligned}\mathbb{E}[Y|Z = 1] &= \mathbb{E}[Y|Z = 1, C]\mathbb{P}(C) + \mathbb{E}[Y|Z = 1, A]\mathbb{P}(A) + \mathbb{E}[Y|Z = 1, N]\mathbb{P}(N) \\ &= \mathbb{E}[Y(1)|C]\mathbb{P}(C) + \mathbb{E}[Y(1)|A]\mathbb{P}(A) + \mathbb{E}[Y(0)|N]\mathbb{P}(N)\end{aligned}\quad (32.18.68)$$

donde usamos que bajo $Z = 1$: los Compliers toman $T = 1$, los Always-Takers toman $T = 1$, los Never-Takers toman $T = 0$.

Paso 2: Aplicación de exclusión e independencia

Por exclusión, $Y_{i(z,t)} = Y_{i(t)}$, entonces $\mathbb{E}[Y|T = 1, A] = \mathbb{E}[Y(1)|A]$ y análogamente para otros tipos. Por independencia, $\mathbb{E}[Y(t)|\text{tipo}, Z = 1] = \mathbb{E}[Y(t)|\text{tipo}]$.

Paso 3: Descomposición de $\mathbb{E}[Y|Z = 0]$

Análogamente:

$$\begin{aligned}\mathbb{E}[Y|Z = 0] &= \mathbb{E}[Y|Z = 0, C]\mathbb{P}(C) + \mathbb{E}[Y|Z = 0, A]\mathbb{P}(A) + \mathbb{E}[Y|Z = 0, N]\mathbb{P}(N) \\ &= \mathbb{E}[Y(0)|C]\mathbb{P}(C) + \mathbb{E}[Y(1)|A]\mathbb{P}(A) + \mathbb{E}[Y(0)|N]\mathbb{P}(N)\end{aligned}\quad (32.18.69)$$

Bajo $Z = 0$: Compliers toman $T = 0$, Always-Takers toman $T = 1$, Never-Takers toman $T = 0$.

Paso 4: Diferencia del numerador

Restando:

$$\mathbb{E}[Y|Z = 1] - \mathbb{E}[Y|Z = 0] = (\mathbb{E}[Y(1)|C] - \mathbb{E}[Y(0)|C])\mathbb{P}(C) = \mathbb{E}[Y(1) - Y(0)|C] \cdot \mathbb{P}(C) \quad (32.18.70)$$

Los términos de Always-Takers y Never-Takers cancelan exactamente porque su tratamiento no depende de Z .

Paso 5: Cálculo del denominador

Para el denominador del IV:

$$\begin{aligned}\mathbb{E}[T|Z = 1] &= 1 \cdot \mathbb{P}(C) + 1 \cdot \mathbb{P}(A) + 0 \cdot \mathbb{P}(N) = \mathbb{P}(C) + \mathbb{P}(A) \\ \mathbb{E}[T|Z = 0] &= 0 \cdot \mathbb{P}(C) + 1 \cdot \mathbb{P}(A) + 0 \cdot \mathbb{P}(N) = \mathbb{P}(A)\end{aligned}\quad (32.18.71)$$

Por tanto:

$$\mathbb{E}[T|Z = 1] - \mathbb{E}[T|Z = 0] = \mathbb{P}(C) \quad (32.18.72)$$

Paso 6: División y cancelación

Dividiendo el numerador por el denominador:

$$\beta_{IV} = \frac{\mathbb{E}[Y(1) - Y(0)|C] \cdot \mathbb{P}(C)}{\mathbb{P}(C)} = \mathbb{E}[Y(1) - Y(0)|C] \quad (32.18.73)$$

La proporción de Compliers cancela, dejando el efecto causal promedio condicional a ser Complier.

□

Proposición A.10 (Identificación de la Proporción de Compliers)

La proporción de Compliers en la población es identificable directamente de los datos:

$$\mathbb{P}(C) = \mathbb{E}[T|Z = 1] - \mathbb{E}[T|Z = 0] \quad (32.18.74)$$

Demostración.

Del Paso 5 de la demostración del teorema LATE, el denominador del estimador IV es exactamente $\mathbb{P}(C)$. Este es estimable consistentemente por la diferencia de medias de tratamiento entre grupos instrumentalizados.

□

Teorema A.17 (Condición de Equivalencia LATE=ATE)

El LATE coincide con el ATE poblacional si y solo si el efecto causal es constante:

$$\text{LATE} = \tau_{\text{ATE}} \Leftrightarrow \beta_{1i} = \beta_1 \quad \forall i \quad (32.18.75)$$

Demostración.

Suficiencia: Si $\beta_{1i} = \beta_1$ constante, entonces $\mathbb{E}[Y(1) - Y(0)|C] = \beta_1 = \mathbb{E}[Y(1) - Y(0)] = \tau_{ATE}$.

Necesidad: Si $LATE = \tau_{ATE}$, entonces $\mathbb{E}[\beta_{1i}|C] = \mathbb{E}[\beta_{1i}]$. Esto requiere que β_{1i} sea independiente del tipo, es decir, constante. Si existiera heterogeneidad correlacionada con la propensión a ser Complier, el LATE sería una media ponderada diferente del ATE.

□

Proposición A.11 (LATE $\neq$ ATT en General)

En general, el LATE difiere del efecto en los tratados:

$$\mathbb{E}[Y(1) - Y(0)|C] \neq \mathbb{E}[Y(1) - Y(0)|T = 1] \quad (32.18.76)$$

Demostración.

La población tratada $T = 1$ cuando $Z = 1$ consiste de Compliers y Always-Takers:

$$\mathbb{E}[Y(1) - Y(0)|T = 1, Z = 1] = \frac{\mathbb{E}[\beta_{1i}|C]\mathbb{P}(C) + \mathbb{E}[\beta_{1i}|A]\mathbb{P}(A)}{\mathbb{P}(C) + \mathbb{P}(A)} \quad (32.18.77)$$

El LATE es $\mathbb{E}[\beta_{1i}|C]$. La igualdad requiere $\mathbb{E}[\beta_{1i}|C] = \mathbb{E}[\beta_{1i}|A]$, que no vale en general. Los Always-Takers pueden tener efectos diferentes (mayores o menores) que los Compliers.

□

Teorema A.18 (No-Identificabilidad de Always-Takers y Never-Takers)

Las proporciones individuales de Always-Takers y Never-Takers no son separadamente identificables. Solo se identifica su suma:

$$\mathbb{P}(A) + \mathbb{P}(N) = 1 - \mathbb{P}(C) \quad (32.18.78)$$

Demostración.

De las ecuaciones de primera etapa:

$$\begin{aligned} \mathbb{E}[T|Z = 1] &= \mathbb{P}(C) + \mathbb{P}(A) \\ \mathbb{E}[T|Z = 0] &= \mathbb{P}(A) \end{aligned} \quad (32.18.79)$$

Con dos ecuaciones y tres incógnitas ($\mathbb{P}(C), \mathbb{P}(A), \mathbb{P}(N)$), el sistema está subidentificado. Solo $\mathbb{P}(C) = \mathbb{E}[T|Z = 1] - \mathbb{E}[T|Z = 0]$ es identificable. Las restricciones adicionales (por ejemplo, conocimiento de $\mathbb{E}[T]$ en la población) podrían identificar $\mathbb{P}(A)$ y $\mathbb{P}(N)$ por separado.

□

Proposición A.12 (Relación Estructural LATE-ITT)

Bajo los supuestos del LATE, el ITT y el LATE se vinculan mediante la proporción de Compliers:

$$\tau_{ITT} = \tau_{LATE} \cdot \mathbb{P}(C) \quad (32.18.80)$$

y por tanto el estimador de Wald no es más que el ITT reescalado:

$$\tau_{LATE} = \frac{\tau_{ITT}}{\mathbb{P}(C)} = \frac{\mathbb{E}[Y | Z = 1] - \mathbb{E}[Y | Z = 0]}{\mathbb{E}[T | Z = 1] - \mathbb{E}[T | Z = 0]} \quad (32.18.81)$$

Demostración.

Descomponemos $\tau_{ITT} = \mathbb{E}[Y | Z = 1] - \mathbb{E}[Y | Z = 0]$ por la ley de expectativas totales, condicionando en la cuadrupartición de tipos (bajo monotonicidad, $\mathbb{P}(D) = 0$):

$$\tau_{ITT} = \sum_{s \in \{C, A, N\}} \mathbb{P}(s) (\mathbb{E}[Y | Z = 1, s] - \mathbb{E}[Y | Z = 0, s]) \quad (32.18.82)$$

Por la independencia del instrumento $Z \perp\!\!\!\perp (Y(0), Y(1), T(0), T(1))$ y la definición de cada tipo:

- **Compliers:** $T(1) = 1, T(0) = 0$, luego $\mathbb{E}[Y|Z = 1, C] - \mathbb{E}[Y|Z = 0, C] = \mathbb{E}[Y(1)|C] - \mathbb{E}[Y(0)|C] = \tau_{LATE}$.
- **Always-Takers:** $T(0) = T(1) = 1$, luego $\mathbb{E}[Y|Z = 1, A] - \mathbb{E}[Y|Z = 0, A] = \mathbb{E}[Y(1)|A] - \mathbb{E}[Y(1)|A] = 0$.
- **Never-Takers:** $T(0) = T(1) = 0$, luego $\mathbb{E}[Y|Z = 1, N] - \mathbb{E}[Y|Z = 0, N] = \mathbb{E}[Y(0)|N] - \mathbb{E}[Y(0)|N] = 0$.

Sustituyendo:

$$\tau_{ITT} = \mathbb{P}(C) \cdot \tau_{LATE} + \mathbb{P}(A) \cdot 0 + \mathbb{P}(N) \cdot 0 = \tau_{LATE} \cdot \mathbb{P}(C). \quad (32.18.83)$$

Análogamente, $\mathbb{E}[T | Z = 1] - \mathbb{E}[T | Z = 0] = \mathbb{P}(C)$ (solo los Compliers cambian su estado de tratamiento). Dividiendo:

$$\tau_{LATE} = \frac{\tau_{ITT}}{\mathbb{P}(C)} = \frac{\mathbb{E}[Y | Z = 1] - \mathbb{E}[Y | Z = 0]}{\mathbb{E}[T | Z = 1] - \mathbb{E}[T | Z = 0]} \quad (32.18.84)$$

□

32.18.7 Capítulo 7: Regression Discontinuity Design

Teorema A.19 (Identificación en Sharp RDD)

Bajo el supuesto de continuidad, el efecto causal en el umbral es identificable:

$$\tau_{(SRD)} = \mathbb{E}[Y(1) - Y(0) | X=c] = \lim_{x \downarrow c} \mathbb{E}[Y|X=x] - \lim_{x \uparrow c} \mathbb{E}[Y|X=x] \quad (32.18.85)$$

Demostración.

La demostración procede por manipulación de esperanzas condicionales y aplicación del supuesto de continuidad.

Paso 1: Descomposición de la esperanza observada por consistencia:

$$\mathbb{E}[Y|X = x] = \mathbb{E}[Y(0)|X = x] + \mathbb{I}\{x \geq c\} \cdot \mathbb{E}[Y(1) - Y(0)|X = x] \quad (32.18.86)$$

Paso 2: Para $x < c$, el indicador es cero:

$$\mathbb{E}[Y|X = x] = \mathbb{E}[Y(0)|X = x] \quad \forall x < c \quad (32.18.87)$$

Paso 3: Para $x \geq c$, el indicador es uno:

$$\mathbb{E}[Y|X = x] = \mathbb{E}[Y(1)|X = x] \quad \forall x \geq c \quad (32.18.88)$$

Paso 4: Tomando límites laterales y aplicando continuidad:

$$\lim_{x \uparrow c} \mathbb{E}[Y|X = x] = \lim_{x \uparrow c} \mathbb{E}[Y(0)|X = x] = \mathbb{E}[Y(0)|X = c] \quad \lim_{x \downarrow c} \mathbb{E}[Y|X = x] = \lim_{x \downarrow c} \mathbb{E}[Y(1)|X = x] = \mathbb{E}[Y(1)|X = c] \quad (32.18.89)$$

Paso 5: Restando los límites:

$$\tau_{(SRD)} = \mathbb{E}[Y(1)|X=c] - \mathbb{E}[Y(0)|X=c] = \lim_{x \downarrow c} \mathbb{E}[Y|X=x] - \lim_{x \uparrow c} \mathbb{E}[Y|X=x] \quad (32.18.90)$$

□

Proposición A.13 (Trade-off Sesgo-Varianza)

El error cuadrático medio condicional del estimador satisface:

$$\text{Sesgo}[\hat{\tau}_{SRD}|X] = O(h^{p+1}) \setminus \text{Varianza}[\hat{\tau}_{SRD}|X] = O\left(\frac{1}{Nh}\right) \setminus \text{MSE} = O(h^{2(p+1)}) + O\left(\frac{1}{Nh}\right) \quad (32.18.91)$$

Bosquejo.

El sesgo emerge de la aproximación de Taylor truncada: el residuo de orden $p + 1$ es $O(h^{p+1})$ localmente. La varianza proviene de la inversa de la matriz de diseño ponderada: aproximadamente $\frac{\sigma^2}{Nh \cdot f_{X(c)} \int K^2(u) du}$ donde $f_{X(c)}$ es la densidad de X en el umbral.

□

Teorema A.20 (Identificación en Fuzzy RDD)

Bajo los supuestos de Relevancia ($\pi_+ \neq \pi_-$), Exclusión (Z afecta Y solo a través de T), Continuidad de $\mathbb{E}[Y(t)|X = x]$, y Monotonicidad ($T_{i(1)} \geq T_{i(0)}$):

$$\tau_{\text{(FRD)}} = \frac{\mu_+ - \mu_-}{\pi_+ - \pi_-} = \mathbb{E}[Y(1) - Y(0) | X=c, \text{Complier}] \quad (32.18.92)$$

Demostración.

La demostración conecta Fuzzy RDD con el marco LATE del Capítulo 6 mediante taxonomía de tipos en la vecindad del umbral.

Paso 1: Definir tipos latentes según respuesta a Z en vecindad de c :

- Compliers: $T_{i(0)} = 0, T_{i(1)} = 1$ (cambian en el umbral)
- Always-Takers: $T_{i(0)} = 1, T_{i(1)} = 1$ (siempre tratados)
- Never-Takers: $T_{i(0)} = 0, T_{i(1)} = 0$ (nunca tratados)

Paso 2: Por Monotonicidad, no existen Defiers ($T_{i(1)} < T_{i(0)}$).

Paso 3: El denominador es la proporción de Compliers:

$$\pi_+ - \pi_- = \mathbb{P}(T = 1 | Z = 1, X = c) - \mathbb{P}(T = 1 | Z = 0, X = c) = \mathbb{P}(C | X = c) + \mathbb{P}(A | X = c) - \mathbb{P}(A | X = c) = \mathbb{P}(C | X = c) \quad (32.18.93)$$

Paso 4: El numerador es el efecto de Z en Y :

$$\mu_+ - \mu_- = \mathbb{E}[Y | Z = 1, X = c] - \mathbb{E}[Y | Z = 0, X = c] = \mathbb{E}[Y(1) - Y(0) | C, X = c] \cdot \mathbb{P}(C | X = c) \quad (32.18.94)$$

por descomposición análoga al teorema LATE.

Paso 5: Dividiendo:

$$\tau_{\text{(FRD)}} = \frac{\mathbb{E}[Y(1) - Y(0) | C, X = c] \cdot \mathbb{P}(C | X = c)}{\mathbb{P}(C | X = c)} = \mathbb{E}[Y(1) - Y(0) | X = c, \text{Complier}] \quad (32.18.95)$$

□

Proposición A.14 (Equivalencia Algebraica con IV)

El estimador Fuzzy RDD es algebraicamente idéntico al estimador de Wald con instrumento $Z_i = \mathbb{I}\{X_i \geq c\}$:

$$\hat{\tau}_{\text{(FRD)}} = \frac{\hat{\mu}_+ - \hat{\mu}_-}{\hat{\pi}_+ - \hat{\pi}_-} = \frac{\widehat{\text{Cov}}(Z, Y)}{\widehat{\text{Cov}}(Z, T) = \hat{\beta}_{\text{(IV)}}} \quad (32.18.96)$$

Demostración.

Para $Z_i \in \{0, 1\}$ binario, la covarianza muestral satisface exactamente:

$$\widehat{\text{Cov}}(Z, Y) = \frac{1}{N} \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y}) = \bar{Z}(1 - \bar{Z})(\bar{Y}_1 - \bar{Y}_0) = \bar{Z}(1 - \bar{Z})(\hat{\mu}_+ - \hat{\mu}_-) \quad (32.18.97)$$

y análogamente $\widehat{\text{Cov}}(Z, T) = \bar{Z}(1 - \bar{Z})(\hat{\pi}_+ - \hat{\pi}_-)$. El factor $\bar{Z}(1 - \bar{Z})$ se cancela exactamente en el cociente, sin necesidad de ninguna aproximación:

$$\hat{\beta}_{\text{(IV)}} = \frac{\widehat{\text{Cov}}(Z, Y)}{\widehat{\text{Cov}}(Z, T)} = \frac{\bar{Z}(1 - \bar{Z})(\hat{\mu}_+ - \hat{\mu}_-)}{\bar{Z}(1 - \bar{Z})(\hat{\pi}_+ - \hat{\pi}_-)} = \frac{\hat{\mu}_+ - \hat{\mu}_-}{\hat{\pi}_+ - \hat{\pi}_-} = \hat{\tau}_{\text{(FRD)}} \quad (32.18.98)$$

□

32.18.8 Capítulo 8: Difference-in-Differences

Teorema A.21 (Identificación del ATT en DiD 2x2)

Bajo el supuesto de tendencias paralelas, el estimador DiD identifica el efecto del tratamiento sobre los tratados:

$$\tau_{\text{DiD}} = (\mathbb{E}[Y_{i1} | G_i = 1] - \mathbb{E}[Y_{i0} | G_i = 1]) - (\mathbb{E}[Y_{i1} | G_i = 0] - \mathbb{E}[Y_{i0} | G_i = 0]) = \mathbb{E}[Y_{i1}(1) - Y_{i0}(0) | G_i = 1] \quad (32.18.99)$$

Demostración.

La demostración procede por descomposición de las diferencias y aplicación de consistencia y PTA.

Paso 1: Definir el cambio observado en el grupo tratado:

$$\Delta_1 = \mathbb{E}[Y_{i1} | G_i = 1] - \mathbb{E}[Y_{i0} | G_i = 1] \quad (32.18.100)$$

Paso 2: Sustituir resultados observados por potenciales:

$$\Delta_1 = \mathbb{E}[Y_{i1}(1) | G_i = 1] - \mathbb{E}[Y_{i0}(0) | G_i = 1] \quad (32.18.101)$$

donde usamos que en $t = 1$, $D_{i1} = 1$ para $G_i = 1$, y en $t = 0$, $D_{i0} = 0$ para todo i .

Paso 3: Definir el cambio observado en el grupo control:

$$\Delta_0 = \mathbb{E}[Y_{i1} | G_i = 0] - \mathbb{E}[Y_{i0} | G_i = 0] \quad (32.18.102)$$

Paso 4: Sustituir por potenciales (grupo control nunca recibe tratamiento):

$$\Delta_0 = \mathbb{E}[Y_{i1}(0) | G_i = 0] - \mathbb{E}[Y_{i0}(0) | G_i = 0] \quad (32.18.103)$$

Paso 5: Aplicar PTA:

$$\mathbb{E}[Y_{i1}(0) - Y_{i0}(0) | G_i = 1] = \mathbb{E}[Y_{i1}(0) - Y_{i0}(0) | G_i = 0] = \Delta_0 \quad (32.18.104)$$

Paso 6: Reescribir Δ_1 usando PTA:

$$\Delta_1 = \mathbb{E}[Y_{i1}(1) - Y_{i1}(0) | G_i = 1] + \mathbb{E}[Y_{i1}(0) - Y_{i0}(0) | G_i = 1] \quad (32.18.105)$$

$$= \tau_{\text{ATT}} + \Delta_0 \quad (32.18.106)$$

Paso 7: Despejar el ATT:

$$\tau_{\text{DiD}} = \Delta_1 - \Delta_0 = \mathbb{E}[Y_{i1}(1) - Y_{i1}(0) | G_i = 1] = \tau_{\text{ATT}} \quad (32.18.107)$$

□

Teorema A.22 (Equivalencia Algebraica DiD-TWFE)

En el diseño canónico 2x2, el estimador OLS de τ en el modelo TWFE es algebraicamente idéntico al estimador DiD:

$$\hat{\tau}_{\text{OLS}} = \hat{\tau}_{\text{DiD}} \quad (32.18.108)$$

Demostración.

El estimador OLS within resuelve:

$$\hat{\tau}_{OLS} = \frac{\sum_{i=1}^N \sum_{t=0}^1 (D_{it} - \bar{D}_i - \bar{D}_t + \bar{D})(Y_{it} - \bar{Y}_i - \bar{Y}_t + \bar{Y})}{\sum_{i=1}^N \sum_{t=0}^1 (D_{it} - \bar{D}_i - \bar{D}_t + \bar{D})^2} \quad (32.18.109)$$

Para el diseño 2x2:

- Grupo tratado ($G_i = 1$): $\bar{D}_i = 0.5$, $\bar{Y}_i = \frac{Y_{i0} + Y_{i1}}{2}$
- Grupo control ($G_i = 0$): $\bar{D}_i = 0$, $\bar{Y}_i = \frac{Y_{i0} + Y_{i1}}{2}$
- Periodo 0: $\bar{D}_0 = 0$, $\bar{Y}_0 = \frac{1}{N} \sum_i Y_{i0}$
- Periodo 1: $\bar{D}_1 = \frac{N_1}{N}$, $\bar{Y}_1 = \frac{1}{N} \sum_i Y_{i1}$

Evaluando el numerador para unidad tratada en $t = 1$ ($D_{i1} = 1$):

$$D_{i1} - \bar{D}_i - \bar{D}_1 + \bar{D} = 1 - 0.5 - \frac{N_1}{N} + \frac{N_1}{N} \cdot \frac{1}{2} = 0.5 - \frac{N_1}{2N} = \frac{N_0}{2N} \quad (32.18.110)$$

Para unidad tratada en $t = 0$ ($D_{i0} = 0$):

$$0 - 0.5 - 0 + \frac{N_1}{2N} = -\frac{N_0}{2N} \quad (32.18.111)$$

Para unidades control, las desviaciones son $-\frac{N_1}{2N}$ en $t = 1$ y $\frac{N_1}{2N}$ en $t = 0$. Simplificando, el numerador converge a:

$$\frac{N_0 N_1}{N^2} [(\bar{Y}_{11} - \bar{Y}_{10} - (\bar{Y}_{01} - \bar{Y}_{00}))] \quad (32.18.112)$$

El denominador es $\frac{N_0 N_1}{N^2}$. Por tanto $\hat{\tau}_{OLS} = (\bar{Y}_{11} - \bar{Y}_{10} - (\bar{Y}_{01} - \bar{Y}_{00})) = \hat{\tau}_{DiD}$.

□

Proposición A.15 (Sesgo por Controles Ya Tratados)

Las comparaciones que usan unidades ya tratadas como controles introducen sesgo cuando existen efectos dinámicos. Formalmente, si $ATT(g, t)$ depende del tiempo transcurrido desde la adopción $e = t - g$:

$$\mathbb{E}[Y_{it}(0) \mid G_i = g', t \geq g'] \neq \mathbb{E}[Y_{it}(0) \mid G_i = g', t < g'] \quad (32.18.113)$$

El grupo “control” ya tratado no proporciona un contrafactual válido para el grupo tratado más reciente.

Demostración.

Para cohorte g tratada en periodo $t \geq g$, el outcome potencial sin tratamiento es $Y_{it}(0)$. Para cohorte $g' < g$ (tratada más temprano) en periodo $t \geq g > g'$, el outcome observado es $Y_{it} = Y_{it}(1)$ con efecto acumulado $ATT(g', t) \neq 0$.

Si usamos g' como control para g en periodo t , la diferencia es:

$$\mathbb{E}[Y_{it} \mid G_i = g] - \mathbb{E}[Y_{it} \mid G_i = g'] = ATT(g, t) - ATT(g', t) + tendencia \quad (32.18.114)$$

El término $-ATT(g', t)$ contamina la estimación. Bajo PTA, la tendencia común se cancela, pero el efecto dinámico del control ya tratado permanece como sesgo.

□

Teorema A.23 (Condición de Inesgadez de TWFE)

El estimador TWFE es inesgado para el ATT promedio si y solo si el efecto del tratamiento es constante en el tiempo y homogéneo entre cohortes:

$$ATT(g, t) = \tau \quad \forall g \in \mathcal{G}, t \geq g \quad (32.18.115)$$

Demostración.

Suficiencia: Si $ATT(g, t) = \tau$ constante para todo g, t , la doble diferencia entre la cohorte g (tratada) y g' (ya tratada) en la ventana (t_{pre}, t_{post}) es:

$$\begin{aligned} & [\mathbb{E}(Y|G = g, t_{post}) - \mathbb{E}(Y|G = g, t_{pre})] \\ & - [\mathbb{E}(Y|G = g', t_{post}) - \mathbb{E}(Y|G = g', t_{pre})] \\ & = (\tau + \Delta_g) - (\tau + \Delta_{g'}) = \Delta_g - \Delta_{g'} \end{aligned} \quad (32.18.116)$$

donde Δ_s es la tendencia temporal del grupo s . Bajo PTA, $\Delta_g = \Delta_{g'}$, así que la doble diferencia devuelve 0; los errores de usar grupos ya tratados como controles se cancelan exactamente cuando el efecto es homogéneo. Sumando sobre todos los pares ponderados por w_k , el TWFE converge a τ .

Necesidad: Si $ATT(g, t)$ varía entre cohortes, las ponderaciones $w_k \in \mathbb{R}$ de Goodman-Bacon pueden ser negativas para comparaciones donde el grupo ya tratado g' tiene $ATT(g', t) > 0$. El TWFE promedia efectos con signos opuestos, produciendo sesgo de ponderación que no desaparece con $n \rightarrow \infty$.

□

Proposición A.16 (Equivalencia Bajo Efecto Constante)

Bajo el supuesto de efecto constante $ATT(g, t) = \tau$ para todo $g, t \geq g$:

$$\hat{\tau}_{(TWFE = \hat{\tau}_{Callaway-Sant'Anna} = \hat{\tau}_{Sun-Abraham} = \tau)} \quad (32.18.117)$$

Todos los estimadores son consistentes para el mismo parámetro.

Demostración.

Cuando $ATT(g, t) = \tau$, el sesgo por usar controles ya tratados desaparece porque $ATT(g', t) = \tau = ATT(g, t)$. Las comparaciones 2x2 con controles ya tratados estiman $\tau - \tau + \tau = \tau$ (el efecto del control se cancela con el efecto del tratado en la diferencia).

Callaway-Sant'Anna usa controles válidos que también estiman τ . Sun-Abraham con restricción de efecto constante colapsa a $\delta_{g,e} = \tau$ para todo $g, e \geq 0$, y la agregación ponderada reproduce τ .

□

32.18.9 Capítulo 9: Control Sintético**Proposición A.17 (Propiedad de Convexidad)**

El predictor del control sintético satisface:

$$\hat{X}_1 = X_0 w^* \in \text{Conv}(\{X_2, \dots, X_{J+1}\}) \quad (32.18.118)$$

donde $\text{Conv}(\cdot)$ denota la envolvente convexa de las columnas de X_0 . Esto contrasta con OLS sin restricciones, que puede producir $\hat{X}_1$ fuera de la envolvente convexa (extrapolación).

Demostración.

Por construcción, $w^* \in \mathcal{W}$ implica $w_j^* \geq 0$ y $\sum_j w_j^* = 1$. Por definición de combinación convexa:

$$X_0 w^* = \sum_{j=2}^{J+1} w_j^* X_j \quad (32.18.119)$$

es un punto en la envolvente convexa de los vectores de predictores donantes. La restricción de no-negatividad en $\mathcal{W}$ es esencial; OLS sin restricciones permite $w_j < 0$ o $\sum_j w_j \neq 1$, generando extrapolación potencialmente fuera del rango de datos observados.

□

Teorema A.24 (Cota del Error de Estimación)

Bajo el modelo de factores latentes, el error del estimador SynC satisface:

$$|\hat{\tau}_{1t} - \tau_{1t}| \leq |\lambda_t| \cdot |\Delta_\mu| + \left| \sum_{j=2}^{J+1} w_j^* \varepsilon_{jt} - \varepsilon_{1t} \right| \quad (32.18.120)$$

donde $\Delta_\mu = \mu_1 - \sum_{j=2}^{J+1} w_j^* \mu_j$ es el error de aproximación en las cargas factoriales.

Demostración.

Del modelo factor-interactivo:

$$\begin{aligned} Y_{1t}(0) &= \delta_t + \theta_t^\top p Z_1 + \lambda_t^\top p \mu_1 + \varepsilon_{1t} \\ \hat{Y}_{1t}(0) &= \sum_j w_j^* Y_{jt}(0) = \delta_t + \theta_t^\top p \left(\sum_j w_j^* Z_j \right) + \lambda_t^\top p \left(\sum_j w_j^* \mu_j \right) + \sum_j w_j^* \varepsilon_{jt} \end{aligned} \quad (32.18.121)$$

El error de estimación es:

$$\begin{aligned} \hat{\tau}_{1t} - \tau_{1t} &= \hat{Y}_{1t}(0) - Y_{1t}(0) \\ &= \theta_t^\top p \left(\sum_j w_j^* Z_j - Z_1 \right) + \lambda_t^\top p \left(\sum_j w_j^* \mu_j - \mu_1 \right) + \left(\sum_j w_j^* \varepsilon_{jt} - \varepsilon_{1t} \right) \end{aligned} \quad (32.18.122)$$

Si el ajuste en covariables es perfecto ($\sum_j w_j^* Z_j = Z_1$), el primer término desaparece. El segundo término satisface por Cauchy-Schwarz:

$$|\lambda_t^\top p \Delta_\mu| \leq |\lambda_t| \cdot |\Delta_\mu| \quad (32.18.123)$$

El tercer término es el error de agregación idiosincrático.

□

Teorema A.25 (Teorema de Sesgo de Abadie-Diamond-Hainmueller (2010))

Si existe $w^* \in \mathcal{W}$ tal que:

1. $\sum_{j=2}^{J+1} w_j^* \mu_j = \mu_1$ (match perfecto en factores latentes no observados), y
2. $\sum_{j=2}^{J+1} w_j^* Y_{jt}(0) = Y_{1t}(0)$ para todo $t \leq T_0$ (match exacto en el período pre-tratamiento), entonces el sesgo del estimador SynC en el período post-tratamiento satisface:

$$|\mathbb{E}[\hat{\tau}_{1t} - \tau_{1t}]| = O\left(T_0^{-\frac{1}{2}}\right) \quad (32.18.124)$$

Bosquejo.

Bajo las condiciones (i)-(ii), $\Delta_\mu = \mu_1 - \sum_j w_j^* \mu_j = 0$ y el error de estimación se reduce al error idiosincrático:

$$\hat{\tau}_{1t} - \tau_{1t} = \sum_{j=2}^{J+1} w_j^* \varepsilon_{jt} - \varepsilon_{1t} \quad (32.18.125)$$

El promedio pre-tratamiento de este error es $\frac{1}{T_0} \sum_{t=1}^{T_0} \left(\sum_j w_j^* \varepsilon_{jt} - \varepsilon_{1t} \right)$, que bajo $\mathbb{E}[\varepsilon_{jt}] = 0$ y varianza finita converge a 0 a tasa $T_0^{-\frac{1}{2}}$ por la ley de grandes números. La implicación práctica es fundamental: *más historia pre-tratamiento T_0 reduce el sesgo asintóticamente, independientemente del número de donantes J .*

□

Proposición A.18 (DiD como Caso Especial del SynC)

El estimador DiD con efectos fijos de unidad y tiempo es un caso especial del SynC cuando:

1. $w_j = \frac{1}{J}$ para todo j (pesos uniformes)
 2. $F = 1$ (un solo factor latente, λ_t escalar)
 3. $\mu_i = 1$ para todo i (cargas factoriales homogéneas)
- Bajo estas condiciones, el modelo se reduce a $Y_{it}(0) = \delta_t + \lambda_t + \varepsilon_{it}$, que es el modelo aditivo de DiD.

Demostración.

Con $F = 1$ y $\mu_i = 1$:

$$Y_{it}(0) = \delta_t + \theta_t Z_i + \lambda_t + \varepsilon_{it} \quad (32.18.126)$$

Si adicionalmente no hay covariables observables ($Z_i = 0$) o $\theta_t = 0$, el modelo es $Y_{it}(0) = (\delta_t + \lambda_t) + \varepsilon_{it}$, que es el modelo de efectos fijos de tiempo aditivo. Con pesos uniformes $w_j = \frac{1}{J}$:

$$\hat{Y}_{1t}(0) = \frac{1}{J} \sum_{j=2}^{J+1} Y_{jt} = \bar{Y}_t^{(-1)} \quad (32.18.127)$$

El estimador del efecto es:

$$\hat{\tau}_{1t} = Y_{1t} - \bar{Y}_t^{(-1)} = (Y_{1t} - Y_{1,T_0}) - (\bar{Y}_t^{(-1)} - \bar{Y}_{T_0}^{(-1)}) + (Y_{1,T_0} - \bar{Y}_{T_0}^{(-1)}) \quad (32.18.128)$$

Bajo el supuesto de tendencias paralelas ($Y_{1,T_0} - \bar{Y}_{T_0}^{(-1)} = 0$ en expectativa), esto coincide con el estimador DiD de cambios en diferencias.

□

Proposición A.19 (Intercambiabilidad bajo H_0)

Bajo la hipótesis nula de no efecto del tratamiento ($\tau_{jt} = 0$ para todo $j, t > T_0$), la distribución conjunta de $(r_1, \dots, r_{J+1})$ es intercambiable: invariante ante permutaciones de los índices de unidad.

Demostración.

Bajo H_0 , $Y_{jt} = Y_{jt}(0)$ para todo j y $t > T_0$. El algoritmo SynC es determinista dado los datos: para cada unidad j , los pesos $w^{*(j)}$ son función de $\{Y_{it}\}_{i \neq j, t \leq T_0}$.

La intercambiabilidad (suficiente para la validez exacta del test de Fisher) requiere que la distribución conjunta del vector $(r_1, \dots, r_{J+1})$ sea invariante ante permutaciones de los índices de unidad. No se requiere que las unidades sean idénticamente distribuidas; basta con que, bajo H_0 :

1. Los residuos pre-intervención sigan un modelo de factores latentes con estructura simétrica entre unidades:
 $Y_{jt}(0) = \lambda_t' \mu_j + \varepsilon_{jt}$, de modo que la etiqueta de qué unidad es “tratada” es intercambiable (Abadie, Diamond & Hainmueller, 2010, Apéndice A).
 2. No existe efecto del tratamiento ($H_0: Y_{jt}(1) = Y_{jt}(0)$ para $t > T_0$).
- Bajo (i)–(ii), permutar qué unidad se llama “tratada” produce la misma distribución para r_j . Por tanto la distribución empírica de $\{r_j\}_{j=1}^{J+1}$ bajo H_0 asigna probabilidad $\frac{1}{J+1}$ a cada rango, y el p-valor $p = \frac{|\{j: r_j \geq r_1\}|}{J+1}$ es exacto (no asintótico) bajo H_0 .

□

32.18.10 Capítulo 10: Mediación Causal**Proposición A.20 (Paradoja del Efecto Cero en Mediación)**

Es posible que el efecto total del tratamiento sea cero mientras existen efectos directo e indirecto no nulos que se cancelan exactamente.

Demostración.

Considere el siguiente sistema de potenciales:

- Mediador: $M_{i(0)} \sim \text{Bernoulli}(0.5)$, $M_{i(1)} = 1 - M_{i(0)}$ (complemento)
- Resultado: $Y_{i(t,m)} = (-1)^{t+m}$ (alterna entre -1 y 1)

El efecto total es:

$$\begin{aligned} \mathbb{E}[Y(1, M(1)) - Y(0, M(0))] &= \mathbb{E}[(-1)^{1+M(1)} - (-1)^{0+M(0)}] \\ &= \mathbb{E}[(-1)^{1+(1-M(0))} - (-1)^{M(0)}] \\ &= \mathbb{E}[(-1)^{2-M(0)} - (-1)^{M(0)}] \\ &= \mathbb{E}[(-1)^{M(0)} - (-1)^{M(0)}] = 0 \end{aligned} \quad (32.18.129)$$

Sin embargo, los efectos descomponibles son no nulos. El efecto directo controlado al nivel $m = 0$:

$$\mathbb{E}[Y(1, 0) - Y(0, 0)] = (-1)^1 - (-1)^0 = -1 - 1 = -2 \quad (32.18.130)$$

El efecto indirecto a través del cambio en M es igualmente no nulo. La cancelación perfecta ocurre porque el sistema está diseñado para que los efectos sean iguales y opuestos, no porque no existan mecanismos causales. $\square$

Teorema A.26 (Descomposición Aditiva de Efectos Naturales)

El efecto total se descompone aditivamente en efecto directo natural e indirecto natural:

$$\text{ATE}(x) = \text{NDE}(x) + \text{NIE}(x) \quad (32.18.131)$$

Demostración.

La demostración requiere sumar y restar el término intermedio $\mathbb{E}[Y(1, M(0)) \mid X = x]$:

$$\begin{aligned} \text{ATE}(x) &= \mathbb{E}[Y(1, M(1)) - Y(0, M(0)) \mid X = x] \\ &= \mathbb{E}[Y(1, M(1)) - Y(1, M(0)) + Y(1, M(0)) - Y(0, M(0)) \mid X = x] \\ &= \underbrace{\mathbb{E}[Y(1, M(0)) - Y(0, M(0)) \mid X = x]}_{\text{NDE}(x)} \\ &\quad + \underbrace{\mathbb{E}[Y(1, M(1)) - Y(1, M(0)) \mid X = x]}_{\text{NIE}(x)} \end{aligned} \quad (32.18.132)$$

La sustitución directa de $\mathbb{E}[Y(0, M(0))]$ por $\mathbb{E}[Y(1, M(0))]$ falla porque no respeta la estructura de contrafactuales. El reordenamiento correcto suma y resta el término híbrido que comparte el tratamiento $T = 1$ con el primer sumando y el mediador $M(0)$ con el segundo. $\square$

Teorema A.27 (Fórmula de Mediación de Pearl)

Para mediador continuo o discreto con densidad/densidad de probabilidad sobre $\mathcal{M}$, el efecto directo natural se identifica como:

$$\text{NDE}(x) = \int_{\mathcal{M}} (\mathbb{E}[Y \mid T = 1, M = m, X = x] - \mathbb{E}[Y \mid T = 0, M = m, X = x]) d\mathbb{P}(M = m \mid X = x) \quad (32.18.133)$$

Demostración.

La derivación procede en siete pasos desde el contrafactual híbrido:

Paso 1: Definir el objetivo $\mathbb{E}[Y(1, M(0)) \mid X = x]$.

Paso 2: Aplicar la ley de esperanzas iteradas condicional en $M(0)$:

$$\mathbb{E}[Y(1, M(0)) \mid X = x] = \int_{\mathcal{M}} \mathbb{E}[Y(1, m) \mid M(0) = m, X = x] d\mathbb{P}(M(0) = m \mid X = x) \quad (32.18.134)$$

Paso 3: Aplicar ignorabilidad del tratamiento para sustituir $M(0)$ por M observado bajo $T = 0$:

$$\mathbb{P}(M(0) = m \mid X = x) = \mathbb{P}(M = m \mid T = 0, X = x) \quad (32.18.135)$$

Paso 4: Aplicar independencia cross-world para desacoplar:

$$\mathbb{E}[Y(1, m) \mid M(0) = m, X = x] = \mathbb{E}[Y(1, m) \mid X = x] \quad (32.18.136)$$

Paso 5: Aplicar ignorabilidad del mediador para sustituir el potencial por la expectativa condicional observada:

$$\mathbb{E}[Y(1, m) \mid X = x] = \mathbb{E}[Y \mid T = 1, M = m, X = x] \quad (32.18.137)$$

Paso 6: Combinar los resultados de los pasos 2-5:

$$\mathbb{E}[Y(1, M(0)) \mid X = x] = \int_{\mathcal{M}} \mathbb{E}[Y \mid T = 1, M = m, X = x] d\mathbb{P}(M = m \mid T = 0, X = x) \quad (32.18.138)$$

Paso 7: Calcular el NDE restando $\mathbb{E}[Y(0, M(0)) \mid X = x] = \mathbb{E}[Y \mid T = 0, X = x]$:

$$\begin{aligned} \text{NDE}(x) &= \int_{\mathcal{M}} \mathbb{E}[Y \mid T = 1, M = m, X = x] d\mathbb{P}(M = m \mid T = 0, X = x) \\ &\quad - \int_{\mathcal{M}} \mathbb{E}[Y \mid T = 0, M = m, X = x] d\mathbb{P}(M = m \mid T = 0, X = x) \\ &= \int_{\mathcal{M}} (\mathbb{E}[Y \mid T = 1, M = m, X = x] - \mathbb{E}[Y \mid T = 0, M = m, X = x]) d\mathbb{P}(M = m \mid T = 0, X = x) \end{aligned} \quad (32.18.139)$$

□

Teorema A.28 (Colapso Lineal de Efectos Naturales)

En el LSEM sin interacciones, los efectos naturales colapsan a:

$$\text{NDE} = \beta_1 \quad \text{y} \quad \text{NIE} = \alpha_1 \beta_2 \quad (32.18.140)$$

Demostración.

La demostración procede por sustitución directa de los potenciales lineales:

Paso 1: Calcular $\mathbb{E}[Y(1, M(0)) \mid X = x]$:

$$\begin{aligned} \mathbb{E}[Y(1, M(0)) \mid X = x] &= \mathbb{E}[\beta_0 + \beta_1 \cdot 1 + \beta_2 M(0) + \beta_3^{\rightarrow} px + \varepsilon_Y \mid X = x] \\ &= \beta_0 + \beta_1 + \beta_2 \mathbb{E}[M(0) \mid X = x] + \beta_3^{\rightarrow} px \\ &= \beta_0 + \beta_1 + \beta_2(\alpha_0 + \alpha_2^{\rightarrow} px) + \beta_3^{\rightarrow} px \end{aligned} \quad (32.18.141)$$

Paso 2: Calcular $\mathbb{E}[Y(0, M(0)) \mid X = x]$:

$$\mathbb{E}[Y(0, M(0)) \mid X = x] = \beta_0 + \beta_2(\alpha_0 + \alpha_2^{\rightarrow} px) + \beta_3^{\rightarrow} px \quad (32.18.142)$$

Paso 3: Restar para obtener NDE:

$$\text{NDE} = \mathbb{E}[Y(1, M(0)) - Y(0, M(0)) \mid X = x] = \beta_1 \quad (32.18.143)$$

Paso 4: Calcular $\mathbb{E}[Y(1, M(1)) \mid X = x]$:

$$\mathbb{E}[Y(1, M(1)) \mid X = x] = \beta_0 + \beta_1 + \beta_2(\alpha_0 + \alpha_1 + \alpha_2^{\rightarrow} px) + \beta_3^{\rightarrow} px \quad (32.18.144)$$

Paso 5: Restar para obtener NIE:

$$\text{NIE} = \mathbb{E}[Y(1, M(1)) - Y(1, M(0)) \mid X = x] = \beta_2 \alpha_1 \quad (32.18.145)$$

Paso 6: Verificar descomposición:

$$\text{ATE} = \mathbb{E}[Y(1, M(1)) - Y(0, M(0)) \mid X = x] = \beta_1 + \alpha_1 \beta_2 = \text{NDE} + \text{NIE} \quad (32.18.146)$$

□

Proposición A.21 (Fórmulas Correctas bajo Interacción $T \times M$)

Si el modelo de resultado especifica interacción:

$$Y_i = \beta_0 + \beta_1 T_i + \beta_2 M_i + \beta_4 T_i M_i + \beta_3^* p X_i + \varepsilon_{Yi} \quad (32.18.147)$$

entonces las fórmulas de Baron-Kenny $\widehat{\text{NDE}} = \hat{\beta}_1$ y $\widehat{\text{NIE}} = \hat{\alpha}_1 \hat{\beta}_2$ son inconsistentes. Las expresiones correctas para los efectos naturales son:

$$\text{NDE} = \beta_1 + \beta_4 \cdot \mathbb{E}[M(0) | X] \quad \text{NIE} = (\beta_2 + \beta_4) \cdot \alpha_1 \quad (32.18.148)$$

donde α_1 es el coeficiente de T en la regresión del mediador.

Demostración.

Bajo el modelo con interacción, los potenciales anidados son:

$$Y_{i(t,m)} = \beta_0 + \beta_1 t + \beta_2 m + \beta_4 tm + \beta_3^* p X_i + \varepsilon_{Yi} \quad (32.18.149)$$

Calculando $\mathbb{E}[Y(1, M(0)) - Y(0, M(0)) | X]$:

$$\mathbb{E}[Y(1, M(0)) | X] = \beta_0 + \beta_1 + (\beta_2 + \beta_4) \mathbb{E}[M(0) | X] + \beta_3^* p X \quad (32.18.150)$$

$$\mathbb{E}[Y(0, M(0)) | X] = \beta_0 + \beta_2 \mathbb{E}[M(0) | X] + \beta_3^* p X$$

Restando: $\text{NDE} = \beta_1 + \beta_4 \mathbb{E}[M(0) | X]$. Análogamente:

$$\mathbb{E}[Y(1, M(1)) | X] = \beta_0 + \beta_1 + (\beta_2 + \beta_4) (\mathbb{E}[M(0) | X] + \alpha_1) + \beta_3^* p X \quad (32.18.151)$$

por lo que $\text{NIE} = (\beta_2 + \beta_4) \alpha_1$.

□

32.18.11 Capítulo 11: Robustez y Validación**Teorema A.29 (Identificación Parcial del ATE con Datos Limitados (Cotas de Manski Adaptadas))**

Bajo ignorabilidad débil y datos limitados ($n < 500$), el ATE satisface cotas sharp adaptadas. Definamos: $\tau_{\text{obs}} = \mathbb{E}[Y | T = 1] - \mathbb{E}[Y | T = 0]$ (diferencia de medias observada), $p = \mathbb{P}(T = 1)$ (prevalencia del tratamiento), $\Delta_t = \sup Y(t) - \inf Y(t)$ (rango del resultado potencial t). Entonces:

$$\tau_{\text{ATE}} \in [\tau_{\text{obs}} - \Delta_0(1 - p) - \Delta_1 p - \varepsilon(n), \tau_{\text{obs}} + \Delta_0(1 - p) + \Delta_1 p + \varepsilon(n)] \quad (32.18.152)$$

donde $\varepsilon(n)$ es un término de incertidumbre que crece como $O\left(\frac{1}{\sqrt{n}}\right)$, reflejando la mayor varianza en muestras pequeñas. Esta cota es más conservadora que la estándar de Manski, incorporando explícitamente la incertidumbre muestral.

Demostración.

La demostración extiende el teorema de Manski incorporando límites de concentración.

Paso 1: Expresar la esperanza observada con error muestral:

$$\mathbb{E}_{n[Y | T=t]} = \mathbb{E}[Y | T = t] + \xi_t, \quad |\xi_t| \leq \frac{C}{\sqrt{n_t}} \quad (32.18.153)$$

donde C depende de la varianza de Y y n_t es el tamaño muestral en el grupo t .

Paso 2: El estimador observado satisface:

$$\hat{\tau}_{\text{obs}} = \tau_{\text{obs}} + \xi_1 - \xi_0 \quad (32.18.154)$$

Paso 3: Incorporar este error muestral en las cotas de Manski:

$$\begin{aligned} \tau_{\text{ATE}} &\geq \hat{\tau}_{\text{obs}} - \Delta_0(1-p) - \Delta_1 p - \frac{C}{\sqrt{n_0}} - \frac{C}{\sqrt{n_1}} \\ \tau_{\text{ATE}} &\leq \hat{\tau}_{\text{obs}} + \Delta_0(1-p) + \Delta_1 p + \frac{C}{\sqrt{n_0}} + \frac{C}{\sqrt{n_1}} \end{aligned} \quad (32.18.155)$$

Paso 4: Definir $\varepsilon(n) = \frac{C}{\sqrt{n_0}} + \frac{C}{\sqrt{n_1}}$ para obtener la cota adaptada.

□

32.18.12 Capítulo 13: Modelos Causales Estructurales**Teorema A.30 (Condición de Markov Causal)**

Sea $\mathcal{M} = \langle U, V, F, P(U) \rangle$ un SCM con DAG acíclico $\mathcal{G}$, y supóngase que las variables exógenas $U_1, \dots, U_n$ son mutuamente independientes. Entonces la distribución conjunta de las variables endógenas factoriza según $\mathcal{G}$:

$$P(V_1, \dots, V_n) = \prod_{i=1}^n P(V_i | \text{pa}(V_i)). \quad (32.18.156)$$

Demostración.

La demostración procede en tres pasos, explotando la aciclicidad del DAG y la independencia mutua de los ruidos exógenos.

Paso 1: Orden topológico. Por ser $\mathcal{G}$ un DAG, existe un ordenamiento topológico de los nodos $V_{(1)}, V_{(2)}, \dots, V_{(n)}$ tal que si $V_{(j)} \in \text{pa}(V_{(i)})$, entonces $j < i$. Sin pérdida de generalidad, re-indexamos para que $V_1, V_2, \dots, V_n$ sea dicho orden. Por la regla de la cadena de la probabilidad:

$$P(V_1, \dots, V_n) = \prod_{i=1}^n P(V_i | V_1, \dots, V_{i-1}). \quad (32.18.157)$$

Paso 2: Reducción a padres. La ecuación estructural $V_i := f_{i(\text{pa}(V_i), U_i)}$ implica que, condicionado en los valores de $\text{pa}(V_i)$, la variable V_i es función exclusivamente de U_i . Dado que U_i es independiente de todos los demás U_j (por la hipótesis de independencia mutua), y que las variables $\{V_j : j < i, V_j \notin \text{pa}(V_i)\}$ están determinadas por ruidos $\{U_k\}_{k \neq i}$, se sigue que:

$$P(V_i | V_1, \dots, V_{i-1}) = P(V_i | \text{pa}(V_i)). \quad (32.18.158)$$

Formalmente, $\{V_j : j < i, V_j \notin \text{pa}(V_i)\}$ son funcionalmente independientes de V_i dado $\text{pa}(V_i)$ porque sus ruidos subyacentes no comparten U_i .

Paso 3: Sustitución. Sustituyendo se obtiene la factorización deseada:

$$P(V_1, \dots, V_n) = \prod_{i=1}^n P(V_i | \text{pa}(V_i)). \quad (32.18.159)$$

□

Teorema A.31 (Equivalencia Rubin-Pearl)

Sea $\mathcal{M} = \langle U, V, F, P(U) \rangle$ un SCM, y sea $T \in V$ una variable de tratamiento con valores en $\{0, 1\}$.

Defínase el resultado potencial de Rubin como:

$$Y(t) := Y_{\mathcal{M}_{\text{do}(T=t)}}, \quad (32.18.160)$$

es decir, el valor de Y en el submodelo mutilado donde se fuerza $\text{do}(T = t)$. Entonces, para toda unidad

i y todo $t \in \{0, 1\}$:

1. $Y_{i(t)}$ está bien definido como variable aleatoria en el espacio de probabilidad inducido por $P(U)$.
2. $Y_i^{\text{obs}} = T_i Y_{i(1)} + (1 - T_i) Y_{i(0)}$ (consistencia).
3. $\mathbb{E}[Y(t)] = \mathbb{E}_{\text{do}(T=t)}[Y]$.

Demostración.

(1) Buena definición. El submodelo mutilado $\mathcal{M}_{\text{do}(T=t)}$ reemplaza f_T por $T := t$, manteniendo intactas todas las demás funciones estructurales. Por la aciclicidad del DAG y el hecho de que $P(U)$ es una distribución propia, el sistema de ecuaciones de $\mathcal{M}_{\text{do}(T=t)}$ tiene una solución única (casi seguramente). El valor de Y en esta solución define $Y(t)$ como una variable aleatoria en $(\Omega, \mathcal{F}, P)$ inducida por (U, F) .

(2) Consistencia. En el mundo observado, T es determinado por $f_{T(\text{pa}(T), U_T)}$. Si para una unidad particular $T = t$, entonces el valor observado de Y satisface $Y = f_{Y(\text{pa}(Y), U_Y)}$ evaluado en $T = t$. Pero esta es exactamente la misma ecuación que determina $Y(t)$ en $\mathcal{M}_{\text{do}(T=t)}$ (pues T ya está fijado en t en ambos casos), siempre que $\text{do}(T = t)$ no altere $\text{pa}(Y) \setminus \{T\}$ ni U_Y , lo cual está garantizado por la definición de mutilación. Por tanto, $Y = Y(t)$ cuando $T = t$.

(3) Igualdad de esperanzas. Por definición, $\mathbb{E}[Y(t)]$ es la esperanza de Y bajo la distribución inducida por $\mathcal{M}_{\text{do}(T=t)}$. Pero esta distribución es, por construcción, $P_{\text{do}(T=t)}(V)$, de modo que $\mathbb{E}[Y(t)] = \mathbb{E}_{P_{\text{do}(T=t)}(\cdot)}[Y] = \mathbb{E}_{\text{do}(T=t)}[Y]$. $\square$

32.18.13 Capítulo 14: DAGs y Estructuras Fundamentales**Teorema A.32 (Soundness y Completeness de la d-separación)**

Sea $\mathcal{M} = \langle U, V, F, P(U) \rangle$ un SCM con DAG $\mathcal{G}$ y distribución inducida $P(V)$.

1. **Soundness (Corrección):** Si $X \perp\!\!\!\perp_d Y \mid Z$ en $\mathcal{G}$, entonces $X \perp\!\!\!\perp Y \mid Z$ en $P(V)$.
2. **Completeness (bajo fidelidad):** Si $P(V)$ es fiel a $\mathcal{G}$, entonces $X \perp\!\!\!\perp Y \mid Z$ en $P(V)$ implica $X \perp\!\!\!\perp_d Y \mid Z$ en $\mathcal{G}$.

Demostración (esbozo de Soundness).

La demostración completa puede consultarse en Pearl (2009, Teorema 1.2.4) y Verma & Pearl (1988). Presentamos la idea central. Por la Condición de Markov Causal, $P(V)$ factoriza según $\mathcal{G}$. La factorización implica la propiedad de Markov local: cada variable es condicionalmente independiente de sus no-descendientes dados sus padres. A partir de esta propiedad local, se demuestra por inducción sobre la longitud de los caminos que si Z bloquea todos los caminos entre X e Y , entonces X e Y son condicionalmente independientes dado Z . La inducción trata separadamente los tres conectores fundamentales, explotando que la factorización de Markov hace que el condicionamiento en el nodo intermedio de cadenas y horquillas “desconecte” probabilísticamente los extremos, mientras que la ausencia de condicionamiento en colisionadores preserva la independencia. $\square$

32.18.14 Capítulo 15: El Criterio Backdoor

Teorema A.33 (Fórmula de Ajuste Backdoor)

Sea $\mathcal{G}$ un DAG compatible con un SCM $\mathcal{M}$ y sea $\mathbf{Z}$ un conjunto que satisface el criterio backdoor para (T, Y) . Entonces:

$$P_{\{\text{do}(T=t)\}}(Y = y) = \sum_{\{\mathbf{z}\}} P(Y = y \mid T = t, \mathbf{Z} = \mathbf{z}) P(\mathbf{Z} = \mathbf{z}). \quad (32.18.161)$$

Demostración.

La demostración procede en tres pasos, explotando la definición del submodelo mutilado y las propiedades de la d-separación.

Paso 1: Invariancia de $\mathbf{Z}$ bajo intervención. Por la condición (1) del criterio backdoor, $\mathbf{Z} \cap \text{De}(T) = \emptyset$. Las variables en $\mathbf{Z}$ no son afectadas por la intervención sobre T , por lo que su distribución marginal es invariante:

$$P_{\{\mathcal{M}_{\{\text{do}(T=t)\}}\}}(\mathbf{Z} = \mathbf{z}) = P(\mathbf{Z} = \mathbf{z}). \quad (32.18.162)$$

Esta igualdad es crucial: nos permite estimar la distribución de $\mathbf{Z}$ en el mundo intervenido usando datos del mundo observado.

Paso 2: Invariancia condicional de Y . En el submodelo mutilado $\mathcal{M}_{\{\text{do}(T=t)\}}$, la función estructural de Y no es alterada (solo se reemplaza la de T). Además, en el grafo mutilado $\mathcal{G}_{\{\bar{T}\}}$ (sin aristas entrantes a T), la d-separación de T e Y por $\mathbf{Z}$ en $\mathcal{G}_{\{\bar{T}\}}$ implica que, en $\mathcal{M}_{\{\text{do}(T=t)\}}$, Y es condicionalmente independiente de los mecanismos alterados dado T y $\mathbf{Z}$. Por tanto:

$$P_{\{\mathcal{M}_{\{\text{do}(T=t)\}}\}}(Y = y \mid T = t, \mathbf{Z} = \mathbf{z}) = P(Y = y \mid T = t, \mathbf{Z} = \mathbf{z}). \quad (32.18.163)$$

El condicionamiento en el mundo intervenido coincide con el condicionamiento observacional porque el mecanismo que genera Y a partir de $(T, \mathbf{Z})$ no ha sido intervenido.

Paso 3: Ley de probabilidad total en el mundo intervenido.

$$\begin{aligned} P_{\{\text{do}(T=t)\}}(Y = y) &= \sum_{\{\mathbf{z}\}} P_{\{\mathcal{M}_{\{\text{do}(T=t)\}}\}}(Y = y \mid T = t, \mathbf{Z} = \mathbf{z}) P_{\{\mathcal{M}_{\{\text{do}(T=t)\}}\}}(\mathbf{Z} = \mathbf{z}) \\ &= \sum_{\{\mathbf{z}\}} P(Y = y \mid T = t, \mathbf{Z} = \mathbf{z}) P(\mathbf{Z} = \mathbf{z}). \end{aligned} \quad (32.18.164)$$

La primera igualdad es simplemente la ley de probabilidad total en el submodelo mutilado. La segunda sustituye los resultados de los Pasos 1 y 2.

□

32.18.15 Capítulo 16: El Criterio Frontdoor**Teorema A.34 (Fórmula de Identificación Frontdoor)**

Sea $\mathcal{G}$ un DAG compatible con un SCM $\mathcal{M}$ y sea $\mathbf{M}$ un conjunto que satisface el criterio frontdoor para (T, Y) . Entonces:

$$P_{\{\text{do}(T=t)\}}(Y = y) = \sum_{\{\mathbf{m}\}} P(\mathbf{M} = \mathbf{m} \mid T = t) \sum_{\{t'\}} P(Y = y \mid T = t', \mathbf{M} = \mathbf{m}) P(T = t' \mid T = t, \mathbf{M} = \mathbf{m}). \quad (32.18.165)$$

Demostración.

La demostración descompone el efecto total en dos etapas, cada una identificable por separado.

Paso 1: Descomposición. Por la ley de probabilidad total en el mundo intervenido:

$$P_{\{do(T=t)\}}(Y = y) = \sum_{\{m\}} P_{\{do(T=t)\}}(Y = y \mid M = m) P_{\{do(T=t)\}}(M = m). \quad (32.18.166)$$

Paso 2: Identificación del primer tramo ($T \rightarrow M$). Por la condición (2) del criterio frontdoor, no hay caminos de puerta trasera no bloqueados entre T y M . Por tanto:

$$P_{\{do(T=t)\}}(M = m) = P(M = m \mid T = t). \quad (32.18.167)$$

Paso 3: Identificación del segundo tramo ($M \rightarrow Y$). Por la condición (3), T bloquea todos los caminos de puerta trasera entre M e Y , por lo que T satisface el criterio backdoor para (M, Y) . Aplicando la fórmula de ajuste backdoor a esta relación:

$$P_{\{do(M=m)\}}(Y = y) = \sum_{\{t'\}} P(Y = y \mid M = m, T = t') P(T = t'). \quad (32.18.168)$$

Paso 4: Acoplamiento. En el mundo con $do(T = t)$, el valor de M está fijado por el mecanismo natural $P_{\{do(T=t)\}}(M)$. Una vez que M toma un valor particular, el efecto de M sobre Y en ese mundo es exactamente el efecto intervenido $P_{\{do(M=m)\}}(Y)$, porque T ya no ejerce influencia adicional sobre Y excepto a través de M (condición 1). Formalmente:

$$P_{\{do(T=t)\}}(Y = y \mid M = m) = P_{\{do(M=m)\}}(Y = y). \quad (32.18.169)$$

Paso 5: Sustitución final. Sustituyendo:

$$\begin{aligned} P_{\{do(T=t)\}}(Y = y) &= \sum_{\{m\}} \left(\sum_{\{t'\}} P(Y = y \mid M = m, T = t') P(T = t') \right) P(M = m \mid T = t) \\ &= \sum_{\{m\}} P(M = m \mid T = t) \sum_{\{t'\}} P(Y = y \mid T = t', M = m) P(T = t'). \end{aligned} \quad (32.18.170)$$

□

32.18.16 Capítulo 17: Naturaleza de las Causas

Teorema A.35 (Inevitabilidad de los Contrafactuales para la Causa Singular)

No existe una partición $Z = z$ definida en términos puramente observacionales (es decir, sin invocar resultados potenciales $Y_{i(t)}$) que sea siempre suficiente para que la condición de rescate probabilista coincida con la causa singular.

Esquema de la demostración.

La demostración procede por construcción. Dado un modelo con heterogeneidad de efectos (como el Ejemplo Ejemplo 226), toda partición observacional $Z = z$ que rescata la condición probabilista debe coincidir con los tipos latentes de respuesta (“adversamente susceptibles”, “no habrían quedado embarazadas”). Estos tipos son precisamente los conjuntos $\{u : Y_{x(u)} \neq Y_{x'}(u)\}$, que solo pueden definirse en vocabulario contrafactual. Por tanto, la definición de la subpoblación rescatadora presupone los mismos contrafactuales que pretende evitar.

□

32.18.17 Capítulo 18: Do-Calculus

Teorema A.36 (Regla 1: Inserción/eliminación de observaciones)

Sea $\mathcal{G}$ el DAG causal. Si $Y \perp\!\!\!\perp_d Z \mid X, W$ en $\mathcal{G}_{\{\bar{X}\}}$, entonces:

$$P_{\{do(x)\}}(y \mid z, w) = P_{\{do(x)\}}(y \mid w). \quad (32.18.171)$$

Demostración.

La intervención $\text{do}(X = x)$ mutila las aristas entrantes a X , produciendo $\mathcal{G}_{\{\overline{X}\}}$. En este grafo, la d-separación $Y \perp\!\!\!\perp_d Z \mid X, W$ implica, por la condición de Markov causal aplicada al submodelo $\mathcal{M}_{\{\text{do}(X=x)\}}$, la independencia condicional $Y \perp\!\!\!\perp Z \mid X, W$ en la distribución intervencional $P_{\{\text{do}(x)\}}(\cdot)$. Por tanto, $P_{\{\text{do}(x)\}}(y \mid z, w) = P_{\{\text{do}(x)\}}(y \mid w)$, puesto que Z no aporta información adicional sobre Y una vez que W y la intervención están dados.

□

Teorema A.37 (Regla 2: Intercambio acción/observación)

Si $Y \perp\!\!\!\perp_d Z \mid X, W$ en $\mathcal{G}_{\{\overline{XZ}\}}$, entonces:

$$P_{\{\text{do}(x), \text{do}(z)\}}(y \mid w) = P_{\{\text{do}(x)\}}(y \mid z, w). \quad (32.18.172)$$

Demostración.

En $\mathcal{G}_{\{\overline{XZ}\}}$, se eliminan tanto las aristas entrantes a X como las salientes de Z . La d-separación en este grafo indica que, habiendo fijado X mediante intervención, Z no tiene efecto causal residual sobre Y (pues sus flechas salientes han sido borradas) y, simultáneamente, no hay caminos de confusión no bloqueados entre Z e Y . Por tanto, en el submodelo $\mathcal{M}_{\{\text{do}(X=x), \text{do}(Z=z)\}}$, la distribución de Y condicional en Z es la misma que bajo $\text{do}(X = x)$ sin intervenir sobre Z :

$$P_{\{\mathcal{M}_{\{\text{do}(x), \text{do}(z)\}}\}}(y \mid z, w) = P_{\{\mathcal{M}_{\{\text{do}(x)\}}\}}(y \mid z, w) = P_{\{\text{do}(x)\}}(y \mid z, w). \quad (32.18.173)$$

Esto implica $P_{\{\text{do}(x), \text{do}(z)\}}(y \mid w) = P_{\{\text{do}(x)\}}(y \mid z, w)$.

□

Teorema A.38 (Regla 3: Inserción/eliminación de intervenciones)

Si $Y \perp\!\!\!\perp_d Z \mid X, W$ en $\mathcal{G}_{\{\overline{X}, \overline{Z(W)}\}}$, donde $Z(W)$ es el conjunto de nodos en Z que no son ancestros de W en $\mathcal{G}_{\{\overline{X}\}}$, entonces:

$$P_{\{\text{do}(x), \text{do}(z)\}}(y \mid w) = P_{\{\text{do}(x)\}}(y \mid w). \quad (32.18.174)$$

Demostración.

El grafo $\mathcal{G}_{\{\overline{X}, \overline{Z(W)}\}}$ elimina aristas entrantes a X y aristas entrantes a los nodos de Z que no son ancestros de W (tras la intervención en X). La d-separación en este grafo implica que, bajo $\text{do}(X = x)$, la intervención adicional sobre Z no altera la distribución de Y condicional en W , porque cualquier efecto de Z sobre Y está mediado exclusivamente por W . Formalmente, en el submodelo $\mathcal{M}_{\{\text{do}(x), \text{do}(z)\}}$,

$$P_{\{\mathcal{M}_{\{\text{do}(x), \text{do}(z)\}}\}}(y \mid w) = P_{\{\mathcal{M}_{\{\text{do}(x)\}}\}}(y \mid w), \quad (32.18.175)$$

lo que establece $P_{\{\text{do}(x), \text{do}(z)\}}(y \mid w) = P_{\{\text{do}(x)\}}(y \mid w)$.

□

Teorema A.39 (Complejidad del Do-Calculus, Shpitser & Pearl 2006)

Sea $\mathcal{G}$ un DAG causal y $P(V)$ una distribución positiva sobre las variables observadas V . Si el efecto causal $P_{\{\text{do}(X)\}}(Y)$ es identificable a partir de $P(V)$, entonces existe una secuencia finita de aplicaciones de las tres reglas del do-calculus que transforma $P_{\{\text{do}(X)\}}(Y)$ en una expresión libre del operador $\text{do}(\cdot)$.

Esquema de la demostración.

La demostración de Shpitser y Pearl (2006) es constructiva y se basa en tres ingredientes: (1) la noción de *hedge*, una estructura gráfica que caracteriza la no-identificabilidad; (2) el Algoritmo ID, que aplica las tres reglas de manera sistemática; (3) la prueba de que si ID no encuentra una expresión libre de $\text{do}(\cdot)$, entonces existe un *hedge* y el efecto es genuinamente no-identificable. El lector interesado puede consultar el artículo original para una exposición completa de la demostración.

□

32.18.18 Capítulo 19: Contrafactuales

Teorema A.40 (Descomposición de la PNS)

Bajo la condición de monotonía $Y_1(u) \geq Y_0(u)$ para todo u ,

$$\text{PNS} = P(Y = 1 \mid T = 1) - P(Y = 1 \mid T = 0). \quad (32.18.176)$$

En este caso, la PNS coincide con el ATE en escala de diferencia de riesgos si T es aleatorizado.

Demostración.

Por la ley de probabilidad total y monotonía:

$$\text{PNS} = P(Y_1 = 1) - P(Y_0 = 1) = \sum_u [Y_1(u) - Y_0(u)] P(u) = \mathbb{E}[Y_1 - Y_0] = \text{ATE}. \quad (32.18.177)$$

Sin monotonía, existen unidades para las que T es preventivo ($Y_1 = 0, Y_0 = 1$) y la PNS está acotada por:

$$\text{ATE} - \theta \leq \text{PNS} \leq \text{ATE} + \theta, \quad (32.18.178)$$

donde $\theta = P(Y_1 = 0, Y_0 = 1)$.

□

32.18.19 Capítulo 20: Descubrimiento Causal

Teorema A.41 (Teorema de Meek (1995) – Completitud de reglas de orientación)

Sea $\mathcal{P}$ un PDAG obtenido tras orientar v-colisionadores en un esqueleto consistente con un DAG $\mathcal{G}^*$. La aplicación exhaustiva de las cuatro reglas de orientación de Meek (R1–R4) produce exactamente el CPDAG $[\mathcal{G}^*]$ de la clase de equivalencia de $\mathcal{G}^*$. Ninguna regla adicional puede orientar más aristas sin asumir información extra.

Demostración.

Las reglas R1–R4 son *sound* (toda orientación que producen es correcta en todo DAG de la clase) y *complete* (toda arista orientable en el CPDAG es orientada por alguna secuencia de aplicaciones de R1–R4). La prueba de completitud (Meek, 1995) procede mostrando que si una arista permanece no dirigida tras saturar R1–R4, existe al menos un DAG en la clase de equivalencia con cada orientación posible, por lo que la orientación no es identificable.

□

Teorema A.42 (Identificabilidad de LiNGAM)

Bajo el modelo LiNGAM con errores no gaussianos i.i.d. y DAG acíclico, la matriz de coeficientes B (y por tanto el DAG completo) es **identificable** a partir de datos puramente observacionales. No hay ambigüedad de clase de equivalencia.

Demostración.

El modelo se escribe $\mathbf{X} = \mathbf{B}\mathbf{X} + \mathbf{e}$, de donde $\mathbf{X} = (\mathbf{I} - \mathbf{B})^{-1}\mathbf{e} = \mathbf{A}\mathbf{e}$. Si los e_i son independientes y no gaussianos, el teorema de Skitovich-Darmois implica que $\mathbf{A}$ es identificable salvo permutación y escala. Como $\mathbf{B}$ es triangular inferior bajo un ordenamiento causal consistente, ICA (Independent Component Analysis) seguido de permutación a forma triangular recupera $\mathbf{B}$ de manera única.

□

32.18.20 Capítulo 21: Aprendizaje Causal**Teorema A.43 (Imposibilidad de reducción entre estratos (Pearl, 2019))**

No existe algoritmo que, recibiendo como entrada únicamente la distribución observacional $P(\mathbf{V})$ (Estrato 1), pueda computar consistentemente $P(Y \mid \text{do}(X = x))$ (Estrato 2) para un par arbitrario (X, Y) sin supuestos estructurales adicionales (como la estructura del DAG). Análogamente, no existe algoritmo que, con solo $P(Y \mid \text{do}(X = x))$, compute $P(Y_x \mid X = x', Y = y')$ (Estrato 3) sin el SCM completo.

Demostración.

La demostración procede por construcción de dos SCMs $\mathcal{M}_1$ y $\mathcal{M}_2$ tales que:

1. $P_{\mathcal{M}_1}(\mathbf{V}) = P_{\mathcal{M}_2}(\mathbf{V})$ (idénticos en el Estrato 1), pero $P_{\mathcal{M}_1}(Y \mid \text{do}(X = x)) \neq P_{\mathcal{M}_2}(Y \mid \text{do}(X = x))$ (distintos en el Estrato 2).
2. $P_{\mathcal{M}_1}(Y \mid \text{do}(X = x)) = P_{\mathcal{M}_2}(Y \mid \text{do}(X = x))$ para todo x (idénticos en el Estrato 2), pero $P_{\mathcal{M}_1}(Y_x \mid X = x', Y = y') \neq P_{\mathcal{M}_2}(Y_x \mid X = x', Y = y')$ (distintos en el Estrato 3).

El primer par se construye con dos DAGs de la misma clase de equivalencia Markoviana (mismo esqueleto y v-colisionadores pero orientaciones diferentes). El segundo par requiere dos SCMs con iguales funciones estructurales pero distintas distribuciones de ruidos exógenos $\mathbf{U}$ que producen las mismas distribuciones intervencionales pero distintos contrafactuales.

□

Corolario A.5 (Criterio de selección de variables por invariancia)

Si un predictor f utiliza **únicamente** las causas directas de Y (i.e., $f(X) = f(\text{Pa}(Y))$), entonces la distribución condicional $P^e(Y \mid f(X))$ es invariante entre entornos, porque el mecanismo $P(Y \mid \text{Pa}(Y))$ es un módulo autónomo del SCM que no se altera por cambios en otros mecanismos.

Demostración.

Por modularidad, $P(Y \mid \text{Pa}(Y))$ es un mecanismo autónomo del SCM. Cambios en la distribución conjunta $P^e(\mathbf{V})$ debidos a intervenciones o cambios poblacionales solo pueden afectar mecanismos de variables intervenidas. Si ninguna variable en $\text{Pa}(Y)$ fue intervenida, el mecanismo $P(Y \mid \text{Pa}(Y))$ permanece invariante. Si alguna fue intervenida, el cambio afecta a $P^e(\text{Pa}(Y))$ pero no a la forma funcional del mecanismo.

□

32.18.21 Capítulo 22: Meta-Learners

Teorema A.44 (Tasa casi óptima del R-learner (Nie & Wager, 2021))

Bajo condiciones de regularidad (suavidad de τ , m , e y convergencia suficiente de sus estimadores preliminares), el R-learner alcanza una tasa de convergencia para $\hat{\tau}_R$ que iguala—salvo factores logarítmicos—la tasa óptima de estimar una función de regresión estándar de la misma suavidad. Los errores en la estimación de m y e entran **solo a segundo orden**, permitiendo el uso de estimadores de ML regularizados (que convergen a tasa $o_P(n^{-\frac{1}{4}})$) sin sacrificar la eficiencia de $\hat{\tau}_R$.

Demostración.

La descomposición de Robinson orthogonaliza el efecto de tratamiento respecto a las funciones nuisance: la derivada de Gateaux del score respecto a m y e evaluada en la verdad es cero (condición de Neyman). Por tanto, fluctuaciones $o_P(n^{-\frac{1}{4}})$ en $\hat{m}$ y $\hat{e}$ introducen sesgo $o_P(n^{-\frac{1}{2}})$, que es asintóticamente despreciable frente al error de estimación de τ .

□

32.18.22 Capítulo 23: Doble Desviación**Teorema A.45 (Normalidad asintótica del DML (Chernozhukov et al., 2018))**

Bajo las siguientes condiciones:

1. $\psi(W, \theta, \eta)$ satisface la condición de ortogonalidad de Neyman en η_0 ;
2. $\hat{\eta}$ converge a η_0 a tasa $o_P(n^{-\frac{1}{4}})$ en norma L_2 : $|\hat{\eta} - \eta_0|_{P,2} = o_P(n^{-\frac{1}{4}})$;
3. Cross-fitting en K pliegues (fijo);
4. Condiciones de momentos y regularidad estándar;

se tiene:

$$\sqrt{n}(\hat{\theta}_{\{\text{DML}\}} - \theta_0) \xrightarrow{d} \mathcal{N}(0, \sigma_{\{\text{DML}\}}^2), \quad (32.18.179)$$

donde $\sigma_{\{\text{DML}\}}^2 = \mathbb{E} \frac{[\psi(W, \theta_0, \eta_0)]^2}{(\mathbb{E}[\bar{A}^2])^2}$. En particular, los intervalos de confianza basados en esta distribución normal son **asintóticamente válidos** aun cuando $\hat{\eta}$ se estime con métodos de ML fuertemente regularizados.

Demostración.

La expansión de $\sqrt{n}(\hat{\theta}_{\{\text{DML}\}} - \theta_0)$ admite la descomposición:

$$\begin{aligned} \sqrt{n}(\hat{\theta}_{\{\text{DML}\}} - \theta_0) &= \frac{1}{\sqrt{n}} \sum_{i=1}^n \psi(W_i, \theta_0, \eta_0) \\ &\quad + \sqrt{n} \mathbb{E} \left[\frac{\partial \psi}{\partial \eta}(W, \theta_0, \eta_0)(\hat{\eta} - \eta_0) \right] \\ &\quad + O_P(\sqrt{n} |\hat{\eta} - \eta_0|_{P,2}^2 + o_{P(1)}). \end{aligned} \quad (32.18.180)$$

El segundo término se anula por la condición de ortogonalidad de Neyman (derivada de Gateaux cero). El tercer término es $O_P\left(\sqrt{n} o_P(n^{-\frac{1}{2}})\right) = o_{P(1)}$ bajo la tasa $o_P(n^{-\frac{1}{4}})$ para $\hat{\eta}$. El primer término satisface el TCL por construcción.

Por tanto, el comportamiento asintótico está dominado por el primer término, que no involucra los nuisance parameters.

□

32.18.23 Capítulo 24: Efectos Heterogéneos

Teorema A.46 (Normalidad asintótica del árbol honesto, Athey & Imbens 2016)

Sea $\hat{\mathcal{L}}(x)$ la hoja que contiene a x en un árbol honesto. Bajo las siguientes condiciones:

1. **Soporte común:** existe $\eta > 0$ tal que $\eta \leq \mathbb{P}(A = 1 \mid X = x) \leq 1 - \eta$ para todo $x \in \mathcal{X}$.
2. **Tamaño mínimo de hoja:** $|\mathcal{S}^{\{\text{est}\}} \cap \mathcal{L}| \geq k$ para toda hoja $\mathcal{L}$, con $k \rightarrow \infty$ cuando $n \rightarrow \infty$.
3. **Árbol balanceado:** la profundidad del árbol crece como $o(\log n)$ y el número de hojas $K_n = o(\sqrt{n})$.
4. **Momentos finitos:** $\mathbb{E}[Y^4 \mid X, A] < \infty$ y las varianzas condicionales de Y son acotadas lejos de cero.

Entonces, para casi todo x en el soporte de X ,

$$\frac{\hat{\tau}(\hat{\mathcal{L}}(x)) - \tau(x)}{\sqrt{\hat{V}(x)}} \xrightarrow{d} \mathcal{N}(0, 1), \quad (32.18.181)$$

donde $\hat{V}(x) = \frac{\hat{\sigma}_1^2(\hat{\mathcal{L}}(x))}{n_1(\hat{\mathcal{L}}(x))} + \frac{\hat{\sigma}_0^2(\hat{\mathcal{L}}(x))}{n_0(\hat{\mathcal{L}}(x))}$, con $\hat{\sigma}_a^2$ la varianza muestral de Y en el brazo a dentro de la hoja.

Demostración.

Sea $\mathcal{L}^*(x)$ la hoja “oráculo” que contiene a x en el árbol poblacional (límite determinista del árbol muestral). La diferencia $\hat{\tau}(\hat{\mathcal{L}}(x)) - \tau(x)$ se descompone en tres términos:

$$\begin{aligned} & \underbrace{\hat{\tau}(\hat{\mathcal{L}}(x)) - \tau(\mathcal{L}^*(x))}_{\text{variabilidad muestral}} \\ & + \underbrace{\tau(\mathcal{L}^*(x)) - \tau(x)}_{\text{sesgo de aproximación}} \\ & + \underbrace{\hat{\tau}(\hat{\mathcal{L}}(x)) - \hat{\tau}(\mathcal{L}^*(x))}_{\text{error de estimación de la partición}}. \end{aligned} \quad (32.18.182)$$

Por honestidad, condicional en $\mathcal{S}^{\{\text{tr}\}}$, el primer término es una diferencia de medias sobre datos i.i.d. y converge a una normal por el TCL al ser la hoja suficientemente grande. El segundo término es $o(1)$ porque $\mathcal{L}^*(x)$ se contrae a $\{x\}$ cuando $n \rightarrow \infty$ bajo las condiciones de crecimiento del árbol. El tercer término es $o_P(n^{-\frac{1}{2}})$ porque la partición estimada converge a la poblacional a tasa al menos $n^{-\frac{1}{2}}$ bajo el supuesto de balanceo y el Lema de Donsker para clases de particiones de complejidad controlada. La combinación de los tres órdenes produce la normalidad asintótica declarada. $\square$

Teorema A.47 (Gaussianidad puntual del Causal Forest, Wager & Athey 2018)

Sea $\hat{\tau}(x)$ el estimador del bosque causal con B árboles, cada uno entrenado en una submuestra de tamaño s_n (sin reemplazo, $s_n \sim n^{\text{beta}}$ con $0 < \beta < 1$). Bajo las mismas condiciones del Teorema Teorema 313, más:

1. **Subsampling:** $s_n \rightarrow \infty$, $\frac{s_n}{n} \rightarrow 0$ (el tamaño de submuestra crece pero es asintóticamente despreciable frente a n).
2. **Honestidad:** cada árbol usa división honesta de la submuestra.
3. **Condiciones de crecimiento:** $\min_{\mathcal{L}} |\mathcal{L}| \gg s_n^{\frac{1}{2}}$ y el diámetro máximo de las hojas tiende a cero.

Entonces, para casi todo x ,

$$\sqrt{s_n}(\hat{\tau}(x) - \tau(x)) \xrightarrow{d} \mathcal{N}(0, \sigma^2(x)), \quad (32.18.183)$$

donde $\sigma^2(x)$ es estimable de manera consistente mediante el *jackknife infinitesimal*:

$$\hat{\sigma}^2(x) = \frac{n-1}{n} \left(\frac{n}{n-s_n} \right)^2 \sum_{i=1}^n \text{Cov}_* (\hat{\tau}_{b(x)}, N_{bi})^2, \quad (32.18.184)$$

con N_{bi} el indicador de que la observación i aparece en la submuestra del árbol b y Cov_* la covarianza empírica sobre los B árboles.

Demostración.

La demostración se basa en la representación del bosque como un operador kernel adaptativo. Definamos el kernel del bosque como $K_{n(x, X_i)} = \alpha_{i(x)}$. Wager y Athey (2018) demuestran que este kernel es asintóticamente equivalente a un kernel de tipo Nadaraya-Watson con ancho de banda $h_n \sim s_n^{-\frac{1}{p}}$ donde $p = \dim(X)$. La honestidad garantiza que el sesgo condicional $\mathbb{E}[\hat{\tau}(x) | \mathcal{S}^{\{\text{tr}\}}] - \tau(x)$ es $o_P(s_n^{-\frac{1}{2}})$. La estructura de dependencia inducida por el bosque se maneja con el *método delta para U-estadísticos incompletos*: $\hat{\tau}(x)$ es aproximadamente una U-estadística de segundo orden sobre las submuestras, y el jackknife infinitesimal (Efron, 2014) provee una estimación consistente de la varianza de dicha U-estadística. La normalidad asintótica se sigue del Teorema Central del Límite para U-estadísticos degenerados de orden finito.

□

Proposición A.22 (Regla de targeting óptimo)

Sea $c > 0$ el costo de administrar el tratamiento y $v > 0$ el valor monetario de una unidad de resultado Y ($v = 1$ si Y ya está expresado en unidades de beneficio). Bajo ignorabilidad y tratamiento binario, la política que maximiza el beneficio neto esperado es:

$$\pi^*(x) = \mathbf{1}\left(\tau(x) \geq \frac{c}{v}\right). \quad (32.18.185)$$

El beneficio incremental esperado de esta política sobre no tratar a nadie es

$$\Delta(\pi^*) = \mathbb{E}\left[\tau(X) \cdot \mathbf{1}\left(\tau(X) \geq \frac{c}{v}\right)\right] - \frac{c}{v} \cdot \mathbb{P}\left(\tau(X) \geq \frac{c}{v}\right). \quad (32.18.186)$$

Demostración.

El beneficio neto de tratar a un individuo con covariables $X = x$ es $v \cdot \tau(x) - c$. La política óptima asigna tratamiento si y solo si este beneficio neto es estrictamente positivo, es decir, $\tau(x) > \frac{c}{v}$. En el umbral $\tau(x) = \frac{c}{v}$, el beneficio neto es cero, por lo que la asignación es indiferente; la función indicadora $\mathbf{1}(\tau(x) \geq \frac{c}{v})$ resuelve esta indiferencia de manera conservadora. El beneficio incremental agregado es la esperanza del beneficio neto condicional a recibir tratamiento bajo π^* :

$$\Delta(\pi^*) = \int_{\{x: \tau(x) \geq \frac{c}{v}\}} (v \cdot \tau(x) - c) d\mathbb{P}_{X(x)}, \quad (32.18.187)$$

que, dividiendo por v , produce la expresión del enunciado. La linealidad de la esperanza justifica cada paso.

□

32.18.24 Capítulo 25: Series de Tiempo y Paneles**Teorema A.48 (Consistencia del SDID, Arkhangelsky et al. 2021)**

Supóngase que el resultado potencial sin tratamiento sigue un modelo de factores interactivos:

$$Y_{it}(0) = \alpha_i + \beta_t + \sum_{r=1}^R \gamma_{ir} \delta_{tr} + \epsilon_{it}, \quad (32.18.188)$$

donde ϵ_{it} es ruido idiosincrático con $\mathbb{E}[\epsilon_{it}] = 0$ e independiente del tratamiento. Si R es fijo y los pesos $\hat{\omega}_i, \hat{\lambda}_t$ convergen a pesos poblacionales que balancean los primeros R factores, entonces:

$$\hat{\tau}_{\{\text{SDID}\}} \xrightarrow{P} \tau_{\{\text{ATT}\}}, \quad (32.18.189)$$

cuando $N_{\{\text{tr}\}}, N_{\{\text{co}\}}, T_0 \rightarrow \infty$. Más aún, $\hat{\tau}_{\{\text{SDID}\}}$ es asintóticamente normal con varianza estimable mediante bootstrap por unidad (no por periodo, para preservar la estructura de dependencia).

Demostración.

Sea $L_{it} = \sum_{r=1}^R \gamma_{ir} \delta_{tr}$ el componente de rango bajo. Los pesos $\hat{\omega}_i$ se eligen para que $\sum_{i:D_i=0} \hat{\omega}_i \gamma_{ir} \approx \frac{1}{N_{\{tr\}}} \sum_{i:D_i=1} \gamma_{ir}$ para cada r , eliminando así el sesgo por factores no observados. Los pesos $\hat{\lambda}_t$ análogamente balancean δ_{tr} . El resultado se sigue del teorema de Abadie et al. (2010) sobre control sintético más el teorema de Beyhum et al. (2024) para DiD con factores interactivos. La doble ponderación asegura que el sesgo remanente es $o_P\left((N_{\{tr\}} T_0)^{-\frac{1}{2}}\right)$.

□

32.18.25 Capítulo 26: Off-Policy Evaluation**Proposición A.23 (Inssegamiento del IPS)**

Bajo soporte común e ignorabilidad, $\mathbb{E}[\hat{V}_{\{\text{IPS}\}}(\pi_e)] = V(\pi_e)$.

Demostración.

Por la ley de esperanzas iteradas y la definición de π_b :

$$\begin{aligned} \mathbb{E}\left[\frac{\pi_{e(A|X)}}{\pi_{b(A|X)}} Y\right] &= \mathbb{E}_X \left[\sum_a \pi_{b(a|X)} \cdot \frac{\pi_{e(a|X)}}{\pi_{b(a|X)}} \cdot \mathbb{E}[Y | X, A = a] \right] \\ &= \mathbb{E}_X \left[\sum_a \pi_{e(a|X)} \cdot \mathbb{E}[Y | X, A = a] \right] = V(\pi_e), \end{aligned} \quad (32.18.190)$$

donde la segunda igualdad usa la cancelación $\frac{\pi_b}{\pi_b} = 1$ dentro de la suma, justificada por el soporte común. La tercera igualdad es la definición de $V(\pi_e)$ bajo ignorabilidad.

□

Teorema A.49 (Doble robustez del DR-OPE, Dudík et al. 2011)

El estimador $\hat{V}_{\{\text{DR}\}}(\pi_e)$ es consistente para $V(\pi_e)$ si se cumple **al menos una** de las siguientes condiciones:

1. **Modelo de resultado correcto:** $\hat{Q}(x, a) \xrightarrow{P} Q_0(x, a) = \mathbb{E}[Y | X = x, A = a]$ para todo (x, a) .
2. **Modelo de propensity correcto:** $\hat{\pi}_{b(a|x)} \xrightarrow{P} \pi_{b(a|x)}$ para todo (x, a) .

Si ambos modelos son correctos, el estimador alcanza la cota de eficiencia semiparamétrica.

Demostración.

Definamos la función de influencia aumentada:

$$\psi(W, V, Q, \pi_b) = \sum_a \pi_{e(a|X)} Q(X, a) + \frac{\pi_{e(A|X)}}{\pi_{b(A|X)}} (Y - Q(X, A)) - V. \quad (32.18.191)$$

Cuando $Q = Q_0$ (modelo de resultado correcto), se tiene $\mathbb{E}[Y - Q_0(X, A) | X, A] = 0$, por lo que $\mathbb{E}[\psi] = V(\pi_e) - V$ independientemente de π_b . Cuando π_b es correcto, se tiene:

$$\mathbb{E}\left[\frac{\pi_{e(A|X)}}{\pi_{b(A|X)}} (Y - Q(X, A)) | X\right] = \sum_a \pi_{e(a|X)} (Q_0(X, a) - Q(X, a)), \quad (32.18.192)$$

que cancela exactamente el sesgo de $\sum_a \pi_{e(a|X)} Q(X, a)$ frente a $\sum_a \pi_{e(a|X)} Q_0(X, a)$. En cualquier caso, $\mathbb{E}[\psi(W, V(\pi_e), \cdot, \cdot)] = 0$, lo que garantiza la consistencia del estimador basado en la ecuación de momento

$$\frac{1}{n} \sum_i \psi(W_i, \hat{V}, \hat{Q}, \hat{\pi}_b) = 0.$$

□

Proposición A.24 (Política óptima como función del CATE)

Bajo ignorabilidad y tratamiento binario con costo c y valor marginal v , la política que maximiza el valor esperado neto es:

$$\pi^*(x) = \mathbf{1}\left(\tau(x) \geq \frac{c}{v}\right), \quad (32.18.193)$$

donde $\tau(x) = \mathbb{E}[Y^1 - Y^0 \mid X = x]$ es el CATE. El valor de esta política es:

$$V(\pi^*) = \mathbb{E}[Y^0] + \mathbb{E}\left[\left(\tau(X) - \frac{c}{v}\right) \cdot \mathbf{1}\left(\tau(X) \geq \frac{c}{v}\right)\right] \cdot v. \quad (32.18.194)$$

Demostración.

El valor de una política π es $V(\pi) = \mathbb{E}[Y^0] + \mathbb{E}[\pi(X) \cdot \tau(X)]$. Incorporando el costo, el beneficio neto es $v \cdot V(\pi) - c \cdot \mathbb{E}[\pi(X)]$. Maximizar esta expresión punto a punto conduce a $\pi^*(x) = \mathbf{1}(v \cdot \tau(x) - c \geq 0)$. Sustituyendo en la fórmula del valor se obtiene la expresión declarada. $\square$

32.18.26 Capítulo 27: Representaciones Causales**Teorema A.50 (IRM recupera causas en el caso lineal, Arjovsky et al. 2019)**

Considérese el modelo generativo lineal:

$$Y = X_S^\top \gamma + \epsilon, \quad \epsilon \perp\!\!\!\perp X_S, \quad (32.18.195)$$

donde $S \subseteq \{1, \dots, p\}$ es el conjunto de causas de Y (padres en el DAG). Sean los entornos $e \in \mathcal{E}_{\text{tr}}$ tales que $\text{Var}_{P^e}(X_S)$ varía entre entornos pero γ es invariante. Supóngase que $\Phi(X) = X$ (representación identidad) y $w \in \mathbb{R}^p$. Entonces, para $\lambda > 0$ suficientemente grande, la solución de IRMv1 satisface:

$$\text{supp}(\hat{w}) \subseteq S, \quad (32.18.196)$$

es decir, IRM asigna peso cero a las variables que no son causas de Y , recuperando el conjunto causal con alta probabilidad.

Demostración.

Sea $w \in \mathbb{R}^p$ un vector de pesos. El gradiente del riesgo cuadrático respecto a un escalar multiplicativo es proporcional a $\mathbb{E}_{P^e}[(Y - X^\top w)X^\top w]$. Para que este gradiente sea cero en todos los entornos simultáneamente, se requiere que $\mathbb{E}_{P^e}[YX_j] = \mathbb{E}_{P^e}[(X^\top w)X_j]$ para todo j y todo e . Si $j \notin S$, entonces $X_j \perp\!\!\!\perp Y \mid X_S$, y la variación de $\text{Var}(X_S)$ entre entornos fuerza que $w_j = 0$ para satisfacer la condición en todos los entornos. Los detalles técnicos involucran la invertibilidad de la matriz de covarianzas de X_S y la independencia lineal de las distribuciones de X_S entre entornos. $\square$

32.18.27 Capítulo 30: Agentes Semi Determinísticos**Teorema A.51 (Consistencia del ASCSD bajo CSDC)**

Si el DAG $\mathcal{G}$ es correcto y el actualizador $\mathcal{U}$ es consistente, entonces la política π_t del ASCSD converge a la política causal óptima π^* cuando $n \rightarrow \infty$:

$$\pi_t \xrightarrow{a.s.} \pi^* \quad \text{cuando} \quad t \rightarrow \infty, \quad (32.18.197)$$

donde $\pi^*(s) = \text{argmax}_a \mathbb{E}[Y \mid \text{do}(A = a), s; \mathcal{G}^*]$ y $\mathcal{G}^*$ es el DAG verdadero.

Demostración.

Por la consistencia de $\mathcal{U}$, los mecanismos estimados $\hat{f}_i \xrightarrow{a.s.} f_i^*$ para cada nodo. Por la continuidad del operador argmax , la política determinística derivada de los mecanismos estimados converge a la derivada de los mecanismos verdaderos. La CSDC garantiza que no hay fuente adicional de variabilidad en la ejecución que pueda romper esta convergencia.

□

32.18.28 Nota sobre la cobertura de demostraciones

El Apéndice de Demostraciones reúne pruebas formales de resultados seleccionados de los capítulos del cuerpo monográfico. La cobertura actual incluye demostraciones para los capítulos 1–11, 13–27 y 30.

Los capítulos **sin** demostraciones formales en este apéndice son:

1. **Capítulo 12** (guía de selección de métodos): carácter sintético y de decisión; no introduce teoremas primarios nuevos.
2. **Capítulos 28, 29, 31 y 32** (RL causal, arquitecturas de IA, equidad, hoja de ruta): fronteras aplicadas y de agenda; los resultados formales se citan de la literatura primaria y se discuten en el cuerpo.

Esta declaración evita la impresión de un apéndice “completo al 100%” cuando el volumen prioriza, en esos capítulos, la síntesis monográfica y la conexión con la investigación abierta.

Bibliografía seleccionada

Esta lista reúne las referencias **centrales** de la monografía, agrupadas por función en el argumento GCE. Las bibliografías al final de cada capítulo conservan lecturas especializadas adicionales; aquí se prioriza un núcleo compartido para el lector de posgrado.

32.19 Fundamentos de resultados potenciales e identificación

- Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics*. Princeton University Press.
- Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.
- Holland, P. W. (1986). Statistics and causal inference. *Journal of the American Statistical Association*, 81(396), 945–960.
- Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- Rubin, D. B. (1974). Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, 66(5), 688–701.

32.20 Diseños y estimandos clásicos (Nivel 1)

- Abadie, A. (2021). Using synthetic controls. *Journal of Economic Literature*, 59(2), 391–425.
- Angrist, J. D., Imbens, G. W., & Rubin, D. B. (1996). Identification of causal effects using instrumental variables. *JASA*, 91(434), 444–455.
- Callaway, B., & Sant’Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200–230.
- Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254–277.
- Imbens, G. W., & Angrist, J. D. (1994). Identification and estimation of local average treatment effects. *Econometrica*, 62(2), 467–475.
- Imbens, G. W., & Lemieux, T. (2008). Regression discontinuity designs: A guide to practice. *Journal of Econometrics*, 142(2), 615–635.
- McCrary, J. (2008). Manipulation of the running variable in the RDD. *Journal of Econometrics*, 142(2), 698–714.
- Rosenbaum, P. R., & Rubin, D. B. (1983). The central role of the propensity score. *Biometrika*, 70(1), 41–55.

32.21 Grafos, SCM y do-cálculo (Nivel 2 / Pearl)

- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.
- Pearl, J., & Mackenzie, D. (2018). *The Book of Why*. Basic Books.
- Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of Causal Inference*. MIT Press.
- Shpitser, I., & Pearl, J. (2006). Identification of joint interventional distributions in recursive semi-Markovian causal models. *AAAI*.
- Spirtes, P., Glymour, C., & Scheines, R. (2000). *Causation, Prediction, and Search* (2nd ed.). MIT Press.

32.22 Transporte óptimo y geometría (Nivel 3 / GCE)

- Cheridito, P., & Eckstein, S. (2025). Optimal transport and Wasserstein distances for causal models. *Bernoulli*, 31(2), 1351–1376. ⚠
- Galichon, A. (2016). *Optimal Transport Methods in Economics*. Princeton University Press.
- Villani, C. (2009). *Optimal Transport: Old and New*. Springer. ⚠ (números de teorema del cap. 6 sujetos a cotejo de edición)

32.23 Aprendizaje automático causal y heterogeneidad

- Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized random forests. *Annals of Statistics*, 47(2), 1148–1178.
- Chernozhukov, V., et al. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
- Künnel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B. (2019). Metalearners for estimating heterogeneous treatment effects. *PNAS*, 116(10), 4156–4165.
- Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *JASA*, 113(523), 1228–1242.

32.24 Sensibilidad, equidad e IA causal

- Bareinboim, E. (2025). *Causal Artificial Intelligence*. Wiley-IEEE Press.
- Kusner, M. J., Loftus, J., Russell, C., & Silva, R. (2017). Counterfactual fairness. *NeurIPS*.
- Schölkopf, B., et al. (2021). Toward causal representation learning. *Proceedings of the IEEE*, 109(5), 612–634.
- VanderWeele, T. J., & Ding, P. (2017). Sensitivity analysis in observational research: Introducing the E-value. *Annals of Internal Medicine*, 167(4), 268–274.

Nota. Las marcas ⚠ recuerdan deudas de cotejo de número de teorema o hipótesis exactas frente a la fuente primaria (véase también el material en `gce/artifacts/cotejo_*.md` del repositorio del curso). No invalidan el uso pedagógico de las desigualdades y dualidades clásicas empleadas en el cuerpo.