

Geometría de la Causalidad Estadística

Una jerarquía de funcionales de discrepancia para efectos de tratamiento

Jaime Lincovil

Universidad Nacional de Ingeniería (UNI) · Lima, Perú
Maestría en Ciencias e Ingeniería Estadística · DES504 · 2026

Resumen. Bajo SUTVA, toda pregunta causal se formula como la evaluación de un funcional de discrepancia no negativo $\tau_{\mathcal{D}} = \mathcal{D}(P_{Y(1)}, P_{Y(0)})$. Distintas elecciones de $\mathcal{D}$ definen tres niveles de la **Geometría de la Causalidad Estadística** (GCE): localización ($\mathcal{D}_{\text{loc}} = |\tau_{\text{ATE}}|$), forma (divergencias f) y geometría (W_1 y su refinamiento causal $W^{G,1}$). Introducimos un scorecard axiomático (separación, costo de reasignación, soporte disjunto y estabilidad Lipschitz marginal vs. intervencional) y demostramos la **cadena maestra**

$$|\tau_{\text{ATE}}| \leq W_1(P_{Y(1)}, P_{Y(0)}) \leq W^{G,1}(P_{Y(1)}, P_{Y(0)}). \quad (1)$$

Corregimos puentes inter-nivel erróneos frecuentes, los sustituimos por identidades de Pinsker y de transporte óptimo, y aislamos la **Paradoja del Efecto Cero**: $\tau_{\text{ATE}} = 0$ con $W_1 > 0$. Una cota inferior vía dualidad de Kantorovich–Rubinstein y la desigualdad de Jensen, junto con un experimento numérico reproducible (semilla 42), hacen operativa la jerarquía. El marco provee el esqueleto matemático del libro DES504 y un contrato de coherencia para pipelines que reportan resúmenes de localización, forma y transporte.

Palabras clave: inferencia causal; ATE; distancia de Wasserstein; divergencias f ; transporte óptimo; efectos distribucionales; paradoja del efecto cero.

MSC 2020: 62D20, 62G05, 49Q22, 60E15. · **JEL:** C21, C14.

1 Introducción

La inferencia causal contemporánea habla varios dialectos a la vez: resultados potenciales [1], [2], modelos estructurales y do-cálculo [3], semiparamétrica y *double machine learning* [4], y, más recientemente, transporte óptimo aplicado a efectos distribucionales [5], [6]. Cada tradición resuelve bien su pregunta canónica, pero la fragmentación oscurece una observación elemental: **toda** comparación causal entre un mundo tratado y un mundo de control es, en última instancia, una comparación entre las leyes contrafactuales $P_{Y(1)}$ y $P_{Y(0)}$.

Formalizamos esa observación. Bajo el supuesto de valor de tratamiento estable por unidad (SUTVA; [2], Assumption 1.1), definimos

$$\tau_{\mathcal{D}} := \mathcal{D}(P_{Y(1)}, P_{Y(0)}), \quad \mathcal{D} \geq 0, \quad (2)$$

y llamamos **Geometría de la Causalidad Estadística** (GCE) a la jerarquía inducida por la elección de $\mathcal{D}$:

Nivel	Pregunta	$\mathcal{D}$
-------	----------	---------------

1 · Localización	¿Cambió el centro?	$\mathcal{D}_{\text{loc}} = \tau_{\text{ATE}} $
2 · Forma	¿Cambió la distribución?	D_f (KL, TV, χ^2 , ...)
3 · Geometría	¿Cuál es el costo del cambio?	W_1 y $W^{G,1}$

La columna vertebral del marco es la **cadena maestra**

$$|\tau_{\text{ATE}}| \leq W_1(P_{Y(1)}, P_{Y(0)}) \leq W^{G,1}(P_{Y(1)}, P_{Y(0)}), \quad (3)$$

que sitúa el efecto medio como la parte del costo de transporte atribuible a un desplazamiento rígido, y deja en la brecha $W_1 - |\tau_{\text{ATE}}| \geq 0$ la reestructuración interna invisible al promedio. Esa brecha hace posible —y no contradictoria— la **Paradoja del Efecto Cero**: $\tau_{\text{ATE}} = 0$ con $W_1 \gg 0$.

1.0.1 Contribuciones

1. **Marco unificado** $\tau_{\mathcal{D}}$ con Precondición estructural (grafo $\mathcal{G}$, Markov, fidelidad) como condición de **aplicabilidad**, no como un “nivel métrico” adicional.
2. **Sistema axiomático** con Axiomas 1–3 clásicos y Axioma 4 reformulado como estabilidad Lipschitz de **clases de funcionales** (4a marginal; 4b intervencional), corrigiendo la confusión entre W_1 y $W^{G,1}$ respecto de la convergencia débil.
3. **Cadena maestra** Ecuación 3 y corolarios de lectura (nulidad, direccionalidad de las implicaciones, igualdad bajo traslación pura).
4. **Puentes inter-nivel correctos**: identidad gaussiana y Pinsker ($N1 \rightarrow N2$); TV como Wasserstein con métrica trivial y cota por diámetro ($N2 \rightarrow N3$); no-dominancia general entre D_f y W_1 .
5. **Paradoja del Efecto Cero** con cota inferior vía dualidad KR + Jensen, independiente de σ , y experimento numérico canónico reproducible.

No reclamamos originalidad sobre la dualidad de Kantorovich–Rubinstein ni sobre la teoría general de f -divergencias; las usamos como lemas. La contribución es el **empaquete causal**, los puentes corregidos y la lectura axiomática orientada a funcionales de tratamiento.

Extendemos la misma honestidad a la **Paradoja del Efecto Cero**: que $\tau_{\text{ATE}} = 0$ no implique $P_{Y(1)} = P_{Y(0)}$ es un hecho conocido y central en la literatura de efectos distribucionales¹. Lo nuevo aquí no es que el promedio oculte heterogeneidad —eso ya se sabía—, sino: (a) el empaque axiomático 4a/4b que separa estabilidad marginal de estabilidad intervencional; (b) la cadena maestra con su caso de igualdad como **descomposición** explícita entre desplazamiento rígido y reestructuración interna; y (c) la corrección de los puentes inter-nivel que la literatura aplicada reproduce con frecuencia de forma errónea (Apéndice A).

1.0.2 Organización

La §2 fija el setup. La §3 define los tres niveles. La §4 enuncia los axiomas y el scorecard. La §5 contiene la cadena maestra y los puentes. La §6 desarrolla la paradoja. La §7 reporta el experimento. La §8 esboza implicaciones para la práctica. La §9 discute limitaciones. El Apéndice recoge contraejemplos de cotas falsas y detalles de reproducibilidad.

¹Doksum [7]; Heckman, Smith & Clements [8]; Chernozhukov, Fernández-Val & Melly [9]; y el propio [10] ya citado. Metadatos de [7], [8] y [9] marcados ⚠ pendientes de cotejo bibliográfico primario, con el mismo estándar de cautela que [11] y [12] en este manuscrito.

2 Setup: resultados potenciales y el objeto $\tau_{\mathcal{D}}$

2.1 Resultados potenciales y SUTVA

Consideramos una población de unidades y un tratamiento binario $T \in \{0, 1\}$. Cada unidad posee resultados potenciales $Y(1), Y(0) \in \mathcal{Y} \subseteq \mathbb{R}$ [1], [13]. Escribimos $P_{Y(t)}$ para la ley poblacional de $Y(t)$.

Definición 1 (SUTVA). Adoptamos SUTVA en la forma de [2, Assumption 1.1]: (i) no interferencia entre unidades; (ii) una única versión de cada nivel de tratamiento. Bajo SUTVA, $Y(1)$ e $Y(0)$ —y por tanto $P_{Y(1)}, P_{Y(0)}$ — están bien definidos como objetos poblacionales.

El efecto medio del tratamiento es

$$\tau_{\text{ATE}} := E[Y(1)] - E[Y(0)] = \int y dP_{Y(1)}(y) - \int y dP_{Y(0)}(y). \quad (4)$$

Su signo es información **direccional**. Para insertarlo en una jerarquía de discrepancias no negativas definimos la instancia axiomática del Nivel 1:

Definición 2 (Discrepancia de localización).

$$\mathcal{D}_{\text{loc}}(P, Q) := |E_{P[Y]} - E_{Q[Y]}|. \quad (5)$$

En particular, $\mathcal{D}_{\text{loc}}(P_{Y(1)}, P_{Y(0)}) = |\tau_{\text{ATE}}|$.

2.2 El funcional de discrepancia causal

Definición 3 (Pregunta causal como discrepancia). Fijada una discrepancia $\mathcal{D} : \mathcal{P}(\mathcal{Y}) \times \mathcal{P}(\mathcal{Y}) \rightarrow [0, +\infty]$, la pregunta causal asociada es $\tau_{\mathcal{D}}$ en Ecuación 2. La elección de $\mathcal{D}$ determina el nivel GCE.

2.3 Precondición estructural

La jerarquía opera condicionada a un grafo causal $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ conocido o asumido (diseño experimental, teoría de dominio o consenso disciplinar), junto con:

- la **condición de Markov causal** (factorización de la ley observacional según $\mathcal{G}$; [14], Thm. 6.52 bajo independencia de mecanismos);
- la **fidelidad**: independencia en P implica d-separación en $\mathcal{G}$ ([14], Def. 6.33), **recíproca** de la soundness de la d-separación.

Observación 1 (La Precondición no es un nivel). La Precondición es la **condición de aplicabilidad** de los niveles 1–3. Su producto ($\hat{\mathcal{G}}$ validado, o una distribución sobre estructuras) alimenta la identificación en N1–N2 y la métrica $W^{G,1}$ en N3, que consume $\mathcal{G}$ en su definición. Los algoritmos de descubrimiento (PC, GES, LiNGAM, ...) pertenecen a esa fase lógica, no a la métrica de discrepancia.

Para identificación del ATE en datos observacionales recordamos, en la notación de [15]: consistencia, exchangeability condicional $Y_a \perp A \mid L$ y positividad $f[a \mid l] > 0$ siempre que $\Pr[L = l] > 0$.

3 Los tres niveles

3.1 Nivel 1: localización

Definición 4 (Nivel 1). El Nivel 1 responde: **¿cambió el centro?** Su objeto es τ_{ATE} (Ecuación 4) y su discrepancia axiomática es $\mathcal{D}_{\text{loc}} = |\tau_{\text{ATE}}|$.

Limitación definitoria (ceguera estructural). $\tau_{\text{ATE}} = 0$ no implica $P_{Y(1)} = P_{Y(0)}$. Toda transformación que preserve la media (polarización, bimodalización, cambio de varianza) es invisible en este nivel. Esa ceguera es exactamente la violación del Axioma 1 (Separación) en la §4.

3.2 Nivel 2: forma

Definición 5 (Divergencias f). Sea $f : (0, \infty) \rightarrow \mathbb{R}$ convexa con $f(1) = 0$. La divergencia f [16] es

$$D_f(P \parallel Q) := \int f\left(\frac{dP}{dQ}\right) dQ, \quad (6)$$

cuando $P \ll Q$, y $+\infty$ en caso contrario. Casos: KL ($f(t) = t \log t$), TV ($f(t) = \frac{1}{2} |t - 1|$), χ^2 ($f(t) = (t - 1)^2$).

El Nivel 2 responde: **¿cambió la distribución completa?** Gana sensibilidad a colas, varianza y multimodalidad (Axioma 1 ✓), pero en general: no interpreta un **costo** en unidades de Y (Axioma 2 ✗), exige absolutas continuidad o devuelve ∞ (Axioma 3 ✗) y es inestable bajo convergencia débil (Axioma 4a ✗). Para estimación variacional de D_f , véase [17]. Los efectos cuantílicos [10] y los análisis de f -sensibilidad [18] son instancias aplicadas del Nivel 2.

3.3 Nivel 3: geometría

Sea $(\mathcal{Y}, d)$ un espacio polaco y $\mathcal{P}_1(\mathcal{Y})$ el conjunto de probabilidades con primer momento finito.

Definición 6 (Wasserstein-1). Para $P, Q \in \mathcal{P}_1(\mathcal{Y})$,

$$W_1(P, Q) := \inf_{\gamma \in \Gamma(P, Q)} \int d(x, y) d\gamma(x, y), \quad (7)$$

donde $\Gamma(P, Q)$ es el conjunto de acoplamientos con marginales P y Q . En $\mathcal{Y} = \mathbb{R}$ con $d(x, y) = |x - y|$ usamos la misma notación.

Lema 1 (Dualidad de Kantorovich–Rubinstein). En un espacio polaco,

$$W_1(P, Q) = \sup_{\|f\|_{\text{Lip}} \leq 1} (E_{P[f]} - E_{Q[f]}), \quad (8)$$

donde $\|f\|_{\text{Lip}}$ es la constante de Lipschitz de f [11], [19].

Nota de cautela. El acoplamiento óptimo no identifica la conjunta contrafactual. $\Gamma(P_{Y(1)}, P_{Y(0)})$ es el conjunto de **todas** las leyes conjuntas contrafactuales admisibles —el objeto no identificado del problema fundamental de la inferencia causal (Holland, 1986)—. El transporte

óptimo selecciona, dentro de ese conjunto, el acoplamiento de **costo mínimo**: una selección geométrica, no causal. En particular:

1. La ley del efecto individual $\Delta := Y(1) - Y(0)$ sigue sin identificarse a partir de $P_{Y(1)}, P_{Y(0)}$ solas; lo honesto es reportar cotas de Makarov para su distribución, no leerla del acoplamiento óptimo.
2. En $\mathbb{R}$, el acoplamiento óptimo de W_1 es el **comonotónico** ($Y(1) = F_1^{-1}(F_0(Y(0)))$), que es precisamente el que **minimiza** $\text{Var}(\Delta)$ entre todos los acoplamientos posibles: el escenario más benigno imaginable. Tratarlo como la asignación real sesga sistemáticamente hacia **subestimar** el daño (o la heterogeneidad) del tratamiento.

Este punto es relevante para cualquier lectura distributiva o de equidad de la jerarquía (§8): el costo de transporte cuantifica **reestructuración agregada**, no destinos individuales.

Teorema 1 (Identidad cuantílica de W_1 en $\mathbb{R}$). Para $P, Q \in \mathcal{P}_1(\mathbb{R})$ con funciones cuantílicas F^{-1}, G^{-1} ,

$$W_1(P, Q) = \int_0^1 |F^{-1}(\theta) - G^{-1}(\theta)| d\theta = \int_{\mathbb{R}} |F(x) - G(x)| dx. \quad (9)$$

En particular, si $P = P_{Y(1)}$, $Q = P_{Y(0)}$ y $\text{QTE}(\theta) := F_1^{-1}(\theta) - F_0^{-1}(\theta)$ es el proceso de efectos de tratamiento cuantílico [10], entonces

$$\tau_{\text{ATE}} = \int_0^1 \text{QTE}(\theta) d\theta, \quad W_1 = \int_0^1 |\text{QTE}(\theta)| d\theta. \quad (10)$$

Demostración. El acoplamiento comonotónico $(F^{-1}(U), G^{-1}(U))$ con $U \sim \text{Unif}(0, 1)$ es óptimo para W_1 en $\mathbb{R}$ (Hardy–Littlewood, vía reordenamiento; [11, cap. 2], [19, cap. 2]), lo que da la primera igualdad. La segunda ($\int_0^1 |F^{-1} - G^{-1}| = \int_{\mathbb{R}} |F - G|$) es el cambio de variable estándar entre representación cuantílica y de área entre CDFs, válido por Fubini para funciones de distribución. La lectura de Ecuación 10 sigue de tomar $f(y) = y$ en Ecuación 9 sin valor absoluto para $\tau_{\text{ATE}} = \int (F_1^{-1} - F_0^{-1})$. ■

Observación 2 (Los tres niveles como un solo objeto). Ecuación 10 unifica la jerarquía en una sola imagen: el **Nivel 1** es el valor absoluto de la integral del proceso QTE; el **Nivel 3** es la integral del valor absoluto. La cadena maestra $|\tau_{\text{ATE}}| \leq W_1$ es entonces la desigualdad triangular $|\int g| \leq \int |g|$ aplicada a $g = \text{QTE}$. Y la **Paradoja del Efecto Cero** es exactamente el fenómeno de **cancelación**: una integral cuyo integrando cambia de signo puede anularse mientras su valor absoluto integrado —el costo real de reasignación— permanece grande. Verificado contra el experimento canónico (semilla 42, Tabla 6): la norma L^1 empírica del proceso QTE reproduce $W_1 \approx 6.050$ y su integral con signo reproduce $\tau_{\text{ATE}} \approx -0.137$.

En dimensión uno, W_1 es entonces la norma L^1 del proceso de efectos cuantílicos: el Nivel 3 unidimensional es la integración del Nivel 2 cuantílico.

3.3.1 Refinamiento causal $W^{G,1}$

Comparar solo marginales de Y no controla la estabilidad de funcionales que dependen de **condicionales** a lo largo de $\mathcal{G}$ (efectos do, CATE, valores de políticas secuenciales). La literatura de transporte adaptado y bicausal [20], [21] y su extensión a modelos causales [12] motiva restringir los acoplamientos.

Definición 7 (Acoplamientos bicausales y $W^{G,1}$). Sea $\Pi_G^{\text{bc}}(\mu, \nu)$ el conjunto de acoplamientos bicausales de μ, ν respecto de la filtración inducida por $\mathcal{G}$ (definición operativa alineada a [12]). Definimos

$$W^{G,1}(\mu, \nu) := \inf_{\pi \in \Pi_G^{\text{bc}}(\mu, \nu)} \int \|x - y\| d\pi(x, y). \quad (11)$$

Como $\Pi_G^{\text{bc}}(\mu, \nu) \subseteq \Gamma(\mu, \nu)$, se tiene siempre

$$W^{G,1}(\mu, \nu) \geq W_1(\mu, \nu). \quad (12)$$

3.3.2 La violación de 4b por W_1 es autocontenida

La mitad **negativa** del Axioma 4b —que W_1 falla como cota de estabilidad para funcionales intervencionales— no requiere las hipótesis de [12]: es demostrable con un contraejemplo elemental.

Proposición 1 (Discontinuidad intervencional de W_1). Sobre el DAG $X \rightarrow Y$, sean

$$\mu_n : X \sim \text{Unif}\left\{-\frac{1}{n}, +\frac{1}{n}\right\}, \quad Y = \text{signo}(X), \quad (13)$$

$$\mu : X \equiv 0, \quad Y \sim \text{Unif}\{-1, +1\} \quad (\text{independiente de } X). \quad (14)$$

Entonces $W_1(\mu_n, \mu) = \frac{1}{n} \rightarrow 0$ cuando $n \rightarrow \infty$, mientras que

$$|E_{\mu_n}[Y \mid \text{do}(X = \frac{1}{n})] - E_\mu[Y \mid \text{do}(X = 0)]| = 1 \quad \text{para todo } n. \quad (15)$$

Por tanto no existe $L < \infty$ que haga Lipschitz a los funcionales intervencionales respecto de W_1 : W_1 viola el Axioma 4b.

Demostración. Convergencia. Acóplese $(1/n, +1)$ con $(0, +1)$ y $(-1/n, -1)$ con $(0, -1)$; el costo de cada rama es $|1/n - 0| + |\pm 1 - (\pm 1)| = 1/n$, luego $W_1(\mu_n, \mu) \leq 1/n$. Es también el mínimo entre las dos correspondencias posibles de dos átomos con dos átomos (la alternativa cuesta $1/n + 2$), de modo que $W_1(\mu_n, \mu) = 1/n$.

Divergencia intervencional. Bajo μ_n , el mecanismo de Y es determinista: $\text{do}(X = 1/n)$ da $Y = \text{signo}(1/n) = 1$. Bajo μ , el mecanismo de Y ignora a X : $\text{do}(X = 0)$ da $E_\mu[Y] = 0$ (por simetría de $\text{Unif}\{-1, +1\}$). La diferencia es $|1 - 0| = 1$, constante en n , mientras $W_1(\mu_n, \mu) \rightarrow 0$. ■

Observación 3 (Por qué esto obliga a restringir el acoplamiento, no el costo). El acoplamiento óptimo que logra $W_1(\mu_n, \mu) = 1/n$ empareja $(1/n, +1)$ con $(0, +1)$ —decide a qué copia de $X = 0$ enviar la masa mirando el **valor de Y** que ya trae consigo—. Ningún mecanismo causal genuino puede hacer eso: la intervención fija X **antes** de que Y se determine, y el emparejamiento por valor de Y usa información del efecto para decidir el transporte de la causa. Esto es exactamente lo que Π_G^{bc} prohíbe al exigir que el acoplamiento sea **adaptado** a la filtración de $\mathcal{G}$: primero se acoplan las marginales de X , y solo **después**, condicionalmente y sin mirar hacia adelante, se acoplan las leyes de Y dado X .

Proposición 2 (Contraparte positiva: $W^{G,1}$ sí acota la brecha intervencional). Para μ_n, μ como arriba, $W^{G,1}(\mu_n, \mu) = 1/n + 1 \rightarrow 1$.

Demostración. Por programación dinámica hacia atrás sobre las dos etapas de Π_G^{bc} : (i) la marginal de X bajo μ es degenerada en 0, así que el acoplamiento de marginales está forzado y cuesta $|1/n - 0| = 1/n$ en cada rama; (ii) condicionalmente a X , hay que acoplar $Y_n = \text{signo}(1/n)$ (determinista) con $Y \sim \text{Unif}\{-1, +1\}$ **sin** usar información de la otra rama —el costo de esa cópula 1-D es $E|c - Y| = 1$ para $c \in \{\pm 1\}$ —. Sumando, $W^{G,1}(\mu_n, \mu) = 1/n + 1$. ■

n	W_1	$W^{G,1}$	Brecha intervencional
2	0.5000	1.5000	1.0
10	0.1000	1.1000	1.0
100	0.0100	1.0100	1.0
1000	0.0010	1.0010	1.0

Tabla 1: Verificación numérica: $W_1 \rightarrow 0$ mientras $W^{G,1}$ converge a la brecha intervencional real (= 1).

Nota de cautela. El ejemplo anterior demuestra, sin apelar a [12], que W_1 viola el Axioma 4b. Lo que permanece condicionado a las hipótesis (H) de [12] es únicamente la afirmación **general y positiva**: que $W^{G,1}$ satisface 4b para **toda** clase de funcionales intervencionales de interés (no solo en este ejemplo). Ninguna otra afirmación de este paper depende ya de la forma exacta de (H).

4 Axiomas de una discrepancia causal ideal

Una discrepancia $\mathcal{D}$ ideal para comparación causal debería satisfacer:

Axioma 1 (Separación). $\mathcal{D}(P, Q) = 0$ si y solo si $P = Q$.

Axioma 2 (Costo de reasignación). $\mathcal{D}$ cuantifica, en unidades de la variable resultado, el trabajo mínimo para transformar P en Q .

Axioma 3 (Robustez a soporte disjunto). $\mathcal{D}$ está bien definida y es finita (bajo momentos finitos) incluso cuando $P \perp Q$.

Axioma 4 (Estabilidad de funcionales causales). Para una clase $\mathcal{T}$ de funcionales causales de interés, existe $L < \infty$ tal que

$$|T(P) - T(Q)| \leq L \cdot \mathcal{D}(P, Q) \quad \forall T \in \mathcal{T}. \quad (16)$$

El Axioma 4 se desdobla según $\mathcal{T}$:

- **Axioma 4a (estabilidad marginal).** $\mathcal{T}$ = funcionales de las marginales $P_{Y(1)}, P_{Y(0)}$ (medias, cuantiles, funcionales Lipschitz). La dualidad KR implica que W_1 lo satisface con $L = \|f\|_{\text{Lip}}$.

- **Axioma 4b (estabilidad intervencional).** $\mathcal{T}$ = funcionales que dependen de condicionales dados los padres en $\mathcal{G}$ (efectos do, CATE, valores de políticas). W_1 **no** lo satisface en general; $W^{G,1}$ lo garantiza bajo (H) [12].

Observación 4 (Por qué reformular el Axioma 4). Enunciar el Axioma 4 como “continuidad respecto de la convergencia débil” atribuye las propiedades al revés: W_1 **metriza** la convergencia débil en $\mathcal{P}_1$ ([11], cap. 6), mientras que las distancias bicausales inducen una topología **estrictamente más fina** y por tanto no son continuas respecto de la topología débil ordinaria. Además, el ATE ya es 1-Lipschitz respecto de W_1 (tomar $f(y) = y$ en KR); no es el ejemplo motivador de $W^{G,1}$.

4.1 Scorecard de completitud

Axioma	$ \tau_{\text{ATE}} $	D_f	W_1	$W^{G,1}$
1. Separación	$\times$	$\checkmark$	$\checkmark$	$\checkmark$
2. Costo	$\times^2$	$\times$	$\checkmark$	$\checkmark$ restr.
3. Soporte disjunto	$\checkmark$	$\times$	$\checkmark$	$\checkmark$
4a. Estab. marginal	$\checkmark$	$\times$	$\checkmark$	$\checkmark$
4b. Estab. intervencional	$\times$	$\times$	$\times$	$\checkmark$ ⚠

Tabla 2: Evaluación axiomática de las discrepancias de la jerarquía GCE. La marca ⚠ indica dependencia de hipótesis (H) en [12].

Teorema 2 (Compleitud geométrica (lectura axiomática)). W_1 satisface los Axiomas 1, 2, 3 y 4a. Bajo (H), $W^{G,1}$ satisface además el Axioma 4b. La superioridad de $W^{G,1}$ sobre W_1 es de **topología causal** (filtración de $\mathcal{G}$), no de metrización de la convergencia débil.

5 Cadena maestra y puentes entre niveles

5.1 De N3 a N1: la cadena maestra

Teorema 3 (Cadena maestra). Sean $P_{Y(1)}, P_{Y(0)} \in \mathcal{P}_1(\mathbb{R})$. Entonces

$$|\tau_{\text{ATE}}| \leq W_1(P_{Y(1)}, P_{Y(0)}) \leq W^{G,1}(P_{Y(1)}, P_{Y(0)}). \quad (17)$$

Demostración. Primera desigualdad. La función $f(y) = y$ es 1-Lipschitz en $\mathbb{R}$. Por dualidad KR,

$$W_1(P_{Y(1)}, P_{Y(0)}) \geq E_{P_{Y(1)}}[Y] - E_{P_{Y(0)}}[Y] = \tau_{\text{ATE}}. \quad (18)$$

Aplicando el mismo argumento a $-f$ se obtiene $W_1 \geq -\tau_{\text{ATE}}$, y por tanto $W_1 \geq |\tau_{\text{ATE}}|$.

Segunda desigualdad. Sigue de $\Pi_G^{\text{bc}} \subseteq \Gamma$ y de la definición de $W^{G,1}$ como ínfimo sobre un conjunto más pequeño (Ecuación 12). ■

Corolario 1 (Lectura lógica).

²Coincide con el costo óptimo solo bajo traslación pura (Corolario de igualdad en §5).

1. $W_1 = 0 \Rightarrow \tau_{\text{ATE}} = 0$.
2. Si $|\tau_{\text{ATE}}|$ es grande, entonces W_1 es grande. **El recíproco es falso:** es posible $\tau_{\text{ATE}} \approx 0$ con $W_1 \gg 0$ (Paradoja del Efecto Cero, §6).
3. **Redacción de cotas.** W_1 es una **cota superior** de $|\tau_{\text{ATE}}|$; equivalentemente, $|\tau_{\text{ATE}}|$ es una **cota inferior** de W_1 . No se dirá jamás que “ W_1 provee una cota inferior para el ATE”.

Corolario 2 (Igualdad bajo traslación pura). Si $Y(1) \stackrel{d}{=} Y(0) + c$ con $c \in \mathbb{R}$ fijo, entonces

$$W_1(P_{Y(1)}, P_{Y(0)}) = |c| = |\tau_{\text{ATE}}|. \quad (19)$$

En general, la brecha $W_1 - |\tau_{\text{ATE}}| \geq 0$ cuantifica la **reestructuración interna** (cambios de forma y soporte) invisible al Nivel 1.

Demostración. Bajo traslación pura el acoplamiento óptimo es $(Y(0), Y(0) + c)$ y el costo medio es $|c|$. La igualdad con $|\tau_{\text{ATE}}|$ es inmediata. La no negatividad de la brecha es el Teorema de la cadena maestra. ■

5.2 De N1 a N2

Proposición 3 (Identidad gaussiana). Si $Y(0) \sim \mathcal{N}(\mu_0, \sigma^2)$ y $Y(1) \sim \mathcal{N}(\mu_1, \sigma^2)$ con $\sigma > 0$, entonces

$$D_{\text{KL}}(P_{Y(1)} \parallel P_{Y(0)}) = \frac{(\tau_{\text{ATE}})^2}{2\sigma^2}. \quad (20)$$

En particular, D_{KL} es una función monótona creciente de $|\tau_{\text{ATE}}|$ en esta familia (pierde el signo).

Demostración. Cálculo estándar de la KL entre gaussianas homocedásticas. ■

Observación 5. No se dirá que “el ATE es el primer momento de la KL”: la KL es un escalar y depende del **cuadrado** de τ_{ATE} .

Teorema 4 (Puente de Pinsker para el ATE). Supóngase que $Y(1), Y(0)$ toman valores en un conjunto $\mathcal{Y} \subseteq \mathbb{R}$ de diámetro finito $D := \text{diam}(\mathcal{Y})$, y adoptemos la convención

$$D_{\text{TV}}(P, Q) := \sup_A |P(A) - Q(A)|. \quad (21)$$

Entonces

$$|\tau_{\text{ATE}}| \leq D \cdot D_{\text{TV}}(P_{Y(1)}, P_{Y(0)}) \leq D \cdot \sqrt{\frac{1}{2} D_{\text{KL}}(P_{Y(1)} \parallel P_{Y(0)})}. \quad (22)$$

Demostración. Trasladando si hace falta, podemos asumir $\mathcal{Y} \subseteq [0, D]$. Entonces $0 \leq Y \leq D$ c.s. bajo ambas leyes, y

$$|\tau_{\text{ATE}}| = |E[Y(1)] - E[Y(0)]| = \left| \int_0^D (P_{Y(1)}(Y > t) - P_{Y(0)}(Y > t)) dt \right| \leq \int_0^D D_{\text{TV}}(P_{Y(1)}, P_{Y(0)}) dt = D \cdot D_{\text{TV}}(P_{Y(1)}, P_{Y(0)}).$$

La segunda desigualdad es Pinsker: $D_{\text{TV}} \leq \sqrt{(1/2)D_{\text{KL}}}$ [22]. ■

Gramática uniforme de la jerarquía: cada nivel superior acota al inferior; el recíproco es falso. Un Nivel 2 pequeño fuerza un Nivel 1 pequeño; un ATE grande fuerza divergencias grandes.

5.3 De N2 a N3

Teorema 5 (TV como transporte óptimo elemental). Sea $d_{01}(x, y) := \mathbb{1}[x \neq y]$. Entonces

$$D_{\text{TV}}(P, Q) = W_1^{d_{01}}(P, Q), \quad (24)$$

la distancia de Wasserstein-1 calculada con la métrica discreta d_{01} [23].

Teorema 6 (Cota por diámetro). Si $(\mathcal{Y}, d)$ tiene diámetro finito, entonces

$$W_1(P, Q) \leq \text{diam}(\mathcal{Y}) \cdot D_{\text{TV}}(P, Q). \quad (25)$$

(El enunciado es estándar en transporte óptimo; cf. [11, cap. 6], [23].)

Proposición 4 (No-dominancia (ambas direcciones)). Ninguna de D_{TV} , W_1 domina a la otra en $\mathcal{P}_1(\mathbb{R})$:

1. No existe $c < \infty$ tal que $D_{\text{TV}}(P, Q) \leq c W_1(P, Q)$ para todo P, Q .
2. No existe $c' < \infty$ tal que $W_1(P, Q) \leq c' D_{\text{TV}}(P, Q)$ para todo P, Q (la Cota por diámetro recupera esta dirección solo cuando $\mathcal{Y}$ es acotado).

En particular, $D_{\text{TV}} \leq W_1$ es **falsa** en general, incluso restringida a familias unimodales simétricas.

Demostración. (1) **D_{TV} no domina a W_1 (falla la desigualdad «cota inferior»).** Fijado $\delta > 0$, tómesese $P_n = \mathcal{N}(0, \varepsilon_n^2)$ y $Q_n = \mathcal{N}(\delta, \varepsilon_n^2)$ con $\varepsilon_n \rightarrow 0$ (p. ej. $\varepsilon_n = \delta/n$). Entonces $W_1(P_n, Q_n) = \delta$ para todo n (traslación pura), mientras $D_{\text{TV}}(P_n, Q_n) \rightarrow 1$ cuando $\varepsilon_n \rightarrow 0$. Tomando ahora una sucesión $\delta_n \rightarrow 0$ con $\varepsilon_n \ll \delta_n$ en cada paso, se tiene simultáneamente $W_1 = \delta_n \rightarrow 0$ y $D_{\text{TV}} \rightarrow 1$; cualquier c que satisfaga $D_{\text{TV}} \leq c W_1$ debería cumplir $c \geq 1/\delta_n \rightarrow \infty$, contradicción.

(2) **W_1 no domina a D_{TV} (dirección faltante: masa que escapa).** Sea P cualquier ley con soporte no acotado y momento finito, y $Q_n := (1 - 1/n)P + (1/n)\delta_{n^2}$ (se desplaza una fracción $1/n$ de la masa a un átomo lejano). Como P es difusa, $D_{\text{TV}}(P, Q_n) = (1/n) \sup_A |P(A) - \mathbb{1}[n^2 \in A]| = 1/n \rightarrow 0$. Pero el transporte óptimo debe mover la fracción $1/n$ hasta n^2 , de costo $\approx (1/n)(n^2 - E_P[X]) \approx n \rightarrow \infty$. Ningún c' fijo satisface $W_1 \leq c' D_{\text{TV}}$ para todo n . ■

n	D_{TV}	W_1 (aprox.)
10	0.100	9.97
100	0.010	98.89
1000	0.001	987.50

Tabla 3: Dirección faltante de la no-dominancia: masa que escapa. $D_{\text{TV}} \rightarrow 0$ mientras $W_1 \rightarrow \infty$ (verificado con $P = \text{Unif}(0, 1)$, $N = 2 \times 10^6$ muestras, semilla 42).

Observación 6 (Lectura estadística, no jerárquica). Ninguna de las dos discrepancias es «mejor»: responden a preguntas distintas. W_1 es sensible a colas y valores atípicos porque pondera el costo por la distancia recorrida; D_{TV} los ignora porque solo cuenta masa reasignada, sin importar cuán lejos viaje. El Teorema de cota por diámetro recupera $W_1 \leq \text{diam}(\mathcal{Y}) D_{TV}$ **únicamente** cuando el espacio es acotado —precisamente porque ahí no hay «distancia» en la que la masa pueda escapar—.

Observación 7 (Superioridad axiomática, no métrica). La superioridad del Nivel 3 sobre el Nivel 2 es **axiomática**: W_1 satisface los Axiomas 2, 3 y 4a que toda D_f viola. No es una dominancia métrica universal. En particular, **no** se afirma que $\lim_{\varepsilon \rightarrow 0} W_{1,\varepsilon} = D_{TV}$ para la regularización entrópica: cuando $\varepsilon \rightarrow 0$, el transporte entrópico recupera W_1 sin regularizar [5], [24].

5.4 Síntesis de la progresión

- $N1 \rightarrow N2$ es necesario porque $\mathcal{D}_{\text{loc}}$ viola el Axioma 1.
- $N2 \rightarrow N3$ es necesario porque toda D_f viola los Axiomas 2, 3 y 4a.
- $N3$ se completa con $W^{G,1}$ porque W_1 compara solo marginales y viola el Axioma 4b (bajo (H)).

6 La Paradoja del Efecto Cero

6.1 Enunciado y cota de Jensen

Proposición 5 (Paradoja del Efecto Cero — versión simplificada). Sean $P_0 = \mathcal{N}(0, 1)$ y

$$P_1 = \frac{1}{2} \mathcal{N}(-a, \sigma^2) + \frac{1}{2} \mathcal{N}(a, \sigma^2), \quad a > 0, \sigma > 0. \quad (26)$$

Entonces

$$E_{P_1}[Y] - E_{P_0}[Y] = 0 \quad (27)$$

y

$$W_1(P_1, P_0) \geq a - \sqrt{\frac{2}{\pi}} > 0 \quad \text{para } a > \sqrt{\frac{2}{\pi}}. \quad (28)$$

La cota inferior **no depende** de σ .

Demostración. Paso 1 (ATE nulo). Por simetría de P_1 en torno a 0, $E_{P_1}[Y] = 0 = E_{P_0}[Y]$.

Paso 2 (cota dual). La función $f(y) = |y|$ es 1-Lipschitz. Por dualidad KR,

$$W_1(P_1, P_0) \geq \int |y| dP_1(y) - \int |y| dP_0(y). \quad (29)$$

Para P_0 : $\int |y| dP_0 = E[|Z|] = \sqrt{2/\pi}$ con $Z \sim \mathcal{N}(0, 1)$. Para P_1 : la ley de $|Y|$ bajo P_1 coincide con la de $|a + \sigma Z|$ (mezcla simétrica de dos gaussianas centradas en $\pm a$). Por convexidad de $|\cdot|$ y Jensen,

$$E[|a + \sigma Z|] \geq |E[a + \sigma Z]| = a. \quad (30)$$

Por tanto $W_1(P_1, P_0) \geq a - \sqrt{2/\pi}$, estrictamente positiva si $a > \sqrt{2/\pi}$. ■

Observación 8 (Cota ingenua falsa). La desigualdad $W_1 \geq a - \sigma\sqrt{2/\pi}$ es **falsa** en general. Contraejemplo numérico: $a = 1$, $\sigma = 0.5$ (cumple $a > \sigma\sqrt{2/\pi} \approx 0.40$), pero $W_1 \approx 0.248 < 0.601 = a - \sigma\sqrt{2/\pi}$. La falla típica de la “demostración” ingenua es omitir la resta de $E_{P_0}|Y| = \sqrt{2/\pi}$ o tratar incorrectamente el factor σ dentro de la cota dual.

6.2 Verificación numérica de la cota de Jensen

a	σ	$a - \sqrt{2/\pi}$	W_1 (cuadratura)	¿OK?
2.0	1.0	1.2021	1.2191	✓
1.0	0.5	0.2021	0.2477	✓
0.9	0.1	0.1021	0.4291	✓
1.0	1.0	0.2021	0.3687	✓

Tabla 4: Verificación de $W_1(P_1, P_0) \geq a - \sqrt{2/\pi}$ en cuatro parametrizaciones. W_1 calculado **exactamente** por cuadratura de $\int |F_1 - F_0|$ (no Monte Carlo): error de cuadratura $< 10^{-8}$ en los cuatro casos.

6.3 KL de mezclas: desigualdad, no igualdad

Proposición 6 (Cota de Jensen para la KL de una mezcla). Con P_0 y P_1 como en la Proposición de la paradoja,

$$D_{\text{KL}}(P_1 \parallel P_0) \leq \frac{1}{2} \sum_{i \in \{\pm 1\}} D_{\text{KL}}(\mathcal{N}(ia, \sigma^2) \parallel P_0) = \frac{a^2}{2} + \frac{\sigma^2}{2} - \frac{1}{2} - \frac{1}{2} \log(\sigma^2). \quad (31)$$

La igualdad **no** vale en general: la KL de una mezcla no es la combinación lineal de las KL de sus componentes. El valor exacto se obtiene por cuadratura de $\int p_1 \log(p_1/p_0)$.

Demostración. La forma cerrada $D_{\text{KL}}(\mathcal{N}(\mu, \sigma^2) \parallel \mathcal{N}(0, 1)) = -\log \sigma + (\sigma^2 + \mu^2 - 1)/2$ da el mismo valor para $\mu = \pm a$ (depende solo de a^2), de modo que el promedio sobre las dos componentes es esa cantidad sin duplicar. La desigualdad es la convexidad conjunta $(p, q) \mapsto D_{\text{KL}}(p \parallel q)$ en el primer argumento sobre el simplex, aplicada a la mezcla finita. ■

a	σ	Promedio real	Cota corregida
1	1	0.500000	0.500000
2	1	2.000000	2.000000
1	0.5	0.818147	0.818147
0.9	0.1	2.212585	2.212585
1.5	2	1.931853	1.931853

Tabla 5: Verificación numérica de la Proposición: promedio real de las KL de componentes frente a la cota corregida (coinciden por construcción) y frente a la expresión $a^2 + \sigma^2 - 1 - \log(\sigma^2)$ que aparecía —erróneamente duplicada por un factor 2— en una versión previa de este manuscrito.

7 Experimento canónico

Ilustramos la jerarquía con un DGP de presión arterial (mmHg), diseñado para que el control y el tratamiento compartan la **misma media poblacional**, de modo que el Nivel 1 sea ciego y el Nivel 3 no.

Diseño.

- Control: $Y(0) \sim \mathcal{N}(120, 12^2)$.
- Tratamiento (mezcla de respondedores y no respondedores):

$$Y(1) \sim \frac{1}{2} \mathcal{N}(105, 8^2) + \frac{1}{2} \mathcal{N}(135, 10^2). \quad (32)$$

Media de la mezcla: $(105 + 135)/2 = 120$.

- Muestra: $n = 5000$, semilla 42, implementación vía `numpy` / `scipy.stats.wasserstein_distance`.

Estimadores reportados.

- Nivel 1: $\widehat{\tau_{ATE}} = \bar{Y}_1 - \bar{Y}_0$.
- Nivel 2: $\hat{D}_{KL}$ por histograma en $[60, 180]$ con 60 bins (estimador grosero, solo diagnóstico).
- Nivel 3: $\hat{W}_1$ empírica unidimensional.
- Cota dual empírica: $|\bar{Y}_1 - 120| - |\bar{Y}_0 - 120|$, que por KR con $f(y) = |y - 120|$ es $\leq \hat{W}_1$.

Objeto	Valor	Lectura GCE
ATE	-0.137 mmHg	Nivel 1: 0 (ruido muestral)
D_{KL} (hist.) ³	0.364 nats	Nivel 2: detecta forma
W_1	6.050 mmHg	Nivel 3: costo de reorganización
Cota dual	6.029	$\leq W_1$ (KR) ✓
Cadena	$0.137 \leq 6.050$	$ \tau_{ATE} \leq W_1$ ✓

Tabla 6: Salida del experimento canónico (semilla 42, $n = 5000$). Código: `code/ejemplo_paradoja_canonico.py`.

Interpretación. El tratamiento reorganiza, en promedio, unos 6 mmHg de presión arterial por paciente para transformar la distribución control en la tratada, pese a que el promedio poblacional no se mueve. El Nivel 1 declara “sin efecto”; el Nivel 3 cuantifica el costo de la reconfiguración bimodal (respondedores vs. no respondedores).

Observación 9 (Contrato Proofs-to-Python). Todo pipeline que reporte ATE y W_1 sobre el mismo par de muestras debe poder ejecutar

```
assert abs(tau_ate) <= w1 + 1e-6
assert cota_dual <= w1 + 1e-6
```

Una violación numérica de una desigualdad demostrada delata un bug del pipeline, no un hallazgo científico. Este principio es el eje de §8, donde se amplía a un contrato verificable de cinco puntos.

³Estimador grosero y sensible al número de bins: 0.3495 nats (30 bins), 0.3635 (60 bins, valor reportado), 0.3966 (120 bins) —seed 42, $n = 5000$ —. Tómese como diagnóstico cualitativo de Nivel 2, no como cifra de precisión.

8 Implicaciones para la práctica causal

La jerarquía no reemplaza los métodos de identificación y estimación; los **clasifica** y les impone un contrato de coherencia.

Familia	Nivel GCE	Nota
RCT, matching, IPW/AIPW, IV/LATE, RDD, DiD, SC clásico	N1	Estiman funcionales de localización (posiblemente locales o en subpoblaciones)
DML, meta-learners, causal forests	N1 + ML	Misma localización/CA-TE; nuisances de alta dimensión [4]
QTE, procesos contrafactuales de forma	N2	Forma; en $\mathbb{R}$, $W_1 = \int_0^1 Q_1 - Q_0 $
f -sensibilidad, E-values	N2 como presupuesto	Robustez del N1 parametrizada por D_f [18]
SC distribucional, DiD por transporte	N3	Baricentros / mapas de transporte [6]
PC, FCI, GES, LiNGAM	Precondición	Estructura $\mathcal{G}$, no métrica de efecto
Funcionales do / OPE secuencial	N3 causal	Topología bicausal / $W^{G,1}$ bajo (H)

Tabla 7: Lectura GCE de familias metodológicas frecuentes.

Regla de decisión. Antes de elegir estimador: ¿la pregunta es de centro, de forma o de costo de reasignación? Un error de nivel es un error de tipo III: responder con precisión una pregunta distinta de la que se formuló.

8.1 Contrato de coherencia (formalización verificable)

Una violación numérica de una desigualdad demostrada delata un bug del pipeline, no un hallazgo científico (Observación de la §7). Formalizamos ese principio en cinco puntos, cada uno verificable por máquina:

1. **Declaración de nivel.** Antes de estimar, declarar explícitamente si la pregunta es de localización, forma o costo de reasignación (evita el error de tipo III de la regla de decisión anterior).
2. **Cadena maestra empírica.** $\|\hat{\tau}_{ATE}\| \leq \hat{W}_1 \leq \hat{W}^{G,1}$ sobre las mismas muestras.
3. **Cota dual.** $E_{\hat{P}}[f] - E_{\hat{Q}}[f] \leq \hat{W}_1$ para cualquier f 1-Lipschitz reportada (p. ej. $f(y) = |y - c|$).
4. **No negatividad.** $\hat{D}_{loc}, \hat{D}_f, \hat{W}_1, \hat{W}^{G,1} \geq 0$ siempre.
5. **Trazabilidad de la Precondición.** Reportar la clase de equivalencia estructural usada ($\hat{\mathcal{G}}$ o su CPDAG/PAG), no un DAG puntual sin incertidumbre declarada.

Nota de cautela. El contrato atrapa errores reales. Bajo traslación pura ($Y(1) \stackrel{d}{=} Y(0) + c$), el Corolario de igualdad exige $W_1 = |c| = |\tau_{ATE}|$. Verificado: con $Y(0) \sim \mathcal{N}(0, 1)$, $c = 5$, $n = 5000$ (semilla 42), $\hat{\tau}_{ATE} = 5.000$ y el W_1 correcto reproduce 5.000. Basta que un estimador de W_1 tenga la constante mal puesta —p. ej. un factor 0.5 de más en una normalización— para obtener $\hat{W}_1 = 2.500 < \hat{\tau}_{ATE}$: el punto 2 del contrato falla de inmediato, señalando el bug antes de que contamine ninguna conclusión sustantiva.

9 Discusión y limitaciones

1. **Identificación vs. discrepancia.** Este paper fija el **objeto** $\tau_{\mathcal{D}}$ y sus relaciones. La identificación de $P_{Y(t)}$ a partir de datos observacionales sigue requiriendo supuestos (ignorabilidad, IV, frontdoor, proximal, ...) desarrollados en el libro DES504 y en [3], [15].
2. **Hipótesis (H) de $W^{G,1}$.** La mitad negativa del Axioma 4b —que W_1 falla como cota intervencional— queda demostrada en este paper de forma autocontenida (§3.3.1). Lo que sigue apoyado en [12] es únicamente la mitad positiva y general: que $W^{G,1}$ satisface 4b para toda la clase de funcionales intervencionales de interés, más allá del ejemplo. Hasta fijar ese enunciado general con hipótesis completas en una versión revisada, tratamos esa mitad como resultado condicional (H) y mantenemos Ecuación 12 como hecho elemental.
3. **Números de teorema en [11].** La metrización de la convergencia débil, la cota $\text{diam} \cdot \text{TV}$ y la completitud de $(\mathcal{P}_1, W_1)$ se citan por capítulo (cap. 6) sin fijar números de teorema hasta cotejo editorial final.
4. **Dimensión: la desigualdad y la estimación son hechos distintos.** El experimento y la fórmula $W_1 = \int |F - G|$ son unidimensionales, pero la cadena maestra se extiende a $\mathbb{R}^d$ en su forma fuerte, no solo coordenada a coordenada. Para $u \in \mathbb{R}^d$ con $\|u\|_2 = 1$, la función $f(y) = \langle u, y \rangle$ es 1-Lipschitz⁴, luego por dualidad KR $|\langle u, \tau_{\text{ATE}} \rangle| \leq W_1(P_{Y(1)}, P_{Y(0)})$ para todo u (con τ_{ATE} visto como vector en $\mathbb{R}^d$); tomando el supremo (alcanzado en $u = \tau_{\text{ATE}} / \|\tau_{\text{ATE}}\|_2$) se obtiene

$$\|\tau_{\text{ATE}}\|_2 \leq W_1(P_{Y(1)}, P_{Y(0)}). \quad (33)$$

Esta desigualdad es exacta y no depende de d : verificado con $\tau \in \mathbb{R}^5$ aleatorio (semilla 42), $\|\tau\|_2 = 2.5355$ frente a $\sup_{\|u\|=1} |\langle u, \tau \rangle| = 2.5016$ sobre 4000 direcciones aleatorias (el óptimo exacto en $u^* = \tau / \|\tau\|$ recupera 2.5355). Lo que sí se degrada con d es la **estimación** empírica de W_1 a partir de muestras finitas (maldición de dimensionalidad estadística); ese es un problema de estimación, no una debilidad de Ecuación 33, y ambos hechos no deben mezclarse.

5. **Alcance.** No desarrollamos aquí descubrimiento causal algorítmico, ni agentes basados en LLM, ni una monografía de métodos. Esos temas consumen la jerarquía; no la definen.

10 Conclusión

Hemos condensado la teoría de la jerarquía GCE necesaria para anclar un curso y una monografía de inferencia causal aplicada: un objeto único $\tau_{\mathcal{D}}$, tres niveles, un scorecard axiomático con 4a/4b, la cadena maestra Ecuación 3, puentes inter-nivel verificables, y la Paradoja del Efecto Cero como obstrucción canónica al promedio. El experimento de la Tabla 6 hace el marco ejecutable. La regla metodológica residual es simple: **ninguna cota se enseña, se publica ni se automatiza sin ejecutarse**.

Apéndice A: Cotas falsas frecuentes (contraejemplos)

Observación 10 (Nota de proceso). Una versión previa de este manuscrito reportaba en la Proposición de cota de Jensen para la KL de una mezcla (§6.3) la expresión $a^2 + \sigma^2 - 1 - \log(\sigma^2)$, exactamente el doble del promedio real de las KL de componentes. El error se detectó al ejecutar la verificación numérica exigida por el contrato Proofs-to-Python del propio paper (Observación 6)

⁴Notación: $\langle \cdot, \cdot \rangle$ denota el producto interno euclidiano.

y se corrigió antes de esta versión (ver Tabla 5). Un manuscrito cuya tesis es que **ninguna cota se enseña, se publica ni se automatiza sin ejecutarse** debe, ante todo, aplicarse esa regla a sí mismo.

A.1 Pseudo-cota D_f en función de $\tau_{\text{ATE}}/E[Y(0)]$

La desigualdad del tipo

$$D_f(P_{Y(1)} \parallel P_{Y(0)}) \geq f' \left(1 + \frac{\tau_{\text{ATE}}}{E[Y(0)]} \right) \cdot \left(\frac{\tau_{\text{ATE}}}{E[Y(0)]} \right) \quad (34)$$

es **falsa** como cota general. La divergencia D_f es invariante ante la traslación común $Y \mapsto Y + c$ (la razón de verosimilitud no cambia), mientras que el lado derecho depende de $E[Y(0)]$ y puede hacerse arbitrariamente grande tomando $E[Y(0)] \rightarrow 0$ con τ_{ATE} fijo; además es indefinido si $E[Y(0)] = 0$. El reemplazo correcto es el Teorema de Pinsker de la §5.

A.2 Límite entrópico y variación total

No vale $\lim_{\varepsilon \rightarrow 0} W_{1,\varepsilon} = D_{\text{TV}}$. El transporte óptimo con regularización entrópica converge a W_1 **sin regularizar** cuando $\varepsilon \rightarrow 0$ [5]. El sentido exacto en que el OT generaliza a TV es el Teorema TV- d_{01} de la §5.

A.3 KL de mezcla como suma de KLs

Tratar

$$D_{\text{KL}} \left(\frac{1}{2}P_a + \frac{1}{2}P_{-a} \parallel P_0 \right) = \frac{1}{2}D_{\text{KL}}(P_a \parallel P_0) + \frac{1}{2}D_{\text{KL}}(P_{-a} \parallel P_0) \quad (35)$$

como igualdad es incorrecto; solo vale $\leq$ (Proposición de la §6). El factor de sobreestimación de la cota frente al valor exacto (cuadratura) **no está acotado**: diverge cuando $a \rightarrow 0$ (la KL exacta colapsa a cero más rápido que la cota lineal en a^2) y tiende a 1 cuando a crece y las componentes se separan. No existe un rango fijo «entre 2 y 6»; la tabla siguiente lo ilustra con $\sigma = 1$ salvo donde se indica.

a	KL exacta	Cota corregida	Factor
0.5	0.0136	0.1250	9.21
1 ($\sigma = 0.5$)	0.1854	0.8181	4.41
1	0.1632	0.5000	3.06
2	1.3673	2.0000	1.46
3	3.8107	4.5000	1.18

Tabla 8: Factor cota/exacto de la KL de la mezcla, verificado por cuadratura numérica de $\int p_1 \log(p_1/p_0)$.

Apéndice B: Reproducibilidad

El script canónico vive en `code/ejemplo_paradoja_canonico.py` (idéntico al de `gce/artifacts/`). Dependencias: `numpy`, `scipy`. Ejecución:

`python3 code/ejemplo_paradoja_canonico.py`

Salida esperada (semilla 42):

Nivel 1 ATE : -0.137 mmHg
 Nivel 2 D_KL : 0.364 nats
 Nivel 3 W1 : 6.050 mmHg
 Cota dual : 6.029 $\leq$ W1 = 6.050 [OK]
 Cadena maestra : |ATE| = 0.137 $\leq$ W1 = 6.050 [OK]

Agradecimientos

Este companion teórico condensa y corrige el marco GCE del curso DES504 (UNI, 2026). Las marcas de cautela sobre [12] y los números de teorema de [11] se mantienen deliberadamente hasta cotejo final con las fuentes primarias.

Referencias

- [1] D. B. Rubin, «Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies», *Journal of Educational Psychology*, vol. 66, n.º 5, pp. 688-701, 1974.
- [2] G. W. Imbens y D. B. Rubin, *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press, 2015.
- [3] J. Pearl, *Causality: Models, Reasoning, and Inference*, 2.^a ed. Cambridge University Press, 2009.
- [4] V. Chernozhukov *et al.*, «Double/debiased machine learning for treatment and structural parameters», *The Econometrics Journal*, vol. 21, n.º 1, pp. C1-C68, 2018.
- [5] G. Peyré y M. Cuturi, «Computational Optimal Transport», *Foundations and Trends in Machine Learning*, vol. 11, n.º 5–6, pp. 355-607, 2019.
- [6] F. F. Gunsilius, «Distributional Synthetic Controls», *Econometrica*, vol. 91, n.º 3, pp. 1105-1117, 2023.
- [7] K. Doksum, «Empirical Probability Plots and Statistical Inference for Nonlinear Models in the Two-Sample Case», *The Annals of Statistics*, vol. 2, n.º 2, pp. 267-277, 1974.
- [8] J. J. Heckman, J. Smith, y N. Clements, «Making the Most Out of Programme Evaluations and Social Experiments: Accounting for Heterogeneity in Programme Impacts», *The Review of Economic Studies*, vol. 64, n.º 4, pp. 487-535, 1997.
- [9] V. Chernozhukov, I. Fernández-Val, y B. Melly, «Inference on Counterfactual Distributions», *Econometrica*, vol. 81, n.º 6, pp. 2205-2268, 2013.
- [10] S. Firpo, «Efficient Semiparametric Estimation of Quantile Treatment Effects», *Econometrica*, vol. 75, n.º 1, pp. 259-276, 2007.
- [11] C. Villani, *Optimal Transport: Old and New*, vol. 338. en Grundlehren der mathematischen Wissenschaften, vol. 338. Springer, 2009.
- [12] P. Cheridito y S. Eckstein, «Optimal transport and Wasserstein distances for causal models», *Bernoulli*, vol. 31, n.º 2, pp. 1351-1376, 2025.
- [13] P. W. Holland, «Statistics and Causal Inference», *Journal of the American Statistical Association*, vol. 81, n.º 396, pp. 945-960, 1986.
- [14] J. Peters, D. Janzing, y B. Schölkopf, *Elements of Causal Inference: Foundations and Learning Algorithms*. MIT Press, 2017.
- [15] M. A. Hernán y J. M. Robins, *Causal Inference: What If*. Chapman & Hall/CRC, 2020.

- [16] I. Csiszár, «Information-type measures of difference of probability distributions and indirect observation», *Studia Scientiarum Mathematicarum Hungarica*, vol. 2, pp. 299-318, 1967.
- [17] X. Nguyen, M. J. Wainwright, y M. I. Jordan, «Estimating Divergence Functionals and the Likelihood Ratio by Convex Risk Minimization», *IEEE Transactions on Information Theory*, vol. 56, n.º 11, pp. 5847-5861, 2010.
- [18] Y. Jin, Z. Ren, y E. J. Candès, «Sensitivity Analysis of Individual Treatment Effects: A Robust Perspective», *Journal of the Royal Statistical Society: Series B*, 2023.
- [19] F. Santambrogio, *Optimal Transport for Applied Mathematicians*. Birkhäuser, 2015.
- [20] J. Backhoff-Veraguas, D. Bartl, M. Beiglböck, y M. Eder, «Adapted Wasserstein distances and stability in mathematical finance», *Finance and Stochastics*, vol. 24, pp. 601-632, 2020.
- [21] G. C. Pflug y A. Pichler, *Multistage Stochastic Optimization*. Springer, 2014.
- [22] Y. Polyanskiy y Y. Wu, *Information Theory: From Coding to Learning*. Cambridge University Press, 2024.
- [23] A. L. Gibbs y F. E. Su, «On Choosing and Bounding Probability Metrics», *International Statistical Review*, vol. 70, n.º 3, pp. 419-435, 2002.
- [24] M. Cuturi, «Sinkhorn Distances: Lightspeed Computation of Optimal Transport», *Advances in Neural Information Processing Systems*, vol. 26, 2013.