

SILABUS

CURSO: INFERENCIA CAUSAL APLICADA CON PYTHON

I. DESCRIPCIÓN DEL CURSO

CICLO ACADÉMICO : SEMESTRE 2026-I
HORAS LECTIVAS : 03 HORAS / SEMANA
PRE-REQUISITOS : -
DOCENTE : DR. JAIME LINCOVIL CURIVIL
E-MAIL : jlincovilc@uni.edu.pe

II. SUMILLA DEL CURSO

El curso *Inferencia Causal Aplicada con Python* proporciona una formación rigurosa en los fundamentos teóricos y aplicaciones computacionales del análisis causal, basada en el texto *Inferencia Causal Aplicada con Python* (Lincovil, 2026). Se abordan los cuatro bloques temáticos del libro: (I) Fundamentos y métodos clásicos bajo la Jerarquía GCE; (II) Modelos Causales Estructurales y do-cálculo; (III) Descubrimiento causal y aprendizaje automático para efectos heterogéneos; (IV) Causal AI, equidad y frontera tecnológica. Los estudiantes desarrollarán un proyecto aplicado en tres etapas (planificación, ejecución primaria, finalización), implementando métodos como matching, IPW, IV, DiD, SynC, SCM, DML, Causal Forests y NCMs utilizando librerías como DoWhy, EconML, causal-learn y POT.

III. COMPETENCIAS

Competencia General

Diseñar, implementar y validar estudios de inferencia causal en datos observacionales y experimentales, aplicando métodos clásicos y avanzados en Python con rigor metodológico, transparencia en supuestos y comunicación efectiva de resultados para la toma de decisiones en políticas públicas, economía y ciencia de datos.

Competencias Específicas

- Diferenciar causalidad de correlación mediante el marco de resultados potenciales, la Jerarquía GCE y modelos gráficos causales.
- Aplicar métodos de identificación causal: backdoor, frontdoor, IV, RDD, DiD y SynC bajo supuestos explícitos.
- Implementar estimadores doblemente robustos, DML y meta-learners para efectos heterogéneos con garantías de inferencia.
- Ejecutar descubrimiento causal estructural mediante algoritmos PC, FCI, GES y LiNGAM con validación de sensibilidad.
- Integrar modelos causales con arquitecturas de IA (NCMs, LLMs) y evaluar equidad mediante análisis de caminos lícitos/ilícitos.

- Validar inferencias mediante análisis de sensibilidad (E-value, Rosenbaum), pruebas de placebo y estrés distribucional.
- Gestionar un proyecto causal completo desde la formulación de la pregunta hasta la comunicación de resultados reproducibles.

IV. ESTRATEGIA DIDÁCTICA

Clases magistrales con discusión teórica seguida de laboratorios prácticos en Python. Cada sesión integra dos capítulos del texto base, combinando demostraciones formales con implementación computacional. El proyecto aplicado se desarrolla en tres hitos con retroalimentación iterativa. La evaluación combina revisión técnica automatizada, coevaluación estructurada y validación muestral por el docente.

V. UNIDADES DE APRENDIZAJE

UNIDAD I: Fundamentos y métodos clásicos bajo la Jerarquía GCE (Clases 1–4; Capítulos 1–12)

Establece las bases teóricas: paradoja del efecto cero, métricas de Wasserstein, SUTVA, ATE y sus limitaciones (Cap. 1–2). Desarrolla métodos de selección sobre observables: CIA, matching, propensity score, IPW y doble robustez (Cap. 3–4). Aborda identificación bajo endogeneidad: variables instrumentales, LATE y taxonomía de respondientes (Cap. 5–6). Cubre diseños cuasi-experimentales: RDD, DiD (incl. Goodman-Bacon), SynC y análisis de mediación (Cap. 7–10). Concluye con sensibilidad, validación y pipeline unificado (Cap. 11–12).

UNIDAD II: Modelos Causales Estructurales y do-cálculo (Clases 5–8; Capítulos 13–20)

Introduce SCM, asimetría causal, operador $do(\cdot)$ y condición de Markov (Cap. 13). Desarrolla DAGs, conectores fundamentales y d-separación (Cap. 14). Estudia criterios de identificación: backdoor, frontdoor y do-calculus (Cap. 15–17). Aborda mediación formal, contrafactuales individuales y flujo de trabajo causal con sensibilidad (Cap. 18–20).

UNIDAD III: Descubrimiento causal y aprendizaje automático para efectos heterogéneos (Clases 9–12; Capítulos 21–26)

Presenta descubrimiento estructural: PC, FCI, GES, LiNGAM, NOTEARS y validación (Cap. 21–22). Fundamenta aprendizaje causal vs. predictivo, invariancia e ICP (Cap. 23–24). Desarrolla meta-learners (S/T/X/R), DML ortogonalizado y bosques causales con inferencia válida (Cap. 25–26). Extiende a series de tiempo, paneles escalonados y evaluación de políticas (Cap. 27–28).

UNIDAD IV: Causal AI, equidad y frontera tecnológica (Clases 13–16; Capítulos 27–32)

Explora OPE, bandits contextuales y política óptima (Cap. 27). Estudia representaciones causales, IRM y modelos generativos (CausalVAE) (Cap. 28). Aborda RL causal, CMDP y exploración informada por estructura (Cap. 29). Integra arquitecturas de IA causal (NCMs,

LLMs+motor causal) (Cap. 30). Analiza equidad causal, caminos lícitos/ilícitos y regulación (Cap. 31). Concluye con hoja de ruta, problemas abiertos y síntesis del curso (Cap. 32).

VI. DESCRIPCIÓN CLASE A CLASE

Clase	Contenido y capítulos asociados
1	Paradoja del efecto cero y problema fundamental (Cap. 1–2). Jerarquía GCE, Wasserstein como métrica causal, SUTVA, ATE y su ceguera estructural. Simulación de sesgo de selección y validación RCT en Python.
2	Matching y ponderación (Cap. 3–4). CIA, maldición dimensional, Mahalanobis, propensity score, IPW estabilizado y AIPW. Implementación de doble robustez y eficiencia semiparamétrica.
3	Instrumentos y LATE (Cap. 5–6). Endogeneidad, validez instrumental, 2SLS, taxonomía de respondientes, teorema LATE e ITT. Conexión algebraica IV–RDD fuzzy.
4	Diseños cuasi-experimentales (Cap. 7–10). RDD sharp/fuzzy, estimación local, DiD canónico y TWFE, descomposición Goodman-Bacon, estimadores Callaway-Sant’Anna/Sun-Abraham, SynC y optimización convexa.
5	Mediación y sensibilidad (Cap. 11–12). Efectos NDE/NIE, fórmula de Pearl, colapso lineal Baron-Kenny. Cotas de Manski, Rosenbaum, E-value, ICE Stress Test y pruebas placebo.
6	SCM y DAGs (Cap. 13–14). Asimetría causal, variables exógenas/endógenas, operador $do(\cdot)$, condición de Markov. Conectores fundamentales, d-separación, fidelidad y verificación en pgmpy.
7	Identificación: backdoor y frontdoor (Cap. 15–16). Caminos de puerta trasera, criterio de ajuste, IPW como estimador backdoor. Criterio frontdoor, fórmula de identificación y ejemplo del tabaco.
8	Do-calculus y contrafactuales (Cap. 17–19). Tres reglas del do-calculus, completitud, algoritmo ID. Contrafactuales individuales, abducción-acción-predicción, PNS/PN/PS y atribución de responsabilidad.
9	Flujo de trabajo y descubrimiento causal (Cap. 20–21). Pipeline unificado, AIPW+E-value. Preparación de datos, algoritmos PC/FCI/GES/LiNGAM, métricas SHD/F1/SID y validación cruzada causal.
10	Fundamentos de aprendizaje causal (Cap. 22–23). Jerarquía de Pearl, invariancia, ICP. Meta-learners S/T/X/R, PEHE, QINI curve y targeting óptimo.
11	DML y bosques causales (Cap. 24–25). Ortogonalidad de Neyman, cross-fitting, EconML. Causal Forest, honestidad, intervalos locales y aplicaciones en medicina/marketing.
12	Serie de tiempo y evaluación de políticas (Cap. 26–27). DiD escalonado, SDiD, RNN causales. OPE, IPS, DR-OPE, bandits contextuales y política óptima como función del CATE.

Clase	Contenido y capítulos asociados
13	Representaciones causales y RL causal (Cap. 28–29). IRM, Causal-VAE, disentanglement. CMDP, Bellman causal, curiosidad causal y DTR con Q-learning.
14	Arquitecturas de IA causal y equidad (Cap. 30–31). NCMs, LLMs+motor causal, chain-of-thought causal. Equidad causal, NDE/NIE para atributo sensible, PSE ilícito y contrafactual fairness.
15	Hoja de ruta y problemas abiertos (Cap. 32). Jerarquía ED como métrica unificadora, agenda de investigación, desafíos de identificabilidad/escalabilidad/validación, ética y responsabilidad algorítmica.
16	Síntesis y defensa de proyecto (Repaso integrador). Fronteras de la inferencia causal

VII. EVALUACIÓN: PROYECTO EN TRES ETAPAS

La evaluación se basa en la ejecución de un proyecto aplicado de inferencia causal, desarrollado en tres hitos con fechas fijas de entrega:

Etapas	Entregable	Fecha límite
1. Planificación	Propuesta formal: pregunta causal, DAG justificado, estrategia de identificación, plan de datos y código esqueleto.	Fin de la 2 ^a semana de mayo
2. Ejecución primaria	Implementación parcial: estimación inicial, validación de supuestos, análisis de sensibilidad preliminar y reporte intermedio.	Fin de junio
3. Finalización	Proyecto completo: estimación robusta, sensibilidad exhaustiva, interpretación contextual, notebook reproducible e informe en L ^A T _E X.	Fin de julio

Rúbrica de evaluación (escala 0–20)

Dimensión	Criterio	Descriptor de desempeño (20 pts)
Formulación causal	Claridad de la pregunta y nivel GCE	La pregunta causal está explícitamente ubicada en Nivel 1/2/3 de la Jerarquía GCE; el estimando (ATE/LATE/CATE/NDE) está formalmente definido y justificado teóricamente.

Dimensión	Criterio	Descriptor de desempeño (20 pts)
Especificación del DAG	Rigor en supuestos y justificación de aristas	El DAG incluye todas las variables relevantes, con aristas ausentes/presentes justificadas por teoría o diseño; se documentan confusores observables/no observables y se valida d-separación.
Identificación	Aplicación correcta de criterios (back-door/frontdoor/IV)	Se demuestra algebraicamente la identificabilidad del estimando; se especifica el conjunto de ajuste mínimo o instrumento válido; se discuten limitaciones de validez externa.
Implementación	Calidad del código y uso de librerías especializadas	El notebook es modular, reproducible y utiliza librerías apropiadas (DoWhy/EconML/causal-learn); incluye cross-fitting, manejo de missing y control de semillas.
Validación y sensibilidad	Exhaustividad en pruebas de robustez	Se reportan al menos tres pruebas: placebo (variable/umbral/falso), E-value o Rosenbaum, y estrés distribucional; se interpretan los umbrales de colapso.
Interpretación	Comunicación rigurosa de resultados e incertidumbre	Los efectos se reportan con IC al 95%, se distingue entre significancia estadística y relevancia práctica, y se discuten limitaciones sin sobreinterpretar.
Originalidad y contexto	Pertinencia para el Sur Global y aporte aplicado	El proyecto aborda un problema relevante para Latinoamérica/Perú; incorpora conocimiento de dominio y propone implicancias de política o negocio.
Transparencia y ética	Documentación de supuestos, datos y uso de IA	Se declara la fuente de datos, limitaciones de medición, posibles sesgos éticos y el rol de herramientas de IA en el desarrollo; se adjunta licencia de uso.

Ponderación: Planificación (20%), Ejecución primaria (30%), Finalización (50%). La nota final se expresa en escala vigesimal (0–20). Se requiere aprobación de la Etapa 1 para continuar; la Etapa 3 es requisito para aprobar el curso.

VIII. BIBLIOGRAFÍA

Texto principal

References

Lincovil, J. y Rojas, H (2026). *Inferencia Causal Aplicada con Python*. Universidad Nacional de Ingeniería, Lima, Perú. Monografía del curso.

Lecturas complementarias

References

Angrist, J. D., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics*. Princeton University Press.

Chernozhukov, V., et al. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.

Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press.

Peters, J., Janzing, D., & Schölkopf, B. (2017). *Elements of Causal Inference*. MIT Press.

Rosenbaum, P. (2017). *Observation and Experiment*. Harvard University Press.

Wager, S., & Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *JASA*, 113(523), 1228–1242.